

金工专题报告 20180517

因子方法论之二：协方差矩阵的估计和应用 ——以风险模型和最优化复合因子权重为例

2018 年 05 月 17 日

研究结论

- 本篇报告为“因子方法论”系列报告第二篇。本文中，东吴金工详细梳理了两类学术界较为前沿的协方差矩阵估计方案。并讨论了其在两个常见案例中的应用。
- 第一类协方差估计方案为对协方差矩阵非对角线元素做稀疏化(将部分元素压缩到 0)，该类估计称为**稀疏矩阵估计类**。第二类协方差矩阵的基本思想为，通过调整样本协方差矩阵的特征值，达到优化估计精度的目的，该类估计称为**旋转不变估计类**，包括基于仿真模拟的特征值压缩估计，线性压缩估计，以及基于随机矩阵理论的非线性压缩估计。
- 针对处理矩阵种类的不同，本文也对比了两类方案的估计效果：**方案一**直接对**样本协方差矩阵**做稀疏化或旋转不变估计；**方案二**则对**样本相关系数矩阵**做稀疏化或旋转不变估计，而后在相关系数矩阵上乘以各变量的样本标准差，得到协方差矩阵的估计。
- 实证案例一对比了在风险模型中，使用不同方法估计因子收益率协方差矩阵的表现。数值模拟结果显示：对这种因子间收益波动差别很大的情形，使用方案二(相比方案一)更能提高协方差矩阵的估计精度；随着估计使用的样本量增长，各复杂方法相对简单样本协方差矩阵的精度提升幅度逐渐缩小。在实证结果中，各方法下的估计精度并未像预期中一样，随样本量增长而提升，这是由于随着估计所用样本量提高，回看窗口变长，导致估计结果相对于市场变化反应更加迟钝。基于实证结论，我们建议，使用回看窗口 126 天的方案二下的线性压缩方法去估计因子收益协方差阵。
- 实证案例二中，本文对比了以最大化复合因子 ICIR 为优化目标时，各估计方案下的最优复合因子的表现。共选取 5 个基本面因子与 4 个情绪面因子纳入因子池。除各种估计方法外，本文还尝试使用不同频率，不同回看时长的因子 IC 序列作为协方差估计的样本，回看时长及数据频率包括季度(63 天、13 周)，半年(126 天、26 周、6 个月)，一年(252 天、52 周、12 个月)。结果显示，回看窗口内样本数量越少(月频)，复杂估计方法所得到的 ICIR 比简单的样本协方差矩阵估计下得到的 ICIR 提高越多。但当回看 IC 频率较低(月频)时，复杂的估计方法也不能构成对因子等权配置的绝对优势。随着回看频率提升到周频或日频，几乎所有方法都开始大幅跑赢因子等权配置情形。综合实证结论，我们建议使用方案一，回看窗口 26 周，并配合线性压缩估计或非线性压缩估计去估计 IC 序列协方差矩阵，该方案下，复合因子年化 ICIR 高达 5.7-5.9，相比于因子等权配置下的 ICIR，提升幅度达到 30-35% 的水平。
- **风险提示：**本报告所有的结论均使用历史数据回测得到，模型在未来存在失效风险。

证券分析师 高子剑

执业证号：S0600518010001

021-60199793

gaozj@dwzq.com.cn

研究助理 陈实

021-60199793

chensh@dwzq.com.cn

相关研究

1、《因子方法论之一：基于日内模式的因子改进》2018-02-25

内容目录

1. 前言	4
2. 稀疏化矩阵估计方法介绍	4
3. 旋转不变估计方法介绍	7
4. 处理样本协方差矩阵还是处理样本相关系数矩阵?	13
5. 案例 1：风险因子协方差矩阵估计	15
6. 案例 2：最大化 ICIR 复合因子的构造	22
7. 总结	29
8. 风险提示	30

图表目录

图 1: 硬阈值法(Hard Thresholding)示例, 阈值 $w=0.05$	5
图 2: 软阈值法(Soft Thresholding)示例, 阈值 $w=0.05$	6
图 3: 数值模拟中协方差矩阵的 1000 个特征值的取值.....	10
图 4: 特征组合的在每种估计方法下的估计方差以及真实方差.....	12
图 5: 压缩估计所适用的情形.....	12
图 6: 测试区间内不同因子的日频波动率.....	19
图 7: 参与复合的 9 个子因子中性化后分三组多空对冲净值(纵轴为对数坐标系)	23
图 8: 测试区间内的各个因子的月频 IC 波动率.....	25
图 9: 不同方法下复合因子的 ICIR 相对因子等权配置下 ICIR 的提升柱状图	26
图 10: 不同方法下复合因子相对于 SampleCov 方法下的 ICIR 提升柱状图	28
表 1: 协方差矩阵估计方案汇总.....	14
表 2: 数值模拟: 不同样本量, 不同估计方案下, 协方差矩阵的估计误差	17
表 3: 数值模拟: 不同方案下, 协方差阵的估计相对于 SampleCov 方法的改善 幅度.....	18
表 4: 实证测试: 不同样本量, 不同估计方案下, 协方差矩阵的估计误差	20
表 5: 实证测试: 不同方案下, 协方差阵的估计相对于 SampleCov 方法的改善 幅度.....	21
表 6: 参与复合的 9 个子因子中性化后的(年化)ICIR 表现.....	23
表 7: 不同回看频率周期, 不同估计方法下的最优复合因子的 ICIR 对比	24
表 8: 不同方法下, 最优复合因子的 ICIR 相对因子等权配置下 ICIR 的提升	26
表 9: 不同方法下复合因子相对于 SampleCov 下的 ICIR 提升.....	28

1. 前言

本文为东吴金工“因子方法论”专题报告系列第二篇，在本篇报告中，我们将为读者阐述学术界较为前沿的协方差矩阵估计方法，并且在两个不同的情境下比较不同协方差估计方法的优势与劣势。

所谓协方差估计，是指对于一个服从协方差为 Σ 的 p 维随机变量 $R = (r_1, r_2, \dots, r_p)'$ ，当我们拿到 n 个相互独立的取自该分布的样本 $R_1, R_2, \dots, R_n$ 后，通过该样本集合得到对 Σ 的估计 $\hat{\Sigma}$ 。

协方差估计在因子投资中占有举足轻重的地位，例如，在风险模型中，只有正确估计出因子间收益率的协方差矩阵，才能准确预测投资组合在未来的波动风险，从而在组合优化中做到更精确的风险控制。在因子复合方面，为使得复合因子 ICIR 最大化，因子权重需正比于 $\Sigma_{IC}^{-1} \overline{IC}$ ，其中 Σ_{IC} 为因子 IC 序列的协方差矩阵， $\overline{IC}$ 为因子 IC 序列的期望值。只有对 Σ_{IC} 的估计足够精确，才能使该方法下得到的复合因子的 ICIR 尽量接近理论最优。

经典的统计教材中，通常建议使用样本协方差矩阵作为对真实协方差矩阵的估计，样本协方差矩阵的计算公式为 $S = \frac{1}{n-1} \sum_{t=1}^n (R_t - \bar{R})(R_t - \bar{R})'$ ，其中， $\bar{R}$ 为样本均值，为一个 $p \times 1$ 的列向量。当固定数据的维度 p 为常数时，随着样本量长度 n 趋于无穷大，大数定律告诉我们， S 将逐步收敛到真实的协方差矩阵 Σ 。

在上述情形中，暗含了假设 p/n 趋于 0，这个假设在很多情形下是无法得到满足的，例如，我们要做 9 个子因子的复合时，使用过去 12 个月的月度 IC 数据去估计因子协方差矩阵， p/n 仅为 0.75，与经典情形下 p/n 趋于 0 的假设相去甚远。更极端的情形出现在 $p/n > 1$ 时，这种情形下，样本协方差矩阵 S 甚至是不可逆的。因此，需要引入更加可靠、前提假设更加贴合实际的协方差矩阵估计方式。

本文在第二部分与第三部分中将详细介绍两类学术界最前沿的协方差矩阵估计方案，第一类估计尝试将协方差矩阵做稀疏化处理，第二类则采用调整样本协方差矩阵特征值的方法达到优化估计的目的。两类方法在学术界各自拥有大量的研究文献，为使内容尽量简洁，我们只引用其中最经典的文献，将大树的躯干绘出，而对该方向有兴趣的读者，可以通过进一步的文献阅读，补全其它枝叶。

2. 稀疏化矩阵估计方法介绍

本文介绍的第一类方法为稀疏化矩阵估计方法，其背后的逻辑可以简述为：在庞大的协方差矩阵中，假设某些变量对之间的相关系数为 0，即在所要估计的协方差矩

阵中共 $p*(p+1)/2$ 个未知系数中，将其中一部分非对角线元素固定在 0，减小了需要估计的参数个数，达到降维的目的，从而减小了协方差矩阵估计误差的累积。

将矩阵稀疏化的方法包括硬阈值法(Hard Thresholding)和软阈值法(Soft Thresholding)。其原理相似。

硬阈值法可以参考 Bickel 等[2]。该方法在操作上相当简单，可以概括为：在样本协方差矩阵的基础上，保留矩阵的对角线元素，将非对角线元素与特定的阈值 w 对比，若该元素的绝对值大于 w ，则保留，若该元素的绝对值小于 w ，则直接将该元素压缩到 0。若以公式表达，可以写成如下形式：

$$\hat{\Sigma} = (\hat{\sigma}_{ij})_{p \times p}, \hat{\sigma}_{ij} = \begin{cases} s_{ij}, & i = j \\ s_{ij}, & i \neq j \text{ and } |s_{ij}| > w \\ 0, & i \neq j \text{ and } |s_{ij}| \leq w \end{cases}$$

其中， s_{ij} 为样本协方差矩阵 $S = \frac{1}{n-1} \sum_{t=1}^n (R_t - \bar{R})(R_t - \bar{R})'$ 的第 i 行第 j 列的元素。

图 1：硬阈值法(Hard Thresholding)示例，阈值 $w=0.05$

$$\begin{pmatrix} 1.00 & 0.20 & 0.08 \\ 0.20 & 1.00 & 0.04 \\ 0.08 & 0.04 & 1.00 \end{pmatrix} \xrightarrow{w=0.05} \begin{pmatrix} 1.00 & 0.20 & 0.08 \\ 0.20 & 1.00 & 0.00 \\ 0.08 & 0.00 & 1.00 \end{pmatrix}$$

数据来源：东吴证券研究所

Bickel 等[2]证明，当真实的协方差矩阵满足一定的稀疏条件的前提下，根据样本观察值个数 n 和数据维度 p ，选择合适的阈值 $w = w(n, p)$ ，可以使得该估计在特定范数 ($\|\hat{\Sigma} - \Sigma\|_2 = \lambda_{\max}^{\frac{1}{2}}((\hat{\Sigma} - \Sigma)'(\hat{\Sigma} - \Sigma))$ ， $\lambda_{\max}(\cdot)$ 为求最大特征值的函数) 下收敛于真实的协方差矩阵。

在硬阈值法中，凡是绝对值超过阈值 w 的协方差矩阵的非对角元素，都没有被额外处理。

而在软阈值方法中，对于每个非对角线元素，即便大小超过了对应阈值，也应做相应的处理，例如线性软阈值：每个非对角线元素与阈值 w 对比，若绝对值大于 w ，则保留其正负号，同时，将其绝对值缩小 w ；若绝对值小于等于 w ，则直接将该非对角线元素压缩至 0。若以公式表达，可以写成如下形式：

$$\hat{\Sigma} = (\hat{\sigma}_{ij})_{p \times p}, \hat{\sigma}_{ij} = \begin{cases} s_{ij}, & i = j \\ \text{sign}(s_{ij})(|s_{ij}| - w), & i \neq j \text{ and } |s_{ij}| > w \\ 0, & i \neq j \text{ and } |s_{ij}| \leq w \end{cases}$$

图 2：软阈值法(Soft Thresholding)示例，阈值 $w=0.05$

$$\begin{pmatrix} 1.00 & 0.20 & 0.08 \\ 0.20 & 1.00 & 0.04 \\ 0.08 & 0.04 & 1.00 \end{pmatrix} \xrightarrow{w=0.05} \begin{pmatrix} 1.00 & 0.15 & 0.03 \\ 0.15 & 1.00 & 0.00 \\ 0.03 & 0.00 & 1.00 \end{pmatrix}$$

数据来源：东吴证券研究所

Rothman 等[3]证明，真实协方差矩阵满足特定稀疏性条件时，软阈值法同样能收敛到真实的协方差矩阵。

上述线性软阈值处理有一个数学表达上的优点，如 Xue 等[4]所述，该估计正好是如下凸优化问题的解：

$$\hat{\Sigma} = \arg \min_{\Sigma} \frac{1}{2} \|\tilde{\Sigma} - S\|_F^2 + w |\tilde{\Sigma}|_{1,off}$$

其中， S 为样本协方差矩阵， w 为可调的惩罚系数，其含义与上文中的硬阈值法和软阈值法中的 w 相同。 $\|\cdot\|_F^2$ 为 Frobenius 范数的平方，其定义为矩阵中所有元素的平方和： $\|A\|_F^2 = \sum_{i,j} |A_{ij}|^2$ ， $|\cdot|_{1,off}$ 为矩阵非对角线元素的绝对值之和，定义为 $|A|_{1,off} = \sum_{i \neq j} |A_{ij}|$ 。

无论是硬阈值法，还是将其推广后的软阈值法，虽然其估计比简单的样本协方差矩阵更加接近真实协方差阵，但这两种方法都无法保证所求得的矩阵是正定的，可能会出现估计出的协方差矩阵的最小特征值小于 0。这点在金融资产分析中是致命的。假设 P 个金融资产之间收益率的估计协方差矩阵为 $\hat{\Sigma}$ ，则可以通过特征分解得到：

$$\hat{\Sigma} = U \Lambda U' = (u_1 \ u_2 \ \dots \ u_p) \begin{pmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_p \end{pmatrix} \begin{pmatrix} u_1' \\ u_2' \\ \vdots \\ u_p' \end{pmatrix}$$

其中， u_i 与 λ_i 为 $\hat{\Sigma}$ 对应的特征向量与特征根，且 $\lambda_1, \dots, \lambda_p$ 从小到大排序。其对应的经济意义非常明显：若某个投资组合持有各个资产的数量为 u_i ，则该资产组合波动率平方的估计为 $u_i' \hat{\Sigma} u_i = u_i' U \Lambda U' u_i = \lambda_i$ ，即 λ_i 对应特征资产组合的预期波动率的平方，必为一个大于等于 0 的数字，因此特征值出现负值是显然不合理。针对此问题，有学者提出对上述凸优化问题增加正定的条件，因此，优化问题变为

$$\hat{\Sigma} = \arg \min_{\Sigma \geq \epsilon I} \frac{1}{2} \|\tilde{\Sigma} - S\|_F^2 + w |\tilde{\Sigma}|_{1,off}$$

其中， ϵ 为一个充分小的正数， I 为 P 维的单位矩阵。虽然只增加了这一个限制条件，却使得该问题的求解难度大大增加，Xue 等[4]提出使用交替方向法求解，幸运的是，交替方向法的每一步的优化问题都有显式解，这使得 Xue 等[4]所提出的算法非常

高效。

Liu 等[5]提出了与 Xue 等[4]类似的解决方案，同时，他们给出了含有加权惩罚系数的问题的解法：

$$\hat{\Sigma} = \arg \min_{\Sigma \geq \epsilon I} \frac{1}{2} \|\hat{\Sigma} - S\|_F^2 + w |W \circ \hat{\Sigma}|_{1,off}$$

其中， W 为加权重矩阵，其元素均为非负， $W \circ \hat{\Sigma}$ 为两个矩阵的 hadamard 积，即对应元素相乘所得到的新的矩阵。

W 矩阵内的元素可以取样本协方差阵对应元素的倒数，以使得协方差阵中绝对值较小的值被更快压缩到 0，而绝对值较大的值可以有较小幅度的压缩。Liu 等[5]在模拟实证中，也验证了加权惩罚方法相对于原始方法的优越性。

在稀疏矩阵方法中，只有一个参数是需要人为控制的，那就是惩罚系数 w 。关于惩罚系数 w 的选择，我们借鉴了交叉验证(Cross-Validation)的方法，参照 Bickel 等[6]，将 N 个样本拆分为大小为 $N/\log(N)$ 的测试集，以及长度为 $N(1-1/\log(N))$ 的训练集，通过遍历的方法，挑选出能使得估计协方差矩阵与测试集协方差矩阵的 Frobenius 距离最小的 w ，作为模型的输入 w 。

在下文中，我们将 3 类稀疏矩阵估计纳入对比，它们之间的唯一区别为惩罚系数矩阵不同，第一类的加权惩罚系数矩阵为 $W_{ij} = 1$ ，即 Xue 等[4]所提出的等权情形，在后面，将该估计方法记为 STO_Equal。

第二类的加权系数为样本协方差矩阵元素绝对值的倒数 $W_{ij} = 1/(|S_{ij}| + \epsilon)$ ，其中 S_{ij} 为样本协方差矩阵第 i 行第 j 列的元素， ϵ 为很小的正数，以避免 S_{ij} 为 0 时 W_{ij} 出现无穷大的情形，下文中，将该方法记为 STO_Cov。

第三类的加权系数为软阈值法处理后的协方差矩阵的元素绝对值的倒数 $W_{ij} = 1/(|\hat{\Sigma}_{ij}| + \epsilon)$ ，其中， $\hat{\Sigma}_{ij}$ 为使用上文中软阈值法算出的协方差矩阵估计的第 i 行第 j 列， ϵ 为很小的正数，以避免 $\hat{\Sigma}_{ij}$ 为 0 时 W_{ij} 出现无穷大的情形，下文中，将该方法记为 STO_Sto。

3. 旋转不变估计方法介绍

本文所要介绍的另外一类估计可以称为旋转不变估计类(Rotation-Invariant Estimation)，该方法也可以被称为压缩估计类。首先，我们介绍旋转不变估计的含义。

旋转不变估计类的介绍

承接上一节定义，令 R_t 为列向量，代表一个 p 维资产在时刻 t 的收益率，时间序列样本长度为 n ，令 $\hat{\Sigma}$ 为这 p 个资产的收益率的协方差矩阵 Σ 的估计。

若对于任何一个正交矩阵 Q ，对这 p 个资产通过矩阵 Q 旋转，得到新的 p 个资产组合，则新的 p 个资产组合在第 t 期的收益率向量为 QR_t ，同时新的 p 个资产组合的收益率协方差矩阵变为 $Q\Sigma Q'$ ，而使用同样的估计方法对 QR_t 的协方差矩阵进行估计，如果估计值为 $Q\hat{\Sigma}Q'$ ，即协方差矩阵的估计也发生了同样的变换，则称该方法得到的估计量为旋转不变估计量。

根据 Perlman[7]中的引理 5.3，旋转不变估计类只能是如下形式：

$$\hat{\Sigma} = UDU'$$

其中， $U=(u_1, \dots, u_p)$ ， $u_1, \dots, u_p$ 分别为样本协方差矩阵 S 的特征向量，分别对应的特征值为 $\lambda_1 \leq \dots \leq \lambda_p$ ， $D = \text{diag}(d_1, d_2, \dots, d_p)$ 为对角阵，因此，旋转不变估计所要估计的变量为 $d_1, d_2, \dots, d_p$ ，共 p 个参数，相比于原始协方差矩阵需要估计 $p*(p+1)/2$ 个参数，估计参数个数大幅降低。

显然，当 $d_1, d_2, \dots, d_p$ 为样本协方差阵 S 每个特征向量对应特征值 $\lambda_1, \dots, \lambda_p$ 的时候， $\hat{\Sigma} = S$ ，因此，原始的样本协方差矩阵 S 也属于旋转不变估计类。

接下来，我们要介绍的旋转不变估计类主要有三类，这三类均极具代表意义。他们分别是：Menchero 等[8]提出的样本特征值调整方案；Ledoit 等[9]提出的线性压缩估计；Ledoit 等[10][11]提出的基于随机矩阵 Marčenko-Pastur 方程的非线性压缩估计方法。

基于模拟的特征值调整——BootstrapLike 方法

首先，我们介绍 Menchero 等[8]所提出的样本特征值调整方案，其调整思路类似于统计学中的 bootstrap 的思想，尝试通过模拟的方式发掘样本协方差矩阵特征值对于真实协方差矩阵特征值估计的偏离水平，然后在样本协方差矩阵的特征值上反向修正，得到真实协方差矩阵特征值的估计。

具体而言， n 期 p 个资产的样本协方差矩阵可以被分解为 $S = U\Lambda U'$ ，其中 $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$ ， $\lambda_1 \leq \dots \leq \lambda_p$ 为 S 从小到大排列的特征值， U 为对应特征列向量共同组成的正交矩阵。

而后，模拟生成长度同样为 n 期， p 维，且协方差矩阵为 S 的多元正态随机向量，求出所生成的随机向量的协方差矩阵 $\tilde{S}_1$ ，得到 $\tilde{S}_1$ 的特征分解 $\tilde{S}_1 = \tilde{U}_1 \tilde{\Lambda}_1 \tilde{U}_1'$ ，其中 $\tilde{\Lambda}_1 = \text{diag}(\tilde{\lambda}_1^1, \tilde{\lambda}_2^1, \dots, \tilde{\lambda}_p^1)$ ， $\tilde{\lambda}_1^1 \leq \dots \leq \tilde{\lambda}_p^1$ 为模拟生成的协方差矩阵 $\tilde{S}_1$ 的特征值。Menchero 等[8]认为模拟生成的样本协方差矩阵 $\tilde{S}_1$ 最小特征值 $\tilde{\lambda}_1^1$ 相对于真实的样本协方差矩阵 S 的最小特征值 λ_1 的偏离度，可以作为 λ_1 相对于真实协方差矩阵 Σ 的最小特征值 τ_1 的偏离度的估计。因此，要得到真实特征值 τ_1 的估计，需要对 λ_1 乘以纠偏系数 $(\lambda_1 / \tilde{\lambda}_1^1)$ ，同样，对于其它特征值 $\tau_2, \tau_3, \dots, \tau_p$ 的估计，只需做同样的纠偏操作。

为了使纠偏系数估计更加准确，Menchero 等[8]重复多次模拟，然后将各次的纠偏系数取平均，得到了最终的纠偏系数。本文只介绍了该方法的核心思想，具体操作细

节，读者可以参考原始文献。该方法在 Barra 文档 USE4 中也有使用，相比于原始文档，在 USE4 中的估计方法有微小改动。

该方法的思想类似于统计学中自助抽样法(bootstrap)，因此，在本文中，我们称之为 **BootstrapLike 方法**。

将样本协方差特征值向单位矩阵压缩的方法——LWLinear 方法

第二种旋转不变估计为线性压缩估计类，我们只取其中的代表性的成果，由 Ledoit 等[9]提出的线性压缩估计。

该方法的具体思想为：将样本协方差矩阵向单位矩阵压缩，可以写为如下形式：

$$\hat{\Sigma} = \rho k I + (1 - \rho) S$$

其中， ρ 为 0 到 1 之间的压缩系数，值越大，压缩程度越大； S 为样本协方差矩阵； $k = \text{trace}(S)/p$ ，即为样本协方差矩阵对角线元素的均值， I 为 p 维单位矩阵。

若 S 的特征分解形式为 $S = U \Lambda U'$ ，则可以将上式改写为：

$$\hat{\Sigma} = \rho k I + (1 - \rho) U \Lambda U' = U(\rho k I + (1 - \rho) \Lambda) U'$$

即该估计本质上是将样本协方差矩阵的特征值向单位阵压缩，以减轻样本协方差矩阵特征值在较小的区域严重低估，在较大的区域严重高估的现象[9]。

Ledoit 等以最小化估计协方差矩阵 $\hat{\Sigma}$ 与真实协方差矩阵 Σ 间的 Frobenius 距离为目标，得到最优压缩系数 $(1 - \rho)$ 应等于真实协方差矩阵 Σ 的特征值 $(\tau_1, \tau_2, \dots, \tau_p)$ 的方差与样本协方差矩阵 S 的特征值 $(\lambda_1, \lambda_2, \dots, \lambda_p)$ 的方差之比。他们在文章中给出了压缩系数 ρ 的渐近最优估计，本文将使用 Ledoit 等所给出的方法对协方差矩阵做压缩估计，关于具体操作细节，读者可以参考原始文献[9]。下文中，我们称该方法为 **LWLinear 方法**。

基于随机矩阵理论的非线性压缩方法——QuESTNonlinear 方法与 DirectNonlinear 方法

第三种旋转不变估计方法为非线性压缩，其支撑为随机矩阵理论。首先要向读者介绍，旋转不变估计类中理论上的最优估计的形式：

若以 Frobenius 距离衡量协方差矩阵估计效果的好坏，即以 $\|UDU' - \Sigma\|_F$ 越小代表协方差矩阵的估计效果越好。

$$\begin{aligned} \|UDU' - \Sigma\|_F^2 &= \text{trace}((UDU' - \Sigma)(UDU' - \Sigma)) = \text{trace}(DD - 2U'\Sigma U D + \Sigma\Sigma) \\ &= \text{trace}(\Sigma\Sigma) + \sum_{i=1}^p (d_i^2 - 2u_i'\Sigma u_i d_i) \end{aligned}$$

通过对上式求导，令其导数为 0，可以得到旋转不变估计类中的最优估计，即 $d_i = u_i'\Sigma u_i$ ，为样本协方差矩阵的特征向量与真实的协方差矩阵的二次型的形式。但 Σ 未

知，所以我们仍然无法得到最优的 d_i 值。但在大样本情形下，该类基于随机矩阵理论的非线性压缩方法，可以使得估计逐渐收敛到最优的 $u_i^T \Sigma u_i$ 。接下来，本文将简要介绍这种估计方法。

当我们估计协方差矩阵的时候，若变量个数 p 若远小于观测样本数量 n ，则用最原始的样本协方差矩阵估计方法就能得到不错的估计精度。若 p 与 n 共同趋于无穷大，且 p/n 收敛到某个正数 c ，当 c 值比较大，例如 $c = 0.5$ 时，使用简单的样本协方差矩阵 S 估计真实协方差矩阵会出现非常大的误差。随机矩阵理论中经典的 Marčenko-Pastur 方程 [12]描述了在这种极限比例 c 固定的情形下，样本协方差矩阵 S 的特征值的分布与总体真实协方差矩阵 Σ 的特征值的分布之间的一一对应关系，当得知真实协方差矩阵的特征值的分布时，就可以通过该方程推得样本协方差的特征值分布；反之，若得知样本协方差矩阵的特征值分布，可以反推出真实协方差矩阵的特征值分布。

Ledoit 等[13]将 Marčenko-Pastur 方程进行拓展，并以此为工具，将 d_i 的极限形式写为了样本协方差矩阵特征值及其分布， p/n 极限比例 c 的函数形式。


基于以上结论，Ledoit 等[14]提出了非线性压缩方案，而后进一步改进了之前的非线性压缩估计方案[10]，并将该方法的具体计算步骤在 Ledoit 等[15]中做了详细的介绍。该方法所得到的协方差估计量在 n 与 p 趋于无穷的极限情形下收敛到旋转不变估计类中最优情形。在下文中，我们称该方法为 **QuESTNonlinear 方法**。

最近，Ledoit 等[11]又提出了一种同样基于随机矩阵理论，但算法更为简单快速的非线性压缩估计方法，该方法相比于 QuESTNonlinear 方法的最大优点在于代码简单，计算速度更快，且从模拟结果上看，该方法与 QuESTNonlinear 方法对协方差矩阵的估计提升效果类似。在下文中，我们称该方法为 **DirectNonlinear 方法**。

为了更加直观认识几种旋转不变估计量的估计效果，我们进行如下模拟实验：

对一个 $p=1000$ 维变量 Y ，其服从多元正态分布，其协方差矩阵 Σ 为对角阵，对角线上的元素从小到大排列服从图3所示，对角线最大元素为10，最小元素为1。我们生成 $n=2000$ 个服从上述分布的随机数，得到了 2000×1000 的样本，接下来，使用所得到的样本去估计真实的协方差矩阵。

图3：数值模拟中协方差矩阵的1000个特征值的取值



数据来源：东吴证券研究所

与上文相同，若样本协方差矩阵可以写为 $S = U\Lambda U'$ ，则旋转不变估计量对于协方差矩阵的估计形式为 $\hat{\Sigma} = UDU'$ ，其中， $U = (u_1, \dots, u_p)$ ，为样本协方差矩阵特征向量所组成的矩阵， $D = \text{diag}(d_1, d_2, \dots, d_p)$ 为所要估计的对角矩阵。同时，由上文的分析， $d_1, d_2, \dots, d_p$ 也代表了对 $u_1'Y, \dots, u_p'Y$ 的方差的估计。

下面，我们将对比不同估计方法下特征组合 $u_1'Y, \dots, u_p'Y$ 方差的估计值与真实值的差异，其中， $u_1'Y, \dots, u_p'Y$ 真实方差可以通过 $u_1'\Sigma u_1, \dots, u_p'\Sigma u_p$ 得到。


在图 4 中，我们以黑色的散点画出了 $u_1'Y, \dots, u_p'Y$ 的真实方差，以红色实线和蓝色实线分别表示 QuESTNonlinear 和 DirectNonlinear 方法所得到的对于 $u_1'Y, \dots, u_p'Y$ 方差的估计量，以青色实线代表 LWLinear 线性压缩估计对 $u_1'Y, \dots, u_p'Y$ 方差的估计，以绿色虚线代表 BootstrapLike 方法下的方差估计，最后，以紫色虚线画出了以样本协方差矩阵 S 对特征组合方差的估计。

从图 4 的对比中可以发现，样本协方差矩阵对特征组合 $u_1'Y, \dots, u_p'Y$ 方差估计的误差最大，在特征组合方差较小的一侧，样本协方差矩阵严重低估了真实方差，而在特征组合方差较大的一侧，样本协方差矩阵严重高估了真实方差。线性压缩估计方法 LWLinear 相比于样本协方差矩阵有一定程度的改进，但与真实值偏离仍然较大。两种非线性压缩估计方法 QuESTNonlinear 与 DirectNonlinear 对于真实结果的估计是最佳的，在图中体现为红线与蓝线几乎与黑色的散点重合。而 BootstrapLike 方法，在这个案例中，压缩效果似乎比线性压缩更好，但其并不能像 QuESTNonlinear 和 DirectNonlinear 方法那样，随着样本量的增大，收敛到真实的数值。

上文已经证明，当 $d_1, d_2, \dots, d_p$ 取 $u_1'\Sigma u_1, \dots, u_p'\Sigma u_p$ 时， $\hat{\Sigma} = UDU'$ 能做到在旋转不变估计类中，估计协方差与真实协方差的 Frobenius 距离最小，估计最精准。因此，从估

计精度来说，在数据维度较大(大样本)的情形下，协方差矩阵的估计效果为：两个非线性估计方法最精确，而直接使用样本协方差进行估计最不精确。


图 4：特征组合的在每种估计方法下的估计方差以及真实方差



数据来源：东吴证券研究所

在本章的最后，我们额外附加一个大家感兴趣的问题：介绍了这么多压缩估计的方法后，到底什么情形下压缩估计是必要的？这个答案取决于数据的维度与样本个数之比 p/n 。

图 5：压缩估计所适用的情形



数据来源：文献[16]，东吴证券研究所

图 5 借鉴了 Yao 等[16]所给出的一张图片，在该图片中，当 p/n 小于 0.1 时，被称

为 Low-dim 区域，在这个区域中，使用复杂的协方差矩阵估计手段未必能打败最简单的协方差矩阵估计，因此，建议在这种情形中直接使用最原始的协方差估计，而无须对样本协方差矩阵进行额外处理。而当 p/n 超过 10 时，被称为在 Ultra-dim 区域，在这种维度远大于样本量的区域中，即便是复杂的协方差估计手段得到的结果也可能是很糟糕的，因为在这种情形下，压缩估计理论中的一些前提假设可能会被打破。而在 p/n 处于 0.1 与 1 之间的 MP 区域时，随机矩阵理论中的渐近理论更加有效，因此，在 MP 区域中，使用压缩估计是能起到较好的结果的。

4. 处理样本协方差矩阵还是处理样本相关系数矩阵？

众所周知，协方差矩阵 Σ 可以写为 $\Sigma = MPM$ 的形式，其中， P 为相关系数矩阵， $M = \text{diag}(\sigma_1, \dots, \sigma_p)$ 为 p 个子变量的标准差构成的对角矩阵。

在做协方差矩阵的稀疏化估计或旋转不变估计的时候，我们可以选择如下两个方案：

方案 1，对样本的协方差矩阵进行压缩，一步到位得到协方差矩阵的估计 $\hat{\Sigma}$ ；

方案 2，先对样本相关系数进行压缩估计(相当于将数据先标准化，然后计算标准化后的数据的协方差矩阵)，得到 $\hat{P}$ ，然后使用样本标准差构成的对角矩阵 $\hat{M} = \text{diag}(\hat{\sigma}_1, \dots, \hat{\sigma}_p)$ 乘在 $\hat{P}$ 左右两侧，得到 $\hat{\Sigma} = \hat{M}\hat{P}\hat{M}$ 。

两种方法孰优孰劣，并没有理论上的严格证明，以上文所提到的旋转不变估计量 $\hat{\Sigma} = UDU'$ 来说，使用方案 1 与方案 2 时所用到的特征向量 U 是完全不同的，因此，两种方案其实是在两个旋转不变估计类中做估计，无法直接评判两者谁更优。

在下文的实践部分，在选择使用方案 1 还是方案 2 的问题上，我们将得到一些经验性的规律。当所要估计的 p 维变量的每一维度数据的波动率有很大差异的时候，使用方案 2 会更好，在这种情况下，先将数据标准化，一定程度上可以降低所要压缩的矩阵的条件数(Condition Number, 为矩阵的最大特征值除以最小特征值的比例)，而 Ledoit 等[9]在模拟中发现，条件数过大会影响线性压缩方法 LWLinear 的压缩效果。

而当 p 维变量每个维度数据的标准差差距没有那么大的时候，我们建议使用方案 1，直接对协方差矩阵做处理，这种一步到位的方法在本文的实证中比方案 2 的两步法更加有效。同时，方案 2 相比于方案 1 也有更多的改进空间，正如 BarraUSE4 中所做的那样，我们可以选择使用不同长度不同频率的数据分别估计相关系数和单变量标准差，以使得其相对于市场变化反映更加敏捷，这些内容不在本报告讨论的范围内，后续东吴金工会跟进相关的研究。

本节最后，我们梳理一下上文所提到的方法，并对每一种方法在本文中的命名加以明确，以便于后续的实证对比。

对于稀疏矩阵估计的方法，主要为 Xue 等[4]提出的等权惩罚估计 STO_Equal，以及 Liu 等[5]补充的加权惩罚模型，包括以样本协方差矩阵元素的倒数作为惩罚系数得到的估计 STO_Cov，或以线性软阈值法处理后的样本协方差矩阵元素的倒数作为惩罚系数得到的估计 STO_Sto。对应上文所提到的两个协方差矩阵的估计方案(方案 1: 直接估计协方差矩阵；方案 2: 先估计相关系数矩阵，再回推得到协方差矩阵)，分别赋予前缀 Cov_和前缀 Corr_，共衍生出 6 类估计，我们分别命名为 Cov_STO_Equal、Cov_STO_Cov、Cov_STO_Sto、Corr_STO_Equal、Corr_STO_Cov、Corr_STO_Sto。

对于旋转不变估计量，主要为 Menchero 所[8]提出的 BootstrapLike 估计，Lediot 等[9]所提出的线性压缩估计 LWLinear，Lediot 等[10]后续提出的非线性压缩估计 QuESTNonlinear，以及算法更为简单的非线性压缩估计 DirectNonlinear[11]。对应两种协方差矩阵的估计方案，共衍生出 8 类估计，分别命名为 Cov_BootstrapLike、Cov_LWLinear、Cov_QuESTNonlinear、Cov_DirectNonlinear、Corr_BootstrapLike、Corr_LWLinear、Corr_QuESTNonlinear、Corr_DirectNonlinear。

当然，我们也会引入最原始的样本协方差估计量作为对照，在下文中，样本协方差估计法命名为 SampleCov。

表 1：协方差矩阵估计方案汇总

方法缩写	处理协方差阵 or 相关系数阵	具体估计方法
Cov_STO_Equal	方案一	STO_Equal
Cov_STO_Cov	方案一	STO_Cov
Cov_STO_Sto	方案一	STO_Sto
Corr_STO_Equal	方案二	STO_Equal
Corr_STO_Cov	方案二	STO_Cov
Corr_STO_Sto	方案二	STO_Sto
Cov_BootstrapLike	方案一	BootstrapLike
Cov_LWLinear	方案一	LWLinear
Cov_QuESTNonlinear	方案一	QuESTNonlinear
Cov_DirectNonlinear	方案一	DirectNonlinear
Corr_BootstrapLike	方案二	BootstrapLike
Corr_LWLinear	方案二	LWLinear
Corr_QuESTNonlinear	方案二	QuESTNonlinear
Corr_DirectNonlinear	方案二	DirectNonlinear
SampleCov	无	样本协方差矩阵

数据来源：东吴证券研究所

在接下来的两章中，我们将从两种应用情境下比对几种协方差矩阵估计方法效果的优劣。

5. 案例 1：风险因子协方差矩阵估计

风险模型的本质就是结构化的因子模型，该模型假设股票的相关性可以被一些共同的因子所解释，这些因子包括市场因子、风格因子、行业因子，除了这些公共因子之外，股票之间的残余收益互不相关，同时也与公共因子的收益率不相关。根据风险模型，单只股票*i*在某个区间段内的收益可以被拆解为如下形式：

$$r_i = f_m + \sum_I X_{iI} f_I + \sum_S X_{iS} f_S + u_i$$

其中， r_i 为股票*i*在该区间段内的收益率， f_m 为该区间段内的市场因子收益， f_I 为该时间段内第*I*个行业的收益率， X_{iI} 为股票*i*在第*I*个行业的暴露水平， f_S 为该时段内第*S*个风格因子的收益率， X_{iS} 为股票*i*在第*S*个风格因子的暴露水平，而 u_i 则为市场因子、行业因子、风格因子均无法解释的收益。

若某个股票组合，共包含*N*只股票，每只股票的配置权重为 w_i ，则该组合在某个时段内的收益率可以被写成如下形式：

$$\sum_{i=1}^N w_i r_i = \sum_{i=1}^N w_i f_m + \sum_I \left(\sum_{i=1}^N w_i X_{iI} \right) f_I + \sum_S \left(\sum_{i=1}^N w_i X_{iS} \right) f_S + \sum_{i=1}^N w_i u_i$$

若我们将市场因子、行业因子、风格因子这三类公共因子合并，则收益率可以被改写为如下形式：

$$\sum_{i=1}^N w_i r_i = \sum_K \left(\sum_{i=1}^N w_i X_{iK} \right) f_K + \sum_{i=1}^N w_i u_i$$

其中， X_{iK} 为第*i*只股票在公共因子*K*上的暴露， f_K 为第*K*个公共因子当期的收益率，因子*K*可以为市场因子、行业因子或风格因子。

风险模型在组合归因与组合优化中都扮演重要角色。其中，风险模型一个重要的功能就是对未来的金融资产组合进行波动率预测，可以让管理者清楚地认识到当前所管理的组合所面临的跟踪误差风险的大小，或者通过组合优化为投资者输出一个满足跟踪误差要求的股票配置列表。

为了表述简便，我们将组合收益的拆解写为矩阵的形式，令 $R = (r_1, \dots, r_N)'$ ， $W = (w_1, \dots, w_N)'$ ， $F = (f_1, \dots, f_K)$ ， $U = (u_1, \dots, u_N)'$ ，并定义因子载荷矩阵 X ：

$$X = \begin{pmatrix} X_{11}, \dots, X_{1K} \\ \vdots \\ X_{N1}, \dots, X_{NK} \end{pmatrix}$$

则有

$$\sum_{i=1}^N w_i r_i = W' R = W' X F + W' U$$

组合的风险水平则可以写为：

$$\text{Var}\left(\sum_{i=1}^N w_i r_i\right) = \text{Var}(W'XF) + \text{Var}(W'U) = W'X\Sigma_F X'W + W'\Sigma_U W$$

其中， Σ_F 为公共因子收益率的协方差矩阵， $\Sigma_U = \text{diag}(\sigma_1^2, \dots, \sigma_N^2)$ 为以每只股票特质收益的方差为对角元素的对角矩阵。

因此，组合的波动可以被拆解为由公共因子解释的部分 $W'X\Sigma_F X'W$ ，以及由每个股票的特质波动所解释的部分 $W'\Sigma_U W$ 。因此，若要准确预测组合在未来的风险水平，需要准确预测公共因子的收益率协方差矩阵 Σ_F ，以及准确预测以股票特质波动率方差为对角线元素的对角矩阵 Σ_U 。关于股票特质波动率的预测，可以参考 BarraUSE4 文档中的 Bayesian 压缩的方法。而本文主要对比的是不同协方差矩阵估计方式在估计公共因子收益率的协方差矩阵 Σ_F 上的表现。

在本案例中，需要估计的协方差矩阵 Σ_F 维度 $p=39$ ，具体来说，包含 1 个市场因子，10 个风格因子(Beta、动量、价值、盈利、成长、杠杆、波动、流动性、规模、非线性规模)，28 个申万一级行业因子。

因子协方差矩阵估计好坏的衡量标准

我们使用通用的 Frobenius 距离的方法衡量因子协方差矩阵估计的优劣，具体而言，我们计算协方差矩阵的估计值与真实的协方差矩阵(在实证中，假定以下一个周期的样本协方差矩阵为真实协方差矩阵)的 Frobenius 距离，该距离越小，说明估计越精准。以数学表达式表达，可以写为

$$D = \|\hat{\Sigma} - \Sigma\|_F = \sqrt{\sum_{i,j} (\hat{\Sigma}_{ij} - \Sigma_{ij})^2}$$

其中， $\hat{\Sigma}$ 为估计的因子收益率协方差阵， Σ 为真实的协方差矩阵， $\hat{\Sigma}_{ij}$ 为 $\hat{\Sigma}$ 的第 i 行第 j 列的元素， Σ_{ij} 为 Σ 的第 i 行第 j 列的元素。

在本节剩余部分中，我们将按照以上标准，执行两次测试，分别为模拟测试和实证检验。

在模拟测试中，我们将统计 06 年 1 月份至 18 年 1 月份的 39 个公共因子的日频级别收益率序列，然后以该序列作为总体，计算协方差矩阵，记为 Σ ，并视 Σ 为真实的协方差矩阵，然后，生成长度 n 不等(本文取 $n=63,126,252$)的以 Σ 为协方差矩阵的多维正态分布随机数，并以这些随机数为样本，通过上文介绍的多种方法，计算得到协方差矩阵的估计 $\hat{\Sigma}$ ，最后，统计 $\hat{\Sigma}$ 与 Σ 之间的误差。通过多次模拟，取 $\hat{\Sigma}$ 与 Σ 之间的平均误差最小的方法为最优。

在实证分析中，我们尝试使用滚动窗口的方法向后预测一个月长度的因子收益率

协方差矩阵。具体而言，若 T 时刻为某个月月底，下个月共 21 天，则我们以 $[T+1, T+21]$ 日共 21 天的因子收益率序列所得到的样本协方差矩阵为 Σ_t ，若滚动窗口长度为 n (本文分别测试了 $n=63, 126, 252$ 三种情形，对应一个季度、半年、一年)，则训练样本为 $[T-n+1, T]$ 日的因子收益率序列，通过训练样本计算得到下个月样本协方差矩阵的估计值 $\hat{\Sigma}_t$ ，然后计算其与 Σ_t 之间的距离，每月月底计算一次，在测试区间内月均距离越小，则估计方法越好。

值得一提的是，模拟测试在本节中是不可或缺的，其原因如下：在实证分析中， Σ_t 是下个月的因子收益率的样本协方差矩阵，而并非真实的协方差矩阵。同时，因子的波动水平是时刻变动的， $[T+1, T+21]$ 日的因子波动水平与 $[T-n+1, T]$ 日的因子波动水平并不相同，因此，使用滚动窗口方法预测协方差矩阵会受到模型之外的因素干扰，这部分干扰可能会造成整体结论的改变，模拟测试则将这些额外的扰动因素剔除了，其结论更能体现出协方差矩阵估计方法的优劣，对于实证结果是一个有力的补充。

模拟测试：

将 06 年 1 月至 18 年 1 月份 39 个因子的日频级别的收益率取出，然后，按照上文所述的方法，计算得到整体的协方差矩阵 Σ ，并进行 1000 次模拟，得到 1000 个协方差矩阵的估计 $\hat{\Sigma}_i$ ($i = 1, 2, \dots, 1000$)，而后计算 $\hat{\Sigma}_i$ 与 Σ 之间的 Frobenius 距离 D_i 。

$$D_i = \|\hat{\Sigma}_i - \Sigma\|_F$$

统计 D_i 的均值，如表 2 所示：

表 2：数值模拟：不同样本量，不同估计方案下，协方差矩阵的估计误差

	Cov_STO_Equal	Cov_STO_Cov	Cov_STO_Sto	Corr_STO_Equal	Corr_STO_Cov
n=63	2.26E-04	2.49E-04	2.59E-04	2.02E-04	2.02E-04
n=126	1.63E-04	1.74E-04	1.70E-04	1.52E-04	1.52E-04
n=252	1.20E-04	1.21E-04	1.20E-04	1.13E-04	1.12E-04
	Corr_STO_Sto	Cov_BootstrapLike	Cov_LWLinear	Cov_QuESTNonlinear	Cov_DirectNonlinear
n=63	2.02E-04	2.22E-04	2.15E-04	2.20E-04	2.20E-04
n=126	1.52E-04	1.63E-04	1.59E-04	1.63E-04	1.63E-04
n=252	1.13E-04	1.17E-04	1.15E-04	1.17E-04	1.17E-04
	Corr_BootstrapLike	Corr_LWLinear	Corr_QuESTNonlinear	Corr_DirectNonlinear	SampleCov
n=63	2.07E-04	1.92E-04	1.93E-04	1.92E-04	2.36E-04
n=126	1.47E-04	1.48E-04	1.46E-04	1.46E-04	1.67E-04
n=252	1.09E-04	1.11E-04	1.09E-04	1.08E-04	1.18E-04

数据来源：Wind 资讯，东吴证券研究所

为方便读者阅读，我们也计算了每一类方法相对于简单的样本协方差矩阵估计 SampleCov 的改进幅度 ImproveRatio，计算公式为：

$$\text{ImproveRatio} = \frac{\bar{D}_{\text{SampleCov}} - \bar{D}_{\text{Method}}}{\bar{D}_{\text{SampleCov}}} \times 100\%$$

其中， $\bar{D}_{\text{SampleCov}}$ 为使用样本协方差矩阵计算得到的平均距离， $\bar{D}_{\text{Method}}$ 为其它复杂方法计算得到的平均距离，可见 ImproveRatio 大于 0 时，其它复杂方法相比于简单

的样本协方差矩阵估计方法有改进，小于 0 时，简单的样本协方差矩阵对于真实协方差矩阵的估计更加准确，该比例最大值为 100%。

表 3：数值模拟：不同方案下，协方差阵的估计相对于 SampleCov 方法的改善幅度

	Cov_STO_Equal	Cov_STO_Cov	Cov_STO_Sto	Corr_STO_Equal	Corr_STO_Cov
n=63	4.33%	-5.11%	-9.59%	14.60%	14.48%
n=126	2.12%	-4.46%	-1.97%	8.76%	8.79%
n=252	-1.34%	-2.37%	-1.74%	4.47%	4.78%
	Corr_STO_Sto	Cov_BootstrapLike	Cov_LWLinear	Cov_QuESTNonlinear	Cov_DirectNonlinear
n=63	14.45%	5.96%	8.95%	6.80%	6.79%
n=126	8.80%	2.18%	4.61%	2.36%	2.56%
n=252	4.58%	0.63%	2.45%	0.72%	0.71%
	Corr_BootstrapLike	Corr_LWLinear	Corr_QuESTNonlinear	Corr_DirectNonlinear	SampleCov
n=63	12.47%	18.90%	18.44%	18.97%	0.00%
n=126	12.02%	11.15%	12.45%	12.80%	0.00%
n=252	7.92%	6.27%	7.66%	8.04%	0.00%


数据来源：Wind 资讯，东吴证券研究所

表 3 展示了每种方法在不同样本长度下的 ImproveRatio，从表中我们可以发现如下几个结论：

1、当使用第 4 章中的方案 1(直接对样本协方差矩阵进行稀疏化或做旋转不变估计处理)时，各种复杂估计方法对协方差矩阵精度提升的效果往往不如使用方案 2(对样本的相关系数矩阵进行稀疏化或做旋转不变估计处理，而后反推得到协方差矩阵的估计)的效果。例如，当每次模拟生成的随机数长度 $n = 63$ ，估计方法选择为线性压缩估计 LWLinear 时，Cov_LWLinear 方法相对于简单样本协方差估计的提升仅有 8.95%，相比之下，Corr_LWLinear 方法相对于简单样本协方差估计的提升幅度达到 18.90%。同样的现象出现在所有其它方法上。

造成这个现象的可能原因是，39 个公共因子的波动率水平差距较大，甚至不在一个数量级上，在图 6 中，我们展示了这 39 个因子在整个测试区间内的标准差。我们发现，波动最大的市场因子，其日波动水平在接近 2%的程度，而波动最小的成长因子，其日波动水平仅为 0.1%。在这种情形下，相关系数矩阵的条件数很可能是低于协方差矩阵的条件数的，而协方差矩阵条件数较低的时候，复杂的估计方法往往更能提高估计的准确度。

图 6：测试区间内不同因子的日频波动率



数据来源：Wind 资讯，东吴证券研究所

2、随着观测样本数量 n 的提升，各个方法相对于简单的样本协方差估计方法的估计精度逐渐下降。例如，当观察样本数 $n=63$ ，使用 Corr_DirectNonlinear 方法的时候，其相对于简单样本协方差矩阵的估计精度提升为 18.97%，而随着 n 上升至 126 或 252，该方法相对于样本协方差矩阵的估计精度提升幅度则分别降为 12.80% 和 8.04%。

造成这个现象的原因，是随着 n 的提升，变量维度 p 与观测值数量 n 的比值在逐渐缩小，尤其是对于 $n=252$ 时， $p/n=39/252=0.155$ ，该值已经接近了图 5 中所描述的 Low-dim 区域，在这个区域中，使用简单的样本协方差矩阵已经能较好估计真实协方差矩阵，而使用其它复杂方法进行改进，所获得的精度提升已经不大。

同时，对比表 3，我们可以发现，虽然，在样本数量 n 相同的情况下，复杂方法会比简单的样本协方差估计更优，但错位对比可以发现，无论哪种复杂的估计方式，使用较小样本量 n 进行估计，估计精度都无法优于相对较大样本量 n 情形下，使用最简单的样本协方差矩阵做出的估计 SampleCov。例如，在 $n=63$ 时，使用 Corr_LWLinear 方案下协方差估计计算出的平均误差为 1.92×10^{-4} ，而对比 $n=126$ 时，使用样本协方差估计 SampleCov 方法的平均误差仅为 1.67×10^{-4} 。

但这一现象在实证中是否仍然成立是值得怀疑的，这是因为金融市场本身并非完全平稳，其始终处于一个缓慢的变化过程中，当我们使用样本量 n 较小的时候，意味着使用的数据是更加近期的数据，能更迅速对市场状态的变化产生相应的调整，而当 n 较大的时候，虽然在稳定状态下对协方差矩阵的估计更加精确，但其却因为不能对市场变化迅速调整，反而估计效果可能不如 n 较小的情形，这一点将在本节的实证部分加以验证。

3、不同估计方法横向比较，我们发现，使用旋转不变估计类的效果在绝大多数情形下都好于使用稀疏矩阵方法的估计效果。由此，我们推测，金融时间序列的协方差矩阵，出现稀疏矩阵(部分相关系数为 0)的可能性相对较小，这导致了当强行对矩阵进行稀疏化时，对于协方差矩阵估计效果的提升并不会理想。在旋转不变估计类内部，当使用方案二的压缩估计时，使用线性压缩(LWLinear)和非线性压缩(QuESTNonlinear 或 DirectNonlinear)区别不大，为所有估计方法中提升效果最显著的方案，而 BootstrapLike 方案在n较小时候表现糟糕，当n达到 126 以上以后，其估计效果与线性压缩和非线性压缩相当。

实证检验：

在实证分析中，在每个月月底，通过过去 n 天的因子收益率序列估计得到协方差矩阵 $\hat{\Sigma}_t$ ，用于预测未来一个月的因子收益率的样本协方差协方差矩阵 Σ_t 。预测时间为 2008 年 1 月份到 2018 年 1 月份。类似于模拟测试部分，我们定义第 t 个月的预测误差为 D_t ：

$$D_t = \|\hat{\Sigma}_t - \Sigma_t\|_F$$

D_t 越小，表明预测越准确，表 4 统计了测试时间段内不同预测方法下， D_t 的均值。

表 4：实证测试：不同样本量，不同估计方案下，协方差矩阵的估计误差

	Cov_STO_Equal	Cov_STO_Cov	Cov_STO_Sto	Corr_STO_Equal	Corr_STO_Cov
n=63	6.19E-04	6.37E-04	6.35E-04	6.14E-04	6.12E-04
n=126	6.13E-04	6.19E-04	6.22E-04	6.07E-04	6.07E-04
n=252	6.46E-04	6.49E-04	6.50E-04	6.44E-04	6.41E-04
	Corr_STO_Sto	Cov_BootstrapLike	Cov_LWLinear	Cov_QuESTNonlinear	Cov_DirectNonlinear
n=63	6.10E-04	6.26E-04	6.08E-04	6.16E-04	6.24E-04
n=126	6.06E-04	6.12E-04	6.03E-04	6.08E-04	6.11E-04
n=252	6.44E-04	6.45E-04	6.39E-04	6.42E-04	6.44E-04
	Corr_BootstrapLike	Corr_LWLinear	Corr_QuESTNonlinear	Corr_DirectNonlinear	SampleCov
n=63	6.26E-04	6.04E-04	6.10E-04	6.14E-04	6.38E-04
n=126	6.11E-04	6.02E-04	6.06E-04	6.08E-04	6.19E-04
n=252	6.44E-04	6.39E-04	6.42E-04	6.43E-04	6.49E-04

数据来源：Wind 资讯，东吴证券研究所

为方便读者阅读，我们计算了每一类方法相对于简单的样本协方差矩阵估计 (SampleCov 方法) 的改进幅度，并在表 5 中展示，计算公式为：

$$\text{ImproveRatio} = \frac{\bar{D}_{\text{SampleCov}} - \bar{D}_{\text{Method}}}{\bar{D}_{\text{SampleCov}}} \times 100\%$$

其中， $\bar{D}_{\text{SampleCov}}$ 为使用样本协方差矩阵计算得到的平均距离， $\bar{D}_{\text{Method}}$ 为其它复杂方法计算得到的平均距离。

表 5：实证测试：不同方案下，协方差阵的估计相对于 SampleCov 方法的改善幅度

	Cov_STO_Equal	Cov_STO_Cov	Cov_STO_Sto	Corr_STO_Equal	Corr_STO_Cov
n=63	2.95%	0.13%	0.41%	3.72%	4.04%
n=126	0.91%	-0.07%	-0.54%	1.88%	1.93%
n=252	0.49%	0.01%	-0.12%	0.81%	1.16%
	Corr_STO_Sto	Cov_BootstrapLike	Cov_LWLinear	Cov_QuESTNonlinear	Cov_DirectNonlinear
n=63	4.33%	1.93%	4.62%	3.38%	2.26%
n=126	2.02%	1.05%	2.51%	1.77%	1.33%
n=252	0.82%	0.64%	1.45%	1.00%	0.69%
	Corr_BootstrapLike	Corr_LWLinear	Corr_QuESTNonlinear	Corr_DirectNonlinear	SampleCov
n=63	1.85%	5.31%	4.44%	3.75%	0.00%
n=126	1.30%	2.77%	2.08%	1.76%	0.00%
n=252	0.81%	1.52%	1.12%	0.91%	0.00%

数据来源：Wind 资讯，东吴证券研究所

实证结论与模拟测试中的部分结论类似：1、使用方案一对协方差矩阵的预测能力始终不如方案二强，即直接估计协方差矩阵的效果始终弱于先估计相关系数矩阵，再反推出协方差矩阵的效果；2、随着回看天数 n 的上升，复杂估计方法相对于简单的样本协方差矩阵估计 SampleCov 的提升幅度越来越小；

但同时，我们也发现实证测试中不同于模拟实验的结论：

1、相对于简单的样本协方差矩阵估计(SampleCov 方法)，其它复杂方法在估计精度上的提升比例要低于模拟实验中的情形，且从表 2 与表 4 的对比可以看出，所有方法的实证分析误差均值都要高于模拟情形下的误差均值。

我们认为其中的原因主要包含两点：1) 实证中的 Σ_t 不再是真正的协方差矩阵，而是通过下一个月的因子收益序列计算出的样本协方差阵，其本身与真实的协方差矩阵 Σ 有较大的误差；2) 由于市场状态并非完全平稳，变量之间的相关性或波动水平都会随时间变化，过去一段时间因子间真实的相关系数矩阵和未来一段时间的因子真实相关系数矩阵之间的差异也会造成估计误差的进一步拉大。以上两个因素造成了 $D_t = \|\hat{\Sigma}_t - \Sigma_t\|_F$ 中包含了 3 个组成部分：1) $\hat{\Sigma}_t$ 相对于回看区间内真实协方差矩阵的估计误差；2) Σ_t 相对于未来一个月真实协方差矩阵的估计误差；3) 回看区间内的真实协方差矩阵与未来一个月的真实协方差矩阵之间的偏差。而协方差矩阵的估计方法只能改进 3 个组成部分中的第一个部分，对另外两个部分的误差无能为力。

2、从表 5 中可以看出，对未来协方差矩阵的估计，并非是回看周期 n 越长效果越好，例如，对于使用方案二的线性压缩估计 Corr_LWLinear 方法，其回看 63 天误差的均值为 6.04×10^{-4} ，若将该回看天数延长到半年 126 天，则误差均值下降到 6.02×10^{-4} ，但若将回看天数进一步延长到一年 252 天，预测误差反而上升到 6.39×10^{-4} ，误差有了 6.15% 的上升。其原因可以归为市场状态的时变性，使用较长的回看窗口固然会使得其对于估计窗口内的协方差矩阵估计的精度上升，但其对于市场状态变化的反映速度要慢于使用较短回看窗口的估计，因此，在实际操作中，我们建议投资者需要在反应速度与估计精度之间寻找最优的平衡点，在本文的案例中，回看 126 天所给出的协

方差矩阵的预测效果是最好的，其中，使用方案二的线性压缩估计 Corr_LWLinear 表现最优。

6. 案例 2：最大化 ICIR 复合因子的构造

投资者在做因子投资时，更倾向于使用多个 alpha 因子复合加权的投资方式。这是因为，多因子相对于单因子具有更好的稳健性，当一篮子因子中，某个或某几个因子短期失效时，复合因子仍然能从其它有效因子汲取选股能力，这使得多因子所做出的选股结果在稳定程度上远高于单因子选股的结果。

因子合成中，最常用的方法就是使用单个因子对每只股票进行打分，然后，将打分相加，得到该股票的总分，以总得分的高低作为该股票未来一段时间期望收益高低的标准。

具体来说，假设参与打分的因子共 p 个，且这些因子均已在横截面上做了标准化处理，使得每个因子的均值为 0，标准差为 1。记这 p 个因子分别为 $F = (f_1, \dots, f_p)'$ ，每个因子配置的权重为 $W = (w_1, \dots, w_p)'$ ，则复合因子可以写为：

$$f_{mix} = \sum w_i f_i = W'F$$

若要使得的复合因子 f_{mix} 的收益风险比最大，即 ICIR 最大，则有一个经典的结论描述最优情形下 W 的权重：

$$W = a \Sigma_{IC}^{-1} \overline{IC}$$

其中， a 为任意正数， Σ_{IC} 为 p 个子因子的 IC 序列的协方差矩阵，为 $p \times p$ 的正定矩阵， $\overline{IC}$ 为 p 个因子的 IC 期望值，为一个 $p \times 1$ 的列向量。

当我们已知 Σ_{IC} 和 $\overline{IC}$ 的时候，按照公式配置因子权重所得到的复合因子可以达到最大的 ICIR，但实际情形中，我们对未来的 Σ_{IC} 和 $\overline{IC}$ 只能通过历史数据估计，这两者的估计质量也就直接决定了复合因子的 ICIR 的水平的高低。

在本节，我们将固定 $\overline{IC}$ 的估计方法，同时使用上文所提及的各种协方差估计方案去估计 Σ_{IC} ，进而通过对比使用上述公式计算得到的复合因子的 ICIR 的高低，评判估计效果的好坏。

参与测试因子的预处理：

本文共使用 9 个因子参与测试，包括 5 个基本面因子：单季度营业收入同比增长率，记为 SalesYOY；单季度营业利润同比增长率，记为 OPYOY；ROE_TTM 环比变化，记为 ROE_TTMQOQ；PE_TTM 的倒数，记为 EP_TTM；市净率，记为 BP。同时，也纳入了 4 个情绪因子：过去 20 个交易日的对数日均换手率，记为 TurnoverRatio；过去 20 个交易日相对于万得全 A 指数的特异度，记为特异度；过去 20 个交易日相对万

得全 A 指数拟合 CAPM 模型后的剩余残差波动率，记为波动率；过去 20 个交易日的个股涨跌幅，记为反转。

为了解决不同行业、不同规模的公司之间因子的不可比性，我们对所有参与测试的 9 个因子都做了相对于对数流通市值和行业哑变量的中性化。下表给出了 9 个中性化后的因子在测试区间内月度测算频率下的年化 ICIR：


表 6：参与复合的 9 个子因子中性化后的(年化)ICIR 表现

SalesYOY	OPYOY	ROE_TTMQOQ	EP_TTM	BP	换手率	特异度	波动率	反转
1.72	2.17	2.18	1.52	1.46	-3.03	3.10	-3.11	-2.47

数据来源：Wind 资讯，东吴证券研究所

若每个月月底将股票按中性化后的因子三等分，等权做多因子值最高的一组，等权做空因子值最低的一组，可以得到如下对冲曲线：

图 7：参与复合的 9 个子因子中性化后分三组多空对冲净值(纵轴为对数坐标系)



数据来源：Wind 资讯，东吴证券研究所

估计方案简述：

$\overline{IC}$ 的估计方法：本文中，对于 IC 期望值的估计方法在所有情形下保持一致，均使用过去 12 个月滚动的月频 IC 均值作为对下个月 $\overline{IC}$ 的估计。

Σ_{IC} 的估计方法：协方差矩阵的估计方法为表 1 中所介绍的 15 中估计模式，但我们会在数据的频率以及回看的长度上进一步加以区别，本文分别尝试了使用三种不同频率的 IC 序列对 Σ_{IC} 进行估计，其中，日频级别的 IC 序列分别回看 63 天(1 个季度)、126 天(半年)、252 天(1 年)，周频级别的 IC 序列回看长度分别为 13 周(1 个季度)、26 周(半年)、52 周(1 年)，月频级别的 IC 序列回看长度分别为 6 个月(半年)、12 个月(1 年)。

综上所述，本文将会尝试在 8 个不同频率或回看长度的方案基础上，测试 15 种协方差矩阵的估计区别，同时，也将因子等权配置(SalesYOY、OPYOY、ROE_TTMQOQ、

EP_TTM、BP、特异度赋予权重 1，换手率、波动率、反转因子赋予权重-1)作为基准，纳入比较。由于当回看数据为过去 6 个月的月频 IC 序列时，样本协方差矩阵不可逆，且方案一与方案二下的 BootstrapLike 方法也均不可行，因此，本文将比较 $(8 \times 15 + 1 - 3)$ 共 118 种因子权重配置方案，比较的指标为各个权重配置方案下的复合因子的年化 ICIR 值。

表 7：不同回看频率周期，不同估计方法下的最优复合因子的 ICIR 对比

频率时长	63 天	13 周	126 天	26 周	6 个月	252 天	52 周	12 个月
Cov_STO_Equal	5.02	4.46	5.13	5.18	4.10	5.08	4.79	3.97
Cov_STO_Cov	5.35	3.73	5.21	5.19	3.76	5.15	5.23	3.55
Cov_STO_Sto	5.30	3.96	5.28	5.13	3.94	5.22	5.12	3.59
Corr_STO_Equal	5.39	4.63	5.17	5.05	4.12	5.04	4.91	4.35
Corr_STO_Cov	5.39	4.67	5.26	5.27	4.15	5.12	5.17	4.16
Corr_STO_Sto	5.46	4.59	5.18	5.35	4.15	5.15	4.96	4.00
Cov_BootstrapLike	5.50	5.32	5.27	5.90	null	5.24	5.30	4.74
Cov_LWLinear	5.71	5.31	5.33	5.73	4.71	5.25	5.31	4.76
Cov_QuESTNonlinear	5.53	4.87	5.27	5.84	4.23	5.22	5.24	4.57
Cov_DirectNonlinear	5.55	5.09	5.27	5.91	4.31	5.23	5.26	4.68
Corr_BootstrapLike	5.52	5.39	5.23	5.68	null	5.23	5.26	4.50
Corr_LWLinear	5.40	5.29	5.12	5.51	4.20	5.08	5.09	4.42
Corr_QuESTNonlinear	5.50	4.90	5.26	5.72	3.90	5.22	5.24	4.48
Corr_DirectNonlinear	5.52	4.77	5.24	5.62	3.71	5.23	5.22	4.46
SampleCov	5.34	3.41	5.22	4.89	null	5.20	5.12	3.06
等权	4.39	4.39	4.39	4.39	4.39	4.39	4.39	4.39

数据来源：Wind 资讯，东吴证券研究所


表 7 展示了这 118 中方案下的最优因子组合的年化 ICIR。在表中，我们标注出了每种估计方法下 ICIR 最高(黄色)与最低(绿色)对应的回看时长和频率。

如表 7 所展示，表现最佳的回看时长和频率集中于 63 天和 26 周，而我们常用的滚动 12 个月这种方案，与滚动 6 个月一起，被列为表现最糟糕的回看估计方案。

与上一个案例相似，在实证分析中，并非回看窗口涵盖时间越长所得到的最优复合因子的 ICIR 越高。例如，在 Cov_DirectNonlinear 方案下，回看 26 周时，最优复合因子值 ICIR 达到 5.91，而当回看 52 周时，该值仅有 5.23。其解释也与上一个案例相同：虽然回看期数越多会对历史的协方差矩阵估计越精确，但过长的回看窗口会使得其相对于市场的变化反应变慢，这样反而会增大对未来的因子 IC 协方差矩阵预测误差。因此，我们需要在回看时间与反应速度上找到一个平衡，在本案例中，对稀疏化估计方法以及样本协方差矩阵来说，这个平衡为 63 天，而对于其余的旋转不变估计方案来说，这个平衡为 26 周。

在协方差矩阵估计的两大类方案(方案一、直接估计协方差矩阵；方案二、先估计相关系数矩阵，然后推得协方差矩阵)中，复合因子的 ICIR 表现并不像上一个案例中那样，方案二一边倒地优于方案一，反而在旋转不变估计大类中，方案一在多数情形下都要优于方案二。图 8 给出了参与计算的几个因子的月频 IC 的标准差，最低值在 4.47%，最高为 10.30%，在这种情形下，协方差矩阵的条件数未必会比相关系数矩阵的条件数大很多，此时，方案一这种一步到位的估计方案似乎更具有优势。

图 8：测试区间内的各个因子的月频 IC 波动率



数据来源：Wind 资讯，东吴证券研究所

接下来，我们给出了各个方案相对于因子等权配置方案在 ICIR 上的改进幅度，计算公式为：

$$\text{ImproveRatio} = \frac{ICIR_{\text{Method}} - ICIR_{\text{EqualWeight}}}{ICIR_{\text{EqualWeight}}} \times 100\%$$

其中， $ICIR_{\text{Method}}$ 为所要测试的方法下复合因子的 ICIR， $ICIR_{\text{EqualWeight}}$ 为因子等权配置下复合因子的 ICIR。表 8 展示了不同情形下的 ICIR 相对于因子等权配置的 ICIR 的提升比率：

表 8：不同方法下，最优复合因子的 ICIR 相对因子等权配置下 ICIR 的提升

频率时长	63天	13周	126天	26周	6个月	252天	52周	12个月
Cov_STO_Equal	14.35%	1.54%	16.68%	17.97%	-6.59%	15.72%	8.97%	-9.68%
Cov_STO_Cov	21.69%	-15.17%	18.54%	18.24%	-14.47%	17.29%	19.11%	-19.11%
Cov_STO_Sto	20.55%	-9.92%	20.13%	16.67%	-10.23%	18.73%	16.58%	-18.19%
Corr_STO_Equal	22.59%	5.45%	17.69%	15.04%	-6.19%	14.63%	11.78%	-0.97%
Corr_STO_Cov	22.74%	6.30%	19.70%	19.97%	-5.55%	16.52%	17.57%	-5.22%
Corr_STO_Sto	24.26%	4.57%	17.95%	21.81%	-5.44%	17.25%	12.84%	-8.94%
Cov_BootstrapLike	25.18%	21.15%	19.91%	34.25%	null	19.29%	20.68%	7.87%
Cov_LWLinear	30.08%	20.93%	21.43%	30.38%	7.26%	19.60%	20.83%	8.27%
Cov_QuESTNonlinear	25.97%	10.93%	19.96%	32.86%	-3.82%	18.83%	19.33%	3.99%
Cov_DirectNonlinear	26.41%	15.97%	20.07%	34.50%	-1.80%	19.16%	19.75%	6.60%
Corr_BootstrapLike	25.68%	22.72%	18.96%	29.25%	null	19.11%	19.72%	2.34%
Corr_LWLinear	22.82%	20.49%	16.46%	25.33%	-4.43%	15.58%	15.93%	0.68%
Corr_QuESTNonlinear	25.21%	11.44%	19.83%	30.09%	-11.31%	18.80%	19.29%	1.89%
Corr_DirectNonlinear	25.75%	8.62%	19.34%	27.85%	-15.48%	19.08%	18.80%	1.53%
SampleCov	21.53%	-22.37%	18.77%	11.28%	null	18.36%	16.62%	-30.31%

数据来源：Wind 资讯，东吴证券研究所

为了更加直观展示提升效果，我们将其转化为了柱状图，并在图 9 中展示：

图 9：不同方法下复合因子的 ICIR 相对因子等权配置下 ICIR 的提升柱状图



数据来源：Wind 资讯，东吴证券研究所

当估计协方差矩阵所使用的数据频率为月频时，用于估计的时间窗口内样本总量仅为 6(6 个月)或 12(12 个月)，样本量过小导致估计出的协方差矩阵误差过大，致使估计出的最优因子权重与真实最优权重相去甚远。其中，若使用过去 12 个月月频 IC，以简单的样本协方差(SampleCov)作为 IC 序列真实协方差矩阵的估计时，其最优复合因子的 ICIR 竟然比完全没有优化的等权情形的 ICIR 低 30%！在该回看周期频率下，虽然其它的复杂的方法能较大程度上提高协方差矩阵估计的准确度，使得最优复合因子的 ICIR 大幅提高，但相对于因子的等权配置方案，仍不能获得绝对优势：在回看 6

个月的月频 IC 序列情形下，只有 Cov_LWLinear 方法能击败等权组合，在回看 12 个月的月频 IC 序列情形下，15 种方案中，也仅有 8 种旋转不变估计方案能击败等权配置下的复合因子。

但随着样本量的增加，击败等权因子的方案比例开始增加，当回看长度为 13 周(1 个季度)的时候，虽然用简单样本协方差阵估计协方差矩阵的表现依然糟糕(ICIR 比等权情形下低 22%)，但其它 14 个较为复杂的估计方法中，仅有两个跑输了因子等权配置的情形，其它方案均不同程度上超越了等权因子的表现。而对于回看 26 周、52 周、63 天、126 天、252 天这几种情形，所有的估计方案均能录得超越等权基准 ICIR 的表现。

以上发现对构造因子组合具有非常强的指导意义：即便我们对股票的打分的频率仅为月频这样的相对低频的情形，在估计因子 IC 协方差矩阵时，使用相对更高频率的 IC 序列，对于构造高 ICIR 的因子组合，是有较大帮助的。

最后，我们给出了各种协方差矩阵估计方案下的最优复合因子 ICIR 相对于仅使用简单样本协方差矩阵估计(SampleCov)得到的最优复合因子 ICIR 的改进幅度，计算公式如下

$$\text{ImproveRatio} = \frac{ICIR_{\text{Method}} - ICIR_{\text{SampleCov}}}{ICIR_{\text{SampleCov}}} \times 100\%$$

其中， $ICIR_{\text{SampleCov}}$ 为使用样本协方差矩阵 SampleCov 作为 IC 序列协方差估计时的最优复合因子的 ICIR 值， $ICIR_{\text{Method}}$ 为使用其它方法估计协方差矩阵时得到的最优复合因子 ICIR 的值。两个方案所使用的回看周期和频率必须相同，例如，Corr_LWLinear 方法在回看窗口为 26 周时的表现只能与同样回看 26 周，使用 SampleCov 方法估计协方差矩阵的情形对比。改进幅度如表 9 所示。


表 9：不同方法下复合因子相对于 SampleCov 下的 ICIR 提升

频率时长	63天	13周	126天	26周	252天	52周	12个月
Cov_STO_Equal	-5.91%	30.80%	-1.76%	6.02%	-2.23%	-6.56%	29.60%
Cov_STO_Cov	0.13%	9.27%	-0.19%	6.26%	-0.91%	2.14%	16.07%
Cov_STO_Sto	-0.81%	16.04%	1.14%	4.84%	0.31%	-0.03%	17.39%
Corr_STO_Equal	0.87%	35.85%	-0.91%	3.39%	-3.15%	-4.15%	42.10%
Corr_STO_Cov	0.99%	36.94%	0.79%	7.81%	-1.55%	0.82%	36.00%
Corr_STO_Sto	2.25%	34.71%	-0.69%	9.46%	-0.94%	-3.24%	30.67%
Cov_BootstrapLike	3.00%	56.07%	0.96%	20.65%	0.79%	3.48%	54.78%
Cov_LWLinear	7.04%	55.78%	2.24%	17.17%	1.05%	3.61%	55.35%
Cov_QuESTNonlinear	3.65%	42.90%	1.00%	19.39%	0.39%	2.33%	49.21%
Cov_DirectNonlinear	4.01%	49.40%	1.10%	20.87%	0.67%	2.69%	52.96%
Corr_BootstrapLike	3.41%	58.09%	0.16%	16.16%	0.63%	2.66%	46.85%
Corr_LWLinear	1.06%	55.21%	-1.94%	12.63%	-2.35%	-0.59%	44.46%
Corr_QuESTNonlinear	3.03%	43.56%	0.89%	16.91%	0.37%	2.29%	46.20%
Corr_DirectNonlinear	3.47%	39.92%	0.48%	14.90%	0.61%	1.87%	45.69%

数据来源：Wind 资讯，东吴证券研究所

为了更加直观展示结论，我们将表 9 表示为柱状图的形式，并在图 10 中加以展示：

图 10：不同方法下复合因子相对于 SampleCov 方法下的 ICIR 提升柱状图



数据来源：Wind 资讯，东吴证券研究所

图 10 中的结果与预期完全相符，当回看样本量较小，如回看 12 个月、13 周或 26 周时，稀疏矩阵估计类或旋转不变估计类均可以大幅提高复合因子的 ICIR 值，但是随着回看样本量的增大，当回看周期达到 52 周或者 63 天时，只有旋转不变估计类能提供相对稳定的超越基准的表现，且提升幅度基本也都在 5% 以内，当回看长度达到 126 天或 252 天后， p/n 的值已经小于 0.1，在这种情形下，矩阵稀疏化或特征值压缩所能起到的增益效果非常有限，此时，复杂的协方差估计方案不能显著超越使用简单样本协方差估计的表现也就在情理之中了。

7. 总结

本文在前半部分详细梳理了两大类协方差矩阵的估计方法，第一类为稀疏矩阵方法，其本质为通过对矩阵非对角线元素施加 L1 惩罚项以及正定条件，将协方差矩阵部分非对角线元素压缩至 0，在该大类中，共引入了三个基于不同惩罚系数的子方法。第二类估计方法为旋转不变估计类，其本质为保留样本协方差矩阵的特征向量，同时调整样本协方差矩阵的特征值，达到改进协方差矩阵估计的目的，在该类中，我们介绍了一种线性压缩估计方法，一种基于模拟的特征值调整方法，以及两种基于随机矩阵理论的非线性压缩方法。

在以上所介绍方法的基础上，我们考虑了两种求解协方差矩阵的方案：在第一种方案中，矩阵稀疏化或特征值压缩的对象直接为样本协方差矩阵，一步到位得到协方差矩阵的估计；在第二种方案中，矩阵稀疏化或特征值压缩的对象为样本的相关系数矩阵，而后对估计得到的相关系数矩阵左右分别乘以包含变量标准差信息的对角矩阵，反推得到最终的协方差矩阵的估计。

综合来看，本文共介绍总共 $7 \times 2 = 14$ 种协方差矩阵估计方案。在本文的后半部分，我们将这 14 种协方差矩阵的估计方案应用在了两个不同的情境中。

第一个情境为估计风险模型中公共因子收益率的协方差矩阵。结果显示，当不同因子间波动水平差距很大时，方案二(估计相关系数矩阵，而后反推得到协方差矩阵)与稀疏化矩阵估计类，或旋转不变估计类配合，均可获得相比于方案一更大的提升，其中，旋转不变估计类对估计的提升效果更加显著。在数值模拟结果显示，样本数量增加对于协方差矩阵估计的改进比在相同样本量下更复杂的估计方法的改进效果更显著，样本数量越大，对协方差矩阵的估计精度提升越高，但在实证中，市场是动态变化的，样本数量的增加意味着回看时间的增长，也就意味着估计对于短期市场的变化反映更迟钝。因而，在协方差估计中，需要考虑反映速度与估计精度的平衡，在本文的实证中，我们发现，使用回看半年时间(126 交易日)、方案二下的线性压缩估计对未来一个月的因子协方差矩阵的估计效果最佳。

在第二个情境中，我们讨论了不同协方差矩阵估计方法在最大化复合因子 ICIR 中的应用，套用经典的最大化复合因子 ICIR 的因子权重分配公式，我们统计了在不同协方差矩阵估计方案、不同数据频率及回看长度情形下月频调仓策略的 ICIR 对比。在该案例中，我们分别指定了两个比较基准：1、等权复合因子的 ICIR；2、使用简单的样本协方差矩阵估计(SampleCov)的最优因子权重配比下的复合因子 ICIR。

当我们使用月频 IC 数据估计协方差矩阵时，样本量的稀少(滚动 1 年近 12 个月度数据)导致样本协方差估计(SampleCov)的表现大幅差于等权因子的表现，在这种情形下，若使用稀疏矩阵或者其它旋转不变估计方法，虽然能大幅改进使用简单协方差估计的表现，但改进后也仅有半数左右的方法能跑赢因子等权配置下的 ICIR。

当改用周频或日频 IC 序列估计因子收益协方差矩阵时，同样回看区间长度的样本数据量有大幅增长，伴随而来的是对于协方差矩阵估计精度的提升，进而使得各种估计方法下的最优复合因子的 ICIR 大幅提高。其中，当我们使用向前滚动 26 周或 63 天的历史 IC 序列估计协方差矩阵时，虽然用到的历史数据只有过去半年或一个季度，所有方案下的复合因子 ICIR 均能超过因子等权配置下复合因子的 ICIR 达 20% 乃至 30% 以上，甚至使用最简单的样本协方差矩阵也能超越等权表现 10% 以上。与第一个案例相同，随着回看样本量的增大，复杂估计方式相比于简单的协方差估计矩阵的优势也在缩小，当回看周期达到 126 天或 252 天时，矩阵稀疏化或旋转不变估计方式相对于简单样本协方差估计不再具有明显优势。在本案例中，回看 26 周 IC 值，对协方差矩阵直接施以旋转不变估计能达到最优的回测效果，其相对于等权因子配置下的 ICIR 的提升在 30%-35% 的水平。

本文相对于协方差矩阵的探讨还有很多不足之处，例如，我们没有讨论相关系数矩阵与因子波动水平分别使用不同频率、不同回看长度的历史数据会不会达到更优的估计效果，也没有讨论收益波动率提高的因子的波动率变化趋势具有动量效应或是反转效应，进而动态修正对未来因子波动率的预测。这些内容将放在我们以后的研究中，敬请期待！

8. 风险提示

本报告所有的结论均使用历史数据回测得到，模型在未来存在失效风险。

附注：

[1] 感谢东吴金工实习生傅开波对本报告的重要贡献。

[2] Bickel, P. and Levina, E. Covariance regularization by thresholding. Annals of Statistics. 2008(36):2577-2604.

[3] Rothman, A. J., Levina, E. and Zhu, J. Generalized thresholding of large covariance matrices. Journal of the American Statistical Association. 2009(104): 177-186.

[4] Lingzhou Xue, Shiqian Ma and Hui Zou Positive-Definite L1-Penalized Estimation of Large Covariance Matrices. Journal of the American Statistical Association. 2012, 107(500): 1480-1491.

[5] Han Liu, Lie Wang, Tuo Zhao. Sparse Covariance Matrix Estimation With Eigenvalue Constraints. Journal of Computational & Graphical Statistics. 2014 23(2): 439-459.

[6] Bickel, P. and Levina, E. Covariance regularization by thresholding. Annals of

Statistics. 2008(36): 2577-2604.

[7] Perlman, M.D. Multivariate Statistical Analysis. Online textbook published by the Department of Statistics of University of Washington, Seattle, 2007.

[8] Jose Menchero, Jun Wang, D.J.Orr. Eigen-Adjusted Covariance Matrices. MSCI Research Insight. 2011.

[9] Oliver Ledoit, Michael Wolf. A well-conditioned estimator for large-dimensional covariance matrices. Journal of Multivariate Analysis. 2004, 88(2): 365-411.

[10] Olivier Ledoit, Michael Wolf. Spectrum estimation: A unified framework for covariance matrix estimation and PCA in large dimensions. Journal of Multivariate Analysis. 2015(139): 360-384.

[11] Olivier Ledoit, Michael Wolf. Direct Nonlinear Shrinkage Estimation of Large-Dimensional Covariance Matrices. Working paper.

[12] Silverstein, J.W. Strong convergence of empirical distribution of eigenvalues of large dimensional random matrices. Journal of Multivariate Analysis 1995(55): 331-339.

[13] Olivier Ledoit, Sandrine P éché EigenVectors of some large sample covariance matrix ensembles. Probability Theory and Related Fields. 2011(151): 233-264.

[14] Oliver Ledoit, Michael Wolf. Nonlinear shrinkage estimation of large-dimensional covariance matrices. The Annals of Statistics 2012(40) 2:1024-1060.

[15] Olivier Ledoit, Michael Wolf. Numerical implementation of the QuEST function. Computational Statistics and Data Analysis. 2017(115): 199-223.

[16] Yao, J. Identifying the number of factors from singular values of a large sample auto-covariance matrix, In: Complex Systems in Time Series, London School of Economics. 2015.

免责声明

东吴证券股份有限公司经中国证券监督管理委员会批准，已具备证券投资咨询业务资格。

本研究报告仅供东吴证券股份有限公司（以下简称“本公司”）的客户使用。本公司不会因接收人收到本报告而视其为客户。在任何情况下，本报告中的信息或所表述的意见并不构成对任何人的投资建议，本公司不对任何人因使用本报告中的内容所导致的损失负任何责任。在法律许可的情况下，东吴证券及其所属关联机构可能会持有报告中提到的公司所发行的证券并进行交易，还可能为这些公司提供投资银行服务或其他服务。

市场有风险，投资需谨慎。本报告是基于本公司分析师认为可靠且已公开的信息，本公司力求但不保证这些信息的准确性和完整性，也不保证文中观点或陈述不会发生任何变更，在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。

本报告的版权归本公司所有，未经书面许可，任何机构和个人不得以任何形式翻版、复制和发布。如引用、刊发、转载，需征得东吴证券研究所同意，并注明出处为东吴证券研究所，且不得对本报告进行有悖原意的引用、删节和修改。

东吴证券投资评级标准：

公司投资评级：

买入：预期未来 6 个月个股涨跌幅相对大盘在 15%以上；

增持：预期未来 6 个月个股涨跌幅相对大盘介于 5%与 15%之间；

中性：预期未来 6 个月个股涨跌幅相对大盘介于-5%与 5%之间；

减持：预期未来 6 个月个股涨跌幅相对大盘介于-15%与-5%之间；

卖出：预期未来 6 个月个股涨跌幅相对大盘在-15%以下。

行业投资评级：

增持：预期未来 6 个月内，行业指数相对强于大盘 5%以上；

中性：预期未来 6 个月内，行业指数相对大盘-5%与 5%；

减持：预期未来 6 个月内，行业指数相对弱于大盘 5%以上。

东吴证券研究所

苏州工业园区星阳街 5 号

邮政编码：215021

传真：（0512）62938527

公司网址：<http://www.dwzq.com.cn>