

如何在多因子模型中识别有效因子

——海外文献速览系列之六

2021 年 08 月 02 日

金融工程 定期报告

分析师 | 高智威 电话：0755-82832012 邮箱：gaozhw@dxzq.net.cn

执业证书编号：S1480521030002

投资摘要：

在开发量化投资策略时，海外优秀论文往往能够提供新的思路和方法，为了能够让各位投资者更有效率地吸收海外的经验，东兴金工团队推出**海外文献速览系列**报告。我们将定期从海外文献中筛选思路较为新颖且有潜力应用于国内市场投资的文章，以速览的形式呈现给各位投资者，内容涵盖**资产配置、量化选股、基金评价**以及**衍生品投资**等多个方面。

本篇报告作为该系列报告的第六篇，我们选取了 Campbell R. Harvey, Yan Liu 的文献《**Lucky Factors**》。本文作者利用个股数据，建立面板回归模型，构建了新的假设检验方法，研究了常用的风险因子中对截面预期收益的解释力较强的因子有哪些，值得投资者关注。

确定在截面上驱动预期收益的因子是具有挑战性的，这有至少三方面的原因。第一，检验方法的不同（时间序列回归与截面回归）将给出不同的有效因子结果。第二，不同的投资组合上进行测试会改变候选因子的重要性。第三，考虑到已经提出的数百个因子，在检验过程中必须要处理测试多重性。为此，作者提出了一种新方法，在应对这些挑战方面取得了可观的进展。作者将该方法应用于面板回归中，并展示了令人费解的实证结果，即市场收益因子解释了股票收益率的大部分方差，但在截面回归中却经常被剔除。在本文中，作者没有去掉市场因子。此外，作者绕过了投资组合，而是在不损失解释力的前提下对个股进行测试。最后，作者利用 bootstrap 方法，提出了一个在截面上没有解释力的原假设，从而自然地控制了多重测试的问题。

实证过程表明，这种新的研究框架在针对宽面板，特别是以个股作为测试资产时，能够有效克服 GRS 检验的局限性，并且具有稳健性和灵活性，能够挖掘出一部分在截面预期收益上显著有效的风险因子。实证结果说明，市场收益因子（mkt）、规模（smb）、账面市值比（hml）能够有效降低截面上的等权定价误差；mkt 因子和盈利能力相关因子（qmj）能够有效降低截面上的市值加权定价误差。另外，在扩充了初始的因子集后，实证结果并没有本质上的改变，证明了这种研究框架的稳健性。最后，在考虑择时因子载荷后，作者根据之前的结果重构了模型，使用混合面板回归方法，验证了市场收益、规模和账面市值比三类因子的有效性，也为日后的进一步研究提供了新的思路。

本篇文章基于美国市场的股票数据，在国内市场中股市收益、规模、账面市值比和盈利能力相关的风险因子是否也具有类似的结论值得进一步研究。但如果作者提出的这种结合 bootstrap 方法的面板回归模型、及相应的假设检验方法在国内也依然具有稳健性，那么可以为有效选股因子的选择过程提供一个新思路。

风险提示

本报告内容来源于相关文献，不构成投资建议。文中的结果基于原作者对美国市场历史数据进行的实证研究，当市场环境发生变化的时候，存在模型失效的风险。

目 录

1. 研究背景.....	4
2. 测试方法.....	5
2.1 面板回归模型	5
2.2 备选的回归框架	7
2.3 一些讨论	8
2.3.1 Bootstrap 的假设检验	8
2.3.2 “有用的”因子	8
2.3.3 多重假设检验	8
2.3.4 检验方法的顺序性	8
2.3.5 相关文献	8
3. 实证应用：识别有效的风险因子	9
3.1 备选的风险因子	9
3.2 检验统计量	10
3.3 主要结果：将个股作为测试资产	12
3.3.1 模拟研究	13
3.3.2 市值加权统计量	15
3.3.3 基于个股的测试结果	15
3.3.4 在更大的因子备选集中进行测试	20
3.3.5 经过分类整合的投资组合	22
3.4 稳定性检验	22
3.5 择时因子载荷和其他问题	22
3.6 注意事项	23
4. 结论.....	24
5. 我们的点评.....	25
6. 参考文献.....	25
7. 风险提示.....	25
相关报告汇总	26

插图目录

图 1： 月度因子收益的描述性统计（1968 年 1 月~2012 年 12 月）	10
图 2： 基于个股的模拟研究结果（T=240）	14
图 3： 基于个股的模拟研究结果（T=480）	14
图 4： 调整后的基于个股的模拟研究结果	15
图 5： 基于个股的等权统计量测试结果	16
图 6： 基于个股的市值加权统计量测试结果	19
图 7： 基于个股的等权统计量测试结果（56 个因子）	21
图 8： 基于个股的市值加权统计量测试结果（56 个因子）	22

图 9： 混合面板回归模型结果.....23

表格目录

表 1： 因子缩写及其具体含义.....9

1. 研究背景

在开发量化投资策略时，海外优秀论文往往能够提供新的思路和方法，为了能够让各位投资者更有效率地吸收海外的经验，东兴金工团队推出**海外文献速览系列**报告。我们将定期从海外文献中筛选思路较为新颖且有潜力应用于国内市场投资的文章，以速览的形式呈现给各位投资者，内容涵盖**资产配置、量化选股、基金评价以及衍生品投资**等多个方面。

本篇报告作为该系列报告的第六篇，我们选取了 Campbell R. Harvey, Yan Liu 的文献《**Lucky factors**》。

哪些因子可以在截面和时间序列上解释预期收益呢？有数百篇论文提出了各种各样的因子。还有许多新的论文旨在帮助研究人员选择一组恰当的因子。然而，选择因子的这个过程仍然存在许多问题。比如，选定一组因子的过程与进行测试的投资组合密切相关。另外，识别有效因子还受到测试方法（即时间序列回归和横截面回归）的影响。最后，考虑到大量的候选因子，这其中有些可能只是“幸运的”，仅仅是因为测试的多重性才被提出。

本文主要面临的问题有三个方面。首先，作者希望对资产定价测试的时间序列和横截面两方面有更多的了解。例如，为什么市场因子是迄今为止最重要的时间序列上的收益驱动因子（以及几乎所有投资组合形成时的第一个主成分），但市场因子却常常被剔除，或者更糟的是，当与其他因子结合在一起时，会改变信号？市场因子具有明显的理论吸引力，但其实证成功率有限。

其次，众所周知，资产定价结果高度依赖于构建投资组合的方法。例如，流行的 HML 和 SMB 因子可能适用于按规模和价值分类的 25 个投资组合，但在按行业分类的投资组合中效果不佳。理想情况下，在测试中不应使用投资组合，但不可否认的是，使用投资组合可以降低噪声。

第三，面对数百种因子，需要直接面对多重测试问题。在因子测试的典型设置中，假设有一组预先确定的因子和另一组备选因子。如果想知道某一个备选因子的表现有多好，就需要考虑到测试过程中的运气成分，宣布有用并与预先确定的因素分组。

本文解决了上述所有这些问题，并在每一个方面都取得了一定的进展。作者提出了一种分步模型选择方法，该方法是专门为面板回归因子测试设计的，并且可以很容易地适应其他测试框架。作者提出了一种 bootstrap 方法来从备选因子中选择“有用”的因子，其中，在原假设下，备选因子的横截面解释力为零。虽然 bootstrap 方法并不新鲜，但本文的具体实现是新的，并且对于识别增量因子非常有用。

本文的实证分析过程侧重于面板回归方法，该回归模型检验当截面上有很多测试资产时“有用”的风险因子，因此与著名的 Gibbons、Ross 和 Shanken (GRS, Gibbons 等人, 1989) 检验法相关。考虑到本文所用的面板回归模型属于宽面板，即相对于时间序列维度具有较大的横截面，GRS 检验法的几个问题可能是无法克服的。首先，当截面维数较高时，很难可靠地估计残差协方差矩阵。一个相关的问题是，GRS 统计量变得异常大，截面上的资产数量也很大，这将导致我们拒绝大多数因子模型。最后，根据 GRS 检验得出来的均值-方差有效投资组合中某些资产常常会有不切实际的空头头寸 (Fama 和 French, 2015b)，使人对其经济解释产生怀疑。对此，作者提出了一些备选的检验统计量，这些统计量是从 GRS 统计量出发联想得到的，但对残差协方差矩阵的准确估计的依赖性较小。并且从经济角度看，它们也更容易理解，因为它们试图抓住与投资者财务相关的投资机会。作者还展示了如何通过一个 bootstrapping 过程对这些检验统计量进行估计。

本文的研究框架也提供了一种比 GRS 检验框架更直观的方法来对过去 50 年中提出的无数因素进行排序。假设现在需要比较两个备选的因子模型：基础模型 M 和增广模型 M+。尽管研究人员经常使用 M 和 M+ 产生的 GRS 统计量之间的差异来衡量 M+ 的增量贡献，但不清楚这种推断是如何工作的。问题的核心是 M 和 M+ 是在两个不同的零假设下构建的，在 GRS 检验法下，这两个假设是不相容的。相比之下，本文的研究框架提出的检验统计量允许将 M 设置为与原假设对应的模型，然后评估 M+ 的增量贡献。考虑到一些关于截面预期股票收益的文献中提到的控制多重测试的重要性，这个方法的另一个好处是，如果尝试了多个 M+，使用这种方法能够重新评估每个 M+ 的重要性。可以通过对检验统计量的显著性排序取最大值的方法来实现这一点。

本文并没有解决所有问题，也没有为资产定价测试提供灵丹妙药。但是作者认为，本文给出的研究方法是一个适度的创新，也是一个特别有用的因子选择，或者回归选择方法。本文的结构如下。在第二部分中，作者介绍了本文使用的测试框架。在第三部分，作者将该方法应用于选择在截面收益上有解释力的风险因子，也提供了基于传统投资组合和个股的两种测试资产的见解。最后一节提供了一些结论。

2. 测试方法

作者在面板回归的背景下提出了本文使用的模型，这与本文中的主要应用相对应。该模型对预测回归和 Fama-MacBeth 横截面回归的适应性将在在线附录第 ID 节中给出，这一节还包含了关于该方法的实施细节。与横截面回归相比，在面板回归中，个别股票收益的极端观测值和潜在的模型错误的影响可能会减轻（作者将在后面更详细地讨论这个问题）。因此，以个股作为测试资产的首选模型是一个面板回归模型。

2.1 面板回归模型

本文所用的方法可以应用于资产定价测试中常用的面板回归模型，其中资产收益是在一组公共因子上回归的。构建该模型的目的是既要选择备选因子，又要解开其在时间序列和横截面上解释力强弱。

首先写下下一个时间序列回归模型，

$$R_{i,t} - R_{f,t} = a_i + \sum_{j=1}^K b_{i,j} f_{j,t} + \epsilon_{i,t}, \quad i = 1, \dots, N, \#(1)$$

在该式中，超额时间序列 $R_{i,t} - R_{f,t}$ 被投影到 K 个同期因子收益上， $f_{j,t}$ 。要素收益是与零成本投资相对应的多空策略收益。如果一组因素是均值-方差有效的（或者，等价地，如果相应的 beta 定价模型是真的），回归截距的横截面应该与零不可区分。这构成了经典 GRS 检验的可检验假设。

GRS 检验广泛应用于实证资产定价研究，但有几个问题阻碍了该检验或一般时间序列检验的进一步应用。首先，GRS 测试几乎总是拒绝。这意味着几乎没有模型能够成功地解释截面预期收益。因此，大多数研究人员使用 GRS 检验作为模型性能的一种度量（参见，例如，Fama 和 French, 2015a）。例如，如果模型 A 产生的 GRS 统计量比模型 B 小，我们会将模型 A 作为“更好”的模型，尽管两个模型都没有通过 GRS 检验。但是模型 A 的性能是否“明显”超过了 B？最初的 GRS 检验无法回答这个问题，因为检验的原假设是所有截距项都严格等于零。当两个相互竞争的模型都产生不为零的截距时，GRS 检验的设计初衷并不是用来衡量两个模型的相对性能的。

本文所用的方法为这个模型比较问题提供了一个潜在的解决方案。特别是，对于嵌套的两个模型，它允许研究人员度量较大模型相对于较小模型的增量贡献，即使两个模型都不能满足 GRS 原假设。其次，基于小 N

(横截面维数)和大 T (时间序列维数) 的渐近逼近的 GRS 检验的推论可能是有问题的。例如, 对于小 N , MacKinlay (1987) 表明, 当时间序列样本量较小时, 检验的可信力往往会下降。Affleck-Graves 和 McDonald (1990) 表明, 资产收益的非正态性会严重扭曲 GRS 检验的规模和/或可信力。作者所用的方法依赖于 bootstrap 模拟, 并且对小样本或非正态性失真具有鲁棒性。事实上, 通常建议使用基于 bootstrap 的重采样技术来减轻这些偏差来源。最后, 对于本文中在具有较大 N 和相对较小 T 的面板上的应用, GRS 检验通常不起作用。

作者试图通过使用自己的 bootstrap 方法来克服 GRS 检验中的上述缺点。具体来说, 作者将因子收益正交化, 使得正交化因子不影响截面预期收益。这种对截面没有影响的情况构成了原假设。在原假设下, 作者通过 bootstrap 方法得到了截面上定价误差的实证分布。然后, 作者将原始因子下产生的截面定价误差的实际 (即真实值) 与此实证分布进行比较, 以推断因子的显著性。这个面板回归方法可以描述成如下形式:

不失一般性, 假设只用一个因子, 例如市场超额收益 $f_{1,t} = R_{m,t} - R_{f,t}$, 对 (1) 式两边同时取无条件期望, 可以得到,

$$E(R_{i,t} - R_{f,t}) = a_i + b_{i,1}E(f_{1,t}) \quad \#(2)$$

资产的平均超额收益可以被分解为两部分, 第一部分是时序回归截距项 (a_i), 第二部分是时序回归斜率和平
均因子收益的乘积 ($b_{i,1}E(f_{1,t})$)。

为了让单因子模型生效, 需要令所有资产的截距项等于 0, 即 $a_i = 0$ 。将这个条件引入 (2) 式, 可以得到 $b_{i,1}E(f_{1,t}) = E(R_{i,t} - R_{f,t})$ 。直观地说, $b_{i,1}E(f_{1,t})$ 的横截面需要与预期资产收益 (即 $E(R_{i,t} - R_{f,t})$) 的横截面一致, 以充分吸收时间序列回归中的截距。在时序回归中, 这个条件很难满足, 因为截面上的风险载荷是由各个单独的时序回归决定的。这些风险载荷可能与截面上的预期收益一致, 从而使单因子模型生效, 也可能不一致。这表明一些因子可能在时间序列回归时会产生一个较大的 R^2 , 但对解释截面上的预期收益贡献不大。

从 (2) 式可得到的另一个重要结果是: 一方面, 如果令 $E(f_{1,t}) = 0$, 那么因子 $f_{1,t}$ 对截面上的预期资产收益的影响为零。实际上, 如果 $E(f_{1,t}) = 0$, 那么时序回归的截距项在这个截面上的值应该恰好等于截面上的预期超额收益, 因子模型应该能够解释这一现象。另一方面, 截面因子均值为 0 并不影响时序回归, R^2 和回归系数 $b_{i,1}$ 都会被保留下来。

从之前的讨论中, 作者产生了设计测试方法的灵感。对于单因子模型, 作者定义一个“伪”因子 $\tilde{f}_{1,t}$, 它等于从原时间序列中减去其样本内平均值。这个伪因子维持了 $f_{1,t}$ 原有的在时间序列上的解释力, 但在解释截面上的预期收益方面没有任何作用。利用伪因子, 作者用 bootstrap 方法重新采样时间段, 以获得统计数据的分布。该统计数据总结了在截面上的定价错误情况 (即回归截距上的错误)。可选的统计数据包括截距绝对值的平均/中位数、均方截距和 t 统计量的绝对值。之后, 作者将原始因子的统计数据与进行 bootstrap 之后的数据进行比较。

该方法直接适用于多因子模型。假设现在有 K 个预选因子, 需要测试第 $(K+1)$ 个因子。首先应该通过时间序列回归将 $(K+1)$ 因子投影到预选的因子上。然后在通过从 $(K+1)$ 因子中减去回归截距来定义新的伪因子。这与前面的单因子模型示例类似。在单因子模型中, 这个过程等同于将因子投影到一个常数上。

为了便于理解, 作者以单因子模型为例, 展示了该方法是如何进行的。对于单因子基础模型, 资产 i 的回归方程为,

$$R_{i,t} - R_{f,t} = a_i + b_{i,1}f_{1,t} + e_{i,t} \quad \#(3)$$

往基础模型中加入一个新的因子 $f_{2,t}$ ，并将更改后的模型表示为，

$$R_{i,t} - R_{f,t} = a_i^* + b_{i,1}^* f_{1,t} + b_{i,2}^* f_{2,t} + e_{i,t}^* \quad \#(4)$$

如果 $f_{2,t}$ 比 a_i 更有助于解释截面上的预期收益，那么 a_i^* 应该更接近 0，因此，只需比较 a_i 和 a_i^* 。通常情况下， $a_i^* \neq a_i$ 。那么只需调整 $f_{2,t}$ 的值，使调整后的 $f_{2,t}^*$ 失去在截面上的解释力，即满足 $a_i^* = a_i$ 。具体来说，作者将 $f_{2,t}$ 投影到 $f_{1,t}$ 上，这一过程的回归方程为

$$f_{2,t} = \delta_0 + \delta_1 f_{1,t} + \varepsilon_t \quad \#(5)$$

$$f_{2,t}^* \equiv f_{2,t} - \delta_0 = \delta_1 f_{1,t} + \varepsilon_t \quad \#(6)$$

根据定义，用 $f_{2,t}^*$ 代替（4）式中的 $f_{2,t}$ 后，可以确保 $a_i^* = a_i$ ，即

$$\begin{aligned} R_{i,t} - R_{f,t} &= a_i^* + b_{i,1}^* f_{1,t} + b_{i,2}^* (\delta_1 f_{1,t} + \varepsilon_t) + e_{i,t}^* \\ &= a_i^* + (b_{i,1}^* + b_{i,2}^* \delta_1) f_{1,t} + \underbrace{(b_{i,2}^* \varepsilon_t + e_{i,t}^*)}_{u_{i,t}^*} \quad \#(7) \end{aligned}$$

根据残差的性质， ε_t 和 $e_{i,t}^*$ 都是与 $f_{1,t}$ 和 **1** 向量正交的。因此，可以将 $u_{i,t}^* = b_{i,2}^* \varepsilon_t + e_{i,t}^*$ 当作新的回归残差。对比（3）式和（7）式，可以发现

$$a_i^* = a_i, \quad b_{i,1}^* + b_{i,2}^* \delta_1 = b_{i,1}$$

对新加入的因子进行这个调整是有经济意义的。在（6）式两侧取期望，可以得到

$$E(f_{2,t}^*) = \delta_1 E(f_{1,t})$$

由此可知，在经济意义上，调整后的新因子 $f_{2,t}^*$ 被预选因子吸收了，因为其溢价完全由预选因子的敞口来解释。在这种情况下，调整后的因子对截面上的预期收益的影响为零。同时，它与样本中的原始因子序列具有良好的时序相关性，与预选因子具有与原始因子相同的时序相关性。因此，调整后的因子除了均值外，保留了原始因子的时间序列特性。

使用这个伪因子，用 **bootstrap** 方法（即重新采样时间段）可以生成定价误差的分布。在这一步中，与单因子情况不同，无论是对于原始回归还是基于伪因子的 **bootstrap** 回归，都会始终保留模型中的原始 K 个因子。通过这种测试方法，作者得以研究候选因子的增量贡献。可以把这种方法归为一种逐步模型选择方法。

2.2 备选的回归框架

使用该研究框架时，可以直接调整所用的回归方法，以适应不同的设置，如预测回归，或是 Fama 和 MacBeth（1973）的截面回归。在 ID.1 部分的在线附录中，作者使用预测回归设置来讨论引导实现的其他细节。然后，作者在在线附录的 ID.2 节中，在 Fama-MacBeth 回归框架内重新构建了这个模型。

在本文中，作者主要以个股为单位应用这种回归方法。作者认为，在使用个股时，面板回归应优先于截面回归（即 Fama-MacBeth 回归）。原因是，面板回归允许特定资产吸收与利息无关的特质项，从而减轻极端观测和模型错误的影响。事实上，模拟研究表明，面板回归比截面回归更有效。

2.3 一些讨论

2.3.1 Bootstrap 的假设检验

在三种不同的情况下（即预测回归、面板回归和 Fama-MacBeth 截面回归），都可以通过之前的正交化步骤调整右侧变量使其在样本中显得不相关进而变得有用；也就是说，它们在样本中实现了零假设。在零假设下，可以通过重采样得到检验统计量的 bootstrap 分布来进行假设检验。

本文所使用的方法，与一些在资产定价中使用非参数 bootstrap 过程进行推断的文献密切相关。例如，Kosowski 等人（2006）和 Fama 与 French（2010）将零 alphas 设为原假设，并使用 bootstrap 方法对基金绩效进行推断。Ferson 与 Foerster（1994）在模拟环境中使用了 bootstrap 方法，在数据生成过程中生成了备选图。Ludvigson 与 Ng（2009）应用 bootstrap 方法获得了广义标准误差，该误差解释了在他们的第一阶段因子模型估计中的不确定性。本文中所使用的 bootstrap 方法与 Kosowski 等人（2006）和 Fama 与 French（2010）相似，因为作者还试图强制将零假设保留在样本中，并使用 bootstrap 方法进行假设检验。本文中，作者使用 bootstrapping 方法的创新点在于构造特定的因子测试的原假设，并且它在不同的回归框架中有所不同。

2.3.2 “有用的”因子

如果某因子有助于解释截面上的预期收益，就可以认为该风险因子是“有用的”，也就是说，它有助于减少面板回归中的 alpha。在在线附录的 IE.2 节中，作者提供了相关细节。

2.3.3 多重假设检验

本文所使用的回归框架，旨在抑制 Harvey 等人（2016）、Green 等人（2017）和 Hou 等人（2020）最近的论文中分析的因子激增现象。特别是，作者建立因子测试的方式允许其应用 White（2000）和 Romano 与 Wolf（2005）的 reality bootstrap 方法，其目的是控制家庭错误率（family-wise error rate, FWER），即在多个检验中做出至少一个错误发现的概率。在在线附录 IE.3 节中，作者讨论了关于多重假设检验的相关论文。

2.3.4 检验方法的顺序性

作者在在线附录 IE.4 节中讨论了本文使用的逐步模型选择法与替代方法的优缺点。值得注意的是，无论该方法是否依赖添加因子的顺序，都不会影响其在测试的每个阶段的有效性（即，一组因子中的最佳因子是否在多重测试调整的统计阈值下在模型中存活，这与可能预先存在的因素有没有关系）？后续文献中采用本文测试框架的范例论文包括 Lin、Palazzo 与 Yang（2020）、Chen 等人（2019）和 Croce 等人（2019）的论文。这些论文采用预先选定的一组因子，并使用类似的方法来评估他们提出的因子的增量贡献。

2.3.5 相关文献

作者还对相关文献进行了讨论。特别是，讨论了本文的方法和 GRS 测试之间的联系，调和了本文的检验方法和流行（Barillas 与 Shanken, 2017）方法之间的差异，并将本文所用的测试框架与随机折现因子（stochastic discount factor, SDF）的文献联系起来。作者在在线附录 IE.5 节中提供了相关讨论的详细信息。

3. 实证应用：识别有效的风险因子

在本节中，作者将面板回归模型应用于风险因子的选择。逐步选择有助于解释截面预期收益的风险因子，同时控制测试多重性。

3.1 备选的风险因子

原则上，前文提出的这个方法可以应用到对所有已提出的风险因子进行分类的重大任务中。该方法吸引人的一个特点是它允许风险因子的数量大于测试投资组合的数量，这在传统的多元回归模型中是不可行的。然而，本文并不追求这一点，而是将重点放在一组精选的显著风险因素上。如何选择测试组合是一个主要的争议问题，因为不同的测试组合会导致不同的结果。相比之下，对个股进行测试则避免了随意构建投资组合。因此，作者将在流行的投资组合和个股上应用该面板回归方法。

具体来说，作者选取了 14 个主流的风险因子来应用这一面板回归方法。将这 14 个因素作为备选风险因子，并逐步选择这组因子。表 1 中展示了这些因子的缩写。

表1：因子缩写及其具体含义

缩写	具体含义	来源
rmw	profitability	Fama 与 French (2015a)
cma	investment	Fama 与 French (2015a)
mkt	market	Sharpe (1964)
smb	size	Fama 与 French (1993)
hml	book-to-market	Fama 与 French (1993)
roe	profitability	Hou 等人 (2015)
ia	investment	Hou 等人 (2015)
bab	betting against beta	Frazzini 与 Pedersen (2014)
gp	gross profitability	Novy Marx (2013)
psl	liquidity	Pástor 与 Stambaugh (2003)
mom	momentum	Carhart (1997)
qmj	quality minus junk	Asness 等人 (2019)
skew	coskewness	Harvey 与 Siddique (2000)
civ	common idiosyncratic volatility	Herskovic 等人 (2016)

资料来源：《Lucky Factors》，2021 年 4 月 21 日

图 1 中给出了这 14 个主要因子的汇总统计数据。这 14 个风险因子产生了可观的多空策略收益。其中九个策略收益的 t 统计量高于 3.0，这是 Harvey 等人 (2016) 提出的一个潜在的新截止点。相关系数矩阵表明某些因素有聚集效应。首先是“价值”组，由账面市值比 (hml)、Fama and French (2015a) 投资因子 (cma) 和 Hou 等人 (2015) 投资因子 (ia) 组成。第二个是“盈利能力”组，由 Fama 和 French (2015a) 的盈利能力因子 (rmw)、Hou 等人 (2015) 的盈利能力因子 (roe) 和 Asness 等人 (2019) 的 qmj 因子组成。例如，cma 和 ia 的相关性为 0.90，rmw 和 qmj 的相关性为 0.76。

图1：月度因子收益的描述性统计（1968年1月~2012年12月）

Panel A: Factor returns														
	mkt	smb	hml	mom	skew	psl	roe	ia	qmj	bab	gp	cma	rmw	civ
Mean	0.052	0.022	0.048	0.081	0.024	0.055	0.068	0.057	0.048	0.105	0.039	0.047	0.033	0.060
t-stat	[2.17]	[1.32]	[3.08]	[3.54]	[1.84]	[2.99]	[5.09]	[5.76]	[3.74]	[5.98]	[3.24]	[4.44]	[2.92]	[3.48]

Panel B: Factor correlation matrix														
	mkt	smb	hml	mom	skew	psl	roe	ia	qmj	bab	gp	cma	rmw	civ
mkt	1.00													
smb	0.30	1.00												
hml	-0.32	-0.24	1.00											
mom	-0.14	-0.03	-0.15	1.00										
skew	-0.02	-0.05	0.23	0.03	1.00									
psl	-0.05	-0.04	0.03	-0.03	0.10	1.00								
roe	-0.19	-0.39	-0.11	0.51	0.19	-0.06	1.00							
ia	-0.39	-0.26	0.69	0.04	0.15	0.02	0.04	1.00						
qmj	-0.54	-0.54	0.02	0.26	0.13	0.03	0.68	0.15	1.00					
bab	-0.09	-0.07	0.40	0.18	0.24	0.06	0.25	0.35	0.19	1.00				
gp	0.08	0.06	-0.34	0.01	-0.01	-0.03	0.34	-0.26	0.45	-0.11	1.00			
cma	-0.41	-0.16	0.71	0.01	0.05	0.03	-0.10	0.90	0.07	0.32	-0.34	1.00		
rmw	-0.21	-0.42	0.11	0.10	0.27	0.03	0.68	0.05	0.76	0.26	0.49	-0.08	1.00	
civ	0.17	0.27	0.13	-0.18	0.04	0.05	-0.26	-0.00	-0.28	0.11	-0.00	0.04	-0.10	1.00

资料来源：《Lucky Factors》，2021年4月21日

为了测试研究结果对本文所研究的这一组因素的敏感性，作者还考虑了由 Ehsani 与 Linnainmaa（2021）所使用的 56 个因子（包括前文提到的 14 个主要因子）的扩展列表。作者参考 Ehsani 与 Linnainmaa（2021）的文章了解那些因子的详细信息。

3.2 检验统计量

在本节中，作者提出了一些同时具有经济和统计意义的检验统计量。直观地说，一个好的检验统计量应该能够反映出在解释截面预期收益时，基础模型和添加一个额外变量后的增广模型之间的差异。对于面板回归模型，令 $\{a_i\}_{i=1}^N$ 和 $\{a_i^+\}_{i=1}^N$ 分别代表基础模型和增广模型在截面上的回归截距项。令 $\{s_i\}_{i=1}^N$ 为基础模型在截面上的回归截距的标准差。由此，作者引入了第一个检验统计量：

$$SI_{ew}^m \equiv \frac{\frac{1}{N} \sum_{i=1}^N (|a_i^+| - |a_i|) / s_i}{\frac{1}{N} \sum_{i=1}^N |a_i| / s_i}$$

其中，SI 表示按比例计算的截距（scaled intercept），ew 代表等权，m 代表均值。直观来看， SI_{ew}^m 衡量的是回归截距绝对值的百分比差异，该差异由基础模型的回归截距标准差来衡量。如果增广模型优于基础模型， SI_{ew}^m 应该为负，即定价误差减小。在原假设定为增广模型中的新加因子对解释截面预期收益的增量贡献为 0 的前提下，这种在定价误差上提升的显著性可以根据进行 bootstrap 方法后的实证分布来进行评价。

虽然 SI_{ew}^m 计算了比例截距绝对值均值的百分比差异，但它对截面上的极端观测值而言可能并不稳健，特别是当使用个股作为研究对象时。因此，作者引入了一个稳健性较好的检验统计量，计算比例截距绝对值的中位数，即 SI_{ew}^{med} 的百分比差值：

$$SI_{ew}^{med} \equiv \frac{\text{med}(\{|a_i^+| / s_i\}_{i=1}^N) - \text{med}(\{|a_i| / s_i\}_{i=1}^N)}{\text{med}(\{|a_i| / s_i\}_{i=1}^N)}$$

其中 med 表示一组变量的中位数，用上标 med 表示。

使这两个检验统计量有效的一个关键假设是，如果增广模型中的新加因子是有用的，即增广模型比基础模型更有助于解释截面上的预期收益，那么 $|a_i^+|$ 的截面均值应该小于 $|a_i|$ 的截面均值。在个股层面，如果增广模型是更准确的资产定价因子模型，那么总体上 $|a_i^+|$ 应该小于 $|a_i|$ ，假设有足够长的因子和资产收益的时序数据。事实上，如果增广模型是更正确的，那么 a_i^+ 应该在总体上为 0，不大于在错误的基础模型下的 $|a_i|$ 。

之所以使用按比例计算的截距，而不是原始截距数据，主要是出于以下几个原因。首先，在时间序列回归模型中，将零成本投资组合（即因子代理）的拟合组合作为基准指数，那么比例截距与持有测试资产、卖空基准指数的多空策略的信息比率密切相关。当测试资产不是多样化的投资组合时，信息比率是衡量投资策略经济意义的一个更好的尺度。这类似于在绩效评估中使用 t 统计量而不是 Jensen's alpha。通常 alpha 的 t 统计量，而不是 alpha 本身，能更准确地表明基金经理的收益率有多“异常”。

其次，比例截距的使用考虑了收益波动率的特质性。假设两个股票在拟合因子模型时产生相同的回归截距。用回归截距的绝对值来衡量的因子模型的错误定价程度，对于噪声较小的股票应该更高。换句话说，在面板回归模型中，应该给噪音较大的股票分配较少的权重。当研究人员把个股作为测试资产时，这一点是特别重要的，因为存在大量的特质性的收益波动。

最后，本文使用的比例截距与 Hall 和 Wilson (1991) 的 bootstrap 假设检验的第二个原则是一致的。事实上，用标准差来衡量截距正是他们所建议的获得关键统计数据的方法。

本文所使用的检验统计量的另一个重要特征是，使用相同的标准差（基础模型下截距估计值的标准差）来缩放基础模型和增广模型的截距。这确保当遵循原假设（即候选因子对解释截面预期收益的增量贡献为 0）时，两个检验统计量恰好为零。如果采用其他的缩放方案，可能会不适用。例如，可以使用基础模型和增广模型各自的标准差来分别缩放两个模型下的回归截距。但这在本文的假设下不起作用，因为正交化备选因子（如减损后的市场因子）被构造成对回归截距的影响为零，因此对标准误差可能产生不可忽略的影响。结果，在原假设下，检验统计量将不等于零，因为相同截距被两个不同的标准误差缩放，这使得很难将备选因子的截面影响与其时序影响分开。检验统计量应该能帮助研究人员分离出备选因子的截面贡献。

本文所采用的检验方法和 GRS 检验有什么区别？GRS 检验假设增广模型为真，并评估 $|a_i^+|$ 的截面数据来检验这一假设。检验失败则表明，增广模型作为一个整体被拒绝，但几乎没有展示某个因子的显著性。相比之下，本文的检验假设基础模型是正确的，并使用比例截距的绝对值的减少来评估增广模型中新加因子的增量贡献。因此，本文的检验方法能够判断新加因子作为单独的风险因子本身是否显著，而无需对整体模型性能进行解释。但是，考虑到潜在真实因子模型的不确定性，任何给定的因子模型都可能是错误的。这一点很重要，因为很难在一个大的截面上为所有资产建立一个正确的模型。下一节会进一步探讨这一点。

另一个不同之处是，本文的检验方法没有像 GRS 检验那样使用整个残差协方差矩阵来加权回归截距的截面，而是使用单个标准差。这种差异可能是本文检验方法的一个缺点，而 GRS 似乎更强大，因为它使用了收益相关结构中的信息。也就是说，它允许使用残差协方差矩阵来构建投资组合。这些投资组合比仅基于被检验因子的投资组合具有更高的均值-方差效率，从而提高了检验的解释力。然而，在实际中，协方差矩阵估计的不稳定性可能抵消检验解释力上的增益。基于 GRS 检验得出的切点投资组合往往在某些资产上的权重是经济意义上不合理的，这说明 GRS 检验是有问题的。此外，当使用个股作为测试资产时，协方差矩阵将难以计算，因为横截面中的资产数量大于时间序列中的周期数量，这使得 GRS 检验方法不适用。考虑到这些问题，作者认为本文的检验方法在应用于大截面资产时可能比 GRS 检验更有优势。本文的检验方法考虑了每个资产的残差波动率，同时避免了对高维度残差协方差矩阵的估计过程。在本节末尾，作者详细比较了本文的检验方法和 GRS 检验方法。

尽管本文主要使用的检验统计量是 SI_{ew}^m 和 SI_{ew}^{med} ，但还有很多其他形式的检验统计量也很合适。比如，如果不用比例截距，那么可能会用原始截距数据。另一种可能是在计算截距差值的时候，使用市值加权，而不是等权。在后面的小节中，作者将探讨其他可能的检验统计量。

本文使用的研究框架允许使用多种多样的检验统计量，由此可见，作者使用的 bootstrap 方法是很灵活的。例如，通常没有基于分位数（例如，中位数）的检验统计量的闭式渐近近似。但本文基于 bootstrap 的方法允许作者对依赖于中位数的检验统计量进行推断，中位数对异常值具有鲁棒性，这对于应用于个股的研究尤其重要。

Fama 与 French (2015a) 没有使用等权的比例截距，而是使用等权的绝对截距（以及其他加权截距的方法）作为启发式检验统计量，以评估其投资和盈利能力因子的表现。本文使用的研究框架允许作者对他们的检验统计量的统计意义做出精确的陈述。作者在模拟研究中表明，本文所使用的检验统计量比基于原始截距数据的检验统计量更具有解释力。因此，作者将重点介绍前面提到的两个检验统计量（即 SI_{ew}^m 和 SI_{ew}^{med} ）以及按市值加权的对应统计量（即 SI_{vw}^m ），这将在本文后面介绍。

Barillas 和 Shanken (2017) 建议使用截距的二次型，这会考虑截距的相关性，以比较备选因子模型。然而，在本文对个股的研究中，对截距的高维协方差矩阵求逆变得不可行。此外，Affleck-Graves 和 McDonald (1990) 表明，仅使用误差协方差矩阵的对角元素构造的 GRS 统计量在模拟研究中表现更好。因此，作者将重点放在前文提到的两个检验统计量上，这两个统计量不会针对截距中的相关性做出调整。

也可以从投资的角度来解释本文引入的检验统计量。作者将这些解释留到了后面将回归结果与 GRS 方法下的结果进行对比的章节中。

3.3 主要结果：将个股作为测试资产

研究人员可以用个股来进行研究，而不是用根据特征分类的投资组合吗？传统的观点是否定的。事实上，Jensen 等人 (1972) 和 Fama 与 MacBeth (1973) 认为，个股的噪声太大了，不适合作为测试资产。GRS 检验也禁止使用个股，因为根据收益残差得到的大型协方差矩阵在求逆时是有问题的。因此，之后的研究人员也都遵循这些建议，使用流行的投资组合，特别是 Fama-French 的 25 个投资组合，来检验资产定价因子。

有一种相反的观点是，使用投资组合可能会在资产定价检验中带来偏差和低效。Avramov 和 Chordia (2006) 的研究表明，当使用个股而不是投资组合时，资产定价的含义有很大不同。Ang 等人 (2016) 认为，使用个股导致的 β 系数更大的离散度可能会增强检验的解释力度。Lewellen 等人 (2010) 也建议使用大量资产而不是少量投资组合来判断模型绩效。

作者认为，考虑个股的一个最重要的原因是，它们提供了一个更清晰的风险因子检验框架。基于特征分类的投资组合的检验可能倾向于识别用同一组测试组合构建的风险因子。如 Lo 和 MacKinlay (1990) 的研究表明，使用个股可以防止基于投资组合的资产定价测试引起的数据窥探偏差。此外，如果重新表述 Jensen 等人 (1972) 和 Fama 与 MacBeth (1973) 中的论点，即股票中的高噪声水平使得大多数检验方法效率低下，那么问题不一定在股票本身，而是在于缺乏针对个股噪声的稳健性较强的统计检验。而本文恰好提供了这样一个检验方法。特别是，本文的研究框架允许对考虑股票波动性和市值的检验统计量进行推断。因此，它减轻了个股的噪声问题（通过降低噪声大的小盘股的权重）。

除了偏差问题之外，本文的研究框架还提供了一种系统的方法来克服使用个股时的许多挑战，包括不平衡面板、截面上的极端观测值、截面相关性（可能是非参数的）以及相对于时间序列的大截面。

3.3.1 模拟研究

作者首先进行模拟研究，看看本文所用的检验方法是否有统计能力来确定一个“真实”的风险因素，即属于潜在因素模型的风险因素。考虑到个股收益的高噪音水平可能会使本文所用的检验方法无能为力，这个模拟测试过程很重要。作者没有进行那种调查方方面面的全面的模拟研究，而是着眼于选择一个比市场因子更有助于解释截面预期收益的备选风险因子。这是因为市场因素是唯一的主导因素，在实证分析中总是首先选择。因而更有趣的是检查进入因子列表的下一个备选因子。

也就是说，作者将市场因子作为唯一的预选因子，选取一些比较有可能存在于真实模型中的风险因子作为备选的新加因子，将新加因子投影到市场因子上，

$$f_t^A = A \times \alpha_f + \beta_m mkt_t + \varepsilon_{f,t}$$

当 $A = 0$ 时，对应原假设，即新加因子对截面预期收益没有增量贡献。当 A 取其他值的时候，则对应备择假设。 A 的取值越大，代表新加因子的风险溢价越高，即新加因子对截面预期收益的增量贡献越显著。

本文的模拟研究有两个不同于标准模拟框架的特点。首先，作者取给定数据中因子载荷的横截面分布。其次，作者利用 **bootstrap** 方法对已实现的收益残差进行重采样，构建模拟的收益面板。与标准模拟研究中假设因子载荷和/或收益残差的参数分布相比，作者所使用的方法使模拟数据更接近实际数据，因此提供了更真实的统计检验能力评估。

为了便于比较现有的结果与方法，作者采用常规的方案，即根据估计的 **beta** 来对个股进行排序。具体来说，作者基于五年滚动窗口的数据来估计因子载荷，并构建一个多空组合，假设在样本外持有一年。作者使用投资组合收益的 **t** 统计量来检验备选因子的显著性。出于比较的目的，作者还考虑了一个简单的无条件 **beta** 排序方案，首先基于它们在整个样本上估计的无条件单变量因子负荷来排序，然后形成多空组合，多头仓位为第一个十分位组，空头仓位为最后一个十分位组。

从模拟研究中可以得出一些结论，如图 2 和图 3 所示。首先，与有条件或无条件 **beta** 排序相比，本文所采用的基于 **bootstrap** 的检验更强大。具体来说，当因子风险溢价与在实际数据中看到的相似时，基于 **t**-统计量的检验的平均值（跨不同因子）比基于条件 β 排序的检验高出约 10%。此外，当时间段的数量与实际数据大致相同时，本文所采用的检验方法在不同的风险因子中的解释力都远远超过 70%。因此，本文的测试方法也具有绝对意义上的可信度。

图2：基于个股的模拟研究结果（T=240）

Factor	Method	A = 0 (null)	A = 0.5	A = 1.0	A = 1.5	A = 2.0
roe	SI_{ew}^m	0.022	0.167	0.517	0.729	0.865
	SI_{ew}^{med}	0.037	0.190	0.441	0.677	0.832
	Cond. β	0.016	0.113	0.377	0.663	0.836
	Uncond. β	0.008	0.055	0.309	0.709	0.885
ia	SI_{ew}^m	0.061	0.214	0.633	0.839	0.969
	SI_{ew}^{med}	0.067	0.213	0.597	0.854	0.947
	Cond. β	0.025	0.191	0.390	0.672	0.869
	Uncond. β	0.014	0.137	0.541	0.833	0.961
qmj	SI_{ew}^m	0.028	0.320	0.671	0.867	0.949
	SI_{ew}^{med}	0.039	0.278	0.608	0.812	0.896
	Cond. β	0.010	0.212	0.576	0.801	0.931
	Uncond. β	0.012	0.133	0.552	0.885	0.971
bab	SI_{ew}^m	0.047	0.248	0.600	0.809	0.947
	SI_{ew}^{med}	0.059	0.229	0.587	0.794	0.939
	Cond. β	0.031	0.134	0.375	0.642	0.828
	Uncond. β	0.023	0.197	0.463	0.773	0.939
cma	SI_{ew}^m	0.053	0.188	0.534	0.723	0.809
	SI_{ew}^{med}	0.043	0.208	0.469	0.714	0.817
	Cond. β	0.036	0.113	0.321	0.648	0.832
	Uncond. β	0.047	0.052	0.337	0.743	0.902

资料来源：《Lucky factors》，2021 年 4 月 21 日

图3：基于个股的模拟研究结果（T=480）

Factor	Method	A = 0 (null)	A = 0.5	A = 1.0	A = 1.5	A = 2.0
roe	SI_{ew}^m	0.024	0.277	0.801	0.937	0.985
	SI_{ew}^{med}	0.021	0.258	0.721	0.925	0.993
	Cond. β	0.013	0.179	0.536	0.843	0.973
	Uncond. β	0.020	0.093	0.525	0.895	0.992
ia	SI_{ew}^m	0.025	0.378	0.861	0.974	1.000
	SI_{ew}^{med}	0.016	0.351	0.834	0.973	1.000
	Cond. β	0.026	0.274	0.756	0.948	0.990
	Uncond. β	0.030	0.383	0.849	0.970	0.992
qmj	SI_{ew}^m	0.032	0.552	0.952	0.999	1.000
	SI_{ew}^{med}	0.027	0.486	0.946	1.000	1.000
	Cond. β	0.011	0.328	0.825	0.987	1.000
	Uncond. β	0.016	0.286	0.879	0.996	1.000
bab	SI_{ew}^m	0.028	0.289	0.737	0.941	0.998
	SI_{ew}^{med}	0.021	0.247	0.683	0.953	0.993
	Cond. β	0.015	0.155	0.591	0.894	0.991
	Uncond. β	0.008	0.127	0.603	0.935	0.997
cma	SI_{ew}^m	0.041	0.373	0.817	0.971	1.000
	SI_{ew}^{med}	0.037	0.312	0.788	0.978	1.000
	Cond. β	0.056	0.201	0.612	0.913	0.981
	Uncond. β	0.051	0.273	0.749	0.967	1.000

资料来源：《Lucky Factors》，2021 年 4 月 21 日

不同测试方法的测试规模也存在显著差异。特别是，用来进行比较的两种 **beta** 类型的实际大小略低于名义大小。这与当偏离原假设时，它们的较低解释力是一致的。这两个 **beta** 排序规模过小的事实可以用相对较短时间序列样本的横截面方法的变量误差（EIV）偏差（即 Shanken, 1992）来解释。而面板回归方法不受截面回归中 EIV 偏差的影响。Jegadeesh 等人（2019）提出了针对个股横截面方法的 EIV 修正。虽然作者没有复制他们的模拟结果，但他们的表 3 显示，Fama-French 三因子模型的平均测试能力约为 76%，有 684 个月度观测值。相比之下，图 3 显示，本文测试方法在只有 480 个月的观察值的情况下，平均测试能力（A=1.0，即风险溢价设定为样本内估计值）在五个因子中为 83%。因此，与最近提出的横截面方法相比，作者提出的这种方法表现更好。尽管如此，为了控制测试中测试规模的差异，作者遵循 Harvey 和 Liu (2020a) 的想法，并基于图 3 进行调整，使不同测试方法在原假设下的 t 统计量取值相同。根据图 4 的结果，在测试能力方面，本文的方法仍然优于两种 **beta** 方法。

图4：调整后的基于个股的模拟研究结果

Factor	Method	A = 0 (null)	A = 0.5	A = 1.0	A = 1.5	A = 2.0
roe	SI_{vw}^m	0.050	0.309	0.904	1.000	1.000
	SI_{vw}^{med}	0.050	0.297	0.830	1.000	1.000
	Cond. β	0.050	0.214	0.642	0.998	1.000
	Uncond. β	0.050	0.106	0.598	1.000	1.000
ia	SI_{vw}^m	0.050	0.419	0.984	1.000	1.000
	SI_{vw}^{med}	0.050	0.425	0.969	1.000	1.000
	Cond. β	0.050	0.300	0.851	1.000	1.000
	Uncond. β	0.050	0.419	0.937	0.999	1.000
qmj	SI_{vw}^m	0.050	0.601	0.998	1.000	1.000
	SI_{vw}^{med}	0.050	0.542	1.000	1.000	1.000
	Cond. β	0.050	0.388	0.993	1.000	1.000
	Uncond. β	0.050	0.334	1.000	1.000	1.000
bab	SI_{vw}^m	0.050	0.329	0.812	0.978	1.000
	SI_{vw}^{med}	0.050	0.279	0.793	1.000	1.000
	Cond. β	0.050	0.185	0.680	0.983	1.000
	Uncond. β	0.050	0.154	0.740	0.991	1.000
cma	SI_{vw}^m	0.050	0.387	0.847	0.987	1.000
	SI_{vw}^{med}	0.050	0.328	0.833	0.990	1.000
	Cond. β	0.050	0.194	0.590	0.886	0.953
	Uncond. β	0.050	0.272	0.745	0.962	0.995

资料来源：《Lucky Factors》，2021年4月21日

第二，使用个股数据未必会失去检验的可信力。具体来说，作者使用 Fama-French 的 25 个投资组合重新进行了测试，发现基于投资组合的测试的平均表现与基于个股的测试的平均表现相似。作者进行模拟研究的关键假设是双因子模型是真正的潜在因素模型。事实上，Fama-French 的 25 个投资组合遵循严格的因子结构，因此可能倾向于与 Fama-French 因子相关的因子（见 Lewellen 等人, 2010）。相比之下，个股提供了一系列不同的资产。

3.3.2 市值加权统计量

除了前面提到的基于等权加权的回归截距的检验统计量以外，还考虑它们的市值加权版本。市值加权具有经济意义。对于产生相同回归截距的两个股票，因子模型的错误定价对于市值较高的股票在经济上更为重要。

因此，作者定义的市值加权检验统计量使用市场价值来加权截面上的比例截距。具体来说，设 $\{me_{i,t}\}_{t=1}^T$ 为股

票 i 的市值时间序列，设 $ME_t = \sum_{i=1}^N me_{i,t}$ 为 t 时刻的总市值。检验统计量由下式给出，

$$SI_{vw}^m \equiv \frac{\sum_{t=1}^T \sum_{i=1}^N \frac{me_{i,t}}{ME_t} \times (|a_i^+| - |a_i|) / s_i}{\sum_{t=1}^T \sum_{i=1}^N \frac{me_{i,t}}{ME_t} \times |a_i| / s_i}$$

其中 vw 代表市值加权 (value weighting)。 SI_{vw}^m 计算的是增广模型和基础模型之间市值加权错误定价水平按时间平均的百分比差异。作者引入的市值加权检验统计量考虑了市值的时间变化。值得注意的是，虽然市值加权检验统计量能更准确地反映出普通投资者所经历的财富效应（见 Fama, 1998），但它们大大减少了小市值股票的影响。

3.3.3 基于个股的测试结果

在本节中，作者把前文的方法应用于个股。在后面的章节中，作者将该方法应用于常用的测试投资组合，并提供基于个股和投资组合的结果之间的详细比较。同时作者强调了基于特征分类的投资组合的测试会产生的潜在偏差。

在本文的实证分析中，在增量选择过程的每一步，作者都报告了每个因子的单一检验 p 值和最小检验统计量的多重检验 p 值。要清楚的是，每一个决定都是基于多个测试 p 值，然而，作者依然报告了单个测试的 p 值以突出多重测试的作用。

图5(等权)和图6(市值加权)给出了基于个股的测试结果。对于等权检验统计量，作者将重点放在 SI_{ew}^{med} 上来解释得到的结果，因为它比 SI_{ew}^m 更具稳定性。

图5：基于个股的等权统计量测试结果

Panel A: Baseline = No factor						Panel B: Baseline = mkt						
Factor	single test			single test			single test			single test		
	SI_{ew}^m	5th-percentile	p-value	SI_{ew}^{med}	5th-percentile	p-value	SI_{ew}^m	5th-percentile	p-value	SI_{ew}^{med}	5th-percentile	p-value
mkt	-0.192	[-0.093]	(0.003)	-0.206	[-0.095]	(0.001)						
smb	-0.081	[-0.081]	(0.056)	-0.109	[-0.117]	(0.061)	-0.041	[-0.045]	(0.063)	-0.062	[-0.052]	(0.032)
hml	0.088	[-0.022]	(0.983)	0.108	[-0.029]	(1.000)	-0.021	[-0.030]	(0.131)	-0.047	[-0.028]	(0.014)
mom	0.091	[-0.034]	(1.000)	0.110	[-0.044]	(1.000)	0.070	[-0.007]	(1.000)	0.089	[-0.012]	(1.000)
skew	-0.008	[-0.031]	(0.278)	-0.002	[-0.034]	(0.478)	-0.004	[-0.009]	(0.167)	-0.003	[-0.013]	(0.319)
psl	0.011	[-0.019]	(0.920)	0.002	[-0.030]	(0.682)	0.001	[-0.004]	(0.409)	-0.003	[-0.012]	(0.237)
roe	0.163	[-0.042]	(0.951)	0.187	[-0.064]	(1.000)	0.142	[-0.019]	(1.000)	0.180	[-0.029]	(1.000)
ia	0.264	[-0.040]	(1.000)	0.291	[-0.048]	(1.000)	0.027	[-0.009]	(0.968)	0.015	[-0.015]	(0.934)
qmj	0.316	[-0.072]	(0.995)	0.358	[-0.090]	(0.998)	0.149	[-0.024]	(0.972)	0.193	[-0.029]	(0.973)
bab	-0.006	[-0.039]	(0.594)	-0.049	[-0.050]	(0.107)	0.018	[-0.010]	(0.983)	-0.014	[-0.017]	(0.181)
gp	0.017	[-0.008]	(0.529)	0.030	[-0.007]	(0.727)	0.023	[-0.005]	(0.961)	0.017	[-0.007]	(0.790)
cma	0.176	[-0.034]	(1.000)	0.199	[-0.035]	(1.000)	-0.012	[-0.013]	(0.057)	-0.031	[-0.019]	(0.027)
rmw	0.116	[-0.011]	(0.986)	0.137	[-0.017]	(0.994)	0.040	[-0.014]	(1.000)	0.048	[-0.020]	(0.975)
civ	-0.096	[-0.044]	(0.023)	-0.130	[-0.062]	(0.031)	-0.018	[-0.018]	(0.052)	-0.049	[-0.030]	(0.021)
multiple test			multiple test			multiple test			multiple test			
min	[-0.109]		(0.004)	[-0.147]		(0.002)	[-0.045]		(0.071)	[-0.057]		(0.039)

Panel C: Baseline = mkt+smb						Panel D: Baseline = mkt + smb+hml						
Factor	single test			single test			single test			single test		
	SI_{ew}^m	5th-percentile	p-value	SI_{ew}^{med}	5th-percentile	p-value	SI_{ew}^m	5th-percentile	p-value	SI_{ew}^{med}	5th-percentile	p-value
mkt												
smb												
hml	-0.017	[-0.020]	(0.061)	-0.040	[-0.025]	(0.011)						
mom	0.055	[-0.004]	(1.000)	0.076	[-0.010]	(1.000)	0.026	[-0.005]	(1.000)	0.046	[-0.013]	(1.000)
skew	-0.013	[-0.010]	(0.029)	-0.015	[-0.013]	(0.036)	0.006	[-0.002]	(0.463)	-0.001	[-0.005]	(0.313)
psl	0.011	[-0.002]	(0.945)	0.016	[-0.005]	(0.970)	0.010	[-0.002]	(0.937)	0.007	[-0.005]	(0.771)
roe	0.058	[-0.006]	(0.987)	0.074	[-0.010]	(0.967)	0.072	[-0.004]	(1.000)	0.080	[-0.011]	(1.000)
ia	0.020	[-0.012]	(0.967)	0.008	[-0.013]	(0.719)	0.038	[-0.004]	(0.975)	0.051	[-0.008]	(1.000)
qmj	0.052	[-0.007]	(0.976)	0.061	[-0.008]	(0.998)	0.128	[-0.004]	(0.982)	0.137	[-0.006]	(0.971)
bab	0.016	[-0.010]	(0.896)	-0.014	[-0.013]	(0.043)	0.045	[-0.003]	(0.989)	0.040	[-0.007]	(0.954)
gp	0.022	[-0.003]	(0.972)	0.020	[-0.009]	(0.951)	0.059	[-0.001]	(0.992)	0.055	[-0.006]	(0.984)
cma	0.001	[-0.009]	(0.341)	-0.009	[-0.012]	(0.137)	0.022	[-0.002]	(0.980)	0.023	[-0.005]	(0.967)
rmw	-0.009	[-0.019]	(0.147)	-0.016	[-0.020]	(0.086)	0.036	[-0.002]	(1.000)	0.043	[-0.006]	(0.992)
civ	0.014	[-0.009]	(0.981)	0.003	[-0.019]	(0.615)	0.015	[-0.008]	(0.991)	0.016	[-0.015]	(0.981)
multiple test			multiple test			multiple test			multiple test			
min	[-0.022]		(0.122)	[-0.027]		(0.018)	[-0.011]		(0.997)	[-0.017]		(0.932)

资料来源：《Lucky Factors》，2021 年 4 月 21 日

值得注意的是，从单个测试和多重测试的角度来看，市场因子都是重要的。从单一测试的角度，为了评估市场因子的显著性，作者采用前文的方法，将 14 个因子正交化，使它们对样本中的截面预期收益没有影响。之后作者用 bootstrap 方法得到了单个检验统计量的实证分布。然后，根据这些实证分布评估已实现的检验统计量，从而得到 p 值。如图 5 的面板 A 所示，市场因子的 SI_{ew}^{med} 的 bootstrap 分布的第 5 百分位数为 -0.095 其解释是，在原假设下，即市场因子没有能力解释截面预期收益，应用 bootstrap 方法后，产生了一个分布的增量到截距。在第 5 个百分位上，市场因子每降低 1%，比例截距的中位数会减少 9.5%。实际因子将平均比例截距减少了 5 个百分点以上，因此作者认为它是显著的。更准确地说，根据市场因子的 SI_{ew}^{med} 实证分布，市场因子的单一测试的结果 -20.6% 所对应的 p 值为 0.001。

从多重检验的角度出发,采用 bootstrap 方法得到最小统计量的实证分布。特别是,按照第 2 节中的 bootstrap 过程,作者对时间段进行重新采样。对于每个 bootstrap 样本,作者首先获得 14 个正交化因子的检验统计量,然后记录所有 14 个统计量中的最小检验统计量。最小统计量是 14 个因素中截距减少最多的。由于所有因素都是正交的,因此对预期收益的横截面没有影响,所以最小统计量说明了最大截距减少有多大可能只是偶然发生的,因此可以控制多重测试。正如 Fama 和 French (2010) 所强调的那样,所有 14 个测试统计数据都基于相同的 bootstrap 样本,这一点很重要,因为可以控制检验相关性。最后,作者将选出的最小统计量与其相应的 bootstrapped 分布进行比较,得到 p 值。

图 5 的面板 A 显示了多重测试的结果。具体来说,最小统计量 SI_{ew}^{med} 的 bootstrap 分布第 5 百分位为 -14.7%。根据多次检验的最小统计量的经验分布,评估 -20.6% 相应的 p 值为 0.002。由于多重测试的 p 值仍然低于 5%,因此从多重测试的角度,市场因子也是显著的。

市场因子在本文的研究框架中是很重要的,这不是一个微不足道的实证结论。尽管市场因子具有很强的理论驱动性,是第一个被测试的系统风险因子 (Jensen 等人, 1972), 但不同的论文通过使用不同的测试方法和测试资产,往往得出相互矛盾的结论。因此,市场因子在实证上是否是一个有效的风险因子还没有达成共识。尽管如此,也许由于其直观的应用和理论相关性,大多数人通常将其用于风险调整 and 资本成本计算。就目前而言, Fama 和 French (2015a) 将市场因素纳入了他们的五因素模型,而没有测试其表现。最近,通过使用个股作为测试资产,并使用 Fama-MacBeth 横截面测试, Jegadeesh 等人 (2019) 拒绝将市场因素作为风险因子。Chordia 等人 (2015 年) 的研究结论只发现市场因子有微弱的作用。相比而言,本文的结果表明,市场因子是迄今为止解释截面预期收益变化时最主要的风险因子。这一结果与 Pukthuanthong 等人 (2019)、Kelly 等人 (2019) 以及 Giglio 与 Xiu (2019) 的研究结论一致。这可能是由于作者使用了面板回归模型。

Fama (2015) 总结了 Fama-MacBeth 截面回归法和面板回归法之间的差异。面板回归法基本上假设因子风险溢价由其样本内估计给出,并试图评估因子风险敞口 (即贝塔系数乘以风险溢价) 所解释的预期超额收益的百分比。GRS 检验是面板回归检验的一个例子。它集中在极端情况下,由因子模型解释的预期超额收益率的百分比必须是 100%,也就是说,因子模型是正确指定的,它是潜在的真实因子模型。本文的检验方法比 GRS 检验要求低,因为这个百分比不必是 100%。一个因素可以被宣布为有用的,只要它在解释一个给定的资产截面预期回报时,在统计学意义上有贡献。事实上,图 5 和图 6 表明,在市值加权和等权的情况下,单独的市场因子降低平均定价误差的程度分别为 44% 和 21%。从经济角度来看,这些数字是巨大的,远远大于其他备选因子对定价误差的减少幅度。

为什么横截面法和时间序列 (面板) 法之间会有这样的对比? 作者认为模型的错误特质化是重要原因。具体而言,时间序列 (面板) 回归允许特定资产的截距吸收一些可以推动预期资产回报但未被回归项 (如市场因素) 描述的特质。因此,这样做更有可能获取回归因子的增量贡献 (截距的减少量), 从而确定回归因子是重要的。相反,根据构造,横截面回归只允许一个截距 (在所有资产中), 因此更容易受到模型错误规范的影响 (即,忽略了驱动横截面收益变化但不包括在回归项中的因子)。使用按特征分类后的投资组合可能会进一步加剧这种情况,因为这种投资组合本身就具有与市场因子无关的强大因子结构。

为了更直观的进行比较,作者提供了一个简单的例子。假设资产 A 和资产 B 都有 10% 的超额收益率。A (B) 的市场 beta 系数为 1 (2)。假设市场风险溢价为 5%。因此, A 的超额收益可以分为两部分,均为 5%, 其中一个由市场风险溢价乘以 beta 系数可得,另一部分是由于忽略了某些风险因子,也可能是因为定价错误。B 的超额收益可以完全由 CAPM 来解释。在这些假设下,横截面回归将产生零斜率系数; 因此, CAPM 被拒

绝。相比之下，面板回归方法将通过 A 和 B 截距的大幅减少正确识别市场因子，同时 A 的未知 α 为 5%，B 的 α 为零。

在图 5 的面板 B 中，在确定了市场因子之后，smb 是剩余因子中最好的因子。根据 SI_{ew}^{med} 的值，比例截距绝对值减少的百分比为 6.2%。对应的多重测试 p 值为 0.039。因此，smb 也具有重要意义。这一结果或许并不令人惊讶，因为等权会给那些在 smb 因子中权重较高的小型企业带来更大的权重。尽管如此，与市场因子相比，smb 因子带来的截距减少比例是第二位的。

在图 5 的面板 C 中，当市场因子和 smb 因子都包含在基础模型中后，hml 是剩余因子中的最佳因子，根据 SI_{ew}^{med} ，因子减少 1% 会使比例截距绝对值减少 4.0%。根据 SI_{ew}^{med} 的分布，hml 因子也有显著的多重测试 p 值（即 1.8%）。因此，作者认为它是重要的风险因子，并将其包含在基础模型中。在基础模型中包括 mkt、smb 和 hml 之后，剩下的因素都不显著，如图 5 的面板 D 所示。因此，测试程序终止。使用等权检验统计量确定真因子模型为 mkt+smb+hml。

这一结果与 Fama 和 French (1993) 一致，但与 Fama 和 French (2015a) 的研究结果不同。Fama 和 French (2015a) 的研究发现，在将 cma 和 rmw 因子对现有因子进行回归的跨越测试中，cma 和 rmw 的 α 值非常显著。对此，作者认为，在跨越测试中幸存下来的重要因素不一定能成功解释个股的收益。例如，将 Berkshire Hathaway 公司的收益率被视为一个因素时，产生了 10.6% 的年化 alpha（与 Fama and French (2015a) 五因素模型相比），t 统计量为 12.3。然而，Berkshire Hathaway 公司的超额收益率并不能解释截面股票收益，因此在本文的测试中毫无用处。

考虑到定价误差降低的幅度，市场因子将基础模型的比例截距中位数降低了 20.6%。以市场因子为条件时，smb 因子可以减少 6.2%，意味着 smb 因子可以减少 4.9% 的定价误差 $(=(1-20.6\%) \times 6.2\%)$ 。以市场因素和 smb 因子为条件时，hml 能减少 4.0%，也就是说 hml 因子可以减少 3.0% $(=(1-20.6\%) \times (1-6.2\%) \times 4.0\%)$ 的基础模型的比例截距。因此，与市场因素相比，smb 和 hml 的经济意义不大。总体降幅（就基础模型的截面截距而言）为 28.5%，表明最终模型在解释等权重下的股票收益率方面的成功率有限。

与本文结果相反，Chordia 等人 (2015) 和 Jegadeesh 等人 (2019) 在研究中也使用了个股，并发现潜在风险因子的几个常用因子（如 smb 和 hml）似乎没有定价。这两篇论文都依赖于 Fama-MacBeth 回归（修正了变量偏差中的错误），并在第二阶段回归中使用 OLS。这种方法能有效地在截面上对股票按等权加权，因此与图 5 中的加权方法一致。因此，本文结果也表明，选出来的因子列表取决于使用的资产定价测试的方法。鉴于本文所用的方法与其他可选的方法（如前所述）相比对完全指定模型的依赖性较小，作者认为该方法更适合用来基于较大的横截面资产进行测试，选择恰当的风险因子。

图6：基于个股的市值加权统计量测试结果

Panel A: Baseline = No factor				Panel B: Baseline = <i>mkt</i>			Panel C: Baseline = <i>mkt</i> + <i>qmj</i>		
Factor	<i>SI_{pw}</i>	single test		<i>SI_{pw}</i>	single test		<i>SI_{pw}</i>	single test	
		5th-percentile	<i>p</i> -value		5th-percentile	<i>p</i> -value		5th-percentile	<i>p</i> -value
<i>mkt</i>	−0.444	[−0.258]	(0.000)						
<i>smb</i>	−0.059	[−0.054]	(0.041)	0.018	[−0.042]	(0.831)	0.076	[−0.032]	(0.994)
<i>hml</i>	0.144	[−0.059]	(0.972)	−0.038	[−0.045]	(0.128)	−0.016	[−0.062]	(0.471)
<i>mom</i>	0.153	[−0.064]	(1.000)	0.130	[−0.012]	(1.000)	0.125	[−0.026]	(1.000)
<i>skew</i>	−0.027	[−0.052]	(0.158)	−0.044	[−0.033]	(0.029)	−0.020	[−0.025]	(0.088)
<i>psl</i>	0.035	[−0.023]	(0.970)	0.016	[−0.011]	(0.996)	0.034	[−0.028]	(0.991)
<i>roe</i>	0.105	[−0.043]	(0.993)	−0.079	[−0.043]	(0.021)	0.038	[−0.025]	(0.967)
<i>ia</i>	0.382	[−0.086]	(0.984)	−0.042	[−0.048]	[0.083]	0.078	[−0.047]	(0.935)
<i>qmj</i>	0.363	[−0.112]	(0.892)	−0.149	[−0.079]	(0.002)			
<i>bab</i>	−0.048	[−0.035]	(0.026)	−0.088	[−0.049]	(0.006)	−0.026	[−0.037]	(0.157)
<i>gp</i>	−0.082	[−0.038]	(0.009)	−0.037	[−0.043]	(0.073)	−0.022	[−0.046]	(0.242)
<i>cma</i>	0.314	[−0.107]	(0.982)	−0.052	[−0.034]	(0.028)	0.019	[−0.038]	(0.941)
<i>rmw</i>	0.045	[−0.014]	(0.942)	−0.146	[−0.066]	(0.019)	0.053	[−0.033]	(1.000)
civ	−0.115	[−0.062]	(0.002)	0.035	[−0.019]	(0.973)	−0.017	[−0.024]	(0.113)
Multiple test				Multiple test			Multiple test		
	<i>min</i>	[−0.258]	(0.000)		[−0.083]	(0.004)		[−0.069]	(0.637)

资料来源：《Lucky Factors》，2021 年 4 月 21 日

图 6 显示了按市值加权的定价误差的测试结果。在市值加权下，市场因子再次成为表现最好的因子。此外，其检验统计量在市值加权下的值远大于等权下的值。根据图 6 的结果，当市场因子被纳入基础模型时，比例截距绝对值的均值降幅达 44.4%，远大于图 5 中在等权重下的值。在价值加权下，市场因素的多重测试 p 值小于 0.001，表明市场因素是一个非常显著的风险因子。在确定市场因子后，下一个最佳因子是 qmj，其多重测试 p 值为 0.004。注意到之前在等权模型中确定的 hml 因子在市值加权的模型也可以使截距降低 3.8%。但这一降幅远小于 qmj 因子 14.9% 的降幅。所以，作者选择了 qmj 因子。在确定市场因子和 qmj 因子并将其纳入基础模型后，其余因子均不显著。最优的 bab 因子的多重测试 p 值为 0.637。因此，在市值加权下，最终找到了一个包含 mkt 和 qmj 的双因素模型。

当依次建立因子模型时，最佳候选因子的统计显著性显著下降。同时值得注意的是，其经济重要性也随之下降。例如，市场因子将价值加权的比例截距绝对值降低了 44.4%。将市场因子纳入基础模型后，第二个选出来的 qmj 因子的增量贡献为当前基础模型截距的 14.9%（相当于原始模型的 8.3%）。在基线模型中包括这两个因素后，次优候选因子（bab）的增量贡献仅为当前基础模型的 2.6%（即原始模型的 1.2%） $(=(1-44.4\%) \times (1-14.9\%) \times 2)$ 。经济意义上的重要性下降使得最终得到的模型比较令人信服。在市值加权下，原始基础模型的截距减少了 52.7%，比使用等权方式的减少量（28.5%）增加了大致一倍。

作者指出，尽管前文的测试结果中将 qmj 因子作为了一个有用的风险因子，但 qmj 因子其实是一组因素的代表，即盈利能力组。该组包括 qmj、rmw 和 roe。组内的三个因素高度相关，在回归测试中表现相似。

在价值加权下确定盈利能力因子对解释截面预期收益有用，这在经济上是有意义的。提出盈利能力因子的论文通常使用企业投资理论来解释他们的发现（例如，Fama 与 French, 2015a 以及 Hou 等人, 2015）。直观上看，大公司的阻力较少，因此可以更好地参与价值最大化，这是投资理论发挥作用的假设。而本文的测试框架使得作者得以按市值加权的方法研究截面上的截距，这证明了该方法的灵活性。

本文使用价值加权方法得到的结果，对于当前在资产定价测试中使用投资组合作为测试资产的研究具有重要的意义。投资组合的平均收益在横截面上是分散的，这有助于资产定价测试，因为分散可能增加测试的可信

度。然而，对于投资组合来说，横截面很小。事实上，Fama-French 的 25 个投资组合收益率的分散很大程度上是由少数以小型股为主的投资组合导致的。在等权重下，流动资产定价测试可能会找出能够解释这些极端投资组合的因子。这也与利用数据挖掘找到一个适合（偶然）这些极端投资组合的因子相对容易一致。然而，这在经济上意义有限，因为对于那些投资组合权重偏向于大盘股的普通投资者来说，覆盖小盘股的投资组合不如覆盖大盘股的投资组合重要。

本文的研究结果指向市场因子、传统因子（即 smb 和 hml ）和盈利能力因子。面板回归框架还有两个方面值得注意。首先，前文的模型中均假设的是常数因子载荷，而 Fama-MacBeth 方法则具有择时载荷。一方面，因子载荷面板框架中，在估计不确定性上的减少可能会超过固定因子载荷引起的偏差增加。另一方面，常数因子载荷似乎更适合于控制买卖股票特征的投资组合构建方法。在在线附录 IG.1 节中，作者展示了如何扩展本文的研究框架，以允许加入择时的因子载荷。

其次，Fama-MacBeth 方法中的横截面回归对于个股来说可能是有问题的，因为横截面上的经常出现极端观测值。去极值可能是一种不明智的做法，因为有时偏大的观测值可能为参数估计提供了重要信息。相比之下，作者提出的面板回归框架侧重于回归截距的减少量或截距的 t 统计量，两者都依赖于整个回归时间序列，受单个观测值的影响较小。

3.3.4 在更大的因子备选集中进行测试

在本节中，作者用 Ehsani 与 Linnainmaa（2021）使用的 42 个额外因子扩充了备选因子列表，因子总数达到了 56 个。本节的目的是评估前文的研究结果是否对预先指定的备选因子集敏感。

在正文的表格中展示所有 56 个因子的统计量是很有挑战性的。因此，在之前研究的 14 个因素的基础上，将只会列出了在新模型中产生负检验统计量的额外因素（ SI_{ew}^m 或 SI_{ew}^{med} ），在市场因子包含在基础模型中之后。因为这些统计量为负值的因子有更高的可能性被选入最终模型。而且在之前的研究中，在市场因子被选入基础模型后，作者没有见过检验统计量为正值，但还能被选入最终模型的因子。

图 7 给出了等权检验统计量的结果，图 8 给出了市值加权检验统计量的结果。在最终因子模型的选择上，结果与之前相同：除了市场因子外，规模（ smb ）和账面市值比（ hml ）在等权重下显著； qmj 因子作为盈利能力组的代表，在价值加权下显著。与前面在图 5 和图 6 中的结果的主要区别在于多重检验调整后的检验统计量。由于候选因子的数量较多，最佳表现因子（即产生最小检验统计量的因子）需要在更严格的多重检验阈值下幸存以彰显其显著性。这一更严格的阈值反映为多重测试 p 值通常高于图 5 和图 6 中相应的值。然而，前文选出的因子的显著性下降通常很小，这突出了前面那 14 个原始因子的显著性；它们在股票收益定价中的重要性不能被另外 42 个因素所取代。

总的来说，本文得出的结果对于在测试中选取的备选因子而言是稳健的。鉴于其他文献中还研究过大量的因子，作者表示不能排除其他备选因子的存在，但能够在测试中确定一个小的子集。

图7：基于个股的等权统计量测试结果（56个因子）

Panel A: Baseline = No factor						Panel B: Baseline = mkt						
Factor	Single test			Single test			Single test			single test		
	S^m_{EW}	5th-percentile	p-value	S^{med}_{EW}	5th-percentile	p-value	S^m_{EW}	5th-percentile	p-value	S^{med}_{EW}	5th-percentile	p-value
mkt	-0.192	[-0.093]	(0.003)	-0.206	[-0.095]	(0.001)						
smb	-0.081	[-0.081]	(0.056)	-0.109	[-0.117]	(0.061)	-0.041	[-0.045]	(0.063)	-0.062	[-0.052]	(0.032)
hml	0.088	[-0.022]	(0.983)	0.108	[-0.029]	(1.000)	-0.021	[-0.030]	(0.131)	-0.047	[-0.028]	(0.014)
mom	0.091	[-0.034]	(1.000)	0.110	[-0.044]	(1.000)	0.070	[-0.007]	(1.000)	0.089	[-0.012]	(1.000)
skew	-0.008	[-0.031]	(0.278)	-0.002	[-0.034]	(0.478)	-0.004	[-0.009]	(0.167)	-0.003	[-0.013]	(0.319)
psl	0.011	[-0.019]	(0.920)	0.002	[-0.030]	(0.682)	0.001	[-0.004]	(0.409)	-0.003	[-0.012]	(0.237)
roe	0.163	[-0.042]	(0.951)	0.187	[-0.064]	(1.000)	0.142	[-0.019]	(1.000)	0.180	[-0.029]	(1.000)
ia	0.264	[-0.040]	(1.000)	0.291	[-0.048]	(1.000)	0.027	[-0.009]	(0.968)	0.015	[-0.015]	(0.934)
qmj	0.316	[-0.072]	(0.995)	0.358	[-0.090]	(0.998)	0.149	[-0.024]	(0.972)	0.193	[-0.029]	(0.973)
bab	-0.006	[-0.039]	(0.594)	-0.049	[-0.050]	(0.107)	0.018	[-0.010]	(0.983)	-0.014	[-0.017]	(0.181)
gp	0.017	[-0.008]	(0.529)	0.030	[-0.007]	(0.727)	0.023	[-0.005]	(0.961)	0.017	[-0.007]	(0.790)
cma	0.176	[-0.034]	(1.000)	0.199	[-0.035]	(1.000)	-0.012	[-0.013]	(0.057)	-0.031	[-0.019]	(0.027)
rmw	0.116	[-0.011]	(0.986)	0.137	[-0.017]	(0.994)	0.040	[-0.014]	(1.000)	0.048	[-0.020]	(0.975)
civ	-0.096	[-0.044]	(0.023)	-0.130	[-0.062]	(0.031)	-0.018	[-0.018]	(0.052)	-0.049	[-0.030]	(0.021)
cp	-0.023	[-0.009]	(0.023)	-0.024	[-0.011]	(0.021)	0.002	[-0.003]	(0.121)	-0.013	[-0.006]	(0.021)
di	0.009	[-0.007]	(0.821)	0.007	[-0.009]	(0.734)	0.003	[-0.001]	(0.306)	-0.001	[-0.003]	(0.119)
ep	-0.020	[-0.011]	(0.015)	-0.019	[-0.013]	(0.029)	0.000	[-0.000]	(0.084)	-0.004	[-0.003]	(0.038)
em	-0.023	[-0.008]	(0.018)	-0.028	[-0.013]	(0.009)	0.006	[-0.000]	(0.363)	-0.005	[-0.002]	(0.023)
lev	-0.002	[-0.009]	(0.200)	-0.001	[-0.010]	(0.407)	0.001	[-0.003]	(0.215)	-0.002	[-0.005]	(0.191)
sp	-0.008	[-0.011]	(0.081)	-0.011	[-0.014]	(0.068)	0.011	[-0.004]	(0.840)	-0.006	[-0.008]	(0.123)
ssi	-0.031	[-0.014]	(0.014)	-0.039	[-0.022]	(0.007)	0.002	[-0.004]	(0.422)	-0.011	[-0.012]	(0.052)
lsi	-0.020	[-0.019]	(0.053)	-0.026	[-0.025]	(0.043)	0.000	[-0.006]	(0.158)	-0.018	[-0.012]	(0.008)
maxr	-0.018	[-0.011]	(0.029)	-0.017	[-0.015]	(0.046)	-0.001	[-0.002]	(0.111)	0.001	[-0.006]	(0.391)
Multiple test			Multiple test			Multiple test			multiple test			
min			min			min			min			
[-0.123]			[-0.136]			[-0.045]			[-0.057]			
(0.000)			(0.000)			(0.071)			(0.039)			
Panel C: Baseline = mkt+smb						Panel D: Baseline = mkt + smb+hml						
Factor	single test			single test			single test			single test		
	S^m_{EW}	5th-percentile	p-value	S^{med}_{EW}	5th-percentile	p-value	S^m_{EW}	5th-percentile	p-value	S^{med}_{EW}	5th-percentile	p-value
mkt												
smb												
hml	-0.017	[-0.020]	(0.061)	-0.040	[-0.025]	(0.011)						
mom	0.055	[-0.004]	(1.000)	0.076	[-0.010]	(1.000)	0.026	[-0.005]	(1.000)	0.046	[-0.013]	(1.000)
skew	-0.013	[-0.010]	(0.029)	-0.015	[-0.013]	(0.036)	0.006	[-0.002]	(0.463)	-0.001	[-0.005]	(0.313)
psl	0.011	[-0.002]	(0.945)	0.016	[-0.005]	(0.970)	0.010	[-0.002]	(0.937)	0.007	[-0.005]	(0.771)
roe	0.058	[-0.006]	(0.987)	0.074	[-0.010]	(0.967)	0.072	[-0.004]	(1.000)	0.080	[-0.011]	(1.000)
ia	0.020	[-0.012]	(0.967)	0.008	[-0.013]	(0.719)	0.038	[-0.004]	(0.975)	0.051	[-0.008]	(1.000)
qmj	0.052	[-0.007]	(0.976)	0.061	[-0.008]	(0.998)	0.128	[-0.004]	(0.982)	0.137	[-0.006]	(0.971)
bab	0.016	[-0.010]	(0.896)	-0.014	[-0.013]	(0.043)	0.045	[-0.003]	(0.989)	0.040	[-0.007]	(0.954)
gp	0.022	[-0.003]	(0.972)	0.020	[-0.009]	(0.951)	0.059	[-0.001]	(0.992)	0.055	[-0.006]	(0.984)
cma	0.001	[-0.009]	(0.341)	-0.009	[-0.012]	(0.137)	0.022	[-0.002]	(0.980)	0.023	[-0.005]	(0.967)
rmw	-0.009	[-0.019]	(0.147)	-0.016	[-0.020]	(0.086)	0.036	[-0.002]	(1.000)	0.043	[-0.006]	(0.992)
civ	0.014	[-0.009]	(0.981)	0.003	[-0.019]	(0.615)	0.015	[-0.008]	(0.991)	0.016	[-0.015]	(0.981)
cp	0.014	[-0.002]	(0.772)	0.015	[-0.001]	(0.819)	0.015	[0.003]	(0.833)	0.017	[0.000]	(0.807)
di	0.003	[-0.000]	(0.227)	0.007	[-0.003]	(0.573)	0.003	[0.002]	(0.181)	0.007	[-0.002]	(0.523)
ep	0.005	[-0.001]	(0.360)	0.007	[-0.002]	(0.588)	0.008	[0.002]	(0.575)	0.013	[-0.001]	(0.800)
em	0.017	[-0.003]	(0.951)	0.015	[-0.001]	(0.904)	0.016	[0.003]	(0.940)	0.014	[-0.001]	(0.848)
lev	0.007	[-0.001]	(0.553)	0.010	[-0.003]	(0.843)	0.007	[0.002]	(0.582)	0.006	[-0.002]	(0.520)
sp	0.027	[-0.004]	(1.000)	0.025	[-0.001]	(1.000)	0.024	[0.002]	(1.000)	0.024	[-0.000]	(1.000)
ssi	0.012	[-0.000]	(0.902)	0.015	[-0.004]	(0.953)	0.018	[0.000]	(0.983)	0.024	[-0.002]	(0.997)
lsi	0.017	[-0.003]	(0.887)	0.016	[-0.000]	(0.877)	0.020	[0.002]	(0.945)	0.017	[0.002]	(0.842)
maxr	-0.000	[-0.002]	(0.113)	-0.000	[-0.007]	(0.314)	0.002	[0.000]	(0.187)	0.002	[-0.004]	(1.000)
multiple test			multiple test			multiple test			multiple test			
min			min			min			min			
[-0.021]			[-0.025]			[-0.011]			[-0.014]			
(0.181)			(0.011)			(0.981)			(0.966)			

资料来源：《Lucky factors》，2021年4月21日

图8：基于个股的市值加权统计量测试结果（56个因子）

Panel A: Baseline = No factor				Panel B: Baseline = <i>mkt</i>			Panel C: Baseline = <i>mkt</i> + <i>qmj</i>		
Factor	<i>SI_{rw}</i>	Single test		<i>SI_{rw}</i>	Single test		<i>SI_{rw}</i>	Single test	
		5th-percentile	<i>p</i> -value		5th-percentile	<i>p</i> -value		5th-percentile	<i>p</i> -value
<i>mkt</i>	−0.444	[−0.258]	(0.000)						
<i>smb</i>	−0.059	[−0.054]	(0.041)	0.018	[−0.042]	(0.831)	0.076	[−0.032]	(0.994)
<i>hml</i>	0.144	[−0.059]	(0.972)	−0.038	[−0.045]	(0.128)	−0.016	[−0.062]	(0.471)
<i>mom</i>	0.153	[−0.064]	(1.000)	0.130	[−0.012]	(1.000)	0.125	[−0.026]	(1.000)
<i>skew</i>	−0.027	[−0.052]	(0.158)	−0.044	[−0.033]	(0.029)	−0.020	[−0.025]	(0.088)
<i>psl</i>	0.035	[−0.023]	(0.970)	0.016	[−0.011]	(0.996)	0.034	[−0.028]	(0.991)
<i>roe</i>	0.105	[−0.043]	(0.993)	−0.079	[−0.043]	(0.021)	0.038	[−0.025]	(0.967)
<i>ia</i>	0.382	[−0.086]	(0.984)	−0.042	[−0.048]	[0.083]	0.078	[−0.047]	(0.935)
<i>qmj</i>	0.363	[−0.112]	(0.892)	−0.149	[−0.079]	(0.002)			
<i>bab</i>	−0.048	[−0.035]	(0.026)	−0.088	[−0.049]	(0.006)	−0.026	[−0.037]	(0.157)
<i>gp</i>	−0.082	[−0.038]	(0.009)	−0.037	[−0.043]	(0.073)	−0.022	[−0.046]	(0.242)
<i>cma</i>	0.314	[−0.107]	(0.982)	−0.052	[−0.034]	(0.028)	0.019	[−0.038]	(0.941)
<i>rmw</i>	0.045	[−0.014]	(0.942)	−0.146	[−0.066]	(0.019)	0.053	[−0.033]	(1.000)
<i>civ</i>	−0.115	[−0.062]	(0.002)	0.035	[−0.019]	(0.973)	−0.017	[−0.024]	(0.113)
<i>ag</i>	−0.050	[−0.022]	(0.000)	−0.008	[−0.003]	(0.013)	−0.007	[−0.003]	(0.891)
<i>noa</i>	−0.041	[−0.025]	(0.011)	−0.007	[−0.005]	(0.032)	0.011	[−0.007]	(0.968)
<i>os</i>	−0.001	[−0.019]	(0.432)	−0.002	[−0.010]	(0.429)	−0.001	[−0.010]	(0.470)
<i>pm</i>	−0.005	[−0.030]	(0.368)	−0.001	[−0.006]	(0.321)	−0.001	[−0.007]	(0.359)
<i>ic</i>	0.003	[−0.019]	(0.757)	−0.002	[−0.006]	(0.248)	0.002	[−0.006]	(0.650)
<i>sg</i>	−0.004	[−0.024]	(0.270)	−0.002	[−0.009]	(0.262)	−0.003	[−0.006]	(0.273)
<i>ssi</i>	−0.062	[−0.042]	(0.021)	−0.012	[−0.006]	(0.009)	0.008	[−0.005]	(0.962)
<i>lsi</i>	−0.047	[−0.033]	(0.033)	−0.007	[−0.005]	(0.031)	−0.004	[−0.006]	(0.121)
<i>sg</i>	−0.036	[−0.024]	(0.018)	−0.010	[−0.006]	(0.022)	0.004	[−0.002]	(0.698)
<i>tef</i>	−0.090	[−0.047]	(0.000)	−0.006	[−0.004]	(0.020)	0.003	[−0.003]	(0.792)
<i>mbeta</i>	−0.004	[−0.028]	(0.401)	−0.001	[−0.006]	(0.351)	−0.000	[−0.005]	(0.292)
<i>fage</i>	−0.021	[−0.033]	(0.068)	−0.005	[−0.004]	(0.028)	0.004	[−0.003]	(0.791)
<i>ivol</i>	−0.026	[−0.040]	(0.132)	−0.002	[−0.005]	(0.223)	−0.003	[−0.006]	(0.130)
<i>lr</i>	−0.019	[−0.022]	(0.091)	−0.005	[−0.004]	(0.041)	0.002	[−0.003]	(0.407)
<i>maxr</i>	−0.035	[−0.041]	(0.069)	−0.002	[−0.005]	(0.237)	−0.007	[−0.006]	(0.033)
Multiple test				Multiple test			Multiple test		
	<i>min</i>	[−0.213]	(0.000)		[−0.073]	(0.002)		[−0.070]	(0.689)

资料来源：《Lucky Factors》，2021年4月21日

3.3.5 经过分类整合的投资组合

为了与前文基于个股的主要结果形成对比，作者将本文的研究方法应用于各种分类投资组合，包括 Fama–French 的 25 个投资组合、beta 分类投资组合、Fama–French 的 49 行业投资组合，以及 Novy-Marx 和 Velikov (2016) 以及 Kozak 等人 (2018) 研究的 90 个低换手率的异常投资组合。在应用过程中，作者强调了投资组合中确定因子集的不稳定性。另外作者还详细讨论了与使用 GRS 检验相关的问题。这些都放在了在线附录 IF 小节中。

3.4 稳定性检验

作者在在线附录第 IB 节中给出了许多稳健性测试，包括在个股分析时去掉至少 10% 的股票、投资组合结果的价值加权指标、成块应用 bootstrap 方法以及低频交易相关的控制变量等等。

3.5 择时因子载荷和其他问题

作者在在线附录第 IG 节中，详细讨论了一些与本文所用的研究方法的问题，包括择时因子载荷、逐步选择的模型、虚假因子、因子模型的不确定性和模型的错误特质化等等。

作者进一步探讨了择时因子载荷的问题。在现在的模型中，作者基本上是假设每个股票产生收益的过程都是平稳的，并使用无条件回归来获得因子载荷。然而，当出现条件信息时，模型应该能够通过将回报的条件分布建模为依赖于条件信息来丰富回报的生成过程。作者将在后文分析这样一个模型。

具体来说，根据前面的结果，作者关注到在等权下的分析中确定的三个主要因素：市场因子、规模因子和账面市值比因子。为了捕捉股票择时特征，作者沿用 Harvey 和 Liu (2020b) 的方法，在回归模型中加入了股票的择时特征排名。此外，为了捕捉因子择时负荷，还应该允许特征排名影响对因子收益的敏感性。模型可以表示为：

$$R_{i,t} - R_{f,t} = a_0 + b_{size,1} \cdot size_{i,t-1} + b_{size,2} \cdot smb_t + b_{size,3} \cdot size_{i,t-1} \times smb_t + b_{btm,1} \cdot btm_{i,t-1} + b_{btm,2} \cdot hml_t + b_{btm,3} \cdot btm_{i,t-1} \times hml_t + b_{mkt,1} \cdot mkt_t + b_{mkt,size} \cdot size_{i,t-1} \times mkt_t + b_{mkt,btm} \cdot btm_{i,t-1} \times mkt_t + \varepsilon_{i,t}$$

其中， $size_{i,t-1}$ 和 $btm_{i,t-1}$ 是滞后一期的规模和账面市值比的排名， mkt_t 表示市场超额收益。作者使用了混合面板回归方法来估计这个模型。同时还使用了按时间（即年-月）和 Fama-French 的 49 个行业进行聚类后稳健的标准差。

图9：混合面板回归模型结果

	Estimate	[Robust t-stat]
Intercept	0.009	[15.99]
$size_{i,t}$	-0.011	[-18.73]
smb_t	1.187	[62.38]
$size_{i,t} \times smb_t$	-0.911	[-33.60]
$btm_{i,t}$	0.002	[2.83]
hml_t	-0.44	[-17.71]
$btm_{i,t} \times hml_t$	1.198	[33.82]
mkt_t	0.893	[58.09]
$size_{i,t} \times mkt_t$	-0.289	[-16.64]
$btm_{i,t} \times mkt_t$	-0.168	[-7.40]
R-square	0.180	
Adjusted R-square	0.180	

资料来源：《Lucky Factors》，2021 年 4 月 21 日

图 9 展示了该模型的回归结果。在该模型中，所有变量都具有高度显著性，这表明使用个股来确定影响股票截面收益的重要因子的能力。值得注意的是，这四个相乘项也很显著，这为择时因子载荷的显著性提供了强有力的证据。此外，特征本身似乎在解释相对于特征分类投资组合本身的收益（具有择时因子载荷）方面也具有增量贡献。相比之下，第 3.3 节中的研究框架侧重于无条件回报，因此不能考虑择时因子载荷或相关特征。图 9 所示的证据不仅支持作者这个使用个股来检验风险因子的主要想法，同时还指出了使用股票择时特征的混合面板回归模型作为未来研究的方向。关于此类混合回归模型的实施细节，可以参考 Harvey 和 Liu (2020b) 的文献，同时还可以根据模型选择的结果来回答以下问题：哪些特征和因子有助于解释个股的截面收益率。

3.6 注意事项

作者在本节中指出，对应用该方法感兴趣的读者需要在三个方面保持谨慎。首先，特定的测试框架（例如，面板回归和横截面回归）可能对测试结果有很大的影响，不论是否进行多重测试校正。如果把个股作为测试资产，那么作者提倡使用面板回归，因为观测值中的离群点过多，可能会回归得到错误的模型。

第二，在测试建议因子的增量贡献时，备选因子和预选因子的列表必须事先确定。指定备选因子列表是构成多重测试偏差的另一个来源。一旦确定了这个列表，逐步选择方法的顺序性质将不会影响最终的测试结果，因为预先确定的因子是固定的，所以只需要做出一个一次性的决定（即，建议的因子是否从备选因子列表中脱颖而出）。

第三，盈利能力在本文测试中有所体现，但这是在 2015 年才发现的因子。从本质上说，这个测试中盈利能力的整个历史都是一个回溯测试。当一个因子没有被挖掘出来时认为它有用可能是意义不明的。相比而言，market、smb 和 hml 的优势在于它们有较长的历史（至少 30 年）。

4. 结论

金融界 50 年来一直在寻找解释预期收益横截面的因素。然而，即使经过这么长时间，对于这种因子的结构是什么样的，仍然没有达成共识。本文也没有找到最终解。然而，本文确实有一些令人烦恼的问题上取得了一些进展。

第一，为什么选择不同的估计犯法（面板时间序列法与 Fama-MacBeth 横截面回归法）会导致不同的有效因子结果？事实上，还有其他令人费解的问题，如市场因子在解释个股收益和投资组合收益的方差方面的明显优势，但它难以解释截面预期收益。作者认为，面板估计方法有许多优点，并可能在模型可能的错误方面更有弹性，如省略变量。此外，作者证明了该方法不受市场因子在时间序列中起作用而在截面中不起作用的情况的影响。结果表明，市场收益率是解释截面预期收益的最重要的因子。

第二，为什么基于不同特征分类的投资组合会给出不同的确定因子结果？例如，基于以规模和账面市值比分类得到的投资组合进而确定的有效因子集，可能与以行业分类的投资组合确定的因子不同。在这一问题上，作者的解决方案很简单。他回避了投资组合，只对个股进行回归研究。而且很重要的一点是，作者的模拟研究表明，使用个股数据进行测试的可信度与使用投资组合时相比是类似，甚至更大的。这一结果也消除了一个以前的共识，即个股噪声太大，不能用作测试资产。

第三，为什么资产定价测试如此依赖于经典的 GRS 检验？众所周知，这种检验有许多局限性。它只能应用于少数资产，它通常给出不切实际的空头头寸，它几乎总是拒绝原假设，并且它通常被用作（有问题的）模型比较的启发式方法。作者强调，这项检验将确定某个因子有很大的超额回报（如 Berkshire Hathaway 的股票），但很少有能够解释截面上的预期回报。

第四，考虑到已经提出了数百个因子，应该如何处理多次测试的问题？对此作者提出了一种基于 bootstrapping 方法的逐步模型选择法。虽然许多研究都使用了 bootstrap 方法进行模型选择（例如，Romano 和 Wolf, 2005），但作者提供了一个独特的实现方案，从而能够识别对截面预期收益有增量贡献的因子。更重要的是，可以在这个研究框架下有条件地进行减损/调整备选因子，使其对截面预期收益失去解释力，但保留其时间序列特性（如相关性和非正态性）。然后，研究者可以在原假设下进行模拟，并将实证分布与实际因子性质进行比较。另外，该方法是通用的，它可以应用于面板回归中选择因子的过程，也可以用于横截面方法以及预测回归。

虽然本文并不打算回答所有这些问题，但仍然取得了一些可观的进展。也就是说，还有很多工作要做。例如，如果一个因子有 30 年的历史，另一个因子最近刚刚被发现（并可能被挖掘出数据），是否应该区别对待两个备选因子？Chen 和 Zimmermann（2021）以及 Jensen 等人（2021）最近的研究强调了过去发现的许多异

常的可复制性。但仅仅因为某个因子在样本数据中重现并不意味着该因子是“真的”。也就是说，如果在挖掘出来以后，或在其他资产（如非美国资产）上也能观测到类似样本中的结果，则更有说服力。

在对个股进行测试时，也有一些问题作者还没有解决。例如，个股的特征会随着时间的推移而变化，从而导致风险载荷的不稳定性。如果采用允许根据股票某些特征进行择时买卖的投资组合构建方法，那么在风险载荷上的不稳定性可能会更明显。这些问题是留给未来研究的。

5. 我们的点评

确定在截面上驱动预期收益的因子是具有挑战性的，这有至少三方面的原因。第一，检验方法的不同（时间序列回归与截面回归）将给出不同的有效因子结果。第二，不同的投资组合上进行测试会改变候选因子的重要性。第三，考虑到已经提出的数百个因子，在检验过程中必须要处理测试多重性。另外，如果使用面板回归模型来检验因子的有效性，最常用的检验模型解释力的检验方法是 GRS 检验，但这种检验具有很多局限性。本文从探究对截面预期收益有解释力的风险因子出发，为了解决上述这些问题，作者提出了一种新的研究框架，即结合 bootstrap 方法的面板回归模型，并针对 GRS 检验的局限性，提出了新的假设检验方案，提出了一个在截面上没有解释力的原假设，并且给出了三种容易理解且有经济意义的检验统计量。这在应对这些挑战方面取得了可观的进展，同时也为后续与量化选股因子相关的研究提供了新的研究框架。

作者将该方法应用于在常用的 14 个风险因子中，挑选能够有效解释截面收益的因子这个问题中。作者绕过了使用某些特定的投资组合会导致结果偏差的问题，选择使用两千余只个股数据进行实证研究。实证结果表明，市场因子是最具有截面预期收益解释力的因子，smb、hml 和代表盈利能力的 qmj 因子也具有显著性，这一结果具有参考意义。另外，作者尝试建立了具有择时因子载荷，而非传统的常数因子载荷的混合面板回归模型，并结合之前的实证结果给出了初步的实证结论，这个模型为以后的研究指出了一条新的道路，具有参考意义。

本篇文章基于美国市场的股票数据，在国内市场中股市收益、规模、账面市值比和盈利能力相关的风险因子是否也具有类似的结论值得进一步研究。但如果作者提出的这种结合 bootstrap 方法的面板回归模型、及相应的假设检验方法在国内也依然具有稳健性，那么可以为有效选股因子的选择过程提供一个新的思路。

6. 参考文献

C.R. Harvey and Y. Liu . Lucky Factors[J]. Journal of Financial Economics 141 (2021) 413–435

7. 风险提示

本报告内容来源于相关文献，不构成投资建议。文中的结果基于原作者对美国市场历史数据进行的实证研究，当市场环境发生变化的时候，存在模型失效的风险。

相关报告汇总

报告类型	标题	日期
金融工程普通报告	量化市场观察：价量轮动策略上周超额达到 3.14%，波动率和技术因子强势反弹	2021-08-01
金融工程普通报告	基金市场跟踪：储能产业 ETF 密集申报，TMT 主题基金表现突出	2021-07-27
金融工程普通报告	量化市场观察：价量轮动策略上周超额达到 3.43%，成长因子表现亮眼	2021-07-25
金融工程深度报告	量化基金研究：偏股主动型基金 2021Q2 持仓分析，抱团因子最新持仓	2021-07-25
金融工程深度报告	量化择基系列之一：如何通过构建基金组合获取打新收益	2021-07-23
金融工程普通报告	基金市场跟踪：TMT 主题 ETF 资金净流入，FOF 基金集中发行	2021-07-19
金融工程普通报告	量化市场观察：推荐行业表现出色，一致预期和成长因子值得关注	2021-07-18
金融工程普通报告	基金市场跟踪：宽基 ETF 资金净流入，新能源主题基金表现突出	2021-07-13
金融工程普通报告	量化市场观察：价量轮动策略大幅跑赢基准，市值因子表现优异	2021-07-11
金融工程普通报告	量化市场观察：北上资金最新动态与 7 月行业配置建议	2021-07-08

资料来源：东兴证券研究所

分析师简介

高智威

东兴证券金融工程首席分析师，北京大学物理学博士，6 年左右金融工程研究经验，曾就职于兴业证券、招商证券，2021 年 2 月加入东兴证券研究所。长期从事金融工程领域研究，擅长量化选股、资产配置、基金研究以及衍生品投资策略等。2015 年、2016 年、2017 年和 2020 年作为团队核心成员上榜新财富最佳分析师。

分析师承诺

负责本研究报告全部或部分内容的每一位证券分析师，在此申明，本报告的观点、逻辑和论据均为分析师本人研究成果，引用的相关信息和文字均已注明出处。本报告依据公开的信息来源，力求清晰、准确地反映分析师本人的研究观点。本人薪酬的任何部分过去不曾与、现在不与、未来也将不会与本报告中的具体推荐或观点直接或间接相关。

风险提示

本证券研究报告所载的信息、观点、结论等内容仅供投资者决策参考。在任何情况下，本公司证券研究报告均不构成对任何机构和个人的投资建议，市场有风险，投资者在决定投资前，务必要审慎。投资者应自主作出投资决策，自行承担投资风险。

免责声明

本研究报告由东兴证券股份有限公司研究所撰写，东兴证券股份有限公司是具有合法证券投资咨询业务资格的机构。本研究报告中所引用信息均来源于公开资料，我公司对这些信息的准确性和完整性不作任何保证，也不保证所包含的信息和建议不会发生任何变更。我们已力求报告内容的客观、公正，但文中的观点、结论和建议仅供参考，报告中的信息或意见并不构成所述证券的买卖出价或征价，投资者据此做出的任何投资决策与本公司和作者无关。

我公司及其所属关联机构可能会持有报告中提到的公司所发行的证券头寸并进行交易，也可能为这些公司提供或者争取提供投资银行、财务顾问或者金融产品等相关服务。本报告版权仅为我公司所有，未经书面许可，任何机构和个人不得以任何形式翻版、复制和发布。如引用、刊发，需注明出处为东兴证券研究所，且不得对本报告进行有悖原意的引用、删节和修改。

本研究报告仅供东兴证券股份有限公司客户和经本公司授权刊载机构的客户使用，未经授权私自刊载研究报告的机构以及其阅读和使用者应慎重使用报告、防止被误导，本公司不承担由于非授权机构私自刊发和非授权客户使用该报告所产生的相关风险和责任。

行业评级体系

公司投资评级（以沪深 300 指数为基准指数）：

以报告日后的 6 个月内，公司股价相对于同期市场基准指数的表现为标准定义：

强烈推荐：相对强于市场基准指数收益率 15% 以上；

推荐：相对强于市场基准指数收益率 5%~15% 之间；

中性：相对于市场基准指数收益率介于-5%~+5% 之间；

回避：相对弱于市场基准指数收益率 5% 以上。

行业投资评级（以沪深 300 指数为基准指数）：

以报告日后的 6 个月内，行业指数相对于同期市场基准指数的表现为标准定义：

看好：相对强于市场基准指数收益率 5% 以上；

中性：相对于市场基准指数收益率介于-5%~+5% 之间；

看淡：相对弱于市场基准指数收益率 5% 以上。

东兴证券研究所

北京

西城区金融大街 5 号新盛大厦 B 座 16 层

邮编：100033

电话：010-66554070

传真：010-66554008

上海

虹口区杨树浦路 248 号瑞丰国际大厦 5 层

邮编：200082

电话：021-25102800

传真：021-25102881

深圳

福田区益田路 6009 号新世界中心 46F

邮编：518038

电话：0755-83239601

传真：0755-23824526