

分析师:

任瞳

rentong@xyzq.com.cn

S0190511080001

徐寅

xuyinsh@xyzq.com.cn

S0190514070004

研究助理:

郑兆磊

zhengzhaolei@xyzq.com.cn

报告关键点

相关报告

《雪球知股乎系列之一: 和关注度因子有个约定》 2017-05-08

《雪球知股乎系列之二: 百万投资组合里的宝贝》 2017-06-19

雪球知股乎系列三: 情绪因子选股正当时

2017年10月14日

投资要点

- 作为 “猎金系列十六”, 本报告研究雪球网的第三个数据源: 非格式化的用户发帖文本。通过机器学习的方式对帖子进行情绪判断, 构建情绪选股因子。
- 研究时窗为 2014 年 1 月-2017 年 7 月, 共计得到 30,658,560 篇帖子。对初始的帖子经过一系列处理得到降噪之后的信息。选择 **27,654 篇帖子作为样本内数据**, 通过人工的方式对帖子打标签, 确定情绪(正向、负向、中性三种情绪), 研究多种机器学习模型的效果, 选择 **SVM 作为最终的训练模型**。模型样本内精准度达到 **70.16%**, 在正向情绪集合、负向情绪集合的召回率分别达到 76.9%、68.2%。进一步判断样本外情绪, 得到原始的情绪因子数据源。
- 构建正向情绪比、负向情绪比、综合情绪比因子(负向情绪比即周期范围内负面帖子数/总帖子数)。测试结果显示, **负向情绪比因子具有较好的选股能力**。整体来讲, 负向情绪比越低, 未来收益会越好, 尤其是在 500 股票池内部选股能力突出。
- **将负向情绪比因子与反转因子结合, 在中证 500 股票池内部构建双因子增强策略**。双因子策略年化超额收益率、夏普率、最大回撤分别达到 11.6%、1.87、6.5%, 显著优于反转因子的相应表现。这意味着当期下跌较多但市场负面情绪没那么严重的股票将会有更高的超额收益。

	总收益率	年化收益率	Sharpe 比率	胜率	最大回撤
基准	60.0%	14.1%	0.46	57.3%	54.3%
反转因子对冲	27.7%	7.1%	1.10	53.5%	10.6%
双因子对冲	48.0%	11.6%	1.87	55.0%	6.5%

- 另外从情绪角度出发也做了一些其他方面的选股因子的尝试, 如根据综合情绪比因子构建的波动率因子在全市场具有不错的选股能力, 月度因子值越大, 未来收益越高。

请阅读最后一页信息披露和重要声明



目 录

1、背景回顾.....	- 3 -
1.1、将不可思议进行到底.....	- 3 -
2、情绪分析综述.....	- 5 -
2.1、情绪分析的基本流程.....	- 5 -
2.2、雪球网情绪判断.....	- 6 -
3、情绪因子构建.....	- 11 -
3.1、因子逻辑.....	- 11 -
3.2、覆盖度分析.....	- 12 -
3.3、不同时间频度的对比分析.....	- 13 -
3.4、悲观情绪比因子在中证 500 股票池有效性测试.....	- 14 -
3.5、其他维度的情绪因子研究.....	- 15 -
4、基于中性化负面情绪比因子构建选股策略.....	- 16 -
4.1、反转因子与负面情绪比因子增强策略.....	- 16 -
5、结语.....	- 18 -
6、参考文献.....	- 19 -
图表 1、雪球网个人关注&发帖行为界面.....	- 4 -
图表 2、投资组合调仓行为界面.....	- 4 -
图表 3、雪球网用户行为分类明细.....	- 4 -
图表 4、情绪因子构建流程图.....	- 6 -
图表 5、删除的部分文本样式.....	- 7 -
图表 6、文本长度累计占比统计.....	- 7 -
图表 7、文本清洗示例.....	- 7 -
图表 8、训练集 Vs 测试集的样本对比分析.....	- 8 -
图表 9、例句的切词结果.....	- 9 -
图表 10、例句切词后的词向量处理结果.....	- 10 -
图表 11、在不同的样本数目下的 SVM Vs. 贝叶斯模型精准度对比结果.....	- 10 -
图表 12、SVM Vs. 贝叶斯模型精准度对比结果.....	- 10 -
图表 13、测试集合上模型表现.....	- 11 -
图表 14、SVM 对样本量的敏感性分析.....	- 11 -
图表 15、不同类别情绪因子的定义.....	- 11 -
图表 16、情绪因子的截面均值趋势图.....	- 12 -
图表 17、不同类别的情绪因子对 A 股的覆盖度研究.....	- 13 -
图表 18、不同周期的关注度因子的 IC 检验.....	- 13 -
图表 19、中性化以后的负面情绪比因子的表现.....	- 13 -
图表 20、中性化以后的负面情绪比因子相关性分析.....	- 14 -
图表 21、中性化以后的负面情绪比因子在 500 内 IC 表现.....	- 14 -
图表 22、中性化负面情绪比因子分位数组合测试结果.....	- 14 -
图表 23、负面情绪比因子分位数测试结果.....	- 15 -
图表 24、综合情绪比波动率因子 IC 测试.....	- 15 -
图表 25、中性化以后的综合情绪比波动率因子分位数测试结果.....	- 15 -
图表 26、中性化以后的综合情绪比波动率因子分位数测试.....	- 16 -
图表 27、选股策略表现.....	- 17 -
图表 28、策略在不同年度的表现.....	- 17 -
图表 29、反转因子对冲选股策略 Vs 双因子增强对冲选股策略净值曲线.....	- 17 -
图表 30、反转因子对冲选股策略 Vs 双因子增强对冲策略最大回撤趋势图.....	- 17 -

1、背景回顾

1.1、将不可思议进行到底

将各种奇奇怪怪的单位罗列一下，我们会发现有个很有意思的对象：不可思议单位。这个单位是描述人类觉得无法想象的事情如果真的发生大概需要的时间间隔。假设以下几个场景：

场景 1：我穿越时空，来到春秋，对话老子：“老人家，我将您的道德经抄录在纸上以便万世传颂好不好？”。老人家沉默不语……他觉得不可思议，何谓纸？想法根本不可能实现，何谈万世传颂。

场景 2：我不死心，赶到盛唐，请教玄奘：“圣僧，我将佛法抄录在纸上以便万世传颂好不好？”。玄奘微微一笑：“出家人不打诳语。”但他心里的小九九在说：没个几百年这不可能实现。


这里的“万世”、“几百年”就是不同时代的人在衡量同一件事情的不可思议单位。问题来了，如果我们穿越过去，跟老子说：我们造了个机器人来服务他老人家，能照顾的非常体贴，关键这家伙啥都会、还能自我学习。你觉得他会啥反应？你问玄奘、你问洪武大帝，他们会是啥反应？如果问此刻的你，你又会是什么反应？

停止穿越、回到现实，“不可思议”指标的缩短见证了人类的进步和科技的力量。目前最具有争议性的就是人工智能。人工智能已经深刻的改变了我们的生活方式、思维习惯。而量化投资领域是计算机最“钱”沿的地方，该如何应对这种冲击？

随着三张报表的研究效用曲线在逐步降低，大数据以及机器学习在量化投资领域的应用愈演愈烈。我们在《雪球知股乎系列之一：和关注度因子有个约定》、《雪球知股乎系列二：百万投资组合里的宝贝》详细的介绍了大数据、机器学习、人工智能的关系和发展。下面我们简单回顾一下前面两篇报告的一些关键性内容，方便后续的研究。

雪球网有很多功能界面，我们通过爬虫的方式获取雪球网上用户 UGC（用户自主生成）的行为内容。雪球网用户行为共计有三种：关注行为、发帖行为、投资组合调仓行为。另外，发帖行为是一种非格式化文本，关注行为是一种格式化文本，包括买入、卖出、关注三种行为，其中关注行为占比 95.5%。

图表 1、雪球网个人关注&发帖行为界面



资料来源：雪球网，兴业证券研究所

图表 2、投资组合调仓行为界面



资料来源：雪球网，兴业证券研究所

数据的时间窗口为 2010 年 12 月 16 日至 2017 年 7 月 21 日,在此期间共获得 4,254,659 个用户、51,320,982 条基本行为。雪球用户基本行为包括: 关注类行为、发帖、创建投资组合 3 种基本动作,其中发帖和创建投资组合行为占比 61.2%、关注类动作占比 38.80%。

图表 3、雪球网用户行为分类明细

	关注	发帖	创建投资组合	总计
数量	19,672,536	30,658,560	989,886	51,320,982
占比	38.3%	59.7%	1.9%	100.0%
因子构建	关注度因子	情绪因子 (本篇报告重点)	价值变动因子	

注:这里创建投资组合行为不是第三种基本行为,第三种基本行为为“用户调仓行为”,数据量级亿级别。

资料来源：雪球网，兴业证券研究所

我们根据关注行为构建了关注度因子，该因子统计了时间周期范围内某个股票被关注的次数，结论有四：

- 1、关注度因子具有反转效应，当期关注度低的股票未来（月度/周度）会有溢价；
- 2、雪球网关注度因子与其他互联网文本关注度因子（主流财经媒体网站、股吧）或者类关注度因子（同花顺点击率等）的秩相关性在 0.7-0.8 左右，具有同质性，也都具有反转效应；
- 3、雪球网关注度因子换手率较高（月度关注度回测的单边换手率均值为 63%）、具有一定的小市值效应；
- 4、关注度因子对于价值因子有一定的增强作用，估值低关注度低的股票未来具有更大的想象空间。

根据投资组合的调仓行为构建价值变动因子，该因子将百万投资组合合并成一个组合，构建月度市值变动率因子，进一步剥离反转因子，该因子具有反转效应：当期调入越多的标的未来下跌的越多，调出越多的标的未来上涨的越多。（具体参见《雪球知股乎系列之一：和关注度因子有个约定》、《雪球知股乎系列二：百万投资组合里的宝贝》）。

而本篇是我们基于雪球网用户发帖行为推出的第三篇报告。研究基本框架如下：

- 1、对用户的发帖进行初始筛选，删除无效的帖子以及文本过长的帖子；
- 2、选择 27,654 篇帖子用于人工打标签，然后通过机器学习的方式对历史全样本进行判断，确定每篇帖子的情绪；
- 3、构建情绪因子用于选股；
- 4、基于有效的情绪因子构建选股策略。

2、情绪分析综述

2.1、情绪分析的基本流程

情绪分析通过运用 NLP、文本挖掘、计算语言学等技术实现对各种非规范化的文本语言处理，达到相应的情绪判断的目的。Stone, Philip^[1]于 1966 年基于研究对象的言语行为去分析病人的心理问题标志着情绪分析的开始。目前主流的研究方法分成无监督的文本情感判断和有监督的情感判断。

无监督的情感判断主要运用情感词的相关信息对文本情绪的判断。Hatzivassiloglou^[2]等的研究表明通过情绪词汇能很好的判断句子的情感倾向。Taboada^[3]等利用情感词典中的关联度和权重信息对文本的情绪进行判断。而

Turney^[4]等则认为词组比单词更能准确的表达情感，包括对语句的情绪进行判断等。简单总结来讲，这种方法的流程是确定情绪词库，然后通过统计文本中不同情绪词库中的词出现的比例，进一步权重化，进而得到最终的情绪值。该方法面临的问题是：1、需要动态维护情绪库；2、忽略了文本的结构问题，导致部分关键信息的丢失。

有监督学习的文本情感分析主要运用贝叶斯模型、支持向量机（SVM, Support Vector Machine）、神经网络等模型进行情感分类。Pang、Lee、Vaithyanathan^[5]最早将该方法用于对电影评论文本分类，分为褒义和贬义两类。其他不同的学者也对机器学习在情绪分析方面的研究进行了不同的尝试和改进。Ye^[6]等比较了贝叶斯、支持向量机在旅行博客上的情绪判断，实验表明支持向量机的效果要优于贝叶斯的方式。


这里需要强调一点，无论是通过词库方式判断文本情绪，亦或通过机器学习的方式判断文本的情绪，都需要通过切词的方式对文本进行碎片化、向量化处理。

2.2、雪球网情绪判断

我们将每一篇文本的情绪分为3类：乐观、悲观、中性，采用机器学习的方式对文本情绪进行判断。可选择的机器学习模型很多，通过对比分析，我们选择SVM作为最终的机器学习模型（后面会有具体的讨论）。

整个文本处理的流程如下：

图表 4、情绪因子构建流程图



资料来源：雪球网，兴业证券研究所

雪球网数据抓取在此就不做赘述，具体参见往期报告。我们接下来重点关注其他关键步骤。

1、删除无效文本：此次研究对象为雪球网用户发的非格式化文本。但有些行为可能仅仅是雪球网的一种推广行为或者无意义的格式文本，鉴于这些文本对最终的情绪分析没有作用，所以删除该类文本。


图表 5、删除的部分文本样式

删除的部分文本内容样式	
类型一	我在今天雪球实盘大赛<***>#摇一摇 PK#日收益比赛中，战胜了<***加部馆长" target="_blank">@加部馆长，抽到了 2 元交易券！你也来参与吧
类型二	我刚下载了 <>@NeOOHe 分享的研报《一本谨慎机智的投资手册》，推荐给你
类型三	我刚刚抢到了 @银行螺丝钉 发放的 0.10 元，你也快来抢~
类型四	我刚赞助了这篇帖子 1 雪球币，也推荐给你
... ..	

资料来源：雪球网，兴业证券研究所

2、删除过长文本：部分文本内容过长，一方面增加了情绪判断的难度：当文本过长时会对切词、情绪分析、包括最终的词向量维度产生较大的影响；另一方面极大的降低学习的效率。我们统计所有样本的字符长度，发现文本长度在 700 以内的样本数占比为 97.5%。鉴于此，我们最终只保留文本长度<=700 的样本作为情绪分析对象。

图表 6、文本长度累计占比统计



资料来源：雪球网，兴业证券研究所

3、文本清洗：原始的文本包含大量的噪音或者对情绪判断无效的信息，因此需要对初始的文本内容进行清洗，一方面提升文本质量、降低词向量空间，另一方面提升运算效率。针对于初始文本的清洗维度大致如下：

图表 7、文本清洗示例

类型	清洗前内容	清洗后
链接类	a href="http://xueqiu.com/S/ a href="http://xueqiu.com/n/	STOCK_URL_ USER_URL_ URL_Base
噪音类	其他噪音类信息（一些内容标识信息，如_blank, height24 等）	Detail_

用户姓名 专门的用户姓名标识

USER_NM_

资料来源：雪球网，兴业证券研究所

4、文本切分：文本清洗后，接下来需要将其分成样本内、样本外数据，同时针对于样本内的数据需要进一步切分成训练集和测试集。保证随机选择的情况下切分的原则是：确保时间维度覆盖度、A股覆盖度。我们抽取了 27,654 篇帖子作为样本内数据。进一步将样本内数据分成训练集和测试集，比例为 70%: 30%（训练集: 测试集）。这样就得到了 19,332 篇幅的训练集合、8,322 篇幅的测试集。样本内正向情绪的文本占比 48.07%、负向情绪的占比 29.49%、中性情绪的文本占比 22.45%。这个比例与目前市场的现象比较一致：国内市场普遍存在着报喜不报忧的现象，而散户投资者的情绪也存在着类似的比例分配情况。

图 8、训练集 Vs 测试集的样本对比分析

样本量	训练集	测试集	类别总计
正向文本	9,295	3,998	13,293 (48.07%)
负向文本	5,682	2,472	8,154 (29.49%)
中性文本	4,355	1,852	6,207
总计	19,332	8,322	27,654

资料来源：雪球网，兴业证券研究所

5、Prep：接下来重点讲述 Prep 板块的流程。该部分主要讲述了如何切词、以及如何将切词以后的结果转化成模型（贝叶斯、SVM 等）的输入。主要步骤包括切词、否定词、词性的应用、词向量空间生成等几个关键步骤。

5.1、切词：这一步的主要目的是对文本进行切词，碎片化文本后，作为进一步研究的对象。而切词的依据是词库。目前比较流行的词库有中科院分词系统 ICTCLAS (Institute of Computing Technology Chinese Lexical Analysis System), 其是基于多层隐马尔科夫模型; 哈工大的 LTP 系统 (Language Technology Platform), 该系统具有包括分词、词性标注在内的一套基于 XML 的中文语言分析处理模块等。我们这里利用的是结巴分词系统。该系统基于前缀词典实现高效的词图扫描, 生成句子中汉字所有可能成词情况所构成的有向无环图 (DAG); 采用了动态规划查找最大概率路径, 找出基于词频的最大切分组合; 对于未登录词, 采用了基于汉字成词能力的 HMM 模型, 使用了 Viterbi 算法。同时为了完善词库, 我们通过自定义的方式导入搜狗金融词库, 构成原始的词库表。

5.2、否定词：否定词的使用会导致语义反转。比如“不/太平”、“不/开心”、“并非/如此”、“从未/快乐”等。根据切词的结果会切出正向词汇, 但实际上上面的表述本身传达的是一种否定的意义。需要对否定句进行特殊处理, 如句子 “I didn’t like this movie”。Das and Chen^[7] (2001) 提出了 “一旦出现否定词, 那么在否定词之后、符号之前的所有切词结果都加上否定词, 进而形成新的词汇”, 根据此规则可以将句子 “didn’t like this movie, but I” 转换

为“didn't NOT-like NOT-this NOT-movie, but I”。我们这里利用的否定词如下：['不', '不可', '切勿', '勿', '反', '未', '未有', '未曾', '别', '否', '否定', '绝不', '没', '没有', '并非', '尚未', '非', '从不', '从未', '毫不', '莫', '无', '绝不', '难以']。

5.3、停用词：停用词(stop words)是指评论文本数量较多，但对文本的情绪倾向分析没有帮助的词语，例如代词“这”、“那”、“他”，副词“也”、“刚刚”，其他词汇如“而”、“及”、“与”、“或”等。根据停用词集合构建的停用词表删除停用词，能够减少数据噪音，提升文本情感分类的准确率。

部分停用词样本如下：[和, 是, 就, 都, 而, 及, 與, 著, 或, 一个, 我们, 你们, 她们, 他们]。这里需要注意的是需要将刚刚“文本清洗”步骤产生的一些词汇，如“STOCK_URL”、“USER_URL”、“URL_Base”、“USER_NM”等添加到停用词里面。

5.4、词性标注：通常而言，表达情感的词汇往往是形容词，此外动词、名词等也有类似的作用。但是数词、量词、介词等词汇可能并无太大的作用；另外如果不做词性的限制，最终词向量空间可能会比较大，也会影响运算效率。因此我们将仅仅考虑形容词、动词、名词等功能实词作为特征。

5.5、词向量：这一步主要说明的是模型的输入，即词向量生成问题。根据前面的文本切分、我们得到了每个文本的分词结果(每一个文本是一个词向量空间， $1 \times N$ 维度，这里的 N 是每个文本切分后的词数目)；然后通过否定词处理将每句否定词位置以后的词语进行否定化处理；进一步丢弃没有意义的词汇，其中没有意义的词汇处理流程包括：停用词的处理以及词性的处理。这样我们就能得到每个文本处理完毕的词向量($1 \times N'$ 维，这里 $N' \leq N$)。然后取所有文本切词后的词量并集，生成词向量全集($1 \times M$)，进一步生成 $K \times M$ (K 个样本)维度的向量空间。

下面以两个文本为例，将上面的过程进行简单的梳理。

图表 9、例句的切词结果

例句	文本内容	切词后
例句 1	大部分员工没离开。	[大部分、员工、没、离开]
例句 2	女孩非常爱吃 Ginger 和甜品。	[女孩、非常、爱、吃、Ginger、和、甜品]

资料来源：雪球网，兴业证券研究所

对上面切词后的结果进行“Prep”阶段处理。1、切词，切词后结果参见上述表格；2、将例句 1 中的否定词“没”添加到后面的“离开”(否定词以后，符号之前的所有分词结果)上形成新词汇“没离开”；3、将例句 2 中的“和”这个停用词去掉；4、然后取所有例句的词全集[大部分、员工、没、没离开、女孩、非常、爱、吃、Ginger、甜品]。依照词向量全集对每个例句切词后的词是否出现在全集中做 0/1 判断处理(0 表示没有出现、1 表示出现)，处理完毕后结果如下：

图表 10、例句切词后的词向量处理结果

例句	Prep 处理后的结果	词向量处理后
例句 1	[大部分、员工、没、没离开]	[1、1、1、1、0、0、0、0、0、0]
例句 2	[女孩、非常、爱、吃、Ginger、甜品]	[0、0、0、0、1、1、1、1、1、1]

资料来源：雪球网，兴业证券研究所

然后根据每个文本词向量化后的结果，结合情绪的帖子得到模型的输入，进行训练。

6、SVM 模型：前面在情绪判断的研究中提及，可以运用 SVM、贝叶斯、神经网络等多种方法对文本情绪进行判断，在效率和效果方面性价比较高的是 SVM 模型。我们这里以 SVM 和贝叶斯模型的对比分析为例进行说明。


选择 N 个情绪文本作为测试对象（训练集：测试集=70%:30%），分别测试 N=6,000、8,000、10,000 时，相应的模型表现。从测试结果来看：1、同样本下 SVM 要优于贝叶斯的表现；2、SVM 模型对 N 的敏感性要优于贝叶斯模型，随着 N 的增大，SVM 效果提升的更快；3、时间效率方面，SVM 也显著的、稳定的优于贝叶斯表现。因此后面的分析中将运用 SVM 作为情绪判断的训练模型。

图表 11、在不同的样本数目下的 SVM Vs. 贝叶斯模型精准度对比结果

样本量	SVM	贝叶斯
6000	61.32%	54.91%
8000	63.93%	55.76%
10000	65.18%	56.31%

资料来源：雪球网，兴业证券研究所

图表 12、SVM Vs. 贝叶斯模型精准度对比结果



资料来源：雪球网，兴业证券研究所

7、训练效果：通过以上的整体操作，我们得到了模型输入，运用 SVM 模型进行训练，得到模型的训练结果，我们从精准度和召回率两个维度考察效果（根据前面的测试集合和训练集合的比例，我们在 27,654 个样本中共计得到 8,322 个测试文本）。在测试集上，模型的精准度为 70.16%。而从召回率的角度来看，正向、

负向、中性文本的召回率分别为 76.9%、68.2%、58.3%。


图表 13、测试集合上模型表现

例句	样本数目	召回率
正向集合	3,998	76.9%
负向集合	2,472	68.2%
中性集合	1,852	58.3%

资料来源：雪球网，兴业证券研究所

另外需要注意的是，正如前面在对比 SVM 和贝叶斯模型对测试样本数目的敏感性分析一样，我们分别测试了 N=6,000、8,000、10,000、15,000、20,000、27,654 个样本时，SVM 模型的表现。随着 N 的增大，模型效果在不断提升，但考虑到打标签的人工成本，我们最终打了 27,654 个样本。

图表 14、SVM 对样本量的敏感性分析



资料来源：雪球网，兴业证券研究所

3、情绪因子构建

3.1、因子逻辑

基于前面的整体研究，我们得到了情绪因子的初始数据源，进一步构建情绪因子。每篇帖子的情绪有三种可能：正向情绪、负向情绪、中性情绪。那么，我们分别定义了以下几种类别的情绪因子。

图表 15、不同类别情绪因子的定义


因子	因子/英文	因子定义
负面情绪比	Neg_ratio	截面负面情绪帖子占截面总量帖子比例
正面情绪比	Pos_ratio	截面正面情绪帖子占截面总量帖子比例
综合情绪比	Pos_Neg_ratio	(截面负面情绪帖子数-截面正面情绪帖子数)/截面总量帖子数

资料来源：雪球网，兴业证券研究所

从占比的角度来讲，我们分别构建了正向情绪占比、负面情绪占比、综合情绪比三个因子。因子之间可能具有一定的相关性，但各因子反应的信息量不一样。

这里，我们研究了三个情绪因子的截面均值历史趋势图。这里以负面情绪比为例进行说明（正面情绪比与其正好相反），14 年至 15 年 7 月呈现单调递增的趋势，尤其是 15 年前半年，当时行情暴涨，但是从负面情绪比指标来看市场表现一定的恐慌情绪；15 年 8 月至今呈现单调递减的趋势，今年以来有一定波动。

图表 16、情绪因子的截面均值趋势图



资料来源：雪球网，兴业证券研究所

下面所有的测试都是在以下条件基础之上进行：

个股数据：全市场选股，剔除不满足交易条件的个股；


行业分类：中信一级行业；

数据区间：2014 年 1 月 1 日至 2017 年 7 月 21 日；

3.2、覆盖度分析

首先研究不同类别的月度情绪因子对 A 股的覆盖度。从结果来看，正向情绪比因子的覆盖度较高，覆盖度均值达到 93.9%，尤其是 2014 年以后的覆盖度已经趋于全市场覆盖；而负面情绪覆盖度相对较低，但是月度因子的覆盖度均值已经达到 83.8%。

图表 17、不同类别的情绪因子对 A 股的覆盖度研究



资料来源：雪球网，兴业证券研究所

3.3、不同时间频度的对比分析

构建周度以及月度频度的上述因子，从 IC 以及分位数组合角度测试因子在全市场的有效性。

图表 18、不同周期的关注度因子的 IC 检验

	关注度因子分类	平均值	标准差	最小值	最大值	IC_IR	t 统计量
月 度	负面情绪比	0.025	5.1%	-10.5%	11.0%	0.49	3.22
	正面情绪比	0.002	4.1%	-7.6%	9.6%	0.05	0.35
	综合情绪比	-0.007	4.4%	-8.7%	9.7%	-0.16	-1.03
周 度	负面情绪比	0.018	4.3%	-10.0%	38.9%	0.41	5.62
	正面情绪比	-0.002	3.2%	-15.6%	8.4%	-0.06	-0.84
	综合情绪比	-0.006	3.8%	-30.4%	10.0%	-0.17	-2.25

资料来源：雪球网，兴业证券研究所

从检测结果来看：1、从频度角度分析，周度频度的因子几乎全部失效，没有选股的预测作用；2、从月度因子具体分析，负面情绪比因子有着较强的选股能力，负面情绪比越低意味着未来标的表现越好。

正面情绪因子失效而负面情绪有一定的预测作用这种现象也比较符合实际。国内股市一般是报喜不报忧，正面情绪存在着大量的噪音，很难从中找到有效的选股信息。而一旦股票形成负面情绪，那市场对股票的认可方面可能进入一个低谷，在悲观里面进行切分，悲观情绪较重的股票可能面临着更大的下行空间。


对悲观情绪比因子进行行业市值中性化，并进一步观察中性化之后的因子与价值、成长、反转、分析师情绪、换手率等因子的相关性。结果发现：中性化以后因子选股能力有所降低；另外，因子与传统的选股因子相关性较低。

图表 19、中性化以后的负面情绪比因子的表现

关注度因子分类	平均值	标准差	最小值	最大值	风险调整的 IC	t 统计量
负面情绪比因子	0.016	4.9%	-11.0%	10.5%	0.328	2.15

资料来源：雪球网，兴业证券研究所

图表 20、中性化以后的负面情绪比因子相关性分析



资料来源：雪球网，兴业证券研究所

虽然中性化以后的负面情绪比因子有效性有所降低，但在不同指数股票池上可能会有另一番惊喜，所以接下来测试中性化负面情绪比因子在中证 500 股票池内部的选股效果。

3.4、悲观情绪比因子在中证 500 股票池有效性测试

验证中性化悲观情绪比因子在中证 500 股票池内部的表现。测试结果显示，在中证 500 股票池内部有较为突出的选股能力，IC 达到 0.022，IC-IR 达到 0.4。而观察分位数组合测试的结果发现悲观情绪比与未来收益率呈现负相关关系，悲观情绪比值越小，未来表现会越好。top 组别（悲观情绪比值最低的）年化收益率为 21.7%，夏普率为 0.65。

后面如无特别强调，悲观情绪比因子均是行业市值中性化以后的结果。

图表 21、中性化以后的负面情绪比因子在 500 内 IC 表现

关注度因子分类	平均值	标准差	最小值	最大值	IC_IR	t 统计量
负面情绪比因子	0.022	5.4%	-10.1%	12.9%	0.394	2.58


资料来源：雪球网，兴业证券研究所

图表 22、中性化负面情绪比因子分位数组合测试结果

	总收益率	年化收益率	Sharpe 比率	换手率	最大回撤率	年化超额收益率	跟踪误差	信息比率	胜率
top	104.6%	21.7%	0.65	1.47	43.6%	3.7%	4.0%	0.91	60.0%
1	85.6%	18.5%	0.59	1.57	42.7%	0.4%	4.1%	0.09	62.2%
2	74.2%	16.4%	0.51	1.45	40.7%	-1.1%	2.9%	-0.39	40.0%
3	72.7%	16.2%	0.50	1.55	41.2%	-1.3%	3.6%	-0.36	40.0%
Bottom	71.7%	16.0%	0.49	1.56	46.4%	-1.3%	3.0%	-0.43	35.6%
市场	81.1%	17.7%	0.55		42.8%				

资料来源：雪球网，兴业证券研究所

图 23、负面情绪比因子分位数测试结果



资料来源：Wind，兴业证券研究所

3.5、其他维度的情绪因子研究

我们根据正向情绪、负向情绪、以及两者截面的差异构建了三个选股因子。实际上我们还进行了多维度的研究。这里将其中比较有意义的一些结果分享出来，希望能起到抛砖引玉的作用。

进一步利用综合情绪比因子，构建该因子的月度波动率因子，测试该因子的有效性。

因子计算步骤：

- 1、计算每个月的（正面帖子数-负面帖子数）/帖子总数，即综合情绪比指标；
- 2、计算该指标的月度波动率，得到综合情绪比波动率因子；

全市场选股测试该因子的表现，并对该因子进行行业市值中性化，一并研究中性化之后的表现。

测试结果显示，该因子具有较强的选股能力，行业市值中性化以后的表现依然稳健，IC 为 0.035，IC-IR 达到 0.69。而中性化以后的分位数测试显示，该因子与收益率之间是严格的单调规律，波动率越高未来表现越好。

固然，基于波动率方面的研究是一种现象，我们尚未从中找到比较合适的解释理论。

图 24、综合情绪比波动率因子 IC 测试

	平均值	标准差	最小值	最大值	IC_IR	t 统计量
综合情绪比波动率	0.045	7.8%	-17.4%	16.7%	0.577	3.74
中性化综合情绪比因子	0.035	5.1%	-4.6%	17.1%	0.690	4.47

资料来源：雪球网，兴业证券研究所


图 25、中性化以后的综合情绪比波动率因子分位数测试结果

	总收益率	年化收益率	Sharpe 比率	换手率	最大回撤率	年化超额收益率	跟踪误差	信息比率	胜率
top	134.6%	27.8%	0.75	1.33	39.4%	3.9%	2.6%	1.47	62.8%
1	122.5%	25.9%	0.70	1.55	39.1%	2.3%	2.0%	1.16	60.5%
2	100.9%	22.2%	0.61	1.58	39.0%	-0.9%	1.9%	-0.45	44.2%
3	95.2%	21.2%	0.57	1.55	40.1%	-1.6%	1.7%	-0.93	44.2%

Bottom	79.4%	18.3%	0.49	1.38	41.8%	-3.9%	2.7%	-1.44	25.6%
市场	106.1%	23.1%	0.63		39.5%	0.0%	0.0%		0.0%

资料来源：雪球网，兴业证券研究

图表 26、中性化以后的综合情绪比波动率因子分位数测试



资料来源：Wind，兴业证券研究所

4、基于中性化负面情绪比因子构建选股策略

中性化负面情绪比因子在中证 500 股票池内部表现出比较好的选股能力。那么该因子对传统的选股因子有没有一定的增强作用呢？从反转因子的角度出发，当前股票下跌幅度较大的股票未来会有更大的成长空间。那么在下跌的里面找到负面情绪相对较低的股票，即当期下跌的非常严重但是市场情绪又不是那么悲观的股票未来是否能取得更高的超额收益呢？

基于月度反转因子和月度中性化负面情绪比因子构建双因子增强策略。

选股基本条件：

个股数据：中证 500 股票池内部选股，剔除不符合条件个股；

行业分类：中信一级行业；

数据区间：2014 年 1 月 1 日至 2017 年 7 月 21 日；

4.1、反转因子与负面情绪比因子增强策略

利用反转因子和中性化负面情绪比因子在中证 500 股票池内部选股。研究的目的是双因子增强策略对比单独的反转因子的选股策略表现。双因子增强策略选股流程如下：每个月最后一个交易日结束后进行组合的筛选和调整，按照中信行业对负面情绪比因子排序、选择每个行业因子值最低的 50% 比例股票作为初始股票池，然后按照反转因子进行排序，选择反转因子最大的 20% 配仓，按中证 500 权重配权。单独的反转因子选股策略相对简单：月度调仓、月底选择反转因子最大的 10% 配仓、行业中性化、中证 500 权重配权。

从对冲策略的结果来看，双因子增强策略表现稳定的优于单反转因子的表现。

在年化收益率、夏普率、最大回撤等关键指标方面都得到了大幅度的提升。而分年度来看，双因子策略也稳定的优于单因子的对冲策略表现。

图表 27、选股策略表现

	总收益率	年化收益率	年化波动率	Sharpe 比率	胜率	最大回撤
基准	60.0%	14.1%	30.5%	0.46	57.3%	54.3%
单因子对冲	27.7%	7.1%	6.5%	1.10	53.5%	10.6%
双因子对冲	48.0%	11.6%	6.2%	1.87	55.0%	6.5%


资料来源：雪球网，兴业证券研究所

图表 28、策略在不同年度的表现

	基准	单因子对冲策略	双因子对冲策略
2014 年	39.0%	2.3%	6.4%
2015 年	43.1%	30.4%	34.1%
2016 年	-17.8%	3.4%	9.0%
2017 年	-2.2%	-7.2%	-4.6%


资料来源：雪球网，兴业证券研究所

图表 29、反转因子对冲选股策略 Vs 双因子增强对冲选股策略净值曲线



资料来源：雪球网，兴业证券研究所

图表 30、反转因子对冲选股策略 Vs 双因子增强对冲策略最大回撤趋势图



资料来源：雪球网，兴业证券研究所

正如前面所言，当期出现大幅下跌的股票并不一定在未来都能获得优异的表现，我们需要从中找到那种市场情绪不是那么悲观的股票，坚定的持有，获取更加稳健的收益。

5、结语

本文是兴业定量研究团队“猎金”系列第十六篇。在本篇中，我们利用用户的发帖，通过数据清洗、打标签、构建情绪判断模型，进一步构建正向情绪、负向情绪、综合情绪比三类因子，验证了负向情绪比因子在中证 500 中的选股能力。进一步结合反转因子构建增强策略，测量结果显示负面情绪比因子与反转因子的结合能大幅度提升反转因子的表现。

不知不觉间，基于雪球网的三篇报告全部落地。回首整个研究历程，从去年年底开始布局整个雪球网的研究计划、到网络文本抓取、再到相应的因子研究，虽然不一定做到步步精细，但我们确有处处打磨；虽然未必做到字字珠玑，但我们定量团队确心有所系。在此和大家分享一些浅见，如能起绵薄作用，将倍感荣幸。

- 1、互联网文本下的大数据研究难点有二：1)、原始数据的获取，国内大数据的兴起和积累大致是从 2013 年左右开始有一个突破点，但数据壁垒较高，获取成本很大；2)、如何从海量信息中抽茧剥丝在有效降噪的情况下，聚焦有效信息，研发有效的选股策略。虽然道阻其长，投入产出比低，但这是一个试错过程，尝试过、尽力过、我们才能知道效果。
- 2、充分利用已有的文本数据，切忌“未来函数”现象的出现。在文本数据的研究过程之中会有很多的研究维度和视角，一不留神就会踩到坑里，还欣喜若狂，以为发现了新大陆。比如雪球网用户的粉丝数、比如投资组合里面的关注人数等。从我们抓取的结果来看，我们能得到这些维度在某个时点的数据，但是没办法去回溯历史上某一时刻这些指标的数值大小，因此也没办法利用这个维度做前期的数据预处理。
- 3、大数据文本下的类关注度因子（和关注度因子相仿的因子，如点击率等）都有很高的同质性。我们兴业定量团队抓取一些主流的财经媒体网站以及东方财富股吧等数据，这些数据源构建的关注度因子的秩相关性均在 0.7-0.8 之间。根据我们《雪球知股乎系列一》对关注度因子的研究，这些因子也都具有反转效应。
- 4、情绪因子真的很“情绪”。情绪分析一直是文本挖掘的一个难题，综合利用到 NLP、机器学习等学科。而中文方面的研究更是难上加难，我们汉语

的独有魅力在这一刻又得到彰显。在对汉语进行情绪分析时，首先需要切词，切词的依据是有效的词库。而我们没有一个权威的、成熟的、得到广泛认可的词库，但这一步是基础，是起步。另外，无论是国内亦或是国外基于情绪构建的选股因子的选股并不是特别显著（相对于传统的选股因子而言）。这也不能算是坏消息，至少意味着未来的研究空间很大。

宛宛转转，三篇报告也已攒完，很感激各位对成果的思考 and 意见。接下来，我们兴业定量研究团队将投入到时效性的文本研究当中，还希望各位从中取“知”、取“悦”。

6、参考文献

[1]. Stone, Philip J., Dexter C. Dunphy, and Marshall S. Smith. "The general inquirer: A computer approach to content analysis." MIT Press, Cambridge, MA (1966).

[2]. Hatzivassiloglou, V. and K.R. McKeown. Predicting the semantic orientation of adjectives, in Proceedings of the 35th annual meeting of the association for computational linguistics and eighth conference of the European chapter of the association for computational linguistics. 1997: Association for Computational Linguistics.

[3]. Taboada, M., et al., Lexicon-Based Methods for Sentiment Analysis. Computational Linguistics, 2011. 37 (2): p. 267-307.

[4]. Turney, P. Thumbs Up or Thumbs Down? Semantic Orientation Applied to Unsupervised Classification of Reviews. Proc. 40th Annual Meeting of the Association for Computational Linguistics (ACL 02), 2002.

[5]. Pang, B., L. Lee and S. Vaithyanathan. Thumbs up?: sentiment classification using machine learning techniques in Proceedings of the ACL-02 conference on Empirical methods in natural language processing-Volume 10. 2002: Association for Computational Linguistics.

[6]. Ye, Q., Z. Zhang and R. Law, Sentiment classification of online reviews to travel destinations by supervised machine learning approaches. Expert Systems with Applications, 2009. 36 (3): p. 6527-6535.

[7]. S. Das, M. Chen. Yahoo! for amazon: extracting market sentiment from stock message boards. 2001

投资评级说明

行业评级 报告发布日后的 12 个月内行业股票指数的涨跌幅度相对同期恒生指数的涨跌幅为基准,投资建议的评级标准为:

推 荐: 相对表现优于市场;
中 性: 相对表现与市场持平
回 避: 相对表现弱于市场

公司评级 报告发布日后的 12 个月内公司的涨跌幅度相对同期恒生指数的涨跌幅为基准,投资建议的评级标准为:

买 入: 相对大盘涨幅大于 15% ;
增 持: 相对大盘涨幅在 5% ~ 15%之间
中 性: 相对大盘涨幅在-5% ~ 5%;
减 持: 相对大盘涨幅小于-5%

机构销售经理联系方式

机构销售负责人			邓亚萍	021-38565916	dengyp@xyzq.com.cn
上海地区销售经理					
姓 名	办公电话	邮 箱	姓 名	办公电话	邮 箱
盛英君	021-38565938	shengyj@xyzq.com.cn	冯诚	021-38565411	fengcheng@xyzq.com.cn
顾超	021-20370627	guchao@xyzq.com.cn	杨忱	021-38565915	yangchen@xyzq.com.cn
			王溪	021-20370618	wangxi@xyzq.com.cn
王立维	021-38565451	wanglw@xyzq.com.cn	李远帆	021-20370716	liyuanfan@xyzq.com.cn
			胡岩	021-38565982	huyan.jg@xyzq.com.cn
姚丹丹	021-38565778	yaodandan@xyzq.com.cn	曹静婷	18817557948	caojt@xyzq.com.cn
地址：上海浦东新区长柳路 36 号兴业证券大厦 12 层（200135）传真：021-38565955					
北京地区销售经理					
姓 名	办公电话	邮 箱	姓 名	办公电话	邮 箱
郑小平	010-66290223	zhengxiaoping@xyzq.com.cn	朱圣诞	010-66290197	zhusd@xyzq.com.cn
			刘晓洲	010-66290220	liuxiaoliu@xyzq.com.cn
肖霞	010-66290195	xiaoxia@xyzq.com.cn	陈杨	010-66290197	chenyang.jg@xyzq.com.cn
袁博	15611277317	yuanb@xyzq.com.cn	吴磊	010-66290190	wulei@xyzq.com.cn
陈姝宏	15117943079	chenshuhong@xyzq.com.cn	王文凯	010-66290197	wangwenkai@xyzq.com.cn
地址：北京西城区锦什坊街 35 号北楼 601-605（100033） 传真：010-66290220					
深圳地区销售经理					
姓 名	办公电话	邮 箱	姓 名	办公电话	邮 箱
朱元贱	0755-82796036	zhuyy@xyzq.com.cn	杨剑	0755-82797217	yangjian@xyzq.com.cn
李昇	0755-82790526	lisheng@xyzq.com.cn	邵景丽	0755-23836027	shaojingli@xyzq.com.cn
王维宇	0755-23826029	wangweiyu@xyzq.com.cn			
地址：福田区中心四路一号嘉里建设广场第一座 701（518035） 传真：0755-23826017					
国际机构销售经理					
姓 名	办公电话	邮 箱	姓 名	办公电话	邮 箱
刘易容	021-38565452	liuyirong@xyzq.com.cn	徐皓	021-38565450	xuhao@xyzq.com.cn
张珍岚	021-20370633	zhangzhenlan@xyzq.com.cn	陈志云	021-38565439	chanchiwan@xyzq.com.cn
马青岚	021-38565909	maql@xyzq.com.cn	曾雅琪	021-38565451	zengyaqi@xyzq.com.cn
申胜雄	021-20370768	shensx@xyzq.com.cn	陈俊凯	021-38565472	chenjunkai@xyzq.com.cn
俞晓琦	021-38565498	yuxiaoqi@xyzq.com.cn	蔡明珠	13501773857	caimzh@xyzq.com.cn
地址：上海浦东新区长柳路 36 号兴业证券大厦 12 层（200135）传真：021-38565955					
私募及企业客户负责人			刘俊文	021-38565559	liujw@xyzq.com.cn
私募销售经理					
姓 名	办公电话	邮 箱	姓 名	办公电话	邮 箱
徐瑞	021-38565811	xur@xyzq.com.cn	杨雪婷	021-20370777	yangxueting@xyzq.com.cn
唐恰	021-38565470	tangqia@xyzq.com.cn	韩立峰	021-38565840	hanlf@xyzq.com.cn
李桂玲	021-20370658	ligl@xyzq.com.cn	施孜琪	021-20370837	shzq@xyzq.com.cn
王磊	021-20370658	wangleil@xyzq.com.cn			
地址：上海浦东新区长柳路 36 号兴业证券大厦 12 层（200135）传真：021-38565955					

港股机构销售服务团队

机构销售负责人			丁先树	18688759155	dingxs@xyzq.com.hk
姓名	办公电话	邮箱	姓名	办公电话	邮箱
王文洲	18665987511	petter.wang@xyzq.com.hk	郑梁燕	18565641066	zhengly@xyzq.com.hk
陈振光	13818288830	chenzg@xyzq.com.hk	周围	13926557415	zhouwei@xyzq.com.hk
孙博轶	13902946007	sunby@xyzq.com.hk			
地址: 香港中环德辅道中 199 号无限极广场 32 楼 3201 室 传真: (852) 3509-5900					

【信息披露】

兴业证券股份有限公司(“本公司”) 在知晓的范围内履行信息披露义务。客户可登录 www.xyzq.com.cn 内幕交易防控栏内查询静默期安排和关联公司持股情况。

【分析师声明】

本人具有相关监管机构所须之牌照。本人确认已合乎监管机构之相关合规要求, 并以勤勉的职业态度, 独立、客观地出具本报告。本报告清晰准确地反映了本人的研究观点。本人不曾因, 不因, 也将不会因本报告中的具体推荐意见或观点而直接或间接收到任何形式的补偿。

【法律声明】

本报告由兴业证券股份有限公司(已具备证券投资咨询业务资格)制作。

本报告由受香港证监会监察的兴证国际证券有限公司(香港证监会中央编号: AYE823)于香港提供。香港的投资者若有任何关于本报告的问题请直接联系兴证国际证券有限公司的销售交易代表。

本报告将依据其他国家或地区的法律法规和监管要求于该国家或地区提供本报告。

本公司不会因接收人收到本报告而视其为客户。客户应当认识到有关本报告的短信提示、电话推荐等只是研究观点的简要沟通, 需以本公司 <http://www.xyzq.com.cn> 网站刊载的完整报告为准, 本公司接受客户的后续问询。

本公司的销售人员、交易人员以及其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本报告意见及建议不一致的市场评论和/或交易观点。本公司没有将此意见及建议向报告所有接收者进行更新的义务。

本公司的资产管理部门、自营部门以及其他投资业务部门可能独立做出与本报告中的意见或建议不一致的投资决策。

本报告并非针对或意图发送予或为任何就发送、发布、可得到或使用此报告而使本公司违反当地的法律或法规或可致使本公司受制于相关法律或法规的任何地区、国家或其他管辖区域的公民或居民, 包括但不限于美国及美国公民(1934年美国《证券交易所》第15a-6条例定义为本「主要美国机构投资者」除外)。

本报告可能附载其它网站的地址或超级链接。对于本报告可能涉及到本公司网站以外的资料, 本公司未有参阅有关网站, 也不对它们的内容负责。提供这些地址或超级链接的目的, 纯粹为了收件人的方便及参考, 连结网站的内容不构成本报告的任何部份。收件人须承担浏览这些网站的风险。

本公司系列报告的信息均来源于公开资料, 本公司对这些信息的准确性和完整性不作任何保证, 也不保证所包含的信息和建议不会发生任何变更。本公司已力求报告内容的客观、公正, 但文中的观点、结论和建议仅供参考, 报告中的信息或意见并不构成所述证券的买卖出价或征价, 投资者据此做出的任何投资决策与本公司和作者无关。

在法律许可的情况下, 兴业证券股份有限公司可能会持有本报告中提及公司所发行的证券头寸并进行交易, 也可能为这些公司提供或争取提供投资银行业务服务。因此, 投资者应当考虑到兴业证券股份有限公司及/或其相关人员可能存在影响本报告观点客观性的潜在利益冲突。投资者请勿将本报告视为投资或其他决定的唯一信赖依据。

若本报告的接收人非本公司的客户, 应在基于本报告作出任何投资决定或就本报告要求任何解释前咨询独立投资顾问。

本报告的版权归本公司所有。本公司对本报告保留一切权利。除非另有书面显示, 否则本报告中的所有材料的版权均属本公司。未经本公司事先书面授权, 本报告的任何部分均不得以任何方式制作任何形式的拷贝、复印件或复制品, 或再次分发给任何其他人, 或以任何侵犯本公司版权的其他方式使用。未经授权的转载, 本公司不承担任何转载责任。