

股票因子个性化：基于股票嵌入的因子优化

——“学海拾珠”系列之一百四十五

报告日期：2023-06-13

主要观点：

分析师：骆昱杉

执业证书号：S0010522110001

邮箱：luoyushan@hazq.com

分析师：严佳炜

执业证书号：S0010520070001

邮箱：yanjw@hazq.com

本篇是“学海拾珠”系列第一百四十五篇，本文提出了一种优化技术因子的通用框架。作者经过观察发现对于不同属性的股票，同一技术因子表现出不同的契合度，这对因子导向的选股和投资策略提出了挑战。为了解决这一问题，本文提出了一种利用股票自身性质对因子进行优化的通用框架。该框架首先根据基金经理集体投资行为形成的有价值的知识库生成股票嵌入特征，即股票 embedding，然后根据 embedding 为每只股票生成缩放系数对标准化后的因子进行二次缩放。实证表明，此种优化方法生成的优化因子可以产生比原始因子更强的投资指导。

相关报告

- 1.《动量、反转和基金经理过度自信——“学海拾珠”系列之一百四十四》
- 2.《模糊因子与资产配置——“学海拾珠”系列之一百四十三》
- 3.《chatGPT 交易策略 15 个月收益 500%+——“学海拾珠”系列之一百四十二》
- 4.《前景理论能否解释共同基金的成绩——“学海拾珠”系列之一百四十一》
- 5.《是否存在宏观公告溢价现象——“学海拾珠”系列之一百四十》
- 6.《利用深度神经网络改进时间序列动量策略——“学海拾珠”系列之一百三十九》
- 7.《基金的协偏度择时能力——“学海拾珠”系列之一百三十八》
- 8.《ETF 交易与分析师预测——“学海拾珠”系列之一百三十七》

● 因子对具有不同特性的股票的影响不同

传统方法根据股票量价等数据按某种特定映射生成技术因子，但事实表明，对于具有不同性质的股票，相同因子的解释可能有较大差异，然而却有可能在某种因子上取得相近数值，这会使技术分析结果与现实情况有较大偏差。因此有必要根据股票性质对因子进行相应的调整。

● 如何对股票属性进行有效表示

本文的目标是根据股票的自身性质对因子进行适当调整，因此首要问题是如何对股票的特性进行抽象化表示。这实际上是一个数据挖掘的过程，近年来“序列 embedding 化”是自然语言处理中一个重点问题，本文借鉴 Skip-Gram 算法学习股票的嵌入特征。

● 新型技术交易因子优化框架（TTIO 框架）

本研究提出了一种新的技术交易因子优化框架，结合股票嵌入技术进行因子优化。设计了一层缩放网络，使得股票的新因子是原始因子的缩放版本。在此基础上，提出了一个用于优化因子的缩放模型，该模型基于股票嵌入为每个因子生成缩放权重。考虑到投资的动态性，该研究还提出了滚动学习机制，根据时间变化调整模型参数。

● TTIO 框架在因子优化和投资策略中的表现优于传统方法

实证结果显示 TTIO 优化因子在 2014 年和 2016 年均显著优于 baseline。同时，通过因子驱动的投资策略的实验，可以看出无论是单一因子还是多因子投资策略，TTIO 模型在除 2015 年外的所有年份都能产生更多的累积收益。最后，实例研究中发现，不同的因子对不同的股票表现出不同的敏感性，而不是简单地给予类似的权重，这证明了 TTIO 模型的有效性。

● 风险提示

文献结论基于历史数据与海外文献进行总结；不构成任何投资建议。

正文目录

1 引言	4
2 研究背景	6
2.1 技术面分析	6
2.2 技术因子	6
2.3 构建基于因子的投资组合	7
2.4 因子有效性评价指标	7
3 股票嵌入特征	7
3.1 基金经理的历史投资组合	8
3.2 构造二分图	9
3.3 通过基金-股票二分图学习股票嵌入特征	9
4 技术交易因子优化模型	10
4.1 模型设计	10
4.2 用于因子优化的缩放模型	10
4.3 滚动学习机制	11
5 实验	11
5.1 实验设置	11
5.2 实验结果	12
6 相关研究	17
7 结论	17
风险提示:	18

图表目录

图表 1 两只特定股票的价格和 30 天内乖离率因子的时间序列数据	5
图表 2 一套普遍的技术因子及相应的计算公式	7
图表 3 基金经理历史投资组合的通用数据图	8
图表 4 滚动学习算法	11
图表 5 不同年份采用不同优化方法的因子的平均 RANK IC	13
图表 6 不同因子驱动的投资策略在不同年份产生的累计回报	14
图表 7 在 BIAS、MACD 和 ROC 上获得最大和最小原始缩放权重的前 5 只股票	15
图表 8 经过 T-SNE 降维的最大和最小缩放权重股票的 EMBEDDING	16


1 引言

技术面分析(Charles(2006), Christopher 等人(1997), Paul 等人(1997))作为量化投资的基本方法之一,侧重于从价格和成交量的角度解释和预测股票走势。技术面分析的核心假设在于,投资决策的所有相关信息都反映在价格和成交量的变化中。因此,价格和成交量数据构成了足够的信息,可以为各种任务做出各种决策,包括市场趋势预测、选股和投资组合管理。

在真正的量化投资中,技术面分析主要用于选择未来回报率较高的股票。特别是,为了应对金融市场的噪声和波动性,已有许多成果基于价格和成交量开发技术交易因子,用来提供可靠的交易信号(Chalothon 等人(2012), Abeyratna 和 David(2001), Massoud 等人(2012), Christopher 等人(2011)),这类似于机器学习方法中的特征工程。更具体地说,通用技术交易因子通常是基于对每只股票的原始价格和成交量数据的一致性数学变换而生成的。在现实世界中,人类专家根据他们在金融市场的领域知识总结了各种鲁棒的技术交易因子。作为特征工程中人工生成的特征,各种技术因子基本上代表了不同方面的价格和成交量,并从稳健和全面的角度评估了股票的走势。例如,平滑价格序列并丢弃一些随机性的移动平均因子,是描述趋势的好选择。乖离率表现了当前价格与其移动平均值的偏差,可以稳健地反映股价的现状。因此,技术因子作为所有股票价格和成交量的统一变换,在各种投资任务中发挥着至关重要的作用。

然而,这种统一的计算方法对选择未来利润更高的股票这一任务产生了一定的限制,因为它没有考虑股票的内在特性。事实上,我们观察到,具有不同性质的股票对因子的契合度并不相同。我们发现:即使两只股票在一个特定因子上表现出完全相同的值,由于股票本身的性质,它们也可能保持在本质上完全不同的状态。例如,图表 1 显示了两只特定股票的价格和 30 天内乖离率因子的时间序列数据。从这些数据中可以发现,对于周期性股票 1b,它随着更广泛的市场而变化,并且往往具有更大的波动性,乖离率很容易跳到极值;而对于另一只股票示例 1a,它是一只强大、稳定、成熟的股票,具有长期连续季度分红的历史,在大多数情况下,乖离率会被限制在一定的范围内。因此,即使两种股票都获得了相同的乖离率极值,其意义也完全不同。周期性股票将被视为处于正常状态,因此对它来说该因子几乎没有可供参考的作用。而对于价格稳定的股票,较大的乖离率值将提供丰富的信息,这对预测和投资都很有用。这一现象清楚地表明,一个技术因子对不同股票采取相同的计算方法不足以区分不同股票的未来回报趋势。

图表 1 两只特定股票的价格和 30 天内乖离率因子的时间序列数据



资料来源：《Individualized Indicator for All: Stock-wise Technical Indicator Optimization with Stock Embedding》，华安证券研究所

基于这一观察结果，本文认为挖掘股票的原始价格和成交量数据蕴含的信息对于生成更有力的因子是必要的。一个简单的方法是为每只股票创建一个缩放系数，然而，这很容易导致过拟合。进一步的观察表明，具有共同特征的股票对因子值具有相似的契合度。例如，蓝筹股公司的大多数股票，其股价通常在小范围内变化，在大多数情况下往往会产生低乖离率值。这样的观察启发我们基于股票的普遍性特征进行股票信息转换，以避免潜在的过拟合问题。因此，本文提出了一个技术交易因子优化（TTIO）模型，该模型通过基于股票性质的二次缩放来优化原始因子系数。

关键之处在于如何生成股票的有效表示，以反映经验丰富的投资者的知识和想法。例如，如图表 1 所示，有效表示应该能够区分稳定股票和周期性股票。一个简单的方法是从经验丰富的基金经理那里手动收集这些信息。然而，这种方法由于人类对股票的主观本能导致了对人力成本的高需求和不稳定的准确性，效率相当低。

为了解决上述问题，本文建议从一群经验丰富的基金经理的集体行为中学习股票表示，即股票 embedding。由于每个基金经理对各种特征的股票都有自己的偏好和专业化，例如，一些基金经理会更喜欢稳定的股票以获得低风险的利润，而另一些基金经理则可能更喜欢波动较大的股票以获取更大的回报。基于这一事实，本文假设同一基金的持仓股票可能具有一些共同的特征。因此，本文试图学习股票的嵌入表示，目的是保留股票之间的这种关系，即同一基金持有的股票将获得类似的 embedding。

在得到股票 embedding 后，设计一种有效的方法来利用这种表示优化技术交易因子至关重要。为此，本文提出了 TTIO 模型，该模型利用股票 embedding 的信息对原始技术因子进行优化，以最大限度地提高优化技术因子的有效性。此外，为了避免复杂建模可能导致的过拟合问题，本文仅用一个简单的单层神经网络来构建 TTIO 模型以优化原始技术因子。

根据经验，本文在真实数据上进行实验，通过检查其 IC 来评估因子。此外，我们还根据优化因子对股票投资进行了模拟。并且还利用优化因子来预测回报排序，并通过应用一些交易策略来评估其有效性。与传统因子相比，结果表明，近年来本文生成的优化因子表现明显更好、更稳定。

总之，本文工作的主要贡献包括：

- (1) 提出了一个因子优化模型，通过整合股票的不同属性来实现更好的因子表现。
- (2) 为了表示具有不同性质的股票，本文设计模型学习了基于基金经理集体行为的股票嵌入特征。
- (3) 对真实的股票数据进行了实验，并通过实际投资策略中使用的优化因子表现来评估本文因子优化方法的有效性。

2 研究背景

本节将对技术分析和一些技术交易因子进行基本介绍。在本节中，我们展示了如何将价格和成交量映射到技术交易因子，此外，我们还将描述如何使用此类交易因子来构建投资组合（选择股票），以及介绍评估因子有效性的评估指标。

2.1 技术面分析

一般来说，分析股票和做出投资决策有两种主要方法：基本面分析和技术面分析。基本面分析需要分析公司的财务报表以确定业务的公允价值，而技术分析则假设股票价格已经反映了所有公开信息，因此其侧重于统计分析。从形式上讲，技术分析是研究给定金融市场中过去和现在的价格走势如何用于确定其未来方向(Martin, 2002)。因此，价格和成交量数据包括了技术分析中进行预测的所有信息。

2.2 技术因子

为了在技术分析中根据相应的价格和成交量数据识别特定资产的交易模式，研究人员对股票价格或成交量设计了某种形式的数学计算，即技术交易因子，以预测市场趋势。

本文将研究那些公认的技术因子，这些因子是根据价格和收益的时间序列进行计算得到的。图表2展示了一组普遍的技术因子指标及其计算公式，其中在第*i*天， $P_{high}(i)$ 表示最高价， $P_{low}(i)$ 表示最低价， $P_{open}(i)$ 和 $P_{close}(i)$ 分别表示开盘和收盘价，它们的主要用途如下：

- 指数移动平均线(EMA)是一种衡量价格日常波动的指标，最近的数据会占据更大的权重。
- 指数平滑异同移动平均线(MACD)是通过两条指数移动平均线之间的差来计算的，其中一条线来自长周期(慢线)，另一条来自短周期(快线)。M和n的值通常为12和26。
- 基于K线(KL)的因子通常用于发现股票的趋势和波动。KL相关因子包括K上长度、K下长度和K长度。
- 与乖离率相关的因子衡量价格与简单移动平均线相比的偏差水平。
- ROC相关因子意味着与前几天相比的变化幅度
- 振幅相关指标量化了最近一段时间内的震荡特性。

图表 2 一套普遍的技术因子及相应的计算公式

Technical Indicator	Calculation Formula
$EMA_m(i)$	$EMA_m(i) = [P_{close}(i) - EMA_m(i-1)] \times \frac{2}{m+1} + EMA_m(i-1)$
$MACD(i)$	$EMA_m(i) - EMA_n(i)$
$KLength(i)$	$P_{close}(i) - P_{open}(i)$
$KUpperLength(i)$	$P_{high}(i) - \max(P_{open}(i), P_{close}(i))$
$KLowerLength(i)$	$\min(P_{close}(i), P_{open}(i)) - P_{low}(i)$
$Bias_m(i)$	$P_{close}(i) - \frac{1}{m} \sum_{j=0}^{m-1} P_{close}(i-j)$
$ROC_m(i)$	$(P_{close}(i) - P_{close}(i-m)) / P_{close}(i-m)$
$MeanAmplitude_m(i)$	$\frac{1}{m} \sum_{j=0}^{m-1} (P_{high}(i-j) - P_{low}(i-j)) / P_{close}(i-j)$

资料来源：《Individualized Indicator for All: Stock-wise Technical Indicator Optimization with Stock Embedding》，华安证券研究所

2.3 构建基于因子的投资组合

由于有效的技术交易因子可以用来推测市场的未来趋势，技术交易员通常依靠它们来构建投资组合，以实现最大化收益。一种简单但广泛使用的方法是选择因子值排名的前 k 只股票，在某个交易时间点形成投资组合。而且，交易员通常将投资平均分布在前 k 只股票上，以降低风险，以防股票因子值排名与股票在某一时刻的收益率不符。因此， k 是一个超参数，用于平衡投资组合的稳健性与利润。

另一种提高投资策略稳健性的方法是利用因子组合。由于不同的因子可以捕捉到涵盖股票不同属性的各种价格表现形式，包括趋势、动量和波动率，单个因子有其局限性，在某些情况下可能会失去其效力。另一方面，将多个因子结合在一起，通过避免单个因子的无效性来提高投资稳健性是非常有益的。因此，在应用一定的因子组合方法后，可以基于新的组合因子值来管理投资组合，并以相等的权重投资前 k 只股票。

2.4 因子有效性评价指标

在量化投资领域，信息系数（IC）通常被用作金融分析师预测能力的绩效指标和交易指标的有效性。最普遍的 IC 类型之一是 Rank IC，其计算公式为： $Rank\ IC(I, R, t) = \text{corr}(\text{order}_{t-1}^I, \text{order}_t^R)$ ，其中 I 表示因子值， R 表示收益率， order_{t-1}^I 表示 $t-1$ 时刻的因子排名， order_t^R 表示 t 时刻收益率的排名， corr 表示皮尔逊乘积矩系数(Jacob 等人(2009))，显然，IC 的范围将在 -1 和 1 之间。有些交易因子对投资组合管理有正面影响，有些可能有负面影响，但这两种情况都有助于构建投资组合。

如前所述，具有不同性质的股票对同一因子具有不同的契合度。受此启发，有必要根据股票性质进行调整，以完善现有的技术因子。本文首先提出了一种表示股票属性的股票 embedding 方法，然后展示了如何在提取的股票 embedding 基础上进行因子改进。

3 股票嵌入特征

本节旨在基于“具有相似特性的股票有相似表示”这一假设，获得反映股票性质的有效表示。一种简单的方法是专业人士人工标记。然而，由于其效率和鲁棒性较低的缺陷，这是非常不现实的。因此本文试图从数据挖掘的角度来解决这个问题。

题。具体而言，就是从市场上一群基金经理的历史投资组合中挖掘股票 embedding 作为股票特性的隐状态表示，因为这些数据包括一个有价值的知识库，其中包含基金和股票之间丰富的投资关系信息。


我们发现每个基金经理对各种股票都有自己的偏好和专长，如周期性/稳健型股票、高风险/低风险股票。因此，同一基金内的股票可能具有一些共同的特征。受这一观察结果的启发，本文提出建立一个**基金-股票关系图**，并采用随机游走方法来学习可能在随机游走中同时出现的股票节点的相似 embedding。

在下文中，本文将首先描述基金经理的历史投资组合数据。然后，提出一个二分图来表示基金和股票之间丰富的关系信息。基于现有的图嵌入方法(Cao 等热(2016), Aditya 等人(2016), Mathias 等人(2016), Bryan 等人(2014), Wang 等人(2016))，我们可以用构造的图获得股票表示，其中具有相似性质的股票将倾向于获得相似的嵌入。

3.1 基金经理的历史投资组合

如图表 3 所示，基金经理历史投资组合的真实数据通常被归纳为两种元素，即基金和股票，以及两者之间的投资关系。具体而言，基金 f_i 和股票 s_j 之间的线，即 $w(f_i, s_j)$ ，代表基金 f_i 对股票 s_j 的投资。此外，一只基金可以包含一系列不同股票，一只股票可以由不同基金持有。

图表 3 基金经理历史投资组合的通用数据图



资料来源：《Individualized Indicator for All: Stock-wise Technical Indicator Optimization with Stock Embedding》，华安证券研究所

事实上，这些历史投资组合数据可以使我们能够获得合理的股票特征 embedding。我们发现，每个基金经理对各种股票都有自己的偏好和专业知识。例如，一些经验丰富的基金经理可能更喜欢继续投资于价格序列相对稳定的股票。因此，这些股票更有可能产生类似的收益，因为它们往往由一组基金经理持有。这恰恰与假设相符合，即同一基金持有的股票可能共享一些共同特性。因此，模型能够学习同一基金持有的股票的相似 embedding。

请注意，反映投资偏好的股票性质可能会随着时间的推移而变化。然而，在本节中，我们将重点放在学习特定时间步长 t 的静态 embedding，在下一节中继续讨论如何解决股票特征的动态特性问题。

3.2 构造二分图

给定一个二分图 $G = (U, V, E)$ ，其顶点可分为两个不相交且独立的集合 U 和 V ，通过将 U 映射到基金集合，将 V 映射到股票集合，将 E 映射到基金对股票的具体持仓，将基金的历史投资组合数据表示为二分图是很自然的。这样构建的图使我们能够通过以其二分结构的形式考虑基金和股票之间的投资关系来学习节点（即股票）的 embedding。

3.3 通过基金-股票二分图学习股票嵌入特征

在基金-股票二分图的基础上，本文采用了一种基于 skip-gram 结构的方法来学习股票节点的 embedding，彼此靠近的节点倾向于获得相似的 embedding。具体而言，我们首先基于图中的转移概率生成股票节点随机游走序列，然后以最大化相邻节点概率为目标生成股票 embedding。

基金-股票二分图的随机游走。在随机游走中，从一个结点开始行走，每一步移动到基于边的权重随机选择的相邻节点，因此在由随机游走生成的每个节点序列中，彼此连接且靠近的节点将有更高的概率出现在一起。因此我们倾向于在基金-股票图上生成股票节点序列，其中由相同基金连接的股票有着相似的特征，将具有更高的概率一起出现在随机游走节点序列中。本文只关心股票的嵌入特征，因此不需要为基金生成 embedding，本文提出了一种两阶段随机游走方法，其中只有股票的节点被选择到序列中并进行优化以获得 embedding。

每次我们从一个股票节点开始，然后按照以下方式走到下一个节点。假设节点 v_k 表示随机游走序列中的第 k 个节点，则从股票节点 s_i 到基金节点 f_j 的概率计算公式如下：

$$P(v_k = f_j \mid v_{k-1} = s_i) = \begin{cases} \frac{w_{f_j, s_i}}{\sum_t w_{f_t, s_i}} & \text{if } (f_j, s_i) \in E \\ 0 & \text{otherwise} \end{cases}$$

相似的，从基金节点 f_j 到股票节点 $s_{i'}$ 的概率如下：

$$P(v_{k+1} = s_{i'} \mid v_k = f_j) = \begin{cases} \frac{w_{f_j, s_{i'}}}{\sum_t w_{f_j, s_t}} & \text{if } (f_j, s_{i'}) \in E \\ 0 & \text{otherwise} \end{cases}$$

这样，只需将基金节点作为连接股票节点的中间变量，就可以生成大量只包含股票节点的序列。

最大化相邻节点概率获得股票 embedding。从股票节点序列的生成可以看出，由相同基金连接的股票，基于前面提到的假设，它们是相似的股票，往往会一起出现在节点序列中。因此，我们建议为随机游动序列中彼此接近的节点获得相似的 embedding 表示。这个问题可以通过基于 Skip-Gram 的算法(Mikolov 等人(2013), Sutskever 等人(2013))来解决，该算法目的在于最大化相邻节点条件的概率，其表达式由 g 给出：

$$\max_g \sum_{u \in V} \log \Pr(N_s(u) \mid g(u))$$

其中 $N_s(u)$ 表示节点 u 的相邻节点。在此基础上，使用 Skip-Gram 结构，训练神经网络来预测每个节点实际出现在目标节点周围的概率。训练完成后，使用模型的隐状态作为股票的特征 embedding。

4 技术交易因子优化模型

在学习股票 embedding 的基础上，本文还提出了一个全新的技术交易因子优化框架。4.1 简要介绍获得股票 embedding 的神经网络模型，4.2 节提出我们独特的二次缩放模型，该模型在保持因子的原始特性的基础上，为具有相似特性的股票生成相似的缩放因子。最后，4.3 节介绍了本文的滚动学习机制，以解决市场的动态性带来的股票特性变化问题。

4.1 模型设计

给定一个有效的股票表示，如何生成一个新颖、更好的技术因子？本文采用了一种机器学习方法。我们不是用传统的方式生成由固定数学方程计算的新因子，而是用参数化模型，即神经网络，来表示优化的、据推测更有效的因子，并通过优化因子的性能 IC 来训练该模型。通过这种方式，优化因子就在股票 embedding 和原始技术因子的基础上生成了。

如上所述，我们希望对具有类似性质的股票实现类似的转换。此外，为了尽可能保持原始因子的性质，我们提出了一个一层缩放网络，新的因子只是一个缩放后的原始因子。通过这样的简单设计，可以确保模型具有相似嵌入的股票将具有相似的缩放系数，如果模型隐藏层数较多，那么高度非线性将不能保证这种特性。

4.2 用于因子优化的缩放模型

受上述设计原则和相应挑战的启发，本文提出了一个精心设计的因子优化缩放模型。该模型由两部分组成：一个缩放网络，用于基于股票 embedding 输入为每个因子生成缩放权重，另一个是最终优化器，用于将原始因子与缩放权重相乘来生成新因子。

缩放网络。本文的缩放网络将股票 embedding 作为输入，为每个因子生成股票缩放系数。更具体地说，该模型包含两个步骤：生成原始缩放权重和权重归一化。

本文提出了一个简单的神经网络来计算特定股票 i 相对于因子 j 的原始缩放系数，如(1)式所示，其中 g_i 代表股票 i 的 embedding 向量， w_j 代表隐藏层权重。这个映射的简单性使得为具有类似表示的股票生成类似的原始缩放系数变得容易。

$$r_{ij} = w_j^T g_i \quad (1)$$

得到原始缩放系数后，为了将该系数约束在合理的范围内，我们通过 softmax 算子进一步归一化所有股票的原始缩放权重，如(2)式所示。

$$\alpha_{ij} = \frac{\exp(r_{ij})}{\sum_k \exp(r_{kj})} \quad (2)$$

通过加权缩放优化因子。原始交易因子可能出现正值或负值，为了进行有效的优化，首先将原始因子值标准化到[0,1]的范围内，再将因子 I_{ij} 与其对应的缩放权重 α_{ij} 相乘即可得到优化后的因子 I'_{ij} 。

$$I'_{ij} = I_{ij} \cdot \alpha_{ij} \quad (3)$$

由于新的优化因子被期望有更好的表现，例如在 IC 方面，因此学习目标内设置为最大化相关性的度量值，因为 Rank-IC 不会生成反向传播的梯度。

$$\max |\text{corr}(I'_j, R)| \quad (4)$$

总之，上述设计原则在用于因子优化的缩放模型中得到了强调。首先，整个缩放机制的简单性使我们能够在不大幅改变其原始特性的情况下对原始因子进行适当调整。其次，单层缩放网络的简单性使得为具有相似属性的股票生成相似的缩放权

重变得容易得多。

4.3 滚动学习机制

为了适应投资的动态性质，我们提出了一种滚动学习机制来随着时间的推移调整模型的参数。旋转学习属于在线学习 (Bottou, 1998)，是一种机器学习算法，其中数据按序列顺序传入，并用于在每一步更新未来数据的预测器，而 batch 学习技术通过一次学习整个训练数据集来生成最佳预测器。

在滚动学习中，需要确定学习股票 embedding T_{embed} 和学习、测试技术交易因子优化模型 T_{TTIO} 的确切时间。 T_{embed} 应该选择足够长的时间，以有效地代表股票的性质。考虑到价格序列的高波动性和优化模型的有效期， T_{TTIO} 的选择既不应太短也不应太长。 T_{TTIO} 由训练、验证和测试过程组成： $T_{TTIO} = T_{train} + T_{vali} + T_{test}$ ，其中 T_{test} 决定滚动的时间跨度。本文为每个滚动步骤训练一个模型，算法如图表 4 所示。本文还通过简单地聚合时间段 T_{embed} 中每个图的权重，使我们的股票嵌入模型适应于在时间段 T_{embed} 上学习，而不是在某个时间步长上学习。

图表 4 滚动学习算法

Algorithm 1 Rotation Learning

```

1: procedure ROTATION(Embedding time period  $T_{embed}$ , Learning and test time period for TTIO model  $T_{TTIO}$ , Rotation time span  $t_0 = T_{test}$ . Indicator sequence  $\{I_t\}$ , Walk Length  $l$ , Walks per node  $c$ , Start time  $t_1$ , End time  $t_2$ )
2:    $t = t_1$ 
3:    $ListNewI = []$ 
4:   while  $t < t_2$  do
5:      $G = \text{Construct Bipartite Graph from } t - T_{embed} \text{ to } t$ 
6:      $H = \text{Stock2vec}(G, l, c)$ 
7:      $NewI = TTIOModel(H, I_t)$ 
8:     add  $NewI$  to  $ListNewI$ 
9:      $t = t + t_0$ 
10:  return  $ListNewI$ 
    
```

资料来源：《Individualized Indicator for All: Stock-wise Technical Indicator Optimization with Stock Embedding》，华安证券研究所

5 实验

本节通过大量的实验来证明本文所提出方法的有效性。5.1 中介绍了相关实验设置。之后本文将因子优化模型应用于 A 股市场，结果如 5.2 所示。信息系数(IC)用于评估优化因子的性能。本文将模型与四个基线进行比较，以证明方法的实用性。此外，本文还通过一些简单的交易策略和几个案例研究进一步证明了本文提出的框架的有效性。

5.1 实验设置

数据集。本文收集了 2013 年至 2016 年 2000 多只中国股票的每日价格和 7 类交易因子作为因子增强模型的数据集，这些指标涵盖了中国市场的大多数股票。图表 2 介绍了大多数重要因子。

对于股票 embedding 提取模型，为了有效反应股票的性质，本文收集了 2003

年至 2016 年基金经理的持仓。对所有 A 股进行评估，以测试有关实际累积收益的交易政策。

参数设置。关于股票 embedding，对每个股票生成长度 $l=200$ 的 $c=100$ 个随机游走。对于 Skip-Gram 架构，滑动窗口大小设置为 3。最终股票的表示维度为 $d=32$ 。对于因子优化模型，每一个学习过程的数据集都分为训练集(6 个月)、验证集(3 个月)和测试集(3 个月)。本文不使用 K 折交叉验证，因为我们只关注模型的未來影响。

对比方法。为了评估本文方法的性能，此处设置了 4 个 baseline:

- **Raw** 是根据股票价格或成交量的数学计算生成的原始因子。
- **Norm** 直接对原始技术因子进行标准归一化的简单缩放，与这种方法的对比能够体现本文设计的缩放方法的作用。
- **NoEmb** 直接学习如何通过模型重新缩放技术因子，而不需要像股票 embedding 这样的股票属性的任何信息。我们没有通过股票 embedding 来计算比例系数，而是将其设置为通过反向传播优化的变量。与这种方法相比，我们将能够证明通过股票 embedding 聚合信息的有效性。
- **Complex** 将原始因子的输入和股票 embedding 的输入连接起来，然后将其馈送到两层神经网络，以直接从网络的输出生成新的因子。这种方法旨在显示复杂网络上是否会出现一些过拟合问题。


评估指标。本文使用 Rank IC 来评估优化因子的有效性。为了进一步检验优化因子是否能提高投资回报，我们进行了因子驱动的测试。注意，开发交易策略有很多选择，如时间序列算法和各种机器学习技术，这超出了本文的范围。在这项工作中，我们基于 2.3 节中描述的投资组合构建方法，利用单因子交易策略，并通过回溯计算每个因子的累计和平均收益率。对于因子组合交易策略的任务，我们简单地使用随机森林回归(Liaw 等人, 2002)来预测收益率的排名，并根据预测值投资前 k 只股票。

5.2 实验结果

优化因子的有效性。我们首先进行实验，检查本文的因子优化框架在各种技术因子上的性能。使用 TTIO 框架为 7 类原始因子生成优化因子，并计算优化因子和 baseline 的 Rank IC。图表 5 比较了优化因子和上一节中提到的其他比较方法之间的汇总 Rank IC。从这些数据中，我们可以发现，在 2014 年和 2016 年，优化因子都显著优于 baseline。具体来说，从方法 Norm 的结果可以看出，简单地进行归一化对优化原始因子没有任何意义，甚至反映出与收益率几乎不相关。类似的结果也出现在 Complex 方法中。该复合网络试图将技术因子和股票 embedding 的信息与多层神经网络相结合，并一对一地生成新的因子，而不是基于原始因子进行缩放。这种方法导致了过拟合问题，具体表现为较低的 IC 值。NoEmb 获得了比前两个 baseline 更高的结果。然而，由于缺乏股票 embedding 产生的信息，与本文所提出的模型相比仍有明显的差距，这表明了 TTIO 框架的有效性。

图表 5 还显示，2015 年的表现与 2014 年和 2016 年的表现大不相同，回顾 2015 年的股市，我们观察到股市崩盘中剧烈动荡的价格模式，这导致大多数因子组的 Rank IC 严重降级。

图表 5 不同年份采用不同优化方法的因子的平均 Rank IC




资料来源：《Individualized Indicator for All: Stock-wise Technical Indicator Optimization with Stock Embedding》，华安证券研究所


因子驱动投资的表现。为了进一步研究 TTIO 框架的价值，本文进一步进行了实验，以检验优化的因子是否能提高因子驱动投资的收益率。如 2.3 节所述，有两种基本的因子驱动的交易策略。一种是在一组因子上平均投资根据单个因子的价值排名前 k 的股票，另一种是投资因子组合模型中排名前 k 的股票，此模型即本文中的随机森林模型。在实验中，为了为 k 设置最合适的值，本文先在验证集上找到了最优 k 值，然后将具有确定 k 值的投资策略应用于测试集。图表 6 报告了不同因子驱动的投资策略产生的累积收益。投资策略的测试包括结合多个因子的交易规则，和只考虑了四个 baseline 的单一因子和 TTIO 模型的交易规则。

从这些图中，首先可以看到，2015 年对应的 IC 结果，与 2014 年和 2016 年相比，交易结果出现了异常。除 2015 年之外，无论是单一因子交易模式还是多因子交易模式，Norm 方法都获得了相对较差的结果，但在 2015 年突然跳到了最佳状态。一般来说，多因子相结合的投资比只考虑单因子的投资要好。在 2014 年和 2016 年，结果与因子表现结果一致，这也证明了 IC 评估的有效性。与其他情况相比，Norm 和 Complex 方法获得的结果最差。2014 年，TTIO 仅考虑单因子的投资甚至超过了 Norm 和 Complex 多因子结合的投资。根据投资结果，除 2015 年外，我们可以发现，无论是单因子驱动的交易策略还是因子组合驱动的策略，我们的模型在所有其他情况下都能产生更多的累积收益。


图表 6 不同因子驱动的投资策略在不同年份产生的累计回报



(a) 2016



(b) 2015



(c) 2014

资料来源：《Individualized Indicator for All: Stock-wise Technical Indicator Optimization with Stock Embedding》，华安证券研究所


实例研究。在这个实验中，我们选择了一些有代表性的因子，并展示了这些因子是如何在不同的股票上重新缩放的。更具体地说，我们选择 Bias、MACD 和 ROC 作为示例因子，并显示了 TTIO 模型中获得最大和最小原始缩放权重的 5 只股票。结果如图表 7 所示。从表中我们可以看出，不同的因子对不同的股票表现出不同的敏感性，而不是简单地给予类似的权重。为了显示相似属性股票的密切关系，我们首先利用 t-SNE(Maaten 和 Hinton, 2008)将优化后的股票 embedding 降维到二维。在将前 100 只强化股票和前 100 只弱化股票的股票 embedding 绘制到二维图中后，我们分别为这两组赋予两种不同的颜色。图表 8 显示了关于这三个代表性因子的两组独立数据。从这些图中可以看到，我们的模型能够为具有类似表示/属性的股票分配类似的缩放权重，这与我们的设计原则非常一致。

图表 7 在 Bias、MACD 和 ROC 上获得最大和最小原始缩放权重的前 5 只股票


	Bias		MACD		ROC	
	sector	code	sector	code	sector	code
max	Public Utility	600868	Mechanic Engineering	600165	Bank	601288
	Car	600653	Coal	601015	Nonferrous Metal	601069
	Real Estate	600747	Building materials	600753	Nonferrous Metal	600362
	Electrical Power	601558	Transportation	600751	Bank	601818
	Telecommunication	600680	Real Estate	600733	Petrochemical	601857
min	Media	000892	Computer	300379	Building materials	300374
	Electronic Component	300390	Computer	300369	Car	002725
	Electronic Component	300053	Telecommunication	300250	Electronic Component	000020
	Mechanic Engineering	603111	Computer	603019	Telecommunication	300211
	Medicine	300109	Computer	300448	Electrical Power	000585

资料来源：《Individualized Indicator for All: Stock-wise Technical Indicator Optimization with Stock Embedding》，华安证券研究所


图表 8 经过 t-SNE 降维的最大和最小缩放权重股票的 embedding



(a) Bias



(b) MACD



(c) ROC

资料来源：《Individualized Indicator for All: Stock-wise Technical Indicator Optimization with Stock Embedding》，华安证券研究所

6 相关研究

技术因子是技术分析的基本工具。以往关于因子优化的工作大致可以分为两类：手动改进因子和深度学习因子。几十年前，经验丰富的投资者和经济学家就提出了手动改进因子(Gertler 等人(1986), Alejandro 等人(2011), Thaler(2005), Zhu 和 Zhou(2009))。Gunasekarage 等人(2001)使用四个新兴南亚资本市场的指数数据分析了简单移动平均(SMA)指标的表现，并证明了其产生超额收益的预测能力。Chong 和 Ng(2008)提出，在大多数情况下，相对强弱指数(RSI)和平滑异同移动平均线(MACD)可以产生高于 buy-and-hold 策略的回报。Gatev 等人(Gatev, 2006)不局限于单只股票的因子，而是测试了一种关于价格距离和相关性的对冲基金股票交易策略，实验表明，在对交易成本进行保守估计情况下交易恰当的成对股票能够获得利润。

随着深度学习的发展，越来越多的研究致力于通过端到端表征学习进行因子优化(Kumar 等人(2004), Patel 等人(2015), Qin 等人(2013), Sharang(2015))。这些方法以原始价格甚至手动改进的因子作为输入，并通过深度神经网络学习做出交易决策和未来预测。深度神经网络中的隐状态表示可以被视为学习因子。Takeuchi 等人(2013)简单地提取有用的特征，而不需要进行广泛的特征工程，只考虑每个股票在特定时间段内的价格和累积收益，该项研究是深度学习在股票交易中的首次应用之一。也有一些研究人员直接利用价格和收益作为输入特征，之后通过直接使用价格和成交量相关的特征，应用各种机器学习算法来实现一些预测任务(Cavalcante 等人(2016), However(2014), Ticknor(2013))。此外，Deng 等人(2017)通过将价格差输入深度强化学习模型，将当代深度学习算法引入金融信号处理和在线交易。

与现有的专注于手动改进因子或深度学习方法来创建新因子的努力不同，本文提出通过考虑股票性质来优化股票选择的技术因子。本文引入外部数据来学习股票嵌入特征，并进一步学习基于股票 embedding 的缩放因子。目前来看，本文是第一项通过利用外部数据中的知识来学习和改进技术因子的研究。

7 结论

本文提出了一个通用的、可解释的因子优化框架，利用从外部资源中挖掘的隐藏知识来优化技术因子。本文从一种新思路出发，通过从经验丰富的投资者的集体行为中挖掘股票潜在信息，利用因子的股票契合度方面的差异，采用数据挖掘的方法来学习股票嵌入特征。然后，本文提出了一个精心设计的缩放网络，该模型能够在保留因子的原始属性基础上，为具有相似嵌入特征的股票分配相似的缩放权重。然而，通过本文的模型生成的因子并没有体现出股票的动态特性，因此我们只是用粗略的滚动学习方法使其适应现实金融市场。因此，未来的工作重点应放在动态优化技术因子方面。

文献来源：

核心内容摘选自 Zhige Li、Derek Yang 和 Li Zhao 等人发表于 KDD2019 的文章《Individualized Indicator for All: Stock-wise Technical Indicator Optimization with Stock Embedding》

风险提示:

文献结论基于历史数据与海外文献进行总结；不构成任何投资建议。

重要声明

分析师声明

本报告署名分析师具有 PRC 证券业协会授予的证券投资咨询执业资格，以勤勉的执业态度、专业审慎的研究方法，使用合法合规的信息，独立、客观地出具本报告，本报告所采用的数据和信息均来自市场公开信息，本人对这些信息的准确性或完整性不做任何保证，也不保证所包含的信息和建议不会发生任何变更。报告中的信息和意见仅供参考。本人过去不曾与、现在不与、未来也将不会因本报告中的具体推荐意见或观点而直接或间接接收任何形式的补偿，分析结论不受任何第三方的授意或影响，特此声明。

免责声明

华安证券股份有限公司经 PRC 证券监督管理委员会批准，已具备证券投资咨询业务资格。本报告中的信息均来源于合规途径，华安证券研究所力求准确、可靠，但对这些信息的准确性及完整性均不做任何保证。在任何情况下，本报告中的信息或表述的意见均不构成对任何人的投资建议。在任何情况下，本公司、本公司员工或者关联机构不承诺投资者一定获利，不与投资者分享投资回报，也不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任。投资者务必注意，其据此做出的任何投资决策与本公司、本公司员工或者关联机构无关。华安证券及其所属关联机构可能会持股报告中提到的公司所发行的证券并进行交易，还可能为这些公司提供投资银行服务或其他服务。

本报告仅向特定客户传送，未经华安证券研究所书面授权，本研究报告的任何部分均不得以任何方式制作任何形式的拷贝、复印件或复制品，或再次分发给任何其他人，或以任何侵犯本公司版权的其他方式使用。如欲引用或转载文献内容，务必联络华安证券研究所并获得许可，并需注明出处为华安证券研究所，且不得对文献进行有悖原意的引用和删改。如未经本公司授权，私自转载或者转发本报告，所引起的一切后果及法律责任由私自转载或转发者承担。本公司并保留追究其法律责任的权利。

投资评级说明

以本报告发布之日起 6 个月内，证券（或行业指数）相对于同期沪深 300 指数的涨回撤为标准，定义如下：

行业评级体系

- 增持—未来 6 个月的投资回报领先沪深 300 指数 5%以上；
- 中性—未来 6 个月的投资回报与沪深 300 指数的变动幅度相差-5%至 5%；
- 减持—未来 6 个月的投资回报落后沪深 300 指数 5%以上；

公司评级体系

- 买入—未来 6-12 个月的投资回报领先市场基准指数 15%以上；
- 增持—未来 6-12 个月的投资回报领先市场基准指数 5%至 15%；
- 中性—未来 6-12 个月的投资回报与市场基准指数的变动幅度相差-5%至 5%；
- 减持—未来 6-12 个月的投资回报落后市场基准指数 5%至；
- 卖出—未来 6-12 个月的投资回报落后市场基准指数 15%以上；
- 无评级—因无法获取必要的资料，或者公司面临无法预见结果的重大不确定性事件，或者其他原因，致使无法给出明确的投资评级。市场基准指数为沪深 300 指数。