

2018.11.14

基于 PLS 方法的潜变量因子研究

	陈奥林 (分析师)	殷钦怡 (研究助理)
	021-38674835	021-38675855
	chenaolin@gtjas.com	yinqinyi@gtjas.com
证书编号	S0880516100001	S0880117060109

本报告导读:

本篇报告基于统计中的 PLS 算法并应用潜变量的思想提出了一种因子降维的方法,以提高降维后的主成分对个股下期收益的预测能力,实证结果显示该算法在 A 股中具有较强的选股能力。

摘要:

- 为了能够更好的提高策略的灵活性,降低量化组合中股票只数的限制,本文采用**偏最小二乘法 PLS**,其可以能够摆脱组合层面的束缚,在单只股票上达到因子降维的目的。
- 从算法来看,PLS 算法相较于传统的主成分分析法在选股结果的单调性以及稳定性都有明显的提升,因为 PLS 相比 PCA 更重在主元对被解释变量的解释力度。
- 在 PLS 降维的框架下,我们需要应用“潜变量”的思想,潜变量即一种无法被直接观察到,但是对系统的状态和能观察到的输出都存在显著影响的变量。在实际应用中,为了对个股下期收益率进行预测,我们将个股在因子上的暴露记为显性变量,将因子共同影响下形成的个股预期收益率记为对应的潜变量。
- 我们运用 PLS 算法从包含技术面信息与基本面信息的 26 个特征值中提取的潜变量用于全市场(除银行)选股,潜变量最高的前 20% 的股票稳定跑赢潜变量最低的后 20% 的股票,且夏普比率得到显著提升
- 策略构建:我们构建了按照中证 500 行业权重的行业中性策略,年化超额可达 9.89%,夏普比率可达 1.24,2018 年年化超额收益率为 4.20%
- PLS 算法本身不限制潜变量的个数,而在本篇报告中,我们只是使用了基础的单潜变量算法,即假设每一期股票只受到一个隐含的内在驱动力的影响,这是一个较强的前提假设。后续我们考虑将这个限制放宽,即拓展至一维以上的潜变量空间,以期得到更进一步的选股效果。

金融工程团队:

陈奥林: (分析师)

电话: 021-38674835

邮箱: chenaolin@gtjas.com

证书编号: S0880516100001

李辰: (分析师)

电话: 021-38677309

邮箱: lichen@gtjas.com

证书编号: S0880516050003

孟繁雪: (分析师)

电话: 021-38675860

邮箱: mengfanxue@gtjas.com

证书编号: S0880517040005

蔡昱昊: (研究助理)

电话: 021-38674743

邮箱: caiminhao@gtjas.com

证书编号: S0880117030051

李翔: (研究助理)

电话: 021-38032690

邮箱: lixu019018@gtjas.com

证书编号: S0880117090067

杨能: (研究助理)

电话: 021-38032685

邮箱: yangneng@gtjas.com

证书编号: S0880117080176

殷钦怡: (研究助理)

电话: 021-38675855

邮箱: yinqinyi@gtjas.com

证书编号: S0880117060109

余剑峰: (研究助理)

电话: 021-38676186

邮箱: yujianfeng@gtjas.com

证书编号: S0880118060039

黄皖璇: (研究助理)

电话: 021-38677799

邮箱: huangwangxuan@gtjas.com

证书编号: S0880116100008

相关报告

《基于 PLS 方法的潜变量因子研究》
2018.11.13

《基于风险供求模糊匹配的择时策略》
2018.11.10

《上市公司业绩变脸中的业绩预告之谜》
2018.10.22

《基于日内交易特征的选股策略》2018.10.18

《基于宏观状态的风险预算和资产配置》
2018.09.15

目录

1. 引言	3
2. 潜变量因子投资框架下 PLS 具有强适用性	3
2.1. 潜变量介绍	3
3. 偏最小二乘回归 (PLS) 方法介绍	5
3.1. PLS 相较于 PCA 更侧重于自变量的解释力度	5
4. PLS 方法在潜变量估计上的应用	6
4.1. 建模方法介绍	6
4.2. 入选特征因子描述及预处理	7
5. PLS 方法在 A 股的有效性检验	8
5.1. PLS 在全 A 市场 (除银行) 的区分度检验	8
6. 策略构建	9
7. 后续研究展望	10

1. 引言

在本篇研究报告中，我们创新性地提出了一种区别于传统的多因子研究的、建立在新的统计算法 PLS 上的因子组合构建思路。在本篇报告中，我们通过类似“映射”的思想实现了从高维度的因子空间向低维度的特征空间降维的作用，降维后的特征空间我们将其视为一维的潜变量，用于预测个股下期收益。

此外，该算法相较于主流的降维方法如主成分分析法 (PCA) 在金融建模领域有更强的适用性，因为其相较于 PCA 更加注重于模型对个股下期收益的预测性。在后续的实证检验中，我们发现 PLS 算法相较于 PCA 在股票未来收益上的确具有更强的区分度与更好的单调性。

最后我们基于降维后的一维潜变量构建的行业中性选股策略年化超中证 500 可达 9.36%，夏普比率可达 1.2。

2. 潜变量因子投资框架下 PLS 具有强适用性

2.1. 潜变量介绍

首先我们需要明确的一个问题便是：什么是潜变量？根据潜变量的广义定义，**潜变量(latent variable)**是一种无法直接被观测到，但是对系统的状态和能观察到的输出存在影响的一种变量。潜变量是结构方程模型中两个重要的变量之一，与之对应的是**显性变量(manifest variable)**。在 20 世纪初期，Pearson 和 Spearman 在心理测验中前瞻性地提出了“潜变量”的概念，并将潜变量定义为若干个显性变量、即可观测指标中隐含的“共同结构”。社会学研究中常常需要用到“潜变量”的思想，例如我们经常可以在社会学报告中见到“贫富差距”这个词，这是一个基础性的概念，但是我们无法直接进行测度，因此社会学家往往使用 Gini 系数、Theil 系数、最贫 5% 民众收入百分比等指标进行刻画，并以这些观测指标的平均值来推算潜变量的水平。

在因子投资中，投资者通过观测标的在多个预选出的个股以及市场特征值上的暴露来形成对标的未来收益率的一个预测。而在潜变量因子投资的框架中，这些特征因子的存在是为了更好地对潜变量进行刻画，因为潜变量本身是难以被显性地观察到的，我们能直观观察到的只有特征因子。这也正如统计学家 B.S Everitt 在《An Introduction to Latent Variable Models》一书中介绍的那样，“although latent variables are not observable, certain of their effects on manifest variables are observable, and hence subject to study”。

若用数学公式来表达潜变量的思想，则个股的预期收益率可以被拆解成如下的形式：

$$R_{i,t+1} = E[R_{i,t+1}|F_t] + \varepsilon_{i,t+1},$$

$$= \mu_{i,t} + \varepsilon_{i,t+1}, \mu_{i,t} \text{ 即为潜变量}$$

其中 filtration F_t 表示所有在 t 时刻已知的信息。 $\varepsilon_{i,t+1}$ 代表个股特质收益，

独立于信息流 F_t 中所有的变量且 $E[\varepsilon_{i,t+1}|F_t] = 0$ 。

投资者显然无法知晓信息流 F_t 中的所有信息，通常便只能靠观测特征值

$X_{it}^a, a = 1, \dots, A, s. t. X_{it}^a \subset F_t$ 来形成对预期收益率的认知，因为在定义中潜变量是唯一能够对个股下期实际收益率产生影响的变量，而个股在其余因子（特征值）上的暴露都是现实世界中对潜变量的刻画，其最终目的是为了能够有效通过这些特征值上的暴露来提取个股该期对应的潜变量，即个股下期的预期收益率，若使用数学公式表示则为：


$$X_{it}^a = \delta_t^a * \mu_{i,t} + u_{it}^a$$

δ_t^a 代表从各特征因子 X 到潜变量 μ 的映射系数潜变量。

以下我们用流程图来简要叙述潜变量因子投资与传统的多因子投资之间的区别，传统的多因子投资为：



而在潜变量因子投资下，整体的框架为：




可以看到在传统的多因子框架下，整体的流程大致为先外推再汇总的过程，即需要在组合层面进行汇总；而隐变脸因子投资的顺序与其相反，即先对已有信息进行汇总，降维成潜变量后再外推，即在个股层面进行汇总，从而潜因子投资相对多因子投资一个较为明显的优势是不对个股的数量有要求，策略在实施的时候可以根据个股数量进行灵活运用

3. 偏最小二乘回归 (PLS) 方法介绍

在上一小节中，我们已经对潜变量投资进行了具体的介绍，接下来的问题便是如何才能从浩如烟海的特征值中有效地提取出对个股下期收益有预测能力的潜变量是我们本篇研究的重点。在此我们引进一个新兴的统计算法偏最小二乘回归(Partial Least Squares,即 PLS 方法)。该统计手法最早由统计学家 Wold 于 60 年代提出，原先大量的应用在心理学、化学的相关领域上，是一种多因变量对多自变量的建模方法。

偏最小二乘方法是由最小二乘法(Least Squares)演变而来，王桂增、叶昊在《主元分析与偏最小二乘法》一书中介绍到，PLS 方法在最小二乘法的基础上综合考虑如何最大限度地自变量空间的数据变化信息和自变量对应变量的解释作用，将具有线性相关的数据从高维空间投影到低维特征空间，得到正交的特征向量，再建立特征向量间的线性回归关系。



从上图不难看出，PLS 本质上仍然是一个对特征向量降维和去噪的过程，而之前更为广泛使用的降维方法是主成分分析方法 (Principal Component Analysis, 简称 PCA)，因此接下来我们将介绍 PLS 方法相对于 PCA 方法的优点所在。

3.1. PLS 相较于 PCA 更侧重于自变量的解释力度

主元分析方法早在 1901 年就已经由 Pearson 提出，其基本思想是先对特征变量进行主元分析，提取自变量之间相互正交的主元之后再进一步分析。但在上述步骤中，主元的提取以最大限度地概括自变量空间数据的变化信息为准则，而不考虑主元对于因变量是否有解释作用，因而未被选取的次要主元有可能包含对回归有益的信息，而已被选取的主元也有可能包含对于回归无益的噪声。

而在 PLS 的实际应用中，低维特征向量 X 的选取有两个必要的条件：

1. X 与 Y 尽可能多的携带各自数据表中的信息；
2. X 与 Y 尽可能相关

因而 PLS 方法保证了 X 与 Y 最大限度地代表各自的数据集，并且 X 对 Y 有最强的解释能力，因此 PLS 方法对潜变量的提取有极强的适用性。


表 1 PLS 相较于 PCA 的优势简述

PLS 相较于 PCA	PCA 着重于对自变量做降维分析 PLS 在降维分析的基础上着重于降维后的自变量需要对因变量有最大的预测性。
-------------	---

数据来源：国泰君安证券研究

为了后续更好的比较 PLS 方法相较于 PCA 的优势，我们对之后所使用的同样的特征因子：即涵盖技术面大类（股价、成交量、波动率）与基本面大类（盈利能力、短期偿债、长期清偿、营运能力、成长能力、现金流情况）两大类共九小类因子做了 PCA 的处理，经过 PCA 处理后在股票池中的选股结果如下图所示：

图 1 相同因子经 PCA 处理后选股结果



数据来源：国泰君安证券研究、Wind

可以看到简单的运用 PCA 处理后整体的区分度与单调性均较差，5 组基本上不存在显著的累计净值走势上的差别。因而单纯的使用主成分分析法 PCA 进行因子的降维和去噪而不考虑降维之后的变量与个股下期收益之间的联系，是没有意义的，在实际投资中显然并不适用，从模型的逻辑上出发，PLS 才是一个更好的选择。

4. PLS 方法在潜变量估计上的应用

4.1. 建模方法介绍

依据 PLS 的建模方法，我们运用两步回归来产生 t 时刻对潜变量 $\mu_{i,t}$ 的估计。

第一步：

针对每一个特征值因子 X_{it}^a ，将 t 期的个股收益率对 $t-1$ 期的因子暴露做回归，即

$$R_{it,i=1,\dots,N} = \lambda_t^a * X_{i,t-1}^a, a = 1, \dots, A$$

值得注意的是，实证检验中我们发现回归系数 λ_t^a 的月频变动较大，为了进一步提高模型稳健性，我们采取移动平均的处理方法，时间窗口为过去 5 个月。

第二步：

上一步回归后每个特征值因子都对应一个回归系数 λ_t^a ，将所有的

$\lambda_t^a, a = 1, 2, \dots, A$ 组成向量 λ_t ，与此同时将 t 时刻个股 i 的特征值因子暴露

组成向量 $X_{i,t}$ ，将 $X_{i,t}$ 对 λ_t 回归

$$X_{i,t} = \widehat{\mu}_{i,t} * \lambda_{i,t}$$

回归系数即为潜变量 $\mu_{i,t}$ ，即个股的 $t+1$ 期的预期收益率。

鉴于潜变量 $\mu_{i,t}$ 的实际定义，自然我们可以将其作为一个选股的单项指标，记为 AFER。

4.2. 入选特征因子描述及预处理

对于入选的特征因子，我们希望它们能够从多个维度对个股进行全方位的描述，因此我们考虑同时纳入技术面类因子与基本面类因子。

表 2 总因子池概览

技术面类	股价类	一个月反转
		三个月动量
		六个月动量
	成交量类	前一个月换手率
		前三个月换手率
	波动率	异质波动率
基本面类	盈利能力	净资产收益率 ROE
		资产回报率 ROA
		毛利率
		净利率
	短期偿债	流动比率
		速动比率
		现金比率
	长期清偿能力	负债比率
		产权比率
	营运能力	存货周转率
		应收账款周转率
		总资产周转率
		固定资产周转率
	成长能力	销售收入同比增长
		净利润同比增长
		总资产同比增长
	现金流情况	固定资产占比
		单位销售现金净流入
		债务保障率

数据来源：国泰君安证券研究

值得注意的是，基本面因子由于需要使用销售收入这一项数据，而

银行业的所有上市公司的财务报表里面均是没有该会计项的，因而我们的总股票池中是不含有所有银行业的上市公司的。

在运用 PLS 方法时，针对因子的预处理十分简单，先以行业中位数填充基本面因子中的缺失值后，我们只需先在 3 倍标准差处做截尾处理，即

$$X_a = \mu_a + 3\sigma_a, \text{ if } X_a > \mu_a + 3\sigma_a$$

$$X_a = \mu_a - 3\sigma_a, \text{ if } X_a < \mu_a - 3\sigma_a$$

截尾之后再标准化，即：

$$X_{a_final} = \frac{X_a - \mu_a}{\sigma_a}$$


即可，也就是保证因子的去中心化。

5. PLS 方法在 A 股的有效性检验

5.1. PLS 在全 A 市场（除银行）的区分度检验

接下来我们对 PLS 方法究竟是否适用在 A 股市场进行检验，检验的依据为经过 PLS 方法处理后从特征因子中提取出的 AFER 值本身作为一个选股指标是否对全市场股票（除银行）的表现具有稳定的区分度，尤其是相比 PCA 是否有明显提升。


图 2 PLS 算法在 A 股市场的区分度检验



数据来源：国泰君安证券研究、Wind

与此同时让我们再回顾一下相同的特征因子（参见 4.2，即涵盖技术面大类（股价、成交量、波动率）与基本面大类（盈利能力、短期偿债、长期清偿、营运能力、成长能力、现金流情况）两大类共九小类因子）经 PCA 处理后的选股效果：

图 3 相同因子经 PCA 处理后选股结果



数据来源：国泰君安证券研究、Wind

可以看到 PLS 方法相较于 PCA 在区分度、单调性、稳定度上均有明显的提升。

表 3 PLS 算法与 PCA 算法比较

组别	年化收益率 (PLS)	夏普比率 (PLS)	年化收益率 (PCA)	夏普比率 (PCA)
Group1	11.71%	0.34	15.86%	0.48
Group2	14.75%	0.44	14.11%	0.43
Group3	13.33%	0.39	14.36%	0.41
Group4	13.74%	0.41	14.17%	0.43
Group5	16.95%	0.49	14.25%	0.43

数据来源：国泰君安证券研究

6. 策略构建

选股池：全 A（除 ST、除上市不足 6 个月的次新股）


调仓频率：月频换仓、每月第一天调仓

手续费：双边千三

对比指数：中证 500

组合构建方法：行业权重与中证 500 的行业权重保持一致，行业内部等权配置 AFER top5。另外，鉴于该策略本身无法调入银行股，在银行股的配置上则直接按照对比指数的银行占比配置银行指数。

图 4 中证 500 行业权重策略净值



数据来源：国泰君安证券研究、Wind

表 4 策略分年度表现

年份	年化超额收益	夏普比率	年中最大回撤
2009	0.98%	-0.05	-8.03%
2010	0.71%	-0.36	-11.89%
2011	5.05%	2.02	-3.68%
2012	-1.00%	-1.37	-11.14%
2013	19.13%	1.74	-9.56%
2014	18.55%	2.87	-8.3%
2015	30.07%	0.93	-21.54%
2016	9.1%	0.67	-10.82%
2017	-2.05%	-0.21	-7.88%
2018	4.2% (年化)	2.05	-6.11%

数据来源：国泰君安证券研究

可以看到利用 PLS 算法对因子降维后提取出的潜变量 AFER 在全市场选股上有显著的效果，且在回测的时间段内效果总体较为稳定

7. 后续研究展望

PLS 算法本身不限制潜变量的个数，而在本篇报告中，我们只是使用了基础的单潜变量算法，即假设每一期股票只受到一个内在驱动力的影响，这是一个较强的前提假设。

接下来我们简单地介绍多维的潜变量空间的模型核心思想。该模型需由两部分组成，第一部分为测量模型（也称为外部模型），用于描述显性变量与潜变量的关系；第二部分为结构模型（也称为内部模型），用于描述潜变量之间的关系。

测量模型主要用于从一组显性变量中提取出一个唯一的潜变量，它们之间的关系仍为线性相关，即 $X_{k,j} = \lambda_{k,j} * \mu_k + u_{k,j}$ (X 指代显性变量， μ 指代潜变量)

结构模型则为多维模型的核心，用于描述潜变量之间的关系，即

$$\mu_k = \sum_{j \neq k} \beta_{k,j} * \mu_j + \tau_{k,j}$$

这两部分模型也就意味者潜变量不仅可以由显性变量估计得出（外部估计），还可以通过其他与之关联的潜变量进行估计（内部估计）。

后续我们将拓展 PLS 算法至一维以上的潜变量空间，并在 A 股市场上进行进一步的测试。

本公司具有中国证监会核准的证券投资咨询业务资格

分析师声明

作者具有中国证券业协会授予的证券投资咨询执业资格或相当的专业胜任能力，保证报告所采用的数据均来自合规渠道，分析逻辑基于作者的职业理解，本报告清晰准确地反映了作者的研究观点，力求独立、客观和公正，结论不受任何第三方的授意或影响，特此声明。

免责声明

本报告仅供国泰君安证券股份有限公司（以下简称“本公司”）的客户使用。本公司不会因接收人收到本报告而视其为本公司的当然客户。本报告仅在相关法律许可的情况下发放，并仅为提供信息而发放，概不构成任何广告。

本报告的信息来源于已公开的资料，本公司对该等信息的准确性、完整性或可靠性不作任何保证。本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的的价格、价值及投资收入可升可跌。过往表现不应作为日后的表现依据。在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。本公司不保证本报告所含信息保持在最新状态。同时，本公司对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

本报告中所指的投资及服务可能不适合个别客户，不构成客户私人咨询建议。在任何情况下，本报告中的信息或所表述的意见均不构成对任何人的投资建议。在任何情况下，本公司、本公司员工或者关联机构不承诺投资者一定获利，不与投资者分享投资收益，也不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任。投资者务必注意，其据此做出的任何投资决策与本公司、本公司员工或者关联机构无关。

本公司利用信息隔离墙控制内部一个或多个领域、部门或关联机构之间的信息流动。因此，投资者应注意，在法律许可的情况下，本公司及其所属关联机构可能会持有报告中提到的公司所发行的证券或期权并进行证券或期权交易，也可能为这些公司提供或者争取提供投资银行、财务顾问或者金融产品等相关服务。在法律许可的情况下，本公司的员工可能担任本报告所提到的公司的董事。

市场有风险，投资需谨慎。投资者不应将本报告作为作出投资决策的唯一参考因素，亦不应认为本报告可以取代自己的判断。在决定投资前，如有需要，投资者务必向专业人士咨询并谨慎决策。

本报告版权仅为本公司所有，未经书面许可，任何机构和个人不得以任何形式翻版、复制、发表或引用。如征得本公司同意进行引用、刊发的，需在允许的范围内使用，并注明出处为“国泰君安证券研究”，且不得对本报告进行任何有悖原意的引用、删节和修改。

若本公司以外的其他机构（以下简称“该机构”）发送本报告，则由该机构独自为此发送行为负责。通过此途径获得本报告的投资者应自行联系该机构以要求获悉更详细信息或进而交易本报告中提及的证券。本报告不构成本公司向该机构之客户提供的投资建议，本公司、本公司员工或者关联机构亦不为该机构之客户因使用本报告或报告所载内容引起的任何损失承担任何责任。

评级说明

1. 投资建议的比较标准

投资评级分为股票评级和行业评级。以报告发布后的 12 个月内的市场表现为比较标准，报告发布日后的 12 个月内的公司股价（或行业指数）的涨跌幅相对同期的沪深 300 指数涨跌幅为基准。

2. 投资建议的评级标准

报告发布日后的 12 个月内的公司股价（或行业指数）的涨跌幅相对同期的沪深 300 指数的涨跌幅。

	评级	说明
股票投资评级	增持	相对沪深 300 指数涨幅 15%以上
	谨慎增持	相对沪深 300 指数涨幅介于 5%~15%之间
	中性	相对沪深 300 指数涨幅介于-5%~5%
	减持	相对沪深 300 指数下跌 5%以上
行业投资评级	增持	明显强于沪深 300 指数
	中性	基本与沪深 300 指数持平
	减持	明显弱于沪深 300 指数

国泰君安证券研究所

	上海	深圳	北京
地址	上海市浦东新区银城中路 168 号上海银行大厦 29 层	深圳市福田区益田路 6009 号新世界商务中心 34 层	北京市西城区金融大街 28 号盈泰中心 2 号楼 10 层
邮编	200120	518026	100140
电话	(021) 38676666	(0755) 23976888	(010) 59312799
E-mail:	gt.jaresearch@gt.jas.com		