

2021.04.16

AI 投资方法论：从多因子到多信号

	陈奥林(分析师)	杨能(分析师)
	021-38674835	021-38032685
	chenaolin@gtjas.com	yangneng@gtjas.com
证书编号	S0880516100001	S0880519080008

本报告导读：

本文讨论了股票收益率预测时数据类型选择的问题。

摘要：

- 构建线性回归股票收益率预测模型时，由于 ALPHA 因子对股票收益的“非对称微笑”特征，使用 0-1 二元特征表现优于连续型特征。
- 非对称特征指因子多空收益来源常以多头或空头其中之一为主要收益驱动因素。以风格切换为例，当市场风格从估值转向盈利时，资金从低估值板块转向高盈利板块，高盈利个股涨，低估值个股跌，而低盈利股票涨跌并不确定。
- “微笑曲线”特征指不同分位的因子值对股票收益率的影响不一样，通常中间分位的因子值重要性远小于第一分位和最后分位，即体现为“两头高、中间低”的“微笑”特征。
- 参照广告点击率预测中离散化特征与线性回归相结合的预测模型，我们对传统连续型 ALPHA 因子转换为多个二元离散变量，由此构建了多信号模型。
- 多信号模型相对多因子模型在策略信息比率和最大回撤有一定改善，其中中证 500 增强组合年化超额收益 25.5%，信息比率 4.15，最大回撤 5.9%。
- 多信号模型本质是随机森林模型与多因子模型的结合，通过足够的决策树 BAGGING 的方式实现较精确的股票收益率预测。
- 多信号模型潜在收益上限相对多因子模型大幅提升，在不做行业风格和约束的条件下，模型 TOP 20 组合 2015 年以来获得了 780% 的绝对收益率，年化收益率约 42%，夏普比率 1.33。

金融工程团队：

陈奥林：(分析师)

电话：021-38674835

邮箱：chenaolin@gtjas.com

证书编号：S0880516100001

杨能：(分析师)

电话：021-38032685

邮箱：yangneng@gtjas.com

证书编号：S0880519080008

殷钦怡：(分析师)

电话：021-38675855

邮箱：yinqinyi@gtjas.com

证书编号：S08805190800013

徐忠亚：(分析师)

电话：021-38032692

邮箱：xuzhongya@gtjas.com

证书编号：S0880120110019

刘晔：(分析师)

电话：021-38677309

邮箱：liubingyi@gtjas.com

证书编号：S0880520050001

吕琪：(研究助理)

电话：021-38674754

邮箱：lvqi@gtjas.com

证书编号：S0880120080008

相关报告

基金赎回压力点位测算 2021.03.24
 富国中证细分机械设备产业 ETF 投资价值分析 2021.03.23
 系统化择时之路 2-检验的艺术 2021.03.15
 南方中证 500ETF 投资价值分析 2021.02.24
 因子拥挤视角下的风格配置 2021.02.04

目 录

1. 引言	3
2. 传统多因子模型的收益上限	3
2.1. 多因子选股如何实现高收益?	3
2.1.1. 组合构建	3
2.1.2. 策略表现	4
2.2. 更加严格的风格控制对策略的影响	5
2.3. 小节	6
3. 从多因子到多信号	7
3.1. 广告点击率预测的启发	7
3.2. 连续特征取值是信息抑或噪音?	8
3.3. 多因子 VS 多信号	10
3.3.1. TOP 组合表现对比	10
3.3.2. 不同组合优化参数对比	11
3.4. 多信号模型收益来源分析	11
3.4.1. 因子对股票收益的“非对称微笑”驱动特征	11
3.4.1.1. 非对称性特征	11
3.4.1.2. “微笑”特征	12
3.4.2. 多信号模型本质是“非随机”森林模型	13
3.5. 稳健性进一步检验: LASSO 参数敏感性	13
3.6. 多信号选股模型的收益空间展望	13
4. 总结与展望	14
4.1. 总结: 多信号选股的优势	14
4.2. 展望: AI 选股的研究框架	15
5. 附录	16

请输入摘要信息

1. 引言

AI 投资的第一步是构建收益率预测模型。在预测模型构建前，有一个基础且重要但常被忽视的决策问题：模型输入数据类型（特征/因子）选择连续型数据还是离散型数据？换言之，我们是否需要对连续特征进行离散化处理（Discretization）？特别是对于传统多因子模型采用的线性回归模型，哪种数据类型与线性回归更加匹配？

在使用神经网络、深度学习、提升树等复杂预测模型时，连续型数据特征必然是首选。这是因为连续型数据包含了更多信息，复杂模型能够基于连续变量的信息挖掘股票收益率与因子间的非线性关系，但对于简单朴素的线性回归预测模型而言，信息量占优的连续型解释变量一定优于数量占优的二元变量吗？

在上一篇报告《高风险组合的构建》中，我们已经初步展示了因子离散化在负面选股上对预测效果的提升，本篇报告继续把该思想应用于正面选股上，我们对比了基于连续型因子构建的传统多因子选股策略与基于二元变量构建的 LASSO 回归模型。

研究表明，连续型因子离散化后不仅没有因子信息的损失而出现预测能力下降的情况，相反预测效果有一定提升，体现在策略信息比率和最大回撤的改善，基于离散化因子的中证 500 增强组合年化超额收益 25.5%，信息比率 4.15，最大回撤 5.9%。更为重要的是，量化选股策略潜在收益上限大幅提升，在不做行业风格和约束的条件下，模型预测高收益率 TOP 20 组合 2015 年以来获得了 780% 的绝对收益率，年化收益率约 42%，夏普比率 1.33。

我们把仅基于二元信号变量的选股模型称之为多信号模型，相对于多因子模型，多信号模型更好地反映了因子对股票收益的“非对称微笑”驱动特征，从本质上来说，多信号模型类似于基于 BAGGING 思想的随机森林模型，兼具抗过拟合性和精确性。

2. 传统多因子模型的收益上限

2.1. 多因子选股如何实现高收益？

对比多信号模型与多因子模型之前，我们首先需要了解目前一个优秀的多因子选股策略可实现的最大收益，否则模型间的对比失去意义。结合团队研究成果，我们构建了月调仓的传统多因子选股模型，以期获得策略收益的最大化。

2.1.1. 组合构建

在多因子体系下，策略收益的上限取决于收益预测模型，而收益预测的表现大部分取决于 ALPHA 因子的优劣与数量。在因子质量上，我们采取更加严格的市值行业中性；在因子选择上，除常规 ALPHA 因子之外，

我们加入了大量另类因子，单一的另类因子 IC 虽然不高，但均具有较高的统计显著性（见附录），经测试最终整体为模型带来了超过 7% 的年化超额收益。

组合构建上，我们基本参照了经典的多因子选股体系。我们采用了过去 12 月因子收益率平均加权方式，除传统 BARRA 风险模型控制跟踪误差之外，我们新增了个股风险打分对组合风险进行约束，下表为可行的经典因子选股策略框架，基于此，我们构建了追求高收益的进取型中证 500 指增、追求高信息比的稳健型中证 500 指增以及符合公募基金产品要求的成分股指增。

表 1 经典因子选股回测信息

	中证 500 指增-进取	中证 500 指增-稳健	中证 500 成分股指增
回测区间	201401-202103	201401-202103	201401-202103
调仓频率	月度	月度	月度
股票池	中证全指成分股	中证全指成分股	80%中证 500 成分股+20%其他
因子类型	基本面因子	基本面因子	基本面因子
收益来源	估值修复、盈利边际改善、市场异象等		
因子加权方式	因子收益率均值加权	因子收益率均值加权	因子收益率均值加权
优化目标	最大化预期收益	最大化预期收益	最大化预期收益
跟踪误差约束	无	0.05	无
市值敞口约束	0.3	0.3	0.3
行业敞口约束	0.01	0.01	0.01
个股权重上限	0.2	0.2	0.2
交易成本	0.003	0.003	0.003
调仓成交价格	VWAP	VWAP	VWAP

数据来源：国泰君安证券研究，以上策略均采用统一框架，其他未涉及细节均保持一致

2.1.2. 策略表现


传统基本面多因子选股体系体现出了高信息比与低换手的特点。在不控制跟踪误差的情况下，我们的量化指增策略 2014 年以来至 2021 年 3 月末累积收益达 852.7%，年化超额收益 27.6%，信息比率 4.15，最大回撤 6.5%；采用 BARRA 风险模型严格控制跟踪误差后，最大回撤下降至 5.4%，信息比率提升至 4.373，增加中证 500 成分股 80%持仓限制后，策略年化超额收益为 21.2%。

表 2 传统基本面多因子选股策略表现

	年化超额收益	跟踪误差	信息比率	相对最大回撤	双边年换手倍数
中证 500 指增-进取	27.6%	6.6%	4.152	6.5%	5.84
中证 500 指增-稳健	25.6%	5.8%	4.373	5.4%	5.67
中证 500 成分股指增	21.2%	5.7%	3.696	5.6%	5.33

数据来源：国泰君安证券研究

图 1 传统基本面多因子选股策略表现



数据来源：国泰君安证券研究

表 3 传统基本面多因子选股策略超额收益分年度表现

	中证 500 指增-进取	中证 500 指增-稳健	中证 500 成分股指增
2014 年	30.6%	27.2%	21.6%
2015 年	32.2%	28.3%	23.5%
2016 年	27.6%	28.6%	21.0%
2017 年	18.0%	18.0%	14.9%
2018 年	23.6%	22.0%	20.9%
2019 年	30.3%	27.8%	16.5%
2020 年	28.8%	28.8%	28.9%
2021 年（未年化）	4.6%	2.1%	4.6%

数据来源：国泰君安证券研究

在上述模型中再新增 ALPHA 因子已无法再显著提升策略表现，特别是量价类因子的加入仅增加了收益的波动性。尽管通过反向因子暴露归零、新增市值以外其他风格约束如流动性、动量等“微创新”有助于小幅提升策略表现，但整体提升十分有限，也一定程度上增加了模型的过拟合风险。

2.2. 更加严格的风格控制对策略的影响

基于上述模型，是否可以认为多因子策略的 ALPHA 收益上限一定大于 27%？事实并非如此，以上策略虽然进行了市值和行业风格的中性，但策略收益率仍然包括了一定的风格收益。较松的市值和行业风格控制虽然在样本内回测时带来了正收益，但是在样本外，由于风格的不确定性，风格收益可能为负，从而可能导致策略收益样本内外差异较大。

$$\begin{aligned}
 \text{样本内策略收益} &= \text{ALPHA 收益} + \text{风格收益} \\
 \text{样本外策略收益} &= \text{ALPHA 收益} + / - \text{风格收益}
 \end{aligned}$$

因此，有必要进行更加严格的风格控制，我们把行业和市值与中证 500 基准指数的绝对差距限制下千分之 5 之内，施行更加严格的风格控制，此时的策略收益才是真正的 ALPHA 因子带来的收益。

表 4 严格风格控制策略框架

中证 500 指增-严约束	
回溯区间	201501-202103
调仓频率	月度
股票池	中证全指成分股
因子类型	基本面因子
因子加权方式	因子收益率均值加权
优化目标	最大化预期收益
跟踪误差约束	无
市值敞口约束	0.005
行业敞口约束	0.005
个股权重上限	0.2
交易成本	0.003
调仓成交价格	VWAP

数据来源：国泰君安证券研究

进取型策略实施严格的风格约束后，策略表现年化超额收益从 27.6% 下降至 25.8%，其中信息比率下降明显，从 4.15 下降至 3.81，策略稳定性受到了明显的影响。由此可见，纯 ALPHA 真实年化超额收益实际无法达到 27%。这也反映了当前多因子选股的困境，严格控制风格，收益不足，放开风格，收益波动又过大，失去了多因子策略信息比率高的特征。这一问题几乎无解，原因在于符合传统多因子体系的优秀 ALPHA 十分有限，ALPHA 潜在空间不足，收益上限自然受限。

表 5 严格风险控制策略表现

	年化超额收益	跟踪误差	信息比率	相对最大回撤	双边年换手倍数
中证 500 指增-严约束	25.8%	6.8%	3.814	6.7%	5.74

数据来源：国泰君安证券研究

图 2 严格风险控制策略表现



数据来源：国泰君安证券研究

2.3. 小节

经典的多因子选股体系尽管成熟，但并非完美无缺，策略收益波动自

2019 年以来正在逐渐加大, 年化 25% 的稳定超额收益已经接近多因子体系下低频策略的天花板, 新增 ALPHA 因子能够降低组合波动, 但已难以显著增加长期年化收益, 一个收益高于 25% 的多因子策略可能是在样本内过拟合了难以预测的风格收益, 考察多因子策略的表现需要执行更加严格的风格中性标准。对于这样的表现, 我们并不满足, 在量化选股上, 我们能做得更好吗? 我们将具体介绍多信号选股模型的思路, 与传统多因子模型进行对比。

3. 从多因子到多信号

受 AI 在广告点击率预测领域成功经验的启发, 我们提出多因子转向多信号的设想。本小节将详细说明通过广告点击率预测的方法把上一章节中的多因子模型改进为多信号选股模型的方法。

3.1. 广告点击率预测的启发

在计算广告系统中, 一个可以携带广告请求的用户流量到达后台时, 系统需要在较短时间内返回经过排序的广告列表, 因而需要通过基于用户和广告的特征预测该用户的广告点击率, 优先列示高点击率的广告。对于该问题, 业界用得较多的是基于 LR (逻辑回归) 的点击率预估策略。LR 模型本质仍然是线性回归, 但是与量化投资领域不同的是, 算法工程师通常并不会把连续特征直接加入模型, 而是首先会把连续特征离散化为零一信号, 构建基于离散特征+LR 的预测算法。为何广告点击率预测需要对连续特征离散化? 通常有四方面的原因:

1. 离散化后的特征对异常数据有很强的鲁棒性: 比如一个特征是年龄 >30 是 1, 否则 0。如果特征没有离散化, 一个异常数据“年龄 300 岁”会给模型造成很大的干扰。
2. 逻辑回归属于广义线性模型, 表达能力受限; 单变量离散化为 N 个后, 每个变量有单独的权重, 相当于为模型引入了非线性, 能够提升模型表达能力。
3. 离散化后可以进行特征交叉, 由 $M+N$ 个变量变为 $M*N$ 个变量, 进一步引入非线性, 提升表达能力。
4. 稀疏向量内积乘法运算速度快, 计算结果方便存储。

以上四点原因对于量化选股同样成立:

1. 因子离散化后, 策略鲁棒性大幅提升, 策略不容易受到因子处理细节差异的影响。尽管多因子通过去极值的方法剔除异常值, 但是一方面, 去极值的方法、空值处理方法等细节均带来了模型的复杂度以及过拟合的风险, 另一方面, 对于低信噪比因子来说, 其连续取值意义仅仅增加了模型噪音。例如成长因子、另类因子等。成长因子通常通过财务数据的变化率构造, 由于基数效应的存在, 导致成长得分较高的公司必然是上一期财务数据非常小的公司, 从而导致较低

的信噪比，另类数据因子亦然。

2. 若想大幅提升策略收益，挖掘非线性收益是必然趋势。BARRA 模型中的非线性市值因子已经被市场作为一个十分重要的风格收益来源。我们在 AI 因子挖掘器中挖掘的非线性流动因子也有非常不错的收益预测能力，此类非线性因子显然更适合作离散化处理。
3. 离散化因子的特征交叉相当于把连续型因子加入决策树、神经网络等非线性模型。正如人工智能科学家李沐所言“预测模型是使用离散特征还是连续特征，其实是一个[海量离散特征+简单模型]同[少量连续特征+复杂模型]的权衡”。二者本质虽然相同，但是离散化后的交叉特征的可解释性远高于黑箱模型。
4. 简单的因子构造和较快的回测速度可以降低研究时间成本，增加团队协作，加快模型开发速度。

基于上述原因，离散化特征更适合线性回归模型。

3.2. 连续特征取值是信息抑或噪音？

尽管上一小节提到了把连续变量转换为 0-1 信号的诸多优势，但是离散化后信息必然是有所损耗的，主观上很容易认为连续变量的信息必然是有用的，事实真是如此吗？损耗的信息是有效信息还是无效信息需要我们进一步验证。

为此，我们通过控制变量法进行尝试，对于 2.2 章节的严约束选股模型，我们基本保持不变，仅把因子信号后，观察策略绩效的变化。具体而言，我们对所有 ALPHA 因子分别等分为 5 组，取各因子 Q1、Q5 组 0-1 变量作为模型输入信号。

图 3 连续变量离散化示意图




表 6 多信号选股策略框架

多信号选股模型 V0.1	
回溯区间	201501-202103
调仓频率	月度
股票池	中证全指成分股
模型信号	是否为 ALPHA 因子 TOP20% 或 BOTTOM20%
回顾周期	过去 3 年
信号筛选与预测	LASSO 模型 ALPHA = 0.1
信号权重	各期回归系数等权
优化目标	最大化预期收益
跟踪误差约束	无
市值敞口约束	0.005
行业敞口约束	0.005
个股权重上限	0.2
交易成本	0.003
调仓成交价格	VWAP

数据来源：国泰君安证券研究


回溯结果在我们的意料之外，仅使用 70 个 0-1 信号的选股模型竟能够和传统多因子获得了几乎一样的年化超额收益率，更令人惊讶的是，上述多信号模型的信息比率要好于相应的多因子模型，最大回撤也有所下降，仅换手率有一定上升。

表 7 多信号选股策略表现

	年化超额收益	跟踪误差	信息比率	相对最大回撤	年换手倍数
多信号选股 V0.1	25.5%	6.1%	4.151	5.90%	6.66
比较基准：中证 500 指增-严约束	25.8%	6.8%	3.814	6.7%	5.74

数据来源：国泰君安证券研究

图 4 多三信号选股策略表现



数据来源：国泰君安证券研究

表 8 信号选股策略超额收益分年度表现

	多信号选股 V0.1	多因子选股严约束
2015 年	33.3%	28.3%
2016 年	24.4%	24.1%
2017 年	20.4%	23.2%
2018 年	19.8%	23.7%
2019 年	28.5%	25.8%
2020 年	25.9%	28.6%
2021 年(未年化)	5.8%	4.7%

数据来源：国泰君安证券研究


3.3. 多因子 VS 多信号

衡量一个策略的优劣，不能只重视单一的策略回测结果，而忽视策略的鲁棒性。好的策略应当持股数量越少，策略收益越高，反之，则策略收益越稳定；其次是对组合优化参数的敏感性，一个优秀的策略不应过度依赖于策略中的某一部分，例如某个表现特别好的因子、模型参数以及某些处理细节（空值填充方法、因子标准化方法）等。

3.3.1. TOP 组合表现对比

本小节基于收益预测模型给出的个股得分排序，选择得分最高的 N 只股票作为月频调仓组合。此做法相当于剔除了组合优化的影响，不对股票市值与行业做任何中性，因而能更为纯粹地考察收益率预测模型的优劣。在各持股数量下，多信号策略表现均好于多因子模型。我们测试了 TOP10、TOP20、TOP40 三种组合构建方式，由下图可以看到，多信号选股模型在没有任何风格约束的条件下，TOP 20 组合 2015 年以来获得了 780% 的绝对收益率，年化收益率约 42%，夏普比率 1.33，相对中证 500 指数有近 40% 年化超额收益，而多因子模型无论多少持股数量，超额收益均未显著突破 30%。

图 5 TOP10 选股组合表现对比



数据来源：国泰君安证券研究

表 9 TOP 选股组合策略表现

请务必阅读正文之后的免责条款部分

策略类型	股票只数	年化超额收益	跟踪误差	信息比率	相对最大回撤	双边年换手倍数
多信号选股	10	36.9%	12.9%	2.864	12.7%	7.54
多因子选股	10	29.9%	14.7%	2.030	11.1%	6.66
多信号选股	20	39.2%	10.2%	3.832	13.4%	7.28
多因子选股	20	30.4%	10.6%	2.858	11.9%	6.21
多信号选股	40	34.2%	8.2%	4.163	10.8%	6.68
多因子选股	40	26.0%	8.2%	3.171	10.0%	5.69

数据来源：国泰君安证券研究

3.3.2. 不同组合优化参数对比

在 3.2 节的模型中，我们施行了最为严格的市值与行业中性方法，分别控制市值和行业敞口在千分之 5 以内。本小节，我们适当放松敞口，观察不同风格约束下策略表现的差异。在我们的测试中，多信号选股策略在任意参数下，均显著跑赢了多因子选股策略。

表 10 不同参数组合策略表现

策略类型	行业风格敞口	市值风格敞口	个股权重上限	年化超额收益	跟踪误差	信息比率	最大回撤	年换手倍数
多信号	0.3	0.3	0.02	29.5%	7.0%	4.241	8.1%	6.342
多因子	0.3	0.3	0.02	24.9%	7.6%	3.262	9.1%	5.592
多信号	0.1	0.1	0.02	28.9%	7.1%	4.090	8.2%	6.294
多因子	0.1	0.1	0.02	24.4%	7.7%	3.173	8.8%	5.443
多信号	0.05	0.05	0.02	29.0%	7.0%	4.176	7.9%	6.301
多因子	0.05	0.05	0.02	24.8%	7.6%	3.247	8.9%	5.534
多信号	0.01	0.01	0.02	27.0%	6.3%	4.324	6.3%	6.516
多因子	0.01	0.01	0.02	26.7%	6.9%	3.849	6.9%	5.670

数据来源：国泰君安证券研究

3.4. 多信号模型收益来源分析

3.4.1. 因子对股票收益的“非对称微笑”驱动特征

深刻理解 ALPHA 因子的收益来源有利于我们加深对因子与市场关系的理解，并对因子权重给予合理的配置。对连续因子离散化后，我们发现了更多因子对股票收益率非线性驱动的证据：

3.4.1.1. 非对称性特征


因子多空收益来源常以多头或空头其中之一为主要收益驱动因素。以风格切换为例，当市场风格从估值转向盈利时，资金从低估值板块转向高盈利板块，高盈利个股涨，低估值个股跌，而低盈利股票涨跌并不确定，因而因子对股票收益的影响多空是不对称的。

绝大部分量价类因子体现为空头显著优于多头的特点，基本面因子的多头与空头驱动收益的能力相对均衡，但各年份间仍有较大差异。以 ROA 同比增长因子为例，ROA 同比因子在 2019 年上半年以前，收益多源于

多头，而最近两年内低成长个股显著跑输市场，但高成长公司并未贡献超额收益，表明此因子的配置价值正在下降。

整体上来看，回测期的 98 个样本点里仅 17 个月份出现了双向信号均显著的情况（红蓝柱堆积），其中 42 个月份为单向信号贡献收益，有些月份多头空头信号甚至出现了同向的情况。多信号模型基于因子多空不同的表现，分别给多头信号和空头信号配置权重带来了一部分非线性收益。

图 6 ROA 同比因子月多空收益及多头和空头信号 LASSO 回归系数




数据来源：国泰君安证券研究

3.4.1.2. “微笑”特征

在 Q2 到 Q4 分位的因子值对股票收益率的影响远小于 Q1、Q5 分组信号，即体现为“两头高、中间低”的“微笑”特征。Q2 至 Q4 分组信号整体来看，预测能力远低于 Q1 与 Q5 组。

图 7 不同分组重要性的微笑曲线



数据来源：国泰君安证券研究

注：我们对所有二元变量回归系数取平均计算不同因子分组下的系数均值。

多因子选股有时会选到因子值在各维度比较“平庸”的股票，其特点为在各因子打分上没有明显的短板，单项分数中等，但总分较高，我们认为此类没有鲜明风格的股票可投资逻辑薄弱，难以带来超额收益。仅基于 Q1 和 Q5 分组的多信号模型充分利用了因子对股票收益率影响的微

笑型特征，有效避免买入缺乏鲜明投资逻辑的个股。

需要注意的是，本报告出于简化目的，仅使用了 Q1 与 Q5 分组的信号，整体来看，Q1 与 Q5 信号强于 Q2 至 Q3，并不表明所有因子中部均无效，如何过滤噪音，利用中段分组中的信息，我们将在接下来的报告中进行阐述。

3.4.2. 多信号模型本质是“非随机”森林模型

随机森林模型基于集成学习中的 BAGGING 思想通过众多弱分类器组合成强分类器，使得整体模型的结果具有较高的精确度和泛化性能。多信号模型中的单信号可理解为单个决策树，基于某些特征对股票进行分类，基于 N 个特征的信号为 N 层决策树，每棵树独立同时生成，通过足够多的决策树 BAGGING 的方式实现较精确的股票收益率预测。与随机森林算法不同的是，现有选股模型的决策树并不随机生成，每一颗决策树都是基于量化投资者们对市场投资逻辑的抽象概括，我们将在接下来的报告中进一步分析如何确定有效信号。尽管这一方法牺牲了一部分随机森林的抗过拟合能力，但是也使得模型更加易于理解与主观调整，未来我们可以将多信号模型与纯人工智能模型预测收益率相结合的方式（STACKING 思想）以期获得更加更加稳健的收益率预测能力。

3.5. 稳健性进一步检验：LASSO 参数敏感性

多信号模型相对于传统多因子模型引入了一个 LASSO 回归参数 α 。 α 越大对变量较多的线性模型的惩罚力度就越大，最终选择的信号就越少。 α 直接决定了预测模型使用的信号以及权重，对模型收益率预期的影响至关重要，本小节对模型 α 做进一步检验。

由于我们的信号未逐个检验， α 越小，模型越接近普通线性回归，纳入噪音信号越多，因此在上述模型中需要一个较为严格的特征筛选参数。整体而言，lasso α 越大，跟踪误差越大，极端参数下，模型收益最低降至 20%。

表 11 不同 LASSO ALPHA 下策略表现

lasso alpha	信号平均数量	年化超额收益	跟踪误差	信息比率	相对最大回撤	年换手倍数
0.005	42.6	24.05%	6.04%	3.980	7.79%	6.79
0.01	24.9	25.50%	6.10%	4.151	5.90%	6.66
0.015	15.4	25.23%	6.33%	3.988	6.03%	6.55
0.02	9.7	23.56%	6.58%	3.578	4.99%	6.59
0.03	4.1	19.95%	6.45%	3.095	5.79%	6.32


数据来源：国泰君安证券研究

3.6. 多信号选股模型的收益空间展望

多信号选股模型收益上限远高于传统多因子模型，具体原因有以下几点：

一、从因子数量上来看，多信号选股模型 V0.1 仅使用了 70 个 0-1 哑变量，其中一半还是负向选股信号，在通过 LASSO 模型做特征筛选后，实际用于预测信号数量更少。而在广告点击率预测领域，其因子数量却是成千上亿的。我们认为寻找信号的难度明显小于寻找 ALPHA 因子，模型潜在提升空间巨大。

图 8 LASSO 信号选择数量



数据来源：国泰君安证券研究

二、从 AI 预测模型来看，单纯的 LR、LASSO 等线性模型略显过时，在广告点击率预测实际应用中，FACEBOOK 2014 年提出的 GBDT+LR 模型同样经典，其他模型例如 FM、FFM 等也有不错的表现，使用最新的模型对 CTR 预测有 10% 的提升，我们认为它们同样有望应用到量化选股之中。

三、从挖掘非线性收益来看，我们的模型目前并未利用因子的非线性信息，也并未尝试做特征组合，如何体现出多信号模型非线性预测能力有待进一步研究。

4. 总结与展望

4.1. 总结：多信号选股的优势

在上一篇报告《高风险组合的构建》报告中，我们初步展现了因子离散化在负面排雷上的强大效果。在本篇报告中，我们首先构建了传统的多因子选股模型，获得了年化超额 25% 以上的收益；其次，我们将因子离散化的方法应用于 ALPHA 因子，把 ALPHA 因子转换为 0-1 信号，从而构建了基于多信号的 AI 选股模型。研究发现，在我们的多因子选股体系下对 ALPHA 因子转换为 0-1 信号的过程中，不仅没有损失因子增量信息，反而增加了模型的鲁棒性，甚至在绝大部分组合构建方式下，多信号选股模型均优于多因子选股的表现，由此可知，线性回归模型更适合使用离散特征。进一步，我们说明了为何我们认为我们的多信号模型远未达到模型收益的上限。


我们相信多信号选股模型优于多因子选股模型，原因在于：

- 一、多信号选股并非黑匣子模型，恰恰相反，在选择合适的模型的基础上，多信号模型的选股逻辑比多因子模型更为清晰，这一点从我们在上一篇报告中的看空模型就可以看出。
- 二、多信号模型充分反映了因子对股票收益的“非对称微笑”驱动特征，在剔除了因子中的无效信息后，获得了更多因子的非线性收益。
- 三、多信号模型本质是随机森林模型与多因子模型的结合，其单信号可理解为单个决策树，基于某些特征对股票进行分类，基于 N 个特征的信号为 N 层决策树，每棵树独立同时生成，通过足够多的决策树 BAGGING 的方式实现较精确的股票收益率预测。

4.2. 展望：AI 选股的研究框架

多信号选股是 AI 投资雏形。AI 在量化投资上的应用包括四个方面：特征挖掘、特征组合、协方差阵估计与组合优化。在特征挖掘方面，我们在《决胜样本外：因子挖掘算法革新》中做了详细的介绍，未来我们会继续研究基于遗传规划因子构建高频选股组合。在特征组合和建模方面相关文献表明，基于 ANN 相关模型被认为是表现最佳的收益率预测模型，ANN 模型的预测准确率比表现第二好的梯度提升树要高 30%；在协方差阵估计方面，近年来也有学者提出了基于分层聚类算法的协方差估计方法，相对于传统风险模型，其参数更少，对应的最小方差组合夏普率更高，如何应用 AI 算法进行协方差估计值得进一步分析；最后我们能够研究如何通过 AI 算法完成定制化的优化目标。综上，我们将按照上述流程为量化投资者带来 AI 选股系列研究。

图 9 AI 选股流程



数据来源：国泰君安证券研究

5. 附录

表 12 另类因子介绍

因子名称(英文)	因子名称	因子简介	因子方向	多空收益 T 显著性
rptdays_neut	定期报告发布用时	过去一年四期定期报告发布所需平均天数，取对数	-	-4.414
share_conc_neut	股权集中度	前十大股东持股比例之和	+	4.418
ga_corr_neut	管理费用粘性	过去两年管理费用和营业总收入的相关性	+	5.510
realem2_neut	真实盈余管理	销售操控+生产操控+酌量性费用操控	-	-5.235
holding_inst_neut	机构持股比例	机构投资者最新总持股比例	+	4.557
inst_survey_1y_neut	机构调研频率	过去一年机构调研总次数	+	4.960
inst_num_neut	机构持股数量	最新一期机构持股数量	+	4.583
ar_age_neut	应收款账龄	应收款的账龄(金额加权)	-	-4.850
ar_badratio_neut	应收款坏账率	最新一期应收款坏账率	-	-4.436
ashareholdernum_z_neut	股东数目时序标准分	当前股东数目相对于过去 2 年股东数目的 Zscore	-	-5.664
answerdays_neut	董秘季度回答天数	深圳互动易董秘过去一个月回答问题的总天数	+	5.213
subsidies_neut	政府补助	对数政府补助	+	3.974

数据来源：国泰君安证券研究

本公司具有中国证监会核准的证券投资咨询业务资格

分析师声明

作者具有中国证券业协会授予的证券投资咨询执业资格或相当的专业胜任能力，保证报告所采用的数据均来自合规渠道，分析逻辑基于作者的职业理解，本报告清晰准确地反映了作者的研究观点，力求独立、客观和公正，结论不受任何第三方的授意或影响，特此声明。

免责声明

本报告仅供国泰君安证券股份有限公司（以下简称“本公司”）的客户使用。本公司不会因接收人收到本报告而视其为本公司的当然客户。本报告仅在相关法律许可的情况下发放，并仅为提供信息而发放，概不构成任何广告。

本报告的信息来源于已公开的资料，本公司对该等信息的准确性、完整性或可靠性不作任何保证。本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的的价格、价值及投资收入可升可跌。过往表现不应作为日后的表现依据。在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。本公司不保证本报告所含信息保持在最新状态。同时，本公司对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

本报告中所指的投资及服务可能不适合个别客户，不构成客户私人咨询建议。在任何情况下，本报告中的信息或所表述的意见均不构成对任何人的投资建议。在任何情况下，本公司、本公司员工或者关联机构不承诺投资者一定获利，不与投资者分享投资收益，也不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任。投资者务必注意，其据此做出的任何投资决策与本公司、本公司员工或者关联机构无关。

本公司利用信息隔离墙控制内部一个或多个领域、部门或关联机构之间的信息流动。因此，投资者应注意，在法律许可的情况下，本公司及其所属关联机构可能会持有报告中提到的公司所发行的证券或期权并进行证券或期权交易，也可能为这些公司提供或者争取提供投资银行、财务顾问或者金融产品等相关服务。在法律许可的情况下，本公司的员工可能担任本报告所提到的公司的董事。

市场有风险，投资需谨慎。投资者不应将本报告作为作出投资决策的唯一参考因素，亦不应认为本报告可以取代自己的判断。在决定投资前，如有需要，投资者务必向专业人士咨询并谨慎决策。

本报告版权仅为本公司所有，未经书面许可，任何机构和个人不得以任何形式翻版、复制、发表或引用。如征得本公司同意进行引用、刊发的，需在允许的范围内使用，并注明出处为“国泰君安证券研究”，且不得对本报告进行任何有悖原意的引用、删节和修改。

若本公司以外的其他机构（以下简称“该机构”）发送本报告，则由该机构独自为此发送行为负责。通过此途径获得本报告的投资者应自行联系该机构以要求获悉更详细信息或进而交易本报告中提及的证券。本报告不构成本公司向该机构之客户提供的投资建议，本公司、本公司员工或者关联机构亦不为该机构之客户因使用本报告或报告所载内容引起的任何损失承担任何责任。

评级说明

	评级	说明
1. 投资建议的比较标准 投资评级分为股票评级和行业评级。 以报告发布后的 12 个月内的市场表现为比较标准，报告发布日后的 12 个月内的公司股价（或行业指数）的涨跌幅相对同期的沪深 300 指数涨跌幅为基准。	增持	相对沪深 300 指数涨幅 15%以上
	谨慎增持	相对沪深 300 指数涨幅介于 5%~15%之间
	中性	相对沪深 300 指数涨幅介于-5%~5%
	减持	相对沪深 300 指数下跌 5%以上
2. 投资建议的评级标准 报告发布日后的 12 个月内的公司股价（或行业指数）的涨跌幅相对同期的沪深 300 指数的涨跌幅。	股票投资评级	
	行业投资评级	
	增持	明显强于沪深 300 指数
	中性	基本与沪深 300 指数持平
	减持	明显弱于沪深 300 指数

国泰君安证券研究所

	上海	深圳	北京
地址	上海市静安区新闻路 669 号博华广场 20 层	深圳市福田区益田路 6009 号新世界商务中心 34 层	北京市西城区金融大街甲 9 号 金融街中心南楼 18 层
邮编	200041	518026	100032
电话	(021) 38676666	(0755) 23976888	(010) 83939888
E-mail:	gtjaresearch@gtjas.com		