

2016 年 07 月 24 日

深度研究

金融工程研究

研究所

证券分析师:
021-68591581
联系人 :
021-68591559

代鹏举 S0350512040001
daipj@ghzq.com.cn
田悦 S0350116060012
tiany@ghzq.com.cn

国海研究量化 Alpha 选股策略

——多因子模型系列报告之二

全 A 选股策略回测结果



沪深 300 选股策略回测结果



相关报告

《多因子模型系列报告之一: 因子预测能力初探》——2016-06-30

投资要点:

- 多因子 Alpha 模型一直以来都是量化投资领域研究的重点,在 Alpha 策略中,因子构造和构建收益预测模型这两个方向都对策略效果有着极为重要影响。本报告借鉴机器学习中的分类算法,重点探讨预测模型构造最新的研究成果。本报告将通过多个维度的实证分析,并以在金融领域广泛应用的逻辑回归算法为基准,对比 AdaBoost 分类算法在多因子 Alpha 选股策略中的实际效果。总体来讲,在保证处理数据方法一致的前提下,利用 AdaBoost 算法构造的投资组合净值相对稳健,而 AdaBoost 算法对非线性因子的非参数化拟合能力对多因子模型的构造有着极大的帮助,AdaBoost 分类算法将会在构建 Alpha 策略方面有着广阔的发展空间。
- 根据 AdaBoost 分类算法,我们精心打造了两个真实的股票多头投资组合。第一个组合是基于全 A 选股,以中证 500 指数为对冲基准的选股策略,该策略的特点在于高收益、高分散,但同时伴随着略高的波动性。另外,由于全 A 选股,个股的差异性较大,个股的风格转变较快,同时,在个股持有过程中的停牌、涨跌停等因素也会影响投资组合的流动性,所以该策略更适合风险承受能力较大的投资者。同时,我们还构造了基于沪深 300 成分股选股的另一股票多头投资组合,该组合以沪深 300 为对冲基准,同时保证选股过程中的行业中性,并注重一定条件下相应的现金配置,所以,该组合的特点是稳健低回撤,在牺牲一部分高收益的前提下降低组合的波动,该策略适合于追求稳健、风险承受能力较小的投资者关注。2016 年初以来,以中证 500 为对冲基准的全 A 选股策略超额组合净值为 1.2082, 最大回撤仅为 3.01%, 日回报的年化平均值为 33.07%, 波动率为 6.22%; 以沪深 300 为对冲基准的沪深 300 选股策略超额组合净值为 1.0384, 最大回撤仅为 2.13%, 日回报的年化平均值为 6.68%, 波动率为 5.03%。
- 风险提示: 模型结果仅代表统计意义上的结论,不能保证未来实现,希望投资者在实践中结合多方面的信息作出投资决策。

内容目录

1、前言	4
1.1、算法简介	4
2、模型实证研究：逻辑回归与 AdaBoost 之比较	5
2.1、实证数据	5
2.2、AdaBoost 弱分类器数量选择	6
2.3、因子变换	7
2.4、RANK-IC 对比	11
2.5、分位数组合对比	12
2.6、因子筛选	14
3、国海研究 Alpha 选股策略	16
3.1、股票多头-全 A 选股	17
3.2、股票多头-沪深 300 选股	18
4、未来展望	19

图表目录

图 1: AdaBoost 分类正确率 vs. 弱分类器数量	7
图 2: AdaBoost 因子变换过程.....	9
图 3: 逻辑回归因子变换过程.....	10
图 4: AdaBoost 历史 Rank IC	11
图 5: 逻辑回归 历史 Rank IC	11
图 6: AdaBoost 算法分位数组组合的历史走势	13
图 7: 逻辑回归算法分位数组组合的历史走势	13
图 8: 逻辑回归算法和 AdaBoost 算法多空组合净值走势对比.....	14
图 9: AdaBoost 算法因子选择热图	15
图 10: 逻辑回归算法因子选择热图	15
图 11: 全 A 选股策略收益率	17
图 12: 全 A 选股策略较基准超额净值	17
图 13: 2016 年年初以来全 A 选股策略较基准超额净值	18
图 13: 沪深 300 选股策略收益率	18
图 14: 沪深 300 选股策略较基准超额净值	19
图 15: 2016 年年初以来沪深 300 选股策略较基准超额净值	19
表 1: AdaBoost 算法和逻辑回归算法分档对比	12

1、前言

一直以来，多因子 Alpha 选股模型都是量化投资者共同关注的领域。无论是在因子构造方面还是在利用因子预测收益的方法选择方面，量化研究工作者都投入了无限的精力。在因子选择方面，因子的数量和种类在经过长期的发展之后已经逐渐趋于标准化，在商业化的因子数据提供商不断涌现的大趋势下，量化研究员更倾向于将研究重点放在策略构造方法研究方面。另外一方面，Alpha 选股方法随着数学、计算、统计等方法的发展也越发复杂，而各种方法的核心在于如何将众多因子有效的组合到一起，发挥各自的优势，从而达到选择出在统计上具有超额收益的个股组合，像我们熟知的打分法，回归法都其中典型的应用方法。在量化投资领域，或者更广泛的讲，金融领域一直在借鉴相关领域的方法和成果来研究其独特而复杂的市场行为。

Fintech 的技术革新虽然是在最近几年才流行的概念，但事实上，它一直伴随着金融业的发展而发展。在国际上，量化研究工作者和传统的 IT 工作者的区分度也逐渐在弱化，科学计算方法、统计方法、计算机应用方法等方面已经交织在一起，共同应用到了金融领域。因此，各种成功的经验也会不断的被拿到量化投资领域中来尝试，各种方法的应用本质上是紧跟潮流还是过度设计，成功与失败只有在实践中才能得到检验。本文接下来将会以逻辑回归方法为参照，以 AdaBoost 分类器为例，对机器学习在选股中的应用进行探讨。

1.1、算法简介

逻辑回归方法是一种常用的离散选择模型，在金融领域，很早便被应用于违约风险、早偿风险分析等方面。在选股方面也经常用于预测涨跌分类，因此我们采用此方法为参照物对比机器学习方法的效果。

当我们提到机器学习这个概念的时候，往往会先入为主的认为这已经超过量化的范畴。但是，从概念上讲，方法的原理却很简单：利用因子组合特性预测股票未来趋势；从应用上讲，和回归方法类似，它也是基于因子历史解释能力预测未来的走势。本文应用的 AdaBoost 算法核心思想是通过历史训练数据训练出一组弱分类器，并由这组弱分类器通过各自权重线性加权得到一个强分类器。

二元 AdaBoost 算法流程：

1. 等权重初始化每一个样本权重 $w_i = \frac{1}{N}, i = 1, 2, \dots, N$, N 为样本总数。
2. 从 $m = 1$ 到 M ，迭代训练每一个弱分类器， M 为弱分类器总数
 - a) 利用整体样本训练弱分类器 $T^m(x)$ ，样本权重为 w_i
 - b) 计算弱分类器错误率

$$e^m = \sum_1^N w_i I(T^m(x_i) \neq y_i) / \sum_1^N w_i, I(\bullet) \text{ 为示性函数}$$
 - c) 计算弱分类器权重 $\alpha^m = \log(\frac{1-e^m}{e^m})$
 - d) 更新样本权重 $w_i \leftarrow w_i \exp(\alpha^m I(T^m(x_i) \neq y_i)), i = 1, 2, \dots, N$

e) 归一化 w_i

3. 输出由弱分类器线性加权重分类器 $C(x) = \underset{k}{\operatorname{argmax}} \sum_1^M \alpha^m I(T^m(x) = k)$

针对该算法，以下几个问题在实际应用过程中值得关注：

1. 算法流程中指的二元 AdaBoost 是指分类结果分为两类，在本文应用中，具体是将股票分为强势股和弱势股两类，当然 AdaBoost 算法可以支持多分类，但是在选股应用情景中，多分类是否可以提高预测准确性，我们将会在以后的报告中进行讨论。
2. 弱分类器的数量 M 选择也是分类的关键问题，过少的弱分类器是否可以有效的组合因子分类效果？过多的弱分类器数量是否可以持续提高分类准确性？这两个问题会在本文中进行测试。
3. 另外，弱分类器 $T^m(x)$ 是指计算简单，分类效果较略好于掷硬币的分类方法，如单层的树状分类器，当然，较为复杂分类方法，如逻辑回归法，SVM 法理论上都可以作为弱分类器应用到 Boosting 方法中，但实际效果和计算开销都值得探讨。
4. 在利用单层决策树作为弱分类器时，以哪个因子做为因变量进行分类训练，并不在于 AdaBoost 算法本身，而是 AdaBoost 算法将这个问题代理给弱分类器，这是我们这里应用的决策树算法需要解决的问题，通常情况下，决策树在分类过程中会遍历每个因子，从中筛选基尼不纯度或是熵信息增益，来选择当前分类效果最好的因子，作为此层弱分类器的分类因子，虽然最先选择出的因子体现了该因子在弱分类器中的相对重要作用，但我们不能仅因此判断该因子在整个 AdaBoost 算法中的重要程度，随着弱分类器数量的增加，相对不显著的因子被选中的次数可能在迭代过程中增加，实际上，通过对所有弱分类器中选择因子，按照因子的重要程度进行求和之后才能体现该因子的综合重要程度。

2、模型实证研究：逻辑回归与 AdaBoost 之比较

在本节中，我们通过实证结果比较 AdaBoost 算法用于 Alpha 选股策略的有效性。在数据处理方法相同的前提下，我们测试的结果是，AdaBoost 分类算法的整体结果略好，特别是在因子值与收益率之间存在非线性非单调关系的情况下，AdaBoost 算法通过对弱分类叠加，可以很好的拟合出这种非线性关系。但是，我们需要强调的一点是，在建模过程中，数据处理本身和分类算法的选择同等重要，算法不是万能的，算法只是挖掘出数据中隐含模式的一种方法，建模的本质是在处理金融市场中多变的现象，所以，对方法的测试最终还是要回归经济变量的内在联系。

2.1、实证数据

本文涉及的测试区间为 2014 年 1 月 1 日至 2017 年 7 月 8 日，并以周度数据进行测试。由于本文采取的训练序列为 50 周，所以，从回测开始日期向前推 50 周的周度数据也在模型中应用。在测试之前，首先，我们对每周的横截面因子数据进行分档，本文采用的是按照因子大小排序分为五档，第五档为最高档的集合，依次递减。按照常规做法，收益率也采取两档分法，前 30% 为高档，后 30% 为低档，中间数据不用于训练序列。测试中，选取的因子数据包括七大类 17 个因子，包括技术类因子、动量因子、规模因子、质量因子、成长因子和估值因子。请参照下表。


技术	MA20	20 日均线
	MACD	平滑异同平均线
	TVMA20	成交额 20 日均线
	VOL20	换手率 20 日均值
	DAVOL20	换手率 20 日均值/换手率 120 日均值
	ILLIQUIDITY	20 日收益绝对值之和/20 日成交额
动量	MOMENTUM1P	前一期收益率
规模	LCAP	总市值对数
质量	ROA	
	ROE	
杠杆	LongTermDebtToAsset	长期资产负债比
成长	NetAssetGrowRate	净资产增长率
	NetProfitGrowRate	净利润增长率
估值	PB	
	PE	
	PS	
	PCF	
	EPS	

2.2、AdaBoost 弱分类器数量选择

在算法介绍中我们提到，本文所采用的 AdaBoost 算法采用的是单层决策树作为弱分类器，其关键问题之一在于弱分类器数量的选择。弱分类器的叠加效果决定最终强分类器的分类能力，但是，随着弱分类器数量的增加，分类效果是否还会继续提高，甚至造成过拟合，这个问题值得关注。另外，即使样本内训练数据分类效果提高，样本外的预测效果是否会随之提高，也是一个重要的衡量指标。图 1 是根据 2016 年 7 月 1 日及之前总共 50 周的全 A 股周度数据作为训练集合，以 2016 年 7 月 8 日相对于 2016 年 7 月 1 日的全 A 股一周收益率作为预测数据的测试结果。图中蓝色线段为训练集合的预测成功率随弱分类器数量增加的趋势，开始阶段分类器样本内的预测成功率为 56.3% 左右，随着弱分类器数量的增加，预测成功率逐渐提高到 58.1% 左右，并在 75 个弱分类器叠加之后稳定在 58.1%，因此，继续提高弱分类器的数量，训练成功率并没有增加。而图中绿色线段为测试序列的预测成功率随弱分类器数量变化的趋势，初始阶段预测成功率随弱分类器数量增加呈现较为明显的震荡变化，但是在弱分类器数量达到 300 之后成功率稳定在 56.3%。由于开始阶段预测具有相对较大的不确定性，本文在建模过程中选择 300 个弱分类器作为 AdaBoost 算法弱分类器个数。另外，以

逻辑回归为参照物，其样本内训练序列预测成功率为 57.87%，样本外预测成功率为 56.6%，对比可以看到，AdaBoost 算法虽然在样本内预测成功率略高，但是，样本外的表现并不能超越逻辑回归算法。其它类型的 Boosting 方法，如 Gradient Boosting 等甚至可以将样本内预测成功率随弱分类器的数量增加提高到 100%，但是，样本外的预测能力却没有实质性提高，本文不再具体分析该类算法，但值得注意的是机器学习类算法很容易造成过拟合问题，需要在实际操作中检查其可信度。

图 1: AdaBoost 分类正确率 vs. 弱分类器数量



资料来源：国海证券研究所


2.3、因子变换

Alhpa 模型的实质是通过找到因子或因子组合与未来收益率之间的关系，从而训练出较为稳定的收益预测函数，选取优质个股组合。例如，通常用的线性回归模型就是通过线性回归系数将因子映射到收益率上，从而筛选优质个股，但是其问题在于，长期来看，多数因子与收益率之间往往不存在稳定线性关系，甚至单调性也不能保证，所以线性模型的前提条件往往不能满足。个股分类的方法实际是将连续函数离散化，放松了对模型的限制，只要满足分类组合的加权平均收益有较高的区分度便可以达到模型的目的。在金融领域广泛应用的逻辑回归便是一种良好的分类模型，虽然因子之间仍然是线性叠加，但是输出结果却是分类的概率，因此，它可以作为向高阶分类方法的过度的参照物。更进一步的离散化可以将因子也分组归类，找出因子分组与未来收益分组之间的关系，进一步放松对模型的限制。下面，我们以动量因子为例，阐述因子到收益的映射过程。如图 2 所示，图中很难直观看出单个动量因子对未来收益的关系，线性拟合在长训练序列中虽然可能得到显著系数，但由于非线性或非单调性造成的预测误差也十分明显。相对而言，二元分类法的输出是分类概率，我们希望通过概率大小分组，构造组合

收益具有良好区分度的组合。另外，对因子进行分组也省去了回归方法中对原始因子数据的标准化、去极值等过程。我们的分组方法是对训练序列每一期的横截面数据进行分组，使得不同时期数据具有可比性。与原始因子数据类似，分类本身并不会影响因子与未来收益之间的内在关系如图 2 中第三个子图所示。分组数据之后会通过模型训练得到因子分位值与决策函数之间的关系图 2 中第四子图所示。最后，通过决策函数结果筛选优质个股，而图 2 中第五子图是决策函数对应未来收益的散点图，其线性关系明显提高。另外，值得注意的是，对比图 3 中第四子图所示（逻辑回归结果）的因子分组均值和收益之间的关系，AdaBoost 算法所示结果具有明显的非线性拟合能力，这也是该算法的突出优点之一。逻辑回归是将因子与决策函数强制定义为对数线性，但在图中所示的结果中，效果要弱于 AdaBoost 算法。

图 2: AdaBoost 因子变换过程


MOMENTUM1P Analysis



资料来源: 国海证券研究所

图 3: 逻辑回归因子变换过程

MOMENTUM1P Analysis




资料来源: 国海证券研究所

2.4、RANK-IC 对比


Rank-IC 是用来评价 Alpha 模型预测能力优劣的重要指标之一，图 4 和图 5 分别为 AdaBoost 算法和逻辑回归算法自 2014 年以来的 Rank-IC 结果。AdaBoost 算法样本外测试结果为 Rank-IC=10.82%，IC-IR=0.8132；逻辑回归算法样本外的测试结果为 RANK-IC=10.73%，IC-IR=0.7815。两种算法的 Rank-IC 在每期数据中的表现基本相似，图中可以清晰辨别出 2014 年底连续的风格反转现象。总体来讲，AdaBoost 算法在 Rank-IC 方面表现略好，离散化的数据处理方法是较为可靠的数据处理方法。

图 4: AdaBoost 历史 Rank IC



资料来源：国海证券研究所

图 5: 逻辑回归 历史 Rank IC



资料来源：国海证券研究所

2.5、分位数组合对比

另外，分位数分组也是一个模型好坏重要的评价标准。图 6 和错误!未找到引用源。分别为 AdaBoost 算法和逻辑回归算法所得到的分位数组合净值曲线¹。两种算法中最高档组合净值都明显优于其他各档的结果。错误!未找到引用源。中多空配对和最高档最低档净值对比中也可以看到，两种算法所计算得到结果十分相近，图中蓝色线段为逻辑回归算法结果，绿色线段为 AdaBoost 算法结果，关键指标如下表所示。从多空配对组合的关键指标来看，AdaBoost 算法结果略微好于逻辑回归算法，但区别不大。

	AdaBoost			逻辑回归		
	多空组合	多头组合	空头组合	多空组合	多头组合	空头组合
累计净值	6.67	7.09	1.06	6.33	6.84	1.06
每期平均收益率	1.53%	1.75%	0.22%	1.49%	1.72%	0.23%
收益率标准差	2.90%	6.44%	5.79%	2.99%	6.40%	5.85%
胜率	72.66%	70.31%	60.94%	70.31%	71.09%	60.94%
最大回撤	16.12%	47.10%	63.18%	16.82%	47.07%	64.27%

两种算法净值的相似性也表明其分类结果近似。我们仍以 2016 年 7 月 1 日收盘之后的数据为例，进行对比。在构造股票多头组合时，我们以模型测算的最高档 10%的股票构建。2016 年 7 月 1 日，全 A 股中所选出的前 10%的股票共 218 只，AdaBoost 算法和逻辑回归算法选出相同个股数量为 148 只，占 67.88%，不同个股为 70 只，占 32.11%。其中，在不同分类的 70 只股票中，被 AdaBoost 分为第十档(最高档)的股票中，有 61 只被逻辑回归算法分为第九当(次高档)，说明两模型的判断十分相似，剩余的 9 只不一致分类的个股中，8 只股票被逻辑回归算法分为第八当，1 只股票被逻辑回归算法分为第七当，分档差距很小，这也是两个模型表现相似的主要原因。当然，两种算法的组合最优还有待考察。


表 1：AdaBoost 算法和逻辑回归算法分档对比

2016/7/1 统计	AdaBoost 算法	逻辑回归算法
第十档总数	218	218
另一算法第九档	61	53
另一算法第八档	8	12
另一算法第七档	1	4
另一算法第六档	0	1
不一致总数	70	70

资料来源：国海证券研究所


¹ 注：这里分位数净值组合是没有交易成本、交易时间点、停牌等因素影响的组合，其结果高于真实回测。

图 6: AdaBoost 算法分位数组的历史走势




资料来源：国海证券研究所

图 7: 逻辑回归算法分位数组的历史走势



资料来源：国海证券研究所

图 8: 逻辑回归算法和 AdaBoost 算法多空组合净值走势对比




资料来源: 国海证券研究所

2.6、因子筛选

接下来,我们看一下模型选择因子的结果。逻辑回归的因子选择比较直观,可以通过回归系数的显著程度进行筛选,而且可以通过系数的正负号直接看出因子与预测概率之间的单调关系,但其劣势是只能通过显著性选择因子去留,却不能直接体现因子之间的相对重要程度(本文采用 97.5%为置信区间)。相对而言,AdaBoost 算法通过弱分类器选择各因子频率和各弱分类的权重得到因子的重要程度,其缺点是,虽然我们可以直接看出因子之间的相对重要性,但是要通过检测才能知道因子与预测概率之间的关系,不适合直观理解。图 9 和图 10 分别为 AdaBoost 算法和逻辑回归算法中自 2014 年初以来因子选择结果的热图。在图 9 中,我们可以通过颜色深浅直观的看到那些因子在哪些时间段的重要性。比如,在 2014 年 9 月与之前 Illiquidity 因子和动量因子在模型中扮演者非常重要的作用,


而在此之后, Illiquidity 的作用逐渐淡化, 交易量的 20 日均值开始起到主导作用, 同时 20 日均线 and 动量因子也扮演者重要的角色, 最近几个月, 动量因子的作用更为明显。相对于技术类因子, 总市值对数因子也长期体现其重要性, 其它类型因子在模型中的重要程度相对较弱。对比逻辑回归模型, 由于本文中, 逻辑回归模型采用因子 p 值作为显著性评价标准, 我们只进行取舍, 不判断相对强弱。图中仍然可以看到, 技术类因子和规模因子在模型中长期显著。从结果来看, 模型对因子的选择性也具有相似性。

图 9: AdaBoost 算法因子选择热图



资料来源: 国海证券研究所

图 10: 逻辑回归算法因子选择热图



资料来源：国海证券研究所

下面我们以 2016 年 7 月 1 日及之前 50 周的数据作为例子训练模型并进行比较。
以 $p=97.5\%$ 为阈值，从逻辑回归中选出 10 个因子中有 8 个因子排在 AdaBoost 算法重要因子的前 10 位，结果较为相似。

AdaBoost		逻辑回归		
因子	相对重要程度	因子	P-Val	系数
x_MOMENTUM1P	0.1740	x_MACD	1.0000	-0.0607
x_LCAP	0.1601	x_DAVOL20	1.0000	-0.0583
x_ILLIQUIDITY	0.1396	x_MOMENTUM1P	1.0000	-0.0883
x_MACD	0.0727	x_LCAP	1.0000	-0.1682
x_ROA	0.0690	x_ROA	1.0000	0.0610
x_TVMA20	0.0526	x_MA20	0.9998	0.0331
x_DAVOL20	0.0525	x_TVMA20	0.9995	-0.0568
x_MA20	0.0433	x_NetProfitGrowRate	0.9993	0.0268
x_ROE	0.0414	x_LongTermDebtToAsset	0.9991	-0.0231
x_NetProfitGrowRate	0.0380	x_VOL20	0.9980	-0.0296
x_VOL20	0.0296	x_NetAssetGrowRate	0.9648	0.0182
x_PCF	0.0266	x_ROE	0.9614	-0.0339
x_LongTermDebtToAsset	0.0228	x_PCF	0.8747	-0.0105
x_EPS	0.0203	x_ILLIQUIDITY	0.8363	0.0223
x_PS	0.0164	x_PB	0.8200	-0.0138
x_PB	0.0149	x_EPS	0.7032	0.0114
x_NetAssetGrowRate	0.0134	x_PE	0.6937	-0.0079
x_PE	0.0129	x_PS	0.6295	0.0079

3、国海研究 Alpha 选股策略

在前一节中，我们针对模型的理论性质做了深入的实证分析。本节中我们根据模型的结果构造 Alpha 投资组合，并展示回测结果。回测过程中，与前一节中的数据处理方式一致，我们将每期横截面数据的因子五档划分，收益率数据前 30% 和后 30% 作为高低两组，每个调仓周期利用前一年的数据进行模型训练并预测下一期选股结果。本节中，我们介绍两个投资组合的表现，分别是全 A 选股策略和沪深 300 选股策略。全 A 选股策略对应较高的风险承受能力，而沪深 300 对应较低的风险承受能力。2016 年初以来，以中证 500 为对冲基准的全 A 选股策略超额组合净值为 1.2082，最大回撤仅为 3.01%，日回报的年化平均值为 33.07%，波动率为 6.22%；以沪深 300 为对冲基准的沪深 300 选股策略超额组合净值为 1.0384，最大回撤仅为 2.13%，日回报的年化平均值为 6.68%，波动率为 5.03%。另外，由于我们在组合中按周调仓，交易成本的影响十分明显，以单边 0.3% 为例，2016 年以来，全 A 选股策略的超额收益为 20.82%，相比于无手续费的回测结果（24.11%）下降 3.29%；沪深 300 组合超额收益 3.84%，相比于无手续费回测结果（6.02%）下降 2.18%。

3.1、股票多头-全 A 选股²

在全 A 选股的股票多头策略中，我们以中证 500 为基准，以全 A 股为选股池，选取模型预测前 10% 个股按周度调仓，回测过程中我们以等权配置，不进行行业中性处理，交易费率采用单边 0.3%。

图 11：全 A 选股策略收益率




资料来源：国海证券研究所

2014 年初以来，超额组合净值为 3.998，最大回撤为 32.69%，回报的年化平均值为 55.19%，波动率为 23.49%。如图 12 所示，超额组合的最大回撤是在 2015 年 6 月股灾之后出现。而 2016 年初以来，如图 13 所示，超额组合净值为 1.2082，最大回撤仅为 3.01%，日回报的年化平均值为 33.07%，波动率为 6.22%。


² 具体结果请参见万得组合管理中的国海研究量化组合二号 2016

图 12: 全 A 选股策略较基准超额净值



资料来源：国海证券研究所

图 13: 2016 年年初以来全 A 选股策略较基准超额净值



资料来源：国海证券研究所

3.2、股票多头-沪深 300 选股³

在沪深 300 选股的股票多头策略中，我们以沪深 300 为基准，以沪深 300 为选股池，采取相对于沪深 300 行业市值中性做法，选取行业内模型预测前 30% 个股，行业之间按行业市值加权，行业内部按个股市值加权，按周度调仓，另一条件是如果模型预测个股为弱势股，即使该股为行业内前 30% 个股也不进行配置，相应资金归为为现金池，回测过程中按周调仓，交易费率采用单边 0.3%。

图 14: 沪深 300 选股策略收益率


³具体结果请参见万得组合管理中的国海研究量化组合一号 2016



资料来源：国海证券研究所


2014 年初以来，超额组合净值为 1.3668，最大回撤为 8.07%，日回报的年化平均值为 12.34%，波动率为 10.37%。如图 15 所示，超额组合的显著回撤主要出现在三个时间段，2015 年初相对于 2014 年底、2015 年 6 月到 9 月相对于 6 月最高点和 2016 年年初相对于 2015 年底股灾之前的高点。而 2016 年初以来，如图 16 所示，超额组合净值为 1.0384，最大回撤仅为 2.13%，日回报的年化平均值为 6.68%，波动率为 5.03%。

图 15：沪深 300 选股策略较基准超额净值



资料来源：国海证券研究所

图 16：2016 年年初以来沪深 300 选股策略较基准超额净值



资料来源：国海证券研究所

4、未来展望

我们将会在未来以周报的形式及时跟踪上节中所构建的两个投资组合表现。在模型方面，值得研究的方面还很多，如，数据预处理的方法、多分档分类、模型组合结果等，我们会在接下来的系列报告中进行探讨。机器学习的分类算法只是目前较为流行的算法之一，在其它领域中广泛应用并取得成功的技术及算法众多，我们也会在未来的研究中尝试更多的优秀成果，来应用到多因子选股策略中。

5、风险提示

模型结果仅代表统计意义上的结论，不能保证未来实现，希望投资者在实践中结合多方面的信息作出投资决策。

【金融工程研究小组介绍】

代鹏举，上海交通大学硕士，8年证券行业从业经历，目前负责化工行业和中小市值研究。

田悦，理学硕士，3年海外投行金融工程工作经历，1年保险机构资产管理工作经历，目前主要负责金融工程量化研究。

【分析师承诺】

代鹏举，本人具有中国证券业协会授予的证券投资咨询执业资格并注册为证券分析师，以勤勉的职业态度，独立、客观地出具本报告。本报告清晰准确地反映了本人的研究观点。本人不曾因，不因，也将不会因本报告中的具体推荐意见或观点而直接或间接收到任何形式的补偿。

【国海证券投资评级标准】

行业投资评级

推荐：行业基本面向好，行业指数领先沪深300指数；

中性：行业基本面稳定，行业指数跟随沪深300指数；

回避：行业基本面向淡，行业指数落后沪深300指数。

股票投资评级

买入：相对沪深300指数涨幅20%以上；

增持：相对沪深300指数涨幅介于10%~20%之间；

中性：相对沪深300指数涨幅介于-10%~10%之间；

卖出：相对沪深300指数跌幅10%以上。

【免责声明】

本报告仅供国海证券股份有限公司（简称“本公司”）的客户使用。本公司不会因接收人收到本报告而视其为客户。客户应当认识到有关本报告的短信提示、电话推荐等只是研究观点的简要沟通，需以本公司的完整报告为准，本公司接受客户的后续问询。

本公司具有中国证监会许可的证券投资咨询业务资格。本报告中的信息均来源于公开资料及合法获得的相关内部外部报告资料，本公司对这些信息的准确性及完整性不作任何保证，不保证其中的信息已做最新变更，也不保证相关的建议不会发生任何变更。本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的的价格、价值及投资收入可能会波动。在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。报告中的内容和意见仅供参考，在任何情况下，本报告中所表达的意见并不构成对所述证券买卖的出价和征价。本公司及其本公司员工对使用本报告及其内容所引发的任何直接或间接损失概不负责。本公司或关联机构可能会持有报告中所提到的公司所发行的证券头寸并进行交易，还可能为这些公司提供或争取提供投资银行、财务顾问或者金融产品等服务。本公司在知晓范围内依法合规地履行披露义务。

【风险提示】

市场有风险，投资需谨慎。投资者不应将本报告为作出投资决策的惟一参考因素，亦不应认为本报告可以取代自己的判断。在决定投资前，如有需要，投资者务必向本公司或其他专业人士咨询并谨慎决策。在任何情况下，本报告中的信息或所表述的意见均不构成对任何人的投资建议。投资者务必注意，其据此做出的任何投资决策与本公司、本公司员工或者关联机构无关。

若本公司以外的其他机构（以下简称“该机构”）发送本报告，则由该机构独自为此发送行为负责。通过此途径获得本报告的投资者应自行联系该机构以要求获悉更详细信息。本报告不构成本公司向该机构之客户提供的投资建议。

任何形式的分享证券投资收益或者分担证券投资损失的书面或口头承诺均为无效。本公司、本公司员工或者关联机构亦不为该机构之客户因使用本报告或报告所载内容引起的任何损失承担任何责任。

【郑重声明】

本报告版权归国海证券所有。未经本公司的明确书面特别授权或协议约定，除法律规定的情况外，任何人不得对本报告的任何内容进行发布、复制、编辑、改编、转载、播放、展示或以其他方式非法使用本报告的部分或者全部内容，否则均构成对本公司版权的侵害，本公司有权依法追究其法律责任。