



金融工程专题报告

证券分析师

肖承志

资格编号: S0120521080003

邮箱: xiaocz@tebon.com.cn

研究助理

相关研究

1. 《云销雨霁，尚待黎明——

德邦金工中期策略报告》，2021.8.24

机器学习因子：在线性因子模型中捕获非线性

——德邦金工文献精译第一期

投资要点：

- **证券收益与风格因子之间不止存在线性关系。**本文的研究表明，在因子与收益的线性关系之外，还有很强的待挖掘的非线性关系。
- **机器学习算法可以用于挖掘非线性关系。**因子与收益之间的非线性关系可能是复杂函数，而用机器学习算法可以高效地对这种非线性关系进行建模、近似。
- **在线性回归模型的基础上叠加机器学习模型，以残差训练它。**线性模型是具有明显含义且相对容易理解的部分。我们保留线性模型的这一优势，用机器学习模型拟合线性回归的残差。
- **机器学习的训练数据需要进行筛选和处理。**训练机器学习模型时，需要选择正确的回顾期和频率。尤其重要的是，输入的回报数据需要进行标准化处理。
- **采用集成模型的方法降低噪音和提取信号。**由于回报数据的低信噪比，机器学习模型总是在拟合信号的同时拟合了噪音，论文通过训练多个机器学习模型，再计算模型预测的平均值，以尽可能消除噪音、提取信号。
- **检查机器学习模型输出因子与其他风格因子的线性相关性。**论文计算了机器学习因子和其他风格因子之间的线性相关系数，发现其绝对值都很小，这表明了机器学习因子的非线性特征。
- **打开机器学习模型的黑箱。**机器学习的软肋之一是其黑箱特征，故其作用机制难以理解。论文通过分析各个风格因子对机器学习输出的影响来推测机器学习的输出逻辑和衡量各个风格因子的非线性贡献。论文衡量了各个风格因子的特征重要性以及风格因子两两之间的交互作用。
- **单独回测机器学习因子。**论文把机器学习因子作为一个选股因子，单独回测其历史表现，这个因子在 1998 年至 2020 年间产生了约 500% 的多空收益回报。这证明了因子的强选股能力。
- **联合回测机器学习因子和风格因子。**论文将机器学习因子插入到风格因子当中，用多因子的方法回测这些因子历史表现。投资组合在 1998 年至 2020 年间产生了超过 80% 的回报。
- **因子表现统计。**论文统计了所有风格因子与机器学习因子的表现，包括 t 值、回报、波动率、信息比率、R 平方、最大回撤、方差膨胀因子 VIF、月自相关系数等，多数统计量表明，机器学习因子是最强的选股因子。
- **机器学习因子选股能力归因。**论文的作者推断，机器学习因子的强大选股能力来源于很多风格因子的非线性选股效应的累积。
- **风险提示：**海外市场波动风险，宏观数据、政策变化风险，模型失效风险



内容目录

1. 前言	4
2. 执行摘要	4
3. 介绍	4
4. 方法	5
5. 结果	6
5.1. 比较机器学习算法	6
5.2. 模型稳定性	8
5.3. 打开黑箱	9
5.4. 交互效应	12
5.5. 样本外表现	13
6. 结论	16
7. 参考文献	17
8. 附录 - 使用的 ML 算法描述	17
9. 风险提示	18
信息披露	20

图目录

图 1: 机器学习模型性能与模型复杂性	7
图 2: 随着时间的推移集成机器学习模型性能	7
图 3: 机器学习预测的相关性	8
图 4: 机器学习因子暴露稳定性	8
图 5: 特征重要性	9
图 6: 特征重要性的相关性	10
图 7: 神经网络模型的部分依赖	10
图 8: 流动性和动量的因变量部分依赖曲线, 三种模型	11
图 9: 互动强度	12
图 10: 动量与规模的交互	12
图 11: ML 因子暴露与 GEMTR 样式的平均相关性	13
图 12: ML 因子暴露与 GEMTR 样式的平均相关性	14
图 13: ML Factor 的全样本十分位数投资组合性能	15
图 14: ML 因子的全样本多变量因子回归	16
图 15: GEMTR 样式和 ML 因子的因子统计	16

1. 前言

这篇报告是我们德邦证券金融工程团队文献精译的第一期。原论文的标题是《Machine Learning Factors: Capturing Nonlinearities in Linear Factor Models》，作者是 George Bonne, Jun Wang 和 Howard Zhang。这篇论文主要介绍了一种利用非线性模型来提高传统线性回归模型的方法。论文的作者首先利用风格因子的线性回归来解释证券的回报并得到拟合残差，随后用残差拟合机器学习非线性模型。结果表明，机器学习非线性因子具有极强的选股能力。作者尝试对非线性模型收益的来源做了解释。作者分析了非线性模型的性质、非线性因子与风格因子的相关性、各个风格因子对于机器学习因子的影响程度以及风格因子的交互作用效果，而这一系列的分析都是为了打开机器学习的“黑箱”，看到它起作用的本质的原因。

2. 执行摘要

机器学习 (ML) 在近年来受到了许多领域越来越多的关注，尽管机器学习已经存在了几十年了。机器学习在金融领域中被大量应用于资产的回报的解释和预测。虽然线性因子模型一直是理解投资组合的风险暴露、风险和收益的主流模型，但是因子风险暴露和回报之间是否真的只存在线性关系，是值得怀疑的。在这里，我们研究了 ML 算法可以在多大程度上检测在线性分量被移除后因子暴露和证券收益之间的关系中的显著非线性和相互作用。

我们之前已经使用简单的技术表明，因子暴露和证券收益之间可能存在非线性关系，特别是对于动量、流动性因子以及在剧烈波动的市场环境下 (Wang、Yao 和 Bonne, 2020 年)。

在这项研究中，我们发现 ML 算法可以识别非线性关系，并且可以用来构建一个具有显著解释力的因子。我们还确定了几个关键要素，这些要素显著影响了 ML 算法解释证券收益横截面的能力，包括对自变量和因变量的标准化，以及将许多 ML 模型的输出的信号的均值作为最终输出的方法。

为了更好地理解机器学习作为一个在黑箱在模型当中扮演的角色，我们定义了因变量部分依赖曲线、特征重要性和交互效应。我们发现流动性和动量因子对 ML 模型的输出影响最大，并且它们的影响也与我们之前的研究一致。此外，我们发现因子之间的相互作用对 ML 模型的输出有显著影响。

我们将我们的 ML 因子作为 MSCI Barra 全球股票交易模型 (GEMTR, Morozov 等, 2016) 中的一个附加因子进行评估，发现它在 1998-2020 年的所有 GEMTR 风格中产生了最强的信息比率 (IR) 和因子回报。我们认为 ML 因子的强大而稳定的性能是通过在单因子中集成众多因子的非线性效应而获得的。

我们相信，使用 ML 技术构建的因子对于多头和多空投资组合的投资组合构建过程都很有价值，并将帮助投资者理解和捕捉非线性和相互作用对业绩的影响。

3. 介绍

多年来，线性因子模型已被广泛用于理解投资组合风险和回报 (Rosenberg, 1974)。此类模型中的大多数因子 (例如 GEMTR) 都是基于基本和直观的公司特

征构建的，例如行业成员资格、估值或其他财务比率、价格回报或波动率，甚至非线性变换（例如，对数或立方）的基本指标。其他因子已使用统计技术构建，例如缺乏直观解释的主成分分析。然后将所得因子合并到一个线性模型中，该模型假设因子暴露和证券收益之间的关系是线性的。该假设允许非常可解释且计算效率高的模型，但可能无法捕捉因子之间的非线性关系或相互作用。

机器学习算法擅长拟合变量之间的复杂关系和相互作用，而且它们也已经存在了几十年。例如，Breiman (1984) 描述了一般的基于树的方法，此后这些方法已被套袋法 (bagging) 和增强 (boosting) 等技术增强 (Friedman, 2001)。第一个人工神经网络由心理学家 Frank Rosenblatt 于 1958 年发明，此后这些算法在图像识别、蛋白质折叠和语言翻译等多个领域取得了成功。最近，人们对 ML 在金融方面的应用产生了浓厚的兴趣，尤其是在资产回报方面。例如，参见 Gu、Kelly 和 Xiu (2020)；Dixon and Polson (2019)；Aw, Jiang 和 Jiang (2019)。

然而，如果使用的数据包含很少的信号和大量的噪声，ML 在拟合复杂模式方面的优势也可能是一个弱点，就像资产回报的情况一样。在这种情况下，ML 模型最终可能拟合的噪声多于信号。尽管如此，Lopez de Prado (2018) 和 Rasekhschaffe (2019) 等其他人士提出了在金融应用程序中使用机器学习的框架和最好的实践，同时最大限度地减少过度拟合的风险。我们在研究中采用了许多这些技术。

与 Rasekhschaffe (2019) 一致，我们的研究还表明，在将 ML 模型应用于资产回报所取得的成功水平中，存在一些细微差别。这些细微差别包括特征工程（原始输入特征的标准化或转换）、因变量的标准化或分组以及多个 ML 模型预测的集成平均。

ML 技术的另一个陷阱是它们的黑箱性质。一个新的可解释机器学习领域已经出现，以减轻这一劣势。Li (2020) 在汇率预测研究中利用可解释 ML 技术将模型预测分解为线性、非线性和交互作用这三个部分。我们使用了类似的方法来观察黑箱内部。

在使用 ML 来识别非线性关系时，我们调查了各种 ML 模型在资产回报上沿多个维度训练的敏感性，包括复杂性参数、输入特征的重要性、因变量的缩放、训练窗口和集成方法。在接下来的部分中，我们将检查这些敏感性以及由此产生的 ML 因子的性能、它们的稳定性以及与传统因子的相关性。

4. 方法

我们的基准模型用 GEMTR 的 22 个风格因子¹暴露作为 ML 算法的输入。风格因子暴露都被标准化²到大约 $[-3, 3]$ 的区间内。我们还探讨了添加更多输入特征，例如行业和国家因子暴露以及其他风格因子或通过运算符构建的因子。我们将因变量设置为下个月的标准化残差收益率，即考虑剔除所有因子的线性贡献后的那部分无法被解释的收益。换句话说，我们训练一个 ML 模型，以使用风格因子暴露作为输入来预测下个月的残差收益率。因此，我们明确指示 ML 模型捕获线性模型在其残差中留下的非线性成分。这与其他主要使用总回报作为因变量的研究有显著差异。我们的框架使我们能够保持线性模型和因子的可解释性，同时利用

¹ GEMTR 二十二风格因子的详细描述见 Morozov et al., 2016

² 处理异常值后，每日计算每个因子减去市值加权平均值后除以 MSCI ACWI IMI 中所有股票的等加权标准差

ML 仅捕获线性模型遗漏的非线性和交互效应。在数学上，我们的 ML 因子可以表示如下，从基本的线性因子模型方程开始：

$$R=Xf+\varepsilon$$

其中 R 是股票收益率向量， X 是所有股票的因子暴露矩阵， f 是通过回归估计的因子收益向量， ε 是特定股票收益的向量。我们的 ML 因子是所有风格因子暴露的线性函数， $G(X)$ ，旨在解释 ε 。因此，

$$\varepsilon=G(X)g+\varepsilon'$$

其中 $G(X)$ 是 ML 因子暴露， g 是 ML 因子回报， ε' 是新的特质回报。结合这两个方程，我们得到：

$$R=Xf+G(X)g+\varepsilon'$$

虽然所描述的框架使用特质回报作为因变量，但我们还探索了因变量的其他变体——总回报与特质回报以及标准化回报与原始回报——发现我们的结果在很大程度上取决于因变量的标准化。在对因变量进行横截面标准化后，我们取得了远远优于使用原始回报的性能。在标准化特质回报与原始回报时，我们也取得了更好的表现。鉴于我们的目标是确定线性因子模型未捕获的回报成分，这些发现与我们的直觉一致。为简明起见，显示的所有结果均使用标准化特质回报作为因变量，并在回归模式下使用 ML 算法获得。

我们的完整样本期是 1995 年 1 月到 2020 年 12 月，我们将其分为两部分——1995 年 1 月到 2007 年 12 月进行模型调整，2008 年 1 月到 2020 年 12 月进行测试。我们在滚动训练框架中进行了调整和测试，在该框架中，我们利用一组固定回顾期（五年）训练了一个模型，并在未来的两年使用这个模型。两年期满后，用新的回顾期的数据集进行训练，并进行后续预测，以此类推。我们将模型在给定时间段内的所有预测视为一个新的因子，并在单因子十分位数投资组合框架和多因子框架中评估它们的表现，在多因子框架中，我们将 ML 因子添加到 GEMTR 中的其他因子当中。

我们测试的 ML 算法包括提升树、随机森林和神经网络，这些模型在预测问题中比较常见。我们在附录中提供了每个和其他 ML 术语的简要说明。感兴趣的读者请参阅 Hastie, Tibshirani 和 Friedman (2009) 来获取更详细的阐述，其中，对我们使用的所有 ML 方法以及其他方法都有详细介绍。

我们对训练数据样本上的 ML 算法进行了调整。对于提升树，我们调整了学习率、树深度和树的数量。对于随机森林，我们调整了树的深度和在给定树节点上使用的特征的比例以及树的数量。对于神经网络，我们调整了网络大小（隐藏层和节点的数量）、学习率和激发函数。


5. 结果

5.1. 比较机器学习算法

我们评估了三种 ML 算法，其中包含 5 年的训练数据回顾窗口，并每两年重

新训练一次模型。在下面的图 1 中，我们显示了由结果预测的信息系数³ (IC) 衡量的性能。对于每个学习算法，我们将性能绘制为主要调整或复杂性参数之一的函数，通过对给定算法评估的最小复杂性进行归一化，以将它们放在可比较的范围内。因为我们观察到在我们评估的所有复杂度水平上的积极性能，我们还展示了每个算法的集成模型的性能，它只是来自每个复杂度等于或低于给定模型的所有模型的预测的等加权平均值。

图 1：机器学习模型性能与模型复杂性




资料来源：MSCI，德邦研究所

注：对于神经网络，复杂度由隐藏节点的数量定义，单个隐藏层网络中最少有八个节点。对于提升树，复杂度由树深度定义，最小为两个。对于随机森林，复杂度由树的数量定义，最小为 50。对于每个算法，归一化复杂度定义为复杂度参数值除以评估的最小值。例如，神经网络的归一化复杂度 10 对应于具有 80 个隐藏节点的神经网络模型——8 个节点的最小复杂度的 10 倍。给定归一化复杂度级别的集成模型由所有与给定级别相同或更低复杂度的模型的预测的等加权平均值定义。样本期为 1995 年至 2007 年。

我们做了几个有趣的观察。首先，我们看到集成模型的性能在我们对更多模型的输出进行平均时仅略微改善或下降，即单个模型的性能随着复杂性的增加而大幅下降。其次，我们从每个算法的各种复杂性模型中观察到了积极和相似的性能。第三，我们发现神经网络模型有最强的表现。为了将集成概念更进一步，我们创建了一个集成的集成——三种算法平均值的平均值。在图 2 中，我们绘制了每个算法的集成以及集成的集成随时间变化的性能。我们看到集成的集成与神经网络集成的表现相似，而年化收益率的十分位数约为 18%。

图 2：随着时间的推移集成机器学习模型性能



³ 信息系数定义为信号（ML 模型预测）与下个月股票收益的秩相关系数，它衡量信号区分未来表现优异者和表现不佳者的能力。

资料来源：MSCI，德邦研究所

注：每个算法的集合是图 1 中所示给定算法的所有复杂级别的所有模型的平均预测。“集合的集合”是三个集合的平均值。样本包括 MSCIACWIIMI 世界中的全球证券。

鉴于各种算法的性能相似，一个自然的问题是：“他们的预测有多相似？”为了回答这个问题，图 3 显示了所测试模型的预测的平均横截面相关性。⁴从中，我们可以看到不同模型的预测来自同一算法和不同算法的相似程度。我们看到大多数算法的相关性仅为 0.35 到 0.55，鉴于图 2 中观察到的性能曲线的形状的相似性，这样相关系数可能低于人们的预期。但是，正是由于不同算法预测之间的相关性不大，而每个模型具有相似的性能，集成才可以更好地增强表现。我们认为，由于证券收益的信噪比较低，每个模型可能会拾取相似的信号和不同的随机噪声。通过集成，我们可以在平均并抑制噪声（减少方差）的同时增强信号，从而提高模型性能。

图 3：机器学习预测的相关性

	Neural Network models					Boosted Tree models					Random Forest models				
	8	16	32	64	128	Tree	Tree	Tree	Tree	Tree	50	100	200	400	800
	Nodes	Nodes	Nodes	Nodes	Nodes	Depth 2	Depth 4	Depth 8	Depth 16	Depth 32	Trees	Trees	Trees	Trees	Trees
8 Nodes		0.56	0.54	0.43	0.34	0.39	0.38	0.33	0.23	0.12	0.24	0.28	0.32	0.34	0.35
16 Nodes	0.56		0.59	0.52	0.45	0.34	0.36	0.34	0.26	0.15	0.27	0.32	0.37	0.39	0.41
32 Nodes	0.54	0.59		0.57	0.49	0.30	0.33	0.32	0.26	0.16	0.27	0.32	0.36	0.39	0.40
64 Nodes	0.43	0.52	0.57		0.54	0.26	0.29	0.30	0.26	0.17	0.27	0.32	0.36	0.39	0.40
128 Nodes	0.34	0.45	0.49	0.54		0.23	0.25	0.27	0.25	0.17	0.25	0.30	0.34	0.37	0.38
Tree Depth 2	0.39	0.34	0.30	0.26	0.23		0.82	0.56	0.27	0.10	0.30	0.34	0.38	0.43	0.44
Tree Depth 4	0.38	0.36	0.33	0.29	0.25	0.82		0.75	0.38	0.16	0.35	0.41	0.46	0.50	0.52
Tree Depth 8	0.33	0.34	0.32	0.30	0.27	0.56	0.75		0.54	0.25	0.38	0.45	0.51	0.55	0.57
Tree Depth 16	0.23	0.26	0.26	0.26	0.25	0.27	0.38	0.54		0.37	0.35	0.43	0.48	0.51	0.53
Tree Depth 32	0.12	0.15	0.16	0.17	0.17	0.10	0.16	0.25	0.37		0.28	0.34	0.39	0.41	0.43
50 Trees	0.24	0.27	0.27	0.27	0.25	0.30	0.35	0.38	0.35	0.28		0.48	0.54	0.58	0.61
100 Trees	0.28	0.32	0.32	0.32	0.30	0.34	0.41	0.45	0.43	0.34	0.48		0.64	0.69	0.72
200 Trees	0.32	0.37	0.36	0.36	0.34	0.38	0.46	0.51	0.48	0.39	0.54	0.64		0.78	0.81
400 Trees	0.34	0.39	0.39	0.39	0.37	0.43	0.50	0.55	0.51	0.41	0.58	0.69	0.78		0.88
800 Trees	0.35	0.41	0.40	0.40	0.38	0.44	0.52	0.57	0.53	0.43	0.61	0.72	0.81	0.88	

资料来源：MSCI，德邦研究所

注：来自不同复杂性的 ML 模型的预测的平均横截面相关性。MSCIACWIIMI 的样本期为 1998 年 1 月至 2007 年 12 月。


5.2. 模型稳定性

我们将模型稳定性测量为 ML 模型预测暴露的逐月自相关。在我们的训练样本期间，用作 ML 模型输入的 GEMTR 样式因子的平均每月自相关为 0.83。我们在下面的图 4 中绘制了来自图 2 的每种学习算法的集成模型预测值的稳定性。我们观察到随机森林模型的稳定性最低，而提升树的稳定性最高，神经网络仅略低于提升树。每个模型每两年重新训练一次，我们看到所有 ML 算法在重新训练日的月自相关性大幅下降。尽管如此，我们没有观察到这些日期的性能发生显著变化。这可能是因为集成模型可以平均并减少预测中的噪声或方差并提高性能。

正如（Rasekhschaffe, 2019）所建议的，通过创建一个集合模型，并让其各个模型在不同日期、不同频率和不同回溯期进行重新训练，可以大大降低重新训练日的不稳定性。

图 4：机器学习因子暴露稳定性

⁴ML 模型预测被视为原始 ML 因子暴露。



资料来源：MSCI，德邦研究所

注：机器学习因子暴露稳定性被定义为机器学习因子暴露的横截面月度自相关。集成模型来自图 2。

5.3. 打开黑箱


ML 算法的一个缺点是它们的黑箱性质。然而，有一些技术，例如部分依赖曲线和特征重要性，可以让人们对黑箱的内部有所了解。具体来说，我们以标准方式定义了部分依赖：作为给定输入值的函数的预测响应，对其他输入用平均值。⁵ 为了促进不同 ML 算法之间的比较，参考 Greenwell (2018)，我们将给定输入的特征重要性度量定义为 ML 模型输出在其部分依赖曲线中的最大变化范围。我们在图 5 中展示了三种算法的特征重要性。我们看到动量和流动性是所有三种算法中最重要的。我们还注意到，短期反转是重要性排前十的因子中唯一的高周转因子，这表明仅使用低周转因子作为输入可以创建具有几乎相同性能的 ML 因子。⁶ 我们还可以看到，最重要的是基于量价的技术因子，而基本面因子次之。

特征重要性向量的相关性很高（如下图 6 所示），表明算法检测到了类似的效果。令人惊讶的是，特征重要性的最低相关性出现在两种基于树的方法之间，尽管这两种方法在图 2 中产生了最相似的性能。

图 5：特征重要性

⁵ python 的 scikit-learn 包中部分依赖和实现的描述请参见 https://scikit-learn.org/stable/modules/partial_dependence.html

⁶ 高换手率因子包括短期反转、季节性、行业动能、新闻情绪、分析师情绪和空头兴趣。



资料来源：MSCI，德邦研究所

注：特征按平均重要性排序。每个模型都在1月的完整样本期内进行训练 1996 年至 2007 年 12 月。y 轴单位是特定回报的标准化偏差 (z 分数)。

图 6：特征重要性的相关性


	Neural Net	Boosted Trees	Random Forest
Neural Net	1	0.77	0.79
Boosted Trees	0.77	1	0.72
Random Forest	0.79	0.72	1

资料来源：MSCI，德邦研究所

注：特征按平均重要性排序。每个模型都在1月的完整样本期内进行训练 1996 年至 2007 年 12 月。y 轴单位是特定回报的标准化偏差 (z 分数)。

为便于阅读，在图 7 中，我们仅展示了神经网络模型的前十个输入的部分依赖曲线，以它们的特征重要性衡量。

图 7：神经网络模型的部分依赖




资料来源：MSCI，德邦研究所

注：神经网络模型中 10 个最重要特征的部分依赖。模型在 1996 年 1 月至 2007 年 12 月的完整样本期间进行训练。y 轴的单位是 z 分数标准化的特质回报。

我们还注意到，流动性和动量这两个最重要的特征的形状与我们在特定回报与因子暴露的单变量研究中观察到的一致 (Wang, 2020)。例如，图 7 显示 ML 算法发现动量暴露非常高(>2)的股票表现比线性模型预期的要好 (0.15 到 0.20 标准差)，而流动性暴露非常高的股票表现比线性模型差。

为了衡量算法之间的一致性，我们检查了流动性和动量的部分依赖性。如图 8 所示，我们在所有三种算法中观察到这两个因子的部分依赖曲线模式一致。我们还注意到，基于树的模型的曲线明显不如神经网络模型的曲线平滑，考虑到模型的功能形式，这是可以理解的。

图 8：流动性和动量的因变量部分依赖曲线，三种模型



资料来源：MSCI，德邦研究所

注：每个模型都在 1996 年 1 月至 2007 年 12 月的整个样本期间进行训练。我们从图 1 中选择了性能最佳的单个模型：24 节点神经网络模型、具有 800 棵树的随机森林模型、具有树深度的提升树模型共 4 个。


总体而言，鉴于我们在图 3 中观察到的不同算法的预测之间的横截面相关性相对较低，特征重要性和部分依赖性的高度相似性似乎令人惊讶。然而，我们怀疑这是不同算法识别出相似信号和不同噪音的进一步证据。我们还评估了向 ML 模型添加更多输入的影响，例如行业或国家因子。

我们发现行业和国家因子对最终的 ML 因子影响不显著，并且它们的特征重要性值非常低。我们还探索了向输入添加其他因子时的差异，并在我们用它们的组件描述符替换特征重要性尺度上的一些更强的因子 (例如流动性和剩余波动率) 时获得了改进的性能。

5.4. 交互效应

为了进一步打开黑箱，我们接下来检查了因子之间的相互作用。通过特征重要性和部分依赖，我们可以观测单个输入影响 ML 因子的方式和幅度。我们还希望了解输入之间的交互是否重要。例如，动量暴露的影响是否取决于大小暴露？基于我们对特征重要性的定义，我们将交互强度定义为在考虑单变量部分依赖后预测响应的范围（最大减去最小）。换句话说，我们改变了两个输入的值，并测量了它们的联合响应与假设没有交互作用时的预期响应有何不同——如果它们的贡献与它们的单变量部分依赖曲线完全线性相加。将 22 个因子作为输入，有 231 ($22 \times 21/2$) 种可能的双变量组合。在图 9 中，我们展示了前 20 个双变量交互，这些交互是由我们的神经网络模型的交互效应度量来衡量的。我们看到交互强度值与特征重要性值相当，表明双变量交互与单变量输入一样重要。我们还看到最强的相互作用涉及表现出很强特征重要性的因子，例如动量、流动性和规模。在图 10 中，我们展示了一个这样强相互作用的例子——动量与规模。


图 9：互动强度



资料来源：MSCI，德邦研究所

注：每个模型都在 1996 年 1 月至 2007 年 12 月的整个样本期间进行训练。我们从图 1 中选择了性能最佳的单个模型：24 节点神经网络模型、具有 800 棵树的随机森林模型、具有树深度的提升树模型共 4 个。

图 10：动量与规模的交互



资料来源：MSCI，德邦研究所

注：我们将双变量交互定义为 ML 模型的预测响应减去来自两个输入中每一个的单变量部分依赖贡献，这在等高线中绘制。


从动量-规模的相互作用中，我们看到动量响应在很大程度上取决于规模暴露，尤其是当动量暴露很小时（换句话说，过去一年表现不佳的股票）。对于动量暴露为负的小盘股，ML 模型预测它们在下个月的表现将比其低动量和其他因子暴露（红框内的区域）的预期表现更差。相比之下，该模型估计，去年表现明显落后的大盘股，其因子暴露的反弹幅度将超过预期（灰框内的区域）。一种解释可能是，资源越多，产品越多，大公司业绩不佳一年越容易扭亏为盈，但小公司资源有限，产品能力差，更难重新站起来。

5.5. 样本外表现

我们使用与之前相同的框架来检查样本外表现——使用 GEMTR 风格因子暴露作为输入，我们训练了一个 ML 模型，以使用过去五年的数据预测下个月的标准化合特定回报。为简单起见，我们在此重点介绍神经网络模型。我们构建了一个由 10 个不同复杂度的神经网络模型组成的集合，其中包含 16 到 48 个隐藏节点和不同的重新训练频率，从 3 个月到 29 个月不等，以减轻重新训练日期的不稳定性和周转率。⁷我们对预测进行平均 10 个模型，并将结果视为一个新因子。我们在标准单变量十分位数投资组合框架中检查了新 ML 因子的特征和性能，并将该因子插入 GEMTR 以评估其对 GEMTR 中所有其他因子之上的解释力的边际贡献。在下面的图 11 中，我们展示 ML 因子暴露与其他 GEMTR 类型因子的平均横截面相关性。

图 11：ML 因子暴露与 GEMTR 样式的平均相关性

⁷ 该集成包含 10 个模型，其中两个模型在单个隐藏层中分别具有 16、24、32、40 和 48 个节点，并且每 3、4、5、7、11、13、17、19、23 和 29 个月重新训练一次，以五个年训练回顾期。




资料来源：MSCI，德邦研究所

注：平均值取自 1998 年 1 月至 2020 年 12 月的整个样本期间。

我们看到，平均而言，相关性接近于零。在图 12 中，我们展示了相关性如何随时间变化，其中四个因子具有最大的平均幅度相关性。出于好奇，我们还添加了动量和 beta，这两个因子的相关性随时间变化很大，尽管它们的平均值接近于零。与动量和贝塔系数的相关性是可变的，但平均接近于零，而剩余波动率和流动性等其他相关性则具有更一致的负相关性，而收益收益率和规模则具有较小的一致正相关性。

图 12：ML 因子暴露与 GEMTR 样式的平均相关性




资料来源：MSCI，德邦研究所

注：相关性是过去 12 个月的平均值。

我们还评估了集成神经网络 ML 因子在整个样本期间的性能。在图 13 中，

我们展示了等权重十分位数投资组合和上下十分位数价差在整个样本期间的表现。我们看到十分位数投资组合的表现从十分位数 1 单调增加到 10 位数，尽管第一组的负超额比第最十组的正超额表现更显著。大部分性能来自极端的十分位数，线性模型可能也无法捕捉到。从 2008 年到 2020 年，样本外期间的十分位数利差（复合年化收益率为 34.4%）明显大于样本内期间（19.7%）。

图 13: ML Factor 的全样本十分位数投资组合性能




资料来源：MSCI，德邦研究所

注：相关性是过去 12 个月的平均值。

我们还在多变量框架中评估了性能，在该框架中我们将 ML 因子添加到 GEMTR 模型并测量其因子回报和对模型解释力的贡献。在图 14 中，我们显示了累积因子回报。我们在样本内和样本外都看到了强劲的表现，尽管样本内的因子回报更强。在图 15 中，我们显示了整个样本期间 GEMTR 中所有风格因子的 ML 因子的统计数据。在此期间，ML 因子在 GEMTR 中的任何因子中具有最高的 IR 和因子回报，尽管它对解释力的以交叉验证的 R2 衡量的贡献仅在 23 个因子中排名第七。这可能是由于 ML 因子的波动性相对较低，有助于提升其 IR。总体而言，因子统计表明 ML 因子具有一些更像 alpha 的特征，有些更像传统的风险因子。我们假设它是一个奖励因子，因为它捕获了许多非线性关系，每一个都微妙且难以单独识别和捕获，但是当加在一起时会产生强大的组合。同样，我们假设图 14 中显示的几乎“好得令人难以置信”的表现是由捕获许多非线性效应的多样化优势驱动的，每个非线性效应本身都很小，但当组合成一个因子时，产生了强大而一致的表现。

图 14: ML 因子的全样本多变量因子回归



资料来源: MSCI, 德邦研究所

注: 相关性是过去 12 个月的平均值。

图 15: GEMTR 样式和 ML 因子的因子统计

Factor	Avg t	% t >2	Return (%)	Volatility (%)	IR	CV R ² Gain (bps)	Max Drawdown (%)	VIF	Monthly Auto Correl.
Beta	6.9	81.8	0.02	5.5	0.00	40.8	38.4	3.1	0.98
Momentum	6.4	78.5	3.04	4.3	0.71	37.1	21.6	2.0	0.92
Size	4.8	72.4	-0.49	2.4	-0.21	21.9	22.9	2.6	1.00
Short-Term Reversal	4.2	68.0	2.30	2.4	0.98	16.9	4.0	1.0	0.18
Residual Volatility	4.2	69.5	-1.49	3.0	-0.50	14.8	45.4	2.3	0.97
Liquidity	3.4	59.6	-0.42	2.3	-0.19	9.5	18.2	1.6	0.98
ML Factor	3.3	71.5	3.82	0.9	4.23	6.5	0.9	1.2	0.70
Earnings Yield	2.8	53.8	1.58	2.1	0.77	6.2	7.7	1.9	0.96
Book-to-Price Ratio	2.5	53.8	1.62	1.7	0.97	4.0	5.7	2.2	0.98
Industry Momentum	2.4	49.1	2.32	0.9	2.59	3.6	0.4	1.0	0.53
Analysts Sentiment	2.4	53.8	1.41	1.1	1.32	3.2	3.0	1.0	0.79
Mid Capitalization	2.2	46.2	0.14	1.4	0.10	3.2	4.9	1.3	0.99
Long-Term Reversal	2.3	48.4	1.26	1.5	0.85	3.0	6.4	1.8	0.95
Leverage	2.2	42.5	0.02	1.4	0.01	2.7	7.6	1.8	0.99
Dividend Yield	2.1	39.6	0.50	1.3	0.39	2.6	5.5	1.8	0.98
Earnings Variability	2.1	43.3	-0.41	1.3	-0.32	2.2	13.7	1.9	0.96
Short Interest	2.1	45.0	-0.96	1.0	-0.93	2.2	15.1	1.0	0.84
Profitability	2.0	42.5	1.37	1.2	1.13	1.4	2.6	2.3	0.99
Investment Quality	2.0	41.5	1.08	0.9	1.21	1.4	2.7	1.4	0.98
Seasonality	1.9	38.5	0.59	0.7	0.83	1.3	7.8	1.0	0.11
Growth	1.9	37.5	0.82	1.2	0.69	1.3	3.8	1.4	0.95
Earnings Quality	1.6	33.5	1.09	0.8	1.41	0.2	1.4	1.6	0.96
News Sentiment	1.1	11.5	0.33	0.5	0.68	-0.5	1.0	1.0	0.33

资料来源: MSCI, 德邦研究所

注: 相关性是过去 12 个月的平均值。

6. 结论

在我们之前的工作 (Wang, 2020) 中, 我们确定了在某些市场条件下, 风格因子风险暴露与证券收益之间的关系存在轻微非线性, 尤其是动量和流动性。在这项研究中, 我们发现 ML 算法还可以识别线性因子模型未捕获的因子风险暴露和证券收益之间的非线性关系。此外, 不同的学习算法似乎在很大程度上捕获了相同的非线性关系, 他们发现的关系与我们在之前使用简单技术的工作中观察到的关系一致。在这里, 我们使用解释性 ML 的方法来深入了解 ML 模型捕获的重要关系。我们再次发现, 从单变量的角度来看, 动量和流动性是最重要的因子。双变量相互作用, 尤其是动量、流动性和其他几个重要因子 (如 beta 和规模), 也

是 ML 模型预测的重要贡献者。

我们发现 ML 模型可用于创建一个因子，为证券收益的横截面增加适度的解释力。由此产生的 ML 因子与 GEMTR 中现有的风格因子的相关性较低，并且在 GEMTR 中所有风格因子的 IR 和因子回报最高。此外，我们发现一些技术，如标准化因变量和集成平均，显著提高了因子的性能。在不同日期对集成中的模型进行集成平均和重新训练也使该因子对 ML 模型的复杂性参数不那么敏感，并且从一个时期到下一个时期更加稳定。

我们相信使用 ML 技术构建的非线性因子是对投资者投资组合构建过程的宝贵补充。

7. 参考文献

- [1] Aw, E., Jiang, J., and Jiang, J. Q. 2019. "The Rise of the Machines: Factor Investing with Artificial Neural Networks and the Cross-Section of Expected Stock Returns." *Journal of Investing* 28: 1–12.
- [2] Breiman, L., Friedman, J., Stone, C., and Olshen, R. 1984. "Classification and Regression Trees." Boca Raton, FL: *Chapman & Hall/CRC*.
- [3] Dixon, M. and Polson, N. 2019. "Deep Fundamental Factor Models."
- [4] Friedman, J. 2001. "Greedy Function Approximation: A Gradient Boosting Machine," *Annals of Statistics* 29: 1189-1232.
- [5] Greenwell, B.M., Boehmke, B., and McCarthy, A. 2018. "A Simple and Effective Model-Based Variable Importance Measure."
- [6] Gu, S., Kelly, B., and Xiu, D. 2020. "Empirical Asset Pricing via Machine Learning." *Review of Financial Studies* 33: 2223-2273.
- [7] Hastie, T., Tibshirani, R., and Friedman, J. 2009. "The Elements of Statistical Learning." New York, *Springer Science + Business Media LLC*.
- [8] Li, Y., Turkington, D. and Yazdani, A. 2020. "Beyond the Black Box: An Intuitive Approach to Investment Prediction with Machine Learning." *Journal of Financial Data Science*. 2: 1-15.
- [9] Lopez de Prado, M. 2018. "Advances in Financial Machine Learning." Hoboken, NJ: *John Wiley & Sons Inc.*
- [10] Morozov, A., Minovitsky, S., Wang, J., and Yao, J. 2016. "Barra Global Total Market Equity Trading Model." *MSCI Model Insight*.
- [11] Rasekhschaffe, K. and Jones, R. 2019. "Machine Learning for Stock Selection." *Financial Analysts Journal*. 75: 70-88.
- [12] Rosenberg, B. 1974. "Extra-Market Components of Covariance in Security Returns." *The Journal of Financial and Quantitative Analysis* 9: 263-274.
- [13] Wang, J., Yao, J., and Bonne, G. 2020, "Straight Talk on Nonlinearities in Linear Factor Models." *MSCI Research Insight*.

8. 附录 - 使用的 ML 算法描述

神经网络 - 也称为人工神经网络, 这种 ML 算法松散地基于动物大脑中神经元的功能和连通性。神经网络由排列在一个或多个层中的“神经元”或节点的集合组成。第一层神经元连接到输入变量并产生一个输出, 该输出是其总输入的函数或通过“激活”函数进行转换, 该函数通常是分段线性 (例如, ReLU)、sigmoid 或其他函数。如果输入超过阈值, 神经元将“激发”或产生输出。根据网络中有多少层神经元, 第一层神经元的输出可以作为第二层神经元的输入, 或者在单层网络的情况下, 聚合起来产生网络的最终结果反应或预测。深度神经网络包含两层或多层神经元。给定网络中足够的复杂性 (节点和层), 神经网络可以拟合任意复杂函数。神经网络对输入变量和输入或因变量中的异常值很敏感。神经网络的重要参数是节点数、层数、学习率和激活函数。

决策树-也称为二叉决策树, 这是一种基于数据集顺序拆分的学习算法, 其中该算法将输入空间拆分为一组矩形, 每个拆分 (树的决策节点) 基于输入变量之一的值。选择每个拆分以对所选损失函数进行最大改进, 这使得算法“贪婪”, 因为在每次拆分时, 它只选择在该点看起来最好的。对新数据点的预测是通过在树的每个节点上遵循决策规则来确定的, 直到在树的终端叶子处结束。对落在给定终端叶子中的任何数据点的预测由一个简单的函数给出, 通常只是一个常数, 由该叶子中训练数据的平均值给出。因此, 简单决策树的函数形式是所有分段常数函数的集合。基于决策树的算法 (例如随机森林和提升树) 的理想特征是决策树可以无缝处理所有类型的变量 (分类、秩或连续实值), 并且该算法对单调变换 (例如缩放) 保持不变输入变量, 因此输入数据中的异常值没有问题。单一的小型决策树也很容易解释。缺点是与其他算法相比, 单决策树很容易过拟合, 具有高方差, 并且通常表现出较差的样本外性能。Boosting (用于 boosted 树) 和 bagging (用于随机森林) 是用于通过组合许多树来提高性能的技术 - 通过 boosting 串联或通过装袋。组合许多树通常会显著提高其预测准确性, 但会牺牲单个 (小) 决策树的简单可解释性。

提升树 - 也称为梯度提升树, 这是一种基于决策树的 ML 算法, 由一组小型决策树组成, 每个决策树都是弱或“基础”学习器。该模型以迭代方式拟合数据, 一次一个基学习器, 每个学习器都拟合上一次迭代的残差或误差。这个迭代过程称为 boosting。这样做时, 算法沿着给定损失函数的梯度移动, 并从许多弱学习器中创建一个强学习器。提升树的重要复杂性参数是学习率、基学习器的数量和每个基学习器的大小。学习率决定了每个基础学习器在每次迭代中允许修改整体模型的程度。较慢的学习率通常会创建更稳健的模型, 但需要更多的时间来训练, 因为需要更多的基础学习器。与随机森林模型不同, 随机森林模型通常不会随着树数量的增加而过拟合, 如果使用过多的树, 提升的树会过拟合。随机森林——一种基于树的学习算法, 在称为“装袋”的过程中对许多大型决策树的预测进行平均。每棵大树都是通过训练数据的随机引导样本 (样本随机性) 生成的, 重要的是, 训练数据的每次拆分只允许在随机选择输入变量 (特征随机性) 时发生。如果有 p 个输入变量, 通常允许 $\sim p/3$ 或 $\sim p/2$ 的输入用于任何给定的拆分, 并且为每个拆分选择不同的随机集。仅允许在每次拆分时使用随机选择的输入生成的树与在每次拆分时都允许使用所有变量时的差异更大。这种特征随机性减少了最终树集合的方差。随机森林模型的重要参数包括每棵树的大小、树的数量、每个引导样本的大小以及每次拆分允许的特征比例。与提升树不同, 随机森林模型一般不会因为随着树数量的增加而过拟合, 但精度会逐渐增加。

9. 风险提示

海外市场波动风险，宏观数据、政策变化风险，模型失效风险。

信息披露

分析师与研究助理简介

肖承志，同济大学应用数学本科、硕士，现任德邦证券研究所首席金融工程分析师。具有 6 年证券研究经历，曾就职于东北证券研究所担任首席金融工程分析师。致力于市场择时、资产配置、量化与基本面选股。撰写独家深度“扩散指标择时”系列报告；擅长各类择时与机器学习模型，对隐马尔可夫模型有深入研究；在因子选股领域撰写多篇因子改进报告，市场独家见解。

分析师声明

本人具有中国证券业协会授予的证券投资咨询执业资格，以勤勉的职业态度，独立、客观地出具本报告。本报告所采用的数据和信息均来自市场公开信息，本人不保证该等信息的准确性或完整性。分析逻辑基于作者的职业理解，清晰准确地反映了作者的研究观点，结论不受任何第三方的授意或影响，特此声明。

投资评级说明

1. 投资评级的比较和评级标准： 以报告发布后的 6 个月内的市场表现为比较标准，报告发布日后 6 个月内的公司股价（或行业指数）的涨跌幅相对同期市场基准指数的涨跌幅； 2. 市场基准指数的比较标准： A 股市场以上证综指或深证成指为基准；香港市场以恒生指数为基准；美国市场以标普 500 或纳斯达克综合指数为基准。	类 别	评 级	说 明
	股票投资评级	买入	相对强于市场表现 20%以上；
		增持	相对强于市场表现 5%~20%；
		中性	相对市场表现在-5%~+5%之间波动；
		减持	相对弱于市场表现 5%以下。
	行业投资评级	优于大市	预期行业整体回报高于基准指数整体水平 10%以上；
		中性	预期行业整体回报介于基准指数整体水平-10%与 10%之间；
		弱于大市	预期行业整体回报低于基准指数整体水平 10%以下。

法律声明

。本公司不会因接收人收到本报告而视其为客户。在任何情况

下，本报告中的信息或所表述的意见并不构成对任何人的投资建议。在任何情况下，本公司不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任。

本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的的价格、价值及投资收入可能会波动。在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。

市场有风险，投资需谨慎。本报告所载的信息、材料及结论只提供特定客户作参考，不构成投资建议，也没有考虑到个别客户特殊的投资目标、财务状况或需要。客户应考虑本报告中的任何意见或建议是否符合其特定状况。在法律许可的情况下，德邦证券及其所属关联机构可能会持有报告中提到的公司所发行的证券并进行交易，还可能为这些公司提供投资银行服务或其他服务。

本报告仅向特定客户传送，未经德邦证券研究所书面授权，本研究报告的任何部分均不得以任何方式制作任何形式的拷贝、复印件或复制品，或再次分发给任何其他人，或以任何侵犯本公司版权的其他方式使用。所有本报告中使用的商标、服务标记及标记均为本公司的商标、服务标记及标记。如欲引用或转载本文内容，务必联络德邦证券研究所并获得许可，并需注明出处为德邦证券研究所，且不得对本文进行有悖原意的引用和删改。

根据中国证监会核发的经营证券业务许可，德邦证券股份有限公司的经营范围包括证券投资咨询业务。