

机器学习与因子（二）：Transformer 特征工程算法测评

核心观点

Transformer 作为 ChatGPT 的底层模型，展示出了其在自然语言任务中的强大性能。股票投资场景和自然语言任务有内在相似之处，金融时间序列可以被看作文字序列，且 Transformer 在处理长期记忆和变长序列任务中有优势。因此，本文尝试在股票投资场景测试 Transformer 算法的特征工程能力。

□ 基于 Transformer 构建特征工程模型

本文以带时间步长的多维因子作为输入数据，以股票的次月回报作为标签，逐步测试了各个超参数对 Transformer 模型的影响，并最终确定了月频调仓场景下应用于股票特征工程的模型架构。

□ Transformer 算法能有效对特征加总

经训练的 Transformer 模型在样本外能有效对股票特征进行加总并筛选股票。经过中证 1000、中证 500、沪深 300 和全市场股票池的检验，模型能有效筛选出股票组合，从而对基准指数或空头组合形成稳定超额。经测试，基于 Transformer 的特征工程模型 IC 为 0.047，IR 为 0.69。

□ Transformer 对比其它算法无明显优势

在相同的场景设定下，本文对比了 Transformer 和《机器学习与因子（一）：特征工程算法测评》中测试的其它十种机器学习模型，Transformer 并未体现出明显优势。可能的原因是月频样本的数量难以满足大参数模型训练要求。

□ 风险提示

模型测算风险：超参数设定对模型结果有较大影响；收益指标等指标均限于一定测试时间和测试样本得到，收益指标不代表未来。

模型失效风险：机器学习模型基于历史数据进行测算，不能直接代表未来，仅供参考。

分析师：陈奥林

执业证书号：S1230523040002

chenaolin@stocke.com.cn

研究助理：陆达

luda@stocke.com.cn

相关报告

1 《机器学习与因子（一）：特征工程算法测评》 2023.06.14

正文目录

1 Transformer 算法	4
1.1 算法简介	4
1.2 Transformer 工作流程	4
2 Transformer 特征工程	7
2.1 数据采集与处理	7
2.2 输入因子构建	7
2.3 模型训练	8
2.3.1 训练数据	8
2.3.2 样本划分	8
2.3.3 超参数选取	9
2.3.4 拟合优度	9
3 实证检验	13
3.1 中证 1000 股票池	13
3.2 中证 500 股票池	14
3.3 沪深 300 股票池	16
3.4 全市场股票池	17
3.5 Transformer 与其它模型比较	20
4 结论与展望	20
5 参考文献	21
6 风险提示	21

图表目录

图 1: Transformer 框架.....	4
图 2: Transformer 编码器、解码器结构.....	5
图 3: Encoders- Decoders 堆叠.....	5
图 4: Encoder 内部结构.....	5
图 5: Self-Attention 机制流程.....	6
图 6: Self-Attention 矩阵运算.....	6
图 7: Query, key, Value 矩阵运算.....	6
图 8: Transformer 算法流程图.....	7
图 9: 三角式位置编码.....	9
图 10: 位置编码对应损失函数.....	10
图 11: 位置编码对应多头年化收益.....	10
图 12: 不同时间步长损失函数（时间步长 T: 1, 3, 6）.....	10
图 13: 不同时间步长多头组合年化收益.....	10
图 14: 不同 Encoder 层数损失函数.....	11
图 15: 不同 Encoder 层数多头组合年化收益.....	11
图 16: 增加 Dropout 前后模型样本内损失函数.....	11
图 17: 增加 Dropout 前后模型多头年化收益.....	11
图 18: 本文使用的 Transformer 模型架构.....	12
图 19: 注意力热度图.....	12
图 20: 中证 1000 多头组合净值表现.....	13
图 21: 中证 1000 股票池 Transformer 算法分组测试.....	13
图 22: 中证 500 多头组合净值表现.....	14
图 23: 中证 500 股票池 Transformer 算法分组测试.....	15
图 24: 沪深 300 多头组合净值表现.....	16
图 25: 沪深 300 股票池 Transformer 算法分组测试.....	16
图 26: 全市场股票池多空组合净值表现.....	17
图 27: 全市场股票池多头组合超额收益.....	18
图 28: 全市场股票池 Transformer 算法分组测试.....	18
图 29: 全市场股票池 Transformer 打分 IC/IR.....	19
图 30: 各特征工程算法模型净值对比.....	20
表 1: 因子池及定义.....	8
表 2: Transformer 模型超参数选择.....	9
表 3: 中证 1000 股票池 Transformer 算法分组绩效指标.....	14
表 4: 中证 500 股票池 Transformer 算法分组绩效指标.....	15
表 5: 沪深 300 股票池 Transformer 算法分组绩效指标.....	17
表 6: 全市场股票池 Transformer 算法分组绩效指标.....	19

1 Transformer 算法

Transformer 算法通过 ChatGPT 展示出了其在自然语言任务中的强大性能。股票投资场景和自然语言任务有内在相似的地方，比如金融时序任务可以被看作 Seq2Seq 任务，而 Transformer 正是该领域的主力算法。因此，本文尝试在股票投资场景探索 Transformer 算法的使用。

1.1 算法简介

Transformer 算法是自然语言处理（NLP）任务所流行使用的深度学习模型。它在机器翻译，文本生成等任务中取得了显著的突破，并逐渐成为 NLP 领域的重要模型。为人熟知的 ChatGPT, BERT 等模型的底层算法就是 Transformer。

在此之前，循环神经网络（RNN）和卷积神经网络（CNN）是常用于 NLP 任务的模型。然而，RNN 存在难以并行计算和处理长距离依赖的问题，而 CNN 则对输入序列的长度有限制。这些问题限制了它们在处理长文本序列时的效果。

Transformer 算法通过引入自注意力机制（self-attention）来解决这些问题。自注意力机制允许模型在处理每个位置时，能够同时考虑到输入序列中的其他位置，从而捕捉到更长距离的依赖关系。此外，Transformer 还使用了多头注意力机制（multi-head attention），通过并行计算多个注意力头来提高模型的表达能力。

Transformer 的核心思想是将输入序列映射为多维空间中的表示，然后通过多层的自注意力和前馈神经网络进行信息的传递和变换。最终，通过解码器将表示映射回目标序列，实现翻译或其他 NLP 任务。

考虑到 Transformer 在自然语言处理领域的巨大成功，其在金融领域的应用潜力值得研究探索。由于其在序列到序列任务的良好表现，在投资领域，其可以应用于时序任务，例如股票价格的估计和市场趋势的估计。通过将历史价格或特征序列作为输入，模型可以学习到股票价格的模式和趋势，并估计未来的价格走势。

1.2 Transformer 工作流程

Transformer 算法可以完成从序列输入到序列输出的任务。其工作流程如图 1 所示。首先，输入序列被获取，并且位置编码被添加到输入序列中。然后，输入序列被送入 Transformer 模型进行计算，以获得输出结果。

图1: Transformer 框架




资料来源：浙商证券研究所；GitHub(<http://jalamar.github.io/illustrated-transformer/>)

Transformer 模型内部由两个主要的模块组成，分别是编码器（Encoders）和解码器（Decoders）。这两个模块可以同时使用，也可以单独使用其中一个模块，具体取决于任务的需求。ChatGPT 和 BERT 模型分别是 Decoder Only 和 Encoder Only 模型。

Transformer 内部编码器，解码器结构如图 2 所示。


图2: Transformer 编码器、解码器结构



资料来源: 浙商证券研究所; GitHub(<http://jalammargithub.io/illustrated-transformer/>)

在 Transformer 模型中, Encoders- Decoders 堆叠是指将多个编码器 (Encoders) 和解码器 (Decoders) 层堆叠在一起的结构。这种堆叠的结构允许模型在处理序列输入到序列输出任务时进行更深层次的特征提取和表示。如图 3 所示。

图3: Encoders- Decoders 堆叠




资料来源: 浙商证券研究所; GitHub(<http://jalammargithub.io/illustrated-transformer/>)

Encoder 编码器内部由自注意力机制 (Self-Attention) 和前馈神经网络 (Feed-Forward Neural Network) 组成。Decoder 解码器的内部结构和 Encoder 内部结构一致。自注意力机制是 Encoder 编码器的核心组件, 后文会详细介绍。

前馈神经网络由两个全连接层和一个激活函数组成, 可以将输入序列的表示进行映射和变换, 以捕捉更丰富的特征和语义信息。Encoder 编码器内部结构如图 4 所示。


图4: Encoder 内部结构



资料来源: 浙商证券研究所; GitHub(<http://jalammargithub.io/illustrated-transformer/>)


自注意力机制（Self-Attention）是 Transformer 模型中的关键组件之一，它在编码器和解码器中都得到了广泛应用。自注意力机制的主要作用是对输入序列中不同位置之间的依赖关系进行建模，以生成上下文相关的表示。自注意力机制的工作流程如图 5 所示。

图5: Self-Attention 机制流程



资料来源：浙商证券研究所；
Attention is all you need;

图6: Self-Attention 矩阵运算




资料来源：浙商证券研究所;GitHub(<http://jalammar.github.io/illustrated-transformer/>)

首先，将输入序列（例如，编码器的输入或解码器的输入）通过线性变换映射到三个不同的表示空间：查询（Query）、键（Key）和值（Value），即上图中的 Q, K, V 三个矩阵。这些线性变换可以通过矩阵乘法和偏置项来实现。计算方法如图 7 所示。

然后，计算 Q 与 K 的相似度得到注意力权重 A。相似度可以使用点积注意力、缩放点积注意力或其他方法来计算。然后，将注意力权重进行归一化，以确保它们的总和为 1。

最后，使用注意力权重 A 对 V 进行加权求和，得到上下文表示 O。注意力权重越高，表示该位置对其他位置的重要性越大，因此在计算上下文表示时，会更多地考虑具有较高注意力权重的值。


图7: Query, key, Value 矩阵运算



资料来源：浙商证券研究所;GitHub(<http://jalammar.github.io/illustrated-transformer/>)

实际上，在自注意力机制中，需要机器学习的参数就是 W_Q , W_K 和 W_V 三个矩阵。实践中，注意力机制模块可在计算出 O 矩阵后，对 O 矩阵进行线性变化，因此会多一个 W_O 矩阵需要学习。

图8: Transformer 算法流程图



资料来源: 浙商证券研究所; GitHub(<http://jalammar.github.io/illustrated-transformer/>)

图 8 比较完整地展示了 Transformer 算法的流程及内部架构。

2 Transformer 特征工程

本文使用 Transformer 算法, 对个股因子和个股次月预期收益率之间的关系进行回归, 并测试算法在该任务中的性能。由于 Transformer 的一大优势是能处理 Seq2Seq 任务, 因此输入数据为 $T \times N$ 的面板数据, 其中 T 为时间步长, N 为特征维度。数据频率为月频。

为客观比较特征工程算法之间的性能, 本文使用与《机器学习与因子(一): 特征工程算法测评》同样的因子池和样本内、外划分方法, 并将文章中测试过的模型作为比较基准。

2.1 数据采集与处理

数据来源: 本文使用 Wind 数据库。数据库提供相对高质量、专业和全面的金融、经济及交易数据。

数据类别: 本文获得的样本数据包括三类, 分别是 A 股上市公司的财务报表数据、交易数据以及部分宏观经济数据。这三类数据为后续特征工程提供基础数据。

时段选择: 本文采用的样本数据时间跨度为 2007 年 1 月至 2023 年 6 月, 总计 198 个月。选取较长的时间序列有助于考察因子的长期稳定性, 同时结束日期也较近, 可以观察到较新的市场状况, 具有一定的时效性。

数据清洗: 对所获得的数据进行了缺失值检测, 删除了有缺失值的样本; 将数据转换到适合模型输入的格式, 如浮点数和整数; 对数据范围差异大的特征进行 Z-score 标准化, 统一量纲。

2.2 输入因子构建

本文用于输入模型的因子与《机器学习与因子(一): 特征工程算法测评》中使用的因子保持一致。因子池及因子定义如表 1 所示。

表1: 因子池及定义

因子大类	因子风格	因子名称	因子定义	备注
基本面	规模	mve	对数市值	月频
	估值	bm	市值账面比	月频
		sp	季度营业收入/季度末市值	季频
	盈利	ROE	ROE_TTM	季频
		op_margin	营业利润率	季频
		chpm	毛利率变化率	季频
		nincr	连续盈利季度个数	季频
		pchgm_pchsale	毛利率变化百分比-营业收入变动百分比	季频
	成长	net_growth	净利润增速	季频
		chato	销售额变化除以总资产	季频; 行业中性化
		chempia	员工人数变化	季频; 行业中性化
		sgr	销售收入变动百分比	季频
		rsup	销售额变动/市值	季频
		egr	净资产账面价值季度百分比变化	季频
	杠杆	asset_liab	资产负债比	季频; 行业中性化
	投资	fixasst_invchg	固定资产存货变动比率	季频
	其它	orgcap	资本化管理费用	季频
		cash	现金及其等价物除以平均总资产	季频
交易类	成交量	std_dolvol	月内交易额标准差	月频
		zerotrade	月内加权 0 交易天数	月频
		ill	月内日收益率/交易额的平均值	月频
		atr	异常周转率, 市场周转率+事件变量对个股周转率回归取残差	月频
		turn	前 3 个月平均股票交易量除以 t 月流通股数量	月频
	价格	er-trend	不同窗口期的移动平均价格和移动平均交易量对收益率滚动回归, 对系数做指数平滑, 预测下一期	月频
		maxret	月内最大日内收益率	月频

资料来源: Leippold M, Wang Q, Zhou W. Machine learning in the Chinese stock market[J]. Journal of Financial Economics, 2021(1).; 浙商证券研究所

2.3 模型训练

2.3.1 训练数据

训练用的输入数据为 $T \times 25$, T 为时间步长, 25 为特征维度。具体特征为 2.2 节中所示的因子。训练使用的标签为 $t+1$ 月的股票月度绝对收益率。本文假设市场 β 信息已包含在特征值中, 因此使用绝对收益率而非超额收益率作为标签。

2.3.2 样本划分

本研究使用 2007 年 1 月至 2023 年 6 月的数据。其中, 2007 年 1 月至 2018 年 12 月的数据作为训练集; 2019 年 1 月至 2023 年 6 月作为测试集。

2.3.3 超参数选取

由于 Transformer 的超参数选择可能会对模型性能产生较大影响，本文测试了多种超参数组合。由于本文不涉及序列到序列的任务，从训练的经济性和模型的鲁棒性角度考虑，使用 Encoder-Only 的 Transformer 架构。超参数组合如表 2 所示。

表2: Transformer 模型超参数选择

超参数项	超参数取值			
位置编码	是	否		
时间步长	1	3	6	
Encoder 层数	1	4	6	8
多头数量	1	5		
前馈 Dropout	0	0.1	0.2	
学习率	1e-4	5e-3	1e-3	
Epoch	50	100	150	200

资料来源：浙商证券研究所


为了测试位置编码信息对模型性能的影响，本文选取三角式位置编码方法进行了实验。在三角式位置编码中，位置 t 对应的位置向量在偶数和奇数位的值分别为：

$$PE_{(t,2i)} = \sin\left(\frac{t}{10000^{2i/d}}\right)$$

$$PE_{(t,2i+1)} = \cos\left(\frac{t}{10000^{2i/d}}\right)$$

图 9 展示了位置编码信息。横坐标表示元素在序列中的位置 t ，纵坐标表示位置对应的编码值。

图9: 三角式位置编码



资料来源：浙商证券研究所；哈佛大学(<http://nlp.seas.harvard.edu/2018/04/03/attention.html>)


2.3.4 拟合优度

本文使用 MSE 损失来衡量模型在样本内的回归性能，通过比较预测值和实际值之间的差异来评估模型的准确性。而在样本外，本文使用模型生成的股票多头组合的年化收益率作为衡量模型特征工程性能的标准。股票多头组合为全市场股票 Transformer 打分最高的 10% 股票等权构成。

图 10 展示了有无位置编码信息的模型在样本内训练过程中的损失函数。横坐标表示 Epoch 数量，纵坐标表示 MSE 损失数值。可以观察到，添加了位置编码信息的模型在样本内的损失下降幅度更大，说明模型的拟合性能得到了提升。


接下来，图 11 展示了模型在样本外（2019 年 1 月至 2023 年 6 月）生成的股票多头组合的年化收益率。从图中可以得到的信息是，具有位置编码信息的股票多头组合的年化收益率高于没有位置编码的组合。

图10: 位置编码对应损失函数



资料来源: Wind; 浙商证券研究所

图11: 位置编码对应多头年化收益




资料来源: Wind; 浙商证券研究所

综上，位置编码信息的引入对于提升模型的回归性能和特征工程性能都是有效的。位置编码能够帮助模型更好地理解输入序列中的位置信息，从而提高模型的表达能力和预测准确性。

本文也测试了输入数据的时间步长对模型性能的影响。图 12 展示了不同时间步长的模型在样本内的损失函数值。横坐标表示 Epoch 数量，纵坐标表示 MSE 损失数值。根据图中的信息，我们可以观察到随着时间步长由 3 步增加至 6 步，模型在样本内的拟合性能显著提升。


接下来，图 13 展示了具有不同时间步长的模型在样本外生成的股票多头组合的年化收益率。我们可以看到，在时间步长为 3 时，模型在样本外表现出最佳的性能。然而，当时间步长为 6 时，出现了过拟合的现象。

图12: 不同时间步长损失函数 (时间步长 T: 1, 3, 6)



资料来源: Wind; 浙商证券研究所

图13: 不同时间步长多头组合年化收益




资料来源: Wind; 浙商证券研究所

综上所述，时间步长的增加能提升模型样本内性能。然而，时间步长并非越长越好，需要根据具体的任务进行权衡和调整。

本文也测试了不同 Encoder 层数对模型回归性能的影响。图 14 为不同 Encoder 层数的模型对应的样本内损失函数。根据图中信息可知，当 Encoder 层数增加时，模型在样本内的拟合能力得到提高。然而，在 Encoder 层数到达 6 层时，再增加 Encoder 层数，模型拟合能力的提升微乎其微。


图 15 展示了不同 Encoder 层数的模型在样本外生成的股票多头组合的年化收益率。根据图中信息可知，随着 Encoder 层数的增加，模型输出的组合的收益呈现下降趋势。这可能是因为过多的 Encoder 层数导致了模型的过拟合，使得模型在未见过的数据上的泛化能力下降。

图14: 不同 Encoder 层数损失函数



资料来源: Wind; 浙商证券研究所

图15: 不同 Encoder 层数多头组合年化收益




资料来源: Wind; 浙商证券研究所

综上所述，Encoder 层数的增加能提升模型样本内性能。但随着 Encoder 的增多，模型在样本外出现了过拟合现象。


为了解决模型容易出现过拟合的问题，本文尝试了一系列方法。包括降低特征维度，添加 Dropout 等方法。对模型做出上述改变后，过拟合现象得到了缓解，但是模型输出组合的收益相比改变之前，出现了较大幅度的下降，如图 16、图 17 所示。因此，最终模型架构中不使用降维和 Dropout 等方法。

图16: 增加 Dropout 前后模型样本内损失函数



资料来源: Wind; 浙商证券研究所

图17: 增加 Dropout 前后模型多头年化收益




资料来源: Wind; 浙商证券研究所

综上，确定最终模型结构如图 18 所示。输入数据时间步长为 3，特征维度为 25，经过自注意力层，残差连接&归一化层，前馈层到最后的线性层，输出次月收益率的预测值。

需要学习的参数为 $4 \times (25 \times 25) + 4 \times 25 + 2 \times 25 + (25 \times 100 + 100 \times 25 + 100 \times 25) + (25 \times 1 + 1) = 7801$ 个。

图18: 本文使用的 Transformer 模型架构




资料来源: 浙商证券研究所

图 19 展示了不同股票特征之间的注意力权重。根据图中信息可以看出, 与成交量相关的特征(zerotrade, ill)和与估值相关的特征(bm)与其他特征之间存在较多的高注意力权重(对应图中黑色色块)。这表明这些特征之间可能存在一定的内在联系。

具有较高权重的特征在模型预测中起到更重要的作用。模型在进行预测时, 会较多关注或依赖这些成交量相关的特征。这个结论与《机器学习与因子 (一): 特征工程算法测评》中的结论较一致。

图19: 注意力热度图



资料来源: Wind; 浙商证券研究所


3 实证检验

本文针对中证 1000 股票池、中证 500 股票池、沪深 300 股票池和全市场股票池分别实证检验了 Transformer 特征工程算法的有效性。

3.1 中证 1000 股票池

使用 2007 年至 2018 年的数据训练 Transformer 模型，在 2019 年后使用该模型对中证 1000 指数成分股进行月度打分。根据打分结果，将中证 1000 指数成分股分为 5 个组。然后，等权买入打分最高的一组股票，形成中证 1000 指数的多头组合。


图20： 中证 1000 多头组合净值表现



资料来源：Wind；浙商证券研究所

图 20 展示了中证 1000 指数多头组合净值表现与超额收益。根据图中信息可知，该组合相对基准能产生稳定的超额收益。这表明，在中证 1000 股票池内，Transformer 算法选股的有效性较好。

图21： 中证 1000 股票池 Transformer 算法分组测试



资料来源：Wind；浙商证券研究所

图 21 展示了中证 1000 股票池经 Transformer 打分分组后的各组收益率、超额收益和信息比率信息。根据图中信息可知，Transformer 打分分组具有较好的单调性，随着 Transformer 打分的提高，组合年化收益、年化超额收益和信息比率也随之提高。

表3: 中证 1000 股票池 Transformer 算法分组绩效指标


	第一组	第二组	第三组	第四组	第五组
累积净值	1.2603	1.7162	1.819	2.2564	2.5538
年化收益	5.39%	13.03%	14.53%	20.26%	23.68%
夏普比率	0.1583	0.5111	0.6055	0.8487	0.9359
年化超额收益率	-6.47%	4.23%	6.19%	13.39%	17.52%
信息比率	-0.4684	0.3636	0.4768	0.9931	1.2958
年化跟踪误差	6.49%	5.76%	6.48%	6.93%	7.05%
2019 年收益率	14.99%	30.96%	20.97%	27.63%	34.10%
2019 年超额收益率	-9.19%	6.77%	-3.21%	3.45%	9.92%
2020 年收益率	2.19%	7.76%	14.15%	30.61%	30.11%
2020 年超额收益率	-17.20%	-11.63%	-5.24%	11.22%	10.72%
2021 年收益率	24.33%	27.06%	34.27%	28.28%	40.26%
2021 年超额收益率	3.81%	6.54%	13.75%	7.76%	19.74%
2022 年收益率	-22.88%	-13.94%	-10.24%	-7.70%	-11.59%
2022 年超额收益率	-1.30%	7.64%	11.34%	13.88%	9.99%
2023 年收益率	8.49%	8.43%	6.35%	10.90%	14.49%
2023 年超额收益率	3.39%	3.33%	1.25%	5.80%	9.39%
最大回撤	-31.12%	-31.00%	-27.41%	-28.60%	-31.14%
年化收益/回撤比	0.17	0.42	0.53	0.71	0.76

资料来源: Wind; 浙商证券研究所

3.2 中证 500 股票池

使用与 3.1 节中同样的方法构造中证 500 多头组合。


图22: 中证 500 多头组合净值表现



资料来源: Wind; 浙商证券研究所

图 22 展示了中证 500 指数多头组合净值表现与超额收益。根据图中信息可知，该组合在 2021 年后相对基准能产生稳定的超额收益。这表明，在中证 500 股票池，Transformer 算法选股的有效性总体较好，但是相比中证 1000 股票池有所下降。

图23: 中证 500 股票池 Transformer 算法分组测试



资料来源: Wind; 浙商证券研究所

图 23 展示了中证 500 股票池经 Transformer 打分分组后的各组收益率、超额收益和信息比率信息。根据图中信息可知，Transformer 打分分组具有较好的单调性，随着 Transformer 打分的提高，组合年化收益、年化超额收益和信息比率也随之提高。

表4: 中证 500 股票池 Transformer 算法分组绩效指标


	第一组	第二组	第三组	第四组	第五组
累积净值	1.3941	1.6441	1.7006	1.8735	1.9008
年化收益	7.82%	11.93%	12.79%	15.30%	15.67%
夏普比率	0.2721	0.5129	0.5821	0.7066	0.65
年化超额收益率	-0.97%	4.37%	5.46%	8.57%	9.03%
信息比率	-0.0781	0.4079	0.4395	0.6568	0.6613
年化跟踪误差	6.31%	5.55%	6.45%	6.85%	7.18%
2019 年收益率	19.81%	27.91%	22.24%	27.48%	21.34%
2019 年超额收益率	-2.86%	5.24%	-0.43%	4.82%	-1.33%
2020 年收益率	5.24%	21.85%	14.07%	25.02%	21.32%
2020 年超额收益率	-15.63%	0.98%	-6.80%	4.14%	0.45%
2021 年收益率	25.57%	21.03%	17.62%	19.57%	35.88%
2021 年超额收益率	9.98%	5.44%	2.04%	3.99%	20.29%
2022 年收益率	-17.79%	-15.44%	-6.46%	-10.34%	-14.90%
2022 年超额收益率	2.52%	4.87%	13.86%	9.98%	5.41%
2023 年收益率	3.89%	0.42%	7.82%	7.10%	8.50%
2023 年超额收益率	1.61%	-1.87%	5.53%	4.81%	6.21%
最大回撤	-29.53%	-26.25%	-24.07%	-24.58%	-32.67%
年化收益/回撤比	0.26	0.45	0.53	0.62	0.48

资料来源: Wind; 浙商证券研究所

3.3 沪深 300 股票池

使用与 3.1 节中同样的方法构造沪深 300 多头组合。


图24: 沪深 300 多头组合净值表现



资料来源: Wind; 浙商证券研究所

图 24 展示了沪深 300 指数多头组合净值表现与超额收益。根据图中信息可知，该组合总体上能对基准产生超额收益，但是超额收益的波动比较明显，稳定性一般。这表明，在沪深 300 股票池，Transformer 算法选股总体有效，但是相比中证 1000 股票池和中证 500 股票池有所下降。

图25: 沪深 300 股票池 Transformer 算法分组测试



资料来源: Wind; 浙商证券研究所

图 25 展示了沪深 300 股票池经 Transformer 打分分组后的各组收益率、超额收益和信息比率信息。根据图中信息可知，Transformer 打分分组单调性一般。随着 Transformer 打分的提高，组合年化收益、年化超额收益和信息比率总体上也随之提高，但是波动性较大。

表5: 沪深 300 股票池 Transformer 算法分组绩效指标


	第一组	第二组	第三组	第四组	第五组
累积净值	1.5261	1.5242	1.3108	1.6662	1.507
年化收益	10.06%	10.03%	6.33%	12.27%	9.74%
夏普比率	0.3778	0.4177	0.2522	0.5684	0.4098
年化超额收益率	6.61%	6.57%	2.41%	9.06%	6.25%
信息比率	0.4062	0.5144	0.1846	0.7123	0.4366
年化跟踪误差	9.71%	7.63%	7.75%	7.62%	8.55%
2019 年收益率	24.67%	30.06%	28.07%	18.57%	28.42%
2019 年超额收益率	-1.48%	3.91%	1.92%	-7.58%	2.27%
2020 年收益率	20.33%	36.58%	22.27%	38.13%	27.01%
2020 年超额收益率	-6.88%	9.37%	-4.94%	10.92%	-0.20%
2021 年收益率	21.02%	6.79%	-2.52%	10.99%	3.32%
2021 年超额收益率	26.22%	11.98%	2.68%	16.19%	8.52%
2022 年收益率	-18.17%	-20.28%	-18.84%	-12.33%	-18.30%
2022 年超额收益率	3.47%	1.35%	2.79%	9.31%	3.33%
2023 年收益率	-0.24%	-1.90%	4.10%	2.32%	7.64%
2023 年超额收益率	0.52%	-1.14%	4.86%	3.08%	8.39%
最大回撤	-27.89%	-30.69%	-31.34%	-26.70%	-31.93%
年化收益/回撤比	0.36	0.33	0.2	0.46	0.31

资料来源: 浙商证券研究所

3.4 全市场股票池

使用 2007 年至 2018 年的数据训练 Transformer 模型, 在 2019 年后使用该模型对全市场股票进行月度打分。根据打分结果, 将所有股票分为 10 组。然后, 等权买入打分最高的一组股票, 形成全市场多头组合, 等权买入打分最低的一组股票, 形成空头组合。


图26: 全市场股票池多空组合净值表现



资料来源: Wind; 浙商证券研究所

图 26 展示了全市场多头组合与空头组合的净值表现与超额收益。根据图中信息可知，多头组合对空头组合能产生稳定的超额收益。这表明，全市场股票池场景下，Transformer 算法选股有效性良好。


图27：全市场股票池多头组合超额收益



资料来源：Wind; 浙商证券研究所

图 27 展示了全市场多头组合与万得全 A 的净值表现与超额收益。根据图中信息可知，多头组合除了 20 年 Q4 至 21 年 Q1 外，对万得全 A 能产生稳定的超额收益。


图28：全市场股票池 Transformer 算法分组测试



资料来源：Wind; 浙商证券研究所

图 28 展示了全市场股票池按 Transformer 打分分组后的各股票组合年化收益率。根据图中信息可知，Transformer 分组单调性良好。随着 Transformer 打分的提高，组合年化收益也随之提高。

图29: 全市场股票池 Transformer 打分 IC/IR



资料来源: Wind; 浙商证券研究所

图 29 展示了全市场股票池 Transformer 个股打分的 IC/IR。Transformer 打分的 IC 均值为 0.047, IR 为 0.69, IC 大于 0 的月份占比为 69.81%。由图中信息和统计信息可知, Transformer 打分有效性较高, 且表现稳定。


表6: 全市场股票池 Transformer 算法分组绩效指标

	第一组	第二组	第三组	第四组	第五组	第六组	第七组	第八组	第九组	第十组
年化收益	4.51%	12.45%	13.52%	14.29%	16.05%	20.82%	21.46%	22.27%	24.24%	20.84%
夏普比率	0.125	0.4914	0.5756	0.625	0.7182	0.9574	0.9759	0.9905	1.057	0.8181
年化超额收益率	-7.00%	4.01%	5.40%	6.39%	8.61%	14.46%	15.23%	16.20%	18.52%	14.49%
信息比率	-0.2696	0.2158	0.3235	0.3939	0.5126	0.8465	0.8481	0.8395	0.8658	0.5876
跟踪误差	0.78%	0.59%	0.53%	0.52%	0.54%	0.56%	0.59%	0.64%	0.71%	0.81%
年化跟踪误差	12.36%	9.32%	8.42%	8.22%	8.58%	8.91%	9.38%	10.11%	11.28%	12.84%
2019 年收益率	14.63%	23.42%	26.35%	28.40%	24.33%	23.90%	25.14%	30.87%	32.03%	25.76%
2019 年超额收益率	-12.30%	-3.51%	-0.58%	1.47%	-2.60%	-3.03%	-1.79%	3.94%	5.10%	-1.17%
2020 年收益率	-0.13%	10.50%	13.26%	12.43%	19.71%	26.68%	25.25%	24.65%	22.51%	18.41%
2020 年超额收益率	-25.75%	-15.12%	-12.36%	-13.18%	-5.91%	1.07%	-0.37%	-0.96%	-3.10%	-7.21%
2021 年收益率	22.68%	24.31%	24.63%	29.37%	29.58%	28.22%	34.42%	34.58%	39.07%	40.67%
2021 年超额收益率	13.51%	15.14%	15.46%	20.20%	20.41%	19.05%	25.25%	25.41%	29.90%	31.50%
2022 年收益率	-21.07%	-10.78%	-11.76%	-10.38%	-7.61%	1.79%	-3.10%	0.67%	2.95%	-1.06%
2022 年超额收益率	-2.41%	7.88%	6.89%	8.27%	11.04%	20.44%	15.56%	19.33%	21.60%	17.60%
2023 年收益率	6.18%	8.17%	8.48%	5.05%	5.60%	9.74%	12.35%	6.95%	9.36%	7.93%
2023 年超额收益率	3.12%	5.11%	5.42%	1.99%	2.54%	6.68%	9.29%	3.90%	6.30%	4.87%
最大回撤	-31.69%	-27.87%	-27.50%	-27.08%	-25.68%	-21.80%	-24.69%	-24.86%	-23.65%	-26.47%
年化收益/回撤比	0.14	0.45	0.49	0.53	0.62	0.96	0.87	0.9	1.03	0.79

资料来源: Wind; 浙商证券研究所

3.5 Transformer 与其它模型比较

图30: 各特征工程算法模型净值对比



资料来源: Wind; 浙商证券研究所

图 30 展示了各机器学习模型输出的多头组合的净值表现。使用相同的因子池，一致的样本划分，同样的训练样本以及同样的组合构建方法，对比各机器学习模型在月频调仓场景下的特征工程能力。Transformer 模型并未对其它更简单的模型展现出优势。

可能的原因有几方面。首先，数据特征可能不适合 Transformer 模型。Transformer 模型在处理序列数据和自然语言处理等领域表现出色。上述两类任务中，输入数据之间内在联系较强，因此 Q 矩阵和 K 矩阵能有效的找到序列之间的注意力权重。金融数据的特点可能与自然语言数据有所不同，可能需要其他类型的模型来更好地捕捉金融市场的特征。其次，样本量不足。月频调仓场景样本量较小，可能无法充分训练 Transformer 模型，从而影响其性能。Transformer 模型通常需要大量的数据进行训练，以学习到有效的特征表示。如果样本量不足，模型可能无法充分学习到数据的潜在模式和规律。

4 结论与展望

Transformer 算法在本文设定的任务场景下具有良好的特征工程能力。在全市场股票池，使用 Transformer 算法对股票打分后形成的多空组合能够稳定获取收益。Transformer 打分的 IC 稳定，IR 值高，单调性良好。在中证 1000 和中证 500 股票池，Transformer 能有效地进行选股并对基准进行增强。

横向比较其它机器学习模型，在同样的任务场景下，Transformer 算法并未表现出优势。可能的原因在于 Transformer 模型对样本量的要求较高，对输入数据有的适应性要求。如果输入数据的特征与 Transformer 模型的工作方式不匹配，可能会导致性能下降。

为解决上述问题，后续可以尝试提升获取样本的频率，从而增加样本数量。挖掘出更符合 Transformer 算法特点的金融数据。

5 参考文献

- [1] Vaswani, Ashish, et al. Attention is all you need. Advances in Neural Information Processing Systems. 2017.
- [2] Leippold M, Wang Q, Zhou W. Machine learning in the Chinese stock market[J]. Journal of Financial Economics, 2021(1).

6 风险提示

模型测算风险：超参数设定对模型结果有较大影响；收益指标等指标均限于一定测试时间和测试样本得到，收益指标不代表未来。

模型失效风险：机器学习模型基于历史数据进行测算，不能直接代表未来，仅供参考。

股票投资评级说明

以报告日后的 6 个月内，证券相对于沪深 300 指数的涨跌幅为标准，定义如下：

1. 买入：相对于沪深 300 指数表现 + 20% 以上；
2. 增持：相对于沪深 300 指数表现 + 10% ~ + 20%；
3. 中性：相对于沪深 300 指数表现 - 10% ~ + 10% 之间波动；
4. 减持：相对于沪深 300 指数表现 - 10% 以下。

行业的投资评级：

以报告日后的 6 个月内，行业指数相对于沪深 300 指数的涨跌幅为标准，定义如下：

1. 看好：行业指数相对于沪深 300 指数表现 + 10% 以上；
2. 中性：行业指数相对于沪深 300 指数表现 - 10% ~ + 10% 以上；
3. 看淡：行业指数相对于沪深 300 指数表现 - 10% 以下。

我们在此提醒您，不同证券研究机构采用不同的评级术语及评级标准。我们采用的是相对评级体系，表示投资的相对比重。

建议：投资者买入或者卖出证券的决定取决于个人的实际情况，比如当前的持仓结构以及其他需要考虑的因素。投资者不应仅仅依靠投资评级来推断结论。

法律声明及风险提示

本报告由浙商证券股份有限公司（已具备中国证监会批复的证券投资咨询业务资格，经营许可证编号为：Z39833000）制作。本报告中的信息均来源于我们认为可靠的已公开资料，但浙商证券股份有限公司及其关联机构（以下统称“本公司”）对这些信息的真实性、准确性及完整性不作任何保证，也不保证所包含的信息和建议不发生任何变更。本公司没有将变更的信息和建议向报告所有接收者进行更新的义务。

本报告仅供本公司的客户作参考之用。本公司不会因接收人收到本报告而视其为本公司的当然客户。

本报告仅反映报告作者的出具日的观点和判断，在任何情况下，本报告中的信息或所表述的意见均不构成对任何人的投资建议，投资者应当对本报告中的信息和意见进行独立评估，并应同时考量各自的投资目的、财务状况和特定需求。对依据或者使用本报告所造成的一切后果，本公司及/或其关联人员均不承担任何法律责任。

本公司的交易人员以及其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本报告意见及建议不一致的市场评论和/或交易观点。本公司没有将此意见及建议向报告所有接收者进行更新的义务。本公司的资产管理公司、自营部门以及其他投资业务部门可能独立做出与本报告中的意见或建议不一致的投资决策。

本报告版权均归本公司所有，未经本公司事先书面授权，任何机构或个人不得以任何形式复制、发布、传播本报告的全部或部分内容。经授权刊载、转发本报告或者摘要的，应当注明本报告发布人和发布日期，并提示使用本报告的风险。未经授权或未按要求刊载、转发本报告的，应当承担相应的法律责任。本公司将保留向其追究法律责任的权利。

浙商证券研究所

上海总部地址：杨高南路 729 号陆家嘴世纪金融广场 1 号楼 25 层

北京地址：北京市东城区朝阳门北大街 8 号富华大厦 E 座 4 层

深圳地址：广东省深圳市福田区广电金融中心 33 层

上海总部邮政编码：200127

上海总部电话：(8621) 80108518

上海总部传真：(8621) 80106010

浙商证券研究所：<https://www.stocke.com.cn>