

2013 年 3 月 26 日

他山之石（2013 年 3 月）

相关研究

他山之石系列一	2012.08.15
他山之石系列二	2012.09.13
他山之石系列三	2012.11.05
他山之石系列四	2012.12.07
他山之石系列五	2013.01.21
他山之石系列六	2013.02.26

总编：高道德
SAC 执业证书编号：
S0850511010035
电 话：021-23219569
Email: gaodd@htsec.com

吴先兴
SAC 执业证书编号：
S0850511010032
电 话：021-23219449
Email: wuxx@htsec.com

丁鲁明
SAC 执业证书编号：
S0850511010033
电 话：021-23219068
Email: dinglm@htsec.com

郑雅斌
SAC 执业证书编号：
S0850511040004
电 话：021-23219395
Email: zhengyb@htsec.com

朱剑涛
SAC 执业证书编号：
S0850512100002
电 话：021-23219745
Email: zhujt@htsec.com

冯佳睿
SAC 执业证书编号：
S0850512080006
电 话：021-23219732
Email: fengjr@htsec.com

联系人
杨勇
电 话：021-23219945
Email: yy8314@htsec.com

飞跃
电 话：021-23219984
Email: dfy8739@htsec.com

张欣慰
电 话：021-23219370
Email: zxw6607@htsec.com

周雨卉
电 话：021-2321760
Email: zyh6106@htsec.com

纪锡麒
电 话：021-23219948
Email: jxj8404@htsec.com

贪婪和恐惧的技术形态会重现么

推荐理由：一直以来，技术分析受人诟病的地方在于很多技术分析的手段和工具有过多主观成分。对此，有一部分研究提出客观的技术形态的识别方法，但大部分方法由于某些特殊的处理方式会造成原始数据中部分重要信息的丢失。本文从投资者情绪的角度出发，提出了一个完全客观的技术形态识别新方法，在一定程度上弥补了以上不足。文章发现基于情绪的技术形态识别在短期内更有价值，而且从行为金融学和社会心理学的角度来看，这些形态在一定的情境下具有重复性和可预测性，可以用来较好的识别各种定义下的技术形态以及设计交易策略。

日最高与最低价的时间序列预测模型

推荐理由：股票价格行为一直被深入研究。尽管开盘价、收盘价、最高价和最低价都是可获得的，对股票回报和波动性的研究通常只使用收盘价。收盘价比其他三个价格包含了更多的关于股票波动的信息吗？答案似乎不是完全肯定的。价格波动区间（最高价-最低价）包含着关于回报波动率的有效信息。Parkinson(1980)的研究显示，价格波动区间在一定假设下比基于收盘价的估计量更能有效地估计回报波动率。该文提供了一个对日最高与最低价格经验性质的探究性分析，建立了一个基于最高价和最低价时间序列预测模型，对未来价格波动区间的量化分析提供了极富意义的参考。

基于核函数的金融时间序列方向变化的预测技术

推荐理由：本文呈现了一个预测时间序列变化方向的全新技术。核方法被用来估计正、负收益的密度函数，随后进一步生成对未来的预测。该技术的最大优势是相比于以回归为基础的某些方法，它只涉及极少的参数，控制着核估计的窗宽。对于核函数中的协方差矩阵，本文提出了一个特殊的形式，使得近期数据在确定密度时的作用更大，这对于避免过拟合是非常重要的。最后，通过对澳大利亚普通股指数超过 15 年的样本外预测，证明了此方法的优异性质。

智能计算在股票组合构建上的运用

推荐理由：本文介绍了智能计算方法在股票组合构建上的运用。首先通过模糊理论对各个指标进行处理，然后运用遗传算法对股票组合进行迭代优化，较之与现在主流的多因子、均值—方差模型组合构建模型是一种新的尝试。此方法在 ASX/S&P200 上进行了实证，取得了不错的效果。市场环境对资产配置的影响研究

市场环境对资产配置的影响研究

推荐理由：在不同市场环境下，风险补偿效应不尽相同，不同风格的投资组合表现也差异较大。本文展示了如何运用市场环境切换模型来划分市场环境、分析根据市场不断变化的风险补偿效应及相应的资产配置策略、展示了该模型在美股市场的实证效果。

并购事件的动量效应与投资者情绪

推荐理由：本文从理论、实证两个角度深刻的研究了并购的动量效应。首先，在并购动机的传统理论下，提升市场情绪理论的假设。三种假设都有效解释了动量效应存在的原因。其次，对于事件研究的市场划分方式有改进，不仅仅通过股票指数走势划分市场环境，也不仅仅通过事件数量划分，根据市场对事件的反应刻画了并购市场的牛、熊市，研究并购市场的波动对于动量效应的影响。第三，从多个维度剖析动量，描述公司主体的并购动量，发现它具有极好的稳定性。第四，在短期窗口中，理论与实践相结合，证实了动量的存在；在长期窗口中，通过情绪理论以及数据验证，说明并购动量会消失甚至反转。

中国股市的动量交易、均值回归与过激反映

推荐理由：动量和反转是证券市场普遍存在的两种效应，与投资者的行为心理紧密相关。以前的研究常常把它们当做两个独立的市场现象进行研究，而事实上动量和反转往往是同时存在，对价格交错影响。如何把两种效应统一到一个模型框架下？本文提供了一种可行的方案。

分析师预测的一致性

推荐理由：学术界一般评价分析师都是根据其预测的准确性，而本文提出了评价分析师的另一种更有效的指标即分析师预测的一致性，并通过实证证明分析师预测的一致性比起准确度更能影响股票市场且对投资者是一个更有意义的信息。此结论让市场对于分析师预测有了新的理解：分析师的预测一致性越高，就越容易成为明星分析师；分析师会倾向提供向下的预测从而实现更高的预测一致性；分析师一致性指标提高了机构投资者存在的比例。

基于市场流动性的情绪指标

推荐理由：本文提供了自对有卖空限制证券的市场定价机制的一种分析框架，主要从市场层面的交易特征出发，为该环境下可能出现的高估值高溢价现象提出合理解释。由于近期国内转融通业务开始试点，标志着 90 只大市值标的批量可做空时代的真正到来，但另一方面以中证 500、中小板、创业板为代表的中小市值公司却依旧处在不可卖空条件之下，1 月以来的大小盘近 10% 的表现分化是否缘于该卖空条件的变化，我们或许可以在借鉴本文献后从流动性角度方面进行更量化的解释。

金融市场的波动率预测：综述（一）

推荐理由：波动率是描述投资风险及经济变化情况的重要指标之一。单纯追求收益而忽略风险的投资方式是不可取的；同时，随着更多的风险对冲和金融投资的工具的出现（如期权），波动率的预测成为金融量化投资领域重要的研究课题之一。本文的作者之一 Granger 是获得过诺贝尔经济学奖的著名的计量经济学家，他在波动率预测方面的造诣是毋庸置疑的。本文是他与 Ser-Huang Poon 教授撰写的波动率预测模型的综述文章的前半部分。该文章系统性的总结了发表于 2003 年以前的经典的波动率预测模型的研究成果，为系统性的了解这一领域在 2003 年以前的研究进展，起到了高屋建瓴的作用。

目 录

贪婪和恐惧的技术形态会重现么	3
日最高与最低价的时间序列预测模型	9
基于核函数的金融时间序列方向变化的预测技术	21
智能计算在股票组合构建上的运用	27
市场环境对资产配置的影响研究	33
并购事件的动量效应与投资者情绪	41
中国股市的动量交易、均值回归与过激反映	47
分析师预测的一致性	50
基于市场流动性的情绪指标	54
金融市场的波动率预测：综述（一）——原因与基本模型介绍	63

贪婪和恐惧的技术形态会重现么

文献来源：Ray R. Sturm. Sequential Greed and Fear in Stock Prices, Journal of Investing, 2012, winter.

推荐人：杨勇 021-23219945

推荐理由：一直以来，技术分析受人诟病的地方在于很多技术分析的手段和工具有过多主观成分。对此，有一部分研究提出客观的技术形态的识别方法，但大部分方法由于某些特殊的处理方式会造成原始数据中部分重要信息的丢失。本文从投资者情绪的角度出发，提出了一个完全客观的技术形态识别新方法，在一定程度上弥补了以上不足。文章发现基于情绪的技术形态识别在短期内更有价值，而且从行为金融学和社会心理学的角度来看，这些形态在一定的情境下具有重复性和可预测性，可以用来较好的识别各种定义下的技术形态以及设计交易策略。

一直以来，技术分析受人诟病的地方在于很多技术分析的手段和工具有过多主观成分。在技术形态的识别中，形态的定义和识别受主观判断的影响很大。为避免这种缺陷，本文从投资者情绪的角度出发，提出了一个完全客观的技术形态识别新方法。

基于这一方法，文章发现基于情绪的技术形态识别在短期内更有价值，而且从行为金融学和社会心理学的角度来看，这些形态在一定的情境下具有重复性和可预测性。

一、文献回顾

大量研究文献均试图度量“恐惧”或“贪婪”这两种投资者情绪或者说市场情绪状态。一种常见的方法如 Lee, Jiang 和 Indro (2002) 年对机构投资者的问卷调查，定期提供投资者情绪指数 (Investors' Intelligence of New Rochelle)，但是另一类方法则认为可以通过直接观察市场指数的上升和下降来度量投资者情绪状态。

事实上，不论是技术分析还是市场有效理论都承认以下这一事实：当市场的参与者对未来的价格判断总体处于乐观状态时，对股票的需求将超过供给，从而抬升股价；同样，当投资者的情绪整体处于悲观状态时，供给将超过需求，从而造成股价下跌。从这个角度来看，对投资者情绪的度量与技术形态的识别在一定程度上是一致的。

Osler 和 Chang (1995) 提出了一种锯齿形态 (zigzag pattern)，在这一形态中，如果某个局部最大值比前一个局部最大值高出一定的百分比，则将该局部最大值定义为波峰；同样，如果某个局部最小值低于前一个局部最小值一定的百分比，则将该局部最小值定义为波谷。他们发现用这一方法定义出来的“头肩”形态在外汇市场上有较好的重复性和预测力。

Lo, Mamaysky 和 Wang (2000) 用 kernel 核函数平滑的方法来寻找股价变动过程中的局部极值，并用此定义了五种技术形态，取得了较好的效果。该方法的优点在于通过 Kernel 核函数平滑的方式过滤了股价波动中的噪音，但是一个显然的缺点是平滑也过滤掉了原始的局部最高值和最低值。Zhou 和 Dong (2004) 等人的研究也存在类似的问题，在此不再详述。

以上分析可知，大量研究结果表明，由于克服了主观判断的影响，客观的技术形态识别方法具有一定的价值，但是也可能由于某些特殊的处理方式造成原始数据的部分重要信息（如最大值和最小值）有所丢失。

二、基于贪婪和恐惧的技术形态定义

借鉴 Osler 和 Chang (1995) 的思路, 本文通过完全客观的方法寻找股价波动过程中的变点, 并据此对锯齿形态进行了进一步的分类。这一做法的两个好处是: 一、变点的寻找是完全客观的; 二、保留了原始数据中的最大值和最小值这一重要的数据信息。

变点的定义方式如下:

$$P_{H_{t-n}} < P_{H_t} < P_{H_{t+n}} \quad (1a)$$

$$P_{L_{t-n}} > P_{L_t} > P_{L_{t+n}} \quad (1b)$$

其中, P_{H_t} 和 P_{L_t} 表示的是第 t 天中的最高价和最低价, n 表示变点前后的时间区域, 满足(1a)或(1b)的极值点都可能成为变点。如果连续两天内出现了两个一样大小的极值点, 那么把第一个极值点定义为变点, 第二个极值点可以看成是对前一个变点的确认。

此外, 由于在任意一个由以上公式定义的变点之后, 必定能观察到一个相反方向的极值点。为了更好的定义锯齿形态, 若由以上公式得到的相邻的两个变点都是局部极大值点, 那么在两者之间的极小值点也被定义为变点; 同样, 若由以上公式得到的相邻的两个变点都是局部极小值点, 那么在两者之间的极大值点也被定义为变点。


由于本文主要关注的是由恐惧和贪婪情绪构成的技术形态, 以及某类特殊的技术形态是否会重现, 因此采用变点方法的另一个好处是技术形态的分类会较为简单, 容易识别。得知最初的某一个变点后, 市场接下来的走势只能是向上或者向下, 再接下来市场终究又会朝着原来的变点方向移动, 从而形成一个新的变点, 然后市场又会朝着新的方向移动, 如此不断反复, 以至于构成了所谓的锯齿形态。

因此, 价格上涨 (a) 之后只可能出现两种情形-调整 (c) 或者下跌 (d); 同样, 价格下跌 (d) 之后也只可能出现两种情形-调整 (c) 或者上涨 (a)。

表 1 给出了两步法下基于变点识别方法定义的四种锯齿形态: I (ac)、II (ad)、III (dc)、IV (da)。其中: a 表示价格上涨且上涨后的价格超出了原有的高点, c 表示对原有趋势的调整且调整后的价格位于前两个变点之间, d 表示价格下跌且下跌后的价格低于原有的低点。

该定义的一个要点是第二步价格变动后的价格是否突破了初始价格, 这一方式的优点是显而易见的。根据 Tversky 和 Kahneman (1974) 的研究, 第二步中价格变动突破了初始价格后, 投资者将自动调整其价格参照点, 而如果不能突破初始价格, 价格参照点则维持不变。

表 1 两步法下四种锯齿形态定义

Pattern	Price Behavior	Definition using Turning Points
I (ac)		$1 < 2 \text{ and } 1 \leq 3$
II (ad)		$1 < 2 \text{ and } 1 > 3$
III (dc)		$1 > 2 \text{ and } 1 \geq 3$
IV (da)		$1 > 2 \text{ and } 1 < 3$

来源：Sequential Greed and Fear in Stock Prices, R. Sturm, Journal of Investing, 2012.

三、四种技术形态统计结果

由于第一个变点的价格低于第二个变点，形态 I 和 II 是牛市形态，而形态 III 和 IV 是熊市形态，统计这些形态出现的频率实际上具有一定的投资价值，可以用来设计交易策略。比如，如果发现形态 I 比形态 II 更经常出现，那么一旦探明变点 2 这个位置后，可以合理的预期该技术形态的支撑位及支撑强度。

为进一步探讨这一问题，表 2 给出了两步法中基于变点方法的四种技术形态统计结果。其中，Panel A、B 和 C 的统计结果中 N（前文变点构造中邻域的天数）的取值分别为 5 天、10 天和 20 天。为了进行对比，作者依据 Marshall, Cahan 和 Cahan (2008) 年的方法构建了两个比较基准（MCC 和 Modified MCC）。

结果表明，在真实样本中，没有一种形态的出现频率与 MCC 比较基准中的相应频率有显著差异，但当 N=5 以及 N=10 时，真实样本中形态 III 和 IV 的出现频率与 Modified MCC 中的相应频率差异显著，真实样本中形态 IV 的出现概率高于形态 III。这意味着在市场大跌之后，价格上涨至突破下跌之前价位的可能性相对更大。

这一结果可能与投资者普遍具有牛市心态或抄底心态有关，而与市场指数向上的漂移状态无关。这是因为，如果市场向上的漂移状态将对此产生影响，那么这一差异也应该在形态 I 和 II 中出现。此外，还应注意，这一差异仅在 N=5 和 N=10 两种情形中出现，这意味着这一技术形态或分析方法仅在短期内有效。

表 2 两步法中基于变点方法的四种技术形态统计（SP500，1962-2009）

Pattern	Frequency					
	S&P 500		MCC Benchmark		Modified MCC	
	<i>n</i>	<i>p</i>	<i>n</i>	<i>p</i>	<i>n</i>	<i>p</i>
Panel A: N = 5						
I (ac)	425	55%	433	55%	480	53%
II (ad)	343	45%	356	45%	434	47%
III (dc)	317	41%	353	45%	432	47%**
IV (da)	450	59%	438	55%	483	53%**
Panel B: N = 10						
I (ac)	236	58%	240	59%	257	56%
II (ad)	174	42%	168	41%	203	44%
III (dc)	166	40%	173	42%	216	47%*
IV (da)	245	60%	236	58%	244	53%*
Panel C: N = 20						
I (ac)	139	58%	135	55%	118	56%
II (ad)	101	42%	111	45%	93	44%
III (dc)	92	38%	108	44%	94	44%
IV (da)	148	62%	140	56%	118	56%

注：*，**表明真实样本与比较基准中结果差异度的显著性为 10%和 5%，N 为(1a)和(1b)中邻域取值的天数，n 为相应技术形态在样本中出现的次数，p 为相应形态出现的概率

来源：Sequential Greed and Fear in Stock Prices, R. Sturm, Journal of Investing, 2012.

以上结果表明：投资者普遍具有的贪婪心态或者抄底心态使得形态IV将以较大的概率重复出现。Sturm（2003）的研究表明，价格大幅变动之前的价格行为将影响投资者的信心，从而影响价格大幅变动之后的相应走势。也就是说以上四种形态之前的价格变动有可能对四种形态出现的概率有较大影响。

表 3 进一步给出了三步法中各种情形下技术形态出现概率的统计结果，并与其在两步法中的相应结果进行了对比。注意到，两步法中的四种技术形态 ac、ad、dc 和 da 将被进一步划分为（dac、dcc）、（dad、dcd）、（adc、acc）和（ada、aca）八种形态。

由表 3 的结果可知，考虑了价格大幅变动前价格行为的三步法技术形态识别有显著的区分度，能够将两步法下的技术形态做进一步细分，而且这一结果在 N=5、10 或 20 中都成立。

比如，两步法中形态 da 的出现概率为 59%，但是如果进一步分析 da 出现前的价格变动，会发现其细分子形态 aca 的出现概率将大幅提升至 75%，而另一细分子形态 ada 的出现概率则大幅降低至 38%。

表 3 技术形态统计：三步法 VS 两步法

Pattern	Frequency			
	S&P 500		S&P 500 Benchmark	
	<i>n</i>	<i>p</i>	<i>n</i>	<i>p</i>
Panel A: N = 5				
I (aca)	318	75%***	450	59%
II (acc)	106	25%***	317	41%
III (ada)	132	38%***	450	59%
IV (adc)	211	62%***	317	41%
V (dcd)	189	59%***	343	45%
VI (dcc)	129	41%***	425	55%
VII (dad)	154	34%***	343	45%
VIII (dac)	296	66%***	425	55%
Panel B: N = 10				
I (aca)	172	73%***	245	60%
II (acc)	65	27%***	166	40%
III (ada)	73	42%***	245	60%
IV (adc)	102	58%***	166	40%
V (dcd)	101	61%***	174	42%
VI (dcc)	65	39%***	236	58%
VII (dad)	73	30%***	174	42%
VIII (dac)	170	70%***	236	58%
Panel C: N = 20				
I (aca)	102	73%***	148	62%
II (acc)	37	27%***	92	38%
III (ada)	46	45%***	148	62%
IV (adc)	56	55%***	92	38%
V (dcd)	54	59%***	101	42%
VI (dcc)	38	41%***	139	58%
VII (dad)	47	32%***	101	42%
VIII (dac)	100	68%**	139	58%

注：*，**表明真实样本与比较基准中结果差异度的显著性为 10%和 5%，N 为(1a)和(1b)中邻域取值的天数，n 为相应技术形态在样本中出现的次数，p 为相应形态出现的概率

来源：Sequential Greed and Fear in Stock Prices, R. Sturm, Journal of Investing, 2012.

为了确保三步法中相应形态的概率偏离是由投资者情绪或者行为偏好导致的，我们将三步法得到的结果与相应的比较基准进行了对比，结果见表 4。

表 4 的结果显示，并不是每个形态的区分度都来源于投资者的情绪或行为偏好，但是基本结果与表 2 保持一致。

比如，当 N=5 时，与 Modified MCC 基准相比，形态 I（aca）和 VI（dcc）出现的概率相对更高，而形态 II（acc）和 V（dcd）出现的概率相对更低；当 N=10 时，与 Modified MCC 基准相比，形态 III（ada）出现的概率相对更高，形态 IV（adc）出现的概率相对更低。

考虑到形态 I（aca）、VI（dcc）和 III（ada）均属于牛市形态或熊市末期形态，而形态 II（acc）、V（dcd）和 IV（adc）均属于牛市末期形态或者熊市形态，以上结果表明投资者的情绪状态总是偏乐观的，做多的倾向更为明显。

从结果的显著程度来看，这一结果在 N=5 时更显著，当 N=20 时不再显著，进一步说明这一技术分析方法仅在较短的时间区间内有效。

表 2 的结果表明，在较短的时间区间内，价格大跌后更有可能出现价格的大幅上行，而且将上涨到超出下跌之前的水平；将这种“下跌-大涨”的形态进一步分解后发现，如果在下跌之前的价格是上涨的话，那么随后出现大涨的可能性将变得更大。

表 4 三步法中的技术形态统计（SP500，1962-2009）

Pattern	Frequency					
	S&P 500		MCC Benchmark		Modified MCC	
	<i>n</i>	<i>p</i>	<i>n</i>	<i>p</i>	<i>n</i>	<i>p</i>
Panel A: N = 5						
I (aca)	318	75%	303	70%*	323	67%***
II (acc)	106	25%	130	30%*	158	33%***
III (ada)	132	38%	134	38%	160	37%
IV (adc)	211	62%	222	62%	275	63%
V (dcd)	189	59%	227	65%	283	66%*
VI (dcc)	129	41%	124	35%	148	34%*
VII (dad)	154	34%	128	29%	151	31%
VIII (dac)	296	66%	309	71%	331	69%
Panel B: N = 10						
I (aca)	172	73%	166	69%	176	68%
II (acc)	65	27%	75	31%	82	32%
III (ada)	73	42%	70	41%	68	33%*
IV (adc)	102	58%	99	59%	135	67%*
V (dcd)	101	61%	98	57%	136	63%
VI (dcc)	65	39%	74	43%	80	37%
VII (dad)	73	30%	70	30%	67	28%
VIII (dac)	170	70%	165	70%	176	72%
Panel C: N = 20						
I (aca)	102	73%	94	69%	85	71%
II (acc)	37	27%	43	31%	34	29%
III (ada)	46	45%	46	41%	33	35%
IV (adc)	56	55%	66	59%	61	65%
V (dcd)	54	59%	71	67%	59	63%
VI (dcc)	38	41%	35	33%	35	37%
VII (dad)	47	32%	40	29%	34	29%
VIII (dac)	100	68%	99	71%	82	71%

注：*，**表明真实样本与比较基准中结果差异度的显著性为 10%和 5%，N 为(1a)和(1b)中邻域取值的天数，n 为相应技术形态在样本中出现的次数，p 为相应形态出现的概率

来源：Sequential Greed and Fear in Stock Prices, R. Sturm, Journal of Investing, 2012.

日最高与最低价的时间序列预测模型

文章来源: YIN-WONG CHEUNG, University of California, Santa Cruz, USA, AN EMPIRICAL MODEL OF DAILY HIGHS AND LOWS. Market's INTERNATIONAL JOURNAL OF FINANCE AND ECONOMICS, Int. J. Fin. Econ. 12: 1–20 (2007)

推荐人: 吴先兴 021-23219449

推荐理由: 股票价格行为一直被深入研究。尽管开盘价、收盘价、最高价和最低价都是可获得的, 对股票回报和波动性的研究通常只使用收盘价。收盘价比其他三个价格包含了更多的关于股票波动的信息吗? 答案似乎不是完全肯定的。价格波动区间(最高价-最低价)包含着关于回报波动率的有效信息。Parkinson(1980)的研究显示, 价格波动区间在一定假设下比基于收盘价的估计量更能有效地估计回报波动率¹。该文提供了一个对日最高与最低价格经验性质的探究性分析, 建立了一个基于最高价和最低价时间序列预测模型, 对未来价格波动区间的量化分析提供了极富意义的参考。

股票价格行为一直被深入研究。尽管开盘价、收盘价、最高价和最低价都是可获得的, 对股票回报和波动性的研究通常只使用收盘价。实际上, 基于收盘价的研究所数量远远超过基于其他三个价格的研究。收盘价比其他三个价格包含了更多的关于股票波动的信息吗? 答案似乎不是完全肯定的。例如, 最高价与最低价是对应于超额需求发生反转的价格, 这一信息没有被反映在收盘价格中。同时, 价格波动区间(最高价-最低价)包含着关于回报波动率的有效信息。Parkinson(1980)的研究显示, 价格波动区间在一定假设下比基于收盘价的估计量更能有效地估计回报波动率²。因此, 在股票行为研究中, 没有明显的理由忽略关于其他三个变量的信息。

最近, 对于价格波动区间研究的兴趣增加了。除了研究它的随机性质, 一些近期的研究使用价格波动区间来建模研究跨期波动行为(intertemporal volatility behavior), 从而把它包含在GARCH和随机波动率模型中来建立条件的或者局部的估计量³。在另一方面, Mok et al. (2000)直接利用最高价和最低价数据来检验标普 500 和恒生指数是否遵从随机游走。总体来说, 这方面的研究数量相对来说还是比较小⁴。

本研究提供了一个对日最高与最低价格经验性质的探究性分析。有几个理由研究日最高与最低价格: 首先, 最高最低价格相对于收盘价包含着额外的信息。例如, 日最高最低价格是资产价格序列的转折点, 而收盘价通常不是。进一步的来说, 最高最低价格可以被用来构造其他的有用变量例如价格波动区间。在研究中, 我们发现使用价格波动区间本身的历史数据进行研究次于使用描述最高最低价格行为的模型。

其次, 有些衍生品的定价需要最高和最低价格。例如, 敲出或敲入期权、回溯期权等奇异期权的构建是以约定期间的最高或是最低价格为基础的⁵。

再次, 最高价和最低价对于某些技术交易策略来说是关键性因素。⁶例如, 价格通道策略在收盘价突破由日最高最低价格数据建立的区间范围时, 进行买入或者卖出。支撑位和阻力位是价格有可能反转的位置, 对这些位置的突破被认为是重要的交易信号。除此之外, 最高价格和最低价格也被用来构造交易技术例如蜡烛图表和随机摆动指标。

¹Beckers (1983), Garman and Klass (1980), Kunitomo (1992), Rogers and Satchell (1991), and Yang and Zhang, (2000).

²Beckers (1983), Garman and Klass (1980), Kunitomo (1992), Rogers and Satchell (1991), and Yang and Zhang, (2000).

³例如 Alizadeh et. al. (2002), Brandt and Diebold (2003), Brunetti and Lildholdt (2005), Chou, (2005), Engle and Gallo (2003), Fernandes et al. (2005), and Gallant et al. (1999)

⁴在相关的研究中, 价格区间被用来研究数据的记忆强度。例如 Hurst (1951), Lo (1991) and Cheung (1993)

⁵回溯期权和敲出期权的例子

⁶例如 Edwards and Magee (1997)。Cheung and Wong (2000), Cheung and Chinn (2001), and Taylor and Allen (1992)。Lo et al. (2000)也对技术分析交易策略进行了深入研究

在此研究中使用的日最高价和最低价的经验模型的灵感是十分直觉性的。对于发达国家例如美国的股票市场，股票价格显示出随机趋势并且它是一个 $I(1)$ 过程，但每日最高价和最低价的差值并不显示出随着时间而差距变大。如果假设在股票价格产生过程中有一个随机趋势，那么最高价和最低价很可能被同一个随机趋势所驱动。如果这是真的，那么最高价和最低价可能分别漂移但是他们的价格差应该不会随着时间而变大。因此，最高价和最低价存在一个协整关系。

为了探究这一观点，我们考虑美国股市三大股指-道琼斯工业指数，纳斯达克指数和标普 500 指数并检验是否最高价和最低价是协整的。为了预期结果，检验验证了两者的之间的协整关系。由协整关系衍生出的 VECM 模型扩展在之后包含了其他的解释变量包括开盘价、收盘价和交易量。而最高价和最低价对冲击的回应在不同解释变量组的条件下进行了分析。

2.初步分析

在这一研究中，我们考虑美国三大股指-道琼斯指数，纳斯达克指数和标普 500 指数。使用从 1990 年 1 月 2 日到 2004 年 12 月 31 日的每日开收盘价、最高价、最低价和交易量。数据来源于雅虎财经和彭博网站。作为初步分析，使用 ADF-GLS（单位根检验的一个衍生模型）来分析平稳性。

检验结果显示在 Table1 中，单位根检验在开盘价，最高价，最低价，收盘价数据序列中都没有被拒绝，但是在价格波动区间和交易量上被拒绝了。为了与一般的研究作对比，Table1 中也显示了 augmentedDickey-Fuller test 的结果，这两个检验都标明开盘价，最高价，最低价，收盘价数据序列为 $I(1)$ 过程，价格波动区间和交易量为 $I(0)$ 。根据 Q 检验，用于检验的滞后结构充分地捕捉了跨期波动性。

表 1 单位根检验

Table 1. Unit root tests									
	ADF-GLS					ADF			
	STAT	LAG	Q5	Q10		STAT	LAG	Q5	Q10
<i>(A) The Dow Jones Industrial index</i>									
<i>O</i>	-1.352	8	0.007	1.422	-1.249	8	0.007	1.383	
<i>H</i>	-1.332	3	5.663	7.909	-1.225	3	5.657	7.910	
<i>L</i>	-1.513	6	0.069	5.640	-1.432	6	0.070	5.648	
<i>C</i>	-1.53	1	6.455	14.612	-1.447	1	6.483	14.642	
<i>V</i>	-7.106*	11	0.899	12.937	-9.588*	10	0.646	11.395	
<i>R</i>	-5.043*	10	0.324	6.950	-6.253*	10	0.170	3.858	
<i>(B) The NASDAQ index</i>									
<i>O</i>	-1.235	6	0.043	11.818	-1.210	6	0.044	11.857	
<i>H</i>	-1.235	5	0.733	3.359	-1.202	5	0.749	3.425	
<i>L</i>	-1.245	7	0.024	5.698	-1.223	7	0.024	5.672	
<i>C</i>	-1.264	3	2.572	7.610	-1.232	3	2.572	7.633	
<i>V</i>	-4.556*	13	1.257	11.019	-5.281*	10	1.916	15.072	
<i>R</i>	-6.413*	10	1.127	12.329	-7.122*	10	0.847	9.226	
<i>(C) The S&P 500 index</i>									
<i>O</i>	-1.071	8	0.025	1.149	-0.977	8	0.025	1.13	
<i>H</i>	-1.184	2	2.611	9.948	-1.099	2	2.657	10.035	
<i>L</i>	-1.156	10	0.006	0.229	-1.065	10	0.005	0.235	
<i>C</i>	-1.085	8	0.014	0.660	-0.98	8	0.014	0.631	
<i>V</i>	-5.081*	10	1.368	13.592	-5.548*	10	1.168	11.301	
<i>R</i>	-4.993*	11	0.716	13.543	-8.109*	10	0.382	8.664	

Note: The table reports results of applying the ADF-GLS and ADF tests to daily open (O), daily high (H), daily low (L), daily close (C), daily trading volume (V), and daily price range (R) series. Panels A, B, and C give results for the Dow Jones Industrial index, the NASDAQ index, and the S&P 500 index, respectively. 'ADF-GLS' and 'ADF', the ADF-GLS and ADF test results; 'STAT', the test statistics, 'LAG', the lag parameters used in the test procedures; 'Q5' and 'Q10', the Box-Ljung Q-statistics calculated from the first 5 and 10 estimated residual autocorrelations. None of the Q-statistics is significant. ** The rejection of the unit root null hypothesis at the 5% level.

资料来源：An Empirical Model of Daily Highs and Low

日开盘价 O_t 、收盘价 C_t 、最低价 L_t 、最高价 H_t 和交易量序列 V_t , $R_t=H_t-L_t$ 。 $\Delta O_t, \Delta C_t, \Delta L_t, \Delta H_t, V_t$ 和 R_t 的数据序列的关联度见 Table2。对于三大股指来说，

$\Delta O_t, \Delta L_t, \Delta H_t$ 有很高的相关系数 (0.57-0.80)。 ΔC_t 与 ΔO_t 的相关系数低,但是与 $\Delta L_t, \Delta H_t$ 有较高的相关系数。交易量与价格变量的变化的相关度很低,但是与价格波动区间有一个相对高的相关系数。这两者的较高相关性可能来自于各自与波动率的关系。在四个价格变量中,价格区间与 ΔL_t 相关度最大,其次是 ΔO_t 。在接下来的部分中,一个动态的多变量的设定将被用来研究最高价和最低价的跨期变化。

表 2 样本相关性

Table 2. Sample correlations					
	ΔO	ΔH	ΔL	ΔC	V
(A) The Dow Jones Industrial index					
ΔH	0.573				
ΔL	0.597	0.800			
ΔC	0.076	0.667	0.639		
V	0.013	0.065	-0.034	0.016	
R	-0.134	-0.015	-0.217	-0.038	0.542
(B) The NASDAQ index					
ΔH	0.762				
ΔL	0.761	0.782			
ΔC	0.260	0.646	0.640		
V	0.002	0.030	-0.019	0.017	
R	-0.232	-0.105	-0.337	-0.121	0.474
(C) The S&P 500 index					
ΔH	0.634	1.000			
ΔL	0.651	0.641	1.000		
ΔC	0.075	0.585	0.570	1.000	
V	-0.063	-0.024	-0.094	-0.026	
R	-0.200	0.034	-0.366	-0.062	0.498

Note: The sample correlations between the stationary variables ΔO_t , ΔH_t , ΔL_t , ΔC_t , and V_t of the Dow Jones Industrial index, the NASDAQ index, and the S&P 500 index are reported.

资料来源: An Empirical Model of Daily Highs and Low

3. 一个经验模型

如前所述,一个研究最高价和最低价的经验模型建立在这两个变量是相互联系并被一些共同的动态因素所驱动的直觉之上。上一节的检验结果显示最高价和最低价都是 I(1) 过程。因而,协整技术被用于探究他们的动态联系。

3.1 协整检验

Johansen procedure 被用来检验协整关系。令 X_t 为 2×1 向量包含着一个指数的每日的最高价和最低价 ($X_t = (H_t, L_t)'$)。 X_t 有一个 $(p+1)$ 阶的自回归表达式-式 2:

$$X_t = \mu + \sum_{i=1}^{p+1} \gamma_i X_{t-i} + \varepsilon_t \quad (2)$$

协整检验结果表明,对于一个给定的股票指数,它的每日最高和最低价格序列是协整的。这说明,它们被同一个随机过程驱动,并且各自随时间随机游走。但是,一个合适的最高价和最低价的线性组合能够消除随机趋势的影响,并且形成了一个平稳的均值回归序列。

3.2 VECM

假定日最高价和最低价序列是协整的,用 VECM 来检测它们的长期和短期的交互作用。VECM 能具体化为式 3:

$$\Delta X_t = \mu + \sum_{i=1}^p \Gamma_i \Delta X_{t-i} + \alpha R_{t-1} + \xi D_t + \varepsilon_t \quad (3)$$

其中 $D_t = (d_{2t}, d_{3t}, d_{4t}, d_{5t})'$ 包含着代表周二, 周三, 周四, 周五的虚拟变量。它被引入来考虑可能的星期影响。Q 统计量显示被选择的 VECM 模型充分的捕捉了数据的动态, 而干扰项没有显示出统计上显著的连续相关性 (Serial Correlation)。

主要实证结论, 首先, 在所有的三大指数中, 价格区间变量在日最高价等式中系数为负, 而在日最低价格等式中有系数为正。价格区间的增大倾向于拉低第二天的最高价, 拉高第二天的最低价。因而, 价格区间变量是自回归的, 这与它的平稳特性也是相符合的。这一结果与协整结果相符合, 并表明价格变量是一个相对合理的误差修正项。价格区间变量在三大股指最低价等式中都是显著的, 但仅仅在一个股指-纳斯达克指数的最高价等式中显著。但没有一个好的理由来解释为什么价格区间变量在日最低价等式中大部分显著而在日最高价等式不是这样。

第二, 对于所有指数, 所有的显著的因变量滞后项系数的估计量都是负的, 而所有的其他的滞后项系数都是正的。例如, 对于道琼斯工业指数的日最高价等式, 滞后的每日最高价的差分项系数是负的, 但那些滞后的日最低价的差分项系数是正的。负的系数表明了回归行为。更高的日最高价趋向于降低, 而较低的日最高价倾向于升高。另一方面, 滞后的日最低价格差分的正系数表明了溢出效应。更高的日最低价导致更高的日最高价, 反之亦然。

第三, 误差修正模型对于股价变动的解释力很好。以标普 500 为数据的模型有最高的调整 R 方 (16.5% 和 17.6%)。对于另外两个股票指数, 调整 R 方在 7.9% 和 9.6% 之间。

此外, 估计表明在日最高和最低数据中星期影响非常弱。大部分星期虚拟变量不显著。对于少数显著的, 其估计量的绝对大小很小。当 D_t 从式子中省略时, 其他估计量本质上是相同的 (考虑到量级和统计显著性), 调整 R 方减少了不到 0.1%。实际上, 对于所有的三个指数, 忽略代表星期影响的虚拟变量情况下, 贝叶斯信息准则 (BIC) 选择的结果都有可以以本质上相同的 Q 统计量通过诊断检验。因而, 为了简介, 星期影响在后续分析中被忽略。

表 4 对 Basic VECM 的估计

Table 4. Estimates of the basic vector error correction models				
	ΔH		ΔL	
	COEFF	T-STAT	COEFF	T-STAT
<i>(A) The Dow Jones Industrial index</i>				
$\Delta H(-1)$	-0.201	-6.492	0.550	15.691
$\Delta H(-2)$	-0.256	-6.951	0.279	6.701
$\Delta H(-3)$	-0.151	-3.877	0.259	5.863
$\Delta H(-4)$	-0.099	-2.507	0.219	4.902
$\Delta H(-5)$	-0.046	-1.202	0.215	4.950
$\Delta H(-6)$	0.028	0.804	0.216	5.553
$\Delta L(-1)$	0.388	14.254	-0.232	-7.509
$\Delta L(-2)$	0.143	4.449	-0.354	-9.707
$\Delta L(-3)$	0.156	4.549	-0.236	-6.045
$\Delta L(-4)$	0.126	3.605	-0.183	-4.625
$\Delta L(-5)$	0.013	0.376	-0.251	-6.501
$\Delta L(-6)$	-0.024	-0.789	-0.206	-5.908
μ	0.001	1.896	-0.001	-1.226
$R(\cdot)$	-0.011	-0.605	0.070	3.474
d_{2t}	0.000	0.243	0.000	-0.612
d_{3t}	0.000	-1.083	-0.001	-2.421
d_{4t}	-0.001	-1.539	-0.001	-1.772
d_{5t}	-0.001	-2.063	-0.001	-1.506
Adjusted R^2	0.082		0.096	
Q5	0.062		0.278	
Q10	2.564		7.367	
<i>(B) The NASDAQ index</i>				
$\Delta H(-1)$	-0.274	-8.790	0.564	15.019
$\Delta H(-2)$	-0.297	-7.775	0.341	7.437
$\Delta H(-3)$	-0.213	-5.186	0.351	7.112
$\Delta H(-4)$	-0.091	-2.153	0.370	7.238
$\Delta H(-5)$	-0.077	-1.829	0.253	4.975
$\Delta H(-6)$	0.002	0.045	0.229	4.719
$\Delta H(-7)$	-0.006	-0.170	0.196	4.594
$\Delta L(-1)$	0.428	16.530	-0.282	-9.044
$\Delta L(-2)$	0.209	6.437	-0.407	-10.438
$\Delta L(-3)$	0.215	6.057	-0.302	-7.075
$\Delta L(-4)$	0.117	3.155	-0.319	-7.159
$\Delta L(-5)$	0.075	2.002	-0.290	-6.470
$\Delta L(-6)$	0.003	0.095	-0.269	-6.261
$\Delta L(-7)$	0.033	1.021	-0.175	-4.515
μ	0.001	1.637	-0.001	-1.138
$R(\cdot)$	-0.053	-2.514	0.047	1.851
d_{2t}	0.001	0.928	0.000	0.156
d_{3t}	0.000	0.078	0.000	-0.504
d_{4t}	0.001	1.541	0.001	1.713
d_{5t}	0.000	-0.690	0.001	0.925
Adjusted R^2	0.094		0.079	
Q5	0.174		0.537	
Q10	1.857		9.257	
<i>(C) The S&P 500 index</i>				
$\Delta H(-1)$	-0.302	-11.980	0.730	24.937
$\Delta H(-2)$	-0.414	-12.471	0.374	9.687
$\Delta H(-3)$	-0.254	-6.906	0.403	9.429

资料来源: An Empirical Model of Daily Highs and Low

表 4 (续) 对 Basic VECM 的估计

Table 4. (continued)

	ΔH		ΔL	
	COEFF	T-STAT	COEFF	T-STAT
$\Delta H(-4)$	-0.208	-5.433	0.365	8.218
$\Delta H(-5)$	-0.122	-3.198	0.334	7.519
$\Delta H(-6)$	-0.074	-2.013	0.324	7.562
$\Delta H(-7)$	-0.067	-2.063	0.211	5.584
$\Delta L(-1)$	0.533	24.699	-0.294	-11.706
$\Delta L(-2)$	0.230	8.141	-0.503	-15.311
$\Delta L(-3)$	0.283	8.912	-0.336	-9.108
$\Delta L(-4)$	0.180	5.371	-0.363	-9.322
$\Delta L(-5)$	0.120	3.543	-0.342	-8.664
$\Delta L(-6)$	0.050	1.535	-0.330	-8.663
$\Delta L(-7)$	0.056	1.924	-0.238	-6.985
μ	0.001	2.621	-0.001	-1.834
$R(.)$	-0.034	-1.520	0.120	4.589
d_{2t}	0.000	-0.245	0.000	-0.543
d_{3t}	-0.001	-1.322	-0.001	-1.262
d_{4t}	0.000	-0.863	0.000	-0.873
d_{5t}	-0.001	-1.434	-0.001	-1.789
Adjusted R^2	0.165		0.176	
Q5	0.165		0.207	
Q10	2.410		4.229	

Note: The estimates of the vector error correction model (3) are reported. Panels A-C give the results for the Dow Jones Industrial index, the NASDAQ index, and the S&P 500 index. Results pertaining to the high and the low equations are reported under the headings ' ΔH ' and ' ΔL .' t -statistics are given in parentheses next to the parameter estimates. ' μ ' is the constant term. $R(.)$ is the lagged range, which is the error correction term with the (1, -1) coefficient restriction. d_{2t} , d_{3t} , d_{4t} , are the Tuesday, Wednesday, Thursday, and Friday dummy variables capturing the day-of-the-week effects. The adjusted R^2 statistics are reported in the row labelled 'Adjusted R^2 .' Q5 and Q10 give the Q -statistics calculated from the first 5 and 10 sample autocorrelations, respectively. All the Q -statistics are insignificant.

资料来源: An Empirical Model of Daily Highs and Low

4. 增广模型

4.1 增加价格变量和交易量变量

由于开盘价和收盘价是同一个价格序列的实现, 他们包含了关于日最高价和最低价演化的信息。另外交易量是一个在研究中被广泛考虑的外生变量。直觉上来说, 交易量是一个相关变量, 因为价格是由供求共同决定的。但事实上, 有相当丰富的关于回报率与交易量的关系的理论和实证研究⁷。因此, 加入开盘价和收盘价以及交易量的数据将会改善模型的表现。

$$\Delta X_t = \mu + \sum_{i=1}^p \Gamma_i \Delta X_{t-i} + \alpha R_{t-1} + \sum_{i=1}^q \Lambda_i \Delta Y_{t-i} + \sum_{i=1}^r \theta_i CO_{t-i} + \sum_{i=0}^s \delta_i V_{t-i} + \varepsilon_t \quad (4)$$

ΔY_{t-i} 是一个矩阵, 其中包含了 ΔO_{t-i} 和 ΔC_{t-i} , $CO_{t-i} = C_{t-i} - O_{t-i}$, V_{t-i} 代表交易量。等式中 ΔY_{t-i} 和 CO_{t-i} 的显著的系数均为正值, 表明日间开盘价和收盘价的变动幅度和一天内收盘价与开盘价之差都与最高价和最低价的变动正相关。收盘价和开盘价捕捉到的局部的价格变动势头帮助解释了日最高价和最低价的变动。

当期交易量和日最高价的变动是正相关的。而滞后的交易量项和日最高价的变动是负相关的。这一结果在日最低价等式中很不相同: 当期交易量和日最低价格的变化负相关, 对纳斯达克和标普 500 指数而言滞后期的交易量对日最低价变化有显著正向影响, 而对道琼斯工业指数影响不明显。

V_t 相对于 ΔY_t 和 CO_t 的解释力和交易量的次要地位是相符合的。在技术分析中,

⁷Karpoff (1987) 有一个关于早期研究的详细回顾。最近的深入研究是 Lo and Wang (2001)

交易量图线通常用来确认价格模式，但是不用来作为主要的预测参考。根据 R 方统计量，模型解释了两变量变动中的近 50%。

表 7 对加入新价格变量和交易量的 VECM 的估计

Table 7. Estimates of the vector error correction models with additional price variables and trading volume

	ΔH		ΔL	
	COEFF	T-STAT	COEFF	T-STAT
<i>(A) The Dow Jones Industrial index</i>				
$\Delta H(-1)$	-0.780	-23.692	-0.137	-3.721
$\Delta H(-2)$	-0.565	-13.936	-0.098	-2.152
$\Delta H(-3)$	-0.418	-9.818	-0.027	-0.566
$\Delta H(-4)$	-0.226	-5.554	0.138	3.026
$\Delta H(-5)$	-0.116	-3.390	0.221	5.776
$\Delta H(-6)$	-0.028	-0.944	0.236	7.039
$\Delta L(-1)$	-0.031	-1.103	-0.763	-24.077
$\Delta L(-2)$	-0.005	-0.154	-0.617	-16.055
$\Delta L(-3)$	0.024	0.670	-0.444	-11.018
$\Delta L(-4)$	0.084	2.446	-0.289	-7.529
$\Delta L(-5)$	0.074	2.463	-0.259	-7.720
$\Delta L(-6)$	0.029	1.050	-0.227	-7.449
μ	0.001	3.228	-0.002	-4.908
V	0.005	9.275	-0.004	-6.720
$V(-1)$	-0.003	-5.155	0.000	0.684
$\Delta O(-1)$	0.392	4.392	0.372	3.712
$\Delta O(-2)$	0.105	1.437	0.171	2.095
$\Delta O(-3)$	0.105	1.914	0.137	2.221
$\Delta O(-4)$	0.081	2.938	0.078	2.524
$\Delta C(-1)$	0.418	4.124	0.595	5.228
$\Delta C(-2)$	0.232	2.621	0.439	4.431
$\Delta C(-3)$	0.331	4.678	0.394	4.961
$\Delta C(-4)$	0.143	2.860	0.160	2.843
$CO(-1)$	-0.437	-4.321	-0.426	-3.751
$R(.)$	-0.045	-2.653	0.107	5.569

资料来源: An Empirical Model of Daily Highs and Low

表 7 (续) 对加入新价格变量和交易量的 VECM 的估计

Table 7. (continued)

	ΔH		ΔL	
	COEFF	T-STAT	COEFF	T-STAT
Adjusted R^2	0.390		0.412	
Q5	1.800		2.148	
Q10	4.402		5.065	
<i>(B) The NASDAQ index</i>				
$\Delta H(-1)$	-0.776	-22.387	-0.054	-1.310
$\Delta H(-2)$	-0.493	-11.283	0.070	1.345
$\Delta H(-3)$	-0.364	-8.616	0.147	2.929
$\Delta H(-4)$	-0.160	-4.647	0.307	7.496
$\Delta H(-5)$	-0.069	-2.037	0.313	7.793
$\Delta H(-6)$	-0.049	-1.495	0.239	6.174
$\Delta H(-7)$	-0.054	-1.846	0.209	6.042
$\Delta L(-1)$	0.056	1.944	-0.753	-22.025
$\Delta L(-2)$	0.143	4.038	-0.523	-12.405
$\Delta L(-3)$	0.154	4.417	-0.410	-9.918
$\Delta L(-4)$	0.162	5.434	-0.293	-8.259
$\Delta L(-5)$	0.085	2.846	-0.317	-8.925
$\Delta L(-6)$	0.065	2.241	-0.253	-7.366
$\Delta L(-7)$	0.050	1.911	-0.218	-6.946
μ	0.002	5.106	-0.001	-2.019
V	0.011	11.731	-0.004	-3.886
$V(-1)$	-0.008	-8.067	0.002	2.007
$\Delta O(-1)$	0.325	6.367	0.426	7.004
$\Delta O(-2)$	0.149	3.336	0.236	4.423
$\Delta O(-3)$	0.094	3.008	0.159	4.285
$\Delta C(-1)$	0.296	5.601	0.313	4.978
$\Delta C(-2)$	0.155	3.416	0.210	3.887
$\Delta C(-3)$	0.101	3.163	0.128	3.366
$CO(-1)$	-0.605	-11.405	-0.805	-12.762
$R(.)$	-0.069	-3.727	0.092	4.181
Adjusted R^2	0.476		0.479	
Q5	1.676		0.805	
Q10	7.662		3.166	
<i>(C) The S&P 500 index</i>				
$\Delta H(-1)$	-0.891	-27.577	0.033	0.895
$\Delta H(-2)$	-0.686	-16.449	0.023	0.487
$\Delta H(-3)$	-0.493	-11.546	0.147	2.971
$\Delta H(-4)$	-0.258	-7.075	0.358	8.507
$\Delta H(-5)$	-0.133	-3.739	0.383	9.332
$\Delta H(-6)$	-0.120	-3.514	0.344	8.668
$\Delta H(-7)$	-0.086	-2.803	0.251	7.086
$\Delta L(-1)$	0.063	2.315	-0.847	-26.885
$\Delta L(-2)$	0.081	2.379	-0.711	-18.040
$\Delta L(-3)$	0.121	3.426	-0.527	-12.959
$\Delta L(-4)$	0.187	5.969	-0.393	-10.843
$\Delta L(-5)$	0.139	4.390	-0.382	-10.418
$\Delta L(-6)$	0.096	3.112	-0.345	-9.714
$\Delta L(-7)$	0.088	3.147	-0.267	-8.260
μ	0.001	2.499	-0.002	-6.120
V	0.004	6.808	-0.007	-9.927
$V(-1)$	-0.004	-6.413	0.003	3.769
$\Delta O(-1)$	0.374	4.741	0.273	2.997

资料来源: An Empirical Model of Daily Highs and Low

表 7 (续) 对加入新价格变量和交易量的 VECM 的估计

Table 7. (continued)

	ΔH		ΔL	
	COEFF	T-STAT	COEFF	T-STAT
$\Delta O(-2)$	0.320	5.229	0.310	4.384
$\Delta O(-3)$	0.222	6.923	0.231	6.222
$\Delta C(-1)$	0.384	4.269	0.570	5.480
$\Delta C(-2)$	0.261	3.561	0.503	5.924
$\Delta C(-3)$	0.121	2.372	0.221	3.741
$CO(-1)$	-0.477	-5.220	-0.437	-4.141
$R(.)$	-0.041	-1.853	0.180	7.006
Adjusted R^2	0.485		0.507	
Q5	3.383		2.073	
Q10	5.484		8.160	

Note: The estimates of the augmented vector error correction model (7) for the high and the low are reported. Panels A-C give the results for the Dow Jones Industrial index, the NASDAQ index, and the S&P 500 index. $\Delta O(.)$, $\Delta C(.)$, $CO(.)$, and $V(.)$ are the extra explanatory variables added to the basic VECM (3). See also the Note to Table 4.

资料来源: An Empirical Model of Daily Highs and Low

4.4 冲击回应

在这一节中, 我们使用广义脉冲分析技术 (Pesaran and Shin, 1998) 来检验在不同的模型中冲击对于日最高价和最低价格的影响。

冲击响应模式在各个模型中不同, 但是这些模式在三大股指中十分相似。总的来说, 对最高价和最低价的变动的冲击是短期的。对于基本的 VECM 模型和冲击发生一天之后响应来说, 日最高价的冲击对日最低价(滞后一天的)的影响大于对日最高价的影响(滞后一天的)⁸。而日最低价的冲击对日最高价的影响也大于对日最低价的。所有的滞后一天的反应都是正向的, 并且影响在第一天之后迅速消失。

对三大指数来说, 交易量对冲击回应模式的影响似乎不大。同预期的一样, 广义冲击回应分析证实了前边的研究-开盘价和收盘价包含了关于最高价和最低价的变动的显著信息, 它们的信息量比交易量所包含的要大。

⁸ 横轴上的数字 2 对应着初始单位冲击的滞后一天的响应

图 1 一般冲击反应 (A) 道琼斯工业指数 (B) 纳斯达克指数 (C) 标普 500




Figure 1. Generalized impulse responses. (A) The Dow Jones Industrial index, (B) the NASDAQ index, (C) the S&P 500 index.

资料来源: An Empirical Model of Daily Highs and Low

图 1 (续) 一般冲击反应 (A) 道琼斯工业指数 (B) 纳斯达克指数 (C) 标普 500




Figure 1—Continued.

资料来源: An Empirical Model of Daily Highs and Low

图 1 (续) 一般冲击反应 (A) 道琼斯工业指数 (B) 纳斯达克指数 (C) 标普 500




Figure 1—Continued.

资料来源: An Empirical Model of Daily Highs and Low

5 结论

受每日最高价与最低价之差不随时间变大的启发，我们基于协整概念构建了一个关于这两个变量的经验模型。结果显示三大美指的日最高与最低价格是具有协整关系的。

开盘价、收盘价和交易量的数据对于解释 VECM 模型中的最高和最低价格有贡献。开盘价和收盘价的贡献高于交易量。包含所有的变量的扩展 VECM 模型（augmented VECM）可以解释最高最低价格变化的 40%-50%。

本研究建模分析构成价格波动区间的最高价和最低价。协整结果显示了仅仅使用价格区间的历史数据来建模是不完善的。对价格区间的建模应该包含最高价和最低价的信息。同时，最高价和最低价可以描述价格区间，但是由价格区间很难得出最高价和最低价的信息。因此，一个最高价和最低价的模型是对现有的对价格区间数据直接建模的研究的补充。

本文建立的模型具有很好的解释力。尽管我们不能阐明这一经验模型的优越性，研究结果确实对股票价格变动研究有一定的启示作用。例如，在构建 GARCH 模型以研究股票收益率过程中，从本文模型中获取的价格区间变量可以用来为条件波动率建模。使用这一价格区间变量也可以改善 GARCH 类型的模型。进一步的，价格区间是波动率的有效估计变量。经验模型提供的对波动率的合理预测，能为期权定价和风险管理提供参数⁹。总的来说，本文的模型可以应用于以（条件）波动率为基础模型中。基于本文的模型，对奇异期权定价和评估和涉及最高价和最低价的技术分析方法有进一步的研究前景。

⁹Cheung et. al., 2005 的研究表明由 VECM 产生的对价格区间的预测要比其他任何形式例如 ARMA 都要好

基于核函数的金融时间序列方向变化的预测技术

文献来源: Andrew Skabar(2008) A kernel-based technique for direction-of-change financial time series forecasting Lecture Notes in Computer Science 5102,: 441-449

推荐人: 冯佳睿 021-23219732

推荐理由: 本文呈现了一个预测时间序列变化方向的全新技术。核方法被用来估计正、负收益的密度函数, 随后进一步生成对未来的预测。该技术的最大优势是相比于以回归为基础的那些方法, 它只涉及极少的参数, 控制着核估计的窗宽。对于核函数中的协方差矩阵, 本文提出了一个特殊的形式, 使得近期数据在确定密度时的作用更大, 这对于避免过拟合是非常重要的。最后, 通过对澳大利亚普通股指数超过 15 年的样本外预测, 证明了此方法的优异性质。

几乎所有的金融时间序列预测最终都会归结到自回归问题, 即在过去观测的基础上预测序列的未来值。常见的做法是, 首先利用样本内数据优化预测模型的参数, 再利用模型在样本外进行预测, 最后通过比较预测值和真实值来度量预测的精度。

在评价预测精度的时候, 主流的做法集中在度量误差的大小上。例如, 在 De Gooijer 和 Hyndman(2006)的文献中, 总共介绍了 17 种常见的度量预测精度的方法, 都是基于预测值和真实值的偏差大小所设计的。但是在很多情况下, 一旦序列走势的方向预测准确, 误差的大小往往就变得不那么重要了。比如, 当一位投资者想要基于预测值做出交易决策时, 能够正确预测价格变化方向的技术远比获得一个较小的预测均方误差的方法更重要。本文将此类技术称之为“变化方向的预测”。

1. 变化方向的预测

预测序列变化方向的一个简单直接的办法是运用回归模型得到下一个时点上的预测值, 然后通过比较它与现值的大小转化为对方向的判断。如果预测值大于现值, 则预测序列“向上”; 否则预测其“向下”。也就是说, 变化方向的预测可以被看作是包含了一步判断的简单回归问题。

许多回归模型被用来完成这个使命, 其中大部分都是线性的。但是随着近年来非线性方法的流行, 利用此类模型进行预测也是屡见不鲜。神经网络就是一个很好的例子, 很多报告都使用这种方法来对金融时间序列进行预测。但是, 非线性模型是否能够比线性或随机游走模型提供更好的预测精度, 一直都存在着巨大的争议。其中一个主要的争论焦点就是非线性模型都包含大量参数。比如一个典型的神经网络架构通常有 100 个以上的权重待优化, 使用传统的梯度下降技术往往会导致严重的过拟合问题, 这在使用包含大量噪声的金融商品价格数据时显得更为突出。为了防止过拟合的出现, 要求在使用神经网络时更加细致地挑选隐藏单元的个数、标准化的系数以及早期的停止点, 而完成这些步骤就需要非常繁琐且代价巨大的交叉验证过程。而且, 在优化过程中使用不同的权重初始值并不一定能够得到相同的预测结果。

本文采用了一个在概念上完全不同的方法来预测时间序列的变化方向。和将预测作为一个回归问题来处理不同, 本文将其视作一个二元的分类问题, 直接预测变化的方向。这样做有以下几个好处。第一, 投资者是基于他们对某个商品的价格在未来是上涨还是下跌的判断, 而非涨跌的幅度, 来做出交易决策的。这就在金融系统内部创造出一股潜在的动力, 使得预测变化方向比预测具体的值更加可靠。第二, 将预测概念化为一个分类问题后, 可以应用更多的统计手段, 而不仅仅局限于回归。本文将具体介绍一类可生成的分类模型, 结合密度函数估计和贝叶斯定理, 在获得序列向上或向下移动的后验概率之后做出推断。而非类似于神经网络方法那样, 找到某个最优函数后, 将一组输入变量映射到变化方向的预测上去。它相对于传统分类技术的一个最大优势在于其精简的模

型，通常只包含少数几个参数。

下文将具体介绍该方法的实施步骤，并以澳大利亚普通股 (AORD, Australian All Ordinaries) 指数为对象进行实证分析。

2. 可生成的分类模型

可生成分类模型的基础是估计产生观测数据的概率密度函数。具体来讲，首先估计密度函数，接着使用贝叶斯定理生成后验概率，最后运用这一概率分布进行分类。以下着重介绍密度估计方法是如何被应用到时间序列变化方向的预测上去的。

2.1 准备工作

由于金融商品的价格序列通常都是高度不平稳的，因此很自然地需要对原始的价格数据做一定的变换。而变换后的变量一般都是依赖于绝对或相对的价格变化，本文将使用收益率。第 t 日的收益率定义为 $r_t = (p_t - p_{t-1}) / p_{t-1}$ ，其中 p_t 和 p_{t-1} 分别是第 t 日和第 $t-1$ 日的价格。本文的目标是预测价格在第 t 日的变化方向，也就是预测 r_t 的符号。特别地，本文希望在第 t 日之前的 D 个交易日收益率的基础上预测 r_t 的符号。记 $(r_{t-1}, r_{t-2}, \dots, r_{t-D})$ 为第 t 日的滞后收益率向量，那么本文的目标就是基于 $(r_{t-1}, r_{t-2}, \dots, r_{t-D})$ 预测 $\text{sign}(r_t)$ 。为记号方便，将上述向量以列向量的形式表达，记为 $X_t = (r_{t-1}, r_{t-2}, \dots, r_{t-D})^T$ ，并称其为一个数据点。如果存在 N 个数据点，那么可用如下形式表示这个数据集： $X = \{x_1, x_2, \dots, x_N\}$ ，其中 $|X| = N$ 。

2.2 密度估计

在统计学中，有三种最常用的方法估计概率密度函数：参数、非参数和半参数。参数方法要求事先假定分布的形式（例如，正态分布），之后的工作就是去估计决定该分布的若干个参数（例如，正态分布的均值和协方差矩阵）。不过，这一方法的问题在于很多数据都不服从一个标准的分布，强行对其建模常常会导致非常糟糕的估计结果。

第二种方法是核估计或称为 Parzen 窗估计方法，是一个典型的非参数技术。其基本思想是利用一定范围内各点密度的平均值对总体密度函数进行估计，即

$$p(x) = \frac{1}{|X|} \frac{1}{(2\pi)^{D/2} |\Sigma|^{1/2}} \sum_{n=1}^{|X|} \exp\left(-\frac{1}{2}(x - x^n)^T \Sigma^{-1}(x - x^n)\right), \quad (1)$$

其中 x 就是需要估计概率密度的那个点，而 $X = \{x_1, x_2, \dots, x_N\}$ 则是用来估计密度函数的一组样本，因子 $1/(2\pi)^{D/2} |\Sigma|^{1/2}$ 是一个常数，它保证了在每一处使用正态核函数的区域内，密度函数估计量的和始终等于 1， Σ 是正态核函数的协方差矩阵。这一方法的关键之处就在于 Σ 的选择，它决定了核函数在每一个窗口 (window) 内的形状，起到了光滑参数的作用。如果窗宽太窄，那么估计的密度函数在每个样本点周围都会出现尖峰；反之，若窗宽太大，密度函数则会被过度平滑。

第三个方法是半参数，或称为混合模型，它可视作是参数和非参数方法的某种折衷。使用半参数方法时，需要 M 个分布来对模型建模，其中 M 是远远小于样本点的个数的。

在下文中，仅讨论非参数方法的运用。

2.3 分类

由贝叶斯定理可知，某个观测 x 属于类别 C_j 的后验概率是

$$p(C_j | x) = \frac{p(x | C_j) P(C_j)}{p(x)}, \quad (2)$$

其中 $p(x|C_j)$ 是已知样本属于类别 C_j 的条件概率密度函数; $P(C_j)$ 是样本属于类别 C_j 的先验概率, 可由训练样本估计得到; $p(x)$ 是 x 的无条件概率密度函数。而 $p(x)$ 可由下式确定

$$p(x) = \sum_{j=1}^J p(x|C_j)P(C_j), \quad (3)$$

故可将其视为一个正则因子, 保证各类别的概率之和为 1。在获得所有的后验分布之后, 可将 x 归类到 $p(C_j|x)$ 最大的那个类别 C_j 。变化方向的预测是一个二元分类问题, 一个样本或者属于类别 C_+ (向上移动), 或者属于 C_- (向下移动)。假定数据点 X 被分成两个集合, X_+ 和 X_- , 各自包含向上和向下移动所对应的数据点, 那么 $p(x|C_+)$ 的 Parzen 估计是

$$p(x|C_+, \Sigma) = \frac{1}{|X_+|} \frac{1}{(2\pi)^{D/2} |\Sigma|^{1/2}} \sum_{n=1}^{|X_+|} \exp\left(-\frac{1}{2}(x - x_{+,n})^T \Sigma^{-1} (x - x_{+,n})\right), \quad (4)$$

类似地, 还能给出 $p(x|C_-)$ 的表达式。利用贝叶斯定理可以估计 $P(C_+|x_n, \Sigma)$ 和 $P(C_-|x_n, \Sigma)$ 这两个后验概率。

3. 协方差矩阵的优化

本文使用上述的非参数方法估计密度函数, 因此唯一需要确定的参数就是在估计过程中定义正态核函数所必需的协方差矩阵。下面, 首先讨论如何将该协方差矩阵参数化, 然后再研究怎样优化其中的参数。

3.1 协方差矩阵的参数化

一般说来, 协方差矩阵可以取三种形式: 球型, 每个维度上的方差都相等; 对角型, 不同维度上的方差不同, 但是主方向与坐标轴一致; 完整型, 方差的主方向可任意。由于 Σ 是一个对称阵, 在绝大多数情况下, 它包含 $D(D+1)/2$ 个独立成分, 其中 D 是输入空间的维度 (即, 滞后收益率的个数)。在对角型的情形中, 协方差矩阵所有的非对角元素都等于零, 这样一来, 独立成分的数量就减少为 D 个。而在球型的情形中, 协方差矩阵的对角元都相等, 因此只存在一个非零的成分。

来自于时间序列的数据点通常都是有序的, 而且从直觉上讲, 近期值在用来预测时也往往比那些距今较久远的值更重要。也就是说, 预测应当对近期值更加敏感。鉴于此, 核函数中的协方差矩阵就不应该是完全对称 (即, 球型) 的, 而应该给距今不同时期的收益率数据以不同的权重。为了满足这个要求, 对于不同滞后期数, 可以假定如下的方差形式:

$$\sigma_{t-n}^2 = ae^{k(n-1)}, \quad (5)$$

其中 σ_{t-n}^2 ($n \in \{1, 2, \dots, D\}$) 是核函数中方向平行于滞后项 r_{t-n} 所对应坐标轴的方差, k 是一个指数尺度因子, a 表示平行于滞后期一期的方差。这样, 协方差矩阵 Σ 的形式为:

$$\begin{pmatrix} a & 0 & 0 & \cdots & 0 \\ 0 & ae^k & 0 & \cdots & 0 \\ 0 & 0 & ae^{2k} & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & ae^{(D-1)k} \end{pmatrix}.$$

从这个协方差矩阵的形式可以看出, 共有 D 个滞后收益率对密度函数的估计起作用, 并且随着滞后期的增大, 所起的作用呈指数级递减。

3.2 协方差矩阵参数的 MAP 优化

假定所要研究的样本被分成两部分：训练数据集 X ，以及 holdout 验证数据集 X_h 。在 holdout 验证数据集中的观测是独立同分布的假定下，最优的 Σ 就是预测 holdout 样本变化方向最准确的那个值。记该值为 $\Sigma_{MAP}(\text{max a posteriori})$ ，并可由下式计算得到

$$\begin{aligned}\Sigma_{MAP} &= \underset{\Sigma}{\operatorname{argmax}} \prod_{n=1}^{|X_h|} P(C_+ | x_n, \Sigma)^{y_n} P(C_- | x_n, \Sigma)^{1-y_n} \\ &= \underset{\Sigma}{\operatorname{argmax}} \sum_{n=1}^{|X_h|} y_n \ln(P(C_+ | x_n, \Sigma)) + (1-y_n) \ln(P(C_- | x_n, \Sigma))\end{aligned}\quad (6)$$

其中 $P(C_+ | x_n, \Sigma)$ 和 $P(C_- | x_n, \Sigma)$ 分别是第 n 个交易日序列向上和向下移动的概率， y_n 是观测到的第 n 个交易日的变化方向；即，如果 $r_n > r_{n-1}$ ，那么 $y_n=1$ ；否则 $y_n=0$ 。通过以上的参数化之后，优化协方差矩阵的问题就转化成寻找最优的 a 和 k 。在下文的实证中，这两个参数是通过格点搜索的方法得到的。

4. 实证结果

假定收益率序列是平稳的，那么以抛硬币的方式预测序列未来变化方向的准确率可以认为是 50%，而如果本文模型确实有效，那么它的预测正确率应当显著高于 50%。但不幸的是，很多金融时间序列都是非平稳的，因为从较长的周期来看，价格始终有向上的趋势，所以只要简单地预测每天上涨，就能使准确度显著大于 50%。如下的方法可以用来弥补由于这种非平稳性带来的预测偏差。

记 z_a 代表样本外测试期中所有上涨的交易日所占的比例， z_p 代表预测上涨的交易日所占的比例。因此在抛硬币的模型下，做出正确向上预测的期望占比应为 $(z_a \times z_p)$ ，而正确预测下跌的期望比例则为 $((1-z_a) \times (1-z_p))$ 。如此，正确预测的期望占比为

$$w_{exp} = (z_a \times z_p) + ((1-z_a) \times (1-z_p)). \quad (7)$$

那么，下文想要检验的就是 w_{mod} （本文模型的预测正确率）是否显著地高于 w_{exp} （补偿后的抛硬币预测正确率）。因此，这个假设检验问题就可以表达为如下的形式：

$$H_0: w_{mod} \leq w_{exp} \quad H_1: w_{mod} > w_{exp}$$

下面将以澳大利亚普通股指数的部分样本为研究对象，利用样本外预测的结果，对上述问题进行单边 t 检验。具体说来，样本的时间区间为 1992 年 1 月至 2006 年 12 月 31 日，将其分为 202 个长度为 20 天的测试期。对这 20 个交易日涨跌的预测都是根据之前 250 天的数据为基础构建的模型所做出的。对于每个数据点，使用的滞后期都为 10。对于每个 20 天的预测期，本文都计算了 w_{mod} 和 w_{exp} ，在此基础上，应用配对 t 检验来确定两者的均值是否存在显著的差别。

既然在估计的过程中涉及参数 a 与 k 的选择，自然，检验的显著性是如何受到两者取值的影响也是本文所感兴趣的。表 1 展示了不同参数组合下 t 检验的显著性，表 2 则是对表 1 中某一种情况的补充信息。

表 1 比较 w_{mod} 和 w_{exp} 的单边 t 检验 p 值 (加粗表示 0.01 的水平下显著, *表示该行的最小值)

$\begin{matrix} k \\ a \end{matrix}$	0.000	0.100	0.200	0.300	0.400	0.500	0.600	0.800	1.000	5.000
0.10	0.8197	0.8462	0.8783	0.5735	0.3471	0.4935	0.2260	*0.0989	0.2169	0.3987
0.50	0.4952	0.2041	0.0212	0.0074	*0.0050	0.0065	0.0110	0.0016	0.0141	0.0399
1.00	0.2430	0.1192	0.0196	0.0309	0.0089	*0.0038	0.0062	0.0203	0.0087	0.0160
1.50	0.3488	0.0282	0.0313	0.0061	*0.0019	0.0016	0.0052	0.0055	0.0110	0.0106
2.00	0.1036	0.0281	0.0219	0.0006	*0.0005	0.0019	0.0109	0.0091	0.0199	0.0127
2.50	0.1009	0.1095	0.0166	0.0087	*0.0009	0.0092	0.0186	0.0115	0.0403	0.0205
3.00	0.1012	0.0511	0.0053	0.0029	*0.0026	0.0071	0.0189	0.0164	0.0672	0.0083
3.50	0.0913	0.0591	*0.0039	0.0040	0.0090	0.0292	0.0486	0.0296	0.0676	0.0094
4.00	0.0901	0.0306	0.0084	*0.0056	0.0126	0.0293	0.0841	0.0337	0.0610	0.0059
4.50	0.1087	0.0659	0.0081	*0.0037	0.0114	0.0244	0.0479	0.0423	0.0401	0.0073
5.00	0.1624	0.0366	*0.0041	0.0058	0.0151	0.0306	0.0502	0.0484	0.0297	0.0060

资料来源: "A kernel-based technique for direction-of-change of financial time series forecasting"

表 2 训练样本和测试样本预测准确率的均值, 以及预测情况的列联表

	Mean Train Acc.	Mean Test Acc.	Confusion Matrix
$\begin{matrix} a = 2.0 \\ k = 0.0 \end{matrix}$	0.7830	0.5141	$\begin{bmatrix} 1143 & 946 \\ 1025 & 941 \end{bmatrix}$ (2089) (1966)
$\begin{matrix} a = 2.0 \\ k = 5.0 \end{matrix}$	0.5369	0.5263	$\begin{bmatrix} 1005 & 757 \\ 1163 & 1130 \end{bmatrix}$ (1762) (2293)
$\begin{matrix} a = 0.5 \\ k = 0.4 \end{matrix}$	0.7465	0.5245	$\begin{bmatrix} 1191 & 951 \\ 977 & 936 \end{bmatrix}$ (2142) (1913)
$\begin{matrix} a = 2.0 \\ k = 0.4 \end{matrix}$	0.5958	0.5343	$\begin{bmatrix} 1127 & 847 \\ 1041 & 1040 \end{bmatrix}$ (1974) (2081)
$\begin{matrix} a = 5.0 \\ k = 0.4 \end{matrix}$	0.5628	0.5224	$\begin{bmatrix} 1009 & 777 \\ 1159 & 1110 \end{bmatrix}$ (1786) (2269)

资料来源: "A kernel-based technique for direction-of-change of financial time series forecasting"

注: 列联表中的上下两行分别对应预测的上涨和下跌, 左右两列为实际的上涨和下跌, 括号内为每一行的和

在表 1 中列示的所有 p 值中, 最小的为 0.0005, 对应的参数值为 $a=2.00$ 和 $k=0.40$ 。而从表 2 中可知, 此时样本外的平均预测准确率 (202 个测试期上预测准确率的均值) 是 0.5343, 而在训练样本内 (202 个长度为 250 天的训练数据集上预测准确率的均值) 的准确率则是 0.5958。

为了研究使用非球型协方差矩阵的效果, 观察表 1 中的第一列 ($k=0.0$) 可以发现每一个 p 值都远高于所在行的其余值, 并均高于 0.01 这一显著性水平。进一步考察 k 的作用, 考虑 $a=2.0$, $k=0.0$ 这一组合发现, 在训练样本内, 其预测准确率的均值高达 0.7830, 远远高于 $a=2.0$, $k=0.4$ 这一组合下的 0.5958。但如果比较两者在样本外的预测准确率却是相反的状况, 这表明 $k=0.0$ 时, 模型过度拟合了训练样本。再观察表 1 中最右边那列, 对应的是 $k=5.0$, 这对于尺度因子来说, 取值偏大。在此条件下得到的 p 值非常接近于只使用 1 阶滞后期的结果。特别地, 当 $a=2.0$, $k=5.0$ 时, 训练样本内的预测准确率均值是 0.5369, 低于 $a=2.0$, $k=0.4$ 的情形, 这表明发生了拟合不足的现象。经过以上的讨论, 可以认为使用形如(5)式的协方差矩阵来构造核函数是成功的, 它使得近期数据在建模中的作用大于距今较远的那些信息。

为研究参数 a 的效应, 考察表 2 中的最后三行, 在这三种情形下, k 都等于 0.4。当 a 增大时, 样本内数据的预测准确率渐次降低。这一现象可以用以下事实来解释, 较小

的 a 对应的是较窄的窗宽，使得在此范围内的密度函数估计偏向于尖峰的形态，从而发生过拟合现象。相反地，较大的 a 则会导致过于光滑的密度估计，因此也无法对训练样本建立精确的模型。

最后，从表 2 中那些训练样本内预测准确率较低的情形（例如， $a=2.0$ ， $k=5.0$ 和 $a=5.0$ ， $k=0.4$ ）可以看到，预测序列向下运动的次数显著大于对上涨的预测。这是因为假定了上涨和下跌的先验概率相等，而在实际情况中，上涨的发生次数要明显多于下跌（即，收益率序列是非平稳的）。一旦密度函数被过度平滑后，导出的后验概率估计会非常接近先验概率。这也告诉我们，如果提高上涨或降低下跌的先验概率以反映价格长期趋向于上涨这一事实，那么最终预测序列向上移动的次数也会随之上升，从而能够获得比本文中大约 53.4% 的样本外预测准确率更好的结果。例如，如果相信市场表现出强烈的牛市或熊市的行为，就可以通过预先设定先验概率来达到更加准确的预测。

5. 总结

本文呈现了一个以密度函数估计为基础的新技术，用以对金融时间序列数据的变化方向进行预测。该技术的一个明显优势就是相比于诸如神经网络之类的分类模型，它只涉及极少的参数，而且这些参数都能够很容易地用交叉验证的方法予以优化。此外，非球型核的使用使得近期数据在建模中的影响要高于那些距今久远的数据，这降低了模型对输入空间维度的敏感程度，因而也降低了过拟合的风险。澳大利亚普通股指数的实证分析表明本文技术所能达到的样本外的预测准确率显著高于以抛硬币方法得到的结果。

智能计算在股票组合构建上的运用

文献来源: Adam Ghandar, School of Computer Science, University of Adelaide, Zbigniew Michalewicz, School of Computer Science, University of Adelaide, A Computational Intelligence Portfolio Construction System for Equity Market Trading, IEEE Congress on Evolutionary Computation (CEC 2007) 798-805

推荐人: 张欣慰 021-23219370

推荐理由: 本文介绍了智能计算方法在股票组合构建上的运用。首先通过模糊理论对各个指标进行处理, 然后运用遗传算法对股票组合进行迭代优化, 较之与现在主流的多因子、均值—方差模型组合构建模型是一种新的尝试。此方法在 ASX/S&P200 上进行了实证, 取得了不错的效果。

本文介绍了一种通过智能计算来进行组合管理的方法, 涉及策略的交易信号由模糊理论确定。一个模糊规则库由一系列不同的模糊规则构成, 规则采用“如果—那么”的形式, “如果”部分描述了技术指标的状态, “那么”部分则赋予该技术指标对应的一个数据评级。举一个例子: 如果均线系统显示买入信号极端的弱, 那么则赋予其评级 0.9。

若千个规则构成一个规则库, 例如, 规则库 RB 由以下三个规则构成:

如果均线系统显示买入信号极端的弱, 那么则赋予其评级 0.9;

如果股价变化很大并且双均线系统卖出信号很强, 那么则赋予其评级 0.4;


如果能量潮指标极高并且移动均线买入信号中等, 那么则赋予其评级 0.5。

每一个指标我们均赋予其 7 个状态: 极高、高、较高、中等、较低、低、极低。这 7 种状态描述了指标所处位置对应的相对维度。

成员隶属度函数的初始值由历史数据得到, 然后根据最新数据不断更新。首先, 我们将某一观测变量的数值升序排列, 然后将排好序的序列等分成 P 组, 这样我们就生成了 P 个成员函数, 每个成员函数将最大和最小的观测分别赋予最大和最小值, 每个组中的观测均值定义为该成员函数的中心。这样, 一个成员隶属度函数完全就由观测的最大、最小及均值确定。如果一个观测值恰好等于成员隶属度函数的中心, 那么我们就认为此观测是该集合的成员, 如果一个观测在最大或最小值附近, 那么该观测的成员属性极低。

图 1 以移动均线买入信号为例, 将成员隶属度函数可视化的展示给读者。

图 1 移动均线买入信号对应的成员隶属度函数



资料来源: 海通证券研究所

股票的选取通过遗传算法完成。初始规则库通常随机生成，但也常常加入若干个经验选定的规则库，在本文中，我们加入的是一些技术指标（具体指标详见后文）。遗传算法分为以下几个步骤：

- 1、初始化 n 个规则库构成的 $P = \langle RB_1, RB_2, \dots, RB_n \rangle$ 以及最大迭代次数 N ;
- 2、计算 1 中每个规则库的生成组合的收益率（具体计算方法参见后文）;
- 3、根据 2 的计算结果确定截至当前的最优规则库;
- 4、交叉运算和变异运算：交叉运算指交换不同股则库中的部分规则，变异运算指对指标状态评级的微调（例如：如果均线系统显示买入信号极端的弱，那么则赋予其评级 0.9，将评级微调为 0.8 或 1.0），得到新的股则库构成的集合;
- 5、控制 4 中的调整幅度，使得子集与母集的变化不至于过大;
- 6、重复 2-5 中的步骤 N 遍;
- 7、迭代 N 步后的最优结果定义为最终结果。

下面我们要介绍如何针对给定的规则库对股票进行评级，下面用一个例子来说明。考虑以下一些规则：

- 1、单均线买入信号强烈，评级设定为 0.7;
- 2、股价和成交量变化都很大，评级设定为 0.4;

在某一天，股票 X 的技术指标有如下观测：

成交量变化 0.5;

移动均线买入信号 0.95;


价格变化 0.2;

开始，规则库中的各规则相互独立。移动均线买入信号的成员隶属度函数由历史观测的最小、均值和最大值确定（最小、均值及最大值分别为 0.12、0.97 和 3.88，由历史观测得到），我们用下式（1）来定义成员隶属度函数 $m(x)$ ：

$$m(x) = \begin{cases} \frac{x - \min}{\text{center} - \min} & , \quad \text{if } \min \leq x \leq \text{center} \\ 1 & , \quad \text{if } x = \text{center} \\ \frac{\text{center} - x}{\text{center} - \max} & , \quad \text{if } \text{center} \leq x \leq \max \\ 0 & , \quad \text{otherwise} \end{cases} \quad (1)$$

图 2 以可视化的形式展示了移动均线是如何映射到相应的成员隶属度函数的，移动均线的买入信号值为 0.95，其对应到的隶属度为 0.97。此外，我们将根据隶属度对评级进行调整，移动均线买入信号的调整后评级为 $0.97 \times 0.7 = 0.679$ 。

图 2 移动均线买入信号与模糊隶属度的映射



资料来源：海通证券研究所

本系统依次考察每一个规则，我们的第二个规则有两个输入变量：价格、成交量。对于这种情况，每一个子规则均按照前述方法单独计算，价格变动 20% 对应成员函数隶属度 0.5，成交量变化 50% 对应成员函数隶属度 1，然后将两个规则的隶属度相乘得到 $0.5 \times 1 = 0.5$ 。这两个规则的调整后的联合评级为 $0.5 \times 0.4 = 0.2$ 。

最终的得分根据各个规则的评级联合计算得到， $RB(X)$ 定义为规则库的联合中心得分，定义如下：

$$RB(X) = \frac{\sum O_i}{\sum r_i}$$


其中 O_i 是股票 X 在规则 i 上的隶属度调整后的评级， r_i 是股票 X 在规则 i 上的评级。

根据我们前面的计算结果，该股票在第一、第二条规则上的隶属度调整后评级分别是 0.679 和 0.20，因此该股票的联合评分为 $(0.679 + 0.2) / (0.7 + 0.4) = 0.799$ 。

上述的过程可以对全市场的股票进行评分，这样我们可以根据评分对市场 M 中的股票进行排名， $R(M) = \langle X_{i1}, X_{i2}, \dots, X_{in} \rangle$

$$\text{其中 } M = \{X_1, X_2, \dots, X_n\}, RB(X_{ik}) \geq RB(X_{ik+1})$$

图 3 股票排名和组合构建流程



资料来源：海通证券研究所

在上述系统中，组合 P_t 定义了 t 时刻的股票持仓，其中股票集 $M = (X_1, X_2, \dots, X_n)$

$$P = [a_1 X_{i1}, \dots, a_k X_{im}]$$

其中 $a_1, \dots, a_k$ 是自然数， $\{X_{i1}, X_{i2}, \dots, X_{im}\} \subseteq M$ ， $Value(P, t) = \sum a_i \times price(X_{ij})$

我们的策略采用多空策略，即买入排名靠前的股票，同时做空排名靠后的股票。我们用 ROI 指标来评价组合在模拟期的表现：

$$ROI = \frac{\ln(V_{t1}) - \ln(V_{t0})}{t_1 - t_0}$$

其中 V 是组合的市值， t_1 是考察结束时点， t_0 是考察起始时点。

对于不同的规则库，如果在考察期内 $ROI(RB_X) > ROI(RB_Y)$ ，那么我们就认为规则库 RB_X 比规则库 RB_Y 更能区分出股票的优劣。

前面我们引入 ROI 来度量股票的表现，为了完善评价体系，我们引入惩罚函数，我们推荐考虑以下两种惩罚函数来对 ROI 进行调整：

1、组合损失惩罚 (Portfolio loss penalty)

2、奥卡姆剃刀惩罚 (Ockham's razor penalty)

组合损失惩罚函数的加入可以大大降低组合的风险，在模拟期内我们每天计算组合的涨跌，如果当天组合有亏损，我们则加入惩罚项，这样即便最终组合收益很高，但这个惩罚函数对当天巨大的亏损非常严厉。组合损失惩罚函数的具体定义如下：

$$m(x) = \begin{cases} 0.01, & \text{if } \delta \geq -5\% \\ 0.1, & \text{if } -5\% \geq \delta \geq -10\% \\ 10, & \text{if } \delta \leq -10\% \end{cases}$$

其中 δ 表示组合的日涨跌幅。

奥卡姆剃刀惩罚的原理是，在试图了解某事物时，不采用不必要的信息是获得真相或获得最佳解释的最快途径，较少的规则发生过度拟合的可能性也比较小。其定义如下：

$$P(\text{Ockham}) = \text{规则库中的规则数} * K$$

其中 K 是惩罚常数。

我们对上述方法进行了实证回测，股票样本池是 ASX/S&P 200 成分股，回测期是 2001-2006 年。我们需要用到的数据包括股票的价格和成交量。通过股票价格和成交量，我们计算出一系列技术指标，而这些技术指标构成了我们的规则库。具体的规则库包括以下规则：

- 1、股价变化：股价在最近 20 天的变化。
- 2、移动均线买/卖信号：最近一天的收盘价和过去 20 天均价相比较。
- 3、组合市值：组合在 t 时刻的净值。


4、双均线买/卖信号：最近 10 天的均价和过去 20 天均价相比较

5、能量潮(OBV)买/卖指标。

6、Alpha: 由 CAPM 模型计算得到。

按照上述的策略，策略组合相对于基准指数的表现如图 4（数据统计见表 1），在回测 5 年中组合的年化波动率为 16%，同期基准的年化波动率为 10%，但组合的累积净值超越了同期基准指数 4 倍。

图 4 股票多头组合相对于基准指数表现



资料来源：海通证券研究所


表 1 策略组合表现与基准指数表现对比

	ASX S&P 200	System portfolio
Excess Holding Period Returns	90.32%	802.64%
Excess Annualized Geometric Returns	8.70%	38.85%
Annualized Volatility	9.91%	15.98%
Sharpe Ratio	0.928	2.512
Probability of a loss greater than 10% in any given month	0%	1.8%
Probability of a gain greater than 10% in any given month	1.2%	14.1%

资料来源：海通证券研究所

我们还按月度划分，统计了组合月度的收益（见图 5），单月最大跌幅为 10.4%，且月度损失超过 10% 的情况只发生了这一次，而月度盈利 10% 以上的概率则达到了 14.1%。

图 5 组合月度收益表现



资料来源：海通证券研究所

市场环境对资产配置的影响研究

文章来源: Manuel Ammann, The Effect of Market Regimes on Style Allocation, Working Paper Series in Finance Paper No.20, May 2006,p46

推荐人: 周雨卉 021-23219760

推荐理由: 在不同市场环境下, 风险补偿效应不尽相同, 不同风格的投资组合表现也差异较大。本文展示了如何运用市场环境切换模型来划分市场环境、分析根据市场不断变化的风险补偿效应及相应的资产配置策略、展示了该模型在美股市场的实证效果。

我们发现两种可以根据不同平均收益, 波动和相关性区分开的市场环境。在高波动率市场环境, 价值股表现较好; 而在低波动率市场环境, 动量股票表现较好。市场环境的切换使得投资者改变其组合风格, 风险偏好。这类根据市场环境改变而变更投资策略的方法可以带来可观的收益。本篇文章意在通过市场环境切换模型分析根据时间不断变化的风险补偿效应及相应的资产配置策略。

一、概述

首先, 我们构建一个与风险补偿数据产生相关的过程, 该过程允许不对称的平均收益, 波动率和相关性。在这个方法里, 预期收益率、波动性和相关性随着市场环境而变化。

经验告诉我们市场在不同市场环境下存在不同的风险溢价 (MRP), 小盘溢价 (SMB), 价值溢价 (HML) 和动量溢价 (UMD)。我们可以将市场环境依据不同的收益, 波动率和相关性分为两种不同市场环境。

环境 1: 在样本区间发生占比 25%, 以高波动率, 低 MRP 和 UMD, 中等 SMB, 高 HML 为特征。

环境 2: 在样本区间发生占比 75%, 以低波动率, 高回报率的的市场组合和动量股票, 低回报率的小盘股和价值股为特征。

特别的, 在高波动率市场环境下进行价值投资, 在低波动率的市场环境下进行动量投资可以获得非常高的超额收益。

本文的大纲为: 第二部分展现了市场环境切换模型文献概况、目前在金融领域和风格投资的运用 (此处略)。第三部分构建了资产配置的一般问题, 展示了如何运用市场环境切换模型来解决该问题, 以及如何估计模型中的参数。第四部分, 我们给出结果并对该结果进行讨论。

二、文献综述 (略)

三、不同市场环境下的风格投资

在这一节中, 我们描述一个一般的组合选择问题并给出参数估计

3.1 组合选择

一般的资产配置问题可以被描述为: 在时间 t , 一个投资者面临在 N 种资产中做配置选择以在时间 T 最大化其效用 $U(W_T)$, 形式为:

$$\max_{\alpha_t} \mathbb{E}_t [U(W_T)] \quad , \quad (1)$$

这里 α_t 是 t 时刻组合权重向量，其和为一。下一个阶段的财富为：
 $W_{t+1} = R_{t+1}(\alpha_t)W_t$

在 $t+1$ 时刻总的组合收益为：

$$R_{t+1}(\alpha_t) = \sum_{j=1}^N \exp(y_{t+1}^j) \alpha_t^j \quad , \quad (2)$$

我们选用 CRRA 效用函数：

$$U(W_T) = \frac{W_T^{1-\gamma}}{1-\gamma} \quad , \quad (3)$$

其中， γ 是投资者的风险厌恶系数。

假设一个投资者在 t 时刻选择组合权重向量为 α_t^* 以最大化其效用函数：

$$\alpha_t^* = \arg \max_{\alpha_t} \mathbb{E}_t \left[\frac{W_T^{1-\gamma}}{1-\gamma} \right] \quad . \quad (4)$$

上述描述的问题中，并没有涉及到数据产生环节，因此这是一个非常普遍的资产配置问题。接下来我们引入 K 个不同的市场环境 S 进入数据产生过程。对单个阶段，收益率 y_t 依据不同的市场环境 S_t 而有所不同。

S_t 服从马尔科夫链，在 t 时刻环境 i 向 $t+1$ 时刻环境 j 的转换概率定义为：
 $p_{ij,t} = p(S_{t+1} = j | S_t = i)$ 。 $f(y_{t+1} | S_{t+1})$ 代表市场环境 S_{t+1} 下 y_{t+1} 的概率密度方程。在我们的模型里， $f(y_{t+1} | S_{t+1})$ 是多变量正态分布函数其转换概率为常数。因此， S_t 市场环境下 y_{t+1} 的概率密度函数可以写为：

$$g(y_{t+1} | S_t = i) = \sum_{j=1}^K p_{ij,t} \cdot f(y_{t+1} | S_{t+1} = j) \quad . \quad (5)$$

为了计算最优组合权重，我们可以运用标准数值积分算法，例如：高斯积分法。

3.2 参数估计

本文我们运用基于马尔科夫链蒙特卡罗的贝叶斯方法来估计模型参数。假设平均收益率和他们的协方差矩阵在不同的环境下不同。表示为：

$$\begin{aligned} y_t &= \mu_{S_t} + e_t \\ e_t &\sim MVN(0, \Sigma_{S_t}) \\ \mu_{S_t} &= \mu_1(1 - (S_t - 1)) + \mu_2(S_t - 1) \\ \Sigma_{S_t} &= \Sigma_2(1 - (S_t - 1)) + \Sigma_2(S_t - 1) \end{aligned} \quad (6)$$

其中, $y_t = [MRP_t \text{ } SMB_t \text{ } HML_t \text{ } UMD_t]'$ 是 t 时刻的风险溢价向量。 $S_t=1$ 对应市场环境 1; $S_t=2$ 对应市场环境 2。 μ_{S_t} 是不同市场环境下的平均收益, Σ_{S_t} 是不同市场环境下的协方差矩阵。 e 是以均值为 0, 为协方差矩阵的多变量正态分布的误差项。根据两状态, 一阶的马尔科夫变化过程, 转化概率表示如下:

$$\begin{aligned} p(S_t = 1 | S_{t-1} = 1) &= p_{11} \\ p(S_t = 2 | S_{t-1} = 2) &= p_{22} \end{aligned} \quad (7)$$

贝叶斯方法的关键是将 $\mu_1, \mu_2, \Sigma_1, \Sigma_2, p_{11}, p_{22}$, 视作随机变量。我们需要推导出联合后验概率分布 $g(\bar{S}_T, \mu_1, \mu_2, \Sigma_1, \Sigma_2, p_{11}, p_{22} | \bar{y}_T)$, 可以写为:

$$g(\bar{S}_T, \mu_1, \mu_2, \Sigma_1, \Sigma_2, p_{11}, p_{22} | \bar{y}_T) = g(\mu_1, \mu_2, \Sigma_1, \Sigma_2 | \bar{y}_T, \bar{S}_T) \cdot g(p_{11}, p_{22} | \bar{S}_T) \cdot g(\bar{S}_T | \bar{y}_T) \quad (8)$$

这里 g 代表密度。因此运用马尔科夫链蒙特卡罗抽样法, 参数可以依据重复下列三个步骤估计出来。

步骤 1: 从 $g(S_t | \bar{S}_{\neq t}, \mu_1, \mu_2, \Sigma_1, \Sigma_2, p_{11}, p_{22}, \bar{y}_T)$ 生成 $S_t, t = 1, 2, \dots, T$ 。

步骤 2: 从 $g(p_{11}, p_{22} | \bar{S}_T)$ 生成 p_{11} 和 p_{22}

步骤 3: 从 $g(\mu_1, \mu_2, \Sigma_1, \Sigma_2 | \bar{S}_T, \bar{y}_T)$ 生成 $\mu_1, \mu_2, \Sigma_1, \Sigma_2$

步骤 1 的 g 可以写成:

$$g(S_t | \bar{S}_{\neq t}, \mu_1, \mu_2, \Sigma_1, \Sigma_2, p_{11}, p_{22}, \bar{y}_T) \propto g(S_t | S_{t-1}) \cdot g(y_t | S_t) \cdot g(S_{t+1} | S_t) \quad (9)$$

其中, $g(S_t | S_{t-1})$ 和 $g(S_{t+1} | S_t)$ 为转变概率, 且 $g(y_t | S_t) \sim MVN(\mu_{S_t}, \Sigma_{S_t})$ 。

3.3 样本外检验

我们运用一系列准则来检验市场环境切换模型的可靠性。我们希望我们估计的风险溢价向量尽可能的接近实际的风险溢价。

检验一:

我们估计的风险溢价可以写为下列形式:

$$E(y_{t+1}) = p(S_{t+1} = 1 | S_t = i) \cdot \mu_1 + p(S_{t+1} = 2 | S_t = i) \cdot \mu_2 \quad (16)$$

风险溢价估计误差的均方根值可以写为:

$$RMSE = \left(\frac{1}{T-1} \sum_{t=1}^{T-1} (y_{t+1} - \mathbb{E}(y_{t+1}))^2 \right)^{0.5} \quad (17)$$

该值越小，越好。

检验二：

我们通过计算预估风险溢价和实际风险溢价相关性的皮尔森系数来检验模型的可靠性，该系数越接近于 1，模型的预测性越好。

检验三：

我们对每个风险因子做回归，

$$y_{t+1}^i = b_0 + b_1 \cdot \mathbb{E}(y_{t+1}^i) \quad (18)$$

在准确的预测下， $b_0=0$ 且 $b_1=1$ 。

四、实证结果

4.1 数据选择

我们选择的数据对象来自于 Fama and French data library: 市场组合 MRP，账面市值比因子（HML），市值因子（SMB），动量因子（UMD），无风险利率（RF）。样本区间为 1927 年 1 月至 2004 年 12 月。

HML 和 SMB 因子构建通过 6 个依据市值大小和市值账面比构建的市值加权的 6 个组合计算而得。区分大小的阈值是 NYSE 交易的市值中位数。区分市值账面比（即成长、中性、价值）的阈值为 30% 和 70% 分位点。 $SMB = 1/3 * (\text{小市值组合收益} + \text{小市值中性组合收益} + \text{小市值成长组合收益}) - 1/3 * (\text{大市值组合收益} + \text{大市值中性组合收益} + \text{大市值成长组合收益})$ 。 $HML = 1/2 * (\text{小市值组合收益} + \text{大市值组合收益}) - 1/2 * (\text{小市值成长收益} + \text{大市值成长收益})$ 。

下表展示了我们选取的数据的统计学特性

表 1 数据的描述性统计

	MRP	SMB	HML	UMD	RF
Mean	0.647	0.184	0.481	0.751	0.305
Median	0.980	0.025	0.240	0.935	0.270
Maximum	38.180	38.040	35.350	18.380	1.350
Minimum	-29.030	-21.490	-11.480	-50.920	-0.060
Standard deviation	5.489	3.375	3.574	4.731	0.257
Skewness	0.213	1.600	2.037	-2.997	0.999
Kurtosis	10.627	23.897	17.635	30.861	4.112
Observations	936.000	936.000	936.000	936.000	936.000
Percentile (10%)	-5.308	-3.359	-3.140	-3.457	0.020
Percentile (25%)	-2.165	-1.590	-1.350	-0.805	0.090
Percentile (75%)	3.780	1.845	1.840	2.930	0.450
Percentile (90%)	6.028	3.598	4.138	4.926	0.640
Jarque-Bera test for normality	2262.207	17346.256	8955.209	31527.381	202.813
Jarque-Bera test (p-value)	0.000	0.000	0.000	0.000	0.000

4.2 风格溢价的不同市场环境

表 2 展示了不考虑市场环境和考虑市场环境切换下的不同参数估计结果。总体来看我们的分析清晰地展示了两个不同的市场环境。在市场环境 1 下，MRP、SMB 和 UMD 的预期溢价低，仅仅 HML 展现高的风险溢价。由于所有的风险因子均为高波动，我们将环境 1 定义为高波动市场环境。与此相对的环境 2，市场风险和动量股票有较高的预期收益而小股票和价值股收益较低，且环境 2 各个风险因子的波动率也较低，我们将环境 2 定义为低波动率环境。


环境 1 发生样本区间段的 25%，环境 2 发生占样本区间段的 75%。除了发生的不同频率意外，两个环境的转换概率也很不相同。低波动率环境展示了高度的一致性，而高波动率环境较为不稳定。从低波动率环境向高波动率环境转换的概率仅为 9%。而从高波动率环境向低波动率环境转换的概率为 28%

表 2 同时也展示了不同 t 检验结果。在环境 1，仅仅小盘股有较高的超额收益为 15.16%；对比不区分市场环境的模型，仅仅价值股提供较高的超额收益。但是，这个现象在环境 2 中有所不同：市场风险和动量股票均能提供较高的超额收益。

表 2 不考虑市场环境和考虑市场环境切换下的不同参数估计结果

Unconditional	MRP	SMB	HML	UMD
Mean	7.77** (2.17)	2.21 (1.33)	5.77** (1.41)	9.00** (1.87)
Volatility	19.03** (0.44)	11.70** (0.27)	12.38** (0.29)	16.39** (0.38)
Correlation MRP	1			
Correlation SMB	0.32** (0.03)	1		
Correlation HML	0.18** (0.03)	0.08* (0.03)	1	
Correlation UMD	-0.34** (0.03)	-0.22** (0.03)	-0.38** (0.03)	1
Regime 1				
Mean	0.40 (7.48)	3.09 (4.64)	15.16* (5.09)	-1.27 (7.04)
Volatility	31.80** (1.69)	19.67** (1.04)	21.25** (1.11)	29.72** (1.61)
Correlation MRP	1			
Correlation SMB	0.37** (0.06)	1		
Correlation HML	0.29** (0.06)	0.14* (0.06)	1	
Correlation UMD	-0.50** (0.05)	-0.28** (0.06)	-0.46** (0.05)	1
Regime 2				
Mean	10.22** (1.70)	1.92 (1.05)	2.62* (1.07)	12.44** (1.14)
Volatility	12.01** (0.38)	7.33** (0.25)	7.13** (0.28)	7.78** (0.31)
Correlation MRP	1			
Correlation SMB	0.20** (0.04)	1		
Correlation HML	-0.07 (0.05)	-0.07 (0.04)	1	
Correlation UMD	0.15** (0.05)	-0.01 (0.05)	-0.03 (0.05)	1
Number of states in		in %	NBER recession	NBER boom
Regime 1	235.50 (16.77)	25.16%	45.45%	20.29%
Regime 2	700.50 (16.77)	74.84%	54.55%	79.71%
Transition matrix	P(...,1)	P(...,2)		
P(1,...)	0.72 (0.05)	0.28 (0.05)		
P(2,...)	0.09 (0.02)	0.91 (0.02)		
Statistical tests				
T-test for means	2.17*	0.33	3.12**	2.33*
T-test for volatility	15.11**	15.62**	17.01**	16.88**
Box-M F-value	131.60**			
Box-M p-value	0.0000			

图 1 环境 2 的发生概率估计



4.3 在市场环境切换模型下的资产配置

在这一节中，我们回到市场环境如何影响资产配置。

图 2 展示了当投资者的风险厌恶程度（RRA）为 3 时的资产配置结果。结果显示以 3 个月为投资区间的资产配置在环境 1 和环境 2 分配到各种风格组合的权重情况不尽相同。

图 2 风险厌恶系数为 3 时在不同市场环境的资产配置




表 3 展示了在不同的风险厌恶下最优资产配置情况。比如：极端风险厌恶者在市场环境 1 会比市场环境 2 多投入 4.62%~15.46% 的资产到价值股里。对于一个能够承受适当风险的投资者，在在市场环境 1 会比市场环境 2 多投入 1.85%~5.3% 的资产到价值股里。

表 3 不同风险厌恶投资者在不同市场环境下的资产配置

Investment Horizon	Regime	RRA = 3			RRA = 5			RRA = 7		
		SMB	HML	UMD	SMB	HML	UMD	SMB	HML	UMD
3	Regime 1	36.50%	37.16%	26.33%	45.53%	37.52%	16.95%	49.15%	37.63%	13.22%
	Regime 2	36.09%	35.31%	28.59%	46.22%	27.25%	26.52%	51.91%	22.17%	25.92%
	Difference	0.41%	1.85%	-2.26%	-0.70%	10.27%	-9.57%	-2.76%	15.46%	-12.70%
6	Regime 1	41.23%	36.33%	22.43%	48.75%	35.42%	15.83%	50.94%	35.13%	13.93%
	Regime 2	41.03%	33.99%	24.98%	49.81%	27.15%	23.04%	53.07%	24.56%	22.37%
	Difference	0.21%	2.34%	-2.55%	-1.06%	8.27%	-7.21%	-2.13%	10.57%	-8.43%
12	Regime 1	51.64%	32.84%	15.52%	57.27%	31.08%	11.65%	58.75%	30.62%	10.63%
	Regime 2	51.64%	28.69%	19.67%	59.10%	23.07%	17.83%	61.22%	21.50%	17.38%
	Difference	0.00%	4.15%	-4.15%	-1.84%	8.01%	-6.17%	-2.47%	9.12%	-6.65%
24	Regime 1	65.66%	25.94%	8.41%	69.67%	24.10%	6.24%	70.71%	23.62%	5.67%
	Regime 2	66.74%	20.81%	12.43%	71.78%	17.24%	10.98%	73.11%	16.31%	10.58%
	Difference	-1.08%	5.13%	-4.04%	-2.11%	6.86%	-4.75%	-2.40%	7.31%	-4.91%
36	Regime 1	74.94%	20.64%	4.41%	78.16%	18.94%	2.90%	78.99%	18.50%	2.51%
	Regime 2	76.29%	16.04%	7.67%	80.10%	13.40%	6.50%	81.09%	12.72%	6.19%
	Difference	-1.35%	4.60%	-3.25%	-1.94%	5.54%	-3.60%	-2.10%	5.77%	-3.68%
48	Regime 1	81.79%	16.47%	1.74%	84.51%	14.90%	0.50%	85.21%	14.49%	0.29%
	Regime 2	83.13%	12.57%	4.30%	86.22%	10.43%	3.30%	87.02%	9.88%	3.11%
	Difference	-1.34%	3.90%	-2.56%	-1.71%	4.47%	-2.76%	-1.80%	4.62%	-2.81%

并购事件的动量效应与投资者情绪

文献来源: Richard J. Rosen ,Merger momentum and investor sentiment: the stock market reaction to merger announcements, The journal of business,vol.79,No.2 (March 2006), 987-1017

推荐人: 郑雅斌

推荐理由: 本文从理论、实证两个角度深刻的研究了并购的动量效应。首先,在并购动机的传统理论下,提升市场情绪理论的假设。三种假设都有效解释了动量效应存在的原因。其次,对于事件研究的市场划分方式有改进,不仅仅通过股票指数走势划分市场环境,也不仅仅通过事件数量划分,根据市场对事件的反应刻画了并购市场的牛、熊市,研究并购市场的波动对于动量效应的影响。第三,从多个维度剖析动量,描述公司主体的并购动量,发现它具有极好的稳定性。第四,在短期窗口中,理论与实践相结合,证实了动量的存在;在长期窗口中,通过情绪理论以及数据验证,说明并购动量会消失甚至反转。

本文主要研究并购发生后的市场反应是否依赖于近期的并购市场以及并购主体公司的历史表现。过去的研究很少将重点放在并购周期上,而我们将重点放在这个周期的影响上。

分别就公告后的短期以及长期效应进行研究,并提出传统的两种并购理论,以及我的投资者情绪理论。这三种理论都能够为并购动量提供解释。动量在市场和公司层面都存在,但长期来看动量就会消失。

1. 并购动量的来源

我将并购动量定义为:最近的市场环境与市场对并购公告反应的相关性。例如:“并购牛市”即为市场对并购给予正面反应的环境。“并购牛市”与“并购波段”有相关性但并不相同(“并购波段”定义为一段时间内并购公司数量的多少):因为“并购波段”一般而言通过并购的数量衡量,而非市场对事件的反应。本节将描述几种并购动量的来源并提出后节讨论的假设。

➤ 新古典主义理论

如果并购动量存在,它必然能够反应并购后企业的协同作用。统计显示,多数并购事件发生在经济危机之后,并有历史研究证明市场给出了事件正面反应,由此,经济危机很可能能够提高企业的协同兼并效果。

新古典主义理论认为并购的动机来自提高企业价值。如果它成立,那么并购动量与并购波段应该高度相关,因为经济危机之后的数量激增说明这个阶段的并购公司具有更好的并购价值,从而应该显著战胜其他阶段的并购公司,在这种阶段中就会激发并购的正向动量效应。

➤ 管理层动机理论

管理层动机也会提高并购活动。如果管理层可以通过并购其他竞争对手公司,降低自己公司被收购的概率,很多公司可能会进行防御性并购。如果并购波段中,更多的是防御性并购(尤其在经济危机中),这种并购并不产生价值。所以,较差的并购在时间上具有集中性,那么这类公司也会有动量效应,这个阶段的公司表现持续差于其他阶段的公司。

➤ 市场情绪理论

市场对并购公告的反应不仅仅来自并购产生的协同作用，还包含管理层能为股东捕捉多少价值、市场是否预期到并购、股东是否理性反应。如果投资者普遍错误估计并购价值，并购动量就会产生。因为过度的乐观情绪会影响市场反应，股票收益与并购公告存在正相关关系。并且，市场情绪会感染管理层。管理层被市场乐观情绪影响，更倾向于在热门并购市场中进行并购。再者，管理层会利用市场的正向反应来开发投资者。在热门市场中，并购公司股价会被抬高，从而使管理层获利。

有证据显示，在市场走势较好时，并购更容易发生。股价与并购公告在牛市中的相关性可以反应乐观预期，但从长期来看，股价会出现反转。

三种理论为并购动量提供了不同的解释，且说明并购市场的当前情况与市场对新公告的反应存在联动关系。如果并购来自协同作用或者乐观预期，短期必然产生股价动量，但长期来看却有不同表现：协同作用能够增加公司长期价值，乐观预期却会使股价反转。如果并购原因是防御性的，那么长期来看，股价表现可能比其他并购更差。

2. 模型与样本

2.1 数据

选用 1982 到 2001 年的数据。1、仅选用并购金额高达被并购公司 50% 以上、且购买后占有目标公司 90% 以上股权的并购案。主要为了剔除逐步的慢性并购，不如前者的市场反应及时快速。2、仅包含协议式并购而非投标竞价。原因之一是投标竞价的样本量太少，之二是投标竞价之后的市场反应全部都是正向的(可能与投标竞价均以现金形式成交有关系，与市场条件关系不大)。后期验证，即便加入投标竞价标的，结果依然显著。3、剔除被并购标的市值过小的样本（被并购标的的市值小于并购公司的 10%），因为这种样本对并购公司后期股价影响不明显。结果显示，阈值选在 25% 以下，我们的结果均显著。4、剔除并并购标的市值过大样本（超过并购公司 120%），因为该类样本过少且具有特殊性。

2.2 模型


模型目的是验证并购活动与股价的变化如何影响市场对并购事件的反应，从长期、短期两个角度。研究主体为并购公司。

市场反应 = 函数（并购活动、市场动量、主体公司的并购活动、主体股价动量、交易特定或主体控制的变量）

➤ 市场情况变量

变量一为当前并购点之前一年中的样本量。有研究表明，并购数量高度自相关，上一年的并购数量对当年数量有高度预测价值。变量二为并购牛市的衡量方法（即收益情况）。计算事件之后 5 天内的累计 alpha 收益（CAAR）。变量的计算：当前并购点之前一年中的 CAAR 均值。这两个变量具有相关性但高点位置有所不同。

图 1 CAAR 与并购数量的关系



资料来源：海通证券研究所

➤ 主体公司的并购活动

衡量公司主体的并购质量：前三年最后一次并购事件的 5 日 CAAR。并计算并购时点之前三年中的并购数量。同时加入一个 0、1 变量，指示当前是否公司这三年的第一次并购公告。

➤ 股价收益变量

并购与股市环境关系较大：如牛市中数量增多。我选用市值加权指数，公告前一年至前三天的指数收益作为市场环境变量。主体收益变量：公告前一年至前三天的买入持有超额收益（BHAR）。

➤ 其他特殊变量

1、并购目标分位：私有企业、国营公司、子公司。两种出资方式：股票并购以及包含其他融资模式的并购。2、有研究表明，并购多样化的时候主体股价收益会提高，故而将主体分为 17 个行业类别，如果并购涉及两个不同行业的公司，变量数值为 1。16% 的样本是多样化并购。3、主体公司市值变量，有研究表象短期 CAAR 与市值呈负相关。4、目标、主体市值比。5、主体公司财务质量（PB、ROA）

3. 短期收益

➤ 回归结果

在全市场维度以及公司维度都发现了动量效应。并购市场的动量（12 月平均 CAAR）、股票市场动量系数为正且显著。公司并购动量显著性略低。市场以及公司的并购数量都不显著。上涨市中并购公告后的 CAAR 比下跌市高。非常多的公司层面控制变量结果都显著，说明收益不仅仅与过去文献中的假设因子相关。

表 15 日 CAAR 对各变量的回归结果

	Full Sample (1)		Early Time Period (1982-89) (2)		Later Time Period (1990-2001) (3)	
	Coefficient	p-Value	Coefficient	p-Value	Coefficient	p-Value
Merger momentum:						
Trailing 12-month average CAAR	.384	(.001)***	-.247	(.368)	.295	(.028)**
Trailing 12-month number of mergers/1,000	-.050	(.338)	-.007	(.915)	-.024	(.005)***
Market momentum:						
Trailing 12-month return on CRSP index	.023	(.006)***	-.010	(.494)	.044	(<.001)***
Bidder-specific merger momentum:						
CAAR on bidder's last announcement	.048	(.082)*	-.067	(.366)	.054	(.061)*
First merger dummy	.004	(.284)	.012	(.222)	.002	(.571)
Number of mergers by firm in last 3 years	.001	(.558)	-.001	(.830)	.001	(.628)
Bidder-specific stock momentum:						
Trailing 12-month BHAR on bidder's stock	-.004	(.080)*	.007	(.228)	-.004	(.042)**
Control variables:						
Private target	.024	(<.001)***	.009	(.235)	.029	(<.001)***
Subsidiary	.029	(<.001)***	.001	(.935)	.037	(<.001)***
Public target with stock financing	-.021	(<.001)***	-.021	(.036)**	-.019	(<.001)***
Private target with stock financing	.008	(.084)*	-.005	(.507)	.009	(.063)*
Subsidiary with stock financing	-.011	(.265)	.002	(.886)	-.014	(.223)
Log of total assets	-.011	(<.001)***	-.012	(.001)***	-.010	(<.001)***
Ratio of target-to-bidder size	.034	(<.001)***	.037	(.003)***	.033	(<.001)***
Bidder book-to-market	.002	(.357)	.005	(.435)	.002	(.562)
Bidder ROA	.014	(.185)	-.052	(.180)	.017	(.137)
Diversifying merger	-.004	(.175)	-.003	(.597)	-.005	(.205)
Adjusted R ²	.0746		.1296		.0771	
Observations	6,259		935		5,324	

资料来源：海通证券研究所

➤ 几点讨论

结论充分验证了并购动量：好的并购环境中，CAAR 会提升；公司历史的并购受欢迎，会提高后期收益；好的股市整体走势，CAAR 也会有更好的表现。这和新古典主义和过度乐观主义理论都一致。

有一点值得讨论：公司前期股价收益具有负相关系数。一个可能的解释为：前期股价明显上涨的公司，高管对自己过度自信，即便在市场环境不好或者市场不看好并购时，依然进行并购。由此，骄傲导致的非良性并购使得理性股票持有者折价抛售股票。另外，有人将这种现象解释为，股价涨幅较好的公司股价被高估，更倾向于通过发行股票的方式募资进行并购，而有人验证过，认为股票募资并购后的 CAAR 表现不好。但我将股票募资样本剔除后，系数依然为负，说明这种解释应该不成立。

4. 长期收益

将时间窗口延长。如果新古典主义成立，那么长期来看，收益在公告之后应该没有明显趋势；如果过度乐观成立，那么后期应该出现股价反转；如果管理层动机驱动收购，会加剧后期的股价下跌表现。

我考察三年的时间窗口。长期窗口的考察方法有买入持有收益法、以及组合收益法，两种方法的区别在其他文献中有过论证，在这里我们两种方法都会进行验证。

➤ 买入持有 (BHAR)

$$BHAR = \frac{\prod_{t=1}^T (1 + R_t)}{\prod_{t=1}^T (1 + R_{index,t})}$$

测试窗口有两种，一种从公告前两天至后三年（全窗口），一种从公告后一天至三年。样本显示，BHAR 均值为-6.66%（但结果没有通过显著性检验）。长期的负向表现与前期假设一致。

➤ 回归结果

并购市场动量（12 个月的 CAAR），本次并购事件的前期 CAAR，系数都显著为负，且系数绝对值高出短期收益的系数很多。指数 12 月走势也显著负相关，说明上涨市中的并购长期来看表现差于下跌市中的并购案例。CAAR 从公告后长期来看收益全部回吐，系数基本为-1。

公司层面的动量因子，却并没有明显反转迹象。其系数从长、短期来看方向都一致。故而公司层面的动量长期也不会被反转。

在长期回归中，我们包含了另外一些变量（如观察的三年窗口中，公司又进行了新的并购），结果在第三列中展示。三年中又进行并购的公司，长期收益相对更好。这说明公司运营好的话，就倾向于做更多的兼并。且收购国营公司也有助于长期发展。引入更多的变量，并不影响市场动量指标与长期收益之间的负相关关系。

表 2 BHAR 对各变量的回归结果

	Postannouncement Returns (1)		Total Window Returns (2)		Postannouncement Returns (3)	
	Coefficient	p-Value	Coefficient	p-Value	Coefficient	p-Value
CAAR	-1.152	(<.001)***			-1.177	(<.001)***
Merger momentum:						
Trailing 12-month average CAAR	-8.549	(<.001)***	-8.198	(<.001)***	-9.617	(<.001)***
Trailing 12-month number of mergers/1,000	.530	(.357)	.240	(.684)	1.500	(.009)***
Market momentum:						
Trailing 12-month return on CRSP index	-.425	(<.001)***	-.393	(<.001)***	-.444	(<.001)***
Bidder-specific merger momentum:						
CAAR on bidder's last announcement	.232	(.504)	.205	(.539)	.207	(.552)
First merger dummy	.104	(.003)***	.118	(.001)***	.111	(.001)***
Number of mergers by firm in last 3 years	.016	(.349)	.023	(.193)	-.002	(.907)
Number of mergers by firm in the postac-						
quisition period					.061	(<.001)***
Number of mergers by firm in the postac-						
quisition period financed with stock					-.034	(.327)
Number of mergers by firm in the postac-						
quisition period with public targets					.081	(.038)**
Bidder-specific stock momentum:						
Trailing 12-month BHAR on bidder's stock	-.089	(<.001)***	-.088	(<.001)***	-.091	(<.001)***
Control variables:						
Private target	-.023	(.581)	.004	(.920)	-.026	(.537)
Subsidiary	.046	(.247)	.081	(.038)**	.039	(.332)
Public target with stock financing	-.086	(.047)**	-.107	(.007)***	-.084	(.054)*
Private target with stock financing	-.074	(.046)**	-.086	(.028)**	-.065	(.090)*
Subsidiary with stock financing	-.079	(.506)	-.082	(.556)	-.053	(.653)
Log of total assets	.068	(<.001)***	.064	(<.001)***	.062	(<.001)***
Ratio of target-to-bidder size	.112	(.058)*	.119	(.041)**	.126	(.032)**
Bidder book-to-market	.085	(.003)***	.086	(.003)***	.088	(.002)***
Bidder ROA	.221	(.046)**	.241	(.035)**	.221	(.047)**
Diversifying merger	-.097	(.001)***	-.103	(.001)***	-.095	(.002)***
Adjusted R ²	.0695		.0506		.0817	

资料来源：海通证券研究所

➤ 组合收益方法

另外一种常用的长期收益检测法为组合收益法，将标的按照时间序列计算收益。分别计算所有样本、以及按照自变量（如市场并购动量）划分的样本组合收益，以月度为频率计算前三年中有并购发生的股票月度收益，之后计算并购发生后三年内的月度收益均值。结果与 BHAR 的结果没有明显差异，12 月 CAAR 最高的组合长期收益最低，在并购牛市中进行并购的公司长期收益弱于并购冷淡期中的公司。

表 3 组合收益的统计检验

	Top Quartile	Second Quartile	Third Quartile	Bottom Quartile	p-Value*	Sign of Coefficient (BHAR Regression)
Trailing 12-month average CAAR	-13.99%	-5.81%	1.08%	11.63%	.050	...
Trailing 12-month number of mergers/1,000	-4.34%	7.54%	-2.16%	-1.56%	.713	0†
Trailing 12-month return on CRSP index	-3.67%	-1.29%	-1.48%	4.77%	.448	...
CAAR on bidder's last announcement	-.40%	-18.44%	2.15%	-2.65%	.821	0
Trailing 12-month BHAR on bidder's stock	-3.74%	-14.18%	-4.79%	.48%	.664	...
CAAR	-6.86%	-11.53%	-6.20%	-2.65%	.671	...

资料来源：海通证券研究所

➤ 几点讨论

我们的结果与我们提出的过度乐观假设一致。并购牛市可以通过 12 个月的平均 CAAR 衡量，与短期收益正相关但与长期收益负相关。牛市中，乐观情绪使投资者不断抬高股价买入，但当并购结果逐步显示后，情绪回归理性后股价将进行打折。

5. 结论

本节研究了市场对并购公告的反应与市场环境之间的联动关系。我发现了并购市场动量存在的良好证据，并购更倾向在并购牛市中发行，且市场反应明显比冷淡期中更好。但长期来看，市场反应发生反转。这与我们所做的投资者情绪理论完全一致。

过去的研究注意到并购在行业或是整体经济危机后会集中出现，因为经济危机会加强并购后企业的协同效应，但这并不能解释长期收益的反转现象。另一种并购动机为管理层动机进行防御并购，这能够解释市场冷淡时并购表现不好的原因。

中国股市的动量交易、均值回归与过激反映

文献来源: Yangru Wu, Rutgers University, Newark, Momentum trading, mean reversal and overreaction in Chinese stock market ,Review of Quantitative Finance and Accounting, Vol. 37, Issue 3, pp 301-323 ,Oct 2011.

推荐人: 朱剑涛

推荐理由: 动量和反转是证券市场普遍存在的两种效应, 与投资者的行为心理紧密相关。以前的研究常常把它们当做两个独立的市场现象进行研究, 而事实上动量和反转往往是同时存在, 对价格交错影响。如何把两种效应统一到一个模型框架下? 本文提供了一种可行的方案。

按照 De Long(1990) 的理论, 投资者的正反馈效应 (positive-feedback) 会推动股价远离基本面价值。当市场有好消息发布时, 理性投机者可能会先于跟风交易者买入股票, 促进价格上涨, 以期其正反馈效应吸引跟风交易者进场, 推动股价持续上扬, 产生短期的动量效应。但股价不可能长期缺乏基本面的支持, 因而从长期来看, 股价具备回归基本面的反转效应。

基于上面的假设, 作者建模把股票价格分解为两部分:

$$p_t = y_t + x_t$$

其中 p_t 为 t 时刻某只股票价格的自然对数, y_t 是股票的长期价值, 由股票的基本面因素决定, x_t 是价格的短期波动, 由市场交投决定。 y_t 和 x_t 属不可观测变量, 理论上可以用卡尔曼滤波的方法估算其状态值, 但是这样会大幅提升模型的运算量, 因而作者简化起见, 采用了类似 CAPM 的方法, 令 $y_t = \beta \cdot z_t$, z_t 为市场加权指数的对数价格, β 为系数。短期波动 p_t 采用下列形式来反映长期均返和短期动量效应:

$$x_t = (1 - \delta)\mu + \delta x_{t-1} + \sum_{j=1}^J \phi_j \Delta x_{t-j} + \eta_t$$

其中 $\Delta x_t = x_t - x_{t-1}$, $0 \leq \delta, \phi_j \leq 1$, $\{\eta_t\}$ 为与 $\{x_t\}$ 不相关的高斯白噪声。可以看到 $\delta < 1, \phi_j = 0 \quad j = 1 \dots J$ 时, x_t 是纯均值常返序列; 当 $\delta = 1, \phi_j = 1$ 时, 模型是一个纯的动量模型。

实证采用的数据是国泰安信息科技提供的沪深交易所 1990.12.12 到 2001.12.31 日的数据。作者首先对纯的动量和反转模型进行了验证, 结果显示 A 股市场总体呈现反转效应, 动量效应并不明显 (具体数据可以参考原文, 我们这里重点对比上述模型对单纯动量和反转模型的改进)。

然后作者又利用上面的动量反转混合模型, 选定不同的观察期 (J) 估计模型的参数, 并预测持有期 (K) 的收益, 按照预测收益从大到小排列, 买入前 10% 的股票组合, 卖空后 10% 的股票组合, 策略实证结果如下:

表 2 动量反转混合策略实证结果（沪市）

Table 4 Performance of parametric portfolio switching strategies: Shanghai “A” shares Mean reversion with momentum

	K = 1 day		K = 1 week		K = 1 month		K = 3 months		K = 6 months	
	Return	t-ratio	Return	t-ratio	Return	t-ratio	Return	t-ratio	Return	t-ratio
<i>J = 0, pure mean reversion</i>										
Max	0.427	2.573	0.374	2.247	0.367	2.198	0.375	2.237	0.370	2.212
Max-min	0.070	1.200	0.031	0.609	0.045	0.939	0.093	1.766	0.144	2.179
Max-vw mkt	0.139	3.393	0.086	2.242	0.079	2.130	0.087	2.543	0.082	2.494
Max-ew mkt	0.058	1.756	0.005	0.167	-0.002	-0.088	0.005	0.219	0.001	0.044
<i>J = 1 week</i>										
Max	0.440	2.644	0.378	2.305	0.367	2.227	0.372	2.248	0.366	2.215
Max-min	0.130	2.319	0.060	1.299	0.035	0.850	0.069	1.419	0.117	1.857
max-vw mkt	0.152	3.831	0.090	2.582	0.079	2.422	0.084	2.733	0.078	2.599
max-ew mkt	0.070	2.205	0.009	0.322	-0.002	-0.077	0.003	0.137	-0.003	-0.150
<i>J = 1 month</i>										
Max	0.430	2.598	0.372	2.248	0.376	2.277	0.374	2.261	0.366	2.223
Max-min	0.082	1.531	0.010	0.204	0.030	0.661	0.080	1.559	0.134	2.109
Max-vw mkt	0.142	3.521	0.084	2.305	0.088	2.499	0.086	2.564	0.078	2.462
Max-ew mkt	0.061	1.885	0.003	0.093	0.006	0.241	0.004	0.190	-0.003	-0.157
<i>J = 3 months</i>										
Max	0.455	2.767	0.394	2.403	0.385	2.336	0.379	2.295	0.370	2.253
Max-min	0.113	2.093	0.080	1.530	0.128	1.956	0.166	2.140	0.198	2.240
Max-vw mkt	0.167	4.183	0.106	2.824	0.097	2.752	0.091	2.781	0.082	2.591
Max-ew mkt	0.086	2.665	0.025	0.856	0.016	0.615	0.009	0.415	0.001	0.045
<i>J = 6 months</i>										
Max	0.455	2.768	0.415	2.521	0.372	2.271	0.363	2.222	0.358	2.187
Max-min	0.094	1.654	0.060	1.086	0.029	0.512	0.045	0.595	0.090	0.991

Table 4 continued

	K = 1 day		K = 1 week		K = 1 month		K = 3 months		K = 6 months	
	Return	t-ratio	Return	t-ratio	Return	t-ratio	Return	t-ratio	Return	t-ratio
Max-vw mkt	0.167	3.998	0.126	3.079	0.084	2.151	0.075	2.077	0.070	1.965
Max-ew mkt	0.085	2.433	0.045	1.324	0.002	0.073	-0.006	-0.211	-0.011	-0.399
<i>J = 9 months</i>										
Max	0.521	3.027	0.432	2.614	0.403	2.432	0.380	2.284	0.378	2.283
Max-min	0.190	3.048	0.105	1.675	0.125	1.693	0.125	1.282	0.154	1.469
Max-vw mkt	0.233	4.276	0.144	2.961	0.115	2.430	0.092	2.083	0.090	2.192
Max-ew mkt	0.152	3.220	0.063	1.487	0.034	0.830	0.011	0.284	0.008	0.238
<i>J = 12 months</i>										
Max	0.500	2.832	0.397	2.353	0.369	2.220	0.343	2.088	0.355	2.170
Max-min	0.134	1.578	0.029	0.444	0.068	0.939	0.105	1.113	0.173	1.684
Max-vw mkt	0.212	2.848	0.109	2.004	0.081	1.547	0.055	1.159	0.067	1.489
Max-ew mkt	0.131	1.897	0.027	0.553	-0.001	-0.012	-0.027	-0.646	-0.015	-0.372

This table reports the mean returns (annualized) and t-ratios of Max, min, Max-min, Max-vw Market, and Max-ew market port min is the bottom decile portfolio, and vw Market and ew Market are the value-weighted and equally-weighted averages of i Exchange. The strategies considered are pure mean reversion and mean reversion with momentum. J denotes the number of mom The sample covers the period from December 12, 1990 to December 31, 2001 with 2,732 daily returns observations and 637 st ends on December 12, 2001 with 1,823 trading days

Numbers italicized and in bold face denote statistical significance at the 10% level or better using a 2-sided test

数据来源：海通证券研究所

可以看到在上述 42 组参数组合下，多头组合的表现都要强于空头组合，且超额收益率有一半以上在 10% 的置信水平下显著；和纯动量策略相比，42 种不同参数组合下，混合策略 39 次战胜了同样参数的纯动量策略；在 7 个不同持有期中，有五个持有期，混合策略的平均收益率都高于纯反转策略。深市的结果比较类似，不再赘述。

为了进一步验证动量反转混合模型的稳健性，作者考察了不同的组合选取比例、实际交易中的延后和交易费用对策略收益的影响，结果列于表 2，策略的参数选取为 J=12

个月，K=12 个月（Baseline Case）。

表 3 动量反转混合策略的稳健性检验（沪市）

Table 6 Robustness of portfolio performance results: Shanghai “A” shares

	Mean Return	SD	t-ratio	Sharpe ratio	Alpha	Beta	Annual portfolio turnover rate
<i>Baseline case</i>							
Max	0.338	6.962	2.075	0.049	0.060	0.958	0.840
Max-min	0.222	4.798	1.978	0.046	0.112	0.497	0.881
Max-wv mkt	0.050	1.871	1.148	0.027	0.060	-0.042	
Max-ew mkt	-0.031	1.604	-0.825	-0.019	-0.019	-0.053	
<i>Portfolio formed one day after ranking</i>							
Max	0.345	6.951	2.119	0.050	0.061	0.957	0.840
Max-min	0.208	4.786	1.856	0.043	0.098	0.487	0.881
Max-wv mkt	0.052	1.853	1.187	0.028	0.061	-0.043	
Max-ew mkt	-0.030	1.588	-0.815	-0.019	-0.018	-0.053	
<i>Stocks sorted into 3 portfolios</i>							
Max	0.367	7.031	2.227	0.052	0.084	0.977	0.662
Max-min	0.118	3.470	1.457	0.034	0.049	0.314	0.662
Max-wv mkt	0.079	1.599	2.102	0.049	0.084	-0.023	
Max-ew mkt	-0.003	1.250	-0.086	-0.002	0.005	-0.033	
<i>Stocks sorted into 5 portfolios</i>							
Max	0.373	6.971	2.286	0.054	0.094	0.958	0.763
Max-min	0.174	4.216	1.759	0.041	0.090	0.380	0.775
Max-wv mkt	0.085	1.903	1.911	0.045	0.094	-0.042	
Max-ew mkt	0.004	1.635	0.101	0.002	0.016	-0.053	
<i>Stock sorted into 20 portfolios</i>							
Max	0.382	7.573	2.152	0.050	0.085	1.041	0.821
Max-min	0.352	5.622	2.671	0.063	0.200	0.688	0.862
Max-wv mkt	0.094	2.063	1.940	0.045	0.085	0.041	
Max-ew mkt	0.012	1.723	0.308	0.007	0.006	0.030	

This table reports summary statistics for the trading strategy of mean reversion with 12-month momentum and 12-month holding period. Max is the top portfolio, min is the bottom portfolio, and vw Market and ew Market are the value-weighted and equally-weighted averages of all “A” shares traded at the Shanghai Stock Exchange. The alphas and betas are obtained by estimating the traditional CAPM. The mean, standard deviation and alpha are annualized. The sample covers the period from December 12, 1990 to December 31, 2001 with 2,732 daily returns observations and 637 stocks

Numbers italicized and in bold face denote statistical significance at the 10% level or better using a 2-sided test

数据来源：海通证券研究所

在原始策略的参数设计下，多空组合取得了 22.2% 的年化收益，且在 5% 的置信水平下显著；由于策略换手率不高，年换手平均在 1 一下，因而交易费用对收益的影响不大；延后一天购买会让多空组合的收益降低到 20.8%，但仍然在 10% 的置信水平下显著；不论全市场股票是划分为 3 等分、5 等分还是更细的 20 等分，按策略选出的多空组合都能获得显著正收益。

本文为投资者提供了一个时序模型来定量描述 A 股市场长期反转和短期动量的混合效应，基于此构建的股票多空策略表现明显好于单纯的动量或是反转策略，且稳健性强。不过作者实证过程用到的数据时间段太早，在当前行情下，上述模型是否依然有效，需要我们进一步验证。

分析师预测的一致性

文献来源: GILLES HILARY and CHARLES HSU ,Analyst Forecast Consistency ,
The Journal of Finance, Volume 68, Issue 1, pages 271–297, February 2013

推荐人: 纪锡靛 021-23219948

推荐理由: 学术界一般评价分析师都是根据其预测的准确性, 而本文提出了评价分析师的另一种更有效的指标即分析师预测的一致性, 并通过实证证明分析师预测的一致性比起准确度更能影响股票市场且对投资者是一个更有意义的信息。此结论让市场对于分析师预测有了新的理解: 分析师的预测一致性越高, 就越容易成为明星分析师; 分析师会倾向提供向下的预测从而实现更高的预测一致性; 分析师一致性指标提高了机构投资者存在的比例。

摘要:

长期以来投资者对分析师的预测都有着极大地需求, 因此很多学者都在研究分析师预测是如何影响市场价格的形成和分析师自身的职业发展。而一般的文献都是用预测的准确度即预测值与真实值的绝对差值来衡量分析师的表现, 认为其是影响价格的重要因素, 同样准确度越高给分析师带来的正面福利就越高。同时监管部门也一直在寻找评价分析师最为有效的指标。本文我们认为分析师预测的有效性应该建立在预测的信息量而不是准确度上, 举个例子, 如: 分析师 A 对收入的预测总是比真实值低 3 美分, 而 B 有 50% 的概率预测收入高于真实值 2 美分, 50% 预测低于真实值 2 美分, 但对投资者来说更偏好分析师 A, 虽然其预测的准确度不如 B 高, 但是 A 对于真实值的预测含有的信息量高于 B, 对于投资者来说是更有现实意义的。

本文的贡献包括以下几个方面:

A) 之前在研究预测的有效性和分析师前景的时候, 都是以分析师预测的准确性为唯一的衡量标准, 本文将大众的视线从准确度 (分析师预测与真实值的绝对差值) 转移到一致性程度 (预测与真实值差的波动率) 这一被大多数人所忽略的指标上来。并且本文验证了一致性是衡量分析师的更有效的指标, 为研究分析师行为寻找到了一个更准确的指标。

B) 分析师预测的一致性直接关系到分析师的福利分配, 预测的一致性越高, 分析师影响价格的能力越高, 信息含量越高, 机构投资者对其的需求就越大, 从而其声誉就越高, 成为明星分析师的可能性就越大。

C) 本文也为分析师一贯调低预测值这一行为找到了更有力的证据, 即为了实现预测一致性的最大化, 分析师更倾向于 lowball 的行为, 同时这也解释了众多分析师预测存在一定偏差的原因。

D) 我们同时也发现投资者的经验丰富程度直接影响到其更侧重于分析师预测的一致性或准确度, 一般经验丰富的投资者更注重预测的一致性, 反之注重准确度。因此市场上存在越多经验丰富的投资者, 则一致性对市场的影响程度就越高。这也解释了市场上现有对分析师评价存在不同指标的原因。

实证分析:

1. 一致性预测与市场影响力: 预测一致性和准确度越高的分析师对市场的影响力就越大, 而相较于准确度来说, 一致性对市场的影响程度更高更显著。

$$Beta_{ij} = \alpha_0 + \alpha_1 Cons_{ij} + \alpha_2 Accu_{ij} + \alpha_k X_{ij}^* + \epsilon_{ij}$$

我们用 Beta(股票超额收益对修正后的预测的回归系数)来衡量预测信息量, Cons (预测与真实值差值的波动率排名)表示预测的一致性, Accu (预测与真实值差值的绝对值排名)为预测的准确度,同时考虑了另外 6 个控制变量的影响(Boldness: 分析师预测偏离水平, Horizon: 预测提前天数, Experience: 分析师经验水平, Breadth: 分析师覆盖公司数量, BrokerSize: 经纪公司拥有分析师数量, Cover: 研究某公司的分析师数量)

$$Cons = 1 - (\text{rank} - 1) / (\text{number of analysts following the firm} - 1)$$

构建 Cons 指标共有三步: 1、估计分析师 i 对公司 j 在 q 季度的预测真实值差; 2、计算上一步预测误差值的波动率; 3、对每一位分析师预测波动进行排序, 并且根据公式进行变换得到分析师预测一致性指标 Cons。构建 Accu 也用类似的方法, 只是对分析师排序是用预测偏差的绝对值。

数据选取的是 1994-2006 年来自 I/B/E/S 的预测数据, 根据上述公式回归结果为: 预测一致性和准确性越高都提高预测的信息含量, 并且一致性的系数绝对值和显著性都要高于准确度 (4 倍的差距); 从控制变量结果可知, 预测发布的时间越早个人预测的结果就越接近平均预测值, 来自越大公司的分析师的预测数据对市场的影响越大。

表 1 分析师预测的一致性对市场信息含量的影响

Variable	Beta 1	SqrBeta 2
Intercept	-19.69 (-5.33)	-1.58 (-3.95)
Cons	8.71 (11.16)	0.72 (8.13)
Accu	1.97 (2.89)	0.45 (5.76)
Horizon	20.11 (9.96)	2.56 (10.39)
Boldness	-6.27 (-3.28)	-0.54 (-2.29)
BrokerSize	0.70 (2.52)	0.15 (4.09)
Experience	-0.46 (-0.47)	0.15 (1.19)
Breadth	0.63 (0.67)	0.03 (0.28)
Cover	7.43 (6.27)	0.57 (4.65)
N	38,096	38,096
R ²	1.93	1.36

资料来源:《Analyst Forecast Consistency》, GILLES HILARY and CHARLES HSU,【2013】

为了进一步验证上一步得到的结论的可靠性, 本文接下来具体分析 Cons 和 Accu 指标 0.3 的相关性是否会对结论产生影响: 首先我们剔除准确度和一致性高于平均水平的预测样本, 对其进行重新上一步的回归估计, 得到跟之前相似的结论; 其次我们对两个指标进行正交变换进行估计, 同样得到了一样的结果, 更加证实了之前的结论是可靠的。

2.一致性指标和分析师福利的关系: 分析师预测一致性的不同对其职业的发展的影响是不同的——预测一致性越高, 分析师在市场的声誉就越高, 成为明星分析师的可能

性就越大。

$$Demo_{i,t} = \gamma_0 + \gamma_1 Cons_{i,t} + \gamma_2 Accu_{i,t} + \gamma_k X_{i,t}^m$$

$$AllStar_{i,t} = \delta_0 + \delta_1 Cons_{i,t} + \delta_2 Accu_{i,t} + \delta_k X_{i,t}^m$$

我们用两个指标表示分析师的福利：雇主的地位和行业内人士的认可程度。Demo 是一个虚拟变量，当分析师 I 被降级的时候为 1，反之为 0，另外当分析师跳槽到一个更小的公司也认为其被降级为 1；AllStar 同样是一个虚拟变量，当分析师在机构投资者杂志上榜时为 1，反之为 0。X 表示控制变量矩阵，表格 3 展示回归结果——一致性显著程度提升了分析师的福利水平：demo 降级程度和一致性准确性呈负相关，且一致性的回归系数和显著性都高于准确度；ALLSTAR 和一致性准确度呈正相关，同样一致性的显著程度高于准确度。为了进一步验证结论的可靠性，同样我们进行稳健性检验，用分析师升级指标 PRMO 替换 DEMO 指标，进行回归，通过实证仍未改变我们的结论。

表 2 分析师预测的准确度和一致性对分析师降级的影响

Variable	Demo	AllStar
	1	2
Cons	-0.30 (-4.24)	0.60 (4.89)
Accu	-0.03 (-0.29)	0.54 (4.03)
Boldness	-0.13 (-0.48)	-0.35 (-0.95)
Breadth	-0.01 (-2.94)	0.02 (4.74)
Cover	0.14 (2.94)	0.15 (2.36)
Experience	-0.01 (-0.26)	0.42 (5.46)
N	15,561	11,985
Pseudo R ²	7.57	23.18

资料来源：《Analyst Forecast Consistency》，GILLES HILARY and CHARLES HSU, 【2013】

3. 一致性预测对分析师行为的影响：我们发现为了提高预测的一致性，分析师倾向于调低其预测值，甚至在一定程度上放弃预测的准确度；同时这一举动会令公司更容易实现市场对其收入的预期，而使得分析师更容易从其获取有效的信息对未来的数据做预测，反过来提高其未来预测的有效性。

$$Cons_{i,j,q} = \alpha_0 + \alpha_1 Lowball_{i,t,q} + \alpha_k X_{i,j,q}^* + e_{i,j,q}$$

$$Accu_{i,j,q} = \alpha_0 + \alpha_1 Lowball_{i,t,q} + \alpha_k X_{i,j,q}^* + e_{i,j,q}$$

LowBall 表示分析师调低预期的意愿程度，结果如下表所示：lowball 和 cons 是显著正相关，表明调低预期的分析师传递更一致的预测，同时不影响其他变量的主要结果；accu 和 lowball 为显著负相关，表示分析师下调预测的动力不是来自准确度。

表 3 分析师调低预测 (lowballing 行为) 对预测一致性的影响

Variable	Cons 1	Accu 2
Intercept	0.56 (28.02)	0.77 (54.25)
Lowball	0.20 (24.84)	-0.11 (-5.32)
Horizon	-0.27 (-16.77)	-0.35 (-17.01)
Boldness	-0.25 (-22.61)	-0.30 (-19.90)
BrokerSize	0.03 (6.23)	0.03 (6.51)
Experience	0.04 (5.12)	0.06 (5.98)
Breadth	-0.02 (-2.69)	-0.04 (-5.00)
Cover	-0.01 (-2.66)	-0.01 (-1.72)
N	286,104	286,104
R ²	6.43	4.47

资料来源:《Analyst Forecast Consistency》, GILLES HILARY and CHARLES HSU, 【2013】

4.一致性预测与投资者的经验: 市场上存在越多的经验丰富的机构投资者, 会大大提升分析师预测的有效和一致性, 相反若存在较少的经验丰富的投资者, 会提升分析师预测的准确度。

一般认为机构投资者比散户经验更为丰富, 因此我们用 inst (机构投资者所占比重) 衡量投资者是否经验丰富, 我们以此为依据将投资者分为高和低的两个子样本进行回归, 结果如下: 一致性和准确度与机构投资者比重呈正相关, 同时一致性的回归系数和显著程度大大高于准确度, 验证了我们的假设。

表 4 分析师预测一致性对投资者成熟水平的影响

Variable	SqrBeta Low Inst 1	SqrBeta High Inst 2
Intercept	-2.23 (-4.38)	-0.80 (-1.43)
Cons	0.40 (3.08)	1.03 (7.85)
Accu	0.53 (4.91)	0.37 (3.30)
Horizon	2.16 (7.17)	3.18 (9.26)
Boldness	-0.44 (-1.42)	-0.62 (-1.87)
BrokerSize	0.15 (3.48)	0.12 (2.51)
Experience	0.13 (0.82)	0.39 (2.19)
Breadth	-0.02 (-0.15)	0.11 (0.66)
Cover	0.83 (5.40)	0.22 (1.21)
N	18,747	18,856
R ²	1.68	1.39

资料来源:《Analyst Forecast Consistency》, GILLES HILARY and CHARLES HSU, 【2013】

基于市场流动性的情绪指标

文献资料: Baker, Malcolm, Jeremy Stein, 2004, "Market liquidity as a sentiment indicator", Journal of Financial Markets 7: 271-299.

推荐人: 丁鲁明 021-23219068

推荐理由: 本文提供了自对有卖空限制证券的市场定价机制的一种分析框架, 主要从市场层面的交易特征出发, 为该环境下可能出现的高估值高溢价现象提出合理解释。由于近期国内转融通业务开始试点, 标志着 90 只大市值标的批量可做空时代的真正到来, 但另一方面以中证 500、中小板、创业板为代表的中小市值公司却依旧处在不可卖空条件之下, 1 月以来大小盘近 10% 的表现分化是否缘于该卖空条件的变化, 我们或许可以在借鉴本文献后从流动性角度方面进行更量化的解释。

摘要

本文建立模型并描述了一些非理性者的特征, 使用诸如: 低买卖价差、价格对交易量的弹性、高换手率等, 解释其对未来证券回报的影响。发现在有卖空限制的证券市场中, 由于非理性投资者的参与, 导致市场价格扭曲, 出现诸如: 交易更活跃、换手率更高、股权融资比例上升、IPO 活跃度上升等直观现象, 并最终伴随后续证券收益率的普遍下降。使用美国的个股基本面加权和等权加权方法都得到了类似的实证效果。

一. 介绍

Amihud and Mendelson (1986), Brennan and Subrahmanyam (1996), and Brennan, Chordia, and Subrahmanyam (1998) 发现: 以单个公司作为截面数据, 发现低价格对交易的影响, 低买卖价差, 高换手率都与未来回报率有联系。

Chordia, Roll and Subrahmanyam (2000, 2001), Hasbrouck and Seppi (2001), Huberman and Halka (2001), Amihud (2000) and Jones (2001) 发现整个市场的流动性伴随时间发生变化, 并且能够影响到未来收益。买卖价差更低的, 价格影响更小的, 换手率更高的, 流动性会更高, 比较其他的股票价格也会稍高, 但回报率低。

Jones (2001) 发现市场整体流动率对市场回报率有很强的预测能力, 特别是等权回报率。在单因素回归中, 使用随机非趋势的换手率指标, 一个标准差的增加可以减少在未来一年的 CRSP 等权指数约 13% 的期望回报率。

Odean (1998a) and Kyle and Wang (1997) 使用了类似的机制, 寻找过度自信程度和流动性指标间的联系, 但这些模型并没有包含流动性指标和预期回报之间的关系。Stigler (1964), Ritter (1991) 等发现当公司发行了股票, 在后续时间里有很低的回报率。即 new issue puzzle.

本文中我们使用的模型依赖于两个关键的假设 1 非理性投资者的存在降低了交易价格偏高带来的负面影响, 并促进流动性的提升。2 卖空限制下非理性投资者的一些特定情绪能够成为影响市场价格的一个重要力量。

我们构建数据分析, 寻找市场流动性同未来预期回报之间的统计关系, 并对之前相关及文献中提出的现象给出合理的数据解释。

二. 基本模型: 投资者情绪与市场流动性


观点 (1)

市场由不同类型投资者构成，价格也由其共同决定。借用 Kyle (1985) 的模型，把不同时段股票的定价与投资者情绪的关系做了明确的定义。

上述模型将市场情绪划分为有三个状态。在第一期至第三期，存在两种类型的非知情交易者。第一类投资者是“聪明”的，在第一期对股票（红利）有正确理性预期；第二类投资者是“愚笨”的，在第一期不能对股票（红利）有正确预期，产生的偏差为愚笨投资者最初的“情绪”，即对股票的错估，这可以看成是愚笨投资者的过度自信，或对私有信号噪音的过度反映，在第二期中，还存在一个“知情交易者”，他能及早获得私有信息，非知情交易者通过与之交易会获取这部分相关私有信息。

聪明的投资者对交易有理性的判断，能充分利用所获信息来估计最终红利，而愚笨的投资者不能对第二期发生交易包含的信息产生充分的反应，说明愚笨投资者能正确但不能充分更新对价值的估值，这可能是因为愚笨投资者没有意识到第二期发生的有价值的新信息，但更可能是因为愚笨投资者对他们拥有的第一期信息过度自信，他们不能对知情交易者的信息做出充分的反应。因此，愚笨投资者的过度自信行为涉及两方面，第一期的情绪冲击和第二期的对交易行为的不充分反应，第三期为清算期，市场价格已经完全由愚笨投资者控制。


图 4 不同阶段情绪下的市场定价差异



资料来源：《Market liquidity as a sentiment indicator》，Baker, Malcolm, Jeremy Stein, 【2004】

假设 1：将投资者情绪分成三个不同的阶段，各阶段的投资者行为导致的价格见图 1：阶段 1：投资者情绪低阶段，聪明投资者参与市场交易，愚笨投资者在场外观望；阶段 2：投资者情绪中等阶段，两类投资者均参与市场交易；阶段 3：投资者情绪高阶段，仅仅有愚笨投资者参与市场交易，聪明投资者在场外观望。价格随着市场投资情绪的提升而上升。


图 5 不同阶段情绪下证券价格对交易量的敏感性关系



资料来源：《Market liquidity as a sentiment indicator》，Baker, Malcolm, Jeremy Stein, 【2004】

假设 2：流动性随着投资情绪的增加而增加。阶段 1→阶段 2→阶段 3，由于不同交易者的交易习惯差异，伴随市场参与者的变化，市场的流动性程度逐步增加（换手率的提升），而交易量对价格的影响逐渐降低。

图 6 不同阶段情绪下的换手率差异



资料来源：《Market liquidity as a sentiment indicator》，Baker, Malcolm, Jeremy Stein, 【2004】

观点（1）补充：

如果没有卖空限制，那我们始终会处于第二阶段，两类投资者均在市场上参与交易，正如 De Long et al.1990 的“a standard noise-trader model”。此种情形下，愚笨投资者情绪仍然会增加，预期收益将减少。但是流动性和交易量不会再发生变动，因为两类投资者所占比重将恒定。即使愚笨投资者比聪明投资者还要过度乐观，全部买进，聪明投资者进行卖空，对价格的边际影响仍和以前一样。如果模型加入卖空限制，情况将发生变化。愚笨投资者将变得越来越乐观，将使聪明投资者退出市场观望，且完全影响定价。

阶段 3，聪明投资者完全退出市场，愚笨投资者完全影响定价方程。再加上愚笨者们对交易包含的信息不能完全做出反应，市场流动性将会显著增加。

观点（2）

流动性随着投资者情绪增加而增加，价格交易影响减小，交易量增加。Admati and Pfleiderer (1988)做了内源性流动量交易的方差，低价格影响，交易量增加，未来回报率会降低。

观点（3）

不理智投资者占据市场主要份额，流动性强，期望回报率下降。De Long et al. (1990)标准的噪声交易者模型，当非理性投资者情绪高涨，那么期望回报率就下降。

观点（4）

当流动性增加的时候，动量利润盈利更大。Lee and Swaminathan (2000)发现高动量的股票伴随着高交易量。流动性与动量策略的条件盈利有密切的关系，并且当市场流动性增加时，动量策略发挥得更好。

观点(5)


从公司财务角度解读流动性和市场表现的关系：股票发行和预期回报。

基于长期基本面，经理有优劣的水平去判断是否公司高估或低估，但是融资决策还是最简单的法则，并且融资决策是市场流动性的一面镜子。

在热销的发行市场，存在一个普遍现象，期望回报率（新股后续收益表现）下降。


下图表明即使经理人没有判断市场信息，融资决策仍可以预测长期回报。在理性市场中往往伴随着较少的增发或新股发行公告，且一旦公告可能反而股价下跌，但在非理性市场中下跌作用有限，另一方面证券发行的数量和规模伴随这市场的非理性投资者增多而增多，在市场中充满非理性投资者的第三阶段，往往是实业经理人最倾向于股权融资的时点。

图7 不同阶段情绪下股权融资公告效应



资料来源：《Market liquidity as a sentiment indicator》，Baker, Malcolm, Jeremy Stein, 【2004】


图8 不同阶段情绪下的股权融资规模差异



资料来源：《Market liquidity as a sentiment indicator》，Baker, Malcolm, Jeremy Stein, 【2004】

上图反映不同市场参与主体下,上市公司或拟上市公司倾向于股权融资的规模,非理性投资者参与越多的市场,其市场价格往往更高估,选择在该阶段进行股权融资是上市公司的最优选择,对应股权摊薄成本最低。

图9 美国证券市场年换手率同股权融资偏好的关系（1927-1998）



资料来源：《Market liquidity as a sentiment indicator》，Baker, Malcolm, Jeremy Stein, 【2004】

上图反映的是纽约证券交易所换手率与股权融资偏好度的对应变化关系，两者存在显著的正向关系。

对1975年后偏差的解释：1975年的SEC出台浮动佣金政策，竞争加剧，价格下跌，换手率反而有所提升；Baker and Wurgler把在1982年至1986年间6倍债务的增长和换手率的下降的原因部分归结于利率的下降和一个垃圾债券的成长市场，政策主导和其他因素的影响导致了82-86年在股市换手率进一步提升背景下股权融资比例的平稳，背后是该指标的分母---债券融资规模在政策支持下的放大。

三、一些常见的市场现象讨论

讨论1 公司层面的流动性与股票回报率

Amihud and Mendelson (AM) (1986)根据买卖价差构建投资组合并研究组合收益差异。

Brennan and Subrahmanyam (BS) (1996)用 Kyle's 的价格对成交量敏感性参数 λ ，并以参数进行股票分组，发现高参数组合未来三年的月度收益表现显著由于低参数组合。

讨论2 在经济繁荣下，互联网股票的行为

Ofek and Richardson (OR) (2001)发现1999年美国互联网泡沫期间，市场中高估值与低交易较差和异常高的交易量伴随，其可以部分解释当时支持非理性上涨的主要原因。

讨论3 通用流动性与总股回报率

Chordia, Roll and Subrahmanyam (CRSB) (2001)在流动性上识别了整个市场的因素，例如价差，深度，换手率应对短期利率。

Amihud(2000)和琼斯(2001)发现市场换手率，绝对市场回报率与换手率的比率和平均价差对未来的回报率有很好的预测能力。

讨论 4 新股发行困惑

市场指数本身是否是一个好的业绩基准？这个问题起源于一个新股发行困惑，即新上市公司在随后的市场表现总是弱于其他已上市公司的平均水平，从而拖累市场指数整体表现。发行人总是倾向于拥有高比率的市场账面价值，发行后的低回报率与更积极的市场流动性和股票发行的市场时机理论一致。关键思想在于当在市场愿意接受新股发行的基础上，融资决策可以实现。那么这种形式的流动性，像价差，交易量，关于这些非理性投资者影响市场程度的信息，等。这些因素都与回报率有关。

Stigler (1964), Ritter (1991)等提出相对于市场基准，股票发行，得到很低的回报率。Brav and Gompers (1997) 发现新发行公司的平均表现甚至比国库券要差。

Fama (1998) and Mitchell and Stafford (2000)在新股发行困惑上提出经济学和统计学上的新问题：经济上关于价值加权的回报率更好；统计上关于发行活动集中的时间与发行人的回报是不是独立的。

讨论 5 热销发行市场与总股回报率

Bayless and haplinsky (1996)发现热销市场有很多股票增发的行为，减少发行后平均价格涨幅。Baker and Wurgler (2000)热销市场带来的未来回报率很低。

五. 总换手率、股票发行、股票回报率的数据实证

(1) 数据

根据纽约证券交易所的 1927-1997 年的部分数据

用 Ibbotson(2001)价值加权和等值加权 CRSP 投资组合

(2) 换手率与新股发行的融资偏好度

Baker and Wurgler (2000)把在 1982 年和 1986 年之间的 6 倍增加的债务问题一定程度上归结于降低利率和一个垃圾债券的增长市场。

(3) 换手率和融资偏好度预测未来回报率

Baker and Wurgler (2000) and Jones (2001)做了趋势下的研究，本文以去除趋势项后的指标为范围做了研究，并排除了 1927 年前不稳定的因素，用等权指数得出的结果强调了在多数股票上换手率的影响。

(4) 模型解释

模型 1: 换手率和新股发行中的股权融资比例的关系

$$S_t = a + b \text{Turnover}_t + c \frac{D}{P_t} + d_1 R_{t-1} + d_2 R_{t-2} + d_3 R_{t-3} + u_t,$$

S=equity share 融资偏好度 $S=e/(e+d)$

Turnover=换手率

D/P=CRSP 价值加权股息率

R=CRSP 价值加权投资组合的净值报酬率

(t)=time

图 10 实证检验美国市场不同流动性指标对股权融资偏好的影响

	Levels				Detrended Levels			
	coef	[t-stat]	coef	[t-stat]	coef	[t-stat]	coef	[t-stat]
Panel A:	1927-1974				1932-1974			
Turnover	7.68	[4.89]	9.59	[5.71]	6.61	[8.63]	6.73	[5.14]
VW D/P			-1.85	[-1.26]			-0.31	[-0.16]
R_{et-1}			2.46	[1.58]			1.37	[0.68]
R_{et-2}			0.79	[0.64]			-0.69	[-0.41]
R_{et-3}			-0.36	[-0.26]			-1.27	[-1.39]
N		48		46		43		43
R ²		0.42		0.50		0.45		0.50
Panel B:	1927-1998				1932-1998			
Turnover	4.00	[1.50]	3.30	[0.93]	4.10	[2.71]	3.84	[2.24]
VW D/P			1.55	[0.82]			-0.05	[-0.04]
R_{et-1}			2.40	[1.78]			1.45	[1.01]
R_{et-2}			0.60	[0.45]			-0.30	[-0.26]
R_{et-3}			-0.17	[-0.17]			-0.03	[-0.03]
N		72		70		67		67
R ²		0.13		0.12		0.20		0.22

资料来源：《Market liquidity as a sentiment indicator》，Baker, Malcolm, Jeremy Stein, 【2004】

上图采样周期把 1929 年前的股市崩盘时段去除。实证结果显示，股权融资的偏好程度同过去的换手率指标正相关，换手率每变动 1%，对应的股权融资偏好度上升 4-10%，且在 1982 年（标普股指期货推出时点）之前的不可卖空时代，两者回归系数更高。

模型 2：股权融资比率、换手率指标对未来个股收益的预测效果

$$R_t = a + bS_{t-1} + cTurnover_{t-1} + d \frac{D}{P_{t-1}} + u_t,$$

R=股票市场回报率

S=equity share

Turnover=换手率

D/P=股息率

图 11 实证检验美国市场股权融资偏好、年换手率等指标对未来价格表现的负面影响

	Levels				Detrended Levels			
	coef	[t-stat]	coef	[t-stat]	coef	[t-stat]	coef	[t-stat]
Panel A:	1927-1974				1932-1974			
Turnover	7.68	[4.89]	9.59	[5.71]	6.61	[8.63]	6.73	[5.14]
$VW D/P$			-1.85	[-1.26]			-0.31	[-0.16]
R_{et-1}			2.46	[1.58]			1.37	[0.68]
R_{et-2}			0.79	[0.64]			-0.69	[-0.41]
R_{et-3}			-0.36	[-0.26]			-1.27	[-1.39]
N		48		46		43		43
R ²		0.42		0.50		0.45		0.50
Panel B:	1927-1998				1932-1998			
Turnover	4.00	[1.50]	3.30	[0.93]	4.10	[2.71]	3.84	[2.24]
$VW D/P$			1.55	[0.82]			-0.05	[-0.04]
R_{et-1}			2.40	[1.78]			1.45	[1.01]
R_{et-2}			0.60	[0.45]			-0.30	[-0.26]
R_{et-3}			-0.17	[-0.17]			-0.03	[-0.03]
N		72		70		67		67
R ²		0.13		0.12		0.20		0.22

资料来源：《Market liquidity as a sentiment indicator》，Baker, Malcolm, Jeremy Stein, 【2004】

因为正相关，所以系数明显下降，在非降序的换手率上，增加一个标准的偏差，可以导致明年减少 4% 价值加权和 13% 的等价加权回报率，换手率和股权融资偏好度为两个独立变量并与流动性有关，OLS 回归产生了非常大的 29% 的 R²。

可以发现，在对股权融资比率、换手率的单变量回归上，无论是等权重还是市值加权下都是显著指标，以等权为例，1% 的股权融资偏好变动影响 -13% 的下一年平均收益。再加入分红指标后的三指标多元回归的结果中，等权加权方式下也显示为系数显著，表明流动性指标对下一年预期收益的负面影响作用。

六. 结论

在卖空限制政策下，市场流动性是个情绪指标，在一个流动性异常高的市场中的价格变化往往是由非理性投资者决定的。因此高流动性是个迹象，表明这些非理性投资者情绪是积极的，从而未来预期回报率将降低。模型需要有卖空限制的假设——即对信息估计不足的投资者所受到的情绪波动对股价总是正向的，从而在市场亢奋阶段这些非理性投资者往往对理应正常影响股价的新闻更表现为反应不足。

金融市场的波动率预测：综述（一）——原因与基本模型介绍

文献来源：Ser-Huang Poon, Clive W.J. Granger, Forecasting volatility in Financial market: A review, Journal of Economic Literature Vol. XLI(June 2003) pp. 473-539, 2003

推荐人： 飞跃 021-23219984

推荐理由：波动率是描述投资风险及经济变化情况的重要指标之一。单纯追求收益而忽略风险的投资方式是不可取的；同时，随着更多的风险对冲和金融投资的工具的出现（如期权），波动率的预测成为金融量化投资领域重要的研究课题之一。本文的作者之一 Granger 是获得过诺贝尔经济学奖的著名的计量经济学家，他在波动率预测方面的造诣是毋庸置疑的。本文是他与 Ser-Huang Poon 教授撰写的波动率预测模型的综述文章的前半部分。该文章系统性的总结了发表于 2003 年以前的经典的波动率预测模型的研究成果，为系统性的了解这一领域在 2003 年以前的研究进展，起到了高屋建瓴的作用。

1. 介绍

波动率预测是金融市场的重要工作之一，在过去的二十年中，波动率预测引起了学者与实践者极度的重视。在这期间，业界和学术界发表了大量关于波动率预测和波动率模型方面的文章。人们对这方面的大量研究，反映了波动率预测在金融投资、证券估值、风险管理与货币政策制定方面的重要性。

波动率本身并不等同于风险。但当被解释为非确定性时，它便成为处理投资与资产配置问题的重要参数。投资者与基金经理均有一定承担风险的底线。在他们的投资期限内，对于资产波动率的准确估计，是评估资产风险的重要过程。

另一方面，波动率是一些衍生品定价的重要参数。为了能够准确对衍生品价值进行估值，我们需要知道衍生品标的物在衍生品生存期的波动率。实际上，依据市场惯例，人们将波动率作为度量衍生品价格的方式。在当今很多成熟的金融市场环境下，人们甚至可以交易以波动率为标的的产品，波动率本身已经成为一种新的资产。所以，对波动率、进而对波动率的波动率进行预测，成为这些产品定价的重中之重。

然后，自 1996 年巴塞尔 I 协议签署以来，金融风险管理成为金融市场管理的核心内容。这一过程促使世界上的很多金融机构进行波动率预测方面的研究。银行与交易机构必须保持三倍于其 VaR 的现金资产。在有了准确的波动率预测之后，VaR 的预测也并不是难事。当然，这同时依赖于均值估计和未来资产价值的正态分布假设。即使正态分布假设有争议，使用随机波动率过程进行 VaR 预测时，波动率预测仍旧非常重要。

基于波动率预测的重要性，这篇文章的目的在于提供关于这方面研究的综述。从实用主义角度出发，我们认为一个波动率模型的成功之处，不在于它的历史回溯有多么有效，而在于它的外推结果的有效性。尽管我们没有办法将这些波动率模型，在大量的数据和不同的市场环境下，一一进行检验。但是通过对 93 篇相关文章中，所介绍的方法与实证测试的认真回顾，我们能够提供所有波动率方面研究成果的整体研究现状，并给出实用的研究成果及未来的可能研究方向。在我们对相关文献进行筛选时，我们排除了没有外推实证的文章，以及有关于相关性预测的文章，尽管后者在资产组合方面同样有重要的应用。

2. 基础

2.1 波动率、标准差与风险

许多投资者与金融领域的学生并不能很好的区分波动率、标准差与风险，因此我们首先将这三个概念进行解释。在金融领域，波动率通常被定义为一组观测值的标准差 σ ，计算为

$$\sigma^2 = \frac{1}{N-1} \sum (R_t - \bar{R})^2 \quad (1)$$

其中 $\bar{R}$ 是平均回报率。样本的标准差表明了样本分布的二阶矩性质。除非该标准差被认为是正态分布或者其它如 t-分布的参数，否则我们无法对其进行理论上的分析。事实上，我们可以对任意分布产生的样本计算其标准差，在这种情况下，我们只能通过实证的方式获得分布函数。在连续时间模型下， σ 是一个比例参数，它放大或缩小了由标准维纳过程（即布朗运动，译者注）产生的波动。根据标的物的随机过程的参数是否随时间变化，标的物的未来价格分布可以是各种各样的。因此，用波动率进行风险度量本身是没有意义的，除非我们已经假定了标的物的价格满足某种具体类型的分布。

2.2 波动率的定义和度量

如前所述，波动率一般被计算为样本的标准差。Stephen Figlewski(1997)注意到，由于样本的均值的统计性质较差，尤其是在样本数量很少的情况下，因此在估计波动率的时候，选择在零值附近而非均值附近进行计算，可以得到更加精确的波动率估计（当然这是在回报率的均值接近于零的前提下才成立，译者注）。同样，有很多研究设计了更好的波动率的估计方法，其目的在于减小罕见的极值影响（如由 Clifford Ball 和 Walter Torous, 1984 提出的 Maximum likelihood method, 以及 Micheal Parkinson, 1980 和 Mark Garman 与 Michael Klass, 1980 年所提出的 high-low method）。另外公式 1 是对样本方差的无偏估计，但是它的平方根却不是对标准差的无偏估计，其原因在于 Jensen inequality（译者注：平方根函数非线性，因此根据 Jensen 不等式，标准差的估计不可加）。Zhuangxin Ding, Clive Granger 和 Robert Engle（1993）建议直接通过回报率的绝对值来估计波动率。

为了帮助理解公式 1 的在连续时间情况下的情况，我们假设瞬时回报率满足下面这个鞅的随机微分方程

$$dp_t = \sigma_t dW_{p,t}$$

其中 $W_{p,t}$ 是一个标准的维纳过程。由以上方程我们可以知道，单期回报率

$$r_{t+1} = p_{t+1} - p_t$$

的条件方差为

$$\int_0^1 \sigma_{t+\tau}^2 d\tau,$$

它也被称之为 t 与 t+1 期限之间的积分波动率。这个参量在基于随机波动率方程的衍生品定价中至关重要(见 Juhn Hull)。值得注意的是， p_t 是可测的，而 σ_t 则是隐变量。

令 m 为取样频率，且

$$r_{m,t} = p_t - p_{t-1/m} \quad (\text{原文为 } r_{t-1/m}, \text{ 译者注})$$

为连续回报率。若离散的样本回报率之间是线性无关的，并且波动率 σ_t 的样本路径是连续的，那么根据二次变分理论（Ioannis Karatzas 和 Stephen Shreve 1988），我们可知

$$p \lim_{m \rightarrow \infty} \left(\int_0^1 \sigma_{t+\tau}^2 d\tau - \sum_{j=1, \dots, m} r_{m,t+j/m}^2 \right) = 0$$

（这里 $p \lim$ 应该理解为概率分布下的极限，译者注）。因此理论上，如果取样足够平凡，我们可以认为 σ_t 是可以观测的。William Fung, David Hsieh（1991）与 Torben Andersen, Tim Bollerslev（1998）用实际波动率这个术语来表示日内超短时间段的回报率的平方和，其中时间段的长度为 5 至 15 分钟。这样的波动率计算方法给出了一种对隐变量 σ_t 的较为准确的估计方法。同时要注意到，基于金融市场的数据特点，若观测的时间间隔低于 5 分钟，那么由市场的微观结构导致的回报率序列的伪相关性，使得波动率的估计将变得不再准确。这些市场的微观结构包括，交易的非同步性、离散的价格观测、日内的周期性波动率变化特点以及买卖价差的影响。这方面的理论结果同样引起学术界的关注，我们将在 4.4 节回顾这方面的研究成果。

2.3 金融市场波动率的常见特点

金融时间序列及其波动率序列有若干常见的特点，它们包括风险资产回报率的肥尾特点、波动率的聚集性、波动率的非对称性和均值回归性，以及不同资产之间的波动率变化同步的特点。大量的最新研究表明（本文发表于 2003 年，译者注），不同资产之间，其波动率的相关性要远远高于回报率的相关性，且在熊市与金融危机时期均趋于提高。由于金融时间序列的波动率结构非常复杂，Francis Diebold（1998）提醒，不同的波动率水平、波动率结构（即积聚的持续期长短与均值回归速率等）与预测期限，导致不同的波动率预测结果。这些内容将在下面的部分中进一步讨论。

若回报率是 iid 的，那么一段长时期的回报率的方差的计算将很简单，我们可以通过将短时期的方差乘以长时期的时间段个数获得。但由于上面所陈述的波动率特点，使得这种计算过程根本不成立。但尽管对波动率的点估计 $\hat{\sigma}_{T-1,T|t-1}$ 在 $T \rightarrow \infty$ 变得非常不准确，但是除非波动率水平与结构发生了本质上的变化，累计预测 $\hat{\sigma}_{t,T|t-1}$ 却变得更加准确。其原因在于，波动率的均值回归性使得误差互相抵消。

一些研究表明，波动率的时间序列有一个单位根（Philip Perry 1982，和 Adrian Pagan, G. William Schwert 1990），即

$$\sigma_t = \phi \sigma_{t-1} + \varepsilon_t,$$

其中 ϕ 与 1 的区别不显著。其它的文章（如 Granger, Ding, Scott Spear 2000）发现日频率和日内频率的回报率有长记忆性。

选取预测期限的复杂性，一部分是由波动率的均值回归特点导致的。一般来说，若相对于预测期限，采样频率越高，波动率的预测效果越好（Anderson, Bollerslev, Steve Lange 1999）。但是若预测期限很长，如 24 个月，Figlewski（1997）发现使用日频率数据的预测效果，要比月频率数据的预测效果差。在某些情况下，如预测期限大于 10 年，用周数据或者月数据要更好，这是因为高频数据在均值回归模型下更难处理。一般来说，当预测期限逐渐远远大于数据的频率，那么用模型进行预测的效果会失去其优势。实际上，对于大于 6 个月的预测期限，使用至少与预测期限一样长的期限内的低频数据，可以获得更好的预测效果（Andrew Alford, James Boatsman 1995; Figlewski 1997）。

Feiko Drost 与 Theo Nijman（1993）从理论上及一个特殊情形——GARCH（1,1）模型下，证明了波动率结构是不依赖于时间频率的。换句话说，无论采样频率是时、日间还是月频率，波动率结构都应该是相同的。但这在实际情况下并不成立；波动率的特

续性在日数据小表现非常显著，但是若采样频率降低，那么现象变得不再显著。这使得我们难以进一步一般化波动率特征与预测结果。

3. 波动率预测模型

在本节，我们首先介绍不同的、使用历史数据进行波动率预测的时间序列模型。然后我们从另一个角度出发，使用期权价格来获得波动率的市场预期（由于国内并没有期权市场，此部分不在翻译范围之内，译者注）。波动率估计的非参数方法也是预测手段之一，但是由于这种方法的效果很差（Pagan, Schwert 1990, Kenneth West, Dongchul Cho 1995），我们并不打算讨论这种方法。同时，基于神经网络的波动率模型也不在我们的介绍范围之内。

3.1 时间序列波动率预测模型

Stephen Brown(1990), Engle(1993)和 Abdurrahman Aydemir (1998) 包含了一系列的用于波动率预测的模型。Kroner(1996)解释了如何构建和使用波动率预测模型。本节中，我们将范围缩小到所关注的 93 篇文章之中。关于这些模型的各自的特点，请见附录 A。

所有的这些模型都包含了波动率的保持性、聚集性，有些模型将波动率的非对称性也列入模型范畴。对于一个金融资产，我们很容易构建一个供需模型，使得资产的供给为一个常数，而需求则部分上由一个外部变量以非线性的方式驱动。这样的模型所产生的资产回报率是异方差的(heteroskedasticity)。但是这类模型是建立在经济理论基础上的，而并不满足实际情况。我们要介绍的模型并不是建立在经济理论基础上的，而是建立在实际的回报率时间序列基础上，目的是要抓住这些时间序列的基本特点。如果我们能做到这一点，那么我们有理由相信这些模型有一定的预测能力。

3.1.1 基于历史标准差的估计方法

此类模型的基本假设为，对于任意 $\tau > 0$ ， $\sigma_{t-\tau}$ 在时间 $t-1$ 都是已知或者可以估计的。那么最简单的模型为随机游走模型，也就是说 σ_{t-1} 可被当作 σ_t 的估计。将这一思路推广，我们可以得到历史平均估计法（HA）、滑动平均法（MA）、指数光滑法（ES）和指数权重滑动平均法（EWMA）。历史平均估计法将所有的历史标准差都被用于参数估计，滑动平均法舍弃了较早的历史数据，指数光滑法使用了所有的历史数据，而指数权重滑动平均法则使用了较近的历史数据。不同于前两种方法，指数方法对较近的历史波动率给予更大的权重。所有的这些模型，都体现了参数估计中，在增加观测数据和在时间 t 附近采样这两个原则的平衡。

Riskmetric 模型使用了 EWMA 方法。由 James Taylor 在 2001 年提出的 Smooth Transition Exponential Smoothing 模型是一个更有弹性的指数权重方法，其权重依赖于过去数据的大小甚至正负号。之后我们有线性回归法，该方法将当前波动率表示成过去波动率的函数与误差项的和。本质上，简单回归法（Simple Regression）是一种自回归模型。若过去的波动率的误差项也在此类模型范围之内，那么我们就得到了 ARMA 模型。进一步，我们可以考虑波动率序列的 d 阶差分。若取 $d=1$ ，我们可以得到所谓的 ARIMA 模型；而在 $d<0$ 的情况下，我们得到 ARFIMA 模型。最后，我们还可以考虑所谓的 Threshold Autoregression 模型，其中的阈值将序列状态分成两种，在其中一种状态下波动率满足简单回归法，而另一种状态下波动率为白噪声序列。

除了随机游走模型和历史平均估计法，以上介绍的方法都涉及对数据窗口和权重的估计。基本上，估计方法就是在回溯数据上进行优化。更加成熟的方法，会持续的将新的观测值纳入用于参数估计的数据之中。

3.1.2 ARCH 类的条件波动率模型

更为复杂的时间序列模型有 ARCH 类模型，对此类模型有更为详细总结的文献有 Anil Bera, Matthew Higgins 1993, Bollerslev, Ray Chou, Kenneth Kroner (1992), Bollerslev, Engle, Nelson(1994)和 Diebold, Jose Lopez(1995)。与 3.1.1 中的模型不同，ARCH 类模型不需要波动率样本，而通过极大似然估计方法，来将回报率的条件方差 h_t 纳入模型范畴。而且，按照 ARCH 类模型的设定方法， h_t 在时刻 $t-1$ 即可知。所以向前一步的方差估计非常容易，而多步估计则可逐步获得。

第一个 ARCH 模型是 Engle 在 1982 年提出的 ARCH(q)模型，其中 h_t 是过去 q 个回报率的平方值的函数。而 Bollerslev 与 Taylor 在 1986 年提出的 GARCH (p, q) 模型则将 h_t 所依赖的历史数据推广至历史 h_t 。实证说明，GARCH 模型要比 ARCH 模型更简单有效，而 GARCH (1,1) 成为目前最流行的、用于刻画金融时间序列的模型。实际上，Riskmetrics 中所用的 EWMA 方法本质上是一个非稳定版本下的 GARCH (1,1) 模型，其中的 persistence 参数之和为 1，且四阶矩为 0。这类模型常常又被叫做 integrated model。尽管没有令人信服的理论依据，说明波动率应该满足这类模型，但是它们显示了在短期波动率预测方面的强大能力。

EGARCH 模型 (Nelson1991) 将条件方差设定为对数形式，这样我们就不需要再模型上加上条件，以避免小于零的波动率。若在该模型上加上合适的条件，我们刚好可以得到一种模型，使得它们能够抓住波动率的非对称特点，即：负回报率导致的条件方差要大于正回报率所导致的条件方差。其它能够抓住这种波动率的非对称特点的模型包括，TGARCH 模型 (Threshold GARCH)，GJR-GARCH 模型 (Lawrence Glosten, Ravi Jagannathan, David Runkle 1993)，QGARCH 模型 (quadratic GARCH 模型) 和其它各种非线性 GARCH 模型。请参见 Philip Franses 与 Dick van Dijk 于 2000 年发表的综述性文章。

ARCH 和 GARCH 模型都可在 James Hamilton (1989) 的 regime switch 框架下实现，在此框架下，波动率的保持性可以选取不同的参数，其依赖于当前的 regime 是处于高 regime 还是低 regime。最一般的 regime switch 模型是 Stephen Gray (1996) 和 Franc Klaassen (2002) 所研究的 RS-GARCH (1,1) 模型。

如前所述，许多时间序列模型都被设计成，可以模拟波动率的持续性的形式。GARCH 模型将条件方差的自相关性，模拟成指数速率衰减的形式。然而人们注意到，金融资产回报率的平方和绝对值序列的自相关性，衰减的速率要更加缓慢，其行为更像是 I(d)模型。波动率序列中的一个震荡有很长的记忆性，往往在很长时间内都会影响之后的波动率。Engle 与 Bollerslev (1986) 的 Integrated GARCH 模型 (IGARCH) 便是用来模拟这种效果的，但是在该模型下，波动率的震荡对未来的影响一直存在，并且它并不存在非条件方差。这促使了 FIGARCH(p,d,q) (Richard Baille, Bollerslev 与 Hans Mikkelsen 1996) 与 FIEGARCH (p, d, q) (Bollerslev, Mikeelsen1996) (d>0)模型的出现。在 d<0.5 的情况下，fractional integrated 模型的协方差是稳定的。然而，尽管理论上 Fractional integrated 模型被认为是一类非常好的波动率模型，但如 Soosung Hwang, Satchell(1998)与 Granger (2001)所指出的那样，正 I(d)过程隐含了波动率过程存在正的漂移项，或者说是时间趋势，这并不为实证结果所支持。这是该模型的最大弱点。

值得注意的是，除了 I(d)过程之外，有许多模型存在协方差的长记忆性。Granger 与 Namwon Hyung 在 2000 年提出的具有均值偶然破缺的短记忆稳定序列是其中之一。Diebold 和 Atsushi Inoue 在 2001 年发表的文章中，证明如果模型存在期只有很少的几次 regime switch 发生，stochastic regime switching 模型可以出现类似的长记忆性。另外，Gilles Zumbanch 在 2002 的文章中展示了如何利用 IGARCH (2) (即两个 IGARCH 模型的和) 来生成具有长记忆性的时间序列。

3.1.3 随机波动率模型

在随机波动率模型的框架下，波动率变化的驱动源与回报率变化的驱动源不同。按

照这种模拟方法，回报率序列自然存在肥尾效应。而波动率序列的自回归性使得它具有持续性，同时，波动率变化的驱动源与回报率变化的驱动源之间的相关性，使得波动率序列具有了非对称性。Andrew Harvey 在 1998 年进一步提出了所谓的长记忆性随机波动率模型，其要点在于将 fractional integrated order 引入了波动率过程。

但是随机波动率模型的复杂性，使得此类模型没有解析表达式，所以无法通过极大似然估计来估计参数。而其他的类解析方法，如 quasi-maximum likelihood 估计法（QMLE）的估计效率往往很低。因此，估计随机波动率模型的方法更多的是采用模拟的方法。

3.2 基于期权的波动率估计（未译，见本节开头注释，译者注）

信息披露

分析师声明

高道德、吴先兴、丁鲁明、郑雅斌、朱剑涛、冯佳睿：金融工程

以上分析师皆具有中国证券业协会授予的证券投资咨询执业资格，以勤勉的职业态度，独立、客观地出具本报告。本报告所采用的数据和信息均来自市场公开信息，本人不保证该等信息的准确性或完整性。分析逻辑基于作者的职业理解，清晰准确地反映了作者的研究观点，结论不受任何第三方的授意或影响，特此声明。

法律声明

本报告仅供海通证券股份有限公司（以下简称“本公司”）的客户使用。本公司不会因接收人收到本报告而视其为客户。在任何情况下，本报告中的信息或所表述的意见并不构成对任何人的投资建议。在任何情况下，本公司不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任。

本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的的价格、价值及投资收入可能会波动。在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。

市场有风险，投资需谨慎。本报告所载的信息、材料及结论只提供特定客户作参考，不构成投资建议，也没有考虑到个别客户特殊的投资目标、财务状况或需要。客户应考虑本报告中的任何意见或建议是否符合其特定状况。在法律许可的情况下，海通证券及其所属关联机构可能会持有报告中提到的公司所发行的证券并进行交易，还可能为这些公司提供投资银行服务或其他服务。

本报告仅向特定客户传送，未经海通证券研究所书面授权，本研究报告的任何部分均不得以任何方式制作任何形式的拷贝、复印件或复制品，或再次分发给任何其他人，或以任何侵犯本公司版权的其他方式使用。所有本报告中使用的商标、服务标记及标记均为本公司的商标、服务标记及标记。如欲引用或转载本文内容，务必联络海通证券研究所并获得许可，并需注明出处为海通证券研究所，且不得对本文进行有悖原意的引用和删改。

根据中国证监会核发的经营证券业务许可，海通证券股份有限公司的经营经营范围包括证券投资咨询业务。

海通证券股份有限公司研究所

李迅雷 副总裁/首席经济学家/所长
(021) 23219300
lxl@htsec.com

高道德 副所长
(021)63411586
gaodd@htsec.com

路颖 副所长
(021)23219403
luying@htsec.com

江孔亮 所长助理
(021)23219422
kljiang@htsec.com

宏观经济研究团队
姜超(021)23212042
陈勇(021)23219800
曹阳(021)23219981
高远(021)23219669

jc9001@htsec.com
cy8296@htsec.com
cy8666@htsec.com
gaoy@htsec.com

策略研究团队
荀玉根(021)23219658
陈瑞明(021)23219197
吴一萍(021)23219387
汤慧(021)23219733
王旭(021)23219396

xyg6052@htsec.com
chenrm@htsec.com
wuyiping@htsec.com
tangh@htsec.com
wx5937@htsec.com

金融产品研究团队
娄静(021)23219450
单开佳(021)23219448
倪韵婷(021)23219419
罗震(021)23219326
唐洋运(021)23219004
王广国(021)23219819
孙志远(021)23219443
陈亮(021)23219914
陈瑶(021)23219645
伍彦妮(021)23219774
联系人
桑柳玉(021)23219686
曾逸名(021)23219773
陈韵骋(021)23219444

loujing@htsec.com
shankj@htsec.com
niyt@htsec.com
luozh@htsec.com
tangyy@htsec.com
wgg6669@htsec.com
szy7856@htsec.com
cl7884@htsec.com
chenyao@htsec.com
wyn6254@htsec.com
sly6635@htsec.com
zym6586@htsec.com
cyc6613@htsec.com

联系人
周霞(021)23219807

zx6701@htsec.com

联系人
李珂(021)23219821

lk6604@htsec.com

金融工程研究团队
吴先兴(021)23219449
丁鲁明(021)23219068
郑雅斌(021)23219395
冯佳睿(021)23219732
朱剑涛(021)23219745
联系人
张欣慰(021)23219370

wuxx@htsec.com
dinglm@htsec.com
zhengyb@htsec.com
fengjr@htsec.com
zhuji@htsec.com

固定收益研究团队
姜超(021)23212042
姜金香(021)23219445
徐莹莹(021)23219885
李宁(021)23219431

jc9001@htsec.com
jiangjx@htsec.com
xyy7285@htsec.com
lin@htsec.com

政策研究团队
李明亮(021)23219434
陈久红(021)23219393
陈峥嵘(021)23219433
联系人
朱蕾(021)23219946

lml@htsec.com
chenjiuhong@htsec.com
zrchen@htsec.com
zl8316@htsec.com

联系人
周雨丹(021)23219760
杨勇(021)23219945

zxw6607@htsec.com
zyh6106@htsec.com
yy8314@htsec.com

联系人
倪玉娟(021)23219820

nyj6638@htsec.com

计算机行业
陈美凤(021)23219409
蒋科(021)23219474
联系人
安平永(021)23219950

chenmf@htsec.com
jiangk@htsec.com
ayp8320@htsec.com

煤炭行业
朱洪波(021)23219438

zhb6065@htsec.com

批发和零售贸易行业
路颖(021)23219403
潘鹤(021)23219423
汪立亭(021)23219399
联系人
李宏科(021)23219671

luying@htsec.com
panh@htsec.com
wanglt@htsec.com
lhk6064@htsec.com

建筑工程行业
赵健(021)23219472
联系人
张显宁(021)23219813

zhaoj@htsec.com
zxn6700@htsec.com

石油化工行业
邓勇(021)23219404
联系人
王晓林(021)23219812

dengyong@htsec.com
wxl6666@htsec.com

机械行业
龙华(021)23219411
何继红(021)23219674
熊哲颖(021)23219407
联系人
胡宇飞(021)23219810
黄威(021)23219963

longh@htsec.com
hejh@htsec.com
xzy5559@htsec.com
hyf6699@htsec.com
hw8478@htsec.com

农林牧渔行业
丁频(021)23219405
夏木(021)23219748

dingpin@htsec.com
xiam@htsec.com

纺织服装行业
联系人
杨艺娟(021)23219811

yyj7006@htsec.com

非银行金融行业
丁文韬(021)23219944
联系人
黄崑(021)23219638
吴绪越(021)23219947

dwt8223@htsec.com
hm6139@htsec.com
wxy8318@htsec.com

电子元器件行业
邱春城(021)23219413
张孝达(021)23219697
联系人
郑震湘(021)23219816

qiucc@htsec.com
zhangxd@htsec.com
zzx6787@htsec.com

互联网及传媒行业
刘佳宁(0755)82764281
白洋(021)23219646
联系人
薛婷婷(021)23219775

ljn8634@htsec.com
baiyang@htsec.com
xtt6218@htsec.com

交通运输行业
钮宇鸣(021)23219420
钱列飞(021)23219104
虞楠(021)23219382
联系人
李晨(021)23219817

ymniu@htsec.com
qianlf@htsec.com
yun@htsec.com
lc6668@htsec.com

汽车行业
赵晨曦(021)23219473
冯梓钦(021)23219402
联系人
陈鹏辉(021)23219814

zhaocx@htsec.com
fengzq@htsec.com
cph6819@htsec.com

食品饮料行业
赵勇(0755)82775282
联系人
马浩博(021)23219822

zhaoyong@htsec.com
mhb6614@htsec.com

钢铁行业
刘彦奇(021)23219391
联系人
任玲燕(021)23219406

liuyq@htsec.com
rly6568@htsec.com

医药行业
刘宇(021)23219608
联系人
刘杰(021)23219269
冯皓琪(021)23219709
郑琴(021)23219808

liuy4986@htsec.com
liuj5068@htsec.com
fhq5945@htsec.com
zq6670@htsec.com

有色金属行业
施毅(021)23219480
刘博(021)23219401
联系人
钟奇(021)23219962

sy8486@htsec.com
liub5226@htsec.com
zq8487@htsec.com

基础化工行业
曹小飞(021)23219267
联系人
张瑞(021)23219634
朱睿(021)23219957

caoxf@htsec.com
zr6056@htsec.com
zr8353@htsec.com

家电行业 陈子仪(021)23219244 孔维娜(021)23219223	chenzy@htsec.com kongwn@htsec.com	建筑建材行业 联系人 张光鑫(021)23219818	zgx7065@htsec.com	电力设备及新能源行业 张浩(021)23219383 牛品(021)23219390 房青(021)23219692 联系人 徐柏乔(021)23219171	zhangh@htsec.com np6307@htsec.com fangq@htsec.com xbq6583@htsec.com
公用事业 陆凤鸣(021)23219415 联系人 汤砚卿(021)23219768	lufm@htsec.com tyq6066@htsec.com	银行业 戴志锋 (0755)23617160 刘瑞 (021)23219635	dzf8134@htsec.com lr6185@htsec.com	社会服务业 林周勇(021)23219389	lzy6050@htsec.com
房地产业 涂力磊(021)23219747 谢盐(021)23219436 联系人 贾亚童(021)23219421	tll5535@htsec.com xiey@htsec.com jiayt@htsec.com	造纸轻工行业 徐琳 (021)23219767	xl6048@htsec.com	通信行业 联系人 侯云哲(021)23219815 宋伟(021)23219949	hyz6671@htsec.com s_w8317@htsec.com

海通证券股份有限公司机构业务部

陈苏勤 总经理
(021)63609993
chensq@htsec.com

贺振华 总经理助理
(021)23219381
hzh@htsec.com

深广地区销售团队

蔡铁清 (0755)82775962 ctq5979@htsec.com
刘晶晶 (0755)83255933 liujj4900@htsec.com
辜丽娟 (0755)83253022 gulj@htsec.com
高艳娟 (0755)83254133 ggyj6435@htsec.com
伏财勇 (0755)23607963 fcy7498@htsec.com
邓欣 (0755)23607962 dx7453@htsec.com

上海地区销售团队

高溱 (021)23219386 gaoqin@htsec.com
孙俊 (021)23219902 sunj@htsec.com
姜洋 (021)23219442 jy7911@htsec.com
季唯佳 (021)23219384 jiwj@htsec.com
胡雪梅 (021)23219385 huxm@htsec.com
黄毓 (021)23219410 huangyu@htsec.com
朱健 (021)23219592 zhuj@htsec.com
黄慧 (021)23212071 hh9071@htsec.com
王丛丛 (021)23219454 wcc6132@htsec.com
卢倩 (021)23219373 lq7843@htsec.com
孙明 (021)23219990 sm8476@htsec.com
孟德伟 (021)23219989 mdw8578@htsec.com

北京地区销售团队

赵春 (010)58067977 zc8614@htsec.com
郭文君 (010)58067996 gwj8014@htsec.com
隋巍 (010)58067944 sw7437@htsec.com
张广宇 (010)58067931 zgy5863@htsec.com
王秦豫 (010)58067930 wqy6308@htsec.com
江虹 (010)58067988 jh8662@htsec.com
杨帅 (010)58067929 ys8979@htsec.com
张楠 (010)58067935 zn7461@htsec.com

海通证券股份有限公司研究所

地址: 上海市黄浦区广东路 689 号海通证券大厦 13 楼
电话: (021)23219000
传真: (021)23219392
网址: www.htsec.com