



金工基金研究

证券研究报告
量化研究

2013 年 12 月 09 日

他山之石（2013 年 12 月）

相关研究

他山之石系列一	2012.08.15
他山之石系列二	2012.09.13
他山之石系列三	2012.11.05
他山之石系列四	2012.12.07
他山之石系列五	2013.01.21
他山之石系列六	2013.02.26
他山之石系列七	2013.04.26
他山之石系列八	2013.04.26
他山之石系列九	2013.05.23
他山之石系列十	2013.07.02
他山之石系列十一	2013.07.26
他山之石系列十二	2013.08.28
他山之石系列十三	2013.10.09
他山之石系列十四	2013.11.12

总编：高道德
SAC 执业证书编号：
S0850511010035
电话：021-23219569
Email: gaodd@htsec.com

丁鲁明
SAC 执业证书编号：
S0850511010033
电话：021-23219068
Email: dinglm@htsec.com

郑雅斌
SAC 执业证书编号：
S0850511040004
电话：021-23219395
Email: zhengyb@htsec.com

朱剑涛
SAC 执业证书编号：
S0850512100002
电话：021-23219745
Email: zhujt@htsec.com

冯佳睿
SAC 执业证书编号：
S0850512080006
电话：021-23219732
Email: fengjr@htsec.com

杨勇
SAC 执业证书编号：
S0850512080006
电话：021-23219945
Email: yy8314@htsec.com

张欣慰
SAC 执业证书编号：
S0850513070005
电话：021-23219370
Email: zwx6607@htsec.com

注意力分散效应——干扰信息如何导致超预期在股价上反应不足

推荐理由：本文针对业绩超预期这一事件，结合干扰信息，从比较独特的角度分析投资者的注意力对于超预期股票表现的影响。文章从多个角度剖析了当投资者同时处理多个信息时，由于其注意力被分散，往往会导致其对信息的处理不够充分。由此，很多信息并不如大家预想的在有效市场的表现那样，立刻就会反映完毕，而是会延迟一段时间体现，造成股价漂移现象。而这种现象，恰恰构成了一定的投资机会。

金融冲击的实际影响：来自分析师覆盖数量变化的证据

推荐理由：本文主要研究了券商分析师覆盖与否对于上市公司的投融资决策的影响。我们假设一个公司如果减少了分析师覆盖，则会增加信息不对称性从而增加资本成本，从而公司会减少其对外投资和融资。通过实证发现，公司减少一个分析师覆盖确实会使得其对外投资资产占比减少 1.9%，融资资产占比减 2.0%。文章第一次创新性的证实了分析师覆盖的改变确实对公司决策政策会产生影响，从而有助于学界进一步分析其他金融冲击对市场的影响。

基于递归决策树的投资组合选择

推荐理由：这篇论文创新之处是提出了一种递归的决策回归数模型，同传统的决策回归树模型的差异主要在于决策树的修建采用了递归的模式，将这种决策树方法用来选择股票。文章采用了一系列基本面和技术变量，来判断当前公司的市场价值被低估、高估或者被正确定价。观察期内模型的表现表明德国 XETRA DAX 股票收益能够充分被公开可得的经济数据所预测。本研究的另一个结论是，当隐含波动率被引入训练样本时，有效提高了模型的预测能力。

基于价格低频信号的外汇动量交易策略

推荐理由：用经典技术指标进行交易获得的收益常不稳定，主要原因是价格数据序列里的高频信号干扰了指标的识别能力，作者在本文中为我们提供了两种方法来提取价格数据中的低频信号，并基于此设计交易策略，效果提升明显。

利用 MACD 柱状图的头肩形态来预测市场方向

推荐理由：本文主要关注 MACD 头肩形态的识别和交易，并针对这一形态的交易结果做统计分析。作者首先定义了 MACD 柱状图的头肩形态，并对该形态进行分类，然后介绍了如何在该形态完全形成之前进行有效识别。作者发现该形态的形成对未来市场走向有明显的预测作用，并在此基础上提出了基于 MACD 形态识别的交易规则。统计结果表明：该方法的胜率为 81%，盈亏比则高达 4.4，平均持有时间为 8 天，是一个较好的中短期择时交易策略。

过往 52 周最高价的出现时间与动量效应

推荐理由：本文基于过往 52 周最高价的出现时间提出了一个新的动量策略。实证发现，那些于近期达到 52 周最高价的个股在未来的表现明显地优于那些最高价出现在很久之前的股票。特别地，如果根据 52 周最高价的出现时间距当前的远近程度排序，最近的 10% 所形成组合的收益平均每个月超越最远的 10% 组合 0.70%。进一步研究表明，加入过往 52 周最高价发生时间的分类条件后，有效提升了以当前价格和最高价接近程度为基础的动量策略的收益表现。尤其值得注意的是，当该策略应用于最近达到 52 周最高价的股票时，产生的平均月度收益大约是那些很久没有创新高的股票的 2 倍。

聚类方法在组合构建中的应用

推荐理由：均值一方差模型在组合构建中被广泛运用，实际操作中常用重抽样和贝叶斯方法来降低估计误差对组合权重的影响。众所周知，估计股票间的相关性比估计期望收益要简单的多，本文用聚类法来改进均值一方差模型，更多的利用了协方差矩阵的信息而淡化了预期收益的信息，优化后组合的稳定性和表现都得到了提高。

连续竞价和内幕交易

推荐理由：Klue 模型和 Glosten 与 Milgrom 模型是市场微观结构研究的两大开山模型。尽管这两篇文章时代比较久远，但这两大模型从不同角度第一次对 informed trader 和 uninformed trader 在市场上的交易行为给出了数学化的描述，同时对这些交易行为所对应的市场特性给出了论证，是后来类似文章的思想源泉。GM 模型利用市价单为泊松分布过程，和做市商挂买卖单的假设，给出了一个真实市场的近似描述。相对于 GM 模型而言，Klue 模型重点研究了由一个内幕交易者、一群噪音交易者和做市商构成的 batch-auction 类型的市场。这里内幕信息可以是将要披露的信息，也可以是交易者自身对市场变化的判断。所谓 batch-auction 市场，意思是说做市商并不事先挂单，而是由市价单的寻求方报单，将报单量和报单方向轧差整合后，由做市商在不以盈利为目的（因为他们之间存在充分竞争关系）的情况下给出一个合理价格。因此，我们可以看出 Klue 模型的假设与通常的市场规则并不相符。但受纳什均衡理论影响极深的八十年代，Klue 通过均衡理论的论证方式，给出了在一个均衡态的情况下，内幕交易者的最优报单方法和做市商的报价准则。

进阶大类资产配置方法

推荐理由：伴随着中国经济在全球产业链分工中的占比不断提升，中国经济与全球经济波动特征逐渐接近，这一特征在全球股市波动方面有着尤其重要的特征体现。在进行国内股市整体波动因素分析时，海外因素已经成为投资者不可或缺的重要考量，我们有必要从全球证券视角出发，了解海外全球大类资产配置的一些方法。本文从全球大类资产的指数表现为基础，试图寻找各类资产背后真正的独立影响因素，并以此为基础构

目 录

注意力分散效应——干扰信息如何导致超预期在股价上反应不足	3
金融冲击的实际影响：来自分析师覆盖数量变化的证据	8
基于递归决策树的投资组合选择	14
基于价格低频信号的外汇动量交易策略（2）	22
利用 MACD 柱状图的头肩形态来预测市场方向	27
过往 52 周最高价的出现时间与动量效应	33
聚类方法在组合构建中的应用	44
连续竞价和内幕交易	53
进阶大类资产配置方法	57

注意力分散效应——干扰信息如何导致超预期在股价上反应不足

原文：David Hirshleifer, Sonya Seongyeon Lim, Siew Hong Teoh, the journal of finance, volume 64, issue 5, pages 2289-2325, October 2009.

推荐人：郑雅斌 021-23219395

推荐理由：本文针对业绩超预期这一事件，结合干扰信息，从比较独特的角度分析投资者的注意力对于超预期股票表现的影响。文章从多个角度剖析了当投资者同时处理多个信息时，由于其注意力被分散，往往会导致其对信息的处理不够充分。由此，很多信息并不如大家预想的在有效市场的表现那样，立刻就会反映完毕，而是会延迟一段时间体现，造成股价漂移现象。而这种现象，恰恰构成了一定的投资机会。

一、引言

很多心理学研究已经验证了人们在同时处理多条信息时，往往可能由于“内存不足”出现注意力不够、忽视一些信息的现象。我们认为这在金融市场上也存在。如果说投资者在同一时刻接收过多信息，很可能对多数信息都反应不足。针对上市公司公布财报这个事件，对于很多业绩超预期的公司，当天如果很多公告同时发布，投资者短期内对于财报的内容往往反应较弱，但在随后的时间内，其对于财报内容的反应会逐渐反应出来，产生价格漂移现象。

二、注意力分散的心理学基础

很多心理学家已经验证了人们在同一时间处理多个任务时，往往很难同时分析多个信息。案例一：当把“蓝色”这个单词打印成红色，然后让人读出这个字到底代表什么颜色时，人的反应都会较慢；案例二：在一个人的左右耳分别传送不同的信息，并要求他重复其中一只耳朵听到的信息，然后会发现，这个人基本上对另一只耳朵听到的信息没有什么印象。

在金融市场上，当投资者希望预测一家公司的未来盈利状况时，他可能需要面临非常多同时公布的信息，在这种时候注意力被分散后，投资者往往就很难对公布的信息给出正确的或者是合适的反应。

三、数据来源

我们采用 CRSP-Compustat 以及 IBES 从 1995 年至 2004 年的数据，计算上市公司每天发布的季报数量。盈利超预期（预测误差 FE :forecast error）的计算方式为：采用分析师最近 60 个交易日有预测的数据，选取市场上分析师盈利预测的中位数，将这个数据与财报中的真实盈利相减。我们剔除盈利预测高过股价的数据，同时剔除股价小于 1 元的股票。所有的预测误差都需要通过股价进行标准化：

$$FE = (\text{真实盈利} - \text{预测盈利}) / \text{上个财季结束时的股价}$$

我们在研究中需要计算两种时间窗口的收益数据，一个是财报发布当天短期对股价的影响，一个是发布后较长时间窗口下的收益影响（即财报公布后的股价漂移效应）。两个时间窗口的定义方式分别为：【0,1】，【2,61】。第二个窗口选择 60 个交易日的原因，是已经有研究证明盈利公布后的股价漂移多数发生在 60 个交易日以内。计算超额收益的方式，为股票累计收益-基准累计收益。

我们将市场按照市值、市净率这两个指标划分为 5X5 的组合，总共 25 个组合代表

不同风格的基准组合。每只股票寻找其匹配的风格组合作为基准。

四、竞争性新闻对于财报公布日的收益、交易量以及财报公布后的价格漂移影响

我们有以下三个假设：

- 1、超额收益对于盈利超预期的敏感性随着竞争性新闻数量的增多会有所下降。
- 2、财报当日的交易量随着竞争性新闻的增多会下降。
- 3、财报公布后，超额收益的敏感性随着竞争性新闻的增多会有所提升。

1 中和 3 的方向不一致，主要是考察窗口的不一致导致，1 考察公布当下的收益，3 考察公布后的收益。

我们这里所说的竞争性新闻，指的是当日公布的具有竞争性的其他家上市公司的财务报表。

我们按照盈利超预期的数据将公司分为 10 档，再按照当日公布的财报总数量分为 10 档，总共有 10X10，100 个组合。统计每个组合其在财报公布期【0,1】窗口以及公布后【2,61】窗口的超额收益。我们主要观察 FE10（即预计预测正向超预期最大幅度的组合）以及 FE1（业绩负向超预期最大幅度组合）的收益差。这个收益差越大，说明投资者的反应越剧烈，收益差越小，说明投资者的注意力被分散，其对消息的反应越小。

表 1 中的 CAR 代表累计超额收益，1-10 个分类组合，分别代表财报低峰期（low-news days）以及财报高峰期（high-news days）。我们看到，在【0,1】窗口上，FE10 以及 FE1 的收益差，明显在财报低峰期比较高，说明财报较少的时间段上投资者对于盈利超预期的反应更为敏感。而在【2,61】的窗口上，FE10 以及 FE1 的收益差方向相反，财报公布后的较长时间中，如果财报公布数量处于高峰期，那么投资前期超预期的股票相对投资前期低于预期的股票，超额收益可达 4.6%。这说明在高峰期公布当下，投资者的注意力被分散，无法立刻给与盈利超预期的财报内容股价上的反应，只能在后续的一定时间内逐步反应完毕。（所有的结果均通过统计显著检验）

这些结论与我们前期的假设一致，因为如果是在有效的市场中，所有投资者均能够迅速对获取信息给出反应，那么超额收益应该集中在【0,1】窗口中反应完毕，在随后的时间中不应出现价格漂移现象。

表 1 累计超额收益统计

NRANK	Average CAR[0,1] for Earnings surprise deciles 10 and 1			Average CAR[2,61] for Earnings surprise deciles 10 and 1		
	FE1	FE10	FE10-FE1	FE1	FE10	FE10-FE1
1 (low-news days)	-3.27%	3.81%	7.07%**	-0.99%	1.82%	2.81%
2	-3.31%	3.45%	6.76%**	-1.67%	3.10%	4.77%**
3	-3.22%	3.52%	6.74%**	-2.09%	2.09%	4.18%**
4	-3.54%	2.50%	6.04%**	-4.79%	3.25%	8.04%**
5	-3.37%	2.22%	5.59%**	-2.19%	2.24%	4.43%**
6	-3.17%	3.16%	6.33%**	0.96%	4.17%	3.21%
7	-3.67%	2.82%	6.49%**	-3.32%	2.32%	5.64%**
8	-3.45%	2.79%	6.24%**	-2.68%	6.30%	8.98%**
9	-3.49%	2.83%	6.32%**	-1.21%	4.16%	5.37%**
10 (high-news days)	-3.06%	2.61%	5.67%**	-2.97%	4.44%	7.41%**
Difference (10-1)	0.20%	-1.20%**	-1.40%*	-1.98%	2.62%	4.60%*

资料来源：Driven to distraction: Extraneous events and underreaction to earnings news

注：*代表显著性水平在 5%，**代表显著性水平在 1%

五、回归分析

本章节我们通过控制股票的市值、市净率等其他因素，分析我们所得到的结论是否是这些因素影响导致的，以此进一步验证我们的假设。

除了盈利超预期的排名（FE），公告数量的排名（NRANK），我们加入变量：

市值、市净率、分析师数量、财报公布延迟期（LAG）、机构持股（IO）、日期变量进行回归分析。

$$CAR = a_0 + a_1 FE + a_2 NRANK + a_3 (FE \times NRANK) + \sum_{i=1}^n c_i X_i + \sum_{i=1}^n b_i (FE \times X_i) + \varepsilon.$$

结果发现，对于 FE、NRANK 的系数均显著。

1、正向、负向业绩超预期

我们对于正、负向业绩超预期标的分别统计。发现对于正向超预期，投资者短期内的反应对公告数量更为敏感，即公告数量导致的注意力分散作用在正向公告中更为明显。参考表 2 中的 FEXNRANK 系数。对于正向业绩超预期，公告数量越多、超预期越多，其短期内的反应不足，超额收益与 FEXNRANK 的系数应该为负，[0,1]区间系数确实为负，而[2,61]区间系数为正，说明投资者只是短期内对于正向超预期反应不足。而负向消息，其[2,61]区间的系数并没有通过 5% 的显著性检验，说明长期来看公告数量对负向消息并没有太大注意力分散的影响。

表 2 正、负向预计超预期对于公告数量的敏感性

	Positive Earnings Surprises			Negative Earnings Surprises		
	CAR[0,1]	CAR[2,61]	CAR[0,61]	CAR[0,1]	CAR[2,61]	CAR[0,61]
FE	1.475*** (0.178)	0.957 (0.634)	2.582*** (0.694)	0.538** (0.257)	-1.133 (0.819)	-0.277 (0.834)
NRANK	0.032 (0.039)	-0.345** (0.135)	-0.292** (0.147)	-0.005 (0.067)	-0.593*** (0.224)	-0.526** (0.233)
FE×NRANK	-0.039*** (0.013)	0.120** (0.049)	0.074 (0.055)	0.015 (0.018)	0.156*** (0.059)	0.153** (0.061)
Controls, interacted with FE	X	X	X	X	X	X
Constant	-2.401*** (0.532)	-0.528 (1.921)	-3.173 (2.055)	-5.224*** (0.955)	-1.581 (3.146)	-7.779** (3.187)
# Observations	64,231	63,643	63,643	36,584	36,064	36,064
R-squared	2.0%	1.1%	1.7%	2.0%	1.6%	1.5%

资料来源：Driven to distraction: Extraneous events and underreaction to earnings news

注：*代表显著性水平在 10%，**代表显著性水平在 5%，***代表显著性水平在 1%

2、注意力分散对成交量的影响

我们仅分析异常交易量在公告公布时的变动，定义方法为，将第 J 日的交易量，减去公告之前【-41，-11】这段时间的 log 交易量的平均。

$$VOL[j] = \log(DollarVol_{t+j} + 1) - \frac{1}{30} \sum_{k=-41}^{t-11} \log(DollarVol_k + 1).$$

我们主要观察 vol(0)和 vol(1)即公布日当天、公布后第一天异常交易量的变化。分别将交易量针对业绩超预期的绝对值（AFE）、NRANK、FE 的排序、市场交易量（MKTVOL、MKTVOL2）指标进行回归。各类回归都发现 NRANK 的系数均为负，且在 1%置信水平内显著。说明：在公告日的高峰阶段，异常交易量相对而言会由于注意力分散而有所减少。

表 3 正、负向预计超预期对于公告数量的敏感性

	(1)	(2)	(3)	(4)	(5)	(6)
	VOL[0]	VOL[0]	VOL[0]	VOL[0,1]	VOL[0,1]	VOL[0,1]
AFE	0.031*** (0.002)	0.031*** (0.002)		0.030*** (0.001)	0.029*** (0.001)	
NRANK	-0.022*** (0.002)	-0.028*** (0.003)	-0.028*** (0.003)	-0.022*** (0.002)	-0.029*** (0.002)	-0.029*** (0.002)
Dummy variables for FE deciles			X			X
MKTVOL		0.779*** (0.044)	0.781*** (0.043)			
MKTVOL2					0.818*** (0.046)	0.820*** (0.046)
Controls		X	X		X	X
Constant	0.470*** (0.016)	0.634*** (0.036)	0.686*** (0.038)	0.530*** (0.014)	0.718*** (0.032)	0.794*** (0.034)
# Observations	117,640	117,640	117,640	117,640	117,640	117,640
R-squared	0.7%	3.0%	3.0%	1.0%	4.2%	4.4%

资料来源：Driven to distraction: Extraneous events and underreaction to earnings news

注：*代表显著性水平在 10%，**代表显著性水平在 5%，***代表显著性水平在 1%

六、组合交易策略的构建

我们利用业绩超预期以及公告数量这两条信息来构建交易型策略，检验是否能够获利。将市场按照超预期、公告数量两个变量划分为 5X5 的组合，计算每个组合的平均收益。每个月，观察过去三个月中发布的业绩超预期公告，之后构建组合持有一个月时间。通过 Fama-French 模型回归计算组合 alpha。

如果我们仅在高峰日的股票中构建组合 (NRANK5), FE5-FE1 组合的 alpha 差高达 1.64%，结果在 1% 置信水平上显著。如果在公告低峰日操作，则 alpha 差仅有 0.77%。从表 4 中的具体数据我们都可以得到如下结论：参考了公告日当天的消息数量，再对业绩超预期事件进行参与，选择公告当天会产生注意力分散的时刻，那么在随后价格漂移过程中能够获利的空间会有显著放大。

表 4 组合 alpha 统计

	Earnings Surprise Quintile					FE5-FE1 (Good - Bad)
	FE=1 (Bad news)	2	3	4	FE=5 (Good news)	
All	-0.57 (0.36)	-0.53*** (0.20)	-0.12 (0.14)	0.04 (0.14)	0.75*** (0.26)	1.32*** (0.26)
NRANK 1	-0.21% (0.42)	-0.53** (0.22)	-0.17 (0.21)	0.04 (0.21)	0.56** (0.24)	0.77 (0.47)
2	-1.10*** (0.37)	-0.56** (0.24)	-0.04 (0.21)	-0.23 (0.18)	0.45 (0.28)	1.55*** (0.26)
3	-0.51 (0.43)	-0.61*** (0.23)	0.02 (0.17)	-0.02 (0.15)	0.70** (0.30)	1.22*** (0.37)
4	-0.16 (0.50)	-0.56** (0.25)	-0.26 (0.16)	0.32 (0.20)	0.94*** (0.34)	1.09*** (0.40)
NRANK 5	-0.60* (0.34)	-0.44*** (0.17)	-0.15 (0.14)	0.06 (0.17)	1.04*** (0.34)	1.64*** (0.31)
NRANK5	-0.38 (0.33)	0.09 (0.16)	0.03 (0.20)	0.02 (0.21)	0.48 (0.24)	0.86 (0.47)
- NRANK1						

资料来源：Driven to distraction: Extraneous events and underreaction to earnings news

注：*代表显著性水平在 10%，**代表显著性水平在 5%，***代表显著性水平在 1%

七、相关与不相关的信息

在前面的研究中，我们不对产生干扰的信息进行分类，但是不同类型的信息影响应该不一样。比如，google 披露财报后有大幅超预期，投资者很有可能将注意力投注在其他可能大幅超预期的互联网公司上。我们将消息分为同一个行业的、不同行业的两大类信息，认为一种是和观察标的相关的，一种是不相关的。为了避免有些行业的公告数量相对比较多，我们在每一个行业中，采用相关信息 (NrelRank)、不相关信息 (NunrelRank)

的数量排序作为回归变量。主要观察 FEXNrelRank，以及 FEXNunrelRank 项的系数。

两个系数均为负，说明消息的数量均有一定分散注意力的影响。但是从 $car[0,1]$ ， $car[2,61]$ 的系数看到，不相关消息的系数均大于相关消息的系数，且结果通过显著性检验。说明：不相关的信息，在短期内其分散注意力的作用更为明显，长期来看，会加大价格漂移现象的幅度（即增大后期可能的获利空间）。

表 5 相关、不相关信息的处理

	(1)	(2)	(3)	(4)	(5)	(6)
	CAR[0,1]	CAR[0,1]	CAR[0,1]	CAR[2,61]	CAR[2,61]	CAR[2,61]
FE	0.976*** (0.075)	1.019*** (0.079)	1.022*** (0.079)	0.907*** (0.252)	0.741*** (0.271)	0.748*** (0.270)
NrelRank	0.063** (0.032)		0.010 (0.039)	-0.244** (0.105)		-0.044 (0.141)
FE×NrelRank	-0.015*** (0.005)		-0.004 (0.006)	0.026 (0.017)		-0.011 (0.022)
NunrelRank		0.092** (0.036)	0.084* (0.046)		-0.355*** (0.123)	-0.321* (0.165)
FE×NunrelRank		-0.021*** (0.006)	-0.018** (0.007)		0.052** (0.021)	0.061** (0.028)
Controls, interacted with FE	X	X	X	X	X	X
Constant	-5.941*** (0.470)	-6.154*** (0.492)	-6.163*** (0.493)	-5.765*** (1.658)	-4.939*** (1.761)	-4.921*** (1.760)
Observations	92,685	92,685	92,685	91,737	91,737	91,737
R-squared	5.7%	5.7%	5.7%	1.1%	1.1%	1.1%

资料来源：Driven to distraction: Extraneous events and underreaction to earnings news

注：*代表显著性水平在 10%，**代表显著性水平在 5%，***代表显著性水平在 1%

八、总结

我们认为，当大量的财报在同一天公布，那么投资者对于当天的业绩超预期公司反映往往是不足的，因为其注意力被分散，这表现在短期的股价表现以及短期的成交量上。当然，这种短期的注意力分散，会在随后的时间上被弥补，由此产生一个较长时间窗口的价格漂移现象。基于此现象构建的投资策略在公告高峰日选股后，确实能够获利。并且我们发现，相关消息的干扰对投资者影响并不大，不相关消息的干扰造成的分散现象更为明显。

金融冲击的实际影响：来自分析师覆盖数量变化的证据

原文：FRANCOIS DERRIEN and AMBRUS KECSKES, THE JOURNAL OF FINANCE • VOL. LXVIII, NO. 4 • AUGUST 2013 P1407-1440

推荐人：纪锡靛 021-23219948

推荐理由：本文主要研究了券商分析师覆盖与否对于上市公司的投融资决策的影响。我们假设一个公司如果减少了分析师覆盖，则会增加信息不对称性从而增加资本成本，从而公司会减少其对外投资和融资。通过实证发现，公司减少一个分析师覆盖确实会使得其对外投资资产占比减少 1.9%，融资资产占比减 2.0%。文章第一次创新性的证实了分析师覆盖的改变确实对公司决策政策会产生影响，从而有助于学界进一步分析其他金融冲击对市场的影响。

【摘要】

本文主要针对一个特殊的金融冲击——分析师覆盖的减少进行研究，检验其对上市公司的投融资政策的影响。包括券商倒闭和合并在内都会引起分析师终止覆盖。我们假设一个公司一旦减少了分析师对其的覆盖研究会增加市场对其的信息不对称，增加了公司的资本成本，从而引起公司的盈利能力下降，最后导致其投资项目急剧减少。同样的，由于公司的外部融资成本无论是在绝对数上和相对数上都受到内部融资成本的影响，因此分析师覆盖的减少最终也会导致公司的外部融资减少。

由于本文关注的是外生因素带来的冲击，因此我们主要研究的是由券商倒闭和合并引起的分析师覆盖的减少，文章统计了 1994-2008 年的情况，一共有 52 家券商倒闭和合并，导致 1724 家公司减少了分析师覆盖。

我们发现，随着分析师覆盖的减少，1、公司股价会发生显著性的下降（我们观察的公司相比其他公司在两个月的观察期内其股价要低 1.05%）；2、公司减少一个分析师覆盖确实会使得其对外投资资产占比减少 1.9%，融资资产占比减少 2.0%，资本开支下降 0.67%，研发支出下降 0.21%，收购支出下降 0.97%。同样，还会分别减少债务和股票发行 1.07%、0.90%，同时公司现金流量占总资产占比也会减少 1.1%；3、本文研究还发现，当分析师成本越高的时候，分析师覆盖减少对公司的冲击越显著：对于较少分析师覆盖的小公司，减少分析师覆盖信息不对称会更严重从而有更大的影响。

另外本文的结论还需要一个重要的前提成立，即分析师的研究确实能够对投资者和公司有所贡献和影响。为了验证这个前提，文章通过对分析师的研究质量（准确性和一致性）进行分析，证实分析师的研究平均水平还是有一定影响力的。

一、数据和样本

本文进行两个维度的比较，一个是在同一时间比对有分析师覆盖和没有分析师覆盖的同类型公司，一个是比对同一家公司在分析师覆盖前后的变化。


本文统计了 1994-2008 年之间券商消失的情况，且进行对比取的时间窗口为三个月，即对比分析师覆盖减少的三个月前后的差别。我们定义分析师覆盖此公司需要满足分析师对其进行盈利预测满一年以上，同时为了保证数据的完整性，文章剔除了在上市日期与分析师覆盖减少日期距离一年之内的相关数据。

为了与观察的公司进行横向比较，文章选取了与其在行业、财务数据等方面一致的公司为其比对公司。具体要求为：与观察的公司必须同行业，资产现金流在行业五分位数同样排名的，且要求其满足两个公司覆盖的分析师数量基本一致，同时将观察公

司的总资产现金流与前一步所选的公司进行比对排名，取综合排名差距最小的那个公司最后为比对公司。总而言之，我们所取的比对公司要在行业上，资产和现金流和分析师覆盖情况与观察公司最接近。

本文的分析师数据取自 I/B/E/S，股票交易数据取自 CRSP，财务数据取自 COMPUSTAT，债务及股权发行数据来自 SDC。

图 1 券商和分析师覆盖公司减少的分布图



资料来源：THE JOURNAL OF FINANCE

上图为券商和分析师覆盖公司减少的分布图，从图中可知券商在 2000-2001 年急剧减少，而在 1995-1996 没有变化，而出现分析师减少覆盖的公司主要出现在 2000-2002 年，另外从数量上也可知，少数的券商变化引起了大量公司减少分析师覆盖。

由于我们取的观察公司与比对公司之间只有分析师覆盖有所不同，因此通过比较两者的情况就能够获取分析师覆盖减少引起的变化信息。本文通过以下一组变量描述公司的财政决策：投资情况（资本、研发费用，并购支出）、融资情况（债务股本发行情况包括短期和长期）、分红情况、现金流量。

我们还研究了在分析师覆盖急剧减少的时点前后其公司股票收益率是否有变化，发现在 2 个月的窗口期内，相对比对公司来说我们观察的公司股价下降了 1.05%（T 值为 -1.73）。

同时我们还对比了一下观察公司和比对公司的情况，包括行业，分析师覆盖数量，资本，现金流等。

图 2 描述性统计分析（1）

	25 th Percentile		Median		75 th Percentile		p-value of Test of Equality of Medians	p-value of Test of Equality of Distributions
	Treatment Firms	Control Firms	Treatment Firms	Control Firms	Treatment Firms	Control Firms		
Matching variables								
Total assets (\$M)	588	586	2,329	2,246	9,016	7,867	0.658	0.554
Q	1.28	1.32	1.81	1.88	2.94	3.06	0.143	0.217
Cash flow	4.82%	5.36%	9.28%	9.74%	14.17%	14.86%	0.143	0.118
Number of analysts	11.0	10.0	18.0	18.0	24.0	25.0	0.918	0.583
Investment variables								
Capital expenditures	2.60%	2.47%	4.82%	4.65%	8.50%	8.23%	0.261	0.372
Research and development exp.'s	0.00%	0.00%	0.23%	0.18%	5.78%	5.29%	0.812	0.699
Acquisitions expenditures	0.00%	0.00%	0.00%	0.04%	2.14%	2.22%	0.261	0.670
Total investment	6.13%	6.16%	10.52%	10.18%	17.33%	16.88%	0.433	0.670
Financing variables								
Change in short-term debt	0.00%	0.00%	0.00%	0.00%	0.00%	0.00%	0.927	0.974
Change in long-term debt	-1.05%	-0.98%	0.00%	0.00%	3.21%	3.25%	0.781	0.641
Equity issuance	0.19%	0.22%	0.77%	0.81%	2.28%	2.29%	0.433	0.350
Total financing	-0.20%	-0.15%	2.14%	2.10%	6.54%	7.15%	0.759	0.860

资料来源：THE JOURNAL OF FINANCE

图 3 描述性统计分析（2）

Table I—Continued

	25 th Percentile		Median		75 th Percentile		p-value of Test of Equality of Medians	p-value of Test of Equality of Distributions
	Treatment Firms	Control Firms	Treatment Firms	Control Firms	Treatment Firms	Control Firms		
Payout variables								
Dividends	0.00%	0.00%	0.00%	0.00%	1.35%	1.36%	0.340	0.810
Share repurchases	0.00%	0.00%	0.14%	0.08%	3.14%	3.17%	0.233	0.670
Total payouts	0.00%	0.00%	1.23%	1.15%	5.28%	5.05%	0.586	0.836
Change in cash holdings	-1.10%	-0.84%	0.15%	0.26%	2.35%	2.66%	0.610	0.117
Analysts' expectations variables								
Earnings estimates	2.6%	2.7%	4.9%	4.8%	7.1%	6.8%	0.584	0.203
Investment recommendations	3.5	3.5	3.8	3.9	4.2	4.2	0.185	0.181
Long-term earnings growth rate est.'s	11.4%	12.1%	15.3%	16.1%	22.9%	23.0%	0.028	0.015
Price targets	12.3%	11.1%	29.6%	24.2%	60.6%	50.3%	0.001	0.000

资料来源：THE JOURNAL OF FINANCE

通过以上比对可知，我们选择的两个样本组在其他方面，特别是影响财政决策的其他方面都很类似，唯一不同的就是分析师覆盖数量，因此为下一步证明分析师数量减少影响公司财政决策的结论先提供了一个前提条件。

二、主要结论

1、分析师覆盖减少的影响

首先我们先计算公司财务决策变量在-1 到 1 年度的平均变化值，最后衡量出观察的公司和比对的公司的差值。


图4 分析师覆盖的减少对公司财务决策指标的影响

	Mean Treatment Difference (Year +1 vs. Year -1)	Mean Control Difference (Year +1 vs. Year -1)	Mean of Diff-in-Diffs (Treatments vs. Controls)	t-statistic for Difference-in- Differences
Investment				
Capital expenditures	-0.01%	0.62%	-0.67%***	-4.73
Research and dev. exp.'s	0.40%	0.60%	-0.21%***	-2.27
Acquisitions expenditures	0.09%	1.11%	-0.97%***	-3.36
Total investment	0.41%	2.41%	-1.92%***	-5.18
Financing				
Change in short-term debt	0.06%	0.06%	0.00%	0.02
Change in long-term debt	-0.17%	0.97%	-1.07%***	-2.79
Equity issuance	-1.13%	-0.10%	-0.90%***	-2.88
Total financing	-1.34%	0.89%	-2.02%***	-4.00
Payouts				
Dividends	0.10%	0.12%	-0.02%	-1.12
Share repurchases	0.15%	0.08%	0.08%	0.48
Total payouts	0.30%	0.23%	0.11%	0.61
Change in cash holdings	-0.06%	1.03%	-1.12%***	-2.62

资料来源：THE JOURNAL OF FINANCE

从上表格可知，各个财务指标均显著，资本支出下降了0.67%，研发支出下降0.21%，并购支出下降0.97%，整体投资下降了1.92%，从融资指标总体来看显著下降2.02%，其中长期债务融资下降了1.07%，股权融资下降了0.90%，而对短期债务融资影响并不显著；另外分红指标并未有显著影响；最后来看现金流指标显著的下落了1.12%。

图5 观察公司与对比公司的比较



资料来源：THE JOURNAL OF FINANCE

本文还验证了更长的窗口期内减少分析师覆盖对公司的影响，取三年为限，我们发现几个指标都是在分析师覆盖减少的时点前后一年的时候变化剧烈，同时分红指标相对其他指标来说受到的影响要小的多，这跟我们之前得到的结论保持了一致。

2、分析师覆盖减少受到公司市值规模和分析师覆盖数量的影响程度分析

接下来文章检验了分析师覆盖减少对公司的影响程度是否受到其他因素的影响。我们发现一个较少分析师覆盖的公司相对于较多分析师覆盖的大公司来说，分析师覆盖减少的机会成本要大的多，受到影响的程度也要大的多，原因在于对于一个只有 5 个分析师覆盖的公司来说，一名分析师的作用要远远大于拥有 25 名分析师覆盖的公司，因此当两个公司同时减少一名分析师覆盖的时候，小公司比起大公司来说出现信息不对称的程度要高的多。我们将样本内的 1724 个公司按照市值规模和分析师覆盖数量大小分为五个组合分别进行检验其对决策指标的影响，我们可以看到的规模小，分析师覆盖数量少的公司受到的影响要大的多。

图 6 分析师覆盖减少受到公司市值规模和分析师覆盖数量的影响程度（1）

Panel A: Mean Differences-in-Differences Conditional upon Market Capitalization					
	Q1 (smallest)	Q2	Q3	Q4	Q5 (biggest)
Investment					
Capital expenditures	-0.83	-1.01	-0.74	-0.53	0.05
Res. and dev. expenditures	0.07	-0.22	-0.21	0.12	-0.27
Acquisitions expenditures	-1.25*	-0.96	-1.17*	-1.03	-0.62
Total investment	-2.44**	-2.34**	-2.03*	-1.47	-0.79
Financing					
Change in short-term debt	0.31	-0.50**	0.20	0.08	-0.03
Change in long-term debt	-2.09**	-1.91**	-1.98**	-0.23	0.46
Equity issuance	-4.28***	-0.16	-0.75	-1.10	0.51
Total financing	-5.69***	-2.62**	-2.58**	-1.16	1.16
Payouts					
Dividends	-0.08	0.03	-0.04	0.08	-0.05
Share repurchases	-0.03	0.05	0.16	0.09	0.03
Total payouts	-0.05	0.19	0.08	0.16	0.00
Change in cash holdings	-1.91**	-0.81	-1.19	-1.35	-0.11

资料来源：THE JOURNAL OF FINANCE

图 7 分析师覆盖减少受到公司市值规模和分析师覆盖数量的影响程度（2）

Panel B: Mean Differences-in-Differences Conditional upon Analyst Coverage					
	Q1 (least)	Q2	Q3	Q4	Q5 (most)
Investment					
Capital expenditures	-0.75	-1.05	-0.58	-0.49	-0.43
Res. and dev. expenditures	0.11	-0.38	-0.05	-0.33	0.00
Acquisitions expenditures	-1.61***	-1.58**	-0.83	-0.29	-0.74
Total investment	-2.69**	-3.00**	-1.47	-1.04	-1.24
Financing					
Change in short-term debt	0.01	0.52**	-0.15	-0.42	-0.04
Change in long-term debt	-0.83	-2.38***	-0.14	-1.00	-1.47*
Equity issuance	-4.07***	-0.05	-1.49*	-0.73	0.74
Total financing	-4.76***	-1.70	-1.66	-1.94	-0.83
(Continued)					
Payouts					
Dividends	-0.04	-0.03	-0.02	-0.00	0.01
Share repurchases	0.29	-0.19	0.33	-0.27	0.06
Total payouts	0.34	-0.21	0.27	-0.34	0.23
Change in cash holdings	-1.76**	-0.90	-1.45	0.53	-1.49

资料来源：THE JOURNAL OF FINANCE

3、券商分析师的研究质量分析

要得出本文的结论，必须保证一个重要的前提，即只有在分析师的研究确实对公司

的信息或者决策产生实质性意义的情况下，结论才能成立。因此本部分我们将对分析师的研究质量进行研究，看其是否确实对上市公司产生作用。

图 6 分析师覆盖减少受到公司市值规模 and 分析师覆盖数量的影响程度 (1)

Panel A: Relative Earnings Estimate Accuracy of Brokers and Analysts that Disappear				
	Number of Observations	Mean	Median	Mean Weighted by Number of Firms Covered
Brokers	71	0.520	0.539	0.535
Analysts	373	0.536	0.546	0.554

Panel B: Analysts' Expectations for Treatment Firms for Analysts that Disappear Compared to Other Analysts				
	Mean			
	Number of Observations	Analysts that Disappear	Other Analysts	p-value of Test of Equality
Earnings estimates	1,635	3.4%	3.8%	0.226
Investment recommendations	966	3.7	3.8	0.003
Long-term earn.'s gr. rate est.'s	698	18.4%	19.5%	0.043
Price targets	804	56.7%	60.3%	0.563

	Median			
	Number of Observations	Analysts that Disappear	Other Analysts	p-value of Test of Equality
Earnings estimates	1,635	4.7%	4.9%	0.235
Investment recommendations	966	4.0	3.8	0.000
Long-term earn.'s gr. rate est.'s	698	15.0%	16.5%	0.022
Price targets	804	26.2%	28.3%	0.441

资料来源：THE JOURNAL OF FINANCE

由上表可知，我们所观察到得消失的券商和分析师的预测准确率排名的均值和中位数都高于平均水平，从而验证了我们之前的说法，即券商的分析师的研究质量较高且对上市公司的确产生实质性的影响。

基于递归决策树的投资组合选择

原文: Anton Andriyashin, Wolfgang Härdle, Roman Timofeev, SFB 649 Discussion Paper 2008-009, Humboldt-Universität zu Berlin, Germany, January 15, 2008.


推荐人: 吴先兴 021-23219449

推荐理由: 这篇论文创新之处是提出了一种递归的决策回归数模型, 同传统的决策回归树模型的差异主要在于决策树的修建采用了递归的模式, 将这种决策树方法用来选择股票。文章采用了一系列基本面和技术变量, 来判断当前公司的市场价值被低估, 高估或者被正确定价。观察期内模型的表现表明德国 XETRA DAX 股票收益能够充分被公开可得的经济数据所预测。本研究的另一个结论是, 当隐含波动率被引入训练样本时, 有效提高了模型的预测能力。

1、引言

该文介绍了一种递归的分类和回归树(CART)来选择股票。由于其属性(Breiman, et al 1987), 相比其他更传统的模型 CART 提供了更好的表现收益。CART 股票定价已经被用于其他大型金融机构, 如 SmithBarney(花旗集团的一员), see Sorensen, et al (1999)。该模型取得了 19.62%(年化), 标准偏差 11.96%和夏普比率为 1.23。摩根大通(Seshadri 2003)使用 CART 技术将美国科技类股票分为三类: 估价过高, 低估和合理定价的。他们的定量模型表现显示 14.6%的年化回报率对应的标准偏差为 9.5%, 夏普比率为 1.54。该文将模型用于 XETRA DAX 指数包含的公司, 周度进行调整组合, 年化收益率为 19.99%, 相应的夏普比率为 0.88, 明显优于这段相关区间的其他基准指数。最后作者又在学习样本中包涵了隐含波动率变量, 策略的表现高达年化 25.55%, 相应的夏普比率为 1.59。见图 1。CART(实线)在与主要证券交易所指数和无风险利率的比较中显示了更好的表现。这些结果证明隐含波动率作为一个风险因素参与收益预测的重要性。

图 1 主动 CART 策略和基准策略收益曲线



资料来源: Recursive Portfolio Selection with Decision Trees

2. 递归 CART 模型介绍

CART 代表分类和回归树,这是一种非参数分类方法,在决策树的股票选择应用中,很自然的把类向量的有一个元素 $y \in Y$ 作为一个预定义特征的股票,例如股票可能被主观地低估、高估或者它也可能有主观合理的价格。在这个设置 $y \in \{\text{多、空、中性}\}$ 是三个预定义的股票分类。 X 能够包含有关一个特定的股票的一系列基本面和技术变量,可能包含一些宏观经济因素。然而,可能有几种方法来评估历史股票潜在在上述提到条款和构建向量 Y ,这方面会第四部分在更多细节上进行检验。

在这一点上,我们假设,每个观察有其集合构成整个学习样本的向量 Y ,结合现有的数据从过去的 X 和(可能需要另外计算)目标特征 Y ,数据集 (X,Y) 用于提取可用数据模式——这是通过“学习”即建立一个决策树 T ,从过去提取不同的结果,并试图“解释”过去观察到的 X 和 Y 在二叉树形式之间的联系。当新的市场信息变得可获得时,决策树被使用将新数据从 Y 分类到这样,对于一个给定的股票使用现有的树,可以产生多、空或维持当前的仓位的推荐意见。

决策树对数据集的应用意味着进行三个主要步骤:

构建最大树 $T_{\max}$;

选择正确的树的尺寸(树修剪) T ;

使用构造新数据的分类树;

2.1 最大树的构建

P 是变量个数,如果 $X = (X_1, X_2, \dots, X_P)$ 是学习样本矩阵,这里有 M 个观察样本,类向量 Y 具有相同的长度 M ,让我们假设有 J 个独特类(当 $y_i \in \{\text{多、空、中性}\}$ 对应于 $J = 3$)。

分类树的构建依据分叉规则,规则决定了每个节点的分叉 s^* 。它的目的是通过分裂初始更小同质(父节点)分为两部分(两个子节点)创建两个更大同质组。一个分叉包含变量 X_{p^*} , $p^* \in \{1, \dots, P\}$ 的矩阵, P 、解释变量 X 和问题值 x^* , 导致分叉节点的父节点 t_P 分为 t_L 和 t_R , 问题“ $X_{p^*} < x^*$ 吗?”把 t_P 分成两个不同的组,包含最大可行的内在的同质性。

同质性是通过一个杂质函数 $i(t)$ 定义。这是一个随机函数拥有一个独特的最大值在点 $(\frac{1}{J}, \frac{1}{J}, \dots, \frac{1}{J}) \in R^P$ 和独特的最小值在点

$(1, 0, 0, \dots, 0), (0, 1, 0, \dots, 0), \dots, (0, 0, 0, \dots, 1) \in R^P$ 。它还拥有一些重要的技术属性,可参考 Breiman, et al(1987)提供的更多细节。

分叉对应的最大同质性左和右子节点相对于父节点相当于分割后的最大化杂质函数 $\Delta i(t)$ 为任意节点 t 和任意分叉的变化:

$$\Delta i(t) = i(t_P) - \mathbb{E}\{i(t_C)\} \quad (2)$$

$$\mathbb{E}\{i(t_C)\} = p_L i(t_L) + p_R i(t_R), \text{节点 } C = \{L, R\}$$

假设 p_L 和 p_R 为左右节点的可能性估计(父节点到两个子节点的各自比例的观察分布)。

$$\Delta i(s, t) = i(t) - p_L i(t_L) - p_R i(t_R) \quad (3)$$

对于一个任意数据分叉 s :

因此,在每个节点解决了如下优化问题:

$$s^* = \arg \max_s \Delta i(s, t) = \arg \max_s \{-p_L i(t_L) - p_R i(t_R)\} = \arg \min_s \{p_L i(t_L) + p_R i(t_R)\} \quad (4)$$

注意 t_L 和 t_R 是 s 的隐式方程, 因为任意问题变量 $\chi_{\tilde{p}}, \tilde{p} \in \{1, \dots, P\}$ 或者一个任意问题值 $\bar{X}$ (任意 $\bar{S}$ 的变化: $\chi_{\tilde{p}} < \bar{X}$) 的变化能够促使值 t_L 和 t_R 也会变化。

在这个算法中, CART 搜索了组成矩阵 X 所有可能的变量的值, 获得最佳分叉 s^* 使得杂质函数 $\Delta i(s^*, t)$ 的变化最大。

最大树 $T_{\max}$ 包含节点对于一个给定数据集的最大数量。换句话说, 这是一个树的建立是由式(4)应用到原始数据集产生分叉数据部分直到以下条件成立。这个条件定义了 $T_{\max}$ 的树, 每个终端节点只包含观测属于相同类 j :

$$\forall t \in \tilde{T} \exists j: p(j|t) = 1 \quad (5)$$

$\tilde{T}$ 是树 T 的终端节点。

下一个重要步骤是定义杂质函数 $i(t)$ 。虽然杂质函数可以在许多方面被定义, 基尼指数是金融领域应用很好的选择, 请参阅 Kolyshkina & Brookes(2002)。

2.2 Gini 分叉定律

采用 gini 系数的概念, 这种特殊形式的杂质函数 $i(t)$ 可以写成如下:

$$i(t) = \sum_{k=1}^J \sum_{l=1, l \neq k}^J p(k|t)p(l|t) \quad (6)$$

$K, l=1, J$ 是类指数。

$$p(j|t) = \frac{n_t(j)}{n_t} \quad (7)$$

$N_t(j)$ 是属于类 $j \in \{1, \dots, J\}$ 的 $\mathcal{X}$ 的观测值的数目, j 已经被过滤至对应一个给定分叉 s 的节点 t ; n_t 是节点 t 中包含观测值的总数。

应用 gini 分叉定律到 (3) 式, $\Delta i(t)$ 变换为:

$$\Delta i(t) = - \sum_{j=1}^J p^2(j|t) + p_L \sum_{j=1}^J p^2(j|t_L) + p_R \sum_{j=1}^J p^2(j|t_R) \quad (8)$$

(4) 遵循以下形式:

$$s^* = \arg \max_s \left\{ - \sum_{j=1}^J p^2(j|t) + p_L \sum_{j=1}^J p^2(j|t_L) + p_R \sum_{j=1}^J p^2(j|t_R) \right\} \quad (9)$$

2.3、优化树尺寸

树的算法构建如下。方程(9)是第一个应用于整个学习样本(根节点) $\mathcal{X}$, 之后, 它适用于创建树的每个节点。这个过程可以循环, 直到 $i(t) = 0$, 每个终端节点如(5)所示, 或者直到树的大小变得平衡。

但是什么事平衡或者优化的树尺寸? 为什么最大树常常不是最佳选择?

在 Breiman, et al(1987) 的研究中引入一些新的措施, 可以考虑树的复杂性, 即它的大小可以被由终端节点的数量估计。最大的树会因为它的大尺寸而被处罚, 然而另一方面, 它

能最初完美的样本内预测。小型树,当然,它们的大小得到一个低得多的惩罚,但他们的预测能力自然是有限的。因此,目标是找到一个树的大小和预测能力的平衡。这可以通过 cost-complexity 函数来实现,将在本节后文中定义。

首先定义节点 t 的内部错误分类误差 $e(t) = 1 - \max_j p(j|t)$, 定义 $E(t) = e(t)p(t)$, 内部错误分类树误差为:

$$E(T) = \sum_{t \in \tilde{T}} E(t) \quad (10)$$

当 $\tilde{T}$ 是一系列终端节点, 对于任何子树 $T < T_{\max}$, 定义终端节点 $|\tilde{T}|$ 为它自身复杂度的度量。复杂度成本很熟旨在优化决策树尺寸:

$$E_{\alpha}(T) = E(T) + \alpha |\tilde{T}| \quad (11)$$

当 $\alpha \geq 0$ 是复杂度参数, $\alpha |\tilde{T}|$ 是成本因素。

尽管 α 能有无限制值, $E_{\alpha}(T)$ 最小化的 $T_{\max}$ 的子树的数目是有限的。因此修剪 $T_{\max}$ 导致子树序列 $T_1, T_2, T_3 \dots$ 的创建, 伴随递减的终端节点数目。既然序列是有限的, 如果 $T_{(\alpha)}$ 是一些任意 α 的最优子树, 它将保持最优知道复杂性参数没有改变为某 α' 当 $T_{(\alpha')}$ 成为新的最优子树只到复杂性参数值为 α'' 。

3、实证分析

在本研究中,我们取 2000 年 4 月 27 日至 2003 年 10 月 30 日 XETRA DAX 样本公司数据, 包括历史股价, 包含一系列技术和基本面指标。

表 1 可用变量列表 t 为当前时间段

Indicator	Type	Frequency	Description
Momentum	Technical	1 day	$M_t = P_t - P_{t-T}, T = 20$
Stochastic	Technical	1 day	$\frac{P_t - P_L}{P_H - P_L}, P_H = \max(P_t), P_L = \min(P_t)$
MA	Technical	1 day	$MA(T) = \frac{\sum_{i=t-T}^t P_i}{T}, T = 12$
MA St. Error	Technical	1 day	Standard deviation of MA
MACD	Technical	1 day	$(1 - \frac{n_1}{n_2})\{MA(n_1) - MA(n_2 - n_1)\}$ $n_1 = 12, n_2 = 26$
ROC	Technical	1 day	$\frac{P_t}{P_{t-T}}, T = 10$
TRIX	Technical	1 day	Triple exponentially smoothed MA
BV	Fundamental	1 month	Book Value
CF	Fundamental	1 month	Cash Flow
Dividends paid	Fundamental	1 month	-
			Depreciation
EPS	Fundamental	1 month	Earnings Per Share
Sales	Fundamental	1 month	-
ImplVola	Fundamental	1 day	Implied volatility

资料来源: Recursive Portfolio Selection with Decision Trees

因为对技术参数和基本面数据(参考表 4.1) 不同的测量时间,使用哪个时间尺度进行选股分析是一个开放的问题。显然,日数据为我们提供了一个足够数量的观察学习样本,

但与此同时他们可能包含不受欢迎的市场波动和自然噪声。每月收集基本数据以来,他们每天的变化给我们带来新信息。另一方面,月度数据将给我们每年 12 个观测值,这并不足以构建一个可靠的树。因此我们的分析基础要基于每周观测数据,在数据规模和信息内容之间权衡。最终包含每周结束的技术数据和股价标准化后的基本面指标。

可用数据分为三组:学习样本,测试/校准样本和验证集。第一个数据集是学习样本,用于构建每个公司的初始决策树。测试集是用于优化模型参数。最后,运用优化后的模型参数,评估模拟每个股票的表现使用的最后一部分数据,验证集。

在第二部分,股票类(存储在向量 Y)以三种可能的值的形式被引入,多头、空头或中性分别代表低估,高估和正确定价股票。在这项研究中,我们在以下方式评估股票的相对表现。

设 $\bar{R}$ 为某一正向阈值,对给定的 $\bar{R}$, 树的分类如以下定义:

$$\begin{cases} R_t \geq \bar{R} & \Rightarrow long \\ -\bar{R} \leq R_t \leq \bar{R} & \Rightarrow neutral \\ R_t \leq -\bar{R} & \Rightarrow short \end{cases}$$

$$R_t = \frac{P_{t+1} - P_t}{P_t}$$

下一时间段的收益率为

阈值 $\bar{R}$ 的优化是使用单独校准设置每个股票。方法是:在校准期内模拟交易活动,使股票的回报最大化。设置 值从0%到3%,步长0.25%,分析了每只股票13种不同的场景。虽然不同的股票导致不同的 值,在大多数情况下 是接近1.5%。

4. 回测结果


仓位用股票的等权重组合 (或多或空)在每时段形成。由于交易系统每周更新,投资组合的权重也被重新计算。如果 $A_t > 0$ 是当前周期 t 建议主动仓位股票的数量,那么投资组合的权重在时间点为 ω_{it} , 交易成本为 10 个基点/每次列入计算的操作:

$$|\omega_{it}| = \frac{1}{A_t}. \quad (14)$$

如果 $A_t = 0$,那么投资组合头寸保持不变。


图 7 描绘了 CART 策略的收益曲线和传统基准:XETRA DAX 指数,富时 100 指数和道琼斯工业指数的收益表现,图 8 显示了每周的投资组合回报。无风险利率是近似三个月 LIBOR 利率。观察期间的平均年利润为 19.99%相应的夏普比率为 0.88。

图 7 学习样本不含隐含波动率的主动 CART 策略收益率曲线；基准策略收益率曲线



资料来源：Recursive Portfolio Selection with Decision Trees

图 8 不含隐含波动率变量学习样本的主动 CART 策略每周投资收益



资料来源：Recursive Portfolio Selection with Decision Trees


表 2 不含隐含波动率变量学习样本的投资组合表现统计量

	Value
Sharpe ratio	0.88
Mean relative weekly	19.99%
Skewness	0.63
Kurtosis	6.69
Risk free (Avg. LIBOR)	0.04

资料来源: Recursive Portfolio Selection with Decision Trees


为测试隐含波动率的股票价格预测能力,第二次组合包含学习样本的隐含波动率变量。每周的收益和收益曲线可见图 9 和 10。投资组合的表现见表 3。因为 SAP(24243) 隐含波动率数据不可得,我们从第二组合排除了这只股票。

图 9 学习样本包含隐含波动率的主动 CART 策略收益率曲线; 基准策略收益率曲线



资料来源: Recursive Portfolio Selection with Decision Trees

图 10 包含隐含波动率变量学习样本的主动CART策略每周投资收益



资料来源：Recursive Portfolio Selection with Decision Trees

表 3 含隐含波动率变量学习样本的投资组合表现统计量

	Value
Sharpe ratio	1.59
Mean relative weekly	25.55%
Skewness	1.00
Kurtosis	5.68
Risk free (Avg. LIBOR)	0.04

资料来源：Recursive Portfolio Selection with Decision Trees

很明显,隐含波动率变量,至少在给定的股票市场 and 期间内,有一个正向股票价格的预测能力。

5. 总结

在该文中,作者是假设基于适当分析可用市场数据能够对股票进行有效选择,即当前的股票价格和滞后指标之间有一种未知的非线性形式关系。这种关系在这里通过一个决策回归树的非参数分类方法来估计。决策树是一个分类规则,通过二叉树的形式描述了股票价格和可用市场信息之间的关系,并进一步预测了未来价格的运动。我们认为这种关系可能会随着金融市场的演变而改变,因此重建每个时期(周)的决策树,最新的观测被包括到学习样本中来保持更新,并且旧的数据被排除出样本来保持样本固定的大小。

为了评估风险因素对股票预测能力的重要性,文章创建了两个不同的组合,包括和不包含隐含波动率变量的学习样本。第一个投资组合构建只使用技术和基本面信息,年化收益率为 19.99%,相应的夏普比率为 0.88,明显优于传统的基准策略。包括隐含波动率变量后,交易系统回测表现提高到每年 25.55%收益率和夏普比率 1.59。这个结果说明股票溢价能被风险因素(隐含风险波动率)很好地解释。

基于价格低频信号的外汇动量交易策略

原文: Harris, Richard D.F.&Yilmaz, Fatih, A momentum trading strategy based on the low frequency component of the exchange rate, Journal of Banking & Finance. Vol 33(2009), pp: 1575-1585


推荐人: 朱剑涛 021-23219745

推荐理由: 用经典技术指标进行交易获得的收益常不稳定, 主要原因是价格数据序列里的高频信号干扰了指标的识别能力, 作者在本文中为我们提供了两种方法来提取价格数据中的低频信号, 并基于此设计交易策略, 效果提升明显。

为了展示金融数据中的不同频率成分, 作者按照 Christiano and Fitzgerald (2003) 的频段滤波方法, 把 1986-2006 年间的美元/日元的月价格数据在样本内拆分成趋势项、周期项和噪音项 (图 1)。一个好的交易策略应该能够识别趋势项, 同时又能对市场周期项的变化及时作出反应, 避开噪音项的干扰。投资者传统上采用移动均线方法来过滤高频噪音信号, 但均线系统难以在滞后性和平滑性上取得较好的平衡, 作者在本文中提供了 HP 滤波和核回归 (Kernel Regression) 两种方法来过滤高频噪音, 获取低频信号。

图 1 美元/日元汇率月价格数据的频率拆分 (1986 - 2006)

Figure 1 Decomposition of USD/JPY into Trend, Cycle and Irregular Components



Notes: The figure shows the decomposition of the monthly USD/JPY spot exchange rate over the period June 1986 to May 2008 into trend (Panel A), cycle (Panel B) and the irregular component (Panel C) using the Christiano and Fitzgerald (2003) band-pass filter.

数据来源: Journal of Banking & Finance

假设 t 时刻的价格记为 S_t , HP 滤波即是要找到一组序列 S_t^* 使得下面的算式取得最

小值

$$\sum_{t=1}^T (S_t - S_t^*)^2 + \lambda \sum_{t=2}^{T-1} [(S_{t+1}^* - S_t^*) - (S_t^* - S_{t-1}^*)]^2$$

上式中的前半部分衡量的是序列 S_t^* 对 S_t 的拟合程度，后半部分则通过 S_t^* 的二阶导数来度量 S_t^* 的平滑性。 λ 是人为设定的系数，用来表示对序列 S_t^* 的平滑度的惩罚系数，当 $\lambda = 0$ 时， S_t^* 即原序列；当 $\lambda \rightarrow \infty$ 时， S_t^* 趋于直线。

Kernel Regression 是一种加权平均方法，

$$S_t^* = \frac{\sum_{\tau=\tau_0}^{\tau_1} K\left(\frac{t-\tau}{h}\right) S_\tau}{\sum_{\tau=\tau_0}^{\tau_1} K\left(\frac{t-\tau}{h}\right)}$$

其中 $K(u)$ 为核函数，通常有下面四种形式：

$$\begin{aligned} \text{Gaussian} & \quad \frac{1}{\sqrt{2\pi}} \exp(-0.5 * u^2) \\ \text{Parabolic} & \quad \frac{3}{4} (1 - u^2) I(|u| \leq 1) \\ \text{Triangular} & \quad (1 - |u|) I(|u| \leq 1) \\ \text{Cosine} & \quad \frac{\pi}{4} \cos\left(\frac{\pi}{2} u\right) I(|u| \leq 1) \end{aligned}$$


h 为其宽度参数，值远大，那么过往数值在趋势拟合过程中的权重就越大。两种方法对美元/日元汇率数据的平滑效果如图 2 所示，平滑曲线的平滑度和滞后性可分别由参数 λ 和 h 控制。

为了测试上面两种数据平滑方法对交易策略效果的提升，作者以 1986.06 到 2008.05 期间九种外汇的月数据为对象进行了测试，同时还把九个外汇的等权重指数（EWP）作为第十个对象用来综合对比。交易策略采用的是短均线上穿长均线建多仓，下穿建空仓的基本方法，未考虑交易费用。

作者首先采用的是原始价格数据，未做任何平滑处理，结果如图 3 所示。可以看到，从收益率和最大回撤两个角度综合考虑，MA(1,2)的效果最好。

图 2HP filter 和 Kernel Regression 对美元/日元汇率数据的平滑效果比较

Figure 5 Out-of-sample USD/JPY Trend Forecasts



Notes: The figure shows the out-of-sample forecasts of the non-linear trend for the USD/JPY exchange rate over the period June 1993 to May 2008 using the Hodrick-Prescott filter with a smoothing parameter of 14,400 and the average of the four kernel regressions with the default bandwidth value.

数据来源: Journal of Banking & Finance

图 3 双均线方法在原始价格数据上的测试结果

Table 2 Trading Strategy Performance (Moving Average)

Panel A: Directional Accuracy										
	EUR	JPY	GBP	CHF	SEK	NOK	AUD	CAD	NZD	EW P
MA(1, 2)	54.4%	56.7%	41.7%	51.7%	53.3%	50.0%	52.2%	47.8%	51.1%	52.8%
MA(1, 3)	51.7%	57.8%	40.6%	46.1%	53.9%	47.2%	46.7%	48.3%	51.1%	51.7%
MA(1, 4)	51.1%	55.6%	41.1%	48.3%	51.7%	46.7%	48.3%	48.9%	56.1%	51.1%
MA(1, 5)	52.8%	53.3%	42.2%	46.7%	56.1%	47.2%	46.7%	50.0%	56.7%	53.3%
MA(1, 6)	51.7%	51.7%	43.3%	45.0%	57.2%	46.7%	48.3%	51.7%	58.3%	51.7%
MA(2, 3)	46.7%	55.0%	44.4%	46.1%	50.0%	51.7%	47.2%	45.0%	50.0%	46.1%
MA(2, 6)	53.3%	53.3%	47.8%	45.0%	59.4%	53.3%	51.7%	50.6%	58.9%	55.6%
MA(3, 6)	51.1%	50.0%	52.8%	48.3%	61.1%	50.6%	53.3%	50.0%	63.3%	55.0%
Panel B: Return										
	EUR	JPY	GBP	CHF	SEK	NOK	AUD	CAD	NZD	EW P
MA(1, 2)	6.14%	0.67%	-2.80%	1.54%	2.43%	0.90%	3.32%	0.58%	4.38%	1.91%
MA(1, 3)	6.24%	2.62%	-3.39%	0.12%	2.38%	-0.37%	-0.21%	0.86%	3.74%	1.33%
MA(1, 4)	4.39%	2.55%	-3.26%	1.59%	-0.31%	-0.89%	-0.28%	1.51%	6.57%	1.32%
MA(1, 5)	4.93%	2.48%	-2.43%	1.24%	1.76%	-0.81%	-1.37%	1.26%	5.07%	1.35%
MA(1, 6)	3.63%	2.91%	-2.43%	-0.65%	2.75%	-0.86%	-0.47%	2.49%	5.58%	1.44%
MA(2, 3)	2.50%	4.27%	-2.97%	-1.22%	-1.22%	0.87%	-2.11%	0.41%	0.54%	0.12%
MA(2, 6)	3.41%	4.74%	0.13%	-1.39%	4.30%	2.55%	0.92%	0.90%	5.33%	2.32%
MA(3, 6)	1.53%	-0.34%	1.01%	0.16%	6.07%	1.11%	2.67%	-1.31%	7.94%	2.09%
Panel C: Sharpe Ratio										
	EUR	JPY	GBP	CHF	SEK	NOK	AUD	CAD	NZD	EW P
MA(1, 2)	0.71	0.06	-0.39	0.15	0.24	0.14	0.33	0.06	0.44	0.41
MA(1, 3)	0.72	0.23	-0.47	0.01	0.23	-0.06	-0.02	0.09	0.37	0.27
MA(1, 4)	0.50	0.23	-0.46	0.16	-0.03	-0.13	-0.03	0.16	0.66	0.28
MA(1, 5)	0.56	0.22	-0.34	0.12	0.17	-0.12	-0.14	0.13	0.51	0.28
MA(1, 6)	0.41	0.26	-0.34	-0.06	0.27	-0.13	-0.05	0.26	0.56	0.29
MA(2, 3)	0.28	0.38	-0.42	-0.12	-0.12	0.13	-0.21	0.04	0.05	0.02
MA(2, 6)	0.39	0.43	0.02	-0.14	0.43	0.39	0.09	0.09	0.53	0.45
MA(3, 6)	0.17	-0.03	0.14	0.02	0.61	0.17	0.27	-0.14	0.81	0.40
Panel D: Maximum Drawdown										
	EUR	JPY	GBP	CHF	SEK	NOK	AUD	CAD	NZD	EW P
MA(1, 2)	18.1%	37.8%	50.8%	32.2%	37.8%	20.7%	17.3%	33.1%	19.4%	9.6%
MA(1, 3)	15.9%	23.6%	51.7%	38.9%	32.1%	20.7%	29.1%	29.1%	24.9%	11.5%
MA(1, 4)	18.9%	25.2%	48.9%	34.4%	41.0%	27.9%	29.7%	23.3%	16.8%	8.2%
MA(1, 5)	18.9%	24.8%	42.8%	18.2%	26.6%	26.6%	47.8%	26.0%	28.2%	10.0%
MA(1, 6)	25.7%	30.9%	45.3%	26.5%	26.8%	27.7%	36.9%	26.1%	29.1%	13.3%
MA(2, 3)	19.1%	22.5%	48.1%	30.5%	44.1%	24.2%	37.9%	25.3%	40.4%	14.2%
MA(2, 6)	23.3%	16.7%	23.2%	44.5%	32.1%	10.7%	26.4%	33.8%	39.7%	16.2%
MA(3, 6)	25.6%	40.3%	25.8%	34.1%	18.8%	23.7%	31.0%	51.8%	32.8%	15.3%

Notes: The table reports the directional accuracy, annualised return, annualised Sharpe ratio and maximum drawdown for the momentum trading strategy based on the MA(m, n) rule. Results are reported for the G10 currencies and the equally weighted portfolio (EWP). The evaluation period is June 1993 to May 2008.

数据来源: Journal of Banking & Finance

随后作者分别用 HP 滤波和 Kernel Regression 方法对原数据进行了过滤，再对过

滤后的价格数据采用 MA(1,2) 的双均线策略进行测试，测试结果见图 4。对于 HP 滤波（图 4 左），不论参数 λ 取 11520, 12960, 14400, 15840, 17820 中的任何一个，MA(1,2) 策略此时的收益率都明显高于原始价格数据下的表现，例如 EWP 组合此时的收益率都超过 4.3%，显著高于原始数据下的 1.9%；经过 HP 滤波后，MA(1,2) 策略的 Sharpe Ratio 和最大回撤也明显表现得比原始数据情况下的好。对于 Kernel Regression 而言，策略的表现与核函数的选取有关，综合收益率与最大回撤考虑，前文提到的四种核函数的表现都优于原始数据，其中 Triangular Kernel 的表现最好，注意测试过程中宽度参数 h 设置为总体数据长度的四分之一。

图 4 双均线方法分别在 HP 滤波和 Kernel Regression 过滤后的价格数据上的测试结果

Table 3 Trading Strategy Performance (Hodrick-Prescott Filter)

Panel A: Directional Accuracy										
	EUR	JPY	GBP	CHF	SEK	NOK	AUD	CAD	NZD	EWP
11,520	55.6%	53.3%	57.8%	51.1%	60.0%	53.3%	55.0%	53.3%	61.1%	61.1%
12,960	56.7%	53.3%	57.8%	51.1%	58.3%	53.9%	55.0%	53.3%	61.1%	60.0%
14,400	56.1%	53.9%	57.8%	51.1%	58.9%	54.4%	55.0%	53.9%	61.7%	60.6%
15,840	56.1%	53.3%	57.8%	51.7%	58.9%	53.9%	54.4%	55.0%	62.2%	60.0%
17,820	55.6%	53.3%	57.8%	51.7%	59.4%	53.9%	55.0%	55.0%	61.1%	60.6%

Panel B: Return										
	EUR	JPY	GBP	CHF	SEK	NOK	AUD	CAD	NZD	EWP
11,520	5.15%	4.35%	2.48%	3.35%	5.57%	1.44%	6.20%	3.09%	8.61%	4.47%
12,960	5.25%	4.35%	2.48%	3.09%	4.63%	1.49%	6.20%	3.09%	8.61%	4.36%
14,400	5.14%	4.37%	2.33%	3.09%	4.73%	1.71%	6.20%	3.64%	9.20%	4.49%
15,840	5.14%	3.97%	2.33%	3.38%	4.46%	1.42%	6.04%	4.25%	9.38%	4.49%
17,820	4.57%	3.97%	2.33%	3.38%	4.85%	1.35%	6.67%	4.37%	7.81%	4.37%

Panel C: Sharpe Ratio										
	EUR	JPY	GBP	CHF	SEK	NOK	AUD	CAD	NZD	EWP
11,520	0.59	0.39	0.35	0.33	0.56	0.22	0.63	0.32	0.88	0.76
12,960	0.60	0.39	0.35	0.31	0.46	0.22	0.63	0.32	0.88	0.74
14,400	0.59	0.39	0.32	0.31	0.47	0.26	0.63	0.38	0.94	0.76
15,840	0.59	0.36	0.32	0.34	0.44	0.21	0.61	0.45	0.96	0.77
17,820	0.52	0.36	0.32	0.34	0.48	0.20	0.68	0.46	0.79	0.76

Panel D: Maximum Drawdown										
	EUR	JPY	GBP	CHF	SEK	NOK	AUD	CAD	NZD	EWP
11,520	15.6%	32.5%	16.2%	23.7%	22.2%	31.0%	15.5%	32.3%	24.3%	8.7%
12,960	15.6%	32.5%	16.2%	23.7%	32.8%	30.2%	15.5%	32.3%	24.3%	8.1%
14,400	16.5%	32.5%	17.9%	23.7%	31.6%	26.8%	15.5%	32.3%	24.3%	7.7%
15,840	16.5%	32.5%	17.9%	22.0%	37.6%	26.8%	15.5%	32.3%	24.3%	7.5%
17,820	16.5%	32.5%	17.9%	22.0%	34.7%	26.8%	15.5%	28.9%	24.3%	7.1%

Notes: The table reports the directional accuracy, annualised return, annualised Sharpe ratio and maximum drawdown for the momentum trading strategy based on the Hodrick-Prescott filter for different values of the smoothing parameter, λ . Results are reported for the G10 currencies and the equally weighted portfolio (EWP). The Hodrick-Prescott filter is initially estimated using the sample June 1986 to May 1993. Trading signals are then generated recursively for the period June 1993 to May 2008, by applying an MA(1, 2) trading rule to the estimated non-linear trend.

Table 4 Trading Strategy Performance (Nadaraya-Watson Kernel Regression)

Panel A: Directional Accuracy										
	EUR	JPY	GBP	CHF	SEK	NOK	AUD	CAD	NZD	EWP
Gaussian	56.7%	48.9%	54.4%	51.7%	56.1%	57.2%	53.3%	53.9%	58.3%	57.8%
Parabolic	56.7%	53.9%	53.9%	53.9%	59.4%	52.2%	55.6%	58.3%	60.0%	62.8%
Triangular	58.3%	53.9%	50.6%	53.3%	60.0%	52.8%	56.7%	57.2%	61.7%	62.8%
Cosine	57.2%	53.9%	53.3%	54.4%	60.0%	52.8%	55.6%	57.8%	61.7%	62.8%

Panel B: Return										
	EUR	JPY	GBP	CHF	SEK	NOK	AUD	CAD	NZD	EWP
Gaussian	4.20%	0.70%	0.39%	3.16%	4.24%	3.05%	3.70%	4.32%	5.91%	3.30%
Parabolic	5.38%	4.76%	1.61%	4.90%	5.02%	1.49%	6.75%	3.84%	7.86%	4.62%
Triangular	6.55%	4.81%	0.29%	4.44%	6.22%	1.85%	7.26%	3.89%	8.66%	4.89%
Cosine	5.61%	4.76%	1.38%	5.07%	5.36%	1.78%	6.75%	3.78%	8.72%	4.80%

Panel C: Sharpe Ratio										
	EUR	JPY	GBP	CHF	SEK	NOK	AUD	CAD	NZD	EWP
Gaussian	0.48	0.06	0.05	0.32	0.42	0.46	0.37	0.45	0.59	0.56
Parabolic	0.62	0.43	0.22	0.49	0.50	0.22	0.69	0.40	0.80	0.80
Triangular	0.76	0.43	0.04	0.44	0.62	0.28	0.74	0.41	0.88	0.87
Cosine	0.64	0.43	0.19	0.51	0.54	0.27	0.69	0.40	0.89	0.83

Panel D: Maximum Drawdown										
	EUR	JPY	GBP	CHF	SEK	NOK	AUD	CAD	NZD	EWP
Gaussian	17.9%	49.9%	26.9%	20.4%	27.6%	12.6%	27.4%	16.5%	26.4%	13.2%
Parabolic	18.6%	28.0%	21.1%	19.7%	22.2%	23.4%	16.9%	29.7%	29.2%	9.8%
Triangular	11.6%	28.0%	32.2%	28.5%	16.8%	20.2%	18.0%	35.1%	24.3%	7.9%
Cosine	18.6%	28.0%	22.3%	19.7%	22.2%	19.1%	16.9%	30.6%	24.3%	9.7%


Notes: The table reports the directional accuracy, annualised return, annualised Sharpe ratio and maximum drawdown for the momentum trading strategy based on the Nadaraya-Watson kernel regression using different distributions. The bandwidth parameter is set to one quarter of the inter-quartile range. Results are reported for the G10 currencies and the equally weighted portfolio (EWP). The kernel regression is initially estimated using the sample June 1986 to May 1993. Trading signals are then generated recursively for the period June 1993 to May 2008, by applying an MA(1, 2) trading rule to the estimated non-linear trend.

数据来源：Journal of Banking & Finance

最后作者讨论了 MA(1,2) 策略结果对 HP 滤波的参数 λ 和 Kernel Regression 的宽度参数 h 的敏感性，结果如图 4 所示，测试对象是等权指数组合 EWP。可以看到两个策略的收益率都明显高于原始数据下 MA(1,2) 策略的 1.91%，Sharpe Ratio 也在大部分情况下高于 0.41；策略对 λ 的敏感性较低，不论 Return 和 Sharpe Ratio 随 λ 的变化很小；而用 kernel regression 时，策略的表现随着 h 的增加先升后降，最高值出现在 14 左右。


图 5MA(1,2)策略对 HP 滤波和 Kernel Regression 参数的敏感性

Figure 3 Sensitivity of the Momentum Trading Strategy Based on the HP Filter



Notes: The figure shows the return (Panel A) and Sharpe ratio (Panel B) of the EWP momentum trading strategy using the Hodrick-Prescott filter for different values of the smoothing parameter, λ .

Figure 4 Sensitivity of the Momentum Trading Strategy Based on the Kernel Regression



Notes: The figure shows the return (Panel A) and Sharpe ratio (Panel B) of the EWP momentum trading strategy using the kernel regression with a parabolic distribution for different values of the bandwidth parameter, h .

数据来源: Journal of Banking & Finance

总的来说，用 HP 滤波和核回归提取低频信号的方法确实可以降低噪音信号的干扰，显著增强技术交易策略的表现。作者在本文中只尝试了外汇市场和最简单的双均线交易系统，其在股票市场、更复杂交易策略下的表现如何，值得一试。

利用 MACD 柱状图的头肩形态来预测市场方向

原文：Mohamed A. Elaasar. Applying Head-and-Shoulders Pattern on MACD Histogram Indicator to Forecast Market Direction, IFTA Journal. 2012:6-16.

推荐人：杨勇 021-23219945

推荐理由：本文主要关注 MACD 头肩形态的识别和交易，并针对这一形态的交易结果做统计分析。作者首先定义了 MACD 柱状图的头肩形态，并对该形态进行分类，然后介绍了如何在该形态完全形成之前进行有效识别。作者发现该形态的形成对未来市场走向有明显的预测作用，并在此基础上提出了基于 MACD 形态识别的交易规则。统计结果表明：该方法的胜率为 81%，盈亏比则高达 4.4，平均持有时间为 8 天，是一个较好的中短期择时交易策略。

一、引言

Gerald Appel 提出的 MACD 是技术分析领域中一个有名的指标。基于对 MACD 柱状图的理解，以及多年的市场技术分析经验，我们聚焦于一种特别的形态，MACD 柱状图的头肩形态，我们发现这是一个很好的市场择时指标。

本文的数据来自路透社，具体的检验对象有：道琼斯工业平均指数（DJIA）、通用电气股价（GE）、白银现货价格、英镑汇率。这四个对象涵盖了三个主要的流动性较好的市场：美国股票市场、商品市场和货币市场。这些观察对象都有很长的交易历史和充足的可用于检验的日度数据。为便于对比分析，四个市场的日度数据都是从 1983 年 1 月开始取到 2009 年 12 月。

需要说明的是，对多个市场做这种检验的意义不仅在于证明这种 MACD 形态可以被应用于各种不同的市场，我们还可以对不同市场上该形态出现的频率和获利效果做对比分析。我们主要关注的指标有：

- 1) 在检验的时间段内，MACD 柱状图头肩形态出现的次数；
- 2) 形态指标交易的成功率；
- 3) 形态指标交易的平均收益率；
- 4) 平均持有期。

二、MACD 柱状图头肩形态的分类

与传统的头肩形态不同，这里我们所检验的头肩形态是反映在 MACD 柱状图中的，不是反映在股价走势图中的，但两者的定义是类似的。一般来说，有两种头肩形态：

1) 正常头肩形态

这种情况下，MACD 形态在柱状图的零轴上方。我们借用 Dr. Alexander 定义股价头肩形态的表述：“头是一个价格的最高峰，并在其左侧右侧各有一个次高峰，即肩。”相同的定义法应用于 MACD 柱状图指标，只是将原话中的“价格”换成“MACD 柱状图的垂直柱状条”，完整说来就是“头是 MACD 柱状图垂直柱状条的最高峰，左右各有一个次高峰，即肩。”正常的头肩形态是市场转向熊市的标志，价格在未来很可能下降。

2) 颠倒的头肩形态

如同价格形态一样，MACD 柱状图也可能出现颠倒的头肩形态，定义如下：“头是 MACD 柱状图垂直柱状条的最低点，左右各有两个次低点，即肩。”这种形态出现在 MACD 柱状图中零轴的下方，是股价即将上升的标志。


具体而言，以上 MACD 柱状图头肩形态又分别可能出现两种情形：

经典头肩形态：这种情况下，我们看到的图形是头在两肩之间（图 1）。

分离的头肩形态：这种情况下，头与两肩中的一个或两个是分开的（图 2）。


从我们的经验来看，MACD 的头肩形态在大多数市场都出现过，与国家无关，与品种无关，且在各种 K 线图中都有发生。这种形态可能发生在任何时间跨度的图形中，从分钟图到小时图，再到日度的、月度的和年度的图形都有。我们在很早的资料中就看到了这个图形的存在，最早可追溯至 20 世纪初，那时北美还在逐步建立它的股票市场，而最近的例子则是埃及的股票市场。

图 1 经典头肩形态举例



数据来源：Mohamed A. Elaasar. Applying Head-and-Shoulders Pattern on MACD Histogram Indicator to Forecast Market Direction, IFTA Journal.

图 2 分离的头肩形态举例



数据来源：Mohamed A. Elaasar. Applying Head-and-Shoulders Pattern on MACD Histogram Indicator to Forecast Market Direction, IFTA Journal.

三、将头肩形态策略应用于 MACD 柱状图

MACD 的头肩形态能帮助技术人员判断潜在的市场趋势。正常的头肩形态预示着未来几天市场可能会下行，而颠倒的头肩形态则预示着市场可能将上涨。利用这种模式来预判市场近期可能的走势是一个简单但是有效的方式。而形态的另一个应用是作为一个确认指标与其他指标相结合使用。

此外，这种 MACD 头肩形态可以成功地应用在交易上。我们现在来介绍基于这种形态的交易方法，并在后面给出具体的统计分析结果来说明 MACD 头肩形态应用于投资交

易的准确度。

1) 基于 MACD 头肩形态的交易规则

首先，我们必须建立 MACD 柱状图。我们用的 MACD 柱状图的默认设置与路透社是相同的，其中 MACD 参数为：快速 EMA 参数 12、慢速 EMA 参数 26、信号线参数 9。


基于 MACD 头肩形态的交易应该从形态的识别开始，但当它的形态处于逐步形成的过程中时，要识别该形态并不像在形态彻底形成之后的识别那么容易。而一旦等到形态形成之后再进入交易则可能已错过最佳的交易时机。因此，接下来要介绍如何在形态形成过程中选择开始交易的时机。

a) 开始交易

经过大量的统计分析发现，对于正常或者颠倒的头肩形态，市场方向往往都是在右肩峰值出现之后才开始的。因此，我们选择在右肩形成的过程中而不是完全形成之后开始交易。

在图 3 的左图中，右肩的峰值是右肩部分最高的柱状条，后面跟着一根比它稍短一点的柱状条。这根紧随其后的稍短柱状条被视为右肩形态形成的确认线。这是一个可以开始交易的信号，应该在下一交易日开盘时进行交易，建立空头头寸。换言之，开始进入交易的时间是在右肩峰值出现后第二个交易日的开盘时间。在图 3 的右图中，看到做多信号之后，应该相应地在下一个交易日开盘时建立多头头寸。

图 3 基于 MACD 头肩形态交易头寸的建立时间



数据来源：Mohamed A. Elaasar. Applying Head-and-Shoulders Pattern on MACD Histogram Indicator to Forecast Market Direction, IFTA Journal

b) 结束交易

平仓离开的方法原理上与进入交易的原则是差不多的：当一根反转的柱状条已经确定形成时，就应该平仓离场了。

在正常头肩形态下，柱状条的斜率是负的，当柱状条的斜率转向正时，就应该准备平仓。一旦这种信号出现，在反转柱状条出现之后的第二天的开盘时间就应平仓。在图 4 中，我们看到一个 1996 年英镑汇率的真实例子。这是一个正常头肩形态，图上已经标出了买点和卖点。在卖空信号发出后的 10 天内，价格下挫了将近 3%。

而在颠倒头肩形态下，柱状条的斜率是正的，当斜率变为负时，就视为离场信号，应该在该信号出现后第二天的开盘时间平仓。在图 5 显示的是通用电气 1985 年 9 月到 10 月的价格走势，这里形成了一个颠倒的 MACD 头肩形态。做多信号由绿线标出，这一操作在未来的 8 天内取得了 3.7% 的回报，而红线则给出了平仓的时间。

图4 正常头肩形态退出交易的例子（1996年英镑）



数据来源：Mohamed A. Elaasar. Applying Head-and-Shoulders Pattern on MACD Histogram Indicator to Forecast Market Direction, IFTA Journal. 2012:6-1

图5 颠倒的头肩形态退出交易的例子（1985年通用电气）



数据来源：Mohamed A. Elaasar. Applying Head-and-Shoulders Pattern on MACD Histogram Indicator to Forecast Market Direction, IFTA Journal. 2012:6-1

c) 止损


以上形态识别方法选择的开始交易时点，事后有可能被证明是错误的。那么什么时候我们应该止损离场？基于我们的经验和统计分析发现，在右肩进入交易之后，当某一柱状条向与交易开始的柱状条所指示的方向反向变动时，我们首先应该观察该柱状条是否穿过了零轴，以决定我们的下一步操作：

第一种情形：如果柱状条穿过了零轴，那么我们应该在反转柱状条的第二天开盘时平仓，这与一般意义上退出交易的条件是一致的。

第二种情形：如果柱状条没有穿过零轴，我们应该静观其变，直到一根新的柱状条超过了原先右肩的峰值：如果一根新的柱状条超过了之前右肩的峰值，那么第二天就应

该平仓离场（图 6）；反之，如果未能突破之前右肩的峰值，这就相当于构筑了第二个右肩（没有超过第一个右肩的高度），此时我们认为它还是头肩形态，且仍处于右肩部位，持仓不动。

图 6 通过止损退出交易的例子



数据来源：Mohamed A. Elaasar. Applying Head-and-Shoulders Pattern on MACD Histogram Indicator to Forecast Market Direction, IFTA Journal. 2012:6-1

图 7 止损退出交易后又重新进入的例子



数据来源：Mohamed A. Elaasar. Applying Head-and-Shoulders Pattern on MACD Histogram Indicator to Forecast Market Direction, IFTA Journal. 2012:6-1

2) MACD 头肩形态的统计分析

这里我们用到了 1983 年至 2009 年的道琼斯指数、通用电气、白银现货和英镑汇率的数据来做统计。在上述时间段内，这四个市场一共出现了 67 次 MACD 头肩形态。

总体来看，这 67 次头肩形态交易成功率达到 81%，即 54 次成功，13 次失败。其中，道琼斯指数和英镑汇率各出现过 19 次，对于道琼斯 79% 这种交易策略都是成功的，而对于英镑汇率成功率更是高达 84%。对于通用电气，这种形态出现过 17 次，成功率 82%。白银现货市场上，这种基于形态的交易策略成功率最低，一共出现过 12 次，75% 是成功的。

在 67 次头肩形态中，正常头肩形态共计 33 次，占到总次数的 49%，剩下的 51%，是颠倒的形态。在正常头肩形态的 33 次案例中，24 次卖空操作是获得正收益的。对于颠倒的头肩形态，88% 的做多都是成功的。对于道琼斯指数出现的 13 次颠倒头肩形态全部取得了成功。颠倒头肩形态是最为成功的指标，有着很高的统计显著性。

对于全部 4 个市场的成功案例，59% 的收益介于 1%-3% 之间，另外 41% 的成功交易获得了超过 3% 的收益。同样的，绝大多数的失败案例（77%）损失是小于 1% 的，在 13 次失败交易中，仅有白银现货的 1 次失败产生了 4.7% 的最大损失。并且，在 13 次失败中，还有一次是盈亏持平的。每一次失败交易的平均损失为 0.91%，这相对于成功情况的平均收益而言小了太多。接近 2/3 的成功交易带来的收益超过 2%，最高的获益达到了 23%，这发生在白银市场。

MACD 头肩形态策略用于道琼斯指数所取得的最高收益为 12%，发生在 2002 年 10 月，最大的损失是 1995 年 4 月，损失了 1%。用于道琼斯指数平均而言获益 1.2%。54% 的成功交易获得了 1%-3% 的收益。

对于通用电气，一半的成功案例获利 3%，另一半则超过了 3%，在所有失败的案例中，损失都未超过 0.6%。通用电气在 1989 年 11 月的颠倒的头肩形态交易最为成功，取得了 12% 的收益，成功案例中最低收益是 1.2%，发生在 2007 年 2 月和 2008 年 4 月。

纵观这些统计结果，依据获利百分比的分布来看，白银现货是四个市场中最易变的。在全部的交易中，白银获得的最高利润为 23%，发生在 2008 年 9 月，而最大的损失发生在 1983 年 11 月，损失了 4.7%。成功情况下的平均获利为 7.9%，而失败情况下的平均损失为 1.9%。

从检验结果来看，英镑是四种标的最有趣的投资品。从损失收益的分布来看，它是最中庸的，相对于其他三类，英镑汇率的大涨大跌是很少的。88% 的成功交易产生的收益落在 1%-3% 区间内，而其中的 65% 又仅仅介于 1%-2%。最高获益是 1985 年 4 月的 4.8%，成功情况下最低收益是 1%，且发生了 7 次。它的最大损失是 1988 年 6 月的 1.9%，在仅有的三次失败中，平均损失为 1.2%。而对于 16 次成功案例，平均获益 1.87%。

MACD 头肩形态的交易持续时间，即开始交易到平仓离场的时间，也是一个重要的附加考量因素。平均的交易持续期为 MACD 柱状图上的 8 根柱状条，在日 K 线图也就是 8 个交易日。大约 70% 交易持续了 7 至 10 天，频率最高的是 7 天，占了成功交易次数的 26%，其次是 10 天，达到 18%。对于上述四个不同的投资标的，交易的平均持续时间介于 8 到 8.6 天。对于一个成功的交易，至少会持续 5 天，没有一次交易持续时间少于 5 天，同样也没有一次多于 14 天。每个标的的交易都出现过持有 5 天后了结的情况，但是持有 14 天仅仅在道琼斯指数和通用电气股票上出现过。

四、小结

通过统计分析，本文阐明了 MACD 柱状图的头肩形态可以被用于确定交易的多空方向，适用于流动性市场和一般投资品。MACD 线常常被用做分析工具来确定交易开始与离场的时机，但本文所证明的是，MACD 柱状图中融入头肩形态因素亦可以用于判断买卖时机。

统计结果强有力地证明了这种方法应用于交易可以提供期望值为 4.4 的盈亏比，而且胜率可高达 80% 以上，这意味着对于每一次按照头肩形态的交易，期望的风险收益率，包括获利百分比，都是统计显著的。

从交易持有时间看，在日度数据的统计分析中这种基于头肩形态的交易被证明可以在相对较短的时间内（约 8 天）产生一个可以接受的回报。相对于收益率，这个持有时间是可以接受的。

过往 52 周最高价的出现时间与动量效应

原文: F. J. DiTraglia and J. R. Gerlach (2013) Portfolio selection: An extreme value approach. Journal of Banking & Finance 37, 305-323

推荐人: 冯佳睿 021-23219732

推荐理由: 本文基于过往 52 周最高价的出现时间提出了一个新的动量策略。实证发现, 那些于近期达到 52 周最高价的个股在未来的表现明显地优于那些最高价出现在很久之前的股票。特别地, 如果根据 52 周最高价的出现时间距当前的远近程度排序, 最近的 10% 所形成组合的收益平均每个月超越最远的 10% 组合 0.70%。进一步研究表明, 加入过往 52 周最高价发生时间的分类条件后, 有效提升了以当前价格和最高价接近程度为基础的动量策略的收益表现。尤其值得注意的是, 当该策略应用于最近达到 52 周最高价的股票时, 产生的平均月度收益大约是那些很久没有创新高的股票的 2 倍。

1. 介绍

大量实证研究中揭示的几个令人困惑的收益率形态, 对有效市场假说提出了重大挑战。其中最稳健的一个便是个股收益率之间存在动量效应: 近期表现出色的股票在未来一年左右的时间内依然能够延续。自从 Jegadeesh 和 Titman 在 1993 年发表了那篇著名的文献后 (下文以 JT 表示), 股票收益率的动量效应得到了广泛的讨论与研究。其稳健性在好几个国家的不同类型资产中都以样本外检验的形式得到了确认。

George 和 Hwang (2004, 下文以 GH 表示) 基于股票当前价格与过往 52 周最高价的接近程度, 提出了另一种形式的动量策略。他们证明, 当个股按照当前价格与 52 周最高价的比例排序时, 比值较高的个股在未来 6-12 个月内的表现明显优于较低的股票。更重要的是, GH 发现这一策略不仅可以用来解释 JT 的结果, 而且更超越了他们策略的表现。GH 将这一现象归结于“调整和锚定的偏好” (adjustment and anchoring bias, Tversky 和 Kahneman, 1974), 即投资者对那些价格接近于 (远低于) 过往 52 周最高价的股票所展现的正面 (负面) 信息反应不足。

本文检验了 52 周最高价的出现时间在股票收益率动量效应中所扮演的角色。尤其是着重讨论了, 在过去 52 周中, 达到最高价的时间远近是否显著地影响了股票未来的表现。本文假定, 当股票近期处于快速上涨的过程中时, 投资者基于近期偏好, 往往不愿意去追逐这类资产。这样一种行为导致对股价创新高的好消息产生了强烈的反应不足。结果就是, 那些近期才达到 52 周最高价的股票相比于最高价出现在很久之前的能在未来有更好的表现。

为使实证分析更加便捷, 本文定义了一个名为“近期比例”的指标用于捕捉组合构建日距 52 周最高价的时间远近。该指标与 52 周最高价的达到日期距组合构建日的天数呈反向关系。在基础的一元分析中, 本文根据个股的“近期比例”均分成十个投资组合, 考察它们在未来 6 个月周期内的收益表现。与推测一致, 本文发现具有最高“近期比例”的个股, 其表现明显优于最低的那部分。具体来说, 近期比例最高的那十分之一平均每个月能获取 1.42% 的收益, 而后十分之一的月均收益率仅为 0.72%。这两个极端组合之间平均每月 0.70% 的收益差在统计意义上是显著的, 对应的 t 统计量为 4.48。相应的 Fama-French 模型的 alpha 差则为 0.84%, t 统计量为 5.13。进一步, 如果从“近期比例”最低到最高遍历这十个组合, 可以发现, 平均收益几乎是单调上升的。这表明本文所发现的规律并非是由最高和最低这两个组合中的极端收益驱动的。即使把股票只分成 3 组, 依然能得到相似的结论: 具有最高“近期比例”的那 30% 股票显著地在未来超越最低的 30%, 具体幅度为平均每月 0.59%, 对应的 Fama-French 模型的 alpha 差为 0.75%。

在此基础上，本文深入研究了 52 周最高价的出现时间在基于当前价格和最高价接近程度（GH 指标）的 GH 动量策略中扮演的角色。具体来说，本文基于 GH 指标和“近期比例”独立地将股票各分成 3 个投资组合，分别考察其收益情况。结果发现，30% 具有最低“近期比例”的股票中，GH 动量策略平均每个月能获得 0.41% 的收益(t 统计量=2.52)，对应的 Fama-French 模型的 alpha 为 0.63%(t 统计量=5.11)。另一方面，在 30% 具有最高“近期比例”的股票中，GH 动量策略获得了月度 0.83%(t 统计量=4.19)的收益，Fama-French 模型的 alpha 为 1.01%(t 统计量=5.78)。由此可见，高“近期比例”组的原始收益是低“近期比例”组的 2 倍以上。这一证据充分表明，除了当前价格和 52 周最高价的比值外，最高价出现时间的远近同样在 GH 动量策略的收益中扮演了重要角色。

除投资组合排序这一检验外，本文还考察了在公司层面的 Fama-MacBeth 截面回归体系下，“近期比例”的预测能力。利用回归方法，可以方便地引入各种著名的预测变量，包括过去的月度收益，公司规模，以及基于 JT 动量策略的“稳拿”(winners)和“卢瑟”(losers)。回归的结果进一步确认了“近期比例”在增强 GH 动量策略收益中的作用。

本文对于动量策略的研究有以下三个贡献。首先，本文证明了这样一个只依赖 52 周最高价出现时间远近的简单易行的策略，却有着超强的能量，可以产生统计意义上显著且有经济意义的超额收益。有理由相信，这一发现是对有效市场假说的有力挑战。第二，本文证明，当加入 52 周最高价出现时间的远近这个条件后，GH 动量策略的收益得到了显著的改善。这一结果对实际投资而言有着非常重要的指导意义。GH 令人信服地演示了他们的策略能够有效战胜仅基于过往收益率的动量模型，而本文则提供了一条相对直接的途径进一步加强了 GH 策略的收益表现。最后，本文通过分析“近期偏好”在投资者交易决策中所扮演的潜在角色，为行为金融学的研究作出了贡献。

本文余下部分的结构如下：第 2 部分描述了数据和方法。第 3 部分展示的是实证分析的结果。全文在第 4 部分中进行总结。

2. 数据和方法

本文的样本由在纽约证券交易所、美国证券交易所和纳斯达克上市的部分普通股组成，时间周期为 1965 年 1 月至 2008 年 12 月。具体筛选规则是，在每月构建投资组合时，剔除所有股价低于 5 美元以及规模在纽交所排名后十分之一的股票。这些都是研究动量效应的文献中标准的过滤方法，用以保证最终的结果不是由这些流动性不佳，交易量惨淡的个股驱动的。本文涉及的 52 周最高价是指个股在过去 52 周内的最高日收盘价。和 GH 类似，在计算最高价以及相关指标的过程中，股价已经过分红与配股的调整。

在每个月末，计算每一个股票的“近期比例 (recency ratio)”，简写为 RR。

$$RR = 1 - \frac{52 \text{ 周最高价与组合构建日之间的天数}}{364} \quad (1)$$

从(1)式中可以看出，“近期比例”和 52 周最高价出现以来的天数呈反向关系，即最高价如果于近期达到，则 RR 较大；反之，RR 就很小。例如，倘若在组合构建期的最后一天，股价创过去 52 周的新高，那么最高价出现以来的天数就是 0，“近期比例”等于其理论上的最大值，1。

GH 指标反映的是当前价格与 52 周最高价的接近程度，它由下式给出：

$$GH = \frac{\text{当前价格}}{52 \text{ 周最高价}} \quad (2)$$

GH 指标较高表明当前的价格接近 52 周的最高价。同样地，在极端情况下，如果组合构建期的最后一个交易日的收盘价恰好是过去 52 周的最高价，那么 GH 指标达到其可能

的最大值，1。

除了 RR 和 GH 指标，本文也考察了 JT 的模型以及 Moskowitz 和 Grinblatt(1999) 提出的行业动量策略。JT 指标很简单，就是一个股票过去 6 个月的累计收益。在确定行业的收益率时，本文完全按照 Moskowitz 和 Grinblatt(1999)的方法，根据股票的 SIC 代码将其分成 20 个行业，计算每个行业过去 6 个月的市值加权收益。Moskowitz 和 Grinblatt(1999)记录了这些行业收益率中存在动量的证据。在下文的分析中，将这一基于行业收益率的指标记为 MG。

每个组合的收益是通过等权重加权的方式得到的，且存在互相覆盖的计算期，这种方法最初是在 Jegadeesh 和 Titman(1993)的文献中提出的。例如，考虑依据指标 RR 构建的投资组合。在第 t 月，具有最高 RR 的 10%股票被分入“稳拿”组，最低的 10%则进入“卢瑟”组。组合形成后从第 t+2 月一直持有到 t+7 月不变。在构建期和持有期之间预留一个月的空隙是为了减轻由递要价间的跳跃效应导致的伪负相关性的影响。每个月的动量策略包含一个在等权重加权的“稳拿”组合上的多头头寸以及一个等权重加权“卢瑟”组合上的空头头寸。月度的组合收益等于当月组合的收益与之前 5 个月所形成组合在这个月内收益的平均值。这样，对任意一个新的月份，用来计算月度收益的股票中总有大约六分之一被最新的“稳拿”和“卢瑟”替代。在最初的分析中，本文使用十分位点来确定“稳拿”和“卢瑟”，在随后的结果中则取高低各 30%。这种取样方式不仅和 Hong 等人(2000)以及 GH 一致，而且还保证组合中有充分多的个股以获取可靠的推断。

除了组合层面的分析，本文还使用 Fama-MacBeth 截面回归进行研究，以便引入一些常用的预测变量。使用回归方法可以更好地考察“稳拿”和“卢瑟”这两个组合的收益表现，帮助探寻收益率预测能力的来源。

3. 实证结果

3.1 一元结果

本文从考察根据 GH 和 RR 指标构建的投资组合的收益开始分析。表 1 报告的是由 10%分位点 (Panel A) 和 30%分位点 (Panel B) 确定的“稳拿”组合与“卢瑟”组合在 6 个月的持有期内，平均的月度收益。和 GH 的结果一致，本文同样发现基于当前价格和 52 周最高价接近程度的策略有很强的动量效应。GH 的“卢瑟”组合平均每月能获得 0.21%的收益，而“稳拿”组合的月收益率则为 1.32%。这两个极端组合之间 1.11%的差距在统计意义上是显著的，t 统计量为 4.39。对应的 Fama-French 模型的 alpha 是 1.35%，同样显著，t 统计量为 6.16。

表 1 GH 和 RR 组合的月度收益

	GH	RR
<i>Panel A: 10 Portfolios</i>		
L	0.21	0.72
2	0.69	0.71
3	0.91	0.75
4	1.04	0.85
5	1.12	0.95
6	1.18	1.04
7	1.20	1.15
8	1.25	1.26
9	1.28	1.36
H	1.32	1.42
H - L	1.11	0.70
Fama-French alpha	(4.39)	(4.48)
	1.35	0.84
	(6.16)	(5.13)
<i>Panel B: 3 Portfolios</i>		
L	0.60	0.74
2	1.14	0.99
H	1.29	1.33
H - L	0.69	0.59
	(4.07)	(4.74)
Fama-French alpha	0.87	0.75
	(6.08)	(6.09)

In each month t from January 1965 to December 2008, stocks listed on NYSE, AMEX, and Nasdaq are sorted into 10 portfolios for Panel A results and three portfolios (with top and bottom obtained using 30% cutoffs) for Panel B results based on the ratio of current price to 52-week high price (GH) and the recency ratio (RR). The recency ratio captures the recency of 52-week high price and equals $[1 - (\text{current date} - \text{date of 52-week high})/364]$. We exclude stocks with price less than \$5 or with market capitalization below the NYSE smallest decile market capitalization cutoff at the end of the portfolio formation month t . The table reports the average monthly returns from month $t + 2$ month $t + 7$, the return differences of extreme portfolios, and the corresponding alphas from the Fama-French three-factor model. The returns are in percent. The t -statistics are reported in parentheses and are adjusted for autocorrelation using the Newey and West (1987) method.

资料来源：“The timing of 52-week high price and momentum”

本文还找到了基于 RR 指标的组合具有强烈动量效应的证据。RR 指标的“卢瑟”组合每月能获得 0.72% 的收益，而“稳拿”组合则为每月 1.42%。对应的收益差为 0.70%（ t 统计量=4.48），Fama-French 模型的 alpha 是 0.84%（ t 统计量=5.13），两者均在 1% 的水平下显著。仔细观察表 1，有一点非常值得注意，GH 动量效应的很大一部分要归结于“卢瑟”组合极低的收益。“稳拿”组合与中间组合（第 5 组和第 6 组的平均值）的收益差仅为 0.17%，而中间组合却比“卢瑟”组合要高出 0.94%。事实上，从 GH 值最低的那组到第 2 组，收益显著地提高了 0.69%。另一方面，对于 RR 指标，“卢瑟”组合到“稳拿”组合的收益增加显得单调而又稳健。此时，“稳拿”组合与中间组合的收益差是 0.42%，而中间组合与“卢瑟”组合的收益差则为 0.28%。这表明，RR 指标的“稳拿”组合对整体动量收益的贡献更多，尽管这种收益并不如 GH 指标那么高。

系列 B 中基于 30% 分位点的结果也是类似的。GH 指标存在动量效应的证据是显然的，但主要是来源于“卢瑟”组合较低的收益。RR 组合的动量收益同样是显著的，并且“稳拿”与“卢瑟”组合对整体的收益有非常接近的正贡献。当然，两种策略对应的 Fama-French 模型的 alpha 都显著。以上这些结果都为 52 周最高价出现时间的远近能独立预测股价收益这一事实提供了一元证据。

动量效应研究中的一个重要发现是收益率的一月效应。特别地，“卢瑟”组合被证明能在一月取得正收益，因此零成本的“稳拿”减“卢瑟”组合在剔除一月后能获得更高的收益（可参见 JT 和 GH）。为考察一月效应的影响，本文在表 2 中分别报告了一月与其他月份这两种情况下，GH 和 RR 动量策略的收益情况。结果表明，“卢瑟”组合在一月获得了非常高的正收益，导致基于 GH 和 RR 的动量策略在该月份的收益为负值。

表 2 GH 和 RR 组合的月度收益：一月和其余月份

	January only		Excluding January	
	GH	RR	GH	RR
<i>Panel A: 10 Portfolios</i>				
Low	5.36	2.97	-0.26	0.52
2	4.28	3.54	0.36	0.46
3	3.69	3.14	0.66	0.54
4	3.24	3.26	0.84	0.63
5	2.98	3.26	0.95	0.74
6	2.62	3.17	1.05	0.84
7	2.48	3.24	1.08	0.96
8	2.22	2.81	1.16	1.11
9	2.01	2.63	1.22	1.24
High	1.93	2.15	1.27	1.35
H - L	-3.43	-0.82	1.53	0.84
	(-2.32)	(-0.89)	(5.98)	(5.03)
Fama-French alpha	-1.47	-0.50	1.61	0.96
	(-1.05)	(-0.49)	(8.15)	(5.95)
<i>Panel B: 3 Portfolios</i>				
L	4.44	3.44	0.25	0.50
2	2.83	3.24	0.98	0.80
H	2.07	2.55	1.22	1.22
H - L	-2.37	-0.89	0.97	0.72
	(-2.62)	(-1.87)	(5.81)	(5.69)
Fama-French alpha	-0.84	-0.27	1.04	0.83
	(-1.01)	(-0.46)	(7.73)	(6.76)

In each month t from January 1965 to December 2008, stocks listed on NYSE, AMEX, and Nasdaq are sorted into 10 portfolios for Panel A results and 3 portfolios (with top and bottom obtained using 30% cutoffs) for Panel B results based on the ratio of current price to 52-week high price (GH) and the recency ratio (RR). The recency ratio captures the recency of 52-week high price and equals $[1 - (\text{current date} - \text{date of 52-week high})/364]$. We exclude stocks with price less than \$5 or with market capitalization below the NYSE smallest decile market capitalization cutoff at the end of the portfolio formation month t . The table reports the average monthly returns from month $t + 2$ month $t + 7$, the return differences of extreme portfolios, and the corresponding alphas from the Fama-French three-factor model, separately for January and non-January months. The returns are in percent. The t -statistics are reported in parentheses and are adjusted for autocorrelation using the Newey and West (1987) method.

资料来源：“The timing of 52-week high price and momentum”

由于剔除了“卢瑟”组合在一月份巨大的正收益，而“稳拿”组合不论是否包含一月都保持接近的收益表现，使得其余月份的动量效应得到了增强。在以 10% 选取标准时，GH 策略产生的月度收益是 1.53%，Fama-French 模型的 alpha 是 1.61%，而 RR 策略的月度收益和 alpha 分别是 0.84% 和 0.96%。对比表 1 的结果可以发现，一月效应对 GH 策略的影响更大，剔除一月之后，“卢瑟”组合的月度收益迅速下降到 -0.26%，而全月份时的值为 0.21%。而对于 RR，剔除一月后的“卢瑟”组合，每月能获得 0.52% 的收益，而不剔除时则为 0.72%。系列 B 中以 30% 为选取标准的结果也有相同的规律。GH 策略在不包含一月时的收益为 0.97%（ t 统计量=5.81），Fama-French 模型的 alpha 是 1.04%（ t 统计量=7.73），而 RR 策略的这两个值分别为 0.72%（ t 统计量=5.69）和 0.83%（ t 统计量=6.76）。

3.2 描述性统计量

表 3 报告的是 GH 和 RR 指标间的相关性以及基于这两个指标构建的投资组合的某些特征，包括市值的对数，价格，过去 6 个月的累计收益（JT 指标），过去 6 个月市值加权的行业收益（MG 指标）。相关性的均值（中位数）为 0.56（0.57），是由截面相关系数的时间序列计算得到的，且序列的最大、最小值分别为 0.73 和 0.04。正的相关性是可以预期的，因为如果某个股票正在以接近 52 周最高价的价格进行交易，那么它很有可能在近期才达到这一最高价。不过，正如表 1 和表 2 所展示的，这两个指标似乎捕捉到了 52 周最高价在动量效应中的不同信息，并且各自都能独立地预测未来的收益。

表 3 相关系数和描述性统计量

Mean		Median		Minimum		Maximum		
Panel A: Correlation coefficients								
0.56		0.57		0.04		0.73		
Size		Price		JT		MG		
GH	RR	GH	RR	GH	RR	GH	RR	
Panel B: Summary Statistics								
Low	13.98	14.46	22.42	32.63	-8.25	-3.17	3.77	4.24
2	14.65	14.56	40.83	41.61	11.87	6.08	5.52	5.16
High	14.86	14.68	60.86	49.67	28.89	31.55	7.33	7.34
H - L	0.88	0.22	38.45	17.04	37.14	34.72	3.56	3.10
	(31.89)	(7.07)	(16.49)	(7.36)	(56.93)	(41.17)	(26.44)	(25.07)

In each month t from January 1965 to December 2008, we compute the cross-sectional correlations between GH and RR measures and report the mean, median, minimum, and maximum of cross-sectional correlations in Panel A. Panel B reports the average values of log market capitalization (Size), price, JT (buy and hold returns in percentage over prior 6-month period), and MG (value-weighted buy and hold industry return in percent over prior 6-month period) for three portfolios (with top and bottom obtained using 30% cutoffs) based on GH and RR measures, along with difference in values for extreme portfolios. We exclude stocks with price less than \$5 or with market capitalization below the NYSE smallest decile market capitalization cutoff at the end of the portfolio formation month t . The t -statistics are reported in parentheses and are adjusted for autocorrelation using the Newey and West (1987) method.

资料来源：“The timing of 52-week high price and momentum”

从系列 B 中可以看到，基于 GH 和 RR 指标的“卢瑟”组合有着更小的规模和更低的平均股价，这也一如预期。然而，和 RR 的组合相比，GH 组合之间的规模和股价差异很大。这两个指标和 JT 以及 MG 指标之间同样具有正的相关性。而且，基于这两个指标的“卢瑟”组合在构建日之前的 6 个月内收益率为负，但“稳拿”组合却有着很高的正收益。

为了更好地帮助理解“近期比例”与 52 周最高价出现以来的天数这两者之间的关系，本文在图 1 中画出了每一个 RR 的组别内，所有股票创 52 周新高以来天数的平均值（四舍五入取整）。对于“近期比例”最高的第 10 组，平均来说，52 周最高价仅发生在组合构建日的 9 天前；而另一方面，“近期比例”最低的第 1 组，52 周最高价大约发生在构建日的 341 天前，这几乎已经是 52 周这个考察周期的开始日。以上分析表明，52 周最高价的发生时间在本文的样本股中确实存在极大的差异，而利用好这些信息确实能有效地提高策略的收益表现。

图 6 达到 52 周最高价以来的平均天数




Fig. 1. Average Number of Days since 52-Week High Price for Recency Ratio Decile Portfolios. In each month t from January 1965 to December 2008, stocks listed on NYSE, AMEX, and Nasdaq are sorted into decile portfolios based on the recency ratio. The recency ratio captures the recency of 52-week high price and equals $[1 - (\text{current date} - \text{date of 52-week high})/364]$. We exclude stocks with price less than \$5 or with market capitalization below the NYSE smallest decile market capitalization cutoff at the end of the portfolio formation month t . The figure shows the average number of days since 52-week high price was attained for each of 10 recency ratio portfolios (1 - lowest recency ratio; 10 - highest recency ratio).

资料来源：“The timing of 52-week high price and momentum”

3.3 GH 动量策略中“近期比例”的角色

上文详细介绍了 GH 和 RR 指标单独形成一个动量策略的收益表现。下一个目标就是考察将这两种策略融合之后会产生什么效果，即同时考虑 52 周最高价与当前价格的比例关系和时间距离。换句话说，下文想要考察的是，在以当前价格与 52 周最高价的接近程度为基础的动量收益中，最高价发生时间的远近究竟扮演了怎样的角色。在以下

的实证检验中，本文根据 GH 和 RR 指标独立地对样本股进行排序并各自分成 3 组，然后考察这 9 个组别的收益情况。考虑到 GH 和 RR 指标之间较高的相关性，选择各分成 3 组可以保证组内有充分多的股票来接近这两个指标相互独立的假设。这些检验的结果在表 4 中予以展示。在每个 RR 组合（低、中、高）内，本文给出了 GH 的“稳拿”与“卢瑟”组合的收益，以及两者之间的差与对应的 Fama-French 模型的 alpha。

表 4 GH 动量策略的月度收益：控制“近期偏好”

RR measure	GH measure	Average monthly return	Average monthly return excluding January
Low	Winner	1.00 [0.94]	0.91
	Loser	0.59 [0.63]	0.23
	Winner-Loser	0.41	0.68
		(2.52)	(3.98)
	Fama-French alpha	0.63	0.78
		(5.11)	(6.54)
Middle	Winner	1.20 [0.94]	1.13
	Loser	0.68 [0.67]	0.34
	Winner-Loser	0.52	0.79
		(2.94)	(4.64)
	Fama-French alpha	0.69	0.85
		(5.51)	(7.25)
High	Winner	1.37 [0.96]	1.30
	Loser	0.54 [0.71]	0.29
	Winner-Loser	0.83	1.01
		(4.19)	(4.88)
	Fama-French alpha	1.01	1.07
		(5.78)	(5.90)
High (Winner-Loser) – Low (Winner-Loser)	Raw return	0.42	0.33
		(3.57)	(2.78)
	Fama-French alpha	0.38	0.30
		(2.04)	(1.89)

In each month t from January 1965 to December 2008, stocks listed on NYSE, AMEX, and Nasdaq are independently sorted into three portfolios (Low, Middle, and High with Low and High obtained using 30% cutoffs) based on GH and RR. GH is the ratio of current price to 52-week high price, and RR is the recency ratio that equals $[1 - (\text{current date} - \text{date of 52-week high})/364]$. We exclude stocks with price less than \$5 or with market capitalization below the NYSE smallest decile market capitalization cutoff at the end of the portfolio formation month t . For each of the three RR portfolios, the table reports the average monthly returns of GH winner and loser portfolios from month $t+2$ month $t+7$, and the return differences of extreme portfolios along with the corresponding Fama-French alphas, separately for January and non-January months. The differences in returns and alphas of (winner-loser) portfolios across High and Low RR portfolios are reported in the last row. The numbers in square brackets are the average values of GH measure for the associated portfolios. The returns are in percent. The t -statistics are reported in parentheses and are adjusted for autocorrelation using the Newey and West (1987) method.

资料来源：“The timing of 52-week high price and momentum”

检验表明，基于当前价格和 52 周最高价接近程度的 GH 动量策略强烈地依赖于这一最高价的发生时间。正如表 4 中展示的那样，那些“近期比例”最低的 30% 股票，其 GH 动量策略的平均月度收益为 0.41%（ t 统计量=2.52），Fama-French 模型的 alpha 为 0.63%（ t 统计量=5.11）。对于 RR 取值位于上、下 30% 分位点之间的组合，策略的收益（Fama-French 模型的 alpha）上升到 0.52%（0.69%）。最后，对于“近期比例”最高的那 30%，GH 动量策略的收益进一步上升到 0.83%（ t 统计量=4.19），Fama-French 模型的 alpha 为 1.01%（ t 统计量=5.78）。由此可见，那些最近才达到 52 周最高价的股票，其 GH 动量策略的原始收益是那些最高价出现在很久之前的股票的 2 倍，并且这种差距在统计意义上是显著的。表格中还报告了剔除一月收益后的结果。和前文相同，策略收益在不包含一月的月份中都显得更高一些。但三个组合收益率的大小顺序依然没有发生改变：RR 最低的组合，其 GH 动量策略的收益（Fama-French 模型的 alpha）为 0.68%（0.78%），而最高组合则为 1.01%（1.07%）。

表 4 还报告了 GH 指标的均值（方括号中）。显然，在每个 RR 组合内部，“稳拿”和“卢瑟”的 GH 指标并没有显著的差异。如果有，就是“卢瑟”组合的 GH 指标从 RR 最低的组合向最高组合移动的过程中逐渐增大。而对于“稳拿”组合，GH 指标只不过在 RR 最高的组合中略微大一些。由此可见，3 个 RR 组合收益率的差别，并不是由 GH 指标的不同所造成的。总体说来，表 4 中的证据充分说明 GH 动量策略的收益可通过加入 52 周最高价出现时间的远近这一条件来显著增强。

3.4 Fama-MacBeth 截面回归

在通过组合层面的检验确立了 52 周最高价出现时间的重要性后，下文将正式使用 Fama-MacBeth 截面回归检验“近期比例”的预测能力。回归方法提供了一个便捷的机制以同时比较不同动量策略的收益表现。首先，本文确认 GH 提出的以 52 周最高价为基础的动量策略全面优于 JT 和 MG 的模型。具体的回归方程有如下形式（ $j=2$ 至 7，构建期与持有期之间有一个月的间隔）：

$$R_{i,t} = b_{0jt} + b_{1jt} R_{i,t-1} + b_{2jt} \text{Size}_{i,t-1} + b_{3jt} \text{JTH}_{i,t-j} + b_{4jt} \text{JTL}_{i,t-j} + b_{5jt} \text{MGH}_{i,t-j} + b_{6jt} \text{MGL}_{i,t-j} + b_{7jt} \text{GHH}_{i,t-j} + b_{8jt} \text{GHL}_{i,t-j} + e_{it} \quad (3)$$

这里， $R_{i,t}$ 是第*i*个票在*t*月的收益率，Size是个股在前一个月末市值的自然对数，JTH(JTL)是一个哑变量，它等于1表示，该股票*t-j*月之前6个月的累计收益位于前(后)30%；否则，它等于0。MGH(MGL)同样是一个哑变量，如果它等于1，表示这个股票所处的行业在过去6个月的市值加权行业收益排名中位于前(后)30%；否则，该哑变量等于0。GHH(GHL)这个哑变量等于1，代表个股属于GH指标最大(小)的30%；否则它等于0。考虑到短期收益率的反转现象，本文还在模型中引入了过去一个月的收益， $R_{i,t-1}$ 。

对于某个*t*，本文拟合6个截面回归($j=2$ 至7)，并求对应系数估计的均值。哑变量的回归系数代表在对冲掉回归模型中其他控制变量的效应后，“稳拿”与“卢瑟”组合超越截距部分的收益。这样，每个月6个系数估计的均值就提供了对应组合在当月的收益。“稳拿”与“卢瑟”组合的原始收益在下表中给出，它是通过对月度收益的时间序列求均值得到的。对每个组合，Fama-French模型的alpha是通过组合的月度收益对同期的市场收益、规模(SMB)，账面-市值比(HML)这三个因子建立时间序列回归得到的。

表5 Fama-MacBeth 截面回归：GH 的重复

		Raw return		Fama-French alphas	
		January incl.	January excl.	January incl.	January excl.
(1)	Intercept	2.25 (4.02)	1.85 (3.39)	0.61 (2.39)	0.48 (1.93)
(2)	$R_{i,t-1}$	-3.28 (-7.89)	-3.12 (-7.68)	-2.94 (-7.17)	-2.56 (-6.16)
(3)	$\text{Size}_{i,t-1}$	-0.09 (-2.50)	-0.06 (-1.71)	-0.00 (-0.18)	0.00 (0.60)
(4)	JTH	0.16 (1.69)	0.16 (1.74)	0.17 (2.61)	0.17 (2.49)
(5)	JTL	-0.08 (-2.11)	-0.11 (-1.88)	-0.11 (-2.40)	-0.12 (-2.70)
(6)	MGH	0.08 (1.17)	0.08 (1.10)	0.05 (0.97)	0.05 (0.81)
(7)	MGL	-0.08 (-1.20)	-0.09 (-1.35)	-0.06 (-1.07)	-0.08 (-1.21)
(8)	GHH	0.07 (1.46)	0.09 (1.91)	0.13 (3.87)	0.17 (5.02)
(9)	GHL	-0.46 (-5.16)	-0.48 (-5.28)	-0.50 (-7.12)	-0.60 (-8.60)
(8)-(9)	GHH-GHL	0.53 (4.10)	0.57 (4.36)	0.63 (6.72)	0.76 (8.31)

In each month *t* from January 1965 to December 2008, six ($j=2, \dots, 7$) cross-sectional regressions of the following form are estimated for stocks listed on NYSE, AMEX, and Nasdaq: $R_{i,t} = b_{0jt} + b_{1jt} R_{i,t-1} + b_{2jt} \text{Size}_{i,t-1} + b_{3jt} \text{JTH}_{i,t-j} + b_{4jt} \text{JTL}_{i,t-j} + b_{5jt} \text{MGH}_{i,t-j} + b_{6jt} \text{MGL}_{i,t-j} + b_{7jt} \text{GHH}_{i,t-j} + b_{8jt} \text{GHL}_{i,t-j} + e_{it}$. $R_{i,t}$ and $\text{Size}_{i,t}$ are the return and log (market capitalization) of stock *i* in month *t*. JTH (JTL) is a dummy variable that equals 1 for 30% of the stocks with largest (smallest) 6-month cumulative returns at the end of month *t-j*, and is 0 otherwise. MGH (MGL) is a dummy variable that equals 1 if the stock belongs to top (bottom) 30% of the industries based on their 6-month value-weighted industry returns at the end of month *t-j*, and is 0 otherwise, and GHH (GHL) is a dummy variables that equals 1 for 30% of the stocks with largest (smallest) GH measure at the end of month *t-j*, and is 0 otherwise. The coefficients from six regressions are averaged each month and the time-series mean of these averages is reported as the raw return. The Fama-French alphas are obtained from the time-series regressions of each of the individual monthly coefficient estimates on the contemporaneous Fama-French factors. We exclude stocks with price less than \$5 or with market capitalization below the NYSE smallest decile market capitalization cutoff at the end of the month *t-2*. The *t*-statistics are reported in parentheses and are adjusted for autocorrelation using the Newey and West (1987) method.

资料来源：“The timing of 52-week high price and momentum”

表5给出的是上述回归模型的具体估计结果，在所有月份和剔除一月这两种情况下报告了原始收益与Fama-French模型的alpha。这一结果确认了短期反转效应的存在性：过去一个月收益率的系数为负值且非常显著地区别于零。规模和收益之间相反的关系同样在模型中得到证明。至于其他动量策略，本文发现了基于JT指标的“稳拿”组合存在动量收益的证据，而这一现象在“卢瑟”组合中体现得更为明显。MG指标的“稳拿”与“卢瑟”组合都有着正确的符号，但在其他指标存在时并不显著。基于GH指标的“稳拿”组合有着较弱的正收益，在剔除一月后于10%的水平下显著，而Fama-French模型的alpha则在5%的水平下显著。基于GH指标的“卢瑟”组合获得了-0.46%的原始收益，对应的Fama-French模型的alpha是-0.50%，两者都在统计意义上非常显著。GH的“稳拿”与“卢瑟”组合在收益率上的这种不对称性在前文的一元检验中也已体现。总体说来，基于GH策略的“稳拿”减“卢瑟”的对冲组合每月能获取0.63% (*t*统计量=6.72)的收益。这些结果和GH记录的完全一致，进一步确认了GH策略优于JT和MG的动量模型。

为了检验“近期比例”在动量收益中扮演的角色，本文用基于该指标的“稳拿”与“卢瑟”组合代替 GH，得到如下形式的回归方程：

$$R_{i,t} = b_{0jt} + b_{1jt} R_{i,t-1} + b_{2jt} \text{Size}_{i,t-1} + b_{3jt} \text{JTH}_{i,t-j} + b_{4jt} \text{JTL}_{i,t-j} + b_{5jt} \text{MGH}_{i,t-j} + b_{6jt} \text{MGL}_{i,t-j} + b_{7jt} \text{RRH}_{i,t-j} + b_{8jt} \text{RRL}_{i,t-j} + e_{it} \quad (4)$$

这里，RRH(RRL)是一个哑变量，如果股票来自于 t-j 月月末“近期比例”最高（低）的 30%，那么它等于 1；否则等于零。

这个回归模型的结果在表 6 中报告。由于“卢瑟”组合显著较弱的收益，JT 指标的动量效益依然十分强烈。而 MG “稳拿”与“卢瑟”的系数还是不显著，一如前文所述。对于“近期比例”，本文找到了动量效应同时存在于“稳拿”与“卢瑟”组合的证据。“稳拿”组合的原始收益为 0.12%，在 10%的水平下显著。但当一月被剔除后，显著性得到了大大地提升。而 Fama-French 模型的 alpha 不管是否包含一月都在 5%的水平下显著。RR “卢瑟”组合获得的原始收益是-0.19%，Fama-French 模型的 alpha 是-0.26%。显然，“卢瑟”组合收益的绝对值更大，而且原始收益和 alpha 在 5%的水平下都显著，不论是否包含一月收益。RR “稳拿”减“卢瑟”组合能获得 0.30%（t 统计量=4.20）的收益，Fama-French 模型的 alpha 等于 0.41%，同样有极高的显著性（t 统计量=6.06）。总而言之，截面回归的证据确认了即使 JT 和 MG 指标存在，基于 52 周最高价出现时间远近的策略也能获取动量收益。

表 6 Fama-MacBeth 截面回归：“近期比例”的角色

		Raw returns		Fama-French alphas	
		January incl.	January excl.	January incl.	January excl.
(1)	Intercept	2.01 (3.58)	1.64 (2.89)	0.33 (1.28)	0.14 (0.57)
(2)	R_{it-1}	-3.32 (-8.31)	-3.15 (-7.90)	-2.89 (-6.93)	-2.51 (-5.95)
(3)	$\text{Size}_{i,t-1}$	-0.07 (-1.98)	-0.04 (-1.29)	0.03 (0.99)	0.03 (1.22)
(4)	JTH	0.14 (1.99)	0.17 (1.94)	0.17 (2.54)	0.17 (2.51)
(5)	JTL	-0.26 (-4.06)	-0.30 (-4.31)	-0.31 (-4.49)	-0.37 (-5.57)
(6)	MGH	0.07 (1.06)	0.06 (0.92)	0.05 (0.84)	0.05 (0.68)
(7)	MGL	-0.08 (-1.25)	-0.09 (-1.31)	-0.07 (-1.13)	-0.09 (-1.32)
(8)	RRH	0.12 (1.89)	0.14 (3.27)	0.15 (3.70)	0.18 (4.58)
(9)	RRL	-0.19 (-2.96)	-0.17 (-2.52)	-0.26 (-4.81)	-0.27 (-4.78)
(8)-(9)	RRH - RRL	0.30 (4.20)	0.31 (4.05)	0.41 (6.06)	0.45 (6.57)

In each month t from January 1965 to December 2008, six ($j = 2, \dots, 7$) cross-sectional regressions of the following form are estimated for stocks listed on NYSE, AMEX, and Nasdaq: $R_{it} = b_{0jt} + b_{1jt} R_{i,t-1} + b_{2jt} \text{Size}_{i,t-1} + b_{3jt} \text{JTH}_{i,t-j} + b_{4jt} \text{JTL}_{i,t-j} + b_{5jt} \text{MGH}_{i,t-j} + b_{6jt} \text{MGL}_{i,t-j} + b_{7jt} \text{RRH}_{i,t-j} + b_{8jt} \text{RRL}_{i,t-j} + e_{it}$. R_{it} and $\text{Size}_{i,t}$ are the return and log (market capitalization) of stock i in month t . JTH (JTL) is a dummy variable that equals 1 for 30% of the stocks with largest (smallest) 6-month cumulative returns at the end of month $t-j$, and is 0 otherwise. MGH (MGL) is a dummy variable that equals 1 if the stock belongs to top (bottom) 30% of the industries based on their 6-month value-weighted industry returns at the end of month $t-j$, and is 0 otherwise. and RRH (RRL) is a dummy variables that equals 1 for 30% of the stocks with largest (smallest) recency ratio at the end of month $t-j$, and is 0 otherwise. The coefficients from six regressions are averaged each month and the time-series mean of these averages is reported as the raw return. The Fama-French alphas are obtained from the time-series regressions of each of the individual monthly coefficient estimates on the contemporaneous Fama-French factors. We exclude stocks with price less than \$5 or with market capitalization below the NYSE smallest decile market capitalization cutoff at the end of the month $t-2$. The t -statistics are reported in parentheses and are adjusted for autocorrelation using the Newey and West (1987) method.

资料来源：“The timing of 52-week high price and momentum”

本文的最后一个目标是检验“近期比例”在 GH 动量策略中的增强效应。为此，拟合如下的回归模型：

$$\begin{aligned}
 R_{i,t} = & b_{0jt} + b_{1jt} R_{i,t-1} + b_{2jt} Size_{i,t-1} + b_{3jt} JTH_{i,t-j} + b_{4jt} JTL_{i,t-j} \\
 & + b_{5jt} MGH_{i,t-j} + b_{6jt} MGL_{i,t-j} + b_{7jt} GHH_{i,t-j} + b_{8jt} GHL_{i,t-j} \\
 & + b_{9jt} RRH_{i,t-j} + b_{10jt} RRL_{i,t-j} + b_{11jt} RRH_{i,t-j} * GHH_{i,t-j} \\
 & + b_{12jt} RRH_{i,t-j} * GHL_{i,t-j} + b_{13jt} RRL_{i,t-j} * GHH_{i,t-j} \\
 & + b_{14jt} RRL_{i,t-j} * GHL_{i,t-j} + e_{it}
 \end{aligned} \quad (5)$$

在上面这个方程中，交互效应项 $RRH * GHH$ 等于 1 表明个股同时属于 RR 和 GH 指标的“稳拿”组合；否则该项等于零。 $RRH * GHL$ 等于 1 表明个股属于 RR “稳拿”和 GH “卢瑟”。其余两个交互项有着类似的解释与推断。本文研究的焦点在于这些交互效应项的系数估计，因为它们有助于评估“近期比例”这一指标对以当前价格与 52 周最高价接近程度为基础的动量策略收益的影响程度。

表 7 Fama-MacBeth 截面回归：“近期比例”在 GH 动量策略中的角色

		Raw returns		Fama-French alphas	
		January incl.	January excl.	January incl.	January excl.
(1)	Intercept	2.28 (4.25)	1.49 (2.84)	0.65 (2.68)	0.52 (2.19)
(2)	$R_{i,t-1}$	-3.47 (-8.68)	-2.83 (-7.21)	-3.00 (-7.51)	-2.63 (-6.49)
(3)	$Size_{i,t-1}$	-0.09 (-2.56)	-0.03 (-0.99)	-0.01 (-0.30)	0.01 (0.50)
(4)	JTH	0.13 (1.71)	0.11 (1.44)	0.14 (2.19)	0.13 (2.01)
(5)	JTL	-0.11 (-3.17)	-0.10 (-2.67)	-0.12 (-2.70)	-0.13 (-2.91)
(6)	MGH	0.07 (1.19)	0.06 (0.95)	0.05 (0.96)	0.05 (0.88)
(7)	MGL	-0.06 (-1.13)	-0.08 (-1.32)	-0.06 (-1.04)	-0.07 (-1.17)
(8)	GHH	0.00 (0.21)	0.07 (1.49)	0.07 (2.38)	0.12 (3.50)
(9)	GHL	-0.38 (-4.46)	-0.50 (-5.07)	-0.43 (-6.11)	-0.53 (-7.35)
(10)	RRH	0.01 (0.25)	0.03 (0.59)	0.03 (0.78)	0.05 (1.16)
(11)	RRL	-0.12 (-2.24)	-0.13 (-2.20)	-0.16 (-3.63)	-0.16 (-3.29)
(12)	$RRH * GHH$	0.08 (1.96)	0.07 (1.81)	0.05 (1.73)	0.05 (1.57)
(13)	$RRH * GHL$	-0.36 (-3.80)	-0.31 (-3.11)	-0.32 (-2.95)	-0.28 (-2.46)
(14)	$RRL * GHH$	-0.06 (-1.40)	-0.07 (-1.61)	-0.04 (-1.01)	-0.05 (-1.34)
(15)	$RRL * GHL$	0.03 (0.56)	0.01 (0.20)	-0.01 (-0.30)	-0.01 (-0.46)
(16) = (12) - (13)		0.44 (4.54)	0.38 (3.79)	0.38 (3.44)	0.33 (2.89)
(17) = (14) - (15)		-0.09 (-1.16)	-0.08 (-0.96)	-0.03 (-0.36)	-0.04 (-0.42)
(16) - (17)		0.52 (4.51)	0.46 (3.77)	0.41 (3.19)	0.37 (2.74)

In each month t from January 1965 to December 2008, six ($j = 2, \dots, 7$) cross-sectional regressions of the following form are estimated for stocks listed on NYSE, AMEX, and Nasdaq: $R_{i,t} = b_{0jt} + b_{1jt} R_{i,t-1} + b_{2jt} Size_{i,t-1} + b_{3jt} JTH_{i,t-j} + b_{4jt} JTL_{i,t-j} + b_{5jt} MGH_{i,t-j} + b_{6jt} MGL_{i,t-j} + b_{7jt} GHH_{i,t-j} + b_{8jt} GHL_{i,t-j} + b_{9jt} RRH_{i,t-j} + b_{10jt} RRL_{i,t-j} + b_{11jt} RRH_{i,t-j} * GHH_{i,t-j} + b_{12jt} RRH_{i,t-j} * GHL_{i,t-j} + b_{13jt} RRL_{i,t-j} * GHH_{i,t-j} + b_{14jt} RRL_{i,t-j} * GHL_{i,t-j} + e_{it}$. $R_{i,t}$ and $Size_{i,t}$ are the return and log (market capitalization) of stock i in month t . JTH (JTL) is a dummy variable that equals 1 for 30% of the stocks with largest (smallest) 6-month cumulative returns at the end of month $t - j$, and is 0 otherwise. MGH (MGL) is a dummy variable that equals 1 if the stock belongs to top (bottom) 30% of the industries based on their 6-month value-weighted industry returns at the end of month $t - j$, and is 0 otherwise. GHH (GHL) is a dummy variable that equals 1 for 30% of the stocks with largest (smallest) GH measure at the end of month $t - j$, and is 0 otherwise. RRH (RRL) is a dummy variable that equals 1 for 30% of the stocks with largest (smallest) recency ratio at the end of month $t - j$, and is 0 otherwise. The coefficients from six regressions are averaged each month and the time-series mean of these averages is reported as the raw return. The Fama-French alphas are obtained from the time-series regressions of each of the individual monthly coefficient estimates on the contemporaneous Fama-French factors. We exclude stocks with price less than \$5 or with market capitalization below the NYSE smallest decile market capitalization cutoff at the end of the month $t - 2$. The t -statistics are reported in parentheses and are adjusted for autocorrelation using the Newey and West (1987) method.

资料来源：“The timing of 52-week high price and momentum”

上述回归的估计结果在表 7 中展示， JT 和 MG 两个指标的“稳拿”与“卢瑟”的系数和表 5 类似。对于 GH ，“稳拿”系数中只有 Fama-French 模型的 α 显著，而“卢瑟”却有着显著小于零的原始收益和 α 。“近期比例”“卢瑟”组合的系数显著，但“稳拿”组合并非如此。

关注交互项可以发现， $RRH * GHH$ 项的系数均为正，而且除了不含一月的 Fama-French 模型的 α 外，其余都在 10% 的水平下显著。 $RRH * GHL$ 这一项的原始收益和 Fama-French 模型的 α ，不论是否包含一月的收益，其系数都为负值且高度显著。 $RRH * GHH$ 和 $RRH * GHL$ 的原始收益系数差为 0.44%， t 统计量是 4.54，Fama-French 模型的 α 差是 0.38%， t 统计量是 3.44。这一证据支持前文的论断，

即，对那些当前价格接近 52 周最高价，且该最高价是在近期达到的股票（表明存在利好消息），投资者以超越最高价的价格追逐的意愿非常低。另一方面，如果某个股票的当前价格远低于 52 周最高价（ $GHL=1$ ）但最高价却是出现在近期，表明该股票的股价在短期内正经历从 52 周最高价急剧下跌的过程。此时，投资者同样不愿以更低的价格卖出，即使有确定性的负面信息使股价在未来继续下跌。不论是以上哪一种情况，价格趋势的延续都来源于投资者对信息的反应不足。而这种反应不足是由“锚定和调整偏好”造成的，并且进一步由“近期偏好”增强。

重要的是，两个含有 RR “卢瑟”的交互项—— $RRL*GHH$ 和 $RRL*GHL$ 都没有系数显著的证据。而这两项之间的系数差同样是不显著的 -0.09%。这表明，近期才达到 52 周最高价的股票（ $RRH=1$ ），其动量效应要明显地高于那些 52 周最高价出现在很久之前的股票。这种差异正是体现了“近期比例”对动量策略有显著的加成作用。特别地，分析结果再次确认了 52 周最高价出现时间的远近在 GH 动量策略收益中扮演的重要角色。

有趣的是，和表 6 的结果一样，不论是原始收益还是 Fama-French 模型的 α ， RRL 本身的系数继续保持负值且显著。另一方面， RRH 的系数则并不显著。这一证据表明，那些在很久之前达到 52 周最高价的股票继续在未来上演着糟糕的表现，即使是对 GH 取值位于中段的那部分（ $GHH=0$ 且 $GHL=0$ 的股票）。由此可见，RR “卢瑟”的预测能力并不依赖于当前价格是否接近 52 周最高价。而基于交互项系数的证据清楚地说明了“近期偏好”所扮演的增强角色，这种 RRH 和 RRL 上系数的不对称性让人感到困惑，值得深入研究。

4. 总结

本文找到了一个零成本的投资策略，即持有近期达到 52 周最高价的股票作为多头头寸，很久之前出现 52 周最高价的股票作为空头头寸，最终获得了统计意义上显著的收益。加入 52 周最高价出现时间的远近这一条件，对 George 和 Hwang 在 2004 年提出的基于当前价格与 52 周最高价接近程度的动量策略也有着显著的影响。对于那些在近期达到 52 周最高价的股票，这一策略所能获得的收益，是那些很久之前出现 52 周最高价股票的 2 倍之多。本文认为，这些结果归因于“锚定和调整偏好”带来的投资者的

聚类方法在组合构建中的应用

作者: Zhiwei Ren, Worcester Polytechnic Institute, Portfolio Construction Using Clustering Methods, Worcester Polytechnic Institute 2005.05.

推荐人: 张欣慰 021-23219370

推荐理由: 均值一方差模型在组合构建中被广泛运用, 实际操作中常用重抽样和贝叶斯方法来降低估计误差对组合权重的影响。众所周知, 估计股票间的相关性比估计期望收益要简单的多, 本文用聚类法来改进均值一方差模型, 更多的利用了协方差矩阵的信息而淡化了预期收益的信息, 优化后组合的稳定性和表现都得到了提高。

一直以来, 人们对传统均值一方差模型最大的诟病就是对估计误差非常敏感, 微小的估计误差往往会导致构建组合的严重扭曲。

为了解决这个问题, 人们通常采用重抽样或者 Black-Litterman 方法。聚类法是解决这一问题的新方法, 聚类法简单来说就是把高度相关的股票分为一组, 然后将这一组股票作为看做一只股票来处理。当我们将股票分好组后, 我们对各组股票进行传统的均值一方差分析, 聚类法能提高组合的稳定性, 降低估计误差带来的影响。本文我们将会探讨为什么聚类方法有效, 是否聚类方法能够提高均值一方差模型的稳定性、提高构件组合的收益。

一、均值一方差组合优化模型的主要问题

均值一方差模型最大的问题就是对估计误差非常敏感, 该优化模型对输入的预期收益均值以及协方差矩阵依赖性很高, 而且经常导致选出的股票分散度不够, 这也是为什么 Markowitz 理论在组合管理中未被广泛应用的原因。

为了解决这个问题, 人们通常采用重抽样或者 Black-Litterman 方法。

重抽样法以股票的历史价格为样本空间生成价格数据, 然后以模拟的价格数据来构建组合。重抽样法生成的组合有较之原方法构建的组合有更分散和更稳定的优势。然而, 重抽样方法也存在以下一些缺陷:

1、对于大量股票数据的处理, 电脑将会面临很重的负荷;

2、原始输入数据的局部估计误差会影响最终的资产分配结果;

3、不是基于经济学原理的;

4、隐含假设了投资者放弃了效用最大化的研究框架, 此外, 如果你有一个业绩基准, 该方法可能会带来意想不到的风险。

Bayesian 资产配置模型又称为 Black-Litterman 模型, 该方法的背后逻辑是在定量分析的基础上结合一些基本面分析的内容, 他引进了一个新的变量: 基金经理的观点。实战中, Black-Litterman 模型取得了更好的收益和稳定性。

相比于之前的两种方法, 聚类方法是一个更精致的方法, 聚类方法的主要思想来源如下:

1、组合优化在一些不相关、负相关或者低相关性的股票间进行通常会获得更分散、表现更优异的组合。我们这里禁止卖空交易, 对于绝大多数的共同基金和养老基金都适

用。

2、有一些股票的相关性非常高，例如 UPS 和 Fedex，Ford 和 GM，将这些股票作为一只股票看待或许更好。

3、我们将高相关性的股票分组后，各组之间的股票将会大大降低。将各组的股票作为一个股票来处理，则这些股票将有较低的相关性。

4、预测未来收益比预测相关性难度要大很多。

总结起来，聚类方法在组合优化中的运用主要分以下两步：

- 1、将高相关性的股票归类分组；
- 2、将各组股票视为个体，运用均值一方差模型来获取个股的投资权重。

二、聚类方法

组合管理中的两个最重要的统计量是期望回报和协方差矩阵，通常我们通过历史数据来估计这两个参数，由于这两个统计量是估计的，所以不免存在估计误差。

许多的研究表明：估计股票间的相关性比估计期望收益要简单的多。协方差矩阵的估计比预期收益的估计要稳定和可靠的多。所以在组合构建时我们希望更多的利用协方差的信息，而尽量少用期望收益率的信息，我们希望利用更好、跟准确的信息去构建组合。

多利用协方差信息、少利用预期收益信息意味着新构建的组合将对协方差的变动较为敏感，而对预期收益的变动没有那么敏感，聚类方法使得组内股票具有高相关性，组间股票有低相关性。对聚类后的股票组运用均值一方差模型，能够降低预期收益对组合构建的影响，我们以一个两个股票构成的简单组合来说明。

我们有两个股票，预期收益分别为 μ_1 和 μ_2 ，协方差矩阵是 $C = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix}$

风险厌恶系数是 λ ，那么均值一方差模型下的最优权重分配是：

$$h_1 = \lambda \frac{\mu_1 \sigma_{22} - \mu_2 \sigma_{12}}{\sigma_{11} \sigma_{22} - \sigma_{12} \sigma_{21}}$$

$$h_2 = \lambda \frac{\mu_1 \sigma_{21} - \mu_2 \sigma_{11}}{\sigma_{11} \sigma_{22} - \sigma_{12} \sigma_{21}}$$

其中 $\sigma_{12} = \sigma_{21}$ ， $\sigma_{12} = \rho_{12} \sqrt{\sigma_{11} \sigma_{22}}$ 并且 $\sigma_{ii} \geq 0$

为了衡量组合权重对预期收益的敏感性，我们将权重对预期收益求偏导数：

$$\frac{\partial h_1}{\partial \mu_1} = \lambda \frac{\sigma_{22}}{\sigma_{11} \sigma_{22} - \sigma_{12} \sigma_{21}} = \lambda \frac{1}{\sigma_{11}(1 - \rho_{12}^2)}$$

h_1 是股票 1 的权重， μ_1 是股票 1 的预期收益率， ρ_{12} 是股票 1 和股票 2 之间的相关系数， λ 是投资者的风险厌恶系数。很显然，要降低股票 1 权重对预期收益率 μ_1 的敏感性， ρ_{12} 的绝对值越小越好，这也是为什么我们用聚类方法将股票分组，使得组内股票高度相关，而组间股票相关性很低。

聚类方法的操作步骤可以分为以下三步：

1、下载 5000 只股票的历史价格数据，挑选 n 只股票并进行统计分析，我们以相关系数 $\rho = 0.2$ 为界定高低相关性的标准，如果两只股票的相关系数 $\rho \geq 0.2$ ，我们将他们分为一组，否则不放在一组。

2、在步骤 1 操作完成后，有些股票与其他股票的相关系数可能都不高，对于这些股票我们单独将其分为一类。

3、利用均值一方差模型对各组股票进行权重分配。需要注意的是，聚类后的分组能大大减少计算机的运算量，例如我们后面举到的例子，将协方差矩阵从 150×150 降维为 69×69 。若我们对一个股票数量超过 5000 只的组合进行二次优化，那么利用聚类方法可以大大节省计算时间。


三、估计误差的敏感性测试

我们可以拿到 5000 只股票的历史价格信息，我们随机从中抽取 150 只构建组合（不采用 5000 全样本数据主要是处于计算机复合的考虑），我们做两次抽样。

在分析之前，我们首先要确定如何判定一个股票是否与其他股票存在高度的相关性。在基本面分析中，我们可以通过行业分类将股票分组，因为一个行业内的股票通常呈现出较高的相关性。

第二中方法是纯定量的方法：计算任意两个股票间的相关系数并设定一个阈值 ρ^* ，两个股票间的相关系数大于 ρ^* 则视为高度相关，否则认为相关性较低。这里涉及到如何取定一个合理的 ρ^* ，我们取 $\rho^* = 0.2, 0.15$ 分别进行测试，图 1 展示了两次抽样下的 ρ^* 的分布直方图。


图 1 两次抽样下的相关系数分布直方图



资料来源：Portfolio Construction Using Clustering Methods

由于高度相关没有明确的度量标准，我们先以 $\rho = 0.2$ 为标准来测试聚类的效果。图 2 展示了按照 $\rho = 0.2$ 为标准，聚类前和聚类后的有效前沿。

图 2 聚类/非聚类模型下的有效前沿



资料来源：Portfolio Construction Using Clustering Methods

乍一看效果并不令人满意，因为在同样的风险下，聚类前的期望收益甚至高于聚类后的期望收益。然而我们也并不能过于信赖有效前沿的结果，原因如下：

众所周知，组合优化的最大缺陷是估计误差常常会被放大，假设我们对某一股票的预期收益有了错误的高估，如果恰好这一股票的波动率较低，那这一股票将会被赋予很高的权重（谁都会选择低风险、高收益的股票），这是非常危险的做法因为我们在赌我们对预期收益估计的准确性，如果真是的预期收益与估计值相差甚远，那组合的表现会收到很大的影响。

聚类方法能够有效缓解这一问题。前面我们提到聚类的好处之一是可以减少对预期收益估计的依赖，而更多的利用协方差矩阵的估计信息。我们知道对预期收益的估计误差要比协方差矩阵的估计误差大很多，所以聚类方法对估计误差的免疫更强一些。

至此，我们明白好的有效前沿未必在实际投资中能带来更高的收益，因为有效前沿可能是基于一些错误的估计而生成的，同时我们也必须明白聚类法的优势不在于优化有限前沿，而是使得模型对估计误差变得不敏感。

为了度量组合对估计误差的敏感性，我们以 $\rho = 0.2$ 为划分股票高相关性的标准做以下两组测试（ $\rho \geq 0.2$ 的股票定义为高相关性， $\rho < 0.2$ 的股票定义为低相关性）。

---- 敏感性测试 1.1: 随机挑选 15% 的股票并将他们的预期收益率做 $\pm 10\%$ 的调整，然后重新构建组合考察与原组合的差异；

---- 敏感性测试 1.2: 随机挑选 15% 的股票并将他们的预期收益率做 $\pm 10\%$ 的调整，此外，我们强制对原组合中权重最高的股票进行预期收益率 $\pm 10\%$ 的调整，然后重新构建组合考察与原组合的差异。之所以这么做因为我们想考察组合中的第一权重股如果发生估计偏差，会对组合产生多大的影响。

敏感性测试中我们真正做的事是加入一些人为的估计偏差，我们按照如下方法来测试组合前后的权重变化：

假定 $h_{old,i}$ 是股票 i 在引入估计偏差前在原组合中的权重， $h_{new,i}$ 是股票 i 在引入估计偏差后在新组合中的权重，然后用 $\sum_{i=1}^N \left(\left| h_{new,i} - h_{old,i} \right| \right)$ 来度量引入估计偏差前后组合权重的变化。

我们在有效前沿上挑选了 10 个点，考察引入估计偏差前后组合的权重变化，敏感性测试 1.1 的结果如表 1，很明显，聚类后的组合对预期收益的变动变化不明显。

表 1 敏感性测试 1.1 下的组合权重前后变化

Points On EF	Change of weight (no clustering)	Change of weight (clustering)
1	3%	0
2	4%	0
3	5%	1%
4	1%	1%
5	1%	1%
6	1%	0
7	1%	0
8	2%	0
9	2%	0
10	2%	0

资料来源：Portfolio Construction Using Clustering Methods

同样的方法，敏感性测试 1.2 的结果如表 2，与敏感性测试 1.1 一样，聚类后组合的稳定性大幅提高，对估计偏差的敏感程度远不及聚类前的组合。

表 2 敏感性测试 1.2 下的组合权重前后变化

Points on EF	Change of weight (no clustering)	Change of weight (clustering)
1	7%	8%
2	10%	12%
3	13%	14%
4	12%	17%
5	15%	19%
6	16%	22%
7	53%	32%
8	73%	30%
9	114%	15%
10	200%	40%

资料来源：Portfolio Construction Using Clustering Methods

为了进一步测试聚类后组合的稳定性，我们重新选取了 150 只股票构建组合，并作如下敏感性测试：

---- 敏感性测试 2.1: 随机挑选 15% 的股票并将他们的预期收益率做 $\pm 10\%$ 的调整，然后重新构建组合考察与原组合的差异；（这个测试与测试 1.1 一样）

---- 敏感性测试 2.2: 随机挑选 15% 的股票并将他们的预期收益率做 $\pm 10\%$ 的调整，此外，我们强制对原组合中权重最高的 2% 的股票进行预期收益率 $\pm 10\%$ 的调整，然后重新构建组合考察与原组合的差异。之所以这么做因为我们想考察组合中权重较高的股票如果发生估计偏差，会对组合产生多大的影响。

与测试 1 不同的是，我们在测试 2 中以 $\rho = 0.15$ 为聚类的标准。我们在表 3、表 4 中分别展示了敏感性测试 2.1、2.2 的结果，与测试 1 一样，聚类后的优化组合更为稳定。

表 3 敏感性测试 2.1 下的组合权重前后变化

EF	Change of weight (no clustering)	Change of weight (clustering)
1	0.567%	0.27%
2	0.824%	0.38%
3	0.417%	0.474%
4	0.323%	0.078%
5	0.213%	0.089%
6	0.201%	0.093%
7	0.198%	0.111%
8	0.21%	0.112%
9	0.155%	0.138%
10	0.11%	0.215%

资料来源：Portfolio Construction Using Clustering Methods

表 4 敏感性测试 2.2 下的组合权重前后变化

EF	Change Of Weight(nonclustering)	Change of weight(clustering)
1	2.3%	2.9%
2	3.5%	3.5%
3	5.8%	5.3%
4	7.4%	6.2%
5	10.1%	8.7%
6	13.6%	10.8%
7	16.4%	8.4%
8	22.3%	11.4%
9	11.9%	2.5%
10	1.4%	1.1%

资料来源：Portfolio Construction Using Clustering Methods

通过以上的测试，我们知道聚类法的引入大大降低了组合对估计误差的敏感程度。在实际运作中，如果预期收益发生微小的变化，聚类后的组合可以大大降低换手率，提高组合的稳定性。下面我们将对比聚类后的组合与聚类前组合的表现。

四、组合表现测试

由于有效前沿上有无数的点可以生成组合，为了比较的统一性，我们选取风险度一样的两个组合来比较，我们主要考察组合构建后的第一个月和第二个月的表现。

我们用测试 1 中抽样的 150 个股票来考察聚类前后组合表现的对比，结果见表 5。

表 5 聚类前后组合在未来 1-2 个月的表现

Table 6.1. Portfolio performance (non clustering)

Portfolio	Risk	Return in 1st month	Return between 1st and 2nd month
1	2.03	-0.1%	-6.5%
2	2.54	0.6%	-17.1%
3	4.33	3.7%	-54.0%
4	8.72	12.5%	-32.4%

Table 6.2. Portfolio performance (clustering)

Portfolio	Risk	Return in 1st month	Return between 1st and 2nd month
1	2.04	-12.0%	-9.1%
2	2.56	-0.3%	-20.3%
3	4.33	-23.4%	-8.1%
4	8.75	19.2%	-8.8%

资料来源：Portfolio Construction Using Clustering Methods

我们发现聚类后的组合表现要优于聚类前的组合，例如组合 3 和组合 4 在构建后的第 2 个月跌幅分别高达 54% 和 32%，然而聚类后的组合 3、4 在此期间的跌幅均没有超过 10%，这是很重要的一点，因为极端下行风险对组合投资而言是致命的。

为了更好的评价优化后组合的表现，我们构建了聚类前后股票组合构建的等权指数（表 6），同时罗列了同期 DOW 指数和 NASDAQ 指数的表现（表 7）。

表 6 聚类前后等权组合在未来 1-2 个月的表现

Portfolio	Return in 1st month	Return between 1st-2nd month
Evenly weight nonclustering	-2.7%	-6.2%
Evenly weight clustering	0.07%	-7.8%

资料来源：Portfolio Construction Using Clustering Methods

表 7 DOW 指数和 NASDAQ 指数同期表现


Portfolio	Return in 1st month	Return between 1st-2nd month
Dow	-14.1%	9.6%
NASDAQ	-12.1%	-3.8%

资料来源：Portfolio Construction Using Clustering Methods

在我们的这组抽样下，优化后的组合表现都没有明显超过等权组合。观察图 3 中的市场走势可知在考察期内市场是一个强烈反转的市场，优化模型在估算预期收益率时通常采用过去一段时间的平均收益，反转市场下的危险在于过去表现好的股票未来表现会相对较差，所以用过去收益率来作为未来收益率的估计风险很大。

此外，与市场基本相比，表现不佳的很大原因在于我们抽样的 150 只股票大多来自于 NASDAQ，例如 MSFT，DELL，EBAY，IBM 等，而这些股票在我们的考察期内恰好是下跌最严重的时候。

图 3 DOW 指数和 NASDAQ 指数同期走势



资料来源：Portfolio Construction Using Clustering Methods

为了避免抽样的偶然性，我们同样使用测试 2 中抽样的 150 个股票来考察聚类前后组合表现的对比，测试 2 中的股票主要来源 DOW 指数，优化后的结果明显好于测试 1，结果见表 8、表 9。

表 8 聚类前组合在未来 1-2 个月的表现

Port	Risk	Return in 1st month	Return between 1st-2nd month
1	1.12	-0.61%	-4.35%
2	1.18	-0.29%	-4.53%
3	2.70	5.3%	-9.34%
4	7.05	11.36%	-2.15%

资料来源：Portfolio Construction Using Clustering Methods

表 9 聚类后组合在未来 1-2 个月的表现

Port	Risk	Return in 1st month	Return between 1st-2nd month
1	1.12	-0.9%	-1.83%
2	1.18	-0.88%	-1.19%
3	2.70	3.41%	-1.09%
4	7.05	11.72%	-1.98%

资料来源：Portfolio Construction Using Clustering Methods

为了更好的评价优化后组合的表现，我们构建了聚类前后股票组合构建的等权指数（表 10）。

表 10 聚类前后等权组合在未来 1-2 个月的表现

Portfolio	Return in 1st month	Return between 1st and 2nd month
clustering	1.49%	-6.05%
Non clustering	2.57%	-10.6%

资料来源：Portfolio Construction Using Clustering Methods

很明显，测试 2 中聚类后的组合表现较之聚类前更加稳定，且均能较好战胜市场基准。

五、总结

本文的实证表明聚类方法能很好的提高均值一方差模型的稳定性与表现，与重抽样方法相比，聚类法对计算的敏感度更低，由于在实践中聚类法的运用没有重抽样法来得

广泛，因此可供比较的研究并不多，为了更好的将聚类法应用到实践中，以下一些工作是我们后续研究的重点：

1、如何将股票分类？我们在本文中采用了纯定量的方法来进行分类，而利用定性方法（例如按照行业进行分类）也可以达到分类的目的。哪一种效果更好？

2、聚类时相关系数 ρ 如何选取？我们在文中选取了 $\rho = 0.15, 0.2$ 两个值来测算，是否存在更优的参数？

3、定量的方法合适有效、合适失效？我们发现在第一组抽取的 150 个样本下优化效果并不是特别理想，最主要的原因是我们用过去的收益率来预测未来收益率，即隐含了假设过去表现好的股票在未来表现仍然出色。当市场风格发生大转变的时候，量化策略往往会出现比较大的回撤。一个常用的方法便是将定量和定性相结合，一些宏观经济指标通常会给出一些市场趋势变化的信号，定量投资者应该积极关注这些信息。

4、本文中对于分组后的股票采用了组内等权重分配权重的方法，这是一个简化的处理，对于每个组内股票权重的分配，有待进一步研究。

连续竞价和内幕交易

原文：Albert, Kyle, Continuous Auctions and Insider Trading, *Econometrica*, Vol.53, No.6(Nov.,1985),1315-1336.

推荐人：祇飞跃 021-23219984

推荐理由：Klye 模型和 Glosten 与 Milgrom 模型是市场微观结构研究的两大开山模型。尽管这两篇文章时代比较久远，但这两大模型从不同角度第一次对 informed trader 和 uninformed trader 在市场上的交易行为给出了数学化的描述，同时对这些交易行为所对应的市场特性给出了论证，是后来类似文章的思想源泉。GM 模型利用市价单为泊松分布过程，和做市商挂买卖单的假设，给出了一个真实市场的近似描述。相对于 GM 模型而言，Klye 模型重点研究了由一个内幕交易者、一群噪音交易者和做市商构成的 batch-auction 类型的市场。这里内幕信息可以是将要披露的信息，也可以是交易者自身对市场变化的判断。所谓 batch-auction 市场，意思是说做市商并不事先挂单，而是由市价单的寻求方报单，将报单量和报单方向轧差整合后，由做市商在不以盈利为目的（因为他们之间存在充分竞争关系）的情况下给出一个合理价格。因此，我们可以看出 Klye 模型的假设与通常的市场规则并不相符。但受纳什均衡理论影响极深的八十年代，Klye 通过均衡理论的论证方式，给出了在一个均衡态的情况下，内幕交易者的最优报单方法和做市商的报价准则。该结果对真实市场的重要启示有两个：

第一，均衡状态下，做市商为了保护自己（尽管不以盈利为目的，但也不想亏损），会根据其他交易者的报单量来调节最终交易价格。这个调节后的结果就是所谓的“市场深度”。在 Kyle 的模型中，“市场深度”即 Kyle's λ 被描述为做市商为了提供 1 个单位的报单所要求的价差的变化。那么，可以引申这样一个问题：我们的股票市场的 OrderBook 的“市场深度”是否也反映了市场上流动性提供者（限价单挂单者）为了规避“潜在内幕交易者”所带来的损失而寻求一定补偿这一问题上的认知？

第二，均衡状态下，内幕交易者对未来价格所知道的信息，会逐渐的、动态的反映在交易价格中。那么，我们也可以问：如何用更加符合实际情况的模型来描述这一价格发现过程，以指导我们的交易？

事实上，在过去的 30 年中，有众多研究工作者在 informed trader 和 uninformed trader 这一领域做出了大量的工作。其中，最为杰出的工作之一是由 Kerry Back 和 Shmuel Baruch 在 2004 年发表在《Econometrica》上的一篇文章“Information in Security Market: Kyle meets Glosten and Milgrom”。该文章将 Kyle 模型和 Glosten-Milgrom 模型整合在了同一个框架下面，并证明了 Kyle 模型的均衡态可以被看做是 GM 模型的一种极限状态。

一、介绍

新的私下股票信息究竟需要多久才会反映在市场价格中？对于一个知道内幕信息的投资者来说，这些内幕信息究竟有多大价值？噪音交易对价格的波动率有多大影响？到底是什么决定了一个投机市场的波动率？这篇文章通过定量的描述和研究一个内幕交易者在一个动态的价格形成机制模型下的最优交易策略，对以上问题进行了解答。

在我们所要研究的模型里，风险资产（如股票）的交易者分为三类：一位具有唯一的内幕信息的交易者、一群随机交易的噪音交易者以及根据目前交易信息进行最优报价的做市商。交易过程被描述为一系列的竞价过程，该竞价过程被描述为由 Kreps 和 Wilson 的文章中所刻画的序列均衡状态的过程。

每个竞价交易过程可以分为两步。第一步，内幕交易者和噪音交易者同时选取他们

要交易的数量，并推送市价单。在做出选择的过程中，内幕交易者的信息包括他所了解到的清算期（如结算价、当日收盘价等，取决于内幕交易者的交易策略，译者注）的交易标的的价格信息，以及过往的交易记录，但并不取决于噪音交易者的市价单的量（因为他看不到，译者注）。同时，内幕交易者无法预测下一时刻的交易价格和交易量。对于噪音交易者而言，我们假设他们的市价单量是随机的，而且与内幕交易者市价单量独立，同时每次市价单量都与之前的市价单量独立。第二步，做市者设定一个成交价（限价单，译者注），并且接受所有的市价单。但做市者无法区分哪些市价单是噪音者提交哪些是内幕交易者提交。在连续时间下，所有的这些成交量构成了所谓的“Order Flow”。这使得，交易价格的变动完全由“Order Flow”的变化导致（这似乎与我们通常的挂限价单，由其他交易者提交市价单的顺序相反，但是在该模型的均衡理论前提下，顺序并不影响结果，译者注）。换句话说，这样的一个交易结果，完全是由内幕交易者对清算期标的价值的内幕信息的了解，和噪音交易者加内幕交易者的挂单行为，以及做市者的报价行为导致。

假设内幕交易者是风险中性的，换句话说，他们只想最大化他们的预期收益。同时，我们假设，该内幕交易者并不关心本人所观测到的私人信息，以及他过往的交易记录。他的决定并不依赖于由噪音交易者所交易出来的价格和量。另外，我们假设做市商给出的价格为基于当前市价单量信息下，交易标的在清算期清算价格分布的均值。换句话说，他们在此过程中并不以盈利为目的，其预期收益为 0。可以看出，噪音交易者的存在是内幕交易者可以从其他交易者中赚钱的主要原因。

我们假设相关的随机变量为正态分布，那么可以得到一个容易处理的线性结构，该结构令我们得到了一个“序列竞价均衡状态”，在该状态下，所有的价格和交易量信息都是观测量的线性函数。将时间间隔无穷细分，我们还可以得到一个对应的“连续竞价均衡状态”。

在离散序列竞价状态和连续竞价状态下，我们都可以对之前提到的问题得到一个很好的解释。

二、单一竞价均衡态

我们假设标的物在清算日的价格分布 v 是均值为 p_0 ，方差为 Σ_0 的正态分布。噪音交易者的交易量 u 为均值为 0，方差为 σ_u^2 。 v 和 u 之间为独立，内幕交易者的交易量为 x ，由做市商决定的最终交易价格 p 。根据我们之前的假设，内幕交易者对清算日的标的物价格 v 是知道的，且内幕交易者对 σ_u^2 和 Σ_0 也知道，那么我们可以假设内幕交易者的市价单量 x 是关于 v 的一个函数，即 $X(v)$ 。对于做市者来说，他知道整体市价单量 $v+u$ ，因此我们可以假设其“非盈利”报价价格 p 为关于 $v+u$ 的一个函数 $P(v+u)$ 。这意味着，内幕交易者的收益为 $q = (v-p)x$ ，或者写成 $\pi = \pi(X, P)$ 。

均衡态的定义。一个均衡态为满足下面两个条件的配对 X 和 P ，

1>收益最大化：对任意其他的内幕者交易策略 X' 和 v_1 ，

$$E[\pi(X, P)|v = v_1] \geq E[\pi(X', P)|v = v_1];$$

2>市场有效性：随机变量 p 满足

$$p(X, P) = E[v|x+u]。$$

定理：在假设 X 和 P 为线性函数的情况下，存在唯一的均衡状态。定义 β 和 λ 为

$$\beta = \sigma_u / \sqrt{\Sigma_0}, \quad \lambda = 2/\beta, \quad \text{那么}$$
$$X(v) = \beta * (v - p_0), \quad P(x+u) = p_0 + \lambda * (x+u)。$$

均衡态下的一些性质：均衡态 X 和 P 由 σ_u 和 Σ_0 完全决定。我们可以将 $\Sigma_1 = \text{var}[v|p]$ 作为衡量交易价格 p 中所携带信息的标准，那么通过计算可知 $\Sigma_1 = \Sigma_0/2$ 。换句话说，有一半的清算价格信息被包含到了真实交易价格中，而该清算价格风险并不受噪音价格的影响。同时我们看到，在交易未发生之前，除了内幕交易者，市场对清算价格的合理预期为 p_0 ，而做市者为了避免在做市中受损，改变了交易价格为 $p_0 + \lambda(x+u)$ 。这里 λ 恰好衡量单位市价量所带来的交易价格的改变，因此，我们可以将 $1/\lambda$ 当做均衡状态下的市场深度的衡量标准。

3. 序列竞价均衡态

我们下面考虑与单一竞价均衡态类似的序列竞价均衡态。首先介绍我们将要用到的记号：

$\{t_n\}(0 \leq n \leq N)$ 为 $[0,1]$ 区间的一个分化。 $\{u_n\}$ 为一个布朗运动在时刻 t_n 的值，我们用它来记录噪音交易者的累计市价单报单量。类似的，我们用 $\{x_n\}$ 来记录内幕交易者的累计市价单报单量。根据之前的假设，我们知道做市者只可以看到 $\{u_n + x_n\}$ 。由于内幕交易者依据过往成交记录以及 v 作为下一个报单的依据，因此我们可知在时刻 t_n 的报单量为

$x_n = X_n(p_1, \dots, p_{n-1}, v)$ 。（注意，对于内幕交易者来说， p_i 已经足够其作为获得 u_i 信息的依据，译者注）

同样，我们可知做市者所定的价格为

$$p_n = P_n(x_1 + u_1, \dots, x_n + u_n)。$$

那么，我们定义满足以上形式的向量函数 X 和 P

$$X = \langle X_1, \dots, X_N \rangle, P = \langle P_1, \dots, P_N \rangle$$

为内幕交易者的“交易策略”和做市者的“定价准则”。

同时，我们可知内幕交易者在 $n, \dots, N$ 的损益为

$$\pi_1 = (v - p_n)x_n + \dots + (v - p_N)x_N。$$

均衡态定义：一个序列竞价均衡态是满足如下两个条件的 X 和 P ：

1> 收益最大化：对任意 n ，和任意 $X' = \langle X'_1, \dots, X'_N \rangle$ 满足 $X'_1 = X_1, \dots, X'_{n-1} = X_{n-1}$ ，我们有

$$E[\pi_n(X, P) | p_1, \dots, p_{n-1}, v] \geq E[\pi_n(X', P) | p_1, \dots, p_{n-1}, v]。$$

2> 市场有效性条件：

$$p_n = E[v | x_1 + u_1, \dots, x_n + u_n]。$$

利用递归方法我们可以证明如下定理：

定理：存在唯一的线性均衡态，和常数 $\beta_n, \lambda_n, \alpha_n, \delta_n$ 和 Σ_n 使得

$$\Delta x_n = \beta_n(v - p_{n-1})\Delta t_n,$$

$$\begin{aligned}\Delta p_n &= \lambda_n (\Delta x_n + \Delta u_n) \\ \Sigma_n &= \text{var}(v | \Delta x_1 + \Delta u_1, \dots, \Delta x_n + \Delta u_n) \\ E[\pi_n | p_1, \dots, p_{n-1}, v] &= \alpha_{n-1} (v - p_{n-1})^2 + \delta_{n-1}.\end{aligned}$$

给定 Σ_0 ，那么 $\beta_n, \lambda_n, \alpha_n, \delta_n$ 和 Σ_n 是如下差分方程的唯一解：

$$\begin{aligned}\alpha_{n-1} &= \frac{1}{4\lambda_n(1-\alpha_n\lambda_n)} \\ \delta_{n-1} &= \delta_n + \alpha_n\lambda_n^2\sigma_u^2\Delta t_n \\ \beta_n\Delta t_n &= \frac{1-2\alpha_n\lambda_n}{2\lambda_n(1-\alpha_n\lambda_n)} \\ \lambda_n &= \beta_n\Sigma_n / \sigma_u^2 \\ \Sigma_n &= (1-\beta_n\lambda_n\Delta t_n)\Sigma_{n-1}\end{aligned}$$

满足初始条件 $\alpha_N = \delta_N = 0$ 和二阶条件 $\lambda_n(1-\alpha_n\lambda_n) > 0$ 。

均衡态性质：

- 1、衡量交易价格中信息量的参数 Σ_n 是递减的，说明随着交易次数增加，内幕交易者所知道的信息会逐渐体现在交易价格中。
- 2、 σ_u 增加会提高市场深度，但并不影响 Σ_n 。同时，内幕交易者的盈利会相应增加。

进阶大类资产配置方法

原文：FARSHID M.ASL and ERKKO ETULA, 2012. Advancing Strategic Asset Allocation in a Multi-Factor World. Journal of portfolio management, volume 39 No. 1.

推荐人：丁鲁明 021-23219068

推荐理由：伴随着中国经济在全球产业链分工中的占比不断提升，中国经济与全球经济波动特征逐渐接近，这一特征在全球股市波动方面有着尤其重要的特征体现。在进行国内股市整体波动因素分析时，海外因素已经成为投资者不可或缺的重要考量，我们有必要从全球证券视角出发，了解海外全球大类资产配置的一些方法。本文从全球大类资产的指数表现为基础，试图寻找各类资产背后真正的独立影响因素，并以此为基础构

资产配置策略在所有有关投资的概念中可能是最为重要，同时也最为被忽视的一项，高盛的投资管理部（investment management division）的投资策略组（investment strategy group, ISG）发展出一种新的资产配置策略，该策略拓展了以下概念：长期投资收益主要是由多种叫做“收益产生因素”的优秀投资资源所产生的。这种多因素资产配置策略被设计用来帮助投资者更好的理解影响长期投资收益的关键因素和增加对于长期风险和收益的预测的精确度。这种策略同时为投资者提供一种风险分散的新思路，是他们不止关注于通过投资于不同评级的资产来分散风险，同时投资于不同来源的资产（比如股票，债券，货币，衍生品等）来分散风险。

之前，ISG 的投资策略是基于 Black and Litterman 的单因素模型和投资收益的正态分布假设。这些模型同时进一步通过投资过程中的定性假设得到加强。这种新的多因素框架解决了一些传统方法的短处，计量模型只是这个框架的一部分。为了降低模型的风险和更好的了解个人投资者的独特目标和弱偏好（softer performance），数量方法的演算结果和投资经验仍是投资活动中的重要决定因素。

新的资产配置策略通过以下四个关键创新来使投资者受益。

第一，构建了一种多因素模型来在今天复杂的投资环境中识别多种叫做“收益产生因素”的重要投资资源。

第二，发展了鲁棒投资优化理论来应对推测收益预期中的未确定的因素。

第三，设计了因素向导风险分析法来更好的捕捉现实投资中的资产特性，例如肥尾效应和尾端风险。

第四，发展了因素向导模拟技术来应对不同经济场景下的影响，比如低利率市场。

因素导向的资产配置策略：

无论投资者的具体目标是什么，资产配置策略始于了解全球市场中存在的投资机会。投资者必须增加对于可选资产的预期收益和风险的理解。传统策略尝试通过资产定价模型（CAPM），包括 Black and Litterman 模型来解决这个问题。这些策略是基于以市场超额收益为唯一因素的单因素模型来制定的。这种框架下认为能带来具有越高市场暴露，或者称之为 β 的资产，则当然具有越高的风险，同时也有越高的收益。

然而，针对 CAPM 模型，大量的实证和理论证据证明真实世界远远比单一因素模型所描述的要复杂。市场参与者担心很多风险，在市场之上和之外的风险，同时愿意为能够接受这些风险的投资者支付客观的奖励。市场风险带来的相应收益并不是唯一的可靠收益源，因为长期收益同时来源于一些其他的全球风险。

我们用来预测预期收益的模型涉及以下六个（风险）因素：股权、时间、基金、流动性、汇率和新兴市场。（具体可见下图：左侧为风险种类，右侧为可以带来收益的风险的解释。分别为：股权，市场风险；时间，通胀和利率风险；基金，短期信贷风险；流动性，相关风险；汇率，系统汇率风险；新兴市场，相关风险）

图 1 预测资产收益率的六个维度

EXHIBIT 1

Six-Factor Model for Estimating Expected Returns

RISK PREMIUM	REWARDS INVESTORS FOR...
Equity	Market risk
Term	Inflation and interest rate risk
Funding	Risk in short-term credit conditions
Liquidity	Risk in market-wide liquidity conditions
FX	Systematic exchange rate risk
EM	Risks specific to emerging markets

资料来源：《Advancing Strategic Asset Allocation in a Multi-Factor World》，FARSHID M.ASL and ERKKO ETULA, 2012

我们强调 4 个该模型的关键特点：

第一，这些因素之间互相独立。

第二，每个风险溢价都有明确的经济原理解释。

第三，每种风险相应的补偿反映了对于系统风险的弥补。

第四，每种风险溢价都是可被投资利用的。

由于每一个资产组合都能被表示成为以上六个因素的组合，而每一种因素都能够代表一种优秀的长期收益源，这种策略框架为我们提供了一种新的认识在不同资产中风险分散的思路。例子如下图。

图2 选定资产的风险暴露程度

EXHIBIT 2
Examples of Risk Premium Profiles for Selected Asset Classes



Note: The total estimated risk premium and the associated standard error are displayed below each profile.

资料来源：《Advancing Strategic Asset Allocation in a Multi-Factor World》，FARSHID M.ASL and ERKKO ETULA, 2012

可以看到每一种资产都有一个独特的风险溢价，这种重要的特征在传统的只注重股权溢价的策略框架下被完全忽视了。

一个理想的投资组合应该由很多互相独立的收益产生因素所组成。因为我们的框架反映很多的重要投资资源都是互不影响的，这为我们的资产配置策略提供了一种新思路。比起多样化投资的资产的种类，长期资产组合更应该注重选取一个均衡的风险因素组合。

这一点很重要因为不是所有的重要投资资源都能一直产生正收益。在过去的十年内，股权收益大幅下降并远远低于它的长期平均收益。在这种情况下，一个好的长期投资组合应该能够从其他的风险因素获得相当的收益。

下图提供了一个例子，展示了2个假设的资产配置组合。

图3 用新的风险观察维度评价传统资产配置组合

EXHIBIT 3
Diversification from a New Perspective



资料来源：《Advancing Strategic Asset Allocation in a Multi-Factor World》，FARSHID M.ASL and ERKKO ETULA, 2012

从资产组合的角度，左侧的投资组合比右侧的更加分散化（左侧的饼状图几乎由10种资产组合而成，而右侧则只有3种资产）。但是，如果我们查看能提供溢价的风险种类，右侧明显要比左侧多样化。

鲁棒（robust）优化在资产配置中的应用：

在资产组合中，优化的目标是找到最符合投资者特定目的的资产配置组合。为了达到这个目标，许多策略框架关注于投资的风险与收益，建立在 mean-variance 模型的框架下。但是，在缺乏对市场各种条件的严格限制下，直接应用 MV 模型通常会导致投资组合不能分散风险，表现较差。

我们的新鲁棒优化框架估计到一个经常被传统方法忽略到的重要的统计事实。即使是最好的对于预期收益的预测都含有巨大的不确定性（同时也被称之为标准化误差）。这即是说，今天预测的长期资本收益基本上与未来的实际平均收益有着本质上的不同。除此之外，在数据质量和可得性上的差异决定了对有些资产的风险和收益的预测要比其他资产准确的多。

MN 模型已被证明对于这种误差十分敏感，输入数据的微小变化会导致最优投资组合的重大变化，这常常导致窘迫的境况。我们的鲁棒优化技术尝试通过明确投资组合中的预期收益标准差来解决这个问题。例子如下图。

图 4 鲁棒优化前后的资产配置组合差异对比举例

EXHIBIT 4 Robust Optimization Acknowledges that Expected Returns are Uncertain



资料来源：《Advancing Strategic Asset Allocation in a Multi-Factor World》，FARSHID M.ASL and ERKKO ETULA, 2012

右侧为经过鲁棒优化的投资组合，与左侧经传统优化方法构建的组合区别明显。需要注意到上图中的组合结果是在无外在限制的优化情况下取得的。鲁棒优化能帮助我们在主观输入数据不多的情况下构建资产配置组合。


为了展示我们如何用鲁棒优化来处理预测的预期收益的误差，我们来进行一下测试。我们首先使用我们的因素模型用过 2000 年前的数据来推测战略投资资产的预期收益和风险。接着我们通过添加符合正态分布的随机扰动项---完全契合预期收益预测标准差的独立随机误差创造 1000 个波动。

接下来我们将波动后的预期收益和资产的协方差矩阵代入鲁棒优化模型和传统的均值回归模型来获得这 1000 个波动中每一个波动所对应的资产组合比重。在此基础上我们对 2001 到 2010 年间股票组合的进行模拟净值测算，下图体现了其结果。

图 5 鲁棒优化和简单均值方差优化的 10 年资产组合收益对比

EXHIBIT 5

Comparing Hypothetical Robust Optimal Portfolios and Mean-Variance Optimal Portfolios from 2001 to 2010



资料来源：《Advancing Strategic Asset Allocation in a Multi-Factor World》，FARSHID M.ASL and ERKKO ETULA, 2012

可以看到经过鲁棒优化的投资组合的累积收益相较于传统 MV 模型优化要集中的多，无论是在即时的情况（左图）还是在十年总结时（右图）。

Ceria 和 Stubbs 的结果表明在同等风险的情况下，鲁棒优化能够带来更高的收益率，带来更高的可实现的效用边界。Ceria 和 Stubbs 的分析表明在鲁棒优化的框架下构建的投资组合“下注前”收益常常接近于“实现后”的收益。这一特点实际上起源于在鲁棒优化的框架下更高水平的风险分散，故而可以帮助投资者对他们的收益更有信心。

结论

对因素模型的组合调整费用、资金流指标、通胀和税收的预测工作，对于未来投资组合价值的分布影响也是构建投资组合策略的另一个关键部分，尤其是对于开支有特殊要求的捐赠基金。我们的基于因素构建的投资组合的应用能够解决两个传统适用于此领域的蒙特卡洛模拟法的缺陷。

第一，因素分解允许我们避开关于收益独立性、正态分布的假设，有利于构建一个更符合现实的基于因素的分布。第二，实际模型应用中能够考虑到主导的经济环境对于组合表现的影响。举例而言，在一个低利率的环境下，10 年内的整体投资组合收益不仅取决于无风险利率逐渐收敛于长期平均水平的过程，而且取决于风险溢价的调整。使用我们要素模型的组合同时考虑了这两者，给投资者带来对于潜在收益变化范围的更好的理解。

尽管对于投资者很重要，很多长期投资者仍然使用 50 年代和 60 年代的技术决定资产配置。在投资过程中这些工具有数个缺陷限制了他们的价值。我们在鲁棒优化框架下解决了其中的一部分，这些可以应用于资产配置过程的方法允许投资者在考虑他们独特的目标和要求的情况下做出更好的决定。

信息披露

分析师声明

高道德、丁鲁明、郑雅斌、朱剑涛、冯佳睿、杨勇、张欣慰：金融工程

以上分析师皆具有中国证券业协会授予的证券投资咨询执业资格，以勤勉的职业态度，独立、客观地出具本报告。本报告所采用的数据和信息均来自市场公开信息，本人不保证该等信息的准确性或完整性。分析逻辑基于作者的职业理解，清晰准确地反映了作者的研究观点，结论不受任何第三方的授意或影响，特此声明。

法律声明

本报告仅供海通证券股份有限公司（以下简称“本公司”）的客户使用。本公司不会因接收人收到本报告而视其为客户。在任何情况下，本报告中的信息或所表述的意见并不构成对任何人的投资建议。在任何情况下，本公司不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任。

本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的的价格、价值及投资收入可能会波动。在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。

市场有风险，投资需谨慎。本报告所载的信息、材料及结论只提供特定客户作参考，不构成投资建议，也没有考虑到个别客户特殊的投资目标、财务状况或需要。客户应考虑本报告中的任何意见或建议是否符合其特定状况。在法律许可的情况下，海通证券及其所属关联机构可能会持有报告中提到的公司所发行的证券并进行交易，还可能为这些公司提供投资银行服务或其他服务。

本报告仅向特定客户传送，未经海通证券研究所书面授权，本研究报告的任何部分均不得以任何方式制作任何形式的拷贝、复印件或复制品，或再次分发给任何其他人，或以任何侵犯本公司版权的其他方式使用。所有本报告中使用的商标、服务标记及标记均为本公司的商标、服务标记及标记。如欲引用或转载本文内容，务必联络海通证券研究所并获得许可，并需注明出处为海通证券研究所，且不得对本文进行有悖原意的引用和删改。

根据中国证监会核发的经营证券业务许可，海通证券股份有限公司的经营经营范围包括证券投资咨询业务。

海通证券股份有限公司研究所

路 颖 副所长 (021) 23219403 luying@htsec.com	高道德 副所长 (021) 63411586 gaodd@htsec.com	江孔亮 所长助理 (021) 23219422 klijang@htsec.com
姜 超 所长助理 (021) 23212042 Jc9001@htsec.com	赵晓光 所长助理 (021) 23212041 zxcg9061@htsec.com	

宏观经济研究团队

姜 超(021)23212042	jc9001@htsec.com
陈 勇(021)23219800	cy8296@htsec.com
曹 阳(021)23219981	cy8666@htsec.com
高 远(021)23219669	gaoy@htsec.com
周 霞(021)23219807	zx6701@htsec.com
联系人	
顾潇潇(021)23219394	gxx8737@htsec.com

固定收益研究团队

姜 超(021)23212042	jc9001@htsec.com
徐莹莹 (021)23219885	xyy7285@htsec.com
李 宁(021)23219431	lin@htsec.com
倪玉娟(021)23219820	nyj6638@htsec.com

金融工程研究团队

吴先兴(021)23219449	wuxx@htsec.com
丁鲁明(021)23219068	dinglm@htsec.com
郑雅斌 (021)23219395	zhengyb@htsec.com
冯佳睿(021)23219732	fengjr@htsec.com
朱剑涛(021)23219745	zhujt@htsec.com
杨 勇(021)23219945	yy8314@htsec.com
张欣慰(021)23219370	zxw6607@htsec.com
联系人	
祇飞跃(021)23219984	dfy8739@htsec.com
纪锡靛(021)23219948	jxl8404@htsec.com

金融产品研究团队

姜 静(021)23219450	loujing@htsec.com
单开佳(021)23219448	shankj@htsec.com
倪韵婷(021)23219419	niyt@htsec.com
罗 震(021)23219326	luozh@htsec.com
唐洋运(021)23219004	tangyy@htsec.com
王广国(021)23219819	wgg6669@htsec.com
孙志远(021)23219443	szy7856@htsec.com
陈 亮(021)23219914	cl7884@htsec.com
陈 瑶(021)23219645	chenyao@htsec.com
伍彦妮(021)23219774	wyn6254@htsec.com
曾逸名(021)23219773	zym6586@htsec.com
桑柳玉(021)23219686	sly6635@htsec.com
陈韵婷(021)23219444	cyc6613@htsec.com
田本俊(021)23212001	tjb8936@htsec.com

策略研究团队

荀玉根(021)23219658	xyg6052@htsec.com
钮宇鸣(021)23219197	chenrm@htsec.com
汤 慧(021)23219733	tangh@htsec.com
王 旭(021)23219396	wx5937@htsec.com
李 珂(021)23219821	lk6604@htsec.com

中小市值团队

邱春城(021)23219413	qiucc@htsec.com
钮宇鸣(021)23219420	ymniu@htsec.com
何继红(021)23219674	hejh@htsec.com
孔维娜(021)23219223	kongwn@htsec.com

政策研究团队

李明亮(021)23219434	lml@htsec.com
陈久红(021)23219393	chenjiuhong@htsec.com
吴一萍(021)23219387	wuyiping@htsec.com
联系人	
朱 蕾(021)23219946	zl8316@htsec.com
周洪荣(021)23219953	zhr8381@htsec.com

批发和零售贸易行业

路 颖(021)23219403	luying@htsec.com
汪立亭(021)23219399	wanglt@htsec.com
潘 鹤(021)23219423	panh@htsec.com
李宏科(021)23219671	lhk6064@htsec.com

电子元器件行业

赵晓光(021)23212041	zxcg9061@htsec.com
郑震湘(021)23219816	zxx6787@htsec.com

互联网及传媒行业

刘佳宁(0755)82764281	ljn8634@htsec.com
白 洋(021)23219646	baiyang@htsec.com
薛婷婷(021)23219775	xtt6218@htsec.com

石油化工行业

邓 勇(021)23219404	dengyong@htsec.com
王晓林(021)23219812	wxl6666@htsec.com

机械行业

龙 华(021)23219411	longh@htsec.com
熊哲颖(021)23219407	xzy5559@htsec.com
胡宇飞(021)23219810	hyf6699@htsec.com
联系人	
黄 威(021)23219963	hw8478@htsec.com

公用事业

陆凤鸣(021)23219415	lufm@htsec.com
汤砚卿(021)23219768	tyq6066@htsec.com
联系人	
李心宇(021)23212163	lxy9298@htsec.com

非银行金融行业

丁文韬(021)23219944	dwt8223@htsec.com
李 欣(010)58067936	lx8867@htsec.com
联系人	
吴绪越(021)23219947	wxy8318@htsec.com

钢铁行业

刘彦奇(021)23219391	liuyq@htsec.com
------------------	-----------------

建筑工程行业

赵 健(021)23219472	zhaoj@htsec.com
张显宁(021)23219813	zxn6700@htsec.com

医药行业

周 锐(0755)82780398	zr9459@htsec.com
余文心(0755)82780398	ywx9460@htsec.com
刘 宇(021)23219608	liuy4986@htsec.com
江 琦(021)23219685	jq9458@htsec.com
王 威(0755)82780398	ww9461@htsec.com
郑 琴(021)23219808	zq6670@htsec.com
刘 杰(021)23219269	liuj5068@htsec.com
冯皓琪(021)23219709	fhq5945@htsec.com

农林牧渔行业

丁 频(021)23219405	dingpin@htsec.com
夏 木(021)23219748	xiam@htsec.com

银行业

刘 瑞 (021)23219635	lr6185@htsec.com
林媛媛 (0755)23962186	lly9184@htsec.com

房地产业

涂力磊(021)23219747	tl5535@htsec.com
谢 盐(021)23219436	xiey@htsec.com
贾亚童(021)23219421	jiayt@htsec.com

基础化工行业

曹小飞(021)23219267	caoxf@htsec.com
张 瑞(021)23219634	zr6056@htsec.com
联系人	
朱 睿(021)23219957	zr8353@htsec.com

有色金属行业

钟 奇(021)23219962	zq8487@htsec.com
施 毅(021)23219480	sy8486@htsec.com
刘 博(021)23219401	liub5226@htsec.com

计算机行业 陈美凤(021)23219409 蒋科(021)23219474 联系人 王秀钢(010)58067934 安永平(021)23219950	chenmf@htsec.com jiangk@htsec.com wxg8866@htsec.com ayp8320@htsec.com	社会服务业 林周勇(021)23219389	lzy6050@htsec.com	交通运输行业 黄金香(021)23212081 钱列飞(021)23219104 虞楠(021)23219382 联系人 姜明(021)23212111	hjx9114@htsec.com qianlf@htsec.com yun@htsec.com jm9176@htsec.com
--	--	----------------------------------	-------------------	--	--

家电行业 陈子仪(021)23219244 联系人 宋伟(021)23219949	chenzy@htsec.com sw8317@htsec.com	通信行业 徐力(010)58067940 侯云哲(021)23219815	xl9312@htsec.com hyz6671@htsec.com	汽车行业 赵晨曦(021)23219473 陈鹏辉(021)23219814	zhaocx@htsec.com cph6819@htsec.com
---	--------------------------------------	--	---------------------------------------	---	---------------------------------------

电力设备及新能源行业 张浩(021)23219383 牛品(021)23219390 房青(021)23219692 徐柏乔(021)23219171	zhangh@htsec.com np6307@htsec.com fangq@htsec.com x bq6583@htsec.com	食品饮料行业 赵勇(0755)82775282 马浩博(021)23219822	zhaoyong@htsec.com mhb6614@htsec.com	造纸轻工行业 徐琳(021)23219767	xl6048@htsec.com
--	---	---	---	----------------------------------	------------------

纺织服装行业 杨艺娟(021)23219811	yyj7006@htsec.com	煤炭行业 朱洪波(021)23219438	zhb6065@htsec.com	建筑建材行业 张显宁(021)23219813	zxn6700@htsec.com
-----------------------------------	-------------------	---------------------------------	-------------------	-----------------------------------	-------------------

海通证券股份有限公司机构业务部

陈苏勤 总经理
(021)63609993
chensq@htsec.com

贺振华 总经理助理
(021)23219381
hzh@htsec.com

深广地区销售团队 蔡铁清 (0755)82775962 刘晶晶 (0755)83255933 辜丽娟 (0755)83253022 高艳娟 (0755)83254133 伏财勇 (0755)23607963 邓欣 (0755)23607962	ctq5979@htsec.com liujj4900@htsec.com gulj@htsec.com gyj6435@htsec.com fcy7498@htsec.com dx7453@htsec.com	上海地区销售团队 贺振华 (021)23219381 姜洋 (021)23219442 高溱 (021)23219386 李唯佳 (021)23219384 胡雪梅 (021)23219385 黄毓 (021)23219410 朱健 (021)23219592 黄慧 (021)23212071 卢倩 (021)23219373 孙明 (021)23219990 孟德伟 (021)23219989	hzh@htsec.com jy7911@htsec.com gaoqin@htsec.com jiwj@htsec.com huxm@htsec.com huangyu@htsec.com zhuj@htsec.com hh9071@htsec.com lq7843@htsec.com sm8476@htsec.com mdw8578@htsec.com	北京地区销售团队 赵春 (010)58067977 郭文君 (010)58067996 隋巍 (010)58067944 江虹 (010)58067988 杨帅 (010)58067929 张楠 (010)58067935	zhc@htsec.com gwj8014@htsec.com sw7437@htsec.com jh8662@htsec.com ys8979@htsec.com zn7461@htsec.com
--	--	---	---	--	--

海通证券股份有限公司研究所
地址：上海市黄浦区广东路 689 号海通证券大厦 13 楼
电话：(021)23219000
传真：(021)23219392
网址：www.htsec.com