



金工基金研究

证券研究报告
量化研究

2014 年 4 月 9 日

他山之石（2014 年 4 月）

相关研究

他山之石系列一	2012.08.15
他山之石系列三	2012.11.05
他山之石系列五	2013.01.21
他山之石系列七	2013.04.26
他山之石系列九	2013.05.23
他山之石系列十一	2013.07.26
他山之石系列十三	2013.10.09
他山之石系列十五	2013.12.09
他山之石系列十七	2014.02.14

总编：高道德
SAC 执业证书编号：
S0850511010035
电话：021-23219569
Email: gaodd@htsec.com

吴先兴
SAC 执业证书编号：
S0850511010032
电话：021-23219449
Email: wuxx@htsec.com

丁鲁明
SAC 执业证书编号：
S0850511010033
电话：021-23219068
Email: dinglm@htsec.com

郑雅斌
SAC 执业证书编号：
S0850511040004
电话：021-23219395
Email: zhengyb@htsec.com

朱剑涛
SAC 执业证书编号：
S0850512100002
电话：021-23219745
Email: zhuajt@htsec.com

冯佳睿
SAC 执业证书编号：
S0850512080006
电话：021-23219732
Email: fengjr@htsec.com

杨勇
SAC 执业证书编号：
S0850512080006
电话：021-23219945
Email: yy8314@htsec.com

张欣慰
SAC 执业证书编号：
S0850513070005
电话：021-23219370
Email: zxw6607@htsec.com

行业内消息的扩散与股票收益的领先滞后关系

推荐理由：文章从多个维度寻找行业内股票收益之间的领先滞后关系，发现了大市值公司的收益显著领先于小市值公司收益，从而为投资者预测行业内收益的传导方向提供了有效要素。除了市值指标外，也寻找到了多个影响收益传导的要素，如分析师覆盖度、机构持仓等，并且发现收益传导作用很好的解释了行业内动量效应的存在。

金融时间序列的有息平滑

推荐理由：本文提出了一个新颖的平滑时间序列的算法。该算法根据作者提出的有息分割点原则构建，可以将时间序列分割成若干线段，有效地过滤噪声，同时提取出时间序列的长期和短期趋势，从而为行情走势的模式识别提供了可靠的分析基础。

基于通道的趋势交易系统 and 反转交易系统之改进

推荐理由：不论是偏好趋势交易还是偏好反转交易的投资者，以布林带为代表的通道系统无疑是最简单明了的。但当前市场是趋势还是反转的，通道系统本身并不能回答这一问题。此外，如何通过信号过滤处理伪信号、如何选择交易时机等都是影响交易系统最终表现的重要因素。本文摘选的两篇文章试图从不同角度来改进基于通道的趋势交易系统以及反转交易系统，较全面的回答了以上问题。

跟踪误差最小化的一类线性模型

推荐理由：本文研究了四类最小化投资组合与基准指数收益之间跟踪误差的模型。鉴于通常对基金经理的业绩评价都是线性的，因此本文认为线性偏差比二次偏差更能精确地描述投资者对待风险的态度。这些模型的一个共同点是采用最小化绝对偏差代替传统优化模型中的平方偏差。线性规划方法被用来求解精确的组合配置权重。模型被应用于一个包含 6 个国家（美国、日本、英国、德国、法国和瑞士）股票市场指数的投资组合中，目标是最小化组合与 MSCI 世界股市指数之间的跟踪误差。所有计算结果都与二次跟踪误差优化模型进行了对比。各模型所得优化组合的权重以及风险/收益性质的差异十分显著，这表明选择哪类优化模型应当以特定的投资目标为导向。

基于信用利差相对价值的行业轮换

推荐理由：文章将公司资本结构资产价格的基本关系扩展到指数水平。使用 HY/B 信贷指数和标准普尔行业 ETF 构造线性相对价值模型，然后基于 ETF 偏离公允价值的距离进行排序。这一排名成为是简单的相对实力投资策略的基础，这个策略产生相对于标准普尔 500 指数优越的、经风险调整的绝对回报。由于使用信贷市场来判断相对价值，这种投资策略与许多流行的排名方法不相关，并且可以作为现有策略的增强策略使用。此外，策略是为只做多头的投资者设计的，可以用高流动性指数 ETF 实现。

极端变动的丛集效应:股价与天气

推荐理由: 股票市场存在“波动率丛集”效应, 本文发现股价在极端变动日之前三天的日均波幅会明显放大。这说明投资者可能可以构建一个择时策略, 在预测到极端负面股市收益之前将股票变现。事实上, 作者按照此规律构建择时策略, 成功地避免了近80%的负向极端波动。但是需要注意的是, 长期来看这一策略并未能大幅战胜买入持有策略, 但净值的波动率却得到大幅的降低。

业绩公告带来的波动率套利机会

推荐理由: 盈利动量漂移效应 (Post Earnings Announcement Drift) 是市场上已经研究较多的一种现象, 指的是上市公司盈利增长公告后较长时间内股价仍能够显著战胜市场指数。除了收益率的动量, 公司盈利公告前后还存在一种波动率偏移现象, 期权推出后, 投资者就可以借助期权和现货组合来对这种波动率的变动进行事件套利, 本文作者用韩国数据进行了实证, 发现该项套利空间十分可观。

金融中介数据在资产回报截面数据回归中的应用

推荐理由: 现代金融理论认为, 资产与一些随机贴现因子的关联关系可以决定资产定价。在本文中, 作者通过计算美国市场金融中介杠杆和进一步数据处理, 得到对应杠杆因子, 并就历史主要经济事件时点对杠杆因子的有效性进行解释。其次, 将杠杆因子代替随机贴现因子, 添加到预测资产收益的线性模型中去。最后建立时间序列和截距回归模型证明了金融中介机构的杠杆指标能很大程度上解释各类资产的平均超额回报, 这些资产包括不同市值的股票组合, 不同动量的股票组合, 不同持有久期的债券组合等。作者向我们证明了金融中介的杠杆是资产定价的重要因素。

目 录

行业内消息的扩散与股票收益的领先滞后关系	3
金融时间序列的有息平滑	8
基于通道的趋势交易系统和反转交易系统之改进	15
跟踪误差最小化的一类线性模型	26
基于信用利差相对价值的行业轮换	34
极端变动的丛集效应:股价与天气	44
业绩公告带来的波动率套利机会	51
金融中介数据在资产回报截面数据回归中的应用	54

行业内消息的扩散与股票收益的领先滞后关系

文献来源: Industry Information Diffusion and the Lead-Lag Effects in Stock Returns, Kewei Hou, Fisher College of Business, Ohio State University, Working Paper

推荐人: 郑雅斌 021-23219395

推荐理由: 文章从多个维度寻找行业内股票收益之间的领先滞后关系, 发现了大市值公司的收益显著领先于小市值公司收益, 从而为投资者预测行业内收益的传导方向提供了有效要素。除了市值指标外, 也寻找到了多个影响收益传导的要素, 如分析师覆盖度、机构持仓等, 并且发现收益传导作用很好的解释了行业内动量效应的存在。

1、引言

本文主要研究行业内消息的扩散受到哪些因素的影响, 从而分析行业内股票收益的领先、滞后关系受到哪些要素影响。我们发现行业内, 市值较大公司的收益对消息的反映领先于小市值公司, 且收益的传导受到分析师覆盖人数、机构持仓情况以及股票交易量的影响。另外, 我们发现流通股本较大的公司, 或是高估值的公司, 其收益领先于小股本或是低估值公司。更为有趣的是, 小公司的股价对于大公司公布利好消息的反映程度可能大于自己公司发布的利好消息。而且这种收益传导解释了行业动量效应的存在。

2、数据

文章使用了 NYSE、AMEX、NASDAQ 几个指数成分 1963 年到 2001 年的日交易数据, 计算股票的周度收益。财务报表的相关数据采用季报数据, 分析师覆盖数据采用股票滚动一年分析师覆盖数量之和。

3、行业内领先滞后关系

不同行业股票的股价受到不同新闻的影响, 且新闻的传导速度应该有所不同, 我们分别在 Fama-French 的 12 个行业中进行分析。在每一个行业中, 我们都会针对不同的市值组合进行剖析, 按照股票市值将股票划分为三个组合, 市值最大的 30%, 最小的 30% 以及中间档。

● 交叉自相关以及领先滞后的统计检验

下表中我们主要统计市值最大组合以及市值最小组合收益之间的领先滞后关系。收益的滞后时间窗口从一周考察到四周。表 1 中主要罗列了 6 个行业的数据, $P(l,1)$ 代表第 l 个行业的市值最小组合收益, $P(l,3)$ 代表行业内市值最大组合的收益。 ρ 为相关性, $\rho(j,1)$ j 代表行业, 1 代表市值最小组合的收益, ρ 的角标代表考察领先第几期的收益。能够发现, 市值较大组合的领先收益于市值较小组合的滞后收益之间的相关系数 $\rho(j,3)$ 总是大于相关系数 $\rho(j,1)$ 。这说明从市值角度而言, 行业内总是大市值的公司对消息反映较快, 从而将前期收益传导至小市值公司。小市值公司的收益对大市值公司收益的预测能力较差。

表 1 市值组合收益的领先滞后关系

Portfolio industry, size	N	Mean Return	Std. dev. Return	Mean Size	Median Size	$p_0(1)$	$p_0(3)$	$p_1(1)$	$p_1(3)$	$p_2(1)$	$p_2(3)$	$p_3(1)$	$p_3(3)$	$p_4(1)$	$p_4(3)$
P1,1	102	0.0034	0.0225	0.0085	0.0077	1.0000	0.6204	0.3528	0.3312	0.2040	0.1739	0.1607	0.1341	0.0997	0.0962
P1,3	102	0.0027	0.0196	2.1222	0.6566	0.6204	1.0000	0.1009	0.1611	0.0641	0.0893	0.0092	0.0705	-0.0091	0.0086
P2,1	45	0.0036	0.0290	0.0096	0.0090	1.0000	0.6122	0.2708	0.3179	0.1652	0.1558	0.1098	0.1081	0.0972	0.0847
P2,3	45	0.0026	0.0244	3.2086	0.5185	0.6122	1.0000	0.0862	0.1851	0.0668	0.0667	0.0247	0.0561	0.0287	0.0299
P3,1	193	0.0041	0.0229	0.0105	0.0097	1.0000	0.7094	0.3789	0.3428	0.2234	0.1786	0.1580	0.1482	0.1100	0.1096
P3,3	193	0.0024	0.0230	1.3927	0.5623	0.7094	1.0000	0.1038	0.1765	0.0381	0.0509	0.0063	0.0583	-0.0025	-0.0035
P4,1	67	0.0056	0.0313	0.0128	0.0118	1.0000	0.5828	0.2566	0.2900	0.1400	0.1163	0.0746	0.0630	0.0567	0.0398
P4,3	67	0.0022	0.0270	3.4527	1.0951	0.5828	1.0000	0.0501	0.1106	-0.0022	-0.0037	-0.0001	-0.0012	0.0073	-0.0019
P5,1	34	0.0039	0.0271	0.0135	0.0116	1.0000	0.5054	0.2647	0.2454	0.1338	0.0894	0.1117	0.0899	0.0534	0.0525
P5,3	34	0.0025	0.0220	3.7118	1.3395	0.5054	1.0000	0.0770	0.0950	0.0086	-0.0022	0.0312	0.0277	-0.0049	-0.0066
P6,1	179	0.0058	0.0313	0.0084	0.0079	1.0000	0.6739	0.3953	0.3784	0.2286	0.1502	0.1582	0.1402	0.0868	0.1061
P6,3	179	0.0028	0.0370	1.7546	0.3446	0.6739	1.0000	0.0974	0.1238	0.0638	0.0295	0.0436	0.0783	-0.0490	-0.0169

资料来源：Industry Information Diffusion and the Lead-Lag effects of Stocks

● 回归系数检验

除了相关性之外，我们进一步检验回归系数验证之前的结论。下面的回归公式中，K 代表领先滞后期，总共考察领先四周的收益。结果发现， $\sum_{k=1}^K b(k)$ 显著不等于零，且其大于 $\sum_{k=1}^K c(k)$ 。这与前面的结论一致。且系数都能够通过 1% 的显著性检验。

$$R_{i,1}(t) = a_{i,0} + \sum_{k=1}^K a_k R_{i,1}(t-k) + \sum_{k=1}^K b_k R_{i,3}(t-k) + \varepsilon_{i,1}(t),$$

$$R_{i,3}(t) = c_{i,0} + \sum_{k=1}^K c_k R_{i,1}(t-k) + \sum_{k=1}^K d_k R_{i,3}(t-k) + \varepsilon_{i,3}(t).$$

● 行业内与行业间的效果

前面我们考察的是行业内的收益传导，那么行业间是否也存在收益传导效应，本节进行验证。将其他 11 个行业的前期收益作为一个自变量，包含到回归方程中。结论发现 $\sum_{k=1}^K b(k)$ 为 0.23 且在 1% 的水平上显著，而 $\sum_{k=1}^K f(k)$ 仅有 0.029 且并不显著。由此，行业内的传导作用明显强于行业间的传导。

$$R_{i,1}(t) = a_{i,0} + \sum_{k=1}^K a_k R_{i,1}(t-k) + \sum_{k=1}^K b_k R_{i,3}(t-k) + \sum_{k=1}^K f_k R_{\Sigma,j,3}(t-k) + \varepsilon_{i,1}(t),$$

● 强度检验

我们分别采用了不同的收益加权方式（等权、市值加权等），对不同周期的股票收益进行考察，观察不同显著性水平，结论都和我们之前得到的一致。

● 坏消息的传导速度更慢？

好消息和坏消息的传导速度不同，这里对其影响进行鉴定。区分好坏消息的方式，采用前期大市值组合的收益正负方向。引入一个虚变量，D 为 1 时，前期收益为正，否则为 0。

$$R_{i,1}(t) = a_{i,0} + a_1 R_{i,1}(t-1) D_{i,1}(t-1) + a_2 R_{i,1}(t-1) + b_1 R_{i,3}(t-1) D_{i,3}(t-1) + b_2 R_{i,3}(t-1) + \varepsilon_{i,1}(t),$$

表 2 中能够看到，引入变量的系数 b1 为 -0.155 且结果显著，b1+b2 仅有 0.1283，小于 b2 的一半 0.2841，说明前期收益为正时，大市值组合的收益预测能力较差。即负消息的收益传导更能够被预测出来，原因可能在于负收益的传导相对较慢，这主要源自很多做空交易的限制以及投资者的倾向做多行为和心里。

表 2 好消息的检验

Panel E: Intra-Industry Lead-Lag Effect, Good News versus Bad News				
LHS	$R_{i,1}(t-1)D_{i,1}(t-1)$	$R_{i,1}(t-1)$	$R_{i,3}(t-1)D_{i,3}(t-1)$	$R_{i,3}(t-1)$
$R_{i,1}(t)$	0.1447 6.60***	0.1004 6.03***	-0.1558 -6.86***	0.2841 17.83***
$R_{i,3}(t)$	0.0084 0.41	-0.0091 -0.59	-0.0130 -0.57	0.1571 9.88***

资料来源：Industry Information Diffusion and the Lead-Lag effects of Stocks

注：*代表 10%显著，**代表 5%显著，***代表 1%显著

4、其他对领先滞后效应有影响的变量

除了大小市值组合之间的领先滞后关系，还有其他因素可能影响收益的传导。

● 分析师覆盖、机构持仓、交易量

分析师覆盖采用之前一年的数据，交易量采用过去一年的周度平均换手率。结论是，分析师覆盖程度较高（或机构持仓较高、或成交相对活跃）的公司，其收益领先于覆盖率较低（机构持仓低、成交不活跃）的公司。

● 价值、成长变量

高估值公司对于环境、消息的敏感程度相对更高，而我们的结论也发现公司的估值指标在收益的传导中具有解释作用：前期估值较高的公司，同期预测未来小公司的收益具有显著解释作用。

5、跨行业的领先滞后效应

在前面的文章中，在每一个行业内部研究领先滞后效应，那么不同行业之间是否会由于行业特性的区别，存在一定的差异呢。本节在回归方程中，引入行业特性指标，看对于小市值公司的收益解释能力是否有所改变。公式中的 IC_i 即代表行业特性指标。分别考虑以下指标：行业内的公司平均市值、分析师覆盖程度、机构持仓、换手率、异常波动率、分析师分散度、行业竞争程度。

$$R_{i,1}(t) = a_{i,0} + a_1 R_{i,1}(t-1) + b_1 R_{i,3}(t-1) + b_2 R_{i,3}(t-1) \times IC_i(t) + \epsilon_{i,1}(t),$$

我们发现以下这些行业的领先滞后作用更为明显：小市值行业、分析师跟踪较少的行业、机构持仓较低、交易活跃度较低、分析师分散度较高。除此之外，在集中程度较高的行业中（竞争性较低），收益的传导作用难以解释；而在竞争性很强的行业中，大公司前期的收益对未来小公司的收益解释能力很好。竞争程度采用行业内公司的流通股本的方差衡量。

表 3 行业特性指标的解释作用

LHS	$R_{i,t}(t-1)$	$R_{i,t}(t-1)$	Interaction Term
<i>Panel A: IC=Industry Median In(Size)</i>			
$R_{i,t}(t)$	0.2062 27.04***	0.6787 10.98***	-0.0439 -8.03***
$R_{i,t}(t)$	-0.0031 -0.42	0.1414 17.80***	-
<i>Panel B: IC=Industry Median Analyst Coverage</i>			
$R_{i,t}(t)$	0.2449 26.49***	0.2176 13.77***	-0.0147 -5.17***
$R_{i,t}(t)$	-0.0248 -2.48**	0.1311 13.50***	-
<i>Panel C: IC=Industry Median Institutional Ownership</i>			
$R_{i,t}(t)$	0.2236 19.90***	0.1972 9.41***	-0.0033 -3.45***
$R_{i,t}(t)$	-0.0249 -2.07**	0.1217 10.52***	-
<i>Panel D: IC=Industry Median Turnover</i>			
$R_{i,t}(t)$	0.1574 19.71***	0.2568 16.11***	-8.8179 -5.77***
$R_{i,t}(t)$	-0.0027 -0.39	0.1050 12.96***	-
<i>Panel E: IC=Industry Median Idiosyncratic Volatility</i>			
$R_{i,t}(t)$	0.2008 23.85***	0.1326 5.92***	1.0973 2.65***
$R_{i,t}(t)$	-0.0053 -0.68	0.1548 17.87***	-
LHS	$R_{i,t}(t-1)$	$R_{i,t}(t-1)$	Interaction Term
<i>Panel F: IC=Industry Median Analyst Dispersion</i>			
$R_{i,t}(t)$	0.2352 23.33***	0.0885 4.75***	0.4038 3.09***
$R_{i,t}(t)$	-0.0248 -2.48**	0.1311 13.50***	-
<i>Panel G: IC=Industry HERF</i>			
$R_{i,t}(t)$	0.2138 28.21***	0.1851 21.92***	0.1620 3.02***
$R_{i,t}(t)$	-0.0031 -0.42	0.1414 17.80***	-

资料来源: Industry Information Diffusion and the Lead-Lag effects of Stocks

注: *代表 10%显著, **代表 5%显著, ***代表 1%显著

6、年报披露与领先滞后的关系

在考察收益的传导作用时，我们前面主要用了过去的股价数据，同时可以参考的另外一个重要来源是上市公司的年报和季报数据。我们分析当财报披露时，其业绩的重大变动在股价传导中的作用。

业绩的重大变动通过两种方式可以衡量：1、季报披露当周，股票的异常收益率（采用对应市值、估值的基准组合计算异常收益率）；2、（最新一期季报内容-过去四期季报平均）/季报波动率。将小市值公司的收益率针对市值、估值、公司自身的业绩变动（收益、报告两种衡量方式）(AR)、大市值公司的业绩变动(AR_{i,3})，大市值公司的前期收益进行回归，回归系数如表所示。我们发现，前期大市值公司的业绩变动对小公司的收益影响更大，甚至高过小公司自己的公告内容。但其解释力度相对于大市值公司前期的组合收益而言相对较低，因为其含有的噪声信号较多。

表 4 行业特性指标的解释作用

Panel A: Return-Based Measure of Earnings Surprise							
ln(Size)	ln(BE/ME)	AR	AR ₃	R ₃ (-1)	R ₃ (-2)	R ₃ (-3)	R ₃ (-4)
-0.0009	0.0006						
-6.95	4.35						
-0.0008	0.0006	0.0055					
-6.87	4.30	6.09					
-0.0008	0.0006		0.1266				
-6.82	4.70		8.91				
-0.0008	0.0006	0.0054	0.1257				
-6.74	4.65	5.94	8.86				
-0.0009	0.0006	0.0050	-0.0013	0.1684	0.0721	0.0781	0.0105
-6.71	5.72	5.61	-0.04	11.00	2.55	4.86	0.64

Panel B: Earnings-Based Measure of Earnings Surprise							
ln(Size)	ln(BE/ME)	SUE	SUE ₃	R ₃ (-1)	R ₃ (-2)	R ₃ (-3)	R ₃ (-4)
-0.0008	0.0008						
-6.86	5.18						
-0.0009	0.0008	0.0003					
-7.29	5.42	10.31					
-0.0008	0.0008		0.0014				
-6.88	5.79		4.42				
-0.0009	0.0008	0.0003	0.0013				
-7.29	5.99	10.20	4.05				
-0.0009	0.0009	0.0003	0.0007	0.1432	0.0628	0.0812	0.0187
-7.17	7.11	10.21	1.83	9.04	3.69	5.52	1.19

资料来源：Industry Information Diffusion and the Lead-Lag effects of Stocks

7、领先滞后关系与行业动量效应

在海外的多数实证中都发现行业内存在显著的动量效应，收益的传导作用基本能够充分解释这一效应。对每个行业市值最小的 30% 公司收益进行回归，引入前期行业的涨跌幅作为行业动量因子，分别考察前四周、26 周以前 52 周的动量因子（表中的，R_i(-26:-1)，R_i(-52:-1)）。下表中看到，当不引入大市值公司前期的涨跌幅因素时，行业动量确实对收益有较好的解释作用，但是一旦引入大市值公司的涨跌幅因子，动量因子的解释度明显下降，市值组合之间的传导关系构成了动量效应存在的重要原因。

表 5 收益传导对行业动量的解释作用

ln(Size)	ln(BE/ME)	R ₃ (-4:-1)	R ₃ (-26:-1)	R ₃ (-52:-1)	R ₃ (-1)	R ₃ (-2)	R ₃ (-3)	R ₃ (-4)
-0.0009	0.0005							
-7.73	3.85							
-0.0009	0.0005	0.0642						
-7.57	3.98	15.34						
-0.0009	0.0005		0.0155					
-7.90	3.91		10.82					
-0.0009	0.0005			0.0094				
-7.85	4.07			9.22				
-0.0009	0.0005	0.0468	0.0030	0.0060				
-7.98	4.33	8.937783	1.26	3.67				
-0.0009	0.0005	-0.0105	0.0053	0.0035	0.1061	0.0784	0.0593	0.0355
-7.85	4.95	-1.03	1.59	1.54	5.29	4.18	3.24	1.88

资料来源：Industry Information Diffusion and the Lead-Lag effects of Stocks

金融时间序列的有息平滑

原文: Informative Smoothing of Financial Time Series, P34-39, IFTA Journal, 2014

推荐人: 杜灵 021-23219760

推荐理由: 本文提出了一个新颖的平滑时间序列的算法。该算法根据作者提出的有息分割点原则构建, 可以将时间序列分割成若干线段, 有效地过滤噪声, 同时提取出时间序列的长期和短期趋势, 从而为行情走势的模式识别提供了可靠的分析基础。

摘要: 本文提出了一个新颖的平滑时间序列的算法。该算法根据作者提出的有息分割点原则构建, 可以有效地将时间序列分割成若干线段, 有效地过滤噪声, 提取出时间序列的趋势。

关键词: 有息平滑 (informative smoothing), 有息分割点 (informative breaking point), DP 算法 (divide and conquer principle), 幂等 (idempotent)

1、介绍

为了确保结果的稳健和可靠, 在对时间序列进行分析前需要先对其进行平滑以过滤随机扰动和异常值。平滑可以是模式识别变得更加容易, 这一点对技术分析尤为重要, 因为模式可以用来预测时间序列的移动。由于模式通常都是线性的, 因此分段平滑方法是主流。这些方法将时间序列分成若干线段, 每一段则用一个线性函数做近似。这类方法的代表之一就是 ZigZag。

但是大部分平滑方法需要使用者指定一个平滑参数, 以确定对原始时间序列平滑的程度, 例如常见的计算移动平均时所采用的周期。尽管平滑参数很关键, 但通常的方法缺乏一个明确的标准来确定参数的选择。

针对上述问题, 本文中提出了一个有息分割点原则 (CIBP), 可以确定出以交易为目的的最优值。基于这个原则, 本文提出了一个无参数的有息平滑算法 (IS)。它可以区分出长期和短期趋势并将时间序列分割成多个幂等线段。


2、DP 算法

IS 算法源自 DP 算法。DP 算法 (Ramer 1972, Douglas/Peucker 1973) 最初提出是用以平滑河水流动轨迹的。DP 算法需要一个平滑参数 ϵ 以及一组序列 $S = (P_1, \dots, P_n)$ 作为输入。其算法如下 (图 1):

- 1) 用一个线段 (绿色, 图 1b) l 连接 P_1 到 P_n
- 2) 计算各个点到该绿色线段的距离, 记 $d_{\max}$ 为最大距离, P 为对应的点。
- 3) 如果 $d_{\max} \geq \epsilon$ (图 1b、1c、1d), 则 P 为一个分割点。DP 算法将被迭代应用于 $(P_1, \dots, P)$ 和 $(P, \dots, P_n)$
- 4) 如果 $d_{\max} < \epsilon$ (图 1e), 则算法结束, l 即为最终结果。
- 5) 对每个被分割的子序列完成上述操作后即得到最终结果 (图 1f)。

显然, 参数 ϵ 很关键, 太小则时间序列被分割成多个小段 (大量噪声被保留); 太大则分割点过少 (部分有效信息被过滤掉)。

图 1 DP 算法



资料来源：Informative Smoothing of Financial Time Series, P34-39, IFTA Journal, 2014

3、IS 算法

3.1 输入

由于 IS 算法是针对金融时间序列设计的，而金融时间序列通常包含了四类数值：开盘价，最高价，最低价和收盘价。首先，算法要计算 $Y = (Y_1, \dots, Y_n)$ ，其中

$$Y_t = (\text{close}_t + (\text{high}_t + \text{low}_t)/2)/2$$

并针对 Y 进行平滑处理。此外，定义了 $v = (v_1, \dots, v_n)$

$$v_t = (\text{high}_t - \text{low}_t)/2$$

作为波动率的度量。

3.2 第一步：改进的 DP 算法


IS 算法包含三个部分，第一部分是使用改进的 DP 算法处理输入 Y 。图 2 展示了原始 DP 算法对 Y 的处理（图 2a）以及改进版本的结果（图 2b）。改进的 DP 算法与原始算法主要有两点区别：

第一点，测量每个点到连线的垂直距离 d_t （如图 2b 上红线所示），而并非距离。因为对金融时间序列，价格的差具有实际意义。

第二点，不再是比较最大距离 $d_{\max}$ 和 ϵ 之间的大小，我们取而代之比较 $d_{\max}$ 和 $f \cdot v_t$ 。此处， f 本质上是一个控制平滑效果的参数。换言之，当所有点都在 $(y - f \cdot v, y + f \cdot v)$ 中

所包含的时候，算法结束。另外，需要注意，在图 2b 中，突破点（breakthrough）并不是一个分割点，因为分割点需要提供更多地关于真实 Y 与估计值的差异的有效信息。此处，我们暂时假定 f 已知。至于如何求出 f ，在附录中详加介绍。

图 2 原始 DP 算法 (a) 和改进的 DP 算法 (b)



资料来源：Informative Smoothing of Financial Time Series, P34-39, IFTA Journal, 2014


3.3 分割点类型

改进的 DP 算法所生成的平滑后的线段 s 如图 3 所示。所有的 Y 依据平滑效果可以分为三部分。第一部分是上升点，在图中以绿色表示；第二部分是下降点，在图中以红色表示；第三部分是分割点，以蓝色表示。

如果分割点连接的是两个上升段或是两个下降段，即两个同向段，则这样的分割点称为无息分割点（non-informative breaking point）。反之，则称为有息分割点（informative breaking point）。

一方面，无息分割点的存在说明分割的过细，意味着 f 的值过小。另一方面， f 应该尽可能的小已使全部有息分割点都被找到。因为有息分割点是真正对交易有意义的点，有息分割点实质上是一个转折点，它意味着趋势的反转。

图 3 使用任一 f 得到的改进的 DP 算法结果示例



资料来源：Informative Smoothing of Financial Time Series, P34-39, IFTA Journal, 2014

由此，我们推出了有息分割点原则（CIBP）

线性分段的平滑程序的平滑度 $\epsilon \geq 0$ ($=0$ 意味着完全没有平滑)，其最适合交易目的的值是使得所有分割点都是有息分割点的最小值。

在附录中我们提供了一种根据 CIBP 来确定 f 的方法。

3.4 第二步：局部化

至此，使用改进的 DP 算法所得到的平滑结果已经可以分析长期趋势。但是这个平滑结果并不适合用来分析短期趋势，因为 f 是利用所有数据点所确定的。对于部分线段，一个更小的 f 或许就可以满足 CIBP。


为了局部化算法的初始结果，我们对初始结果中的每一个线段 s_i 迭代使用改进的 DP 算法。这个步骤持续地应用于每个片段，直至每个线段都是幂等的（即对该线段再次应用 DP 算法不再改变线段）。

如图 4 所示是一个局部化的示例。第一次应用 DP 算法后，我们得到了全局结果，如图 4b 所示，是两个线段。对这两个线段分别再次应用 DP 算法，线段 2 保持不变，即线段 2 是幂等的。而线段 1 被分解成了两个新的线段，如图 4c 所示。对新的线段再重复应用 DP 算法，没有新的线段被分解出来。此时，所有的线段都是幂等的。IS 算法的第二步就此完成。

3.5 第三步：合并

如图 4c 所示，IS 算法的第二步之后产生出了无息分割点。因此，需要对已有的线段进行合并，合并后的图形如图 4d 所示。合并之后，为了确保所有的线段是幂等的。我们需要对新形成的线段再次应用 DP 算法，直至幂等。

图 4 IS 算法



资料来源：Informative Smoothing of Financial Time Series, P34-39, IFTA Journal, 2014

4、应用实例：ZigZag 方法的替代

ZigZag 是一个常见线性分段的平滑方法，其对原始时间序列的平滑程度取决于一个人为设定的值。因此，这个方法有三个缺点。

1) 同时也是最重要的一点。ZigZag 的结果严重依赖于人为设定的平滑参数。


2) 平滑参数是给定值，因此所有的线段都有同样的平滑程度。然而，平滑程度应该和交易的波动率相关。波动率越高，需要的平滑程度也就越高。

3) ZigZag 生成的线段不是幂等的，因此会随着新数据的出现而改变。

IS 算法可以有效的克服上述的三个缺点，可以作为 ZigZag 方法的一个替代。如图 5 所示，是对 2012 的 DAX 行情的分解。对于不同的平滑参数，ZigZag 给出的平滑折线是不同的。而 IS 算法将 DAX 的走势分解成了 5 部分。前两个线段，IS 算法划分出了多

个短期趋势，而对于第三个线段，IS 算法给出的短期和长期趋势是相同的。而 ZigZag 无法给出这样的分解。对于 IS 分解出的第 5 段长期趋势，在去除了趋势之后，其行情的形状如同一个倒茶柄，这是一个典型的由牛市进入熊市的信号。后面的 2013 年的 DAX 走势验证了这个判断。

图 5 2012 年 DAX 走势的 k 线图的 IS 算法平滑 (a) 和 ZigZag 平滑 (b)



资料来源: Informative Smoothing of Financial Time Series, P34-39, IFTA Journal, 2014

为了更客观地比较 ZigZag 与 IS 算法。我们比较了 DAX 中 30 只个股在 2013 年前 4 个月的行情分解。一方面要计算分解出多少个线段 (平滑程度)，另一方面要测算平滑线段与原始行情之间的差别 (精确度)。对精确度，我们采用

$$\chi^2 = \sum_{i=1}^n \frac{(\hat{Y}_t - Y_t)^2}{Y_t}$$

来度量。显然，分解出来的线段的数量和精确度之间是正相关的。因此，我们定义 $\tau = \chi^2 \cdot \#s$ 来比较算法的优劣，其中 $\#s$ 是线段的数量。 τ 的值越小说明算法越好。

比较结果显示 53.3% 的最小值是 IS 算法给出的。

5、结论

本文中我们提出了一个事后的金融时间序列的 IS 平滑算法。其有如下优点

- 1) 以 CIBP 为指导来确定对数据的平滑程度，使得结果更加客观。
- 2) 可以自动提供出长期趋势和短期趋势
- 3) 可以从短期趋势中去除长期趋势，进而更加有效地进行模式识别。
- 4) 短期趋势线段都是幂等的，因此是稳健的。

附录

此处具体说明 f 的确定方法。

我们首先注意到，在线段 $[\tau_{\text{from}}, \tau_{\text{to}}]$ 中，当且仅当有一个 t 使得 $d_t \geq f \cdot v_t$ 时，才会有一个新的分割点产生。因此，如果

$$f > \max_{t \in [\tau_{\text{from}}, \tau_{\text{to}}]} \left\{ \frac{d_t}{v_t} \right\} := c_{\text{from}; \text{to}}$$

成立，则不会有新的分割点出现。因此我们定义如下的循环迭代算法 $\text{getCandidates}(\tau_{\text{from}}, \tau_{\text{to}})$ 来寻找所有可能的 f :

- 1、设 $cs := \{c_{\text{from}; \text{to}}\}$
- 2、找到 d_{max} 所对应的那个点 P ，记其时间为 τ^* 。
- 3、如果 $\tau_{\text{from}} < \tau^* < \tau_{\text{to}}$ ，则

$$cs := cs \cup \text{getCandidates}(\tau_{\text{from}}, \tau^*) \cup \text{getCandidates}(\tau^*, \tau_{\text{to}})$$

- 4、将 cs 按照升序排列并返回

在得到 cs 之后，我们来计算 f :

- 1、计算 $cs = \text{getCandidates}(1, n)$
- 2、设 $i = 1$
- 3、使用 $f := cs[i]$ 来平滑 Y
- 4、如果结果中包含无息分割点，设 $i = i + 1$ 并重复步骤 3
- 5、返回 f

基于通道的趋势交易系统 and 反转交易系统之改进

原文: Robin Boldt. Applying Trading Strategies to Price Channel Breakout Trading—Statistical Significance of Channel Breakout Variation, IFTA Journal. 2012:33-40.

Ka Ying Timothy Fong. Regime-Switching Trading Bands Using A Historical Simulation Approach, IFTA Journal. 2013:20-27.

推荐人: 杨勇 021-23219945

推荐理由: 不论是偏好趋势交易还是偏好反转交易的投资者, 以布林带为代表的通道系统无疑是最简单明了的。但当前市场是趋势还是反转的, 通道系统本身并不能回答这一问题。此外, 如何通过信号过滤处理伪信号、如何选择交易时机等都是影响交易系统最终表现的重要因素。本文摘选的两篇文章试图从不同角度来改进基于通道的趋势交易系统以及反转交易系统, 较全面的回答了以上问题。

一、基于通道的交易系统简介: 通道突破型 VS 反转型

在上个世纪 80 年代, John Bollinger 创建并发展了布林带 (Bollinger Band), 考虑到当时相对落后的硬件水平, 它在算法上是比较容易实现的。不论是偏好趋势交易还是偏好反转交易的投资者, 以布林带为代表的通道指标无疑是最简单明了的交易系统, 他们能非常清晰的帮助投资者确定进出场的位置。

但随着市场的变化以及计算机运算速度的提高, 对这套技术系统质疑的声音越来越多, 主要集中在两个方面:

首先, 布林带既可以设计成均值回复交易系统, 也可以设计成通道突破交易系统, 但是该当成哪种系统来用布林带本身并无法给出信息: 当价格触及布林带上轨或下轨时, 既有理由看成是趋势的确认, 又有理由认为价格将出现反转; 另外一种情形是, 在价格未最终选择趋势还是反转之前, 它往往会缠绕在通道边界运动, 从而不断产生伪信号, 此时不论布林带是作为反转交易系统还是趋势突破交易系统都是容易失效的。

其次, 布林带假设价格收益率是服从正态分布的, 但真实的分布往往是尖峰厚尾的, 出现极端值的概率比正态分布要高, 用正态分布来计算波动并不准确。

与布林带的核心思想类似, 技术分析中还有类似的通道系统: Moving Average Envelopes、Keltner Channel 和 Donchian Channel 方法。其中:

Bollinger Band 的核心是构建基于股票价格移动均线的 95% 置信区间 (2σ 原则), 时间周期一般都选 20 天。作为反转交易系统, 布林带的上界代表了压力线, 下界代表了支撑线, 当价格向下跌破下界的时候开多, 当价格向上突破上界的时候开空, 若作为趋势交易系统, 交易方向则恰恰相反。

Moving Average Envelopes 方法的基准线, 可以是简单的移动平均线或者指数移动平均线, 并在这个基础上加减固定的百分比 (比如 5%) 形成上下界。虽然在计算上比较简单, 但这个固定百分比的定义不明确, 也没有直观统计意义。

Keltner Channel 方法的基准线, 可以是简单的移动平均线或指数移动平均线 (20 天), 并在这个基础上加减两倍的 ATR (一般是 14 天) 形成上下界。与构建 Bollinger Band 时的价格标准差不同, ATR 的最大好处在于使用了真实的最高价和最低价来确定波动率, 能更好的反映当前的价格波动。

Donchian Channel 方法主要是通过计算过去 n 天的最高点和最低点来构建上下通道。与前面三个策略的不同之处在于，我们往往把 Donchian Channel 当成趋势交易系统来用，而前面的三个则在趋势交易和反转交易中都有应用。在下面的实证部分中，我们将对如何改进 Donchian Channel 在趋势交易中的效果进行统计分析。

事实上，以上四种通道都无法单独成为一个好的交易系统。这是因为在使用这些通道指标之前，交易系统本身并无法对当前的市场状态做出判断，若市场趋势变化了，系统也应当做一定的机制转换。因此，Fong's Band 在这些方法的基础上，做了三方面的改进：首先，用价格的自相关性来判断趋势是否会发生逆转；其次，使用真实的价格分布来构建通道，摒弃了传统的正态分布的假设；最后，叠加价格出现反转的确认条件。有关 Fong's Band 的实证效果成为本文关心的第二部分内容。

二、通道突破型系统的几点思考及实证：以 Donchian Channel 为例

2.1 关于 Donchian Channel 的几点思考

在趋势型交易策略中，通道突破型的交易系统运用广泛。这一部分我们将以 Donchian Channel 为例，对该交易系统的几个细节问题进行实证统计，以得到一个相对较优的策略改进建议。

该策略的主要原理是：基于某一时间窗宽中价格的最高点和最低点构建 Donchian Channel 的上下通道，当价格突破通道上界时发出买入信号直到价格突破通道下界时平仓并反手做空。

对于该策略，主要考虑以下四个问题：

(1) 基于盘中突破还是收盘价突破的效果更好？在具体的交易价格上，前者意味着以价格突破发生时的市价成交，后者意味着以价格突破后第二天的开盘价成交。

(2) 趋势交易中，是做多还是做空的交易更占优？

(3) 时间窗宽的选取对系统盈利的影响有多大？这里主要对比分析了 5、10、20 三个时间窗宽。

(4) 交易突破时，交易量是否放量对交易信号的可靠性是否有影响？这里主要回答那些放量突破的交易信号是否更有效这一问题。

2.2 关于 Donchian Channel 的实证分析

实证样本：德国法兰克福指数包含的 30 支股票。这样一方面可以避免碰到低流动性的股票，另一方面也为统计检验的可靠性保证了足够多的样本量。

时间区间：从 2004.1.1 到 2009.12.31。

交易设置：手续费单边 0.1%，单个股票初始资金 100,000，2% 的静态止损条件（每次交易的亏损金额不超过当次交易开始时头寸的 2%），20% 的止盈条件。

在实证检验中，我们主要通过 t 检验来计算不同条件下的交易利润是否有显著区别，所关心的指标是平均每股利润和平均每笔利润。

以下部分是上述四个问题的统计检验结果，分三个部分详细展开：

第一部分主要是检验不同入场位置对盈亏的影响（针对问题 1），并比较多头和空头

的交易结果（针对问题 2）。这里使用的时间窗宽为 10 天，以 10 天内的最高价和最低价分别作为通道的上下界。

表 1 策略交易结果（不同确认方式以及不同交易方向）

	Setup 1			Setup 2		
	All	Long	Short	All	Long	Short
Mean Net Profit per Stock	13,865.26	6,029.32	7,835.94	4,179.72	1,462.84	2,716.88
Gross Profit	26,718.92	13,394.28	13,324.64	12,590.22	5,757.35	6,832.87
Profit Factor	2.49	2.21	3.33	2.19	2.23	4.53
Total Number of Trades	202	105.50	96.77	81.70	43.43	38.27
Percent Profitable	33%	33%	34%	36%	33%	40%
Average Trade Net Profit	66.45	55.79	78.05	45.68	30.96	68.17
Average Winning Trade	381.50	373.99	389.52	412.13	390.67	430.03
Average Losing Trade	-92.10	-100.58	-82.69	-153.64	-141.62	-166.05
Ratio Avg.Win./Avg.Los.	4.74	4.26	6.14	3.50	3.98	5.56
Largest Winning Trade	1,025.69	810.08	934.77	1,017.98	676.03	937.95
Largest Losing Trade	-2,128.72	-2,045.11	-1,612.51	-2,006.86	-1,787.95	-1,702.40
Total Commission	10,562.28	5,865.82	4,696.46	3,885.28	2,199.58	1,685.69
Max. Drawdown	-3,343.72	-2,717.74	-2,164.90	-3,609.01	-2,692.74	-2,415.83
Max. Intraday Drawdown	-3,920	-3,237.37	-2,702.32	-4,241.17	-3,431.82	-2,945.00
Total Positions	209.1	6,029.32	7,835.94	84.80	45.03	39.77
Position Changes	418.2	13,394.28	13,324.64	169.60	90.07	79.53

资料来源：G Robin Boldt. Applying Trading Strategies to Price Channel Breakout Trading—Statistical Significance of Channel Breakout Variation, IFTA Journal. 2012:33-40.

Setup1 是以趋势突破点的市价入场，对应的是盘中突破即确认趋势；Setup2 是以第二天的开盘价入场，对应的是收盘突破才确认趋势。由表 1 可以看到，不论是平均盈利因子（2.49 vs 2.19）、每笔利润（66.45 vs 45.68）、盈亏比（4.74 vs 3.5）、每股利润（13865.26 vs 4179.72）、最大回撤（-3343.72 vs -3609.01）还是平均亏损（-92.1 vs -153.64），Setup1 都明显优于 Setup2。

由表 2 可知，从平均每股盈利的角度看，以市价成交明显优于以第二天的开盘价成交，这一结果在统计意义上是显著的。造成这一结果的原因有二：其一，与一开盘价成交的交易系统相比，以市价成交的交易系统的交易次数明显提升（81 vs 202），其二，以市价成交交易系统的平均每笔交易的利润同样也比较高。这意味着，无论从哪个角度看，基于盘中突破的趋势交易系统比基于收盘突破的趋势交易系统效果要好。

表 2 基于问题 1 的统计检验（盘中突破 vs 收盘突破）

平均每股利润			平均每笔交易利润		
	Setup 1	Setup 2		Setup 1	Setup 2
Mean performance	13,865.26	4,179.72	Mean performance	66.45	45.68
Mean 1 – Mean 2	9685.54		Mean 1 – Mean 2	20.76	
N	30	30	N	30	30
Standard deviation	7,809.6889	5,235.5954	Standard deviation	37.0400	58.3895
Standard error of mean	1425.8476	955.8846	Standard error of mean	6.7626	10.6604
df	29		df	29	
p-value	less than 0.0001		p-value	0.0481	
t	7.7932		t	2.0639	
Statistically significant?	Yes		Statistically significant?	Yes	

资料来源：G Robin Boldt. Applying Trading Strategies to Price Channel Breakout Trading—Statistical Significance of Channel Breakout Variation, IFTA Journal. 2012:33-40.

对于问题 2，由表 3 的结果可知：空头信号更占优，收益更大。这是一个很有意思的现象，可能与现货市场上投资者习惯于止损但不习惯于追涨有关。因为追涨需要真金白银的买入，而杀跌则仅仅只需要止损即可。

表 3 基于问题 2 的统计检验（做多 vs 做空）

平均每股利润				
	Setup 1 Shorts	Setup 1 Longs	Setup 2 Shorts	Setup 2 Long
Mean performance	7.835,94	6.029,32	2.716,88	1.462,84
Mean 1 – Mean 2	1806.6150		1254.0317	
N	30	30	30	30
Standard deviation	4424.5568	4453.8320	3496.6762	3145.5346
Standard error of mean	807.8099	813.1547	638.4028	574.2934
df	29		29	
p-value	0.0262		0.1048	
t	2.3431		1.6742	
Statistically significant?	Yes		No	

平均每笔交易利润				
	Setup 1 Shorts	Setup 1 Longs	Setup 2 Shorts	Setup 2 Long
Mean performance	55,79	78,05	30,96	68,17
Mean 1 – Mean 2	-22.2557		-37.216	
N	30	30	30	30
Standard deviation	40.3487	42.7422	74.0995	94.2504
Standard error of mean	7.3666	7.8036	13.5287	17.2077
df	29		29	
p-value	0.0035		0.0644	
t	3.1739		1.9226	
Statistically significant?	Yes		No	

资料来源：G Robin Boldt. Applying Trading Strategies to Price Channel Breakout Trading—Statistical Significance of Channel Breakout Variation, IFTA Journal. 2012:33-40.

第二部分主要是构建检验通道的时间窗宽长度对盈利的影响有多大。为了避免出现过度拟合问题，周期的选择并没有经过参数优化，分别用 5 天、10 天和 20 天的周期去测试，观察策略表现会出现什么样的变化。

表 4 中，Setup3 代表 5 天为时间窗宽，Setup4 代表 10 天为时间窗宽，Setup5 代表 20 天为时间窗宽。由该表可以看出，Setup5 有更好的盈利因子（3.14 vs 2.1 vs 2.49）、更低的平均亏损（-62.33 vs -147.92 vs -92.1）和更小的最大回撤（-2343.05 vs -5715.01 vs -3343.72）。因此如果手续费能够降低，那么使用较小的时间窗宽以提高交易频率对投资者会很有吸引力。从利润上来看，Setup3（时间窗宽为 5）确实是很好，但利润并不是判定策略好坏的唯一标准，还要综合其他指标。

表 4 策略交易结果（不同时间窗宽构成的通道：5、10、20）

	Setup 3	Setup 4	Setup 5
Mean Net Profit per Stock	21,622.76	13,865.26	8,977.34
Gross Profit	47,876.75	26,718.92	15,245.41
Profit Factor	2.10	2.49	3.14
Total Number of Trades	304.80	202	132.03
Percent Profitable	44%	33%	26%
Average Trade Net Profit	67.46	66.45	61.27
Average Winning Trade	341.46	381.50	406.79
Average Losing Trade	-147.92	-92.10	-62.33
Ratio Avg.Win./Avg.Los.	2.55	4.74	8.25
Largest Winning Trade	1,158.80	1,025.69	874.03
Largest Losing Trade	-2,599.54	-2,128.72	-1,667.40
Total Commission	23,524.39	10,562.28	4,994.25
Max. Drawdown	-5,715.01	-3,343.72	-2,343.05
Max. Intraday Drawdown	-6,227.29	-3,920	-2,892.24
Total Positions	315.47	209.10	136.90
Position Changes	630.93	418.20	273.80

资料来源：G Robin Boldt. Applying Trading Strategies to Price Channel Breakout Trading—Statistical Significance of Channel Breakout Variation, IFTA Journal. 2012:33-40.

由表 5 的结果可知，时间窗宽缩短对利润提高的影响确实是显著的，这主要是因为交易次数大大提高了，但平均每笔利润却没有明显提高。

表 5 基于问题 3 的统计检验（不同时间窗宽下的效果）

平均每股利润						
	Setup 3 vs. Setup 4		Setup 4 vs. Setup 5		Setup 3 vs. Setup 5	
Mean performance	21,622.76	13,865.26	13,865.26	8,977.34	21,622.76	8,977.34
Mean 1 – Mean 2	7,757.50		4,887.92		12,645.43	
N	30	30	30	30	30	30
Standard deviation	17,273.23	7,809.68	7,809.68	9,893.87	17,273.23	9,893.87
Standard error of mean	3,153.6461	1,425.8476	1,425.8476	1,806.3656	3,153.6461	1,806.3656
df	29		29		29	
p-value	< 0.0001		0.0057		< 0.0001	
t	3.7204		2.9854		4.8476	
Statistically significant?	Yes		Yes		Yes	

平均每笔交易利润						
	Setup 3 vs. Setup 4		Setup 4 vs. Setup 5		Setup 3 vs. Setup 5	
Mean performance	67.46	66.45	66.45	61.27	67.46	61.27
Mean 1 – Mean 2	1.0077		5.1787		6.1863	
N	30	30	30	30	30	30
Standard deviation	53.4428	37.0400	37.0400	44.3606	53.4428	44.3606
Standard error of mean	9.7573	6.7626	6.7626	8.0991	9.7573	8.0991
df	29	29	29	29	29	29
p-value	0.8556		0.4179		0.4528	
t	0.1836		0.8218		0.7609	
Statistically significant	No		No		No	

资料来源：G Robin Boldt. Applying Trading Strategies to Price Channel Breakout Trading—Statistical Significance of Channel Breakout Variation, IFTA Journal. 2012:33-40.

第三部分主要是检验通道突破时成交量的变化对策略表现的影响。这里的成交量用成交量的指数移动平均线（Setup 6、Setup 7 和 Setup 8 对应的时间窗宽分别为 5 天、10 天和 20 天）来测算，Donchian Chanel 的时间窗宽为 5 天。Setup 6v、Setup 7v 和 Setup 8v 分别表示把突破时的成交量小于过去 5 天、10 天和 20 天指数移动平均值的那些样本过滤掉后的情形。

由表 6 的结果可知，从平均每笔交易的利润来看，伴随着高交易量的交易信号并无特别的优势。因此，通道突破时交易量的高低对策略盈利的影响并不大，那些低交易量突破的交易信号也应该考虑，不然会错失很多盈利机会。

表 6 基于问题 4 的统计检验（不同交易量的影响）

平均每股利润						
	Setup 6 vs. Setup 6v		Setup 7 vs. Setup 7v		Setup 8 vs. Setup 8v	
Mean performance	21,622.76	9,346.10	13,865.26	7,239.90	8,977.34	3,683.61
Mean 1 – Mean 2	12,276.66		6,625.35		5,293.72	
N	30	30	30	30	30	30
Standard deviation	17,273.23	7,938.79	7,809.68	4,047.92	9,893.87	3,181.97
Standard error of mean	3,153.6461	1,449.4198	1,425.84	739.04	1,806.36	580.9473
df	29		29		29	
p-value	< 0.0001		< 0.0001		0.0052	
t	5.8185		6.1387		3.0237	
Statistically significant	Yes		Yes		Yes	

平均每笔交易利润						
	Setup 6 vs. Setup 6v		Setup 7 vs. Setup 7v		Setup 8 vs. Setup 8v	
Mean performance	67.46	66.45	66.45	61.27	67.46	61.27
Mean 1 – Mean 2	1.0077		5.1787		6.1863	
N	30	30	30	30	30	30
Standard deviation	53.4428	37.0400	37.0400	44.3606	53.4428	44.3606
Standard error of mean	9.7573	6.7626	6.7626	8.0991	9.7573	8.0991
df	29	29	29	29	29	29
p-value	0.8556		0.4179		0.4528	
t	0.1836		0.8218		0.7609	
Statistically significant	No		No		No	

	Setup 6 vs. Setup 6v		Setup 7 vs. Setup 7v		Setup 8 vs. Setup 8v	
Mean performance	67.4570	63.3550	66.4493	71.4840	61.2707	55.2047
Mean 1 – Mean 2	4.1020		-5.0347		6.0660	
N	30	30	30	30	30	30
Standard deviation	53.4428	56.3418	37.0400	40.6389	44.3606	49.0845
Standard error of mean	9.7573	10.2866	6.7626	7.4196	8.0991	8.9616
df	29		29		29	
p-value	0.4532		0.3702		0.4434	
t	0.7602		0.9102		0.7770	
Statistically significant	No		No		No	

资料来源：G Robin Boldt. Applying Trading Strategies to Price Channel Breakout Trading—Statistical Significance of Channel Breakout Variation, IFTA Journal. 2012:33-40.

三、通道型交易系统的改进：以 Fong's Bond 为例

3.1 Fong's Bond 简介


Fong's Bond 在传统通道交易系统的基础上，做了三方面的改进：首先，使用真实的价格分布来构建通道，摒弃了传统的正态分布的假设；其次，用价格的自相关性来判断趋势是否会发生逆转；最后，叠加价格出现反转的确认条件。

Fong's Bond 的通道是基于历史模拟法来构建的。历史模拟法是一种非参数方法，它被广泛运用于银行的在险价值（Value at risk）的计算中，这种方法不依赖于价格服从正态分布的前提条件，在风险度量的过程中，它引入了分位数。它一个重要的假设是历史将会重演，这也是技术分析的三大原则之一。将过去 n 天的收盘价格序列从小到大升序排列： $v_1 \leq v_2 \leq \dots \leq v_p \leq \dots \leq v_n$ ，其中 p 分位数的价格就是 v_p ，下界是 5% 分位数对应的值，上界是 95% 分位数对应的值。

对于趋势判断，Fong's Bond 使用的是自相关系数。在实证中，为了使自相关性对最近的价格序列更为敏感，我们仅考虑滞后 10 天的一阶自相关性，它刻画了趋势是否会持续下去，完全正相关（ $r=1$ ）代表了趋势会一直持续下去，完全负相关（ $r=-1$ ）则表示趋势会逆转。当相关系数的正负发生改变时，说明趋势要发生逆转了。

为了尽量避免伪信号，Fong's Bond 最后叠加了一个信号确认条件。在新的方向被确认之前，价格和通道边界往往可能会不断的相互缠绕，自相关性指标也可能存在同样的问题。为了避免这类情况的发生，需要对仅仅基于通道所触发的信号进行过滤，比要求当价格向下突破边界后，又向上反转超过一定幅度的时候才入场（图 1）。


图 1 Fong's Bond 信号过滤示意图



资料来源：G Robin Boldt. Applying Trading Strategies to Price Channel Breakout Trading—Statistical Significance of Channel Breakout Variation, IFTA Journal. 2012:33-40.

最终得到的 Fong's Band 交易系统逻辑见图 2:

图 2 Fong's Band 交易系统逻辑示意图



资料来源: G Robin Boldt. Applying Trading Strategies to Price Channel Breakout Trading—Statistical Significance of Channel Breakout Variation, IFTA Journal. 2012:33-40.

3.2 Fong's Bond 的实证结果


我们在以下两个市场中实证对比了 Bollinger Bands 和 Fong's Bands 这两类策略的表现: (1)S&P 500, (2)ETF(GLD), 时间跨度是 2010 年全年。

Bollinger Bands 系统的策略逻辑为: 若当天收盘价下穿或正好位于布林带下界上, 则以第二天的开盘价开多仓; 若当天收盘价上穿或正好位于布林带上界上, 则以第二天的开盘价开空仓, 开仓前先确认已平仓。

Fong's Bands 系统的策略逻辑为: 若当天收盘价下穿或正好位于下界上, 此时的自相关系数为负或者接近于零, 那么当价格向上反弹超过 2% 时, 以后面一天的开盘价开多仓。若当天收盘价上穿或正好位于上界上, 此时的自相关系数为负或者接近于零, 那么当价格向下反弹超过 2% 时, 以后面一天的开盘价开空仓。

由图 3 可知, 标普 500 指数从 2 月中旬到 4 月底、从 9 月初到 10 月底都出现了明显的趋势, 而从 5 月初到 8 月底是在横盘震荡的。从交易结果上可以看到(表 7), Fong's Bands 的利润率明显优于 Bollinger Bands, 因此, 相关性指标在趋势的判定上非常准确高效。


图 3 对于 S&P500 的实证分析: Fong's Band vs Bollinger Band



资料来源: Ka Ying Timothy Fong. Regime-Switching Trading Bands Using A Historical Simulation Approach, IFTA Journal. 2013:20-27.

由图 4 可知, GLD 从 4 月初到 5 月中旬、从 8 月初到 10 月中旬都出现了明显的趋势。从交易结果上可以看到(表 8), Fong's Bands 的利润率同样明显优于 Bollinger Bands, 在上面两个趋势阶段, Bollinger Bands 无法识别, 产生了错误的交易信号。同样, 这也验证了相关性指标的重要性。

图 4 对于 GLD 的实证分析: Fong's Band vs Bollinger Band




资料来源: Ka Ying Timothy Fong. Regime-Switching Trading Bands Using A Historical Simulation Approach, IFTA Journal. 2013:20-27.

表 7 S&P500 的交易信号: Fong's Band vs Bollinger Band

Fong's Bands			Bollinger Bands		
日期	交易	价格	日期	交易	价格
2.2	开多	1100.67	1.22	开多	1092.4
4.27	平多	1184.59	4.14	平多	1210.77
	开空	1184.59		开空	1210.77
6.2	平空	1098.82	5.4	平空	1169.24
	开多	1098.82		开多	1169.24
12.31	平多	1257.64	11.4	平多	1221.2
				开空	1221.2
			12.31	平空	1257.64
利润率		32.8%	利润率		16.4%

资料来源: G Robin Boldt. Applying Trading Strategies to Price Channel Breakout Trading—Statistical Significance of Channel Breakout Variation, IFTA Journal. 2012:33-40.


图 4 对于 GLD 的实证分析: Fong's Band vs Bollinger Band



资料来源: G Robin Boldt. Applying Trading Strategies to Price Channel Breakout Trading—Statistical Significance of Channel Breakout Variation, IFTA Journal. 2012:33-40.

最后，一个有趣的发现是自相关性在大多数时候都大于零（图 5），说明在这些市场中，价格是存在趋势的，而这正是技术分析想要的。

图 5 自相关系数走势



资料来源: Ka Ying Timothy Fong. Regime-Switching Trading Bands Using A Historical Simulation Approach, IFTA Journal. 2013:20-27. Journal. 2013:20-27.

跟踪误差最小化的一类线性模型

原文：Markus Rudolf Hans-Jürgen Wolter and Heinz Zimmermann 1999. A linear model for Tracking Error Minimization. Journal of Banking & Finance 23, 85-103

推荐人：冯佳睿 021-23219732

推荐理由：本文研究了四类最小化投资组合与基准指数收益之间跟踪误差的模型。鉴于通常对基金经理的业绩评价都是线性的，因此本文认为线性偏差比二次偏差更能精确地描述投资者对待风险的态度。这些模型的一个共同点是采用最小化绝对偏差代替传统优化模型中的平方偏差。线性规划方法被用来求解精确的组合配置权重。模型被应用于一个包含 6 个国家（美国、日本、英国、德国、法国和瑞士）股票市场指数的投资组合中，目标是最小化组合与 MSCI 世界股市指数之间的跟踪误差。所有计算结果都与二次跟踪误差优化模型进行了对比。各模型所得优化组合的权重以及风险/收益性质的差异十分显著，这表明选择哪类优化模型应当以特定的投资目标为导向。

1、介绍

共同基金或养老基金的管理者在最优化投资组合的过程中，有一个问题显得愈发重要，那就是如何实现被动投资策略。这就意味着许多投资者的目标可以简化为通过最小化复制组合与基准指数之间收益偏差的平方和（“均方模型”），即跟踪误差的波动，来尽可能接近基准的收益表现。Roll 于 1992 年解决了最小化跟踪误差波动的问题。在金融实务中，采用二次跟踪误差的度量方式非常普遍，因为它具备许多优秀的统计性质。相较于二次跟踪误差的定义，Clarke 等人于 1994 年将跟踪误差定义为被管理的投资组合收益与基准指数收益之间偏差的绝对值。这个定义的提出基于如下事实，从实际投资者的观点出发，二次目标函数很难解释。而在投资者所面临的众多投资目标中，如果以投资组合与基准指数收益之间线性或是绝对偏差来描述，往往更有意义而且具有更直观的解释。Sharpe 于 1971 年已强调过这一事实，并建议用线性规划方法来最优化组合。在上个世纪末，Konno 和 Yamazaki(1991)以及 Speranza(1993)提出了一个基于组合收益平均绝对偏差而非波动率的最优化模型。但是，迄今没有人提出过一类以最小化投资组合收益与基准指数收益之间的线性偏差为目标的指数跟踪模型。

与二次模型相比，线性跟踪误差模型有着几大优势。一方面，对基金经理的业绩评价通常都基于投资组合和基准指数收益率之间的线性关系(参见 Kritzman, 1987)。另一方面，基金经理也会尽可能控制投资组合和基准指数收益之间的极端偏差，以避免自己的管理权被收回。因此，基金经理通常会考虑与基准指数之间的线性偏差而非二次偏差。本文从基金经理所持的上述两种对待组合管理的态度出发，定义了 4 种不同类型的跟踪误差(TE)模型。它们的共同点是跟踪误差完全基于线性目标函数，即采用投资组合和基准指数收益率之间的绝对偏差。Speranza 于 1993 年证明如果投资组合的收益服从正态分布，那么基于 Markowitz(1959)的均值-方差模型与平均绝对偏差模型得出的投资组合权重是一致的。

本文的结构如下。第二部分回顾传统的二次方法；第三部分介绍四种线性规划模型；第四部分详述所有模型的线性规划求解算法；第五部分为应用实例，即最小化六国股票市场指数形成的组合与一个全球股票市场指数的跟踪误差；第六部分为总结。

2、均方优化

在金融学中，线性模型中的均方问题会以不同形式出现，比如，组合复制策略：选取一个组合使其收益能够跟踪或复制一个事先给定的基准。令 Y 为连续复利下基准指数的收益向量， X 为连续复利下 n 项资产的收益率矩阵， β 为需要确定的组合权重。则该问题可以表示为：

$$\epsilon = Y - X\beta, Y \in \mathbb{R}^T, X \in \mathbb{R}^{T \times n}, \beta \in \mathbb{R}^n, \epsilon \in \mathbb{R}^T, \quad (1)$$

其中， n 为资产的数量， T 为观测的数量。

投资组合和基准指数收益偏差的平方和 $\epsilon' \epsilon$ ，通常称为跟踪误差的方差(Roll, 1992)。资产的权重 β 可通过最小化跟踪误差决定，即

$$\min_{\beta} \epsilon' \epsilon = \min_{\beta} (Y - X\beta)' (Y - X\beta), \quad (2)$$

其中 “ $'$ ” 代表矩阵的转置。

(2) 式是一个二次优化问题，资产的权重向量为

$$\beta = (X'X)^{-1}X'Y. \quad (3)$$

均方模型因其计算的简便性而广受欢迎。而且，投资组合权重的估计量 β 具有 BLUE 的性质，即它是最佳线性无偏估计量。除了 (2) 式之外，这个指数复制或跟踪问题还应包含一系列其他线性约束条件 (k 为约束条件的个数)，即

$$A\beta \geq b, A \in \mathbb{R}^{k \times n}, \beta \in \mathbb{R}^n, b \in \mathbb{R}^k. \quad (4)$$

约束条件可以有任意形式，一个简单的例子是关于卖空的限制(投资组合的权重必须非负)，或是组合权重之和等于 1。此外，Roll 于 1992 年又增加了一个约束：投资组合的平均收益要高于基准指数。不过需要注意的是，一旦添加不等式约束，估计量的 BLUE 性质也会随之消失。

3、最小化跟踪误差：四个不同的定义

下面，本文将对两类不同的跟踪误差的定义进行考察。这两类定义与均方误差相比，都可以提供对于目标函数最优解的更直观解释。它们的共同点是最小化投资组合与基准指数之间的绝对偏差，而不是二次偏差。很容易想象，这比用 (2) 式来最小化二次跟踪误差 (TE) 更能恰当地反映多数投资者的投资目标。

第一个模型是最小化平均绝对偏差 (MAD)。投资组合的权重由最小化与基准指数收益的绝对偏差之和来确定(跟踪误差: $1'(X\beta - Y)$)，即

$$\min_{\beta} 1'(X\beta - Y), \text{ 其中 } 1' = (1, \dots, 1) \in \mathbb{R}^T. \quad (5)$$

根据 (5) 式计算的跟踪误差的度量单位为百分数，而采用均方目标函数的度量单位则是百分数的平方。

在第二个模型中，投资组合的权重由最小化与基准指数收益的最大偏差来决定。这类模型统称为 “MinMax” 模型，代表了一种对 “最差情况” 的保护策略。MinMax 规划问题的目标函数为：

$$\min_{\beta} (\max_t |X_t \beta - Y_t|), \quad (6)$$

其中， X_t 代表矩阵 X 的第 t 行， Y_t 代表向量 Y 的第 t 个元素。相比 MinMax 模型，MAD 模型中的异常值被平均化处理了，因此 MAD 模型在数据中有异常值时的稳健性更好。此外，由于二次模型中收益的偏差经过了平方，相较于 MAD 模型，较大的偏差在二次模型中可以获得更高的权重。故与 MAD 模型相比，二次模型估计量对异常值更为敏感。这个结论与 Amemiya (1985, 第 73 页) 的研究结果一致。

除了 MAD 和 MinMax 模型之外，下文将介绍它们的两种变型。对许多投资者来说，风险的另一种表述是所管理的投资组合的收益低于基准指数的可能性，称之为投资的 “下跌风险” (见 Harlow, 1991)。从这个角度来看，跟踪误差的最小化应当聚焦于投资组合与

基准指数收益之间的负偏差。对于 MAD，这意味着在投资组合收益低于基准指数的约束下，最小化绝对偏差之和。这个模型称为“平均绝对下跌偏差模型”(MADD)。而对于 MinMax 模型，就是最小化最大的负偏差，称之为“下跌 MinMax 模型”(DMinMax)。

以下等式概括了下文中将要用到的 4 种不同的跟踪误差的定义：

$$TE_{MAD} = 1'(X\beta - Y), \quad (7a)$$

$$TE_{MADD} = 1'(\bar{X}\beta - \bar{Y}), \quad \text{其中 } \bar{X}_t\beta < \bar{Y}_t, \quad (7b)$$

$$TE_{MinMax} = \max_t |X_t\beta - Y_t|, \quad (7c)$$

$$TE_{DMinMax} = \max_t (\bar{X}_t\beta - \bar{Y}_t), \quad \text{其中 } \bar{X}_t\beta < \bar{Y}_t, \quad (7d)$$

其中，矩阵 $\bar{X}$ 和向量 $\bar{Y}$ 只包含投资组合收益低于基准收益的那些行。

4、线性规划

前一部分介绍的每个模型都可以看作是一个线性规划求解问题：

(a) MinMax 问题：MinMax 问题的基本形式由(6)式给出。令 $z \geq 0$ 为绝对偏差的上界：

$$z \geq |X_t\beta - Y_t|, \quad t \in \{1, \dots, T\}.$$

下面对每个 t ，首先考虑投资组合的收益高于基准指数收益的情况，

$$\text{情况 1: } z \geq X_t\beta - Y_t \geq 0 \Leftrightarrow X_t\beta - z \leq Y_t.$$

第二，考虑投资组合的收益低于基准指数收益的情况，

$$\text{情况 2: } -z \leq X_t\beta - Y_t \leq 0 \Leftrightarrow X_t\beta + z \geq Y_t.$$

现在要最小化上界 z 。注意到，若 $X_t\beta - Y_t \geq 0$ ，则情况 1 中的不等式可以推出情况 2；反之，若情况 2 成立，2 中不等式也可推出情况 1。因此，MinMax 问题可以表示为如下形式：

$$\min_z z \quad \text{s.t. } X_t\beta - z \leq Y_t, \quad X_t\beta + z \geq Y_t. \quad (8)$$

(b) 下跌 MinMax 问题：等价于在上一个规划问题的基础上增加一个对观测值的约束： $X_t\beta \leq Y_t$ ，即投资组合的表现劣于基准指数。因此，只用到了(a)中情况 2 的约束条件，从而可根据(8)式得到该线性规划问题的具体表达形式：

$$\min_z z \quad \text{s.t. } X_t\beta + z \geq Y_t. \quad (9)$$

(c) 平均绝对偏差(MAD)：令 $z_t^+ \geq 0$ 为正偏差， $z_t^- \geq 0$ 为投资组合与基准指数收益之间负偏差的绝对值。从而有，

$$X_t\beta - Y_t > 0 \Leftrightarrow X_t\beta - z_t^+ = Y_t \quad (10)$$

$$X_t\beta - Y_t < 0 \Leftrightarrow X_t\beta + z_t^- = Y_t. \quad (10)$$

目标函数为

$$\min \sum_{t=1}^T (z_t^+ + z_t^-). \quad (11)$$

注意到，无论是 z_t^- 为正的同时 z_t^+ 为 0，还是 z_t^- 为 0 的同时 z_t^+ 为正，都表明一个正的偏差会导致 $z_t^- = 0$ ，而一个负的偏差会导致 $z_t^+ = 0$ 。因此(10)中的这两个等式可以合并为一个约束条件：

$$X_t\beta - z_t^+ + z_t^- = Y_t. \quad (12)$$

(d) 平均绝对下跌偏差(MADD): 如果投资者关心的是投资组合与基准指数之间负偏差, 那么可以从最优化问题中剔除 z_t^+ , 从而表达式可重写为

$$\min \sum_{t=1}^T z_t^- \text{ s.t. } X_t \beta + z_t^- = Y_t. (13)$$

(8), (9), (11)-(13)式仅仅提供了优化问题最基本的描述。具体的线性规划求解过程还是相当复杂的: 如果令 T 为观测期数, 则下跌 MinMax, MAD 和 MADD 模型中的初始矩阵都有 $T+1$ 行, 而 MinMax 模型中更是有 $2T+1$ 行。然而, 利用计算机和优化软件, 这些问题都很容易得到解决。当然, 也可进一步添加其他约束条件。例如, 投资组合的权重非负或是组合权重之和等于 1。这样就可以实现投资组合在约束下的期望收益。

5、实证应用

第 4 部分的模型将在下文中通过一个实证例子予以详细说明。假定某位投资者试图最优化一个包含各国指数的投资组合, 他的目标是最小化投资组合与基准——MSCI 世界股票市场指数之间的跟踪误差。他的投资组合中包括以下国家的股票指数: 美国、日本、英国、德国、法国和瑞士。以每个国家股指的收益率为研究对象, 其统计特征在表 1 中展示。除了完整的样本区间 (1987 年 3 月至 1996 年 4 月), 本文还考虑了两个子区间: 1987 年 3 月至 1992 年 4 月 (62 个月), 1992 年 5 月至 1996 年 4 月 (48 个月)。投资组合的权重是基于第一个子区间的数据优化的, 并利用第二个子区间的数据检验组合权重的持续性。

表 1 MSCI 全收益指数的风险/收益特征 (单位: 美元)

Index	Whole observation period: March 1987 to April 1996			In-the-sample period: March 1987 to April 1992			Out-of-the-sample period: May 1992 to April 1996		
	μ^a	σ^b	β^c	μ^a	σ^b	β^c	μ^a	σ^b	β^c
MSCI USA	9.24	13.91	0.68	6.89	17.43	0.72	11.82	7.30	0.48
MSCI Japan	2.94	26.61	1.45	-3.77	29.63	1.37	12.00	22.14	1.79
MSCI UK	6.80	19.16	1.07	5.61	22.06	1.05	4.85	13.21	1.10
MSCI Germany	7.44	20.41	0.85	5.91	23.72	0.87	9.28	15.33	0.82
MSCI France	6.43	20.50	0.92	5.68	23.50	0.90	5.73	15.76	1.01
MSCI Switzerland	12.85	17.33	0.86	4.13	19.11	0.86	23.34	14.29	0.78
MSCI World	6.74	14.26	1.00	2.97	17.17	1.00	10.93	9.19	1.00

^a Average return in % p.a.

^b Standard deviation in % p.a.

^c Beta to MSCI World.

数据来源: “A Linear Model for Tracking Error Minimization”

指数的收益率是以美元为单位计算的, 基于 1987 年 3 月至 1996 年 4 月的月度数据, 因此每个序列包含总共 110 个观测。下文将采用第 4 部分中介绍的四类跟踪误差模型分别予以分析。在构建组合的过程中, 不容许卖空情况的出现。此外, 还要求组合的权重之和为 1。同时, 二次模型也被用来估计组合的权重向量, 以最小化均方误差来完成。最终的最优组合和最优化之后的目标函数值会在五类模型中进行对比, 具体结果在表 2 中予以展示。

表 2 不同优化模型的最优组合权重（基于样本内区间：1987 年 3 月-1992 年 4 月，单位：%）

Model	USA	JAP	UK	D	F	CH	Value of objective function
MinMax	35.21	30.73	18.09	12.07	0.00	3.90	1.18
DminMax	30.98	28.32	23.52	6.25	0.00	10.92	1.17
MAD	41.00	35.89	12.74	8.57	1.79	0.00	21.81 (0.35) ^a
MADD	41.78	34.32	13.99	7.25	2.66	0.00	11.03 (0.75) ^b
Quadratic TE	39.58	34.74	13.00	7.44	2.30	2.95	0.45 ^c

^aSum of absolute deviations (average of absolute deviations in brackets).

^bSum of absolute downside deviations (average of absolute downside deviations in brackets), 29 observations of the portfolio reveal returns below the MSCI World benchmark.

^cSquare root of the average of the squared deviations between the returns on the MSCI world stock market index and the portfolio.

数据来源：“A Linear Model for Tracking Error Minimization”

一个著名的现象是，美国与日本股市对世界股市指数有最大的解释能力（权重最大），原因是 MSCI 指数是市值加权的，而美国和日本市场在世界范围内有着最高的市值。在欧洲的股票市场上，英国占据着主导地位。MAD 和二次模型的结果非常类似，因为它们都最小化了正、负偏离之和。只不过形式略有不同，前者是绝对偏离之和，后者则是平方偏离之和。这一结果与 Konno 和 Yamazaki(1991)的观点一致，他们证明当基准与组合的收益都服从精确的正态分布时，不论是线性还是二次的目标函数，其优化结果是一致的。由于收益率的非正态性，导致表 2 中，MAD 和二次跟踪误差模型之间存在细微的差别。不过，从表 2 中也能清晰地看到，MAD/二次模型和 MinMax/DminMax 模型的结果之间存在着显著的差异。比如，美国市场的比例就有 10% 的差别。这一结论其实并不令人感到惊讶，四个模型对跟踪误差的定义本身就有所不同。

表 3 中列示了组合的平均收益、标准误以及 beta 系数。令人惊讶的是，尽管这四个模型的定义各不相同，但得到的风险指标却非常相似。不过，平均收益方面并非如此，除了 MAD 和二次跟踪误差模型以外，其余模型的结果相差很大。

表 3 最优组合的风险/收益特征（单位：%）

Model	Average return ^a	Standard deviation ^a	Beta ^b	Sharpe ratio ^c	Treynor ratio ^d
MinMax	3.62	17.42	1.01	0.04	0.61
DminMax	3.72	17.55	1.01	0.04	0.71
MAD	3.28	17.52	1.01	0.02	0.28
MADD	3.48	17.41	1.01	0.03	0.48
Quadratic TE	3.30	17.46	1.01	0.02	0.30
MSCI World Stock	2.97	17.17	1.00	0.03	-0.03
Market					

^aAnnualized values in %.

^bBeta of each portfolio to the MSCI world stock market index.

^cExcess return (average return minus 3%) to volatility ratio.

^dExcess return to beta ratio in %.

Observation period: March 1987 to April 1992 (62 months).

数据来源：“A Linear Model for Tracking Error Minimization”

至此，以上结果揭示了本文的线性优化模型提供了与传统的二次优化模型完全不同的组合权重。然而，线性模型的优势在于其目标函数具有更直观的推断。对一名投资者而言，如果他能够以绝对偏离的形式描述与相对基准的跟踪误差，而不采用平方偏离，那么他就能很容易地确定自己对风险的态度。表 4 是目标函数最优值的比较。

表 4 不同优化模型所得最优组合的目标函数值 (单位: %)

Portfolio	Model					Number of downside deviations
	Quadratic	MinMax	Down-side MinMax	MAD ^a	MADD ^b	
Quadratic	0.45	1.42	1.42	22.06 (0.36)	11.40 (0.38)	30
MinMax	0.61	1.18	1.18	31.00 (0.50)	15.10 (0.56)	27
DMinMax	0.74	1.81	1.17	37.99 (0.61)	18.33 (0.63)	29
MAD	0.46	1.56	1.56	21.81 (0.35)	11.36 (0.38)	30
MADD	0.47	1.39	1.39	22.14 (0.36)	11.03 (0.38)	29

^aSum of absolute deviations (average of absolute deviations in brackets).

^bSum of absolute downside deviations (average of absolute downside deviations in brackets).


Observation period: March 1987 to April 1992 (62 months).

数据来源: “A Linear Model for Tracking Error Minimization”

五个模型中最小的目标函数值以粗体着重标识。当跟踪误差以二次的形式定义时,最优的投资组合是由二次跟踪误差模型提供的,这一点并不令人惊讶。但是,从其他四个模型的目标函数值中还能发现更多有趣的信息。例如,如果投资者关心的是最大绝对下跌偏差(DMinMax),那么持有下跌 MinMax 组合所承担的最小“风险”为 1.18%。它低于二次跟踪误差组合的风险,因为二次跟踪误差组合与基准指数之间最大的绝对下跌偏差(DMinMax)为 1.42%。如果投资者的目标是 minimized 绝对下跌偏差之和,那么将二次跟踪组合替换成 MADD 组合之后,总偏差将从 11.40% 略微下降至 11.03%。


图 1 和图 2 展示了投资组合与基准指数之间每月收益的偏差。二次跟踪组合的结果由灰色柱状图表示。图 1 将 MinMax 组合与基准指数收益的偏差与二次跟踪误差组合的结果进行比较。MinMax 组合与基准(MSCI 世界股票指数)的最大偏差出现在 1988 年 12 月,偏差幅度为 1.18%。二次跟踪组合与基准的最大偏差为 1.42%,出现在 1992 年 4 月。图 2 展示了 DMinMax 组合和二次跟踪组合偏差的对比,下跌偏差有微弱削减的趋势。下跌 MinMax 组合与基准的最大负偏差为 1.17%,出现在 1988 年 12 月,而二次跟踪误差组合的最大负偏差为 1.42%,出现在 1992 年 4 月。

图 1 二次跟踪误差组合以及 MinMax 组合与基准指数的偏差



数据来源: “A Linear Model for Tracking Error Minimization”

图2 二次跟踪误差组合以及 DMinMax 组合与基准指数的偏差



数据来源：“A Linear Model for Tracking Error Minimization”

下面进行样本外检验，表5和表6展示了最终结果。“旧”组合是基于1987年3月至1992年4月间的收益数据所得到的最优跟踪误差组合，而“新”组合则是基于1992年5月至1996年4月间的收益数据所得到的，跟踪误差的结果展示在表5的最后两列。用样本外最优组合的跟踪误差与样本内结果进行比较：在样本外(1992年5月至1996年4月)，“新”MinMax最优组合的跟踪误差为1.09%，而“旧”MinMax最优组合的跟踪误差则大幅偏高，为1.93%。这是由于投资组合内部发生了显著变化：美国的权重有所增加的同时，日本和德国的权重随之减少。其他策略也存在类似的现象。表6展示了“新”样本内组合与“旧”样本外组合在样本外(1992年5月至1996年4月)的风险与收益的特征。当平均收益大体相同时，样本内组合具有更高的风险。

表5 不同优化模型的最优组合权重（基于样本外区间：1992年5月-1996年4月，单位：%）

Model	USA	JAP	UK	D	F	CH	Objective function of the “new” portfolio ^a	Objective function of the “old” portfolio ^b
MinMax	42.21	23.61	16.50	2.97	7.82	6.89	1.09	1.93
DMinMax	45.23	24.50	0.00	2.25	11.29	16.73	0.96	2.13
MAD	48.50	26.23	10.71	8.60	4.91	1.05	13.67 (0.22) ^c	26.44 (0.55) ^c
MADD	47.83	27.14	2.79	11.50	3.73	7.02	6.02 (0.27) ^d	12.77 (0.56) ^e
Quadratic TE	45.95	25.53	13.21	8.81	3.98	2.52	0.44 ^f	0.74 ^f

^aThe values are calculated by portfolio fractions based on March 1987 to April 1992 (62 months, in-the-sample period) and the return data from the in-the-sample period.

^bThe values are calculated by portfolio fractions based on March 1987 to April 1992 (62 months, in-the-sample period) and the return data from the out-of-sample period.

^cSum of absolute deviations (average of absolute deviations in brackets).

^dSum of absolute downside deviations (average of absolute downside deviations in brackets), 22 downside deviations of the portfolio from the MSCI World returns.

^eAbsolute downside deviations (average of absolute downside deviations in brackets), 23 downside deviations of the portfolio from the MSCI World returns.

^fSquareroot of the average of the squared deviations between the returns on the MSCI world stock market index and the portfolio.

数据来源：“A Linear Model for Tracking Error Minimization”

表 6 样本内和样本外最优组合的风险/收益特征

Model	Portfolio based on the in-the-sample period – “new” portfolio			Portfolio based on the out-of-the-sample period – “old” portfolio		
	Average return ^a	Standard dev. ^a	Beta ^b	Average return ^a	Standard dev. ^a	Beta ^b
MinMax	11.56	10.10	1.06			0.96
DMinMax	11.47	9.90	1.05	11.82	11.44	8.94
MAD	12.27	10.05	1.06	13.50	8.77	0.92
MADD	11.20	10.19	1.07	11.32	8.88	0.95
Quadratic TE	11.16	10.03	1.06	12.31	8.73	0.93

^a Annualized values in %.

^b Beta of each portfolio to the MSCI world stock market index.

Observation period: May 1992 to April 1996.

数据来源: “A Linear Model for Tracking Error Minimization”

6、结论

本文研究的动机是，在实际投资中，跟踪误差通常被定义为投资组合与基准指数收益的线性偏离。这有别于传统的学术研究中，二次跟踪误差的概念。本文详细研究了四种最小化组合与基准收益率之间跟踪误差的模型：

- (1) MinMax 模型，最小化组合与基准收益之间的最大绝对偏差；
- (2) 下跌 MinMax 模型，最小化最大负偏差；
- (3) 平均绝对偏差模型，最小化绝对偏差之和；
- (4) 平均绝对下跌偏差模型，最小化负偏差绝对值之和。

以上这些模型的共同点就是只最小化绝对偏差，而非 Roll 在 1992 年的文献中定义的 TEV(tracking error volatility)模型所关注的平方偏差。线性规划方法被用来获得最终的精确解。这 4 个模型被应用于一个包含了 6 个国家（美国、日本、英国、德国、法国和瑞士）股市指数的投资组合中，目标是最小化组合与 MSCI 世界股市指数之间的跟踪误差。以上结果都被用来和二次跟踪误差模型比较。不同模型所得最优组合的权重及其风险/收益性质差异明显，这表明最优模型的选择应当视特定的投资目标而定。如果按照等式(7a)-(7d)的定义来分别挨个评估 5 个最优组合（见表 2）的跟踪误差，可以发现它们之间存在着显著差别。这也说明了在组合优化的过程中，不同的投资目标与对应的目标函数之间的关联性。

基于信用利差相对价值的行业轮换

原文：Dave Klein, Wagner Award Paper, IFTA Journal, 2014 Edition。

推荐人：吴先兴 021-23219449

推荐理由：文章将公司资本结构资产价格的基本关系扩展到指数水平。使用 HY/B 信贷指数和标准普尔行业 ETF 构造线性相对价值模型，然后基于 ETF 偏离公允价值的距离进行排序。这一排名成为是简单的相对实力投资策略的基础，这个策略产生相对于标准普尔 500 指数优越的、经风险调整的绝对回报。由于使用信贷市场来判断相对价值，这种投资策略与许多流行的排名方法不相关，并且可以作为现有策略的增强策略使用。此外，策略是为只做多头的投资者设计的，可以用高流动性指数 ETF 实现。

1、引言

过去四十年已经有很多关于企业资本结构和市场估值的理论研究。一般地，信贷风险上升时股票价值下降，反之亦然。通过好的信贷风险代理指标，可以使用这种关系来判断信贷和股票市场的相对价值。文章利用了指数的这种关系。如果选择恰当的一揽子公司的信贷风险上升（下降），那么它在股票指数中的资产价值就会下降（上升）。我们不需要在信贷组成和股票指数之间的一对一匹配。事实上，我们策略使用相同的信贷指数来判断行业 ETF 的相对价值。

本文的其余部分被分为六个部分。我们将讨论我们的数据来源。接下来，我们比较一个简单的线性模型和信贷股票的相对价值。我们根据信贷-股票模型对行业 ETF，并依此来分析投资策略。然后，我们增加股票、ETF、美国国债和之间的切换来改进策略，以此提高收益、降低投资组合风险。我们最后检验策略的实现并得出结论。

2、数据来源

表 1 列出了我们分析中使用的 9 个行业 ETF。我们使用圣路易斯联邦储备银行的弗雷德经济数据库（<http://research.stlouisfed.org/fred2>）三个月期美国国债收益率以及美国银行/美林的美国高收益指数的期权修正利差，以后称为 HY/B。分析时间跨越 1999 年 7 月至 12 月 2012 年，共 13.5 年。这是一个短期内对股票分析，但它包含两个主要市场的修正以及多个时期股票价格的上涨。

表 1 标准普尔选择行业 SPDR ETF

Ticker	Description
XLY	The Consumer Discretionary Select Sector SPDR Fund
XLP	The Consumer Staples Select Sector SPDR Fund
XLE	The Energy Select Sector SPDR Fund
XLF	The Financial Select Sector SPDR Fund
XLV	The Health Care Select Sector SPDR Fund
XLI	The Industrial Select Sector SPDR Fund
XLB	The Materials Select Sector SPDR Fund
XLK	The Technology Select Sector SPDR Fund
XLU	The Utilities Select Sector SPDR Fund

资料来源：Equity Sector Rotation via Credit Relative Value


3、资本结构的相对价值

相对价值模型的核心是 HY/B 信贷指数和各个行业 ETF 之间的关系。判断一个 ETF 是昂贵或便宜，我们使用一个简单的线性模型：

$ETF_{Fair}(HYB_{Market}) = A * HYB_{Market} + B$ ，其中使用圣路易斯联储的弗雷德数据库的 HY/B 的期权修正价差。由于当信贷风险变化时，信贷息差和股票价值朝着相反的方向变化，因此我们期望方程的参数 A 是负的。使用普通最小二乘法（OLS）线性回归。

当考虑单个企业时，这种信贷-股票关系往往是非线性。直觉是，当企业信贷风险很低时，信贷息差和股票价格之间几乎没有相关性。对于信贷风险高的公司，信贷息差变化快于股票价格变化，因为理论上它们可以趋向于无穷大。在指数级别，可以使用一个非线性模型描述，但当信贷指数给定时线性模型能够很好地描述。为了说明这种关系，图 1 画出从 2012 年 7 月到 2012 年 12 月每周 HY/B 指数与 XLF 的关系图。趋势线下方的点表明 XLF 相比 HY/B 是较便宜的，上方的点表明 XLF 相对昂贵。

图 1 HY/B 与 XLF 每周价值（2012 年 7 月至 12 月）



资料来源：Equity Sector Rotation via Credit Relative Value

一旦使用线性回归模型，我们可以估计每个行业 ETF 的公允价值。更重要的是，我们可以计算出每个 ETF 偏离公允价值的程度：

$$ETF_{disconnect} = \frac{ETF_{fair} - ETF_{market}}{ETF_{market}}$$

我们在两个方面使用这个偏离。首先，我们给行业 ETF 排名来选择投资的一篮子 ETF。其次，我们考虑这个偏离的正负来决定投资 ETF 还是无风险证券。使用 3 月期美国短期国债为无风险证券。

我们假设投资者投资于一篮子 ETF 并且每周调整一次。当我们已经制定出完整的策略后，实施一个更实际的、更低频率的策略（仅针对投资组合中调整的 ETF 进行交易和调仓）。我们注意到这个策略在月度频率上是可行的，尽管回报较低。

4、使用 HY/B 为行业 ETF 排名

如前所述，一旦时间和频率选型，直接使用 HY/B 指数通过 OLS 回归为每个行业 ETF 创建一个公允价值模型。一旦计算出公允价值，ETF 可以依据公允价值偏离比例降序排序接。如果模型拟合好，那么排在前面的一揽子 ETF（即偏离比例较大的）应该产生更高的回报。

我们使用 6 个月时间长度和周频率。回归 26 对数据生成模型。实际操作中，我们使用之前的 26 个周的数据（不包含当前交易日）来构造回归。进一步，因为 HY/B 值第二天公布，我们使用前一天的 HY/B 值来计算每个 ETF 公允价值。

六个月是足够长的时间来建立一个有意义的信贷指数和 ETF 关系，也是足够短的时间可以忽略通货膨胀、股息和政策改变（如市场突发事件）等因素。虽然大部分的分析使用 6 个月的时间长度，文章后面也讨论了不同时间长度模型的敏感性。

让 $Basket_N$ 表示一篮子包含前 n 个排名的 ETF。因此 $Basket_1$ 包含一个 ETF， $Basket_9$ 包含所有九个 ETF。我们的 $Basket_N$ 交易策略为：

Basket_N 策略：每周，投资一揽子等权重的排名前 N 的 ETF

每周重新调整。 $Basket_9$ 的成分不会改变，因为所有的 ETF 都在篮子里。我们希望用包含更少 ETF 的一篮子以高波动率为代价来产生更大的回报。

图 2 显示了一篮子策略的资金曲线和从 1999 年 7 月到 2012 年 12 月 SPY ETF（跟踪 S&P500 指数）的红利再投资。正如所料， $Basket_N$ 策略生成严格降序回报。每种策略均优于 SPY，暗示即使是简单的每周调整的等权重行业 EFT 一揽子策略（ $Basket_9$ 策略）也是值得考虑，假设交易成本和税收负债可以最小化。

图 2 $Basket_N$ 策略的权益曲线



资料来源：Equity Sector Rotation via Credit Relative Value

表 2 $Basket_N$ 策略和 SPY 的回报和风险统计量(99 年 7 月-12 年 12 月)

	$Basket_1$	$Basket_2$	$Basket_3$	$Basket_4$	$Basket_5$
CAGR (13.5 years)	12.4%	9.9%	9.8%	8.2%	8.1%
Volatility	31.5%	25.0%	22.7%	21.8%	21.3%
Sharpe Ratio (2.2%)	0.32	0.31	0.34	0.28	0.28
Sortino Ratio	0.44	0.45	0.49	0.39	0.38
Skewness	0.08	0.29	0.28	0.07	-0.07
MaxDD	-63.2%	-54.0%	-49.7%	-49.2%	-48.2%
Information Ratio	0.43	0.55	0.71	0.68	0.81
	$Basket_6$	$Basket_7$	$Basket_8$	$Basket_9$	SPY
CAGR (13.5 years)	7.6%	7.1%	6.0%	4.7%	2.1%
Volatility	20.8%	20.4%	20.1%	19.9%	20.3%
Sharpe Ratio	0.26	0.24	0.19	0.13	0.00
Sortino Ratio	0.35	0.32	0.25	0.16	-0.01
Skewness	-0.07	-0.14	-0.20	-0.35	-0.37
MaxDD	-48.9%	-48.8%	-50.5%	-52.8%	-54.8%
Information Ratio	0.80	0.82	0.76	0.56	

资料来源：Equity Sector Rotation via Credit Relative Value

当然，不应孤立地看待回报。表 2 展示了每个策略和 SPY 的回报和风险统计量，包括 1999 年 7 月至 2012 年 12 月的股息。正如所料，随着越来越多的证券添加到篮子里波动率减小。索提诺比率（Sortino Ratio）和夏普比率（Sharpe Ratio）一般也相应减少，尽管 Basket₁ 和 Basket₂ 例外。所有篮子策略最大跌幅（MaxDD）依旧很大，引出对篮子策略的改进，本文稍后讨论。

当使用比基准平衡风险和回报时，信息比率是一个有趣的统计量。它提供了一个投资组合的风险修正测量指标（比率的 alpha 除以标准偏差的 alpha），基准是标普 500 指数。一个信息比率高于 0.5 表示策略的活跃回报处于最高四分位数（top quartile）段。Basket₅ 到 Basket₇ 比其他策略好，并且除了 Basket₁，其他策略的信息比率均高于 0.5。

鉴于其相对较高的复合年增长率和高信息比率，我们使用 Basket₆ 进一步分析策略的性能。选择 Basket₆ 而不选 Basket₅ 或 Basket₇ 的原因是为了保持策略改进的一致性。我们还要注意，给定回报和风险统计数据后，不同的投资者可能会喜欢不同篮子。

接下来，我们考虑排序策略对于回归时间长度的敏感性。上面的分析使用 6 个月的时间。表 3 比较 Basket₆ 策略时间长度分别为从 1999 年 10 月到 2012 年 12 月中的 3、4、5、6、7、8 和 9 个月。尽管时间长度为 7、8 个月的样本有更优越的信息比率和复合年增长率，其余大多数统计量是相似的。因此在本文中我们使用一个 6 个月的时间不是任意的。

当回溯测试一个轮换策略，考虑每个候选资产在投资组合中的持有频率是有益的。优越的回报可以通过简单地选择最大回报的证券并在回溯期间持有来获得。表 4 显示 Basket₆ 中每个行业 ETF 相关的百分比和整个分析周期（1999 年 7 月至 2012 年 12 月）的复合年增长率。如果 ETF 选择分布均匀，我们希望每个包含 6/9（66.7%）的时间长度。Basket₆ 策略持有 XLF 和 XLK 最多，这两个行业 ETF 在这一时期的股息修正表现最差。它持有 XLE 的时间最少，而这个 ETF 在这段时间的性能最好。

表 3 Basket₆ 策略在模型回归不同时间长度下的表现和风险统计量(99 年 10 月- 12 年 12 月)

	3 Months	4 Months	5 Months	6 Months	7 Months	8 Months	9 Months
CAGR (13.5 years)	8.0%	8.2%	8.2%	8.3%	9.0%	8.9%	7.6%
Volatility	21.0%	21.1%	21.0%	20.9%	21.0%	20.9%	20.9%
Sharpe Ratio	0.28	0.28	0.28	0.29	0.32	0.32	0.26
Sortino Ratio	0.37	0.39	0.38	0.38	0.44	0.43	0.35
Skewness	-0.06	-0.11	-0.14	-0.08	-0.12	-0.17	-0.22
MaxDD	-48.1%	-47.5%	-48.3%	-48.9%	-47.3%	-49.1%	-52.4%
Inf. Ratio	0.87	0.86	0.84	0.84	0.93	0.92	0.75

资料来源：Equity Sector Rotation via Credit Relative Value

表 4 行业 ETF 在 Basket₆ 投资组合中的复合年增长率和时间长度比率(99 年 7 月- 12 年 12 月)

	CAGR (July 99-Dec 12)	Percentage of Weeks in Portfolio
XLV	4.8%	66.8%
XLP	4.6%	68.6%
XLE	9.1%	55.3%
XLF	-1.8%	72.9%
XLV	3.9%	64.8%
XLI	3.6%	74.0%
XLB	5.0%	64.1%
XLK	-1.9%	71.7%
XLU	4.8%	61.9%

资料来源：Equity Sector Rotation via Credit Relative Value

我们考虑每个行业 ETF 被包含在投资组合中的表现,对比每周 Basket₆ 的平均回报。比较组合通过排除一个 ETF 来包含另一个 ETF 的代价。

表 5 显示每个行业 ETF 被包括在 Basket₆ 投资组合中的年回报率。所有被包含的行业 ETF 表现优于被排除的 ETF, 这意味着策略每周合理选择了六个 ETF。各行业的表现并不统一, 两个 ETF (XLP 和 XLK) 在被包含在投资组合中时仍为负回报。虽然这种类型的表现是可喜的, 但为提高性能和降低风险可以做更多。在下一节中, 我们考虑一个增强的策略有助于限制投资组合的亏损。

表 5 行业 ETF 在 Basket₆ 投资组合中的年回报率和时间长度比率

	ETF Annualized Return	Annualized Return of 'Excluded' ETFs	Strategy Outperformance
XLY	2.0%	-4.2%	6.3%
XLP	-2.0%	-11.3%	9.3%
XLE	33.6%	12.3%	21.3%
XLF	11.3%	7.3%	4.0%
XLV	5.0%	-3.2%	8.2%
XLI	7.0%	-3.0%	10.0%
XLB	6.0%	-1.7%	7.6%
XLK	-4.5%	-6.1%	1.5%
XLU	4.3%	-4.6%	8.9%

资料来源: Equity Sector Rotation via Credit Relative Value

5、除了排名-战术资产配置

上述 Basket_N 策略分析在“买入并持有”SPY 的投资政策产生优越结果。此外, 随着 N 减少, 策略回报增加, 可以通过调整 ETF 在一篮子中的数量产生的回报来平衡风险。不过, 每个篮子的亏损 (drawdown) 与“买入并持有”SPY 投资是可比的, 有时甚至更糟。此外, 相比 SPY, 大多数篮子波动性较高。

解决亏损 (drawdown) 问题同时提高投资组合回报、降低投资组合波动性, 我们回到公允价值回归模型。之前, 我们没有注意到差异百分比的符号。现在, 在行业 ETF 和三个月期国库券之间切换取决于差异的符号是正确的 (也就是说, ETF 是便宜的) 或负的 (ETF 是昂贵的), 以此来增强 Basket_N 策略。新战术资产配置 (TAA_N) 策略如下:

TAA_N 策略:

1. 每个星期, 选择前 N 个排名 ETF 和分割资产成 N 等分股票。
2. 对于每个选择的 ETF:
 - A. 如果公允价值大于市场价值, 资产份额投资 ETF。
 - B. 如果不是, 资产份额投资三个月期国债。

通过这种方式, 我们仍然同 Basket_N 策略一样选择前 n 个 ETF。然而, 我们只投资那些在公允价值模型中有正期望回报的 ETF。战术资产配置策略, 相比上述 Basket_N 策略有两个优点。它提出了篮子的期望回报, 同时限制投资组合的亏损。这种类型战术资产配置策略的机制和动机在克莱恩 (Klein) 的“Credit-Implied Tactical Asset Allocation”中进行了讨论。他们之间一个关键的区别是, 我们投资多个 ETF, 其中一些可能是廉价的, 一些可能是昂贵的。因此, 我们常常部分投资股票市场同时也通常投资于低波动性的国债。

在萧条的市场环境中，该策略有助于限制损失。在景气的市场环境中，该策略遏制获利增长。图 3 显示的股票曲线从 1999 年 7 月至 2012 年 12 月的九个 TAA_N 策略以及 SPY 权益曲线。持有大量美国国债的时期，比如 2003 年，比 SPY 的波动性小得多。

为了更好地了解 TAA_N 策略与可比 Basket_N 策略的对比，图 4 显示了 TAA₆、Basket₆ 和 SPY 股本曲线。TAA₆ 策略优越的回报和减少的损失是显而易见的。然而，由于这一策略通常是至少投资部分美国国债，它在牛市中滞后于 Basket_N 策略。


例如，对于 2002 年 10 月 7 日到 2007 年 4 月 23 日，Basket_N 策略回报率 117%，TAA_N 策略 77%，SPY 103%。这是一个寻求限制损失的策略所面临的挑战。许多投资者将不会留意 TAA 策略有 77% 的回报并且波动性少得多。在事后看来，唯一遗憾的是他们错过了 117% 的涨幅。然而，一个着眼长远的投资者认识到一个较低波动性限制损失的策略，比“买入并持有”策略或者将投资组合暴露在尖锐市场修正中的策略更理想。

为了说明这一点，我们注意到 2008 年 4 月 28 日 TAA₆ 投资组合达到峰值，恢复到 2009 年 7 月 13 日水平（时隔仅一年）。周频率的“买入并持有”SPY 组合（含股息）于 2007 年 10 月 8 日更早达到峰值，但没有恢复直到 2012 年 3 月 12 日（时隔将近四年半）。TAA₆ 投资组合不仅是损失较不剧烈，同时峰值之间的间隔短得多。

我们再考虑如何选择不同篮子尺寸的策略表现效果。表 6 显示了 TAA 投资组合的回报和风险统计数据。每个 TAA 的回报比相关的 Basket 策略更大，并且波动性随着篮子尺寸的增加严格递减，同时也比可比的 Basket 策略小。然而，随着篮子尺寸的增加，复合年增长率不是严格意义上的下降。例如，相比 TAA₄，在 TAA₆ 中有更多的 ETF 更有好处。引入昂贵的 ETF 转换为美国国债的转换，有助于减轻损失在股票被高估的时候，并且提供一种投资协同作用。


篮子里大小的选择给投资者提供了基于预期回报、损失和风险修正出色表现来调整投资组合的机会。一个支持低损失和低波动率的投资者可能会选择 TAA₉ 投资组合因为其风险特征。一个投资者支持高回报可能选择 TAA₁ 因为其占主导地位的预期回报。本文的剩余部分专注于 TAA₆ 策略因为它提供了一个高信息比率和令人羡慕的风险特征的混合。

图 3 TAA_N 策略权益曲线(99 年 7 月 - 12 年 12 月)



资料来源：Equity Sector Rotation via Credit Relative Value

图 4 TAA₆ 策略、Basket₆ 策略和 SPY 股本曲线(99 年 7 月-12 年 12 月)



资料来源：Equity Sector Rotation via Credit Relative Value

表 6 TAA₆ 策略和 SPY 的回报和风险统计量(99 年 7 月-12 年 12 月)

	TAA ₁	TAA ₂	TAA ₃	TAA ₄	TAA ₅
CAGR (13.5 years)	14.5%	13.2%	13.3%	11.7%	12.0%
Volatility	31.0%	23.9%	21.1%	19.5%	18.3%
Sharpe Ratio (2.2%)	0.40	0.46	0.53	0.48	0.54
Sortino Ratio	0.50	0.62	0.70	0.62	0.68
Skewness	0.08	0.33	0.41	0.28	0.28
MaxDD	-60.3%	-47.6%	-44.7%	-41.3%	-36.3%
Information Ratio	0.50	0.72	0.86	0.79	0.82
	TAA ₆	TAA ₇	TAA ₈	TAA ₉	SPY
CAGR (13.5 years)	12.4%	11.8%	11.1%	10.9%	2.1%
Volatility	17.2%	16.2%	15.0%	13.9%	20.3%
Sharpe Ratio	0.59	0.59	0.59	0.62	0.00
Sortino Ratio	0.75	0.73	0.73	0.79	-0.01
Skewness	0.42	0.40	0.60	0.85	-0.37
MaxDD	-30.1%	-27.5%	-26.6%	-25.8%	-54.8%
Information Ratio	0.83	0.76	0.69	0.65	

资料来源：Equity Sector Rotation via Credit Relative Value

在附录中，表 8 列出了 TAA₆ 按年和月的回报，红色表示损失，绿色表示获利。一个直接的事实是策略在分析的时间段内每年获利。当然，在 2008 年上涨 0.5%，基于组合每周调整的当天，很可能为损失。然而，我们相信一个只做多头的投资者会很乐意接受 TAA₆ 盈亏平衡而不愿意忍受 SPY 在 2008 年的损失。获利在整个时期绝不是统一的。股票曲线显示，策略经常在下行的股票市场表现最好，因为其将被高估 ETF 转为美国国债，保留长期被低估的 ETF。

也在附录中，表 9T 列出了 TAA₆ 相对于 SPY 的超额表现 (outperformance)。我们定义 outperformance 为策略的表现-SPY 的表现。红色表明当 SPY 优于策略，绿色表明策略优于 SPY。在 162 个月中，有 86 个月 (53%) 这一策略优于 SPY。然而，平均每月超额表现为 2.9%，平均每月弱势表现为 -1.6%，进一步将策略偏向于超额表现。

紧随 2002 年后，超额表现最好的一年是 2008，这两年市场均下行。超额表现最差的一年是 2003 年，市场强劲上涨，通过 ETF 相对价值模型，股票都被认为昂贵的。


2003 年和 2010 年末至 2011 年年中，使得策略的挑战成为关注的焦点。通过一个完整的周期，策略表现令人钦佩，但投资者经常不关注完整的周期。一个投资者在 2003 年底可能会忽略策略 2002 年的优异表现，反而关注策略在 2003 年产生的相对微不足道的收益 4.8%。通常，错过损失不像错过收益般感觉明显。不过，策略表现不佳并不会持续很长时间，一个从两到三年时间的角度分析的投资者会因为坚持策略而得到较大回报。

6、实际操作-减少投资组合的收益

ETF 排名的战术资产配置策略使投资组合产生更高的回报和优良的风险特性。直到现在，我们忽略了交易成本。我们继续忽视税收的后果，因为这种类型的策略不是为了最小化纳税义务。ETF 之间转换会产生短期资本利得，这一策略相对于买入并持有的投资策略，会增加非豁免投资者的纳税义务。

当挖掘 1999 年 7 月至 2012 年 12 月的 TAA₆ 策略，我们发现一个行业 ETF 被包含在投资组合中的时间平均 7.7 周。图 5 画出了连续每周 ETF 的持有(held)数量。注意“held”是指这个 ETF 是排名前 6 的 ETF 之一，不管相对于 HY/B 指数来说它被认为是昂贵或便宜。ETF 被持有的最长时间是 68 周，超过四分之一的仓位被持有 1 周。

图 5 ETF 仓位数在 TAA₆ 投资组合中的持有周数(99 年 7 月 - 12 年 12 月)



资料来源：Equity Sector Rotation via Credit Relative Value

因为几乎四分之三仓位被持有多于一个星期，我们测试避免调整投资组合对回报和风险的影响。“避免调整”是指仓位不改变直到基础 ETF 退出投资组合、从昂贵变为便宜或从便宜变为昂贵。这将 1999 年 7 月至 2012 年 12 月时期的交易数量从 4764 (6.8 每周) 降到 1717 (2.4 每周)。从理论上讲，这将降低大约 64% 的交易成本，并使策略更容易执行。表 7 比较了 TAA₆ 投资组合和低频率执行的 TAA₆ 策略的回报和风险统计量，忽略交易成本。

表 7 TAA₆ 策略和 TAA₆ 低频策略的回报和风险统计量

	TAA ₆ Weekly Rebalance	TAA ₆ Lower Frequency
CAGR (13.5 years)	12.4%	12.2%
Volatility	17.2%	17.0%
Sharpe Ratio (2.2%)	0.59	0.59
Sortino Ratio	0.75	0.73
Skewness	0.42	0.38
MaxDD	-30.1%	-30.6%
Information Ratio	0.83	0.81

资料来源：Equity Sector Rotation via Credit Relative Value

鉴于类似的统计数据，我们发现一旦考虑现实交易成本，较低频率调整比每周调整的策略更优。无论如何，这两种操作展现了几乎相同的回报和风险特征，而低频率更好的根本原因是其较少的交易。

7、结论

本文将公司资本结构资产价格的基本关系扩展到指数水平。我们使用 HY/B 信贷指数和标准普尔行业 ETF 构造线性相对价值模型，然后基于 ETF 偏离公允价值的距离进行排序。这一排名成为是简单的相对实力投资策略的基础，这个策略产生相对于标准普尔 500 指数优越的、经风险调整的绝对回报。进一步，我们扩展策略（只投资被视为便宜的 ETF，将被视为昂贵的 ETF 的投资转为投资美国国债），提高收益，降低波动性，限制投资损失，更快恢复到以前的高位。

我们相信这种类型的相对实力投资策略在时间长度为几年的投资角度看是值得投资者考虑的。我们也注意到，由于使用信贷市场来判断相对价值，这种投资策略与许多流行的排名方法不相关，并且可以作为现有策略的增强策略使用。策略列出的不是失效保护，而是它确实给投资者提供了一个直截了当的过程，通过改变投资篮子的大小来调整股票投资组合的回报与风险特征。此外，策略是为只做多头的投资者设计的，可以用高流动性指数 ETF 实现。

表 8 TAA₆ 策略月度表现

	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug	Sep	Oct	Nov	Dec	Total
1999							2.6%	-1.0%	1.3%	1.8%	-3.4%	-3.6%	-2.5%
2000	0.9%	-5.9%	2.6%	9.2%	4.7%	-1.6%	4.9%	-1.6%	4.7%	0.4%	6.8%	2.8%	30.7%
2001	-0.1%	4.5%	2.6%	-0.2%	0.4%	2.1%	3.4%	3.0%	-3.0%	3.6%	-1.9%	2.0%	17.2%
2002	1.3%	1.5%	0.7%	4.3%	1.7%	1.1%	15.0%	7.2%	-2.9%	-1.0%	0.0%	4.1%	36.9%
2003	0.4%	-0.3%	2.0%	-4.3%	-4.4%	-3.6%	1.9%	-2.4%	-0.6%	-1.2%	-0.1%	-3.0%	-14.7%
2004	-1.2%	-1.2%	1.3%	0.1%	0.5%	1.0%	0.6%	-0.5%	0.3%	1.0%	0.1%	-1.4%	0.6%
2005	2.2%	0.1%	1.3%	-0.3%	-0.8%	0.1%	-1.1%	0.4%	0.9%	3.0%	-1.6%	-0.3%	3.8%
2006	1.8%	-0.6%	-1.4%	0.0%	0.6%	2.3%	0.0%	-1.7%	-0.8%	-2.4%	-1.9%	-0.2%	-4.3%
2007	0.0%	3.5%	-1.0%	-4.4%	-1.4%	1.9%	3.1%	-0.3%	-1.0%	1.7%	3.0%	4.4%	9.4%
2008	3.1%	1.7%	-1.2%	-1.1%	0.1%	-0.1%	2.8%	3.3%	10.2%	15.2%	-0.3%	8.3%	49.2%
2009	-3.2%	0.1%	4.6%	-4.0%	-3.0%	4.0%	-0.5%	1.6%	-1.5%	-1.6%	-0.8%	-0.3%	-4.8%
2010	3.2%	-1.0%	-4.4%	-1.2%	5.8%	4.5%	0.7%	4.7%	-1.4%	-3.8%	-2.3%	-1.8%	2.4%
2011	0.0%	-0.3%	-0.1%	-1.3%	6.0%	-3.5%	4.7%	11.2%	6.3%	-1.8%	1.5%	1.1%	25.4%
2012	-3.7%	-1.9%	-2.6%	2.8%	0.7%	-0.5%	1.2%	-0.8%	-0.5%	0.4%	0.1%	-0.1%	-4.7%

资料来源：Equity Sector Rotation via Credit Relative Value

表 9 TAA₆ 策略相对于 SPY 的表现

	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug	Sep	Oct	Nov	Dec	Total
1999							-2.0%	0.8%	-2.0%	5.6%	1.7%	-1.6%	2.2%
2000	-1.3%	-7.6%	11.3%	6.2%	4.8%	-1.2%	5.5%	0.5%	-0.2%	0.3%	-0.9%	-0.4%	16.9%
2001	5.3%	-4.0%	-5.9%	10.3%	1.3%	-0.2%	0.2%	-2.9%	-10.5%	10.0%	0.5%	5.4%	7.6%
2002	-4.7%	6.9%	0.0%	-4.0%	0.7%	-5.7%	-0.7%	13.0%	-12.6%	14.0%	3.3%	3.3%	10.7%
2003	-6.8%	-2.8%	7.2%	1.2%	0.1%	0.1%	-0.3%	1.9%	0.8%	0.8%	1.4%	1.8%	4.8%
2004	0.2%	0.7%	0.9%	-2.6%	1.0%	0.7%	-0.2%	1.2%	1.5%	0.7%	5.5%	0.0%	9.7%
2005	2.0%	2.3%	-2.6%	-1.3%	2.3%	0.8%	1.5%	0.5%	0.4%	2.7%	1.9%	0.3%	11.3%
2006	1.7%	0.6%	0.2%	0.6%	-1.9%	3.3%	0.1%	1.2%	0.7%	1.3%	0.4%	0.4%	8.8%
2007	2.4%	-1.9%	2.8%	1.5%	0.7%	0.8%	-0.7%	1.6%	2.9%	-1.1%	1.4%	0.4%	11.3%
2008	0.6%	-1.4%	1.8%	1.7%	-1.2%	-9.7%	2.8%	5.8%	-9.3%	6.9%	-15.7%	23.4%	0.5%
2009	-13.9%	-14.4%	24.8%	4.3%	1.1%	-0.9%	11.3%	4.1%	0.0%	-1.3%	5.4%	2.5%	18.9%
2010	-0.7%	1.6%	1.9%	0.1%	-5.5%	0.4%	10.4%	1.8%	2.8%	0.2%	1.2%	2.2%	17.0%
2011	3.8%	-0.7%	1.7%	0.9%	0.4%	0.6%	0.7%	1.0%	0.4%	12.8%	1.5%	2.8%	28.5%
2012	1.6%	-0.2%	1.5%	-0.6%	-5.9%	6.5%	3.5%	0.2%	2.4%	-1.3%	-0.2%	1.3%	8.8%

资料来源：Equity Sector Rotation via Credit Relative Value

极端变动的丛集效应:股价与天气

原文: Burton G. Malkiel, Atanu Saha, Alex Grecu, The Clustering of Extreme Movements: Stock Prices and the Weather, CEPS Working Paper No. 186, February 2009

推荐人: 张欣慰 021-23219370

推荐理由: 股票市场存在“波动率丛集”效应, 本文发现股价在极端变动日之前三天的日均波幅会明显放大。这说明投资者可能可以构建一个择时策略, 在预测到极端负面股市收益之前将股票变现。事实上, 作者按照此规律构建择时策略, 成功地避免了近80%的负向极端波动。但是需要注意的是, 长期来看这一策略并未能大幅战胜买入持有策略, 但净值的波动率却得到大幅的降低。

一、数据来源及处理分析

在本节中, 我们将介绍被用来分析的每日股市回报和纽约州的温度变化的数据。我们还提供了极端变动日子的幅度和频率的一些简单的统计, 包括极端变动的时间间隔分析。

我们采用1900年1月1日至2006年12月31日间所有交易日道琼斯工业指数日线数据。表1展示了道琼斯指数日收益率的一些相关的统计数据, 我们的样本包括26,884天的每日回报。对于这个样本, 日均收益率是0.0195%, 而日收益的标准差(σ)为1.131%, 年化均值为7.02%、波动率为21.46%。我们按照相同的均值和标准差, 生成一个正态分布并随机模拟26,884个伪回报。

表1 道琼斯指数日收益率与正态分布的对比

Panel A: Comparison of Frequencies of Days

Dow Jones Daily Returns: 1900-2006			Random Draws from a Normal Distribut		
# of Sigmas From the Mean	Number of Observations	Percentage of total	# of Sigmas From the Mean	Number of Observations	Percentage of total
Greater than 1	5,203	19.4%	Greater than 1	8,568	31.9%
Greater than 2	1,217	4.5%	Greater than 2	1,208	4.5%
Greater than 3	427	1.6%	Greater than 3	70	0.3%
Greater than 4	183	0.7%	Greater than 4	1	0.0%
Greater than 5	82	0.3%	Greater than 5	0	0.0%
Greater than 6	52	0.2%	Greater than 6	0	0.0%
Sub-Total	7,164		Sub-Total	9,847	
Total Trading Days	26,884		Total Observations	26,884	

资料来源: The Clustering of Extreme Movements: Stock Prices and the Weather

表1显示, 大约有80.6%的交易日, 道琼斯指数的日回报在均值的1倍标准差之内。在正态抽样中, 只有68.1%的观察在均值的1倍标准差之内。然而, 这两组数据之间的对比是最明显是日回报在均值3倍标准差之外的数据, 道琼斯指数约有1.6%的日收益率在均值的3倍标准差之外, 而正态分布只有0.3%的观测在均值的3倍标准差之外。这与不少学术研究发现的收益率具有“尖峰肥尾”的特征一致。

在表2中, 我们研究一个极端变动日到下一个极端变动日之间的时间间隔。在这里, 我们定义极端变动日为日收益率在日均收益率3倍标准差之外的(我们称之为一个' $3\sigma + \text{day}$ ')日子。在426个极端变动日间隔中, 有322个间隔小于等于25天, 时间

间隔不超过 2 天的极端变动间隔占比更是超过了 31%。道琼斯指数极端变动日的集聚和从正态分布随机抽取的极端变动间隔的非常不同，在正态分布下，我们观察到极端变动间隔不超过 25 天的样本占比少于 6%，相比之下，道琼斯指数收益率的这一比例是 76%。

表 2 极端变动的时间间隔分布统计

Panel B: Time Interval Between 3-Sigma Plus Days

Dow Jones Daily Returns: 1900-2006			Random Draws from a Normal Distribution		
Time Interval in Days	Number of Observations	Percentage of total	Time Interval in Days	Number of Observations	Percentage of total
1	76	17.8%	1	0	0.0%
2	57	13.4%	2	0	0.0%
3 to 5	96	22.5%	3 to 5	0	0.0%
6 to 25	93	21.8%	6 to 25	4	5.8%
Subtotal	322	75.6%	Subtotal	4	5.8%
Greater than 25	104		Greater than 25	65	
Total	426		Total	69	

资料来源：The Clustering of Extreme Movements: Stock Prices and the Weather

我们进一步探讨道琼斯指数的极端变动日集聚的现象（详见表 3）。在整个期间，1990 - 2006，极端变动日的平均时间间隔是 178 天（中值是 116 天）。剔除上个世纪 30 年代的数据，这一平均值上升至 194 天（中值为 126 天）。这 427 个极端变动日，超过一半发生在 20 世纪 30 年代。事实上，在 20 世纪 30 年代，所有交易日中的 9% 的收益在均值的 3 倍标准差之外。相比之下，20 世纪 50 年代是最为平静的，小于 0.25% 的交易日发生了极端变动。

表 3 极端变动的时间间隔的分时段统计


Panel A Dow Jones Daily Returns : 1900-2006				Panel B New York Daily Average Temp's % Deviation from Normal: 1901			
Decade	Number of 3-Sigma Plus days	% of Trading Days	Average Duration Between 3-Sigma Plus Days	Decade	Number of 3-Sigma Plus days	% of Calendar Days	Average Duration Between 3-Sigma Plus Days
1900 s	37	1.47%	62	1900 s	11	0.34%	292
1910 s	28	1.16%	93	1910 s	30	0.82%	121
1920 s	43	1.72%	59	1920 s	13	0.36%	279
1930 s	225	8.94%	11	1930 s	27	0.74%	124
1940 s	17	0.67%	135	1940 s	15	0.41%	264
1950 s	4	0.16%	567	1950 s	13	0.36%	228
1960 s	5	0.20%	309	1960 s	20	0.55%	181
1970 s	11	0.43%	343	1970 s	23	0.63%	189
1980 s	24	0.94%	116	1980 s	21	0.57%	175
1990 s	11	0.44%	207	1990 s	30	0.83%	108
2000 s	22	1.25%	51	2000 s	17	0.66%	171
Total	427			Total	220		
Average		1.58%	178	Average		0.57%	194
Average w/o 1930s		0.84%	194				

Note: A "3-Sigma Plus day" is one where the daily absolute return of Dow or the absolute deviation from normal temperature is greater than or equal to 3-sigma

资料来源：The Clustering of Extreme Movements: Stock Prices and the Weather

过去一个多世纪的极端变动日如图 1 所示。图 1 展示了一些有趣的现象。极端变动日呈现明显的集聚现象。我们注意到，最大的集聚发生在 20 世纪 20 年代后期和 30 年代初期，伴随着股市的繁荣。另一个集群是围绕在三十年代末的经济活动的大萧条，并伴随第二次世界大战的不确定性。最近的集聚发生在 20 世纪 90 年代后期和 21 世纪初的与高科技互联网泡沫破灭。注意在股市中会出现一些少量的大规模单日异动，其中 1987 年 10 月 19 日的跌幅非常突出。最后，注意大的正负变化的涨跌一般是对称的，除了少数极不寻常的急剧下降，并没有证据股市的波动性随着时间的推移在增加。事实上，已经有好几年时间，期间没有极端变动的事件发生。

图 1 20 世纪极端变动日的分布



资料来源：The Clustering of Extreme Movements: Stock Prices and the Weather

我们还从纽约中央公园得到 1901 年至 2006 年的每日气温数据。然后，我们定义温度的日变动为偏离平均温度的百分比。我们的样本包括 38,655 个每天温度偏离正常值的百分比观测值。样本中每日温度变化的标准偏差（ σ ）是 1.46%。我们将温度偏离均值 3 倍标准差以上的日子定义为极端变动日。

表 3 的 Panel B 展示了纽约温度极端变动的发生和其间隔期的数据。A、B 组的比较揭示了一些有趣的差异和相似之处。不同于道琼斯指数，纽约气温极端变动在过去十年中的分布更均匀。对于年 1901 年至 2006 年，共有 220 次温度极端变动的记录。温度极端变化的概率大约只有道琼斯指数中一半，如果将 20 世纪 30 年代的数据排除在外，那这两组数据或许更具可比性。对于纽约的天气温度，两个 $3\sigma + \text{day}$ 之间的持续期为 194 天，这比道琼斯指数的 178 天更高。然而，对于一个剔除了 20 世纪 30 年代数据的道琼斯指数来说，两个 $3\sigma + \text{days}$ 之间的间隔变为 194，完全和纽约的温度的平均极值间隔一样。

二、极值的间隔分析

在本节中，我们将试图寻找可以预测极端变动日的因素。特别地，我们研究极值日（包括道琼斯指数和纽约的温度）前后的相应指标的波动率变化幅度。我们将首先着手于极值日之间的时间间隔的简单回归分析，然后进行使用 Cox 比例模型进行更精确的持续时间分析。

我们考虑的主要解释变量是：(i)（道琼斯指数的回报的绝对值和天气温度偏离均值的百分比）在 $3\sigma + \text{day}$ 前三天的日均绝对值；(ii) 在 $3\sigma + \text{day}$ 后紧接着三天的日均绝对值；(iii) $3\sigma + \text{day}$ 当天的收益率的绝对值

这三个变量的重要统计数据（平均值和标准差）详见表 4。便于比较，我们还给出了 26,884 个道琼斯指数的观测值和 38,655 个纽约天气温度的观测值的平均绝对值和波动率。表 4 的第一行显示，道琼斯指数的日收益的平均绝对值是 0.743%，整个样本的标准偏差是 0.853%。这些数字与表 1 中的统计有所不同，因为在这里我们列出的是回报绝对值的均值、标准差。

表 4 中接下来的三行包含了三个解释变量的统计数据。这三个变量的平均值和标准偏差都是基于 427 个道琼斯指数观测值和 220 个纽约气温观测值，与每一个的 $3\sigma + \text{day}$ 相对应。

表 4 股市、天气极端变动前后特征分析

Table 2: Descriptive Statistics For Extreme-Move Days for Stock Prices and NY Temperature

	Dow Jones Daily Returns: 1900-2006		New York Daily Average Temp's Deviation from Normal: 1901-2006	
	Mean	Standard Deviation	Mean	Standard Deviation
Absolute Value of Daily Return/Daily Change	0.743% (N = 26,884)	0.853%	1.138% (N = 38,655)	0.909%
Average Daily Move 3-days Before a 3 Sigma-Plus Day	2.105%	1.741%	2.563%	1.107%
Average Daily Move 3-days After a 3 Sigma-Plus Day	2.122%	1.602%	2.441%	1.102%
Average Daily Move on the Day of a 3-Sigma Plus Day	4.952%	2.166%	4.984%	0.556%
Number of observations	427		220	

资料来源：The Clustering of Extreme Movements: Stock Prices and the Weather

将表 4 中第一行的数据与二、三行的进行对比发现， $3\sigma + \text{day}$ 的前后三日的日均绝对收益率和普通交易日不一样。 $3\sigma + \text{day}$ 前三天中的日均绝对回报是 2.11%，这几乎是全样本日均绝对回报的三倍。同样的现象也适用于 $3\sigma + \text{day}$ 后三天。所有 $3\sigma + \text{day}$ 当天的绝对回报均值是 4.96%，几乎是所有样本的 7 倍。这一差异是可以想象的，因为在 427 个 $3\sigma + \text{day}$ 回报的日子中，有很多日子回报偏离均值 6-7 个标准差。

现在转向对纽约的温度解释变量的汇总统计数据，我们发现了一个与道琼斯指数惊人的相似处。日平均偏差在 $3\sigma + \text{day}$ 之前和之后的三天比所有样本的均值大得多的（约 2.5 倍）。有趣的是，道琼斯指数和天气温度的“ $3\sigma + \text{day}$ 日变动”的绝对均值惊人的相近，分别为 4.98% 和 4.95%。

在表 4 中的汇总统计数据表明，这些变量对极端变动日的或许有很强的预测作用。在进行严格的间隔时间的分析之前，我们先使用简单的最小二乘回归来检查 $3\sigma + \text{days}$ 之间的时间间隔与解释变量之间的关系。两个最小二乘法分析的结果，一个是道琼斯指数，另一个是纽约温度的结果列于表 5 中。在每一个回归的因变量是 $\ln(T)$ ，其中 T 表示从一个极端变动日到下一个极端变动日的时间间隔，解释变量是在表 4 中讨论过的 3 个。

表 5 股市、天气极端变动前后特征分析

Table 3: Least Squares Analysis of the Time Interval Between 3 Sigma-Plus Days

	Dow Jones Daily Returns		New York Daily Average Temp's Deviation from Normal	
	Estimated Coefficient	T-stat	Estimated Coefficient	T-stat
Three-Days Before	-54.87	-12.20 ***	-123.73	-10.04 ***
Three-Days After	-8.21	-1.64	5.21	0.41
The Day of	-6.37	-1.77	-68.14	-2.65 ***
Intercept	3.72	19.54 ***	9.84	8.22 ***
Number of obs	427		220	
Adjusted R-Squared	0.327		0.362	

资料来源：The Clustering of Extreme Movements: Stock Prices and the Weather

定性来说，道琼斯指数和纽约天气非常相似。在这两种情况下，变量“ $3\sigma + \text{day}$ 前的日均变动”的系数是负的，并且显著性水平很高（t 统计量超过 10），反过来“ $3\sigma + \text{day}$

后三天的日均变动”变量系数不能通过显著性检验。道琼斯指数和纽约的温度的“ $3\sigma + \text{day}$ 日变动”变量系数都是负的，但是在 95% 的区间内不显著。这个变量的系数为负表明， $3\sigma + \text{day}$ 变化的幅度自身和极端变动日之间的时间间隔呈负相关关系。

三、Cox 比例风险模型的极值间隔分析

表 6 展示了我们用 Cox 比例风险模型分析极值持续时间的分析结果。我们用半参数 Cox 模型，而不是一个像 Weibull 或 logistic 模型的参数模型，因为 Cox 模型没有规定风险函数的特定形式。

在最小二乘回归和 Cox 模型的解释变量估计系数的对比中，系数更被人们希望是正的而不是负的。人们应有水平注意，系数的迹象，预计会比负相当积极。正向估计系数表明这些变量缩短了持续期间，也就是缩短了下一个 $3\sigma + \text{day}$ 的到来。例如，和回归结果一致，“ $3\sigma + \text{day}$ 前的三天日均变动”变量的系数估值是正的并且在 Cox 模型的道琼斯和纽约天气数据中的 99 % 的置信区间都显著。同样的，“”变量的系数估值也是正的并且在道琼斯和纽约天气数据中都显著。然而，变量“ $3\sigma + \text{day}$ 后的三天日均变动”在道琼斯和纽约天气数据中都不显著。

表 6 股市、天气极端变动前后特征分析

Table 4A: Estimation of Time Between Extreme-Move Days Using the Cox Duration Model

	Dow Jones: 1900-2006				NY Temp: 1901-2006	
	Coeff-Est	Z-stat	Excluding the 1930s Coeff-Est	Z-stat	Coeff-Est	Z-stat
All 3-Sigma Plus Days						
3-Days Before	32.74	13.25 ***	29.80	8.11 ***	45.60	6.69 ***
3-Days After	4.49	1.42	1.21	0.27	-2.03	-0.31
That Day	6.26	2.51 **	7.27	2.09 **	43.98	3.38 ***
Number of Obs		427	202		220	
Only Positive 3-Sigma Plus Days						
3-Days Before	89.38	9.97 ***	115.94	6.10 ***	36.46	3.76 ***
3-Days After	23.53	3.07 ***	15.98	1.13	9.48	1.06
That Day	10.72	2.50 **	21.57	2.16 **	47.19	2.08 **
Number of Obs		178	80		115	
Only Negative 3-Sigma Plus Days						
3-Days Before	46.35	9.84 ***	41.13	6.18 ***	45.75	4.48 ***
3-Days After	3.77	0.89	2.64	0.48	-6.34	-0.59
That Day	9.07	3.45 ***	10.98	3.25 ***	39.78	2.31 **
Number of Obs		249	122		105	

Note: See Table 3 for definition of the variables

资料来源：The Clustering of Extreme Movements: Stock Prices and the Weather

对于道指，我们剔除 20 世纪 30 年代的数据后重新估计了 Cox 模型（留下了 202 个 $3\sigma + \text{days}$ ）。结果几乎保持不变：参数估值的标志和系数的意义是和使用整个样本期间 1900-2006 对应的。

为了探索 Nelson's (1991) 的发现，市场对于“好消息”和“坏消息”的回应是不对称的，我们接下来分别考虑到了 2 个分支--正的和负的 $3\sigma + \text{days}$ ，在变量“ $3\sigma + \text{day}$ 前的三天日均变动”中，分别衡量在 3 天中正、负回报或温度变化的绝对平均值。其结果贯穿了子样本。变量“日均变动前三天”和“当天”对于不论正的还是负的 $3\sigma + \text{days}$ 均能维持检验的显著性。同样，除了道琼斯指数正的 $3\sigma + \text{days}$ ，变量“ $3\sigma + \text{day}$ 三天

后的均值”的系数是在任何情况下不显著的，。然而，即使在这种情况下，当 1930 年代的数据被剔除后，系数的估计变得不显著。

虽然正向和负向的 $3\sigma + \text{day}$ 的估计结果在系数估值的标志和意义性质上很相似，但是也有一些差异，特别是道琼斯指数。变量“ $3\sigma + \text{day}$ 前的三天日均变动”的系数道琼斯正向 $3\sigma + \text{day}$ 比负向 $3\sigma + \text{day}$ 大不少。即使剔除 20 世纪 30 年代，这个结果也是如此。这意味着正向的 $3\sigma + \text{day}$ “加速”下一个极端变动的到达。

综合而言，表 6 中的 9 组间隔时间模型的分析结果是非常一致的。“ $3\sigma + \text{day}$ ”前三天的均值异常放大，加速了下一个极端变动日的到来。

四、策略的构建

根据前面的分析我们提出一下资产配置策略。

(a) 样本期间开始，组合是 100% 仓位投资于道琼斯指数。也就是说，投资组合的日收益率被认为是和道琼斯指数一样的。

(b) 若某天的回报为负，且前三日的负收益的平均绝对值超过设定的临界值，则该组合平掉所有股票仓位并持有现金。

(c) 投资组合在平仓的时间内获无风险利率的收益。

(d) 在固定的平仓期后，投资者重新买入并持有道琼斯指数。

(e) 平仓和建仓时，我们都会扣除一个固定的交易成本。

我们定义 (b) 中“设定的临界值”为整个样本中所有回报为负的非 $3\sigma + \text{day}$ 的日均绝对值回报。我们把这个临界称为“平仓点”。我们已经考虑到投资组合持有的不同时期的平仓期，包括 2、3、5、7 和 10 天。在平仓期间，日无风险率为 0.0103%。这是基于 1926 年至 2006 年年平均每年国债利率 3.7% 得到的。交易成本我们固定设为 5bp。策略的分析结果见表 7。

表 7 股市、天气极端变动前后特征分析

Table 5: Performance Statistics for Alternative Trading Strategies Based on Extreme-Move Days

	All data (1900-2006)					1936-2006 Only				
	Annual Mean Return (%)	Annual Sigma (%)	Sharpe Ratio	% Days	% of Negative 3-Sigma-plus days avoided	Annual Mean Return (%)	Annual Sigma (%)	Sharpe Ratio	% Days	% of Negative 3-Sigma-plus days avoided
Actual	7.01	21.46	0.15			9.45	17.76	0.32		
Hypothetical Portfolio										
Unwound period 2 days	6.59	16.85	0.17	12%	54%	7.42	14.57	0.26	12%	47%
Unwound period 3 days	7.63	16.05	0.25	16%	65%	7.04	14.03	0.24	16%	55%
Unwound period 5 days	8.62	14.66	0.34	22%	75%	7.53	12.94	0.30	23%	67%
Unwound period 7 days	8.42	13.61	0.35	28%	80%	7.45	11.98	0.31	29%	74%
Unwound period 10 days	8.28	12.53	0.37	34%	86%	7.07	11.03	0.31	36%	79%

Note: "% Days" is the percent of the trading days during which the portfolio remains invested in cash as opposed to being invested in Dow.

资料来源：The Clustering of Extreme Movements: Stock Prices and the Weather

考虑整个 107 年的考察周期，我们发现，一旦发现异动，平仓期超过两天的策略带来的年化收益均能超越道琼斯指数的年化收益。随着平仓时间的变长，保持投资组合投资于现金的比例变化从 12% 到 34%。

两个发现值得特别注意：第一，策略组合的波动性要远远低于道琼斯指数的波动率。道琼斯指数的年化波动率为 21.46%，以发现异动即平仓 2 天的策略来看，投资组合的

年化波动率相对降低了近 400 个基点至 16.85%。在所有情况下，策略组合夏普比率比实际道琼斯指数的夏普比率更高。事实上，对于十天平仓期间，策略组合的夏普比率为 0.37，超过了道琼斯指数的夏普比率（约为 0.15）两倍。

其次，我们的策略以一个相当简单的触发条件平仓，却相当有效的避免了负向的 $3\sigma + \text{days}$ 。即使只有两个天平仓期间，能成功避免了 54% 的负向 $3\sigma + \text{days}$ 。当平仓期增加至 10 天，此百分比扩大至到 86%，这说明该触发条件对未来负向极端波动的预测是相当准确的。

五、总结

已经有相当多的实证工作证实股票收益不是正态分布的，而且我们知道股价的走势不服从随机游走过程，且在某种程度上是可预测的。本文检验了道指和天气的“尖峰肥尾”的特性。我们发现当股市发生“极端变动”时，通常这样的日子会集聚在一起。

通过极端值的间隔时间分析我们发现，极端变动在某种程度上通常可以根据前期的大幅变动来预测。本文一个重要发现是股价的极端变动通常在跟随着前三个交易日中的大幅波动而到来。为此我们构建了一个资产配置策略，投资者可以根据此策略提前预判负向的极端变动是否会到来，相比买入持有策略，该方法无法大幅提高回报，但却可以帮助投资者避免一半以上的负向极端变动，从而大幅降低策略的波动性。

业绩公告带来的波动率套利机会

原文: Bok Baik, College of Business, Seoul National University, Hyoung – Goo Kang, Department of Finance, Hanyang Univ, Young Jun Kim, College of Business, Seoul National University, Volatility Arbitrage around Earnings Announcements, Pacific-Basin Finance Journal, Volume 23, June 2013, Pages 109–130


推荐人: 朱剑涛 021-23219745

推荐理由: 盈利动量漂移效应 (Post Earnings Announcement Drift) 是市场上已经研究较多的一种现象, 指的是上市公司盈利增长公告后较长时间内股价仍能够显著战胜市场指数。除了收益率的动量, 公司盈利公告前后还存在一种波动率偏移现象, 期权推出后, 投资者就可以借助期权和现货组合来对这种波动率的变动进行事件套利, 本文作者用韩国数据进行了实证, 发现该项套利空间十分可观。

波动率偏移 (Volatility Drift) 现象最早由 Patell, Wolfson 分别于 1979、1981 年提出, 他们认为盈利公告前隐含波动率会明显升高, 公告后下降, 该观点在之后美国学者的一系列实证研究中得到支持。但这种波动率漂移现象并非在全球所有市场表现都一样, 作者对韩国的实证研究发现, 业绩公告前后 10 个交易日内隐含波动率是一直在下降的, 具体实证过程如下:

作者选用的研究标的是 2005.12.01 – 2010.06.30 期间韩国市场上交易的欧式个股认购权证, 之所以选择权证而不是个股期权主要是因为权证交易更活跃, 而且权证中的 91.3% 为认购权证。金融和保险行业的个股权证被剔除。作者用 black-scholes 公式反算每只期权的隐含波动率, 然后分别按照等权和成交量加权的方式得到个股当天的隐含波动率, 结果如图 1 所示。

图 1 年报公告前后个股的隐含波动率变化



资料来源: www.sciencedirect.com

可以看到, 不论采取何种加权方式, 个股的隐含波动率在时间前后 10 个交易日内都是呈现单调下降的, 等权的隐含波动率下降更多一些, 波动率漂移模式和美国市场差别非常大, 这可能与不同市场的市场信息提前泄露程度不同有关。另外作者按照权证成交活跃度, 分别选取前 25% 和 50% 的权证计算得到隐含波动率, 结果比较类似, 但成交活跃的权证品种隐含波动率下降的更多。随后作者对事件日前后隐含波动率的均值和中

位数分别进行了 T 检验和 Wilcoxon 检验，结果显示，隐含波动率的下降在绝大部分情况下都是统计上显著的，一半以上的权证的隐含波动率都会在事件日前后十个交易日内显著降低。

图 2 年报公告前后个股的隐含波动率变化统计检验


Days $T_1: T_2$	Average of $\ln(\sigma_{t_2}^{imvol} / \sigma_{t_1}^{imvol})$	T stat	Median of $\ln(\sigma_{t_2}^{imvol} / \sigma_{t_1}^{imvol})$	Wilcoxon stat	% of events where $\ln(\sigma_{t_2}^{imvol} / \sigma_{t_1}^{imvol}) < 0$
-1:0	-0.0002	-0.04	-0.0005	4820.5	47.0%
0:+1	-0.0063	-1.47	-0.0017	-119446***	48.5%
-10:+10	-0.0348	-3.06***	-0.0276	-488376***	57.9%
-9:+9	-0.0162	-1.77*	-0.0182	-296823***	54.6%
-8:+8	-0.0149	-2.83***	-0.0142	-294147***	54.6%
-7:+7	-0.0182	-2.46**	-0.0169	-367102***	55.9%
-6:+6	-0.0163	-2.23**	-0.0139	-343520***	54.3%
-5:+5	-0.0120	-1.85*	-0.0084	-238720***	52.1%
-4:+4	-0.0039	-0.86	-0.0067	-135535***	50.9%
-3:+3	-0.0030	-0.54	-0.0050	-119088***	50.1%
-2:+2	-0.0123	-2.41**	-0.0079	-255504***	52.9%
-1:+1	-0.0065	-1.74*	-0.0036	-107495***	49.9%

资料来源: www.sciencedirect.com

投资者可以通过期权“卖出波动率”的方式对盈利公告事件进行套利：也就卖出一手 call，同时买入 $\delta = \partial c / \partial S$ 股标的股票建仓（c 为权证价格，S 为标的券价格），之后每天根据新数据计算出的 δ ，动态调整现货组合，如果市场波动率如期下跌，那么投资者的期权实际复制成本应该小于之前卖出的期权价格，从而赚取其中价差。在设置了相关交易费用后，作者计算了各个盈利公告事件日前后的平均累积套利收益，如图 3 所示，

从图 3 可以看到，套利策略在时间前后十个交易日的累积平均收益率可以达到 11.4%，表现最差的后 25% 的套利操作也有 1.8% 的平均收益；收益率的均值略高于中位数，表明存在右厚尾现象；如果按照流动性分类，我们发现权证的流动性越好，套利空间越小，但最小也有 3.48% 的收益；年份对套利收益有一定影响，但总体来看，绝大部分时间波动率套利都是可以获利的。

图 3 波动率套利策略在时间日前后的累积收益率变化



	Full sample	Top 50%	Top 25%	Top 10%	Top 5%
N	2461	1231	616	247	124
Mean	11.40%	9.40%	9.40%	10.27%	3.48%
Std Dev	28.30%	27.70%	32.40%	15.12%	15.48%
Min	-377.60%	-377.60%	-377.60%	-52.74%	-30.11%
5%	-16.40%	-16.40%	-16.00%	-10.60%	-19.21%
25%	1.80%	1.60%	2.10%	2.11%	0.92%
50%	10.40%	9.10%	8.70%	10.00%	2.14%
75%	20.90%	18.00%	17.30%	18.63%	11.15%
95%	43.70%	37.10%	35.90%	35.33%	24.86%
Max	546.20%	546.20%	546.20%	109.23%	100.88%
2006 Mean	2.17%	1.92%	-0.55%	-4.06%	0.75%
2007 Mean	11.31%	8.72%	9.06%	9.95%	6.86%
2008 Mean	12.11%	11.39%	9.53%	11.02%	7.89%
2009 Mean	21.44%	20.50%	22.54%	19.47%	18.19%
2010 Mean	6.50%	2.87%	1.94%	4.37%	3.52%
2006 Median	1.76%	1.72%	-0.81%	-0.81%	1.47%
2007 Median	9.96%	8.78%	8.47%	10.43%	8.32%
2008 Median	9.18%	9.02%	7.69%	10.76%	7.70%
2009 Median	16.63%	16.16%	16.82%	17.47%	15.54%
2010 Median	8.17%	6.28%	6.28%	5.91%	4.96%

资料来源: www.sciencedirect.com

随后作者考虑了权证到期日和票面虚值对套利收益的影响, 如图 4 所示,
(OTM/ATM/ITM 分别代表 out of/at/in the money) 权证到期日越短, 虚值越多, 套利收益越大。

图 4 权证到期日和票面虚值对套利收益的影响

Figure 3-1: Mean Trading Profit by Moneyness and Maturity





Figure 3-2: Median Trading Profit by Moneyness and Maturity



资料来源: www.sciencedirect.com

作者在本文得出的韩国市场波动率偏移方式和美国市场很不一样, 国内个股期权推出后, 隐含波动率在盈利公告前后又是怎样变化值得深入研究, 其中或许蕴含着非常可观的套利机会。另外作者在实证过程中并未按照盈利增减的大小对业绩预告事件进行划分, 但这是影响股价波动的重要因素, 而且由于上市公司的业绩预告时间可能发生变动, 因而业绩预告后的隐含波动率变动对投资者可能更有实际操作意义, 这些都是值得继续深入研究的问题。

金融中介数据在资产回报截面数据回归中的应用

原文：Tobias Adrian, Erkki Etula, Tyler Muir [2013]. Financial Intermediaries and the Cross-Section of Asset Returns. Federal Reserve Bank of New York Staff Reports.

推荐人：丁鲁明 021-23219068

推荐理由：现代金融理论认为，资产与一些随机贴现因子的关联关系可以决定资产定价。在本文中，作者通过计算美国市场金融中介杠杆和进一步数据处理，得到对应杠杆因子，并就历史主要经济事件时点对杠杆因子的有效性进行解释。其次，将杠杆因子代替随机贴现因子，添加到预测资产收益的线性模型中去。最后建立时间序列和截距回归模型证明了金融中介机构的杠杆指标能很大程度上解释各类资产的平均超额回报，这些资产包括不同市值的股票组合，不同动量的股票组合，不同持有久期的债券组合等。作者向我们证明了金融中介的杠杆是资产定价的重要因素。

一、摘要

现代金融理论认为，资产与一些随机贴现因子的关联关系可以决定资产定价，随机贴现因子往往与集合财富的边际价值联系在一起，金融中介机构的杠杆作用也能够作为一类随机贴现因子来使用。例如，当资金面收紧和金融中介被迫减债时，财富的边际价值应该会变得更高，这些风险因素会导致金融危机。

在本文中，作者通过计算美国市场金融中介杠杆和进一步数据处理，得到对应杠杆因子，并就历史主要经济事件时点对杠杆因子的有效性进行解释。其次，将杠杆因子代替随机贴现因子，添加到预测资产收益的线性模型中去。最后建立时间序列和截距回归模型证明了金融中介机构的杠杆指标能很大程度上解释各类资产的平均超额回报，这些资产包括不同市值的股票组合，不同动量的股票组合，不同持有久期的债券组合等。

作者向我们证明了金融中介的杠杆是资产定价的重要因素。

二、正文

我们一直对金融市场中的金融中介行为和市场资金流情况有所研究。此前也有相关研究者的其他研究成果。

2.1 文献综述

Brunnermeier and Pedersen (2009)提出了中介机构的资产杠杆比率能够反映中介机构的风险控制松紧程度及对边际资产增长的预期。

Adrian and Boyarchenko (2012)提出了关于金融中介杠杆与资金流的均衡模型。

Adrian and Shin (2010)表明了当经济条件变化下，金融中介机构会积极地调整杠杆。

Adrian, Etula, and Shin (2009), Adrian, Moench and Shin (2013) and Etula (2013)表明金融中介机构的杠杆因素对定价资产来说很有说服力。

Muir (2012)发现金融中介资产回报的风险溢价会与金融危机有很密切的联系。

Cochrane and Piazzesi (2009) 表明债券收益率曲线的第一主成分可以作为债券组合的定价因子。

2.2 如何定义金融中介的杠杆因子

一个金融中介资产负债表的简单案例如下：

图 1 2010 年末金融中介的债务和资产

Assets from Flow of Funds (billions)		Liabilities from Flow of Funds (billions)	
Cash (including segregated cash)	\$96.9	Net repo	\$404.7
Credit market instruments	\$557.6	Corporate and foreign bonds	\$129.7
Commercial paper	\$36.2	Trade payables	\$18.1
Treasury securities (net of shorts)	\$94.5	Security credit	\$936.6
Agencies	\$149.8	Taxes payable	\$3.6
Municipal securities	\$40.0	Miscellaneous liabilities*	\$480.7
Corporate and foreign bonds	\$185.6	Payables to brokers and dealers	
Other (syndicated loans etc)	\$51.4	Securities sold not yet purchased	
Corporate Equities	\$117.2	Payables	
Security credit	\$278.2	Subordinated liabilities	
Miscellaneous assets*	\$1,025.3		
Receivables			
Reverse repos			
Options and Arbitrage			
Commodities			
Investments not readily marketable			
Securities borrowed			
Secured demand notes			
Membership in exchanges			
Affiliates, subsidiaries, and associated partnerships			
Property, furniture, equipment, etc.			
TOTAL	\$2,075.1	TOTAL	\$1,973.4

资料来源：《Financial Intermediaries and the Cross-Section of Asset Returns》，Tobias Adrian, Erkki Etula, 【2013】

上图提供了 2010 年末金融中介的债务和资产明细。

2010 年末美国金融中介商 20.75 亿美元的金融资产分成 5 个主要的类别（1）现金（2）信用市场工具（3）股票（4）安全贷款（5）其他资产

根据集合资产定价和金融中介杠杆理论，我们可以调整杠杆系数来作为定价核心。

我们计算经济自营商的杠杆因子如下

$$Leverage_t^{BD} = \frac{TotalFinancialAssets_t^{BD}}{TotalFinancialAssets_t^{BD} - TotalLiabilities_t^{BD}}$$

BD 指的是中介，交易商（broker-dealer）。

2.3 杠杆因子季节效应剔除

我们使用季节调整频率下杠杆因子的原因，一方面为了过滤数据，让结果更为真实稳健，另一方面季节调整频率下的处理方式会让统计结果能更准确反映出机构杠杆的实际变化情况。

$$LevFac_t = [\Delta \ln(Leverage_t^{BD})]^{SA}$$

图2 不同指标与交易商杠杆因子的相关性


Correlation of Broker-Dealer Leverage Factor with:				
	Log Broker-Dealer Asset Growth	Market Volatility	Baa-Aaa Spread	Financials Stock Return
ρ	0.73	-0.37	-0.16	0.18
p-value	0.00	0.00	0.03	0.02

资料来源：《Financial Intermediaries and the Cross-Section of Asset Returns》，Tobias Adrian, Erkko Etula, 【2013】

上图表示了我们的杠杆因子与金融中介成长性和其他金融资产指标的相关性。

我们看到杠杆因子与金融中介自身规模扩张程度呈显著正相关，杠杆因子与市场波动呈负相关，与信用利差呈现弱负相关、与股市收益弱正相关。因此实际表现中，杠杆率的降低与金融中介的资产减少有关，并且同时也会呈现剧烈的市场波动。

图3 杠杆因子与历史重大经济事件高度关联




资料来源：《Financial Intermediaries and the Cross-Section of Asset Returns》，Tobias Adrian, Erkko Etula, 【2013】

上图所示是 1965-2010 中介杠杆的一阶差分与金融经营商杠杆因子绝对值的对比。在 70 年代的石油危机中，杠杆因子急速下降；87 年股市大跌同样也是如此；更值得注意的是，在 2008 年金融危机中，特别是雷曼兄弟倒闭也对应了随后季度的杠杆因子大幅下降。这里再次表明，多数时间下金融中介杠杆率的大幅波动，都对应了重大宏观经济事件的发生。

（但也不是每一次事件都会造成指标的大幅下跌，比如 2003 年的大幅下降、1994 年最后一个季度的墨西哥比索危机等。）

2.4 家庭资产与金融机构资产杠杆与资产成长的关系对比

图4 家庭资产与金融机构资产成长性与各自杠杆水平的对比分析



资料来源:《Financial Intermediaries and the Cross-Section of Asset Returns》, Tobias Adrian, Erkko Etula, 【2013】

从上图可看到，金融中介商杠杆成长与资产成长呈周期性变化。为了突出这点发现，我们将家庭资产的成长数据作为对比案例。在不调整资产负债表的情况下，家庭杠杆和资产增长呈现负相关，具体表现为家庭资产价值提升之后，杠杆总是机械性下降。相比之下，中介交易商具有完全相反的表现模式，资产增长与杠杆增长呈正相关关系。金融中介商在资产价值增加的同时往往同时增加杠杆率，中介交易商对资产负债采取的是积极主动的态度应对。

2.5 时间序列回归模型的构建和截距模型

我们将杠杆因子添加到预测资产收益的线性模型中去

时间序列回归模型

$$R_{i,t}^e = a_i + \beta_{i,f}' f_t + \varepsilon_t^i$$

截距回归模型

$$E[R_t^e] = \alpha + \beta_f' \lambda_f + \varepsilon \quad i=1, \dots, N$$

λ 代表风险因子,用来估计风险溢价

(风险因子可以用不同因子的组合替代)例如($f = \text{LevShock}$)或者($f = [\text{Rmkt}, \text{RSMB}, \text{RHML}]$)

我们以不同的因子 f 作为自变量回归得到各因子的风险价值。

图 5 不同资产下的风险定价检验

Panel A: Prices of Risk						
	CAPM	FF	FF,Mom	FF,Mom,PC1	LevFac	LevMkt
Intercept	3.39	3.16	1.06	0.66	0.12	-0.19
t-FM	3.55	4.09	1.51	1.14	0.06	-0.21
t-Shanken	3.54	4.03	1.34	1.01	0.04	-0.14
LevFac					62.21	60.97
t-FM					4.62	5.29
t-Shanken					3.12	3.65
Mkt	3.06	2.30	4.54	4.89		5.46
t-FM	0.99	0.80	1.59	1.71		1.75
t-Shanken	0.99	0.80	1.58	1.70		1.55
SMB		1.76	1.57	1.63		
t-FM		0.93	0.83	0.87		
t-Shanken		0.93	0.82	0.86		
HML		3.33	4.37	4.34		
t-FM		1.45	1.90	1.89		
t-Shanken		1.45	1.86	1.85		
MOM			7.82	7.75		
t-FM			2.94	2.91		
t-Shanken			2.92	2.89		
PC1				14.99		
t-FM				1.03		
t-Shanken				0.93		

资料来源：《Financial Intermediaries and the Cross-Section of Asset Returns》，Tobias Adrian, Erkkö Etula, 【2013】

上图所示：模型中使用到的数据为 41 类资产，包括 25 种市值加权分类投资组合，10 种动量分类的投资组合和 6 种国库券。图中第一行显示为截距项，CAPM 为资产定价模型，FF 为 FAMA3 因子，MOM 为动量因子，PC1 为债券收益率序列的第一主成分（Cochrane and Piazzesi[2009]，使用上述 5 个因子解释了不同久期债券的组合收益），LevFac 为杠杆因子。

可以看到，在前 2 列中，每一列都有大于 3% 的截距项，无论是 CAPM 模型还是 FAMA3 因子模型都不能充分解释这些资产中平均回报率的波动。但是 LevFac 的单因子回归则表现为极低的截距项 0.12，表明杠杆因子对资产定价的有效性更高。

图 6 不同因子风险定价模型的测试诊断


Panel B: Test Diagnostics							
MAPE	$E[R^e]$	CAPM	FF	FF,Mom	FF,Mom,PC1	LevFac	LevMkt
Size B/M	7.86	2.62	1.81	1.05	1.01	1.16	1.11
MOM	5.80	3.05	3.75	1.47	1.48	1.79	1.85
Bond	1.65	1.83	1.59	0.17	0.17	0.37	0.26
Intercept		3.39	3.16	1.06	0.66	0.12	0.12
Total	6.45	6.00	5.41	2.08	1.66	1.31	1.36
AdjR2		0.10	0.16	0.81	0.81	0.77	0.78
C.I.AdjR2		[0.02, 0.30]	[0.02, 0.36]	[0.74, 0.88]	[0.72, 0.88]	[0.82, 1]	[0.76, 1]
$T^2(\chi^2_{N-K})$		174.48	167.46	111.45	110.19	67.87	68.86
p-value		0.0%	0.0%	0.0%	0.0%	0.3%	0.0%

资料来源：《Financial Intermediaries and the Cross-Section of Asset Returns》，Tobias Adrian, Erkkö Etula, 【2013】

上图的测试诊断显示，CAPM 和 FF 因子的 R 方值分别为（10%和 16%），而且绝对误差比较大。对比之下，杠杆因子对不同资产检验的绝对误差最小，绝对误差只有 1.3%，R 方值也处于一个显著更高的水平 0.77。

2.6 模拟收益率与历史收益率的比较


图 7 历史收益率 VS 杠杆因子模拟下的预期收益率



资料来源：《Financial Intermediaries and the Cross-Section of Asset Returns》，Tobias Adrian, Erkko Etula, 【2013】

上图为历史真实收益率数据与预期收益率数据对比。我们根据不考虑截距项下的杠杆因子单因素模型预测这些资产组合的收益率，除了动量组合第十组（MOM10）偏离了 45 度线之外，所有测试的资产都非常接近 45 度线，即预测值和真实值极为接近。


图 8 历史收益率 VS FAMA3 因子模拟下的预期收益率



资料来源：《Financial Intermediaries and the Cross-Section of Asset Returns》，Tobias Adrian, Erkko Etula, 【2013】

上图显示，FAMA 因子模拟收益下，资产与标准线的偏离度较大，解释度有所不足。

图 9 历史收益率 VS 5 因子（基准）模拟下的预期收益率



资料来源：《Financial Intermediaries and the Cross-Section of Asset Returns》，Tobias Adrian, Erko Etula, 【2013】

上图可见，除了 MOM1 和 S1B1 偏离 45 度线较大，5 因子预测下的期望收益率与历史数据总体也是较为相近。

图 10 不同定价模型预测下的偏差明细

Panel A: Individual Pricing Errors							
Size and Book-to-Market Portfolios							
	Low	Book-to-Market			High		
	$E[R^e]$: Average Returns						
Small	1.15	8.52	9.17	11.38	13.16		
	4.14	7.67	9.91	10.55	11.54		
Size	4.56	8.00	8.43	9.54	12.46		
	6.09	6.07	7.72	9.01	9.57		
Big	4.47	5.93	4.93	5.72	6.83		
Leverage Pricing Errors							
Small	-3.27	2.31	0.43	1.40	1.39		
	0.73	-0.42	0.46	-0.10	-2.10		
Size	0.76	0.79	0.09	0.49	1.88		
	2.57	-1.24	-0.11	-0.27	-0.53		
Big	1.20	1.18	-0.59	-2.51	-2.11		
5-Factor Pricing Errors							
Small	-5.26	0.47	-0.05	0.89	0.78		
	-0.64	0.97	1.46	0.50	0.00		
Size	0.52	0.48	0.43	0.02	1.88		
	2.76	-0.43	-0.28	0.03	-0.45		
Big	1.30	-0.18	-2.32	-2.14	-1.06		
Momentum Portfolios			Bond Portfolios				
	$E[R^e]$	LevFac	5-Fac		$E[R^e]$	LevFac	5-Fac
Mom 1	-3.75	-2.46	-2.96	0-1yr	0.70	0.15	-0.17
Mom 2	3.06	-1.00	1.71	1-2yr	1.28	-0.56	-0.43
Mom 3	4.80	-0.03	3.52	2-3yr	1.70	-0.02	-0.08
Mom 4	5.10	-0.63	1.02	3-4yr	1.95	-0.27	-0.03
Mom 5	4.15	-2.15	-0.27	4-5yr	2.00	-0.52	-0.05
Mom 6	5.11	-1.67	-0.10	5-10y	2.29	-0.70	-0.24
Mom 7	5.29	-1.23	-1.23				
Mom 8	7.19	0.63	-0.57				
Mom 9	7.61	0.81	-1.61				
Mom 10	11.93	7.25	1.81				

资料来源：《Financial Intermediaries and the Cross-Section of Asset Returns》，Tobias Adrian, Erko Etula, 【2013】

可以看到，杠杆因子模型、5 因子模型下的预测超额收益与真实数据相比偏差都很小。除了资产 S1B1 有异常值之外，其他的偏差几乎都在 $\pm 1\%$ 之内。说明杠杆单因子和 5 因子模型的截面回归模型都可以较为准确地预测资产回报。

2.7 LMP 模型的构建

LMP 为杠杆因子模拟投资组合

我们把非中介金融机构的杠杆因子加入到超额回报中去，回归模型如下

$$Levshock_t = \alpha + [weights]'[BL, BM, BH, SL, SM, SH, Mom]_t + \varepsilon_t$$


BL, BM, BH, SL, SM, SH 分别为规模 (BIG, SMALL) 和市值净值 (LOW, MEDIUM, HIGH) 在无风险利率下的超额收益，MOM 为动量因子。

LMP 模型

$$LMP_t = [normweights]'[BL, BM, BH, SL, SM, SH, Mom]_t$$

这里计算 normweights 的方法是：使用第一步回归得到各因子对应的 weights，然后对每个权重通过加权处理使 $\text{Sum}(\text{normweights})=1$ ，得到对应得到 LMP 模型中 Normweights。

图 12 不同因子的均值偏差



资料来源：《Financial Intermediaries and the Cross-Section of Asset Returns》，Tobias Adrian, Erkki Etula, 【2013】

上图显示，用各类因子组合模拟得到的财务杠杆组合，在 1930 年-2009 年的时间中的 sharp 比率显著高于单独使用 fama 三因子或 mom 动量因子，且已较为接近使用后 4 个指标排列组合下的理论最优 sharp 值 (P)。

结论

在本文中，我们使用金融中介商的杠杆作为一类随机贴现因子。通过验证发现，金融机构杠杆对解释资产组合收益表现具有高度参考价值。金融中介商的杠杆也可以帮助投资者把握投资机会以及提示投资者资金流紧张等风险。

在本文的实证方面，从预测资产收益角度，单一的杠杆因子模型毫不逊色于 FAMA3 因子模型。杠杆因子还能较为准确的解释不同久期债券组合的收益差别，这是普通的基准模型(CAPM,FAMA)所不能做到的。

信息披露

分析师声明

高道德、吴先兴、丁鲁明、郑雅斌、朱剑涛、冯佳睿、杨勇、张欣慰：金融工程

以上分析师皆具有中国证券业协会授予的证券投资咨询执业资格，以勤勉的职业态度，独立、客观地出具本报告。本报告所采用的数据和信息均来自市场公开信息，本人不保证该等信息的准确性或完整性。分析逻辑基于作者的职业理解，清晰准确地反映了作者的研究观点，结论不受任何第三方的授意或影响，特此声明。

法律声明

本报告仅供海通证券股份有限公司（以下简称“本公司”）的客户使用。本公司不会因接收人收到本报告而视其为客户。在任何情况下，本报告中的信息或所表述的意见并不构成对任何人的投资建议。在任何情况下，本公司不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任。

本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的的价格、价值及投资收入可能会波动。在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。

市场有风险，投资需谨慎。本报告所载的信息、材料及结论只提供特定客户作参考，不构成投资建议，也没有考虑到个别客户特殊的投资目标、财务状况或需要。客户应考虑本报告中的任何意见或建议是否符合其特定状况。在法律许可的情况下，海通证券及其所属关联机构可能会持有报告中提到的公司所发行的证券并进行交易，还可能为这些公司提供投资银行服务或其他服务。

本报告仅向特定客户传送，未经海通证券研究所书面授权，本研究报告的任何部分均不得以任何方式制作任何形式的拷贝、复印件或复制品，或再次分发给任何其他人，或以任何侵犯本公司版权的其他方式使用。所有本报告中使用的商标、服务标记及标记均为本公司的商标、服务标记及标记。如欲引用或转载本文内容，务必联络海通证券研究所并获得许可，并需注明出处为海通证券研究所，且不得对本文进行有悖原意的引用和删改。

根据中国证监会核发的经营证券业务许可，海通证券股份有限公司的经营经营范围包括证券投资咨询业务。

海通证券股份有限公司研究所

路 颖 所长 (021) 23219403 luying@htsec.com 高道德 副所长 (021) 63411586 gaodd@htsec.com 姜 超 副所长 (021) 23212042 Jc9001@htsec.com

江孔亮 所长助理 (021) 23219422 kljiang@htsec.com

宏观经济研究团队
姜 超(021)23212042 jc9001@htsec.com
陈 勇(021)23219800 cy8296@htsec.com
曹 阳(021)23219981 cy8666@htsec.com
高 远(021)23219669 gaoy@htsec.com
周 霞(021)23219807 zx6701@htsec.com
联系人
顾潇啸(021)23219394 gxx8737@htsec.com

固定收益研究团队
姜 超(021)23212042 jc9001@htsec.com
李 宁(021)23219431 lin@htsec.com

金融工程研究团队
吴先兴(021)23219449
丁鲁明(021)23219068
郑雅斌(021)23219395
冯佳睿(021)23219732
朱剑涛(021)23219745
杨 勇(021)23219945
张欣慰(021)23219370
联系人
杜 灵(021)23219760 dg9378@htsec.com
纪锡颀(021)23219948 jxl8404@htsec.com

wuxx@htsec.com
dinglm@htsec.com
zhengyb@htsec.com
fengjr@htsec.com
zhujt@htsec.com
yy8314@htsec.com
zxw6607@htsec.com

金融产品研究团队
单开佳(021)23219448 shankj@htsec.com
倪韵婷(021)23219419 niyt@htsec.com
罗 震(021)23219326 luozh@htsec.com
唐洋运(021)23219004 tangyy@htsec.com
孙志远(021)23219443 szy7856@htsec.com
陈 亮(021)23219914 cl7884@htsec.com
陈 瑶(021)23219645 chenyao@htsec.com
伍彦妮(021)23219774 wyn6254@htsec.com
曾逸名(021)23219773 zym6586@htsec.com
桑柳玉(021)23219686 sly6635@htsec.com
陈韵骅(021)23219444 cyc6613@htsec.com
田本俊(021)23212001 tjb936@htsec.com
联系人
冯 力(021)23219819 fl9584@htsec.com

策略研究团队
荀玉根(021)23219658 xyg6052@htsec.com
陈瑞明(021)23219197 chenrm@htsec.com
汤 慧(021)23219733 tangh@htsec.com
王 旭(021)23219396 wx5937@htsec.com
李 珂(021)23219821 lk6604@htsec.com

中小市值团队
邱春城(021)23219413
钮宇鸣(021)23219420
何继红(021)23219674
孔维娜(021)23219223
qiucc@htsec.com
ymniu@htsec.com
hejh@htsec.com
kongwn@htsec.com

政策研究团队
李明亮(021)23219434 lm1@htsec.com
陈久红(021)23219393 chenjiuhong@htsec.com
吴一萍(021)23219387 wuyiping@htsec.com
联系人
朱 蕾(021)23219946 zl8316@htsec.com
周洪荣(021)23219953 zhr8381@htsec.com

批发和零售贸易行业
路 颖(021)23219403 luying@htsec.com
汪立亭(021)23219399 wanglt@htsec.com
潘 鹤(021)23219423 panh@htsec.com
李宏科(021)23219671 lhk6064@htsec.com

互联网及传媒行业
刘佳宁(0755)82764281 ljn8634@htsec.com
白 洋(021)23219646 baiyang@htsec.com
薛婷婷(021)23219775 xtt6218@htsec.com

石油化工行业
邓 勇(021)23219404 dengyong@htsec.com
王晓林(021)23219812 wxl6666@htsec.com

机械行业
龙 华(021)23219411 longh@htsec.com
熊哲颖(021)23219407 xzy5559@htsec.com
联系人
黄 威(021)23219963 hw8478@htsec.com

公用事业
陆凤鸣(021)23219415 lufm@htsec.com
汤砚卿(021)23219768 tyq6066@htsec.com

非银行金融行业
丁文韬(021)23219944 dwt8223@htsec.com
李 欣(010)58067936 lx8867@htsec.com
联系人
吴绪越(021)23219947 wxy8318@htsec.com

钢铁行业
刘彦奇(021)23219391 liuyq@htsec.com

建筑工程行业
赵 健(021)23219472 zhaoj@htsec.com
张显宁(021)23219813 zx6700@htsec.com

医药行业
周 锐(0755)82780398 zr9459@htsec.com
余文心(0755)82780398 ywx9460@htsec.com
刘 宇(021)23219608 liuy4986@htsec.com
江 琦(021)23219685 jq9458@htsec.com
王 威(0755)82780398 ww9461@htsec.com
郑 琴(021)23219808 zq6670@htsec.com
刘 杰(021)23219269 liuj5068@htsec.com

农林牧渔行业
丁 频(021)23219405 dingpin@htsec.com
夏 木(021)23219748 xiam@htsec.com

银行业
刘 瑞(021)23219635 lr6185@htsec.com
林媛媛(0755)23962186 lyy9184@htsec.com

房地产业
涂力磊(021)23219747 tl5535@htsec.com
谢 盐(021)23219436 xiy@htsec.com
贾亚童(021)23219421 jiayt@htsec.com

基础化工行业 曹小飞(021)23219267 张瑞(021)23219634 联系人 朱睿(021)23219957	caoxf@htsec.com zr6056@htsec.com zr8353@htsec.com	有色金属行业 钟奇(021)23219962 施毅(021)23219480 刘博(021)23219401	zq8487@htsec.com sy8486@htsec.com liub5226@htsec.com	计算机行业 陈美凤(021)23219409 蒋科(021)23219474 联系人 王秀钢(010)58067934 安永平(021)23219950	chenmf@htsec.com jiangk@htsec.com wxg8866@htsec.com ayp8320@htsec.com
社会服务业 林周勇(021)23219389	lzy6050@htsec.com	交通运输行业 黄金香(021)23212081 虞楠(021)23219382 姜明(021)23212111	hjx9114@htsec.com yun@htsec.com jm9176@htsec.com	家电行业 陈子仪(021)23219244 联系人 宋伟(021)23219949	chenzy@htsec.com sw8317@htsec.com
通信行业 徐力(010)58067940 侯文哲(021)23219815	xl9312@htsec.com hyz6671@htsec.com	汽车行业 陈鹏辉(021)23219814	cph6819@htsec.com	电力设备及新能源行业 张浩(021)23219383 牛品(021)23219390 陈日华(021)23219716 房青(021)23219692 徐柏乔(021)23219171	zhangh@htsec.com np6307@htsec.com crh9585@htsec.com fangq@htsec.com x bq6583@htsec.com
食品饮料行业 闻宏伟(010)58067941 马浩博(021)23219822	whw9587@htsec.com mhb6614@htsec.com	造纸轻工行业 徐琳(021)23219767	xl6048@htsec.com	煤炭行业 朱洪波(021)23219438	zhb6065@htsec.com
建筑建材行业 周煜(021)23219972	zy9445@htsec.com				

海通证券股份有限公司机构业务部

陈苏勤 总经理
(021)63609993
chensq@htsec.com

贺振华 总经理助理
(021)23219381
hzh@htsec.com

深广地区销售团队
 蔡铁清 (0755)82775962 ctq5979@htsec.com
 刘晶晶 (0755)83255933 liujj4900@htsec.com
 李丽娟 (0755)83253022 gulj@htsec.com
 高艳娟 (0755)83254133 gyj6435@htsec.com
 伏财勇 (0755)23607963 fcy7498@htsec.com
 邓欣 (0755)23607962 dx7453@htsec.com

上海地区销售团队
 贺振华 (021)23219381 hzh@htsec.com
 姜洋 (021)23219442 jy7911@htsec.com
 高湊 (021)23219386 gaoqin@htsec.com
 李唯佳 (021)23219384 jiwj@htsec.com
 胡雪梅 (021)23219385 huxm@htsec.com
 黄毓 (021)23219410 huangyu@htsec.com
 朱健 (021)23219592 zhuj@htsec.com
 黄慧 (021)23212071 hh9071@htsec.com
 卢倩 (021)23219373 lq7843@htsec.com
 孙明 (021)23219990 sm8476@htsec.com
 孟德伟 (021)23219989 mdw8578@htsec.com

北京地区销售团队
 赵春 (010)58067977 zhc@htsec.com
 郭文君 (010)58067996 gwj8014@htsec.com
 隋巍 (010)58067944 sw7437@htsec.com
 江虹 (010)58067988 jh8662@htsec.com
 杨帅 (010)58067929 ys8979@htsec.com
 张楠 (010)58067935 zn7461@htsec.com
 许诺 (010)58067931 xn9554@htsec.com

海通证券股份有限公司研究所
 地址：上海市黄浦区广东路 689 号海通证券大厦 13 楼
 电话：(021)23219000
 传真：(021)23219392
 网址：www.htsec.com