

2019-11-1

金融工程 | 专题报告

多因子选股

如何以“集成学习”的眼光看因子选股——多因子统计学习模型（三）

报告要点

■ 集成学习的概念

集成学习 (Ensemble Learning) 是把多个机器学习模型合并到一起的一套系统性方法, 使多个“弱学习器”通过一定的方式“集成”为一个误差更小的“强学习器”。经典的集成学习方法有 Bagging、Boosting 和 Stacking 等。

■ IC: 相关系数 v.s 训练模型

传统因子选股最重要的概念是 IC, 从相关系数的角度来看是个股的当期期初因子值和个股的当期区间涨跌幅的相关系数。

如果要从机器学习模型的角度来计算 IC, 则需要含一个待定参数的函数 g , 将个股的当期期初因子值和个股的当期区间涨跌幅作为训练数据, 训练这个模型, 最小化损失函数后计算出的参数正好等于 IC。

IC 计算可以看作是带数据预处理 (取 zscore) 的单变量一次函数模型; Rank IC 可以看作是带两步数据预处理 (取排序、取 zscore) 的单变量一次函数模型

■ 多因子加权合成

从 IC 的角度来看, 计算因子历史 IC 或 Rank IC 之后, 常用的方式是将当期因子值按照该因子的历史 IC 或历史 Rank IC 平均值进行加权。

从集成学习的角度来看, 因子间 IC、IC_IR 加权合成或因子间等权合成的方式都可以对应为一个两级 stacking 等权集成模型, 第一级为各个日期截面上的一次函数模型的等权集成, 第二级对应各个因子间的等权集成或加权集成。

■ 改进后年化超额收益 26.73%, 提升 6.37%, IR 达到 3 以上

替换集成学习中的弱学习器, 发现 2011 年以前, 线性弱学习器好于所有非线性弱学习器; 2011 年至 2017 年部分非线性模型好于线性, 部分与线性不相上下; 2017 年以来, 非线性模型普遍好于线性模型, 因子收益越来越趋于非线性化。

最终“多级集成”模型相对中证 500 年化超额收益 26.73%、IR3.25, 而标准流程下的年化超额收益 20.37%、IR2.47, 年化收益提升约 6.37%, IR 达到 3 以上。截至 10.30 日, 今年累积超额收益 13.52%, 较标准流程提高 10.89%。

分析师 覃川桃

☎ (8621) 61118766

✉ qjinct@cjsc.com.cn

执业证书编号: S0490513030001

分析师 邓越

☎ (8627) 65799830

✉ dengyue1@cjsc.com.cn

执业证书编号: S0490517070010

分析师 秦瑶

☎ (8627) 65799830

✉ qinyao@cjsc.com.cn

执业证书编号: S0490513080002

分析师 刘胜利

☎ (8621) 61188705

✉ liusl4@cjsc.com.cn

执业证书编号: S0490517070006

分析师 陈洁敏

☎ (8621) 61188706

✉ chenjm5@cjsc.com.cn

执业证书编号: S0490518120005

分析师 刘懿

☎ (8621) 68751259

✉ liuyi4@cjsc.com.cn

执业证书编号: S0490518120004

联系人 郑起

☎ (8621) 61188706

✉ zhengqi2@cjsc.com.cn

联系人 鲍丰华

☎ (8621) 61188705

✉ baofh@cjsc.com.cn

相关研究

《量化角度看可转债(一):择时配置》2019-10-22

《高频因子(六): 特异视角下的波动率因子》
2019-10-9

《什么行业应该做 beta? 什么行业应该做 alpha?》2019-9-26

风险提示: 1. 回溯测试不保证未来收益;
2. 模拟计算不代表真实收益。

请阅读最后评级说明和重要声明

1 / 24

目录

什么是集成学习	4
传统因子选股也是集成学习	8
从机器学习的角度看 IC	8
因子间 IC 加权是如何对应的	11
集成学习：超越传统因子选股	13
比较基准	13
改善一处细节	16
选择其他弱学习器	16
多级集成	19
总结	23

图表目录


图 1：集成学习模型示意图	4
图 2：模型的“偏差”与“方差”	4
图 3：集成多个高偏差的弱学习器以降低偏差	5
图 4：弱学习器之间差异性不足依旧会导致高偏差	5
图 5：Bagging 方法示意图	6
图 6：Boosting 方法示意图	7
图 7：Stacking 方法案例	7
图 8：机器学习的通式流程示意图	8
图 9：训练一个特殊的单变量一次函数等价于计算 IC	8
图 10：IC 计算可以看作是带数据预处理（取 zscore）的单变量一次函数模型	9
图 11：Rank IC 可以看作是带两步数据预处理（取排序、取 zscore）的单变量一次函数模型	10
图 12：规模因子取排序和 zscore 变换后的函数图像	10
图 13：IC 加权合成中的第一级集成	11
图 14：IC 加权合成中的两级集成	12
图 15：多因子选股流程	13
图 16：常用风格因子 IC 累加值（2005.1 至 2019.10）	14
图 17：常用风格因子 IC 平均值（2005.1 至 2019.10）	14
图 18：排序前 5% 组合单位净值曲线（2007.1.5 至 2019.10.30）	15
图 19：排序前 5% 组合的股票数量（2007.1 至 2019.10，单位：只）	15
图 20：以高阶多项式作为弱分类器	17
图 21：以分段线性函数作为弱分类器	17
图 22：以按市值等分 m 段的 n 阶多项式作为弱分类器	17
图 23：替换弱学习器后相对中证 500 年化超额收益（2007.1.5 至 2019.10.30）	17
图 24：替换弱学习器后的单位净值与 poly1 时的比价（2007.1.5 至 2019.10.30）	18
图 25：采用 poly1_sizeSeg5 作为弱学习器的改进效果（单位净值曲线）	19

图 26: 滚动选择弱学习器	20
图 27: 滚动选择弱学习器的单位净值与中证 500 比价 (2007.1.5 至 2019.10.30)	20
图 28: 多级集成	21
图 29: 多级集成的改进效果 (单位净值曲线, 2007.1.5 至 2019.10.30)	22
图 30: 多级集成的改进效果 (单位净值曲线, 2018.12.28 至 2019.10.30)	23
表 1: 常用的风格因子	14
表 2: 基准组合的收益率	15
表 3: 细节改进之后组合收益率能实现轻微提升 (2007.1.5 至 2019.10.30)	16
表 4: 采用 poly1_sizeSeg5 作为弱学习器的改进效果 (分年收益率)	18
表 5: 采用多级集成的改进效果 (分年收益率)	22

什么是集成学习

集成学习 (Ensemble Learning) 是把多个机器学习模型合并到一起的一套系统性方法, 使多个“弱学习器”通过一定的方式“集成”为一个误差更小的“强学习器”(图 1)。


图 1: 集成学习模型示意图



资料来源:《机器学习》周志华著, 长江证券研究所

机器学习模型总是在降低“偏差 (bias)”和降低“方差 (variance)”之间做权衡 (图 2): “低偏差、低方差”的模型在高噪音的数据集中几乎无法找到, “高偏差、高方差”的模型可被直接淘汰, “低偏差、高方差”的模型单次预测的不确定性较高, “高偏差、低方差”的模型准确度较低。集成学习中的弱学习器通常选取的是较简单的模型, 具有“高偏差、低方差”的特点。


图 2: 模型的“偏差”与“方差”



资料来源: 长江证券研究所

集成学习方法将多个高偏差的弱学习器按照一定方法合成为一个强学习器，单个弱学习器在其各自的能力范围内捕捉到数据集的不同层面的特征，然后再相互组合来接近数据集的“真实特征”，从而达到降低偏差的目的。图 3 是这一过程的示意图，多个弱学习器的平均值可能“正中靶心”。


图 3：集成多个高偏差的弱学习器以降低偏差



资料来源：长江证券研究所

可见，集成学习的两个关键点是弱学习器的选择和合成方法的选择。弱学习要足够简单，同时弱学习器之间的差异性足够大以达到降低偏差的目的（图 4）。合成方法通常选用较简单的方式，如简单平均、加权平均、广义的线性回归（OLS、Logit、Ridge）等。

图 4：弱学习器之间差异性不足依旧会导致高偏差



资料来源：长江证券研究所


比较常见的集成学习方法有 Bagging、Boosting 和 Stacking，下面我们着重介绍这 3 类模型是如何保证弱学习器差异性的。

Bagging (Bootstrap aggregating) 的多个弱学习器采用的是同一种简单模型（所谓“同质集成”），为了保证弱学习器的差异性，Bagging 通过对原始数据集进行“有放回抽样”（bootstrap sampling），用抽出的有差异的抽样数据集分别对各个弱学习器进行训练（图 5）。这样，尽管弱学习器是相同模型，但经训练后模型中的参数的数值是不同的，从而保证了弱学习器间的差异性。除了可以对数据集抽样外，也可以对特征集抽样，使得用于训练各个弱学习器的数据和用到的特征各不相同，以增大差异性。

Bagging 中各个弱学习器的集成方法一般为简单平均。

随机森林模型就是 Bagging 中弱学习器为决策树时的特例。

图 5：Bagging 方法示意图




资料来源：长江证券研究所

Boosting（提升法）的多个弱学习器同样采用相同简单模型（“同质集成”），Boosting 与 Bagging 不同之处在于 Boosting 是串行集成，上一个弱学习器的训练误差反馈到 Boosting 模型中，模型按照某种方式增大数据集中误差较大的样本的权重，用于下一个弱学习器的训练，实现对弱学习器的逐步“提升（boosting）”。可见，Boosting 保证弱学习器间差异性的方式是不断迭代更新数据的权重，并提升下一级弱学习器对误差较大的样本的拟合程度。

Boosting 中各个弱学习器的集成方法一般为依据各弱学习器的准确度计算的加权平均。

Boosting 的代表算法有 Adaboost、GBDT 和 XGBoost 等。

图 6: Boosting 方法示意图



资料来源：长江证券研究所

Stacking（堆叠法）的弱学习器是不同类型的模型（“异质集成”），不同类型的模型进行一级或多级逐层堆叠，然后将各级输出结果通过一个简单的模型进行合成。Stacking 的弱学习器间的差异性来自于它们自身的差异。

图 7 是一个在 KDD-CUP 竞赛中胜出的 stacking 模型案例，该 Stacking 模型一共有 4 层，第 0 层有 64 种各式各样的模型，这些模型的输出又作为后面 3 层模型的输入，依次向下堆叠，最后一层是一个简单的 Logistic 回归合并输出。

图 7: Stacking 方法案例



资料来源：《Multi-Stage Ensemble and Feature Engineering for MOOC Dropout Prediction》，长江证券研究所

传统因子选股也是集成学习

从机器学习的角度看 IC


传统因子选股最重要的概念就是 IC (Information Coefficient, 信息系数), 即个股的当期期初因子值和个股的当期区间涨跌幅的相关系数:

$$IC = corr(x, r) = \frac{Cov(x, r)}{\sigma_x \cdot \sigma_r}$$

这是从相关系数的角度来计算的 IC, 下面我们说明如何以机器学习的角度来看待 IC。

图 8 是机器学习的通式流程示意图。假设有训练数据 (x_i, y_i) , 机器学习模型的训练过程就是通过已知的特征 x_i 和标签 y_i 确定机器学习中的参数 θ 的过程: 将输入的特征 x_i 经过某种函数变换后输出, 并计算输出结果与实际的 y_i 之间的损失函数 (Loss), 通过梯度下降、随机梯度下降 (SGD)、批量梯度下降 (BGD) 等最优化方法, 找到使训练数据集上损失函数的平均值最小的参数 θ 。


图 8: 机器学习的通式流程示意图



资料来源: 长江证券研究所

如果要从机器学习模型的角度来计算 IC, 则需要找到内含单个待定参数的函数 g , 将个股的当期期初因子值和个股的当期区间涨跌幅作为训练数据 (x, r) 训练这个模型, 最小化损失函数后计算出的参数正好等于 IC。

图 9: 训练一个特殊的单变量一次函数等价于计算 IC



资料来源: 长江证券研究所

请阅读最后评级说明和重要声明

8 / 24

这个函数用一个特殊的单变量一次函数就可以做到（图 9），在计算机中编写好函数 g ，调用任意机器学习算法包，选择损失函数为“平方损失”函数，可以验证通过最小化损失函数计算的参数 θ 的数值与通过相关系数公式计算 IC 数值完全一致。

当损失函数为平方损失、函数 g 为线性函数时，就是普通的线性函数的“最小二乘法”（OLS）。“最小二乘法”的称呼取自日语，“二乘”即“平方”，“最小二乘”在机器学习的语言中就是使平方损失函数最小。在这种简单情形下是有解析解的，不必通过梯度下降迭代寻优，因此我们可以证明上述流程的参数确实与 IC 完全相等，参数 θ 通常在单变量线性回归中记作 β ：


$$\frac{\mathbf{r} - \bar{r}}{\sigma_r} = \beta \frac{\mathbf{x} - \bar{x}}{\sigma_x}$$

由线性回归的解析解公式可以计算 β ：

$$\begin{aligned} \beta &= \left[\left(\frac{\mathbf{x} - \bar{x}}{\sigma_x} \right)^T \left(\frac{\mathbf{x} - \bar{x}}{\sigma_x} \right) \right]^{-1} \left(\frac{\mathbf{x} - \bar{x}}{\sigma_x} \right)^T \left(\frac{\mathbf{r} - \bar{r}}{\sigma_r} \right) \\ &= \left[\frac{n \cdot \left(\frac{1}{n} (\mathbf{x} - \bar{x})^T (\mathbf{x} - \bar{x}) \right)}{\sigma_x^2} \right]^{-1} \left(\frac{\mathbf{x} - \bar{x}}{\sigma_x} \right)^T \left(\frac{\mathbf{r} - \bar{r}}{\sigma_r} \right) \\ &= \left[\frac{n \cdot \sigma_x^2}{\sigma_x^2} \right]^{-1} \left(\frac{\mathbf{x} - \bar{x}}{\sigma_x} \right)^T \left(\frac{\mathbf{r} - \bar{r}}{\sigma_r} \right) \\ &= \frac{\frac{1}{n} (\mathbf{x} - \bar{x})^T (\mathbf{r} - \bar{r})}{\sigma_x \cdot \sigma_r} = \frac{Cov(\mathbf{x}, \mathbf{r})}{\sigma_x \cdot \sigma_r} = IC \end{aligned}$$

可以看出两种计算方式等价，也就是说 IC 计算可以看作是一个带数据预处理（取 zscore）的单变量一次函数模型（图 10）。

图 10：IC 计算可以看作是带数据预处理（取 zscore）的单变量一次函数模型



资料来源：长江证券研究所

另一种常用的 IC 是 Rank IC，通过个股的当期期初因子值和个股的当期区间涨跌幅的秩相关系数计算，其中计算相关系数的公式相同，但使用的是数值的大小排名而非数值本身：

$$Rank\ IC = corr(\text{order}(\mathbf{x}), \text{order}(\mathbf{r})) = \frac{Cov(\text{order}(\mathbf{x}), \text{order}(\mathbf{r}))}{\sigma_{\text{order}(\mathbf{x})} \cdot \sigma_{\text{order}(\mathbf{r})}}$$


同样，Rank IC 也可对应线性回归的系数：

$$\frac{\text{order}(\mathbf{r}) - \overline{\text{order}(\mathbf{r})}}{\sigma_{\text{order}(\mathbf{r})}} = \beta \frac{\text{order}(\mathbf{x}) - \overline{\text{order}(\mathbf{x})}}{\sigma_{\text{order}(\mathbf{x})}}$$

由于 IC 和 Rank IC 在在计算相关系数的环节公式完全一致，所以上述推导过程仍然成立。

因此 Rank IC 对应的是带两步数据预处理（取排序、取 zscore）的单变量一次函数模型（图 11）。


图 11：Rank IC 可以看作是带两步数据预处理（取排序、取 zscore）的单变量一次函数模型



资料来源：长江证券研究所

图 12 是某日期截面上规模因子经过“排序+zscore”变换后的函数图像，从结果来看，这类似于一个 sigmoid 函数变换，在因子值取值较大时有一定“饱和作用”，本质上这一过程是一种非线性变换。

图 12：规模因子取排序和 zscore 变换后的函数图像



资料来源：长江证券研究所

另外，由于数据经过 zscore 预处理，一次函数模型中的常数项不是必须的（可有可无）。

因子间 IC 加权是如何对应的

计算了因子历史 IC 或 Rank IC 之后，常用的方式是将当期因子值按照该因子的历史 IC 或历史 Rank IC 平均值进行加权。

T 月初，n 个因子，按照它们过去 12 个月的平均 IC（或 Rank IC）合成的 alpha 得分为：

$$\alpha = \frac{1}{12} \sum_{i=1}^{12} IC_1^{T-i} \cdot x_1^{T_0} + \frac{1}{12} \sum_{i=1}^{12} IC_2^{T-i} \cdot x_2^{T_0} + \dots + \frac{1}{12} \sum_{i=1}^{12} IC_n^{T-i} \cdot x_n^{T_0}$$

其中 x_i 是第 i 个因子， IC_i 是这个因子对应的过去 12 个月的 IC 或 Rank IC。

上面是从 IC 的角度来看，从模型的角度来看，alpha 得分还完全等价地写为：

$$\alpha = \left\{ \frac{g(x_1^T, \beta_1^{T-12}) + \dots + g(x_1^T, \beta_1^{T-1})}{12} \right\}_{\text{因子}_1} + \left\{ \frac{g(x_2^T, \beta_2^{T-12}) + \dots + g(x_2^T, \beta_2^{T-1})}{12} \right\}_{\text{因子}_2} + \dots + \left\{ \frac{g(x_n^T, \beta_n^{T-12}) + \dots + g(x_n^T, \beta_n^{T-1})}{12} \right\}_{\text{因子}_n}$$

其中函数 $g(x, \beta)$ 是带数据预处理（zscore 或 order+zscore）的一次函数，其参数 β 就是 IC 或 Rank IC。

如果因子间加权方式是 IC_IR 加权，按照机器学习模型的理解方式，alpha 得分等价于：


$$\alpha = \frac{1}{\sigma_{IC_1}} \cdot \left\{ \frac{g(x_1^T, \beta_1^{T-12}) + \dots + g(x_1^T, \beta_1^{T-1})}{12} \right\}_{\text{因子}_1} + \frac{1}{\sigma_{IC_2}} \cdot \left\{ \frac{g(x_2^T, \beta_2^{T-12}) + \dots + g(x_2^T, \beta_2^{T-1})}{12} \right\}_{\text{因子}_2} + \dots + \frac{1}{\sigma_{IC_n}} \cdot \left\{ \frac{g(x_n^T, \beta_n^{T-12}) + \dots + g(x_n^T, \beta_n^{T-1})}{12} \right\}_{\text{因子}_n}$$

是模型间按波动率倒数加权。

因子间还有一种常用的加权方式是等权合成，对应的函数 g 就是 β 恒为 1 时的情形。

可见，因子间 IC、IC_IR 加权合成或因子间等权合成的方式都可以对应为一个**两级 stacking 等权集成模型**，第一级为各个日期截面上的一次函数模型的等权集成，第二级对应各个因子间的等权集成或加权集成：如果因子间采用 IC 加权，则对应等权集成；如果因子间采用 IC_IR 加权，则对应第二级为模型间加权集成；如果因子间采用等权合成，则对应线性函数为 $g(x)=x$ 。

图 13：IC 加权合成中的第一级集成



资料来源：长江证券研究所


请阅读最后评级说明和重要声明

11 / 24

第一级集成的示意图见图 13，相当于使用单个因子面板数据的子样本（单个时间截面）分别训练多个模型，然后进行等权重集成。其形似上类似于一个 Bagging，弱学习器是相同的函数，通过对数据抽样（此处为按日期截面抽样，非随机抽样）来获得弱学习器之间的差异性。

经过第一级集成后，再将各因子集成后的输出（图 14 中 a_i ）作为输入，进行第二级集成。

图 14：IC 加权合成中的两级集成



资料来源：长江证券研究所

从图 14 中可以看出，传统多因子 IC/IC_IR 加权合成对应了一个两级 Stacking 集成学习流程，输入数据集是多个因子（即多特征）的面板数据，对应的每个弱学习器只用到一个因子（子特征）、一个日期截面（子样本），对应了集成学习中“数据抽样、特征抽样”的概念，保证训练出的弱学习器之间有足够差异性。


从这个角度看，传统的多因子加权模型其实已经相当先进。虽然还没有随机抽样的概念，但已经包含了数据抽样、特征抽样的过程。从参数的数量上来说也已经十分庞大，每个弱学习器有 1 个参数，T 个时间截面，n 个因子，共有 $T \times n$ 个参数。

集成学习：超越传统因子选股

比较基准

传统多因子模型既然可以被看作是一个集成学习模型，沿着集成学习的概念就可以对其进行改进。为了比较改进的效果，我们首先计算传统的多因子选股流程下的收益率。

图 15：多因子选股流程



资料来源：长江证券研究所

多因子选股的一般流程大致分为“筛选选股因子”、“多因子模型”和“构成股票投资组合”三个部分（图 15）：

- “筛选选股因子”从海量的信息中按照一定指标（如信息系数 IC、分组多空收益率等）筛选出可能蕴含有 alpha 信息的选股因子；
- “多因子模型”将筛选出的多个选股因子按照一定方式（分组打分、等权、IC 加权、IC_IR 加权、多元线性回归等）合成为单个 alpha 得分；
- “构成股票投资组合”依据个股的 alpha 得分按照一定方法（分组等权、风险收益优化、分行业选股等）筛选股票、确定个股权重，从而构成最终的投资组合。

本篇研究报告重点关注第二个步骤“多因子模型”在集成学习框架下的拓展，选股因子固定为常用的风格因子，构成投资组合的方式也采用较简单的排序分组等权组合的方式。使用的常用的风格因子的合成方式见表 1。


表 1: 常用的风格因子

大类因子	子类因子	合成比例
规模	流通市值的自然对数	1
成长	营业收入同比增速	1/3
	归母净利润同比增速	1/3
	ROE同比变化	1/3
估值	PE	4/10
	PB	4/10
	PCF	1/10
	PS	1/10
财务杠杆	资产负债率	3/5
	长期负债占总资产比例	1/5
	长期负债占总市值比例	1/5
beta	与上证指数beta (21交易日)	1/2
	与上证指数beta (252交易日)	1/2
波动率	21交易日波动率	1/2
	252交易日波动率	1/2
流动性	日均换手率对数 (21交易日)	1/3
	日均换手率对数 (63交易日)	1/3
	日均换手率对数 (252交易日)	1/3
动量	区间累积涨跌幅 (过去12月至过去2月)	1/2
	区间日均涨跌幅 (过去12月至过去2月)	1/2
反转	区间累积涨跌幅 (过去1月)	1/2
	区间日均涨跌幅 (过去1月)	1/2

资料来源: Wind, 长江证券研究所


因子使用前都经过过去极值、标准化、与行业和市值正交等处理, 各因子的 IC 累加值和平均 IC 见图 16 和图 17。

图 16: 常用风格因子 IC 累加值 (2005.1 至 2019.10)



资料来源: Wind, 长江证券研究所

图 17: 常用风格因子 IC 平均值 (2005.1 至 2019.10)



资料来源: Wind, 长江证券研究所

选股池为所有 A 股上市公司，并剔除 ST、停牌股票，剔除过去一年平均流通市值位于后 20% 股票，剔除过去一年平均成交额位于后 20% 的股票，暂时剔除科创板股票。在选股池中，每月初各因子按照过去 12 月 Rank IC 平均值加权，合成 alpha 得分，按照 alpha 得分选取前 5% 和后 5% 的股票，构成等权重组合，计算收益率。月度调仓，买卖合计 5% 的交易成本。

按照上述一般流程构造的基准组合的收益率见表 2。Alpha 得分排序前 5% 的组合相对后 5% 组合的年化超额收益为 45.61%，信息系数 3.53；前 5% 相对中证 500 超额收益 20.52%，信息系数 2.48。分年来看，排序前/后 5% 的多空收益近年来并无减弱迹象，但前 5% 相对中证 500 指数 2017 年以来不太理想。图 16 是前 5% 组合的单位净值曲线，图 17 是该组合每月的股票数量，2007 年时大约有 50 只左右，目前大约有 160 只左右。

表 2：基准组合的收益率

名称	前5%	后5%	中证500	前5% - 后5%	前5% - 中证500
年化收益率	29.03%	-16.54%	8.66%	45.57%	20.37%
信息比率	--	--	--	3.54	2.47
2007年	205.13%	92.31%	179.45%	112.82%	25.68%
2008年	-49.22%	-69.92%	-60.80%	20.70%	11.58%
2009年	193.42%	92.23%	131.27%	101.19%	62.15%
2010年	31.40%	-6.11%	10.07%	37.51%	21.34%
2011年	-24.48%	-49.72%	-33.83%	25.24%	9.35%
2012年	10.24%	-21.38%	0.28%	31.62%	9.96%
2013年	48.93%	-11.67%	16.89%	60.60%	32.04%
2014年	66.47%	32.55%	39.01%	33.92%	27.46%
2015年	119.73%	17.49%	43.12%	102.24%	76.62%
2016年	5.76%	-27.98%	-17.78%	33.74%	23.54%
2017年	-9.47%	-37.62%	-0.20%	28.15%	-9.26%
2018年	-25.61%	-50.63%	-33.32%	25.02%	7.71%
2019年（至10.30）	21.34%	-15.17%	18.71%	36.51%	2.63%


资料来源：Wind，长江证券研究所

图 18：排序前 5% 组合单位净值曲线（2007.1.5 至 2019.10.30）



资料来源：Wind，长江证券研究所

图 19：排序前 5% 组合的股票数量（2007.1 至 2019.10，单位：只）



资料来源：Wind，长江证券研究所

请阅读最后评级说明和重要声明

15 / 24

改善一处细节

上面我们说到，用取排序和取 zscore 数据预处理后的一次函数作为弱学习器的集成学习等价于 Rank IC 加权的因子合成，即通过训练集得到的参数是完全一致的。不过二者有一处细节上的差异，从机器学习的角度来说，在输入新一期因子数据（“测试集”）进行计算 alpha 得分时，新数据的预处理流程要与训练模型时的数据处理方式完全相同，即新一期因子数据经过了取排序和取 zscore 后进行合成；但 Rank IC 加权时通常不会对新因子数据取排序，即：

$$\alpha^{\text{Rank IC 加权}} = \overline{\text{Rank IC}_1} \cdot \text{zscore}(x_1) + \dots + \overline{\text{Rank IC}_n} \cdot \text{zscore}(x_n)$$

v.s.

$$\alpha^{\text{ensemble}} = \overline{\text{Rank IC}_1} \cdot \text{zscore}(\text{order}(x_1)) + \dots + \overline{\text{Rank IC}_n} \cdot \text{zscore}(\text{order}(x_n))$$

按照机器学习的观点（新数据的预处理流程要与训练模型时的数据处理方式完全相同）在细节上改进后，组合收益率能实现轻微提升（表 3）。

表 3：细节改进之后组合收益率能实现轻微提升（2007.1.5 至 2019.10.30）

	前5% (改进)	前5% (标准)	前5% - 后5% (改进)	前5% - 后5% (标准)	差异	前5% - 中证500 (改进)	前5% - 中证500 (标准)	差异
年化收益率	29.36%	29.03%	48.16%	45.57%	2.59%	20.70%	20.37%	0.33%
信息比率	--	--	4.05	3.54	0.51	2.59	2.47	0.12

资料来源：Wind，长江证券研究所

选择其他弱学习器

我们知道线性模型的表达能力是有限的，有时无法描述因子的一些非线性现象。


比如有些因子在分 10 组测试中收益率表现出“抛物线”形态，中间组别收益高，两头收益低。这种“抛物线”不仅表现为“因子失效”，而且会对线性模型带来更大损失，因为线性模型总是在因子值两端二择其一（“非黑即白”的二元论因子择时），但此时两端同时表现较差，会始终给投资组合带来损失。

再如有些因子的选股能力是与股票市值相关的¹，用线性模型无法对这种特点进行描述。从 IC 的角度来看，通常的做法是在沪深 300、中证 500、中证 1000 等规模指数中分别计算 IC，即 IC 和市值相关；对应到模型角度，就是因子的一次项系数不再是常数，而是市值的函数。

我们将弱学习器由线性模型替换为高阶多项式（图 20）、分段线性函数（图 21）、一次项按市值分段的高阶多项式（图 22）等，测试分组收益率是否能有所提高。前面我们在证明一次函数的系数和 IC 等价性时用了函数的解析解，但解析解并不是必须的，对于替换后的没有解析解的弱学习器，机器学习算法仍然可以用梯度下降算法求解。


¹ 《构造非线性 ROE 因子——多因子统计学习模型（二）》，长江证券研究所，2019.4.26

图 20：以高阶多项式作为弱分类器




资料来源：长江证券研究所

图 21：以分段线性函数作为弱分类器



资料来源：长江证券研究所


图 22：以按市值等分 m 段的 n 阶多项式作为弱分类器



资料来源：长江证券研究所

我们将弱学习器依次替换为 2 阶、3 阶多项式、分 5 段分段线性函数、系数按市值分 5 段或 10 段的 1 阶和 2 阶多项式进行测试，替换后相对中证 500 年化超额收益对比见图 23，其中 poly1 为弱学习器是一次函数时的年化收益。

图 23：替换弱学习器后相对中证 500 年化超额收益（2007.1.5 至 2019.10.30）




资料来源：Wind，长江证券研究所

请阅读最后评级说明和重要声明

17 / 24

图 24 是替换弱学习器后的单位净值与 poly1 时的比价，可以看出因子收益越来越趋于非线性化：2011 年以前，线性弱学习器好于所有非线性弱学习器；2011 年至 2017 年部分非线性模型好于线性，部分与线性不相上下；2017 年以来，非线性模型普遍好于线性模型。

图 24：替换弱学习器后的单位净值与 poly1 时的比价（2007.1.5 至 2019.10.30）



资料来源：Wind，长江证券研究所

我们具体展示年化收益最高的 poly1_sizeSeg5 的分年收益（表 4）和单位净值曲线（图 25）。

表 4：采用 poly1_sizeSeg5 作为弱学习器的改进效果（分年收益率）


	前5% (改进)	前5% (标准)	前5% - 后5% (改进)	前5% - 后5% (标准)	差异	前5% - 中证500 (改进)	前5% - 中证500 (标准)	差异
年化收益率	32.85%	29.03%	47.95%	45.57%	2.38%	24.19%	20.37%	3.82%
信息比率	--	--	3.86	3.54	0.32	3.00	2.47	0.53
2007年	223.03%	205.13%	140.05%	112.82%	27.23%	43.58%	25.68%	17.90%
2008年	-49.17%	-49.22%	21.40%	20.70%	0.70%	11.63%	11.58%	0.05%
2009年	199.07%	193.42%	113.88%	101.19%	12.69%	67.81%	62.15%	5.66%
2010年	35.65%	31.40%	30.62%	37.51%	-6.89%	25.58%	21.34%	4.24%
2011年	-21.14%	-24.48%	21.14%	25.24%	-4.10%	12.69%	9.35%	3.34%
2012年	13.55%	10.24%	33.84%	31.62%	2.22%	13.28%	9.96%	3.32%
2013年	52.52%	48.93%	61.40%	60.60%	0.80%	35.63%	32.04%	3.59%
2014年	63.91%	66.47%	49.44%	33.92%	15.52%	24.90%	27.46%	-2.56%
2015年	129.85%	119.73%	101.58%	102.24%	-0.66%	86.74%	76.62%	10.12%
2016年	6.20%	5.76%	37.60%	33.74%	3.86%	23.98%	23.54%	0.44%
2017年	-5.34%	-9.47%	33.95%	28.15%	5.80%	-5.14%	-9.26%	4.12%
2018年	-20.80%	-25.61%	26.77%	25.02%	1.75%	12.52%	7.71%	4.81%
2019年 (至10.30)	23.17%	21.34%	29.45%	36.51%	-7.06%	4.46%	2.63%	1.83%

资料来源：Wind，长江证券研究所

请阅读最后评级说明和重要声明

18 / 24

图 25：采用 poly1_sizeSeg5 作为弱学习器的改进效果（单位净值曲线）



资料来源：Wind，长江证券研究所

多级集成


按照集成学习的思路，除了替换掉弱学习器以外，还可以将集成系统“变大”，下面我们展示一个更大的多级集成的例子。

上文中我们展示的是全局来说最好的弱学习器 poly1_sizeSeg5，但这是属于带有“前视偏差”（look-ahead bias）的结论，例如在 5 年前我们是无法得知哪种模型最好，从而无法“正确地”选择这一模型，也无法获得所展示的模型收益。

通常做法是通过当时的历史数据滚动选择最好的模型，图 26 是按照集成学习的思路设计的滚动选择模型的示意图。单因子分别训练了多种弱学习器，然后通过“best-out”方式集成，选择最好的模型，此处“best-out”是通过多元线性回归模型选择 t 值最大的模型输出。


对比全样本最好的弱学习器 poly1_sizeSeg5 的年化超额收益 24.19%、IR2.47，滚动选择弱学习器年化超额收益 23.90%、IR2.87，收益率与全样本最好的模型仅相差 0.29%，且 IR 更优，仅通过样本内滚动几乎达到全样本收益率是很不容易的。图 27 是滚动选择弱学习器后的净值曲线与中证 500 的比价。

图 26：滚动选择弱学习器



资料来源：长江证券研究所

图 27：滚动选择弱学习器的单位净值与中证 500 比价（2007.1.5 至 2019.10.30）




资料来源：长江证券研究所

请阅读最后评级说明和重要声明

20 / 24

另外，上文中 IC 加权时我们直接选择了用 12 个月的 IC 平均值。实际应用时，我们通常还会权衡用多长历史数据来计算 IC 均值，太短无法平滑因子收益的噪音波动，太长无法反应当前实际情况。图 28 是依据集成学习的思路，通过 12 个月和 60 个月的结果再次集成的示意图，集成方式依旧为线性回归。

图 28：多级集成



资料来源：长江证券研究所


表 5 为采用多级集成后的分年收益，图 29 是其单位净值曲线，图 30 为今年以来的单位净值曲线。对比标准流程年化超额收益 20.37%、IR2.47，多级集成相对中证 500 年化超额收益 26.73%、IR3.25，均有大幅提升。今年以来，多级集成超额收益 13.52%，标准流程下仅为 2.63%。

表 5：采用多级集成的改进效果（分年收益率）

	前5% (改进)	前5% (标准)	前5% - 后5% (改进)	前5% - 后5% (标准)	差异	前5% - 中证500 (改进)	前5% - 中证500 (标准)	差异
年化收益率	35.39%	29.03%	52.64%	45.57%	7.07%	26.73%	20.37%	6.36%
信息比率	--	--	4.13	3.54	0.59	3.25	2.47	0.78
2007年	237.63%	205.13%	158.01%	112.82%	45.19%	58.18%	25.68%	32.50%
2008年	-48.25%	-49.22%	22.99%	20.70%	2.29%	12.55%	11.58%	0.97%
2009年	200.86%	193.42%	112.30%	101.19%	11.11%	69.59%	62.15%	7.44%
2010年	30.70%	31.40%	25.20%	37.51%	-12.31%	20.64%	21.34%	-0.70%
2011年	-17.35%	-24.48%	29.14%	25.24%	3.90%	16.48%	9.35%	7.13%
2012年	15.13%	10.24%	34.34%	31.62%	2.72%	14.86%	9.96%	4.90%
2013年	47.17%	48.93%	46.97%	60.60%	-13.63%	30.29%	32.04%	-1.75%
2014年	56.13%	66.47%	45.93%	33.92%	12.01%	17.12%	27.46%	-10.34%
2015年	148.45%	119.73%	124.21%	102.24%	21.97%	105.33%	76.62%	28.71%
2016年	8.93%	5.76%	45.81%	33.74%	12.07%	26.70%	23.54%	3.16%
2017年	-0.02%	-9.47%	34.92%	28.15%	6.77%	0.18%	-9.26%	9.44%
2018年	-21.02%	-25.61%	33.40%	25.02%	8.38%	12.30%	7.71%	4.59%
2019年 (至10.30)	32.23%	21.34%	48.06%	36.51%	11.55%	13.52%	2.63%	10.89%


资料来源：Wind，长江证券研究所

图 29：多级集成的改进效果（单位净值曲线，2007.1.5 至 2019.10.30）



资料来源：Wind，长江证券研究所

图 30：多级集成的改进效果（单位净值曲线，2018.12.28 至 2019.10.30）



资料来源：Wind，长江证券研究所

总结

集成学习是把多个机器学习模型合并到一起的一套系统性方法，使多个“弱学习器”通过一定的方式“集成”为一个误差更小的“强学习器”，经典的集成学习方法有 Bagging、Boosting 和 Stacking 等。

传统因子选股也可以看成是一个集成学习模型。IC 计算可以看作是带数据预处理（取 zscore）的单变量一次函数模型；Rank IC 可以看作是带两步数据预处理（取排序、取 zscore）的单变量一次函数模型。因子间 IC、IC_IR 加权合成或因子间等权合成的方式都可以对应为一个两级 stacking 等权集成模型，第一级为各个日期截面上的一次函数模型的等权集成，第二级对应各个因子间的等权集成或加权集成。

沿着集成学习的概念可以对传统多因子模型进行改进。为描述选股因子的非线性现象，我们将弱学习器替换为 2 阶、3 阶多项式、分 5 段分段线性函数、系数按市值分 5 段或 10 段的 1 阶和 2 阶多项式。2011 年以前，线性弱学习器好于所有非线性弱学习器；2011 年至 2017 年部分非线性模型好于线性，部分与线性不相上下；2017 年以来，非线性模型普遍好于线性模型。因子收益越来越趋于非线性化。

按照集成学习的思路可以将集成系统“变大”。“多级集成”模型相对中证 500 年化超额收益 26.73%、IR3.25，而标准流程下的年化超额收益 20.37%、IR2.47，年化收益提升约 6.37%，IR 达到 3 以上。

投资评级说明

行业评级 报告发布日后的 12 个月内行业股票指数的涨跌幅相对同期相关证券市场代表性指数的涨跌幅为基准, 投资建议的评级标准为:

看 好:	相对表现优于同期相关证券市场代表性指数
中 性:	相对表现与同期相关证券市场代表性指数持平
看 淡:	相对表现弱于同期相关证券市场代表性指数

公司评级 报告发布日后的 12 个月内公司的涨跌幅相对同期相关证券市场代表性指数的涨跌幅为基准, 投资建议的评级标准为:

买 入:	相对同期相关证券市场代表性指数涨幅大于 10%
增 持:	相对同期相关证券市场代表性指数涨幅在 5%~10%之间
中 性:	相对同期相关证券市场代表性指数涨幅在-5%~5%之间
减 持:	相对同期相关证券市场代表性指数涨幅小于-5%

无投资评级: 由于我们无法获取必要的资料, 或者公司面临无法预见结果的重大不确定性事件, 或者其他原因, 致使我们无法给出明确的投资评级。

相关证券市场代表性指数说明: A 股市场以沪深 300 指数为基准; 新三板市场以三板成指 (针对协议转让标的) 或三板做市指数 (针对做市转让标的) 为基准; 香港市场以恒生指数为基准。

联系我们

上海

浦东新区世纪大道 1198 号世纪汇广场一座 29 层 (200122)

武汉

武汉市新华路特 8 号长江证券大厦 11 楼 (430015)

北京

西城区金融街 33 号通泰大厦 15 层 (100032)

深圳

深圳市福田区中心四路 1 号嘉里建设广场 3 期 36 楼 (518048)

分析师声明

作者具有中国证券业协会授予的证券投资咨询执业资格并注册为证券分析师, 以勤勉的职业态度, 独立、客观地出具本报告。分析逻辑基于作者的职业理解, 本报告清晰准确地反映了作者的研究观点。作者所得报酬的任何部分不曾与, 不与, 也不将与本报告中的具体推荐意见或观点而有直接或间接联系, 特此声明。

重要声明

长江证券股份有限公司具有证券投资咨询业务资格, 经营证券业务许可证编号: 10060000。

本报告仅限中国大陆地区发行, 仅供长江证券股份有限公司 (以下简称: 本公司) 的客户使用。本公司不会因接收人收到本报告而视其为客户。本报告的信息均来源于公开资料, 本公司对这些信息的准确性和完整性不作任何保证, 也不保证所包含信息和建议不发生任何变更。本公司已力求报告内容的客观、公正, 但文中的观点、结论和建议仅供参考, 不包含作者对证券价格涨跌或市场走势的确定性判断。报告中的信息或意见并不构成所述证券的买卖出价或征价, 投资者据此做出的任何投资决策与本公司和作者无关。

本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断, 本报告所指的证券或投资标的的价格、价值及投资收入可升可跌, 过往表现不应作为日后的表现依据; 在不同时期, 本公司可以发出其他与本报告所载信息不一致及有不同结论的报告; 本报告所反映研究人员的不同观点、见解及分析方法, 并不代表本公司或其他附属机构的立场; 本公司不保证本报告所含信息保持在最新状态。同时, 本公司对本报告所含信息可在不发出通知的情形下做出修改, 投资者应当自行关注相应的更新或修改。

本公司及作者在自身所知合规范围内, 与本报告中所评价或推荐的证券不存在法律法规要求披露或采取限制、静默措施的利益冲突。

本报告版权仅为本公司所有, 未经书面许可, 任何机构和个人不得以任何形式翻版、复制和发布。如引用须注明出处为长江证券研究所, 且不得对本报告进行有悖原意的引用、删节和修改。刊载或者转发本证券研究报告或者摘要的, 应当注明本报告的发布人和发布日期, 提示使用证券研究报告的风险。未经授权刊载或者转发本报告的, 本公司将保留向其追究法律责任的权利。